AI 금융경제

슬라이드별 학습 가이드

값싼 예측에서 레버리지 ETF까지

2026년 2학기

Contents

1 값싼 예측과 AI의 경제학 9

1.1 슬라이드 01 · 강좌의 지도 . . . 9
1.2 슬라이드 02 · 왜 금융에서 AI를 배우는가 . . . 9
1.3 슬라이드 03 · 주식 매수 질문에 빠진 변수들 . . . 9
1.4 슬라이드 04 · AI 충격과 한국 주식시장의 집중 . . . 10
1.5 슬라이드 05 · 값싼 예측의 경제학 . . . 10
1.6 슬라이드 06 · 세 명제의 연결 . . . 10
1.7 슬라이드 07 · 의사결정을 바꾸지 않는 신호의 가치는 0 . . . 11
1.8 슬라이드 08 · 지도와 압축 . . . 11
1.9 슬라이드 09 · 한 결정에 맞춰 만든 지도 . . . 12
1.10 슬라이드 10 · 공시에서 글자가 이미지일 때 . . . 12
1.11 슬라이드 11 · 빠른 요약과 정확한 요약의 선택 . . . 12
1.12 슬라이드 12 · 암달의 법칙과 업무 병목 . . . 13
1.13 슬라이드 13 · 영상의학 사례가 알려 주는 것 . . . 13
1.14 슬라이드 14 · 암달 곡선의 평탄해짐 . . . 13
1.15 슬라이드 15 · 과업 생산성과 총량 효과의 차이 . . . 14
1.16 슬라이드 16 · 싸진 예측이 재평가하는 것 . . . 14
1.17 슬라이드 17 · 제번스 역설의 그림 . . . 14
1.18 슬라이드 18 · 탄력성으로 보는 반등 . . . 14
1.19 슬라이드 19 · 기술과 직업의 역사 . . . 15
1.20 슬라이드 20 · 약한 고리와 GDP . . . 15
1.21 슬라이드 21 · 분석 가격이 내려갈 때 희소해지는 것 . . . 15
1.22 슬라이드 22 · 내 일의 위험을 평가하는 세 질문 . . . 16
1.23 슬라이드 23 · 데이터 모형에서 예측 모형으로 . . . 16
1.24 슬라이드 24 · 브라이먼의 두 문화 . . . 16
1.25 슬라이드 25 · 두 문화의 원문을 읽는 법 . . . 17
1.26 슬라이드 26 · 금융이 이론 중심 접근을 고수한 이유 . . . 17
1.27 슬라이드 27 · 요인모형의 언어 . . . 17
1.28 슬라이드 28 · 요인 동물원과 다중검정 . . . 18
1.29 슬라이드 29 · 머신러닝의 동일 경기장 . . . 18
1.30 슬라이드 30 · 작은 표본외 결정계수의 의미 . . . 18
1.31 슬라이드 31 · 공개된 예측 신호의 이익 감소 . . . 19
1.32 슬라이드 32 · 계산 규모와 사전 지식 . . . 19

1.33 슬라이드 33 · 이중 하강과 금융 데이터 19

2 금융 텍스트와 언어모형 20

2.1 슬라이드 01 · 텍스트를 금융 데이터로 읽기 20
2.2 슬라이드 02 · 사전에서 언어모형으로 20
2.3 슬라이드 03 · 사전 단어 세기의 함정 20
2.4 슬라이드 04 · 금융 전문 사전의 의미 21
2.5 슬라이드 05 · n그램과 부정 표현 21
2.6 슬라이드 06 · 임베딩은 무엇을 보존하는가 21
2.7 슬라이드 07 · 토큰과 입력의 비용 21
2.8 슬라이드 08 · 어텐션의 계산 22
2.9 슬라이드 09 · 다음 토큰 예측과 압축 22
2.10 슬라이드 10 · 유창한 실패의 출발점 23
2.11 슬라이드 11 · 생성모형의 목적 함수를 정확히 쓰기 23
2.12 슬라이드 12 · 목적 함수에 진실 항이 없다는 뜻 23
2.13 슬라이드 13 · 질문을 바꾸면 평가도 바뀐다 24
2.14 슬라이드 14 · 걸러낼 것이 없는 회사를 시험하기 24
2.15 슬라이드 15 · 모델의 국적을 성향으로 단정하지 않기 24
2.16 슬라이드 16 · 예상을 뒤집는 결과의 검증 24
2.17 슬라이드 17 · 지역 정보의 사각지대 25
2.18 슬라이드 18 · 기억과 진짜 사전 예측의 차이 25
2.19 슬라이드 19 · 모형의 투자 스타일 25
2.20 슬라이드 20 · 만족도 보상의 부작용 26
2.21 슬라이드 21 · 사후 분석과 인과 사슬 26
2.22 슬라이드 22 · 체스 에이전트 실험의 설계 26
2.23 슬라이드 23 · 목표 달성과 규칙 준수는 다른 변수 27
2.24 슬라이드 24 · 굿하트 법칙, 루커스 비판, 대리인 문제 27
2.25 슬라이드 25 · 환각을 과신으로 측정하기 27
2.26 슬라이드 26 · 저장된 지식과 인출의 병목 28
2.27 슬라이드 27 · 보이는 추론의 한계 28
2.28 슬라이드 28 · 다음 토큰 맞히기가 만드는 능력 28
2.29 슬라이드 29 · 산술은 외부 도구로 분리하기 29
2.30 슬라이드 30 · 유창함 대신 재현성을 기준으로 29

3 정규화 회귀와 수익률 예측 29

3.1 슬라이드 01 · 수익률 예측의 출발점 29

3.2 슬라이드 02 · 앞 장에서 이어지는 문제 30
3.3 슬라이드 03 · 시장 수익률 예측의 오래된 실패 30
3.4 슬라이드 04 · 평균보다 큰 변동성 30
3.5 슬라이드 05 · 예측변수 동물원 30
3.6 슬라이드 06 · 높은 배당수익률의 두 해석 31
3.7 슬라이드 07 · 자료를 잘게 나누어도 평균은 정밀해지지 않는다 31
3.8 슬라이드 08 · 단순수익률, 로그수익률, 연속복리 32
3.9 슬라이드 09 · 일별 자료의 다른 역할 32
3.10 슬라이드 10 · 표본 안의 유의성 33
3.11 슬라이드 11 · 표본내와 표본외를 구분하기 33
3.12 슬라이드 12 · 과거 평균과 표본외 결정계수 33
3.13 슬라이드 13 · 웰치와 고열의 판정 33
3.14 슬라이드 14 · 간단한 경제 제약은 도움이 될까 34
3.15 슬라이드 15 · 시간이 지난 뒤의 재검증 34
3.16 슬라이드 16 · 유의성·안정성·실용성의 깔때기 34
3.17 슬라이드 17 · 누적 오차 차이 그래프 읽기 35
3.18 슬라이드 18 · 첫 단계의 결론 35
3.19 슬라이드 19 · 왜 실패하는가 35
3.20 슬라이드 20 · 작은 참 신호의 규모 36
3.21 슬라이드 21 · 과적합 모의실험을 직접 구성하기 36
3.22 슬라이드 22 · 변수 증가와 벌점의 효과 36
3.23 슬라이드 23 · 차원이 커질 때 추정오차의 유도 36
3.24 슬라이드 24 · 편향과 분산을 식으로 분해하기 37
3.25 슬라이드 25 · 세 오차의 경제적 의미 37
3.26 슬라이드 26 · U자형 상충관계 37
3.27 슬라이드 27 · 공짜 점심이 없는 이유 38
3.28 슬라이드 28 · 금융 자료에 맞는 검증 38
3.29 슬라이드 29 · 편향을 의도적으로 쓰는 처방 38
3.30 슬라이드 30 · 첫 번째 처방으로 가기 39
3.31 슬라이드 31 · OLS의 역행렬이 불안정해지는 이유 39
3.32 슬라이드 32 · 능형회귀의 해를 직접 유도하기 39
3.33 슬라이드 33 · 두 변수로 보는 작은 분모 39
3.34 슬라이드 34 · 교점 그림의 해석 40
3.35 슬라이드 35 · 두 계수의 숫자 예 40
3.36 슬라이드 36 · 축소와 유효 자유도 40

3.37 슬라이드 37 · 제약식과 벌점식 41
3.38 슬라이드 38 · 계수 경로 읽기 41
3.39 슬라이드 39 · 표준화가 필수인 이유 41
3.40 슬라이드 40 · 편향된 추정기가 왜 이길 수 있는가 42
3.41 슬라이드 41 · 과거 수익률 357개로 다음 달을 예측하기 42
3.42 슬라이드 42 · 회귀계수에서 읽는 모멘텀과 반전 42
3.43 슬라이드 43 · 모의실험에서 벌점이 작동하는 방식 43
3.44 슬라이드 44 · 여기까지의 처방 43
3.45 슬라이드 45 · 변수 선택의 문제 43
3.46 슬라이드 46 · 제곱 벌점에서 절댓값 벌점으로 43
3.47 슬라이드 47 · 라쏘 목적함수 44
3.48 슬라이드 48 · 연성 임계값의 유도 44
3.49 슬라이드 49 · 마름모의 꼭짓점 44
3.50 슬라이드 50 · 라쏘 경로의 읽기 45
3.51 슬라이드 51 · 상관된 쌍둥이 변수 45
3.52 슬라이드 52 · 엘라스틱넷의 두 벌점 45
3.53 슬라이드 53 · 어떤 벌점이 맞는가 46
3.54 슬라이드 54 · 벌점 선택과 채점 46
3.55 슬라이드 55 · 하이퍼파라미터와 계수의 역할 46
3.56 슬라이드 56 · k겹 교차검증을 계산하기 46
3.57 슬라이드 57 · 금융 교차검증의 두 경고 47
3.58 슬라이드 58 · OLS, 능형, 라쏘의 결과 비교 47
3.59 슬라이드 59 · 예측 점수와 투자 성과가 다른 이유 47
3.60 슬라이드 60 · 시장 전체 예측으로 돌아오기 48
3.61 슬라이드 61 · 극단적 복잡성의 논쟁 48
3.62 슬라이드 62 · 수익률 예측에서 확립된 규칙 48

4 종목 간 기대수익률과 요인 논쟁 48

4.1 슬라이드 01 · 횡단면의 출발점 48
4.2 슬라이드 02 · 앞 장에서 건너오는 다리 49
4.3 슬라이드 03 · 요인 동물원의 네 질문 49
4.4 슬라이드 04 · 특성에서 전략으로 49
4.5 슬라이드 05 · 십분위 포트폴리오 정렬 49
4.6 슬라이드 06 · 파마·맥베스 회귀의 두 단계 50
4.7 슬라이드 07 · 높은 수익률과 이상현상의 차이 50

4.8 슬라이드 08 · 왜 월별 기울기의 표준오차를 쓰는가 51
4.9 슬라이드 09 · 여섯 범주의 지도 51
4.10 슬라이드 10 · 여섯 범주의 대표 신호 51
4.11 슬라이드 11 · 낮은 가격은 두 가지를 말한다 52
4.12 슬라이드 12 · 각 범주를 같은 질문으로 읽기 52
4.13 슬라이드 13 · 모멘텀의 위치 52
4.14 슬라이드 14 · 과거 승자가 계속 이기는가 53
4.15 슬라이드 15 · 모멘텀의 위험과 가격오류 설명 53
4.16 슬라이드 16 · 평균 모멘텀과 폭락 위험 53
4.17 슬라이드 17 · 가치와 성장의 구분 53
4.18 슬라이드 18 · 장부가치/시가총액으로 정렬하기 54
4.19 슬라이드 19 · 가치 프리미엄의 두 해석 54
4.20 슬라이드 20 · 가치 효과의 기간과 측정 54
4.21 슬라이드 21 · 투자와 수익성으로 넘어가기 55
4.22 슬라이드 22 · 빠른 자산 증가와 낮은 미래수익률 55
4.23 슬라이드 23 · 투자율과 할인율의 연결 55
4.24 슬라이드 24 · 수익성 높은 회사의 높은 수익률 56
4.25 슬라이드 25 · 수익성 효과의 항등식과 설명 56
4.26 슬라이드 26 · 두 자산가격 요인모형 56
4.27 슬라이드 27 · 무형자산의 회계 문제 56
4.28 슬라이드 28 · 장부 밖 투자와 비율의 왜곡 57
4.29 슬라이드 29 · 무형자산 프리미엄의 두 설명 57
4.30 슬라이드 30 · 낮은 범주 재현율을 해석하기 57
4.31 슬라이드 31 · 거래마찰은 가격과 비용을 함께 바꾼다 58
4.32 슬라이드 32 · 소형주와 비유동성 58
4.33 슬라이드 33 · 고유변동성과 단기 반전 58
4.34 슬라이드 34 · 거래마찰 범주의 재현 58
4.35 슬라이드 35 · 여섯 범주를 한꺼번에 비교하기 59
4.36 슬라이드 36 · 위험인가 가격오류인가 59
4.37 슬라이드 37 · 두 설명의 서로 다른 예측 59
4.38 슬라이드 38 · 지금까지의 가격 항등식 60
4.39 슬라이드 39 · 네 가지 구별 질문 60
4.40 슬라이드 40 · 판정표의 증거를 읽는 법 60
4.41 슬라이드 41 · 예측자와 설명자의 목표 60
4.42 슬라이드 42 · 투자 CAPM의 최적화 유도 61

4.43 슬라이드 43 · 특성과 공분산을 떼어 놓기 61
4.44 슬라이드 44 · 우연이라는 세 번째 설명 61
4.45 슬라이드 45 · t값 2의 의미가 바뀌는 순간 62
4.46 슬라이드 46 · 잡음 전략 300개의 모의실험 62
4.47 슬라이드 47 · 진짜 전략 10개를 섞었을 때 62
4.48 슬라이드 48 · 왜 새 요인에는 더 높은 기준이 필요한가 63
4.49 슬라이드 49 · 다중검정 규칙의 단계별 계산 63
4.50 슬라이드 50 · 재현 논쟁의 질문 64
4.51 슬라이드 51 · 많은 이상현상이 실패한다는 결과 64
4.52 슬라이드 52 · 많은 요인이 재현된다는 결과 64
4.53 슬라이드 53 · 왜 판정이 갈리는가 65
4.54 슬라이드 54 · 한 요인의 베이지안 축소를 유도하기 65
4.55 슬라이드 55 · 주제별 정보를 함께 쓰기 65
4.56 슬라이드 56 · 사후 판정과 82%의 해석 66
4.57 슬라이드 57 · 발표 뒤 수익의 감소 66
4.58 슬라이드 58 · 새 요인의 올바른 검정 66
4.59 슬라이드 59 · 선택된 통제만 넣을 때의 편향 66
4.60 슬라이드 60 · 새 요인 15개의 비교 67
4.61 슬라이드 61 · 이중 선택의 세 단계 67
4.62 슬라이드 62 · 다음 문제의 문턱 68
4.63 슬라이드 63 · 요인 논쟁을 예측 문제로 다시 쓰기 68
4.64 슬라이드 64 · 이미 시도한 정규화의 교훈 68
4.65 슬라이드 65 · 횡단면 연구의 결론 68

5 레버리지 ETF와 시장 미시구조 69

5.1 슬라이드 01 · 레버리지 ETF를 읽는 세 가지 질문 69
5.2 슬라이드 02 · 반도체 호황은 왜 출발점인가 69
5.3 슬라이드 03 · 7월 급락과 책임론을 분리해서 보기 69
5.4 슬라이드 04 · 시장 충격에 관한 주장과 검증 69
5.5 슬라이드 05 · 경제학적 질문의 범위 70
5.6 슬라이드 06 · 10년 수익률이 단순 배수와 다른 까닭 70
5.7 슬라이드 07 · 다섯 단계의 연결 70
5.8 슬라이드 08 · ETF의 두 시장 70
5.9 슬라이드 09 · NAV와 시장가격의 단위 71
5.10 슬라이드 10 · AP, LP, 설정 단위 71

5.11 슬라이드 11 · 주식처럼 거래되는 펀드 71
5.12 슬라이드 12 · 누가 누구와 거래하는가 71
5.13 슬라이드 13 · 차익거래가 NAV에 가격을 묶는 방식 72
5.14 슬라이드 14 · KODEX 200 설정 단위 계산 72
5.15 슬라이드 15 · 한국의 AP와 LP가 연결되는 순서 72
5.16 슬라이드 16 · 프리미엄과 디스카운트 읽기 73
5.17 슬라이드 17 · LP의 호가와 종가 괴리 의무 73
5.18 슬라이드 18 · 괴리 공시와 투자유의의 단계 73
5.19 슬라이드 19 · 일일 리밸런싱의 출발점 73
5.20 슬라이드 20 · 미국 상품의 배수와 기초자산 74
5.21 슬라이드 21 · 국내 상품과 미국 상품의 비교 단위 74
5.22 슬라이드 22 · 단일종목 ETF와 신규 시장 74
5.23 슬라이드 23 · +2배와 -2배가 같은 방향으로 거래하는 이유 75
5.24 슬라이드 24 · 거래식 L(L-1)Ar의 유도 75
5.25 슬라이드 25 · 지정가 주문과 역방향 자금 흐름 75
5.26 슬라이드 26 · 순설정 F를 포함한 거래식 76
5.27 슬라이드 27 · 한 식에서 두 효과가 나온다 76
5.28 슬라이드 28 · '음의 복리'를 정확히 해석하기 76
5.29 슬라이드 29 · 이틀 경로를 직접 곱해 보기 76
5.30 슬라이드 30 · 일일 재설정과 매수후보유의 정확한 차이 77
5.31 슬라이드 31 · 거래액 20이 만드는 +2 또는 -2 77
5.32 슬라이드 32 · 왕복 변동의 정확한 손실 77
5.33 슬라이드 33 · T일 곱을 2차 항까지 전개 77
5.34 슬라이드 34 · 볼록성과 변동성 항의 분해 78
5.35 슬라이드 35 · 끝점과 경로를 따로 보기 78
5.36 슬라이드 36 · SK하이닉스 사례를 분해하는 방법 78
5.37 슬라이드 37 · 수익률만으로 위험을 평가할 수 없는 이유 79
5.38 슬라이드 38 · 같은 상품의 일간과 1년 샤프비율 79
5.39 슬라이드 39 · 샤프비율의 분자와 분모 79
5.40 슬라이드 40 · 하루에는 왜 샤프가 같나 79
5.41 슬라이드 41 · 보유기간을 늘리면 분포가 바뀐다 80
5.42 슬라이드 42 · T일 복리수익률의 평균과 분산 유도 80
5.43 슬라이드 43 · 샤프가 투자 선택의 전부인가 80
5.44 슬라이드 44 · 자본시장선 CML의 기울기 80
5.45 슬라이드 45 · 현실의 차입금리가 선을 꺾는다 81

5.46 슬라이드 46 · 자산군 샤프비율의 표본 의존성 81
5.47 슬라이드 47 · 내재 레버리지 상품과 개인 차입의 비교 81
5.48 슬라이드 48 · 투자자 계좌에서 사라지는 마진콜 81
5.49 슬라이드 49 · 3배 노출의 두 가격표 82
5.50 슬라이드 50 · 차입 제약과 betting against beta 82
5.51 슬라이드 51 · 강한 추세가 TQQQ에 유리했던 기간 82
5.52 슬라이드 52 · 로그 성장률에서 변동성이 제곱으로 작용한다 83
5.53 슬라이드 53 · 성장률을 최대로 하는 배수 83
5.54 슬라이드 54 · QQQ, 이상적 3배, 실제 TQQQ 83
5.55 슬라이드 55 · 펀드의 매매와 시장가격의 인과관계 83
5.56 슬라이드 56 · 변동성 증폭 가설의 정확한 내용 84
5.57 슬라이드 57 · 종가 거래량을 원화로 계산하기 84
5.58 슬라이드 58 · 상쇄 흐름과 예측된 주문 84
5.59 슬라이드 59 · 역인과와 공통 충격 84
5.60 슬라이드 60 · 마지막 30분 분산 비중의 의미와 한계 85
5.61 슬라이드 61 · 더 읽을 자료와 검증의 순서 85

1 값싼 예측과 AI의 경제학

인공지능을 금융에 적용한다는 말은 먼저 **어떤 정보를 얻어 어떤 선택을 바꾸는가**를 묻는 일이다. 예측의 가치는 그 예측으로 피할 손실과 새로 얻을 편익으로 측정한다. 이 장은 예측의 경제학에서 과업의 보완관계, 가격 조정, 자산가격 예측으로 이어진다. 수학에서 필요한 것은 조건부기대값, 탄력성, 회귀의 기초이며, 각각을 아래에서 다시 정의한다.

1.1 슬라이드 01 · 강좌의 지도

금융에서 AI는 공시 읽기, 신용심사, 거래, 위험관리처럼 다양한 일에 쓰인다. 공통 질문은 **미래를 더 잘 예측하면 현재의 선택과 결과가 어떻게 달라지는가**다. 다음 분기 매출을 맞혀도 주가에 이미 반영된 전망과 거래비용을 고려해야 매수 여부를 정할 수 있다.

각 사례에서 **입력 시점 → 예측값 → 행동 규칙 → 비교 대상**을 순서대로 적어 보자. 월요일 개장 전 공개된 공시로 다음 한 달의 초과수익률을 추정한다면, 예측값이 거래비용과 요구 위험보상을 넘을 때 주문하고 같은 위험의 기준 포트폴리오와 성과를 비교한다. 보유 현금과 위험한도가 달라지면 같은 예측값도 다른 주문량으로 이어진다. 네 요소를 사전에 고정해야 모형의 개선을 평가할 수 있다.

1.2 슬라이드 02 · 왜 금융에서 AI를 배우는가

금융의 입력은 공시, 뉴스, 가격, 재무제표처럼 풍부하지만 목표인 **미래 초과수익률**은 매우 시끄럽다. 같은 기술이라도 영수증 분류에서는 높은 정확도가 곧 생산성으로 이어질 수 있지만, 투자에서는 작은 예측 오차가 큰 손실로 번진다.

금융 수익률은 기업 실적뿐 아니라 금리, 유동성, 투자자 기대가 동시에 움직인 결과다. 예측 모형이 기업의 실적을 잘 맞혀도 시장이 이미 그 정보를 가격에 넣었다면 투자수익은 늘지 않는다. **실적 예측 오차**와 **가격 대비 초과수익 예측 오차**를 별도로 기록해야 하는 이유가 여기에 있다.

가격은 이미 시장 참가자의 전망을 압축한 기준선이다. 매출 증가 확률을 70%로 예측했더라도 현재 가격이 그보다 더 낙관적인 전망을 반영한다면 매수 근거가 약하다. 반대로 확률 추정의 절대 정확도가 평범해도 시장 가격이 특정 위험을 과소평가했다면 유용할 수 있다. 그러므로 모형과 가격이 각각 **무엇을 예상하는지** 같은 단위로 비교해야 한다.

1.3 슬라이드 03 · 주식 매수 질문에 빠진 변수들

"삼성전자를 지금 사도 되는가"라는 질문은 답을 하나로 정할 수 없다. 투자 기간, 이미 가진 종목, 손실 감내 범위, 세금과 수수료가 빠졌기 때문이다. 같은 전망을 가진 두 사람도 현재 포트폴리오가 다르면 최적 행동이 다르다.

먼저 가능한 행동 a를 매수·보유처럼 정하고, 미래 상태 s마다 그 행동의 결과를 효용 $U(a,s)$로 평가한다. 효용은 돈의 액수와 같을 수도 있지만 위험을 싫어한다면 같은 금액의 이익과 손실을 다르게 평가할 수 있다. 상태 확률 $p(s)$로 효용을 가중해 더한 **기대효용**이 가장 큰 행동이 $a^* = \arg\max_a \sum_s p(s)U(a,s)$다. 여기서 arg max는 최대 기대효용의 값이 아니라 그 값을 만드는 **행동**을 돌려준다. AI의 예측은 주로 $p(s)$를 바꾸며, 목표와 투자 제약은 따로 정해야 한다.

효용식에 수치를 넣으면 결정 기준이 드러난다. 1만 원을 투자해 상승 시 2천 원을 얻고 하락 시 3천 원을 잃으며 두 상태만 가능하다면, 위험중립 투자자의 기대순이익은 $2{,}000p - 3{,}000(1-p) =$

$5{,}000p - 3{,}000$원이다. 거래비용이 없다면 $p > 0.6$에서만 매수한다. 상승 확률 60%는 정확히 무차별인 경계이고, 수수료나 위험 회피가 있으면 필요한 확률은 더 높아진다.

질문: 매매비용 100원이 추가되면 매수 확률 경계는? 기대순이익에서 100원을 빼면 $5{,}000p - 3{,}100$원입니다. 위험중립 투자자는 $p > 0.62$일 때 매수합니다. 비용이 커질수록 필요한 예측 확률도 높아집니다.

1.4 슬라이드 04 · AI 충격과 한국 주식시장의 집중

한국 주가지수는 시가총액 가중이므로 소수 반도체 대형주의 변동이 지수 전체에 크게 반영된다. 미국의 장기금리 상승은 먼 미래의 이익을 현재가치로 환산하는 할인율을 높이고, AI 투자 수익성에 대한 의문은 예상 현금흐름을 낮출 수 있다. 두 힘이 동시에 작용하면 관련 기업의 가격은 더 민감하게 움직인다.

AI 기업 사이의 투자·클라우드 구매·반도체 공급 계약은 서로의 매출을 키우지만 현금흐름의 독립성을 보장하지 않는다. 한 고리의 투자 축소가 다른 고리의 매출 전망을 낮추는 **공통 위험**이 될 수 있다. 단순한 "AI 수혜주" 분류보다 자금의 출처와 최종 고객 수요를 추적해야 한다.

시가총액 가중지수에서 기업 i의 단순 기여는 대략 지수 내 비중 w_i와 그 기업 수익률 r_i의 곱 $w_i r_i$다. 비중이 큰 기업의 작은 하락도 여러 소형주의 상승을 덮을 수 있다. 이때 지수 하락을 곧바로 '모든 산업의 AI 전망 악화'로 읽지 말고, 기업별 기여도와 공통 금리 충격을 분리하자.

비중 20%인 종목이 5% 하락하고 나머지 80%의 가중평균 수익률이 0.5% 상승하면, 단순한 한 기간 지수 수익률은 $0.2(-5\%) + 0.8(0.5\%) = -0.6\%$다. 다수 종목이 올라도 지수는 떨어진다. 다만 이 계산은 구성 비중을 기간 시작 시점에 고정한 일차 근사다. 원인을 찾으려면 금리·환율 같은 공통 충격과 기업별 현금흐름 뉴스를 따로 검토해야 한다.

1.5 슬라이드 05 · 값싼 예측의 경제학

예측은 아직 관찰하지 못한 값을 현재 정보로 추정하는 것이다. 비용이 내려가면 기업은 예전에는 예측 문제로 보지 않았던 업무까지 예측 가능한 조각으로 분해한다. 대출 심사에서는 "상환할까"뿐 아니라 "어떤 추가 서류가 판정을 바꿀까"도 예측 대상이 된다.

가격이 떨어진 재화의 사용량이 늘고, 함께 쓰는 보완재의 가치가 바뀐다는 미시경제학을 그대로 적용할 수 있다. 데이터 품질, 손실함수의 설계, 행동할 권한이 대표적인 보완재다. Prediction Machines[1]의 관점은 AI를 만능 지능으로 부르기보다 어떤 투입의 가격이 내려갔는지 묻게 한다.

예측의 수요는 예측 자체보다 **뒤따르는 행동의 손익**에서 나온다. 한 대출의 정상 상환 시 순이익이 10만 원이고 연체 시 손실이 90만 원이라면 기대순이익은 $(1-p)10 - p90 = 10 - 100p$만 원이어서 위험중립 기준 승인 경계는 $p = 10\%$다. 연체확률 추정치를 2%에서 1%로 고쳐도 결정은 그대로지만, 11%에서 9%로 고치면 승인 여부가 바뀐다. 자본규제와 간접비를 넣으면 실제 경계는 달라진다.

1.6 슬라이드 06 · 세 명제의 연결

첫째, 예측은 결정을 바꾸어야 가치가 있다. 둘째, 그 결정이 실제 결과로 이어지려면 업무의 다른 단계가 따라와야 한다. 셋째, 예측 비용이 충분히 내려가면 고객의 수요와 관련 노동·데이터의 가격이 조정된다.

[1] https://www.predictionmachines.ai/

세 명제는 개인의 선택, 기업의 생산과정, 시장 균형이라는 서로 다른 분석 수준이다. 한 건의 예측 성능을 기업의 총산출이나 시장 전체 편익으로 옮기려면 각 수준의 제약과 가격 변화를 계산해야 한다.

세 수준을 연결하는 간단한 장부를 만들 수 있다. 개인 수준에서 한 건당 절감액이 v, 기업이 처리하는 건수가 q라면 직접 편익은 vq다. 그러나 도입 비용과 검토 인력이 필요하고, 시장에 서비스가 늘면 가격과 q 자체가 바뀐다. 한 건의 실험 효과를 전체 산업의 편익으로 곱할 때 이 변화를 빠뜨리지 않아야 한다.

예를 들어 분석 한 건에서 1만 원을 아껴도 승인 단계가 연간 1천 건으로 고정되어 있다면 직접 비용 절감은 최대 1천만 원이다. AI 덕분에 분석 가능한 후보가 1만 건으로 늘어도 승인 용량이 그대로라면 승인된 대출 수는 자동으로 늘지 않는다. 승인 인력이나 규칙을 바꾸어 용량이 커진 다음에는 수요와 부실 위험까지 새로 계산해야 한다.

1.7 슬라이드 07 · 의사결정을 바꾸지 않는 신호의 가치는 0

아직 신호 z를 보지 못하면 모든 상태에 대해 하나의 행동을 정해야 한다. 이때 최선의 기대효용은 $V_0 = \max_a E[U(a,s)]$다. 신호를 본 뒤에는 z에 따라 상태확률을 갱신하고, **신호마다** 가장 나은 행동을 고를 수 있다. 각 신호가 나올 확률로 그 결과를 평균한 값은 $V_1 = E_z[\max_a E[U(a,s) \mid z]]$다. max가 E_z의 안쪽에 있는 이유는 신호를 보고 행동을 바꿀 수 있기 때문이다. 원래 행동을 유지할 수도 있으므로 $V_1 \geq V_0$이고, 정보의 가치는 $V_1 - V_0$이다.

두 신호의 정답률이 달라도 최적 행동이 늘 같다면 행동 가치의 차이는 없다. 예컨대 투자 허용 범위가 너무 좁아 어떤 신호에도 같은 보유량을 유지한다면 더 정밀한 수익률 전망의 즉각적 가치는 0이다. 반대로 드문 파산을 맞히는 신호는 전체 정확도가 낮아도 큰 손실을 피하게 해 가치가 클 수 있다. 이는 Blackwell의 정보 비교[2]를 금융 의사결정에 적용한 것이다.

신호 구매료가 c라면 순가치는 $V_1 - V_0 - c$다.

두 상태의 수치 예시를 보자. 매수하면 상승 시 $+2$, 하락 시 -3이고 보유하지 않으면 0이며, 사전 상승확률은 50%다. 매수의 기대값 $0.5(2) + 0.5(-3) = -0.5$이므로 원래는 매수하지 않는다. 신호가 '좋음'과 '나쁨'을 각각 절반의 확률로 내고, 그 조건부 상승확률이 각각 80%와 20%라면 좋을 때 매수의 기대값은 $0.8(2) + 0.2(-3) = 1$, 나쁠 때는 음수다. 신호를 보고 좋을 때만 사는 가치 $V_1 = 0.5(1) = 0.5$다. 이 값보다 신호 구매료가 높으면 사용하지 않는다.

1.8 슬라이드 08 · 지도와 압축

추상화는 정보를 버리는 일이다. 피카소의 황소 그림은 세부 묘사를 지우면서도 황소를 알아볼 특징을 남긴다. 지하철 노선도는 실제 거리와 방향을 왜곡해 환승 경로를 읽기 쉽게 한다.

좋은 압축은 **목표 결정에 필요한 차이**를 보존한다. 지하철 지도는 환승 경로에는 유용하지만 도보 시간에는 부정확할 수 있다. 금융 모형도 투자 손익을 좌우하는 꼬리위험과 발표 시점은 남겨야 한다.

두 회사의 실적을 모두 '순이익 20% 증가'로 압축해 보자. A는 본업의 반복 수익, B는 일회성 자산 매각 덕분이라면 내년 현금흐름 전망이 달라진다. 투자 결정을 위한 요약에는 이 차이가 남아야 한다. 과거 순이익 증가 여부만 분류한다면 같은 요약으로 충분하다. **좋은 압축의 기준은 사용할 결정**이 정한다.

[2] https://doi.org/10.1214/aoms/1177729032

1.9 슬라이드 09 · 한 결정에 맞춰 만든 지도

현실 x를 표현 $z = f(x)$로 압축하고 예측 $\hat{y} = g(z)$에 따라 행동 $a = h(\hat{y})$을 고른다고 하자. 같은 z를 가진 두 원문이 서로 다른 최적 행동을 요구한다면, 예측 모형을 아무리 개선해도 압축 단계에서 버린 정보는 복원하기 어렵다.

거대언어모형은 학습자료의 패턴을 압축해 답을 생성한다. 금융에서는 문장 요약의 매끄러움보다 의사결정에 필요한 수치, 부정문, 예외 조항, 기준일을 유지하는지가 중요하다. 공시의 "일회성 이익" 한 단어가 사라지면 이익의 지속성 평가가 달라진다.

계약금액, 종료일, 해지 조건, 연결대상 여부를 표로 추출하고 원문 위치를 붙이면 요약의 정확성을 항목별로 검증할 수 있다. 잘 읽히는 문장과 투자 판단에 충분한 기록을 각각 평가하는 방법이다.

결정에 충분한 표현은 같은 z로 압축된 원문들에서 가능한 행동의 기대손익 순위가 유지되어야 한다. 이는 모수 추정을 위한 충분통계량과 목적이 다르다. 손실이 큰 예외 조항 때문에 행동의 순위가 바뀌는 오류를 평균 정확도와 별도로 추적하면 압축의 약점을 찾을 수 있다.

1.10 슬라이드 10 · 공시에서 글자가 이미지일 때

문자 검색은 텍스트 층에 존재하는 글자를 찾는다. 실적 발표의 핵심 문단이 그림으로 삽입되면 사람이 보기에는 같은 문장이지만 기계의 단순 검색에서는 사라질 수 있다. 멀티모달 인식은 이미지의 글자를 읽어 이런 누락을 줄인다.

이미지에서 숫자를 추출한 뒤에는 회계적 의미와 투자 가치를 평가한다. 자산 매각 이익이 반복 가능한지, 현금 유입인지, 주가에 이미 반영됐는지는 원문 숫자만으로 결정되지 않는다.

OCR이 재무제표의 '(1,000)'을 '1,000'으로 읽으면 손실의 부호가 뒤집힌다. '1,000'의 단위를 원에서 백만 원으로 읽으면 금액은 백만 배 달라진다. 표의 행·열 제목과 회계기간까지 바뀌면 전년 대비 증가율도 거꾸로 계산된다. 값마다 원본 위치·단위·기간·부호를 저장하고, (당기 − 전기)/|전기|처럼 후속 계산을 정의해야 오류를 추적할 수 있다.

1.11 슬라이드 11 · 빠른 요약과 정확한 요약의 선택

분석가가 3일 걸려 오류율 1%인 결과를 내고 AI가 10초 걸려 오류율 5%인 결과를 낸다고 하자. "어느 쪽이 좋은가"는 오류 하나의 비용, 마감 시각, 사람이 후속 검토할 수 있는지에 달려 있다. 단순히 속도나 정확도 한 숫자로 고르지 않는다.

오류의 평균 비용을 L, 지연 비용을 D라 하면 총 기대비용의 단순형은 $C = p_{\text{err}} L + D$다. 중요한 공시를 잘못 읽어 큰 주문을 넣는 경우에는 L이 커서 검토 단계가 가치 있다. 반면 수천 개 문서에서 검토 후보만 찾는 1차 선별에는 빠른 도구가 유리할 수 있다.

사람의 확인이 오류 확률을 q에서 q'로 낮추고 오류 시 손실이 L, 확인 비용이 c라면 기대 순편익은 $(q - q')L - c$다. 오류 확률이 5%에서 1%로 줄고 오류 손실이 100만 원이면 기대손실은 4만 원 감소한다. 확인 비용이 2만 원이면 순편익은 2만 원이다. 이 판단에 쓰는 오류 확률은 별도 검증자료에서 확인해야 한다. 예를 들어 '95% 확신' 사례의 실제 오류율이 약 5%여야 그 숫자를 비용 계산에 쓸 수 있다.

1.12 슬라이드 12 · 암달의 법칙과 업무 병목

암달의 법칙(Amdahl's law)을 적용해 전체 처리시간을 1로 정규화하고, 자동화 가능한 부분이 p, 그 부분의 속도가 s배가 된다고 하자. 새 시간은 자동화하지 못한 $1-p$와 빨라진 p/s의 합이다. 따라서 전체 속도 증가는 다음과 같다.

$$S = \frac{1}{(1-p) + p/s}.$$

식의 분모를 직접 대입해 보자. 원래 100시간 중 30시간이 자동화 대상이고 이를 5배 빠르게 하면 새 총시간은 $70 + 30/5 = 76$시간, 속도는 $100/76 \approx 1.32$배다. '대상 과업이 5배 빨라졌다'와 '전체가 5배 빨라졌다'는 전혀 다르다. 새 병목인 70시간을 줄여야 다음 개선이 커진다.

$s \to \infty$일 때 전체 속도의 상한은 $1/(1-p)$다. 자동화 대상이 총시간의 30%라면 도구가 아무리 빨라져도 나머지 70%가 속도를 제한한다.

이 법칙은 **같은 작업량을 순서대로 처리하고**, 개선되지 않은 단계의 시간이 일정할 때 성립한다. 자동화 후 주문 후보가 더 많이 들어오거나 여러 업무가 병렬로 돌면 전체 처리량을 단순히 S배 할 수 없다. 특히 하루 승인 건수처럼 용량 제약을 묻는다면 작업 한 건의 소요시간과 대기열에 쌓이는 건수를 분리해 계산해야 한다.

1.13 슬라이드 13 · 영상의학 사례가 알려 주는 것

의사의 업무에는 영상 판독과 환자 상담, 협업, 시술, 법적 책임이 함께 있다. AI가 판독 시간을 줄이면 한 건당 필요한 사람의 시간과 검사 수요가 함께 변한다.

검사비가 낮아져 검사량이 늘면 상담·설명·후속 치료도 늘 수 있다. 고용 변화를 판단할 때는 한 건당 인력 절감률과 검사량 증가율을 같은 기간에 비교한다. 인구 고령화, 의료 수가, 양성 정원과 규제도 함께 바뀌므로 관찰된 고용 변화 전체를 AI의 효과로 돌릴 수는 없다.

필요한 총 노동시간을 $H = hQ$로 쓰면 h는 검사 한 건에 들어가는 사람의 시간, Q는 검사 건수다. AI로 h가 20% 줄고 Q가 10% 늘면 새 총시간은 $0.8 \times 1.1 = 0.88$배다. 검사량이 40% 늘면 $0.8 \times 1.4 = 1.12$배다. 이 산술은 고용의 가능한 방향을 보여 줄 뿐이고, 실제 인원은 근무시간 조정과 직무 재편에 따라 다시 달라진다.

1.14 슬라이드 14 · 암달 곡선의 평탄해짐

$p = 0.5$이면 자동화 부분을 무한히 빠르게 해도 전체는 최대 2배이고, $p = 0.9$라면 최대 10배다. 어느 단계가 전체 시간에서 큰 비중을 차지하는지에 따라 같은 도구의 효과가 달라진다.

거래 시스템에서 뉴스 분류를 빨리 해도 주문 한도 승인이나 결제 통제가 그대로면 총 처리량은 제한된다. 개선 전후에 각 단계의 소요시간을 재면 새 병목이 어디로 옮겨 갔는지 확인할 수 있다.

$S(s) = 1/(1-p+p/s)$를 s로 미분하면 $dS/ds = (p/s^2)/(1-p+p/s)^2 = p/[(1-p)s+p]^2 > 0$이다. $0 < p < 1$이면 분모가 s와 함께 커져 추가 개선은 작아진다. 이는 '더 큰 모형'에 투자할지 남아 있는 검토·집행 단계에 투자할지 고르는 기준이 된다.

예를 들어 $p = 0.5$이면 $s = 2$에서 전체 속도는 $1/(0.5+0.25) = 1.33$배, $s = 10$에서 $1/(0.5+0.05) = 1.82$배다. 자동화 부분을 2배에서 10배로 다섯 배 더 빠르게 해도 전체 증가는 약 0.49배에 그친다. $p = 1$이라면 남은 병목이 없으므로 $S = s$이고 이 평탄화 논리는 적용되지 않는다.

1.15 슬라이드 15 · 과업 생산성과 총량 효과의 차이

고객상담, 글쓰기, 소프트웨어 개발 같은 개별 과업에서 AI가 시간을 줄인다는 실험은 중요하다. 그러나 임금·고용·GDP는 기업의 도입률, 품질 검토, 수요 증가, 가격 하락, 다른 과업으로의 재배치가 합쳐진 균형 결과다. 개별 과업의 처리속도 증가를 총량 생산성 증가와 동일시할 수 없다.

측정에도 시차가 있다. 초기에는 설치·학습·프로세스 재설계 비용이 들고, 나중에야 보완투자가 이루어진다. 반대로 총량 지표에 변화가 아직 작다고 해서 미시적 편익이 없다는 뜻도 아니다. 생성형 AI와 상담 생산성 연구[3]는 과업 수준의 비교에 유용하다.

과업의 시간 비중, 기업의 도입률, 절감된 시간이 새 산출로 전환되는 비율이 총량 효과를 결정한다. 전체 노동시간의 10%를 차지하는 과업에서 시간을 40% 아끼고 기업의 절반이 도입했다면, 산출량이 고정된 상태에서 평균 노동시간의 직접 절감은 $0.1 \times 0.4 \times 0.5 = 0.02$, 즉 2%다. GDP 효과는 절감된 시간을 어디에 쓰는지, 산출 품질과 자본 투입이 어떻게 변하는지에 따라 달라진다.

1.16 슬라이드 16 · 싸진 예측이 재평가하는 것

예측 서비스의 한계비용이 내려가면 고객은 같은 예산으로 더 많은 예측을 이용할 수 있다. 이때 예측과 함께 쓰는 데이터·판단·집행 능력의 수요도 변한다. 그 가치가 누구에게 돌아가는지는 각 투입의 희소성과 공급 탄력성에 달려 있다.

노동은 한 덩어리가 아니다. 자동화된 과업을 많이 수행하는 노동과 예측을 해석·책임지는 노동은 보완 또는 대체 관계가 다르다. 따라서 "AI가 임금을 올린다/내린다"보다 어떤 과업의 수요가 늘고 공급이 얼마나 빨리 따라오는지 묻는 편이 정확하다.

예측과 사람의 예외 판단이 보완재라면 예측 가격 하락은 예외 판단의 **수요곡선**을 오른쪽으로 옮긴다. 판단 인력을 빠르게 양성할 수 있으면 고용량이 주로 늘고, 공급이 단기에 고정되어 있으면 임금이 더 오른다. 고유 데이터를 가진 기업이 모방을 막을 수 있다면 잉여를 얻지만, 정보가 표준화되어 쉽게 이동하면 경쟁을 통해 고객에게 편익이 돌아간다.

1.17 슬라이드 17 · 제번스 역설의 그림

에너지 효율이 개선되면 같은 이동 거리의 연료비가 내려간다. 비용이 낮아져 주행거리가 늘 수 있으므로 차량 한 대의 효율과 사회 전체의 연료 사용량은 반대 방향으로 움직일 수 있다. 그림의 혼잡한 도로는 **단위당 투입 감소와 총투입 증가가 양립**하는 경우를 보여 준다.

한 건의 자원투입을 e, 처리 건수를 Q라 두면 총투입은 $E = eQ$다. 효율 개선으로 건당 자원투입이 원래의 k배$(0 < k < 1)$가 되면, 건수가 $1/k$배를 **넘을 때** 총투입이 증가한다. 분석 시간이 10분에서 2분으로 줄었다면 건수 3배에서는 총시간이 0.6배, 8배에서는 1.6배가 된다. 건수가 정확히 5배면 총시간은 그대로다.

1.18 슬라이드 18 · 탄력성으로 보는 반등

앞 슬라이드의 총자원 항등식 $E = eQ$에서 e는 서비스 한 건당 자원, Q는 이용 건수다. 곱의 로그를 취하면 $\ln E = \ln e + \ln Q$이므로 작은 변화에 대해 $d\ln E = d\ln e + d\ln Q$다. 로그 변화는 퍼센트 변화에 가깝다. 서비스 가격 P가 내려갈 때 수요가 얼마나 늘어나는지는 양수로 정의한 가격탄력성 $\varepsilon = -d\ln Q / d\ln P$로 나타낸다. 건당 자원 e와 가격 P가 같은 비율로 낮아진다면 $d\ln e = d\ln P < 0$이고, 따라서 $d\ln E = (1-\varepsilon) d\ln P$다.

[3] https://doi.org/10.1093/qje/qjae044

$\varepsilon > 1$이면 $d\ln P < 0$에 대해 $d\ln E > 0$가 되어 반등이 효율 절감을 넘어선다. 의료영상 검사가 저렴해지면 검사 대상을 넓힐 수 있지만, 보험 규칙과 진료 지침이 수요를 제한할 수도 있다. 탄력성은 사례마다 추정해야 한다.

건당 자원과 서비스 가격이 같은 비율로 변한다는 가정은 전력 외의 인력·저장비용이나 가격 전가율이 달라지면 깨진다. 작은 변화의 미분식을 큰 시장 변화에 적용할 때는 탄력성이 일정한지도 확인해야 한다.

일정한 탄력성이라는 강한 가정 아래서는 유한한 변화도 계산할 수 있다. 가격과 건당 자원 투입이 모두 원래의 k배가 되고 $Q \propto P^{-\varepsilon}$이면 $Q_{\text{new}}/Q_{\text{old}} = k^{-\varepsilon}$, $E_{\text{new}}/E_{\text{old}} = k^{1-\varepsilon}$다. $k = 0.5$, $\varepsilon = 1.5$라면 총자원은 $0.5^{-0.5} = \sqrt{2}$배가 된다. 이 식은 가격 전가가 불완전하면 그대로 사용할 수 없다.

역사적으로 효율 개선과 총 연료사용 증가가 함께 나타나도 인구·소득·산업 규모가 동시에 바뀌었다면 그 숫자만으로 가격탄력성을 추정할 수 없다. 반등의 크기에는 가격 변화가 없었을 때의 사용량이라는 반사실이 필요하다.

1.19 슬라이드 19 · 기술과 직업의 역사

증기기관, ATM, 스프레드시트는 모두 한 과업의 비용을 낮췄다. 은행 창구에서는 현금 인출 업무가 줄어도 지점 운영과 고객 상담의 상대적 중요성이 커질 수 있었다. 회계에서는 계산 자동화와 함께 감사·해석 업무가 늘었다.

과거 사례에서는 직업명보다 **어떤 과업이 줄고 남은 서비스의 수요가 얼마나 늘었는지**를 봐야 한다. ATM 도입 뒤 창구 인원이 늘었다 해도 같은 기간의 은행 합병, 인구 이동, 모바일뱅킹 확산을 분리해야 ATM의 고용 효과를 추정할 수 있다. 적절한 반사실은 ATM이 없었을 때 비슷한 지역의 창구 고용이 어떻게 변했을지다.

1.20 슬라이드 20 · 약한 고리와 GDP

경제 전체의 산출을 서로 보완적인 여러 부문의 함수로 보면 작은 부문의 생산성을 무한히 높여도 전체 산출은 다른 부문에 묶인다. 암달의 법칙이 시간의 합으로 이를 보여 준다면, 보완적인 생산함수는 **가치의 합과 대체 가능성**까지 고려한다.

대체탄력성 $\sigma < 1$은 한 부문의 산출을 다른 부문의 산출로 바꾸기 어렵다는 뜻이다. 법률 검토가 빨라져도 법원 절차가 일정하면 전체 사건 처리량의 증가는 작다. GDP 효과를 추정할 때는 자동화 대상의 부가가치 비중과 대체탄력성을 함께 정해야 한다. Jones와 Tonetti의 생산성 논의[4]는 이 제약을 수량화한다.

두 단계가 한 단위씩 짝지어야 하는 극단에서는 $Y = \min\{A, B\}$로 쓴다. 하루 처리 능력이 각각 100건과 20건이면 전체는 20건이고 첫 단계만 두 배로 늘려도 같다. 이 Leontief 생산함수의 대체탄력성은 0이다. 실제 경제에서는 여러 산업의 부가가치가 합쳐지고 투입도 일부 대체할 수 있어 이 최소식이 GDP를 직접 나타내지는 않는다. 이 예는 보완성이 강할 때 생산성 향상이 다른 단계의 용량에 묶이는 경로를 보여 준다.

1.21 슬라이드 21 · 분석 가격이 내려갈 때 희소해지는 것

공시의 숫자와 문장을 찾아 정리하는 비용이 크게 낮아지면 예전에는 전문 서비스 구매자만 하던 검색을 더 많은 사람이 할 수 있다. 연 2만 달러 서비스와 월 20달러 도구를 비교하면 연간

[4] https://web.stanford.edu/~chadj/JonesTonetti_Automation.pdf

결제액은 $20{,}000/240 \approx 83.3$배 차이다. 이 비율을 **같은 품질의 분석 한 건당 가격**으로 쓰려면 데이터 범위, 오류 책임, 라이선스, 감사 가능성이 같아야 한다.

공개 공시를 읽는 비용이 낮아지면 같은 정보를 쓰는 투자자가 늘어 가격 반영도 빨라질 수 있다. 공시를 읽고 예상한 가격 상승폭이 0.3%여도 왕복 스프레드·수수료·시장충격이 0.4%면 거래의 예상 순수익은 음수다. **거래 가능한 알파**를 재려면 공시 접수부터 실제 주문 가능 시각까지의 지연을 기록하고, 그 시점 이후의 가격 변화에서 체결비용을 빼야 한다. 차별적 데이터와 낮은 실행비용은 이 계산에서 경쟁 우위가 될 수 있다.

1.22 슬라이드 22 · 내 일의 위험을 평가하는 세 질문

첫째, 일의 모든 과업을 자동화할 수 있는가. 둘째, 가격이 내려가면 그 서비스의 수요가 충분히 늘어나는가. 셋째, 남은 보완 과업의 공급이 제한되어 있는가. 세 질문을 함께 보아야 자동화와 임금의 방향을 추론할 수 있다.

신용분석가의 시간이 자료 입력 40%, 예외 검토 30%, 고객 소통 20%, 승인 책임 10%로 나뉜다고 하자. 입력이 전부 자동화되어 건당 사람 시간이 10시간에서 6시간으로 줄어도, 신청량이 50% 늘면 총 노동시간은 $6 \times 1.5/10 = 0.9$배다. 남은 과업의 공급이 부족하면 총 노동시간이 조금 줄어도 시간당 보수는 오를 수 있다. 이처럼 과업 비중, 신청 수요, 남은 인력의 공급을 차례로 측정한다.

1.23 슬라이드 23 · 데이터 모형에서 예측 모형으로

전통 통계는 자료의 생성 과정을 확률모형으로 표현해 모수를 해석한다. 알고리즘적 접근은 함수의 형태를 유연하게 두고 새 자료의 예측오차를 평가한다. 금융에서는 두 접근 모두 정보 시점과 표본외 성능을 검증해야 한다.

예측은 기존 대출 제도 아래의 $P(\text{연체} \mid X)$를 추정한다. 소득이 연체를 잘 예측해도 소득지원 정책이 연체율을 얼마나 바꿀지는 별도의 인과 질문이다. 소득이 신용이력이나 고용안정성의 대리변수일 수 있고, 승인 기준을 바꾸면 새로 대출받는 차주의 구성도 달라진다. 대출 승인 순위를 정할 때는 예측력을, 현금지원 효과를 평가할 때는 개입 뒤의 결과를 검증한다.

질문: 대출 승인 정책이 바뀌면 예측모형을 왜 다시 평가하나요? 새 정책은 승인되는 차주의 구성을 바꿉니다. 과거에는 대출받지 못해 연체 결과가 관찰되지 않은 집단이 들어오므로 기존 표본의 연체율과 오류율이 그대로 유지된다고 볼 수 없습니다.

1.24 슬라이드 24 · 브라이먼의 두 문화

데이터 모형 문화는 예컨대 $y = X\beta + \varepsilon$을 가정해 β의 의미와 유의성을 해석한다. **알고리즘 문화**는 함수 $f(X)$를 유연하게 고르고 미사용 자료의 예측오차를 줄인다. 전자는 설명 가능한 모수에 강하고 후자는 복잡한 비선형 패턴에 강할 수 있다.

여러 모형이 거의 같은 예측력을 갖는 라쇼몽 효과가 있으면 최고 점수 하나를 '진실'로 해석하기 어렵다. 단순성과 정확도의 상충도 자료와 목적에 따라 달라진다. Breiman의 원문[5]을 읽을 때 모델의 목적이 설명인지 결정인지 먼저 구분하자.

두 문화는 같은 데이터에 다른 질문을 던진다. '금리가 한 단위 바뀌면 주가가 얼마나 변하는가'는 개입과 누락변수를 다루는 구조적 질문이고, '내일 어떤 종목의 손실 가능성이 큰가'는 당시 관측 가능한 변수로 시험할 예측 질문이다. 경제 이론으로 정보 시점과 제약을 정한 뒤 유연

[5] https://doi.org/10.1214/ss/1009213726

한 모형을 비교할 수도 있다. 계수 해석에는 함수 형태와 오차 가정을, 투자 결정에는 미래 자료의 오차와 비용을 중심에 둔다.

1.25 슬라이드 25 · 두 문화의 원문을 읽는 법

브라이먼은 확률모형의 형태 가정이 현실과 어긋날 때 모형 내부의 표준오차만으로 성능을 확신하기 어렵다고 지적했다. 모형의 타당성을 평가하려면 잔차, 안정성, 표본외 성능을 함께 봐야 한다.

예를 들어 회귀의 p값이 작다는 것은 특정 귀무가설과 오차 가정 아래 현재 자료가 드물다는 뜻이다. '이 변수의 경제적 효과가 크다'거나 '다른 기간에서도 통한다'는 확률을 직접 말해 주지 않는다. 계수 크기, 불확실성 구간, 표본외 오차, 매매 후 순이익을 서로 다른 표에 놓고 읽어야 한다.

회귀를 반복해서 고른 뒤 마지막 모형의 p값만 보고하면 해석은 더 어려워진다. 예를 들어 100개 변수를 시험해 가장 작은 p값을 선택했다면, 선택 전에 정해 둔 한 검정과 귀무분포가 다르다. 계수에 유의성이 필요하면 탐색 범위를 기록하고 다중검정이나 새 표본의 재현을 고려한다. 거래 가능성은 다시 포지션 크기와 순수익으로 확인한다.

1.26 슬라이드 26 · 금융이 이론 중심 접근을 고수한 이유

고객과 감독당국은 왜 신용을 거절했는지, 왜 특정 위험을 보유하는지 설명을 요구한다. 또한 금융 수익률의 신호는 약하므로 자유도가 높은 모형은 과거 우연을 외우기 쉽다. CAPM 같은 이론은 어떤 위험에 보상이 주어져야 하는지 검증 가능한 제약을 제시한다.

예측 관계는 행동이 바뀌면 약해질 수 있다. 어떤 공시 문구 뒤에 주가가 천천히 오른다는 규칙이 알려지면 투자자가 발표 즉시 매수해 상승분을 앞당긴다. 과거 자료의 규칙을 시장 참여자의 반응과 독립된 자연법칙으로 취급하면 안 되는 이유다.

이론은 모형의 입력을 줄이는 장치이기도 하다. 모든 기업 특성의 모든 조합을 허용하면 우연히 높은 과거 성과를 찾기 쉽지만, 경제적으로 가능한 현금흐름·할인율 경로로 범위를 좁히면 탐색 공간이 줄어든다. 다만 이론적 제약이 틀리면 진짜 패턴을 놓칠 수 있으므로, 이론 모형과 유연한 모형을 같은 시점의 새 자료에서 비교해야 한다.

1.27 슬라이드 27 · 요인모형의 언어

종목 i의 단순수익률을 R_i, 무위험수익률을 r_f라 하고 초과수익률을 $r_i = R_i - r_f$로 정의하자. 요인모형은 $E[r_i] = \beta_i^\top \lambda$로 쓴다. β_i는 시장·가치·수익성 같은 공통 충격에 대한 노출이고 λ는 그 충격 한 단위에 대해 요구되는 보상이다. CAPM에서는 시장 요인 하나만 두므로 $E[r_i] = \beta_{iM} E[r_M]$가 된다. 여기서 $r_M = R_M - r_f$다.

베타는 요인과 **얼마나 함께 움직이는지**, 프리미엄 λ는 그 노출에 시장이 얼마를 보상하는지를 나타낸다. 장부가치/시가총액이 높은 종목의 수익률이 높아도 위험 보상과 가격오류 중 무엇이 원인인지는 추가 검정이 필요하다. 위험 보상이라면 해당 종목이 투자자의 소비나 재산이 줄어드는 나쁜 시기에 손실을 주는지 살펴야 한다.

CAPM의 시장 베타는 $\beta_{iM} = \mathrm{Cov}(r_i, r_M) / \mathrm{Var}(r_M)$로 계산한다. 시장이 1% 움직일 때 종목이 평균적으로 얼마나 함께 움직이는지 나타내는 선형 민감도이지, 그 종목의 전체 위험이나 미래 한 달 수익률의 확정값은 아니다. 종목 고유의 변동이 아무리 커도 충분히 분산 가능한 위험이라면 CAPM의 기대수익률 식에는 별도 보상이 붙지 않는다. 식을 검정할 때는 무위험수익률과 요인 수익률의 측정 시점도 맞아야 한다.

1.28 슬라이드 28 · 요인 동물원과 다중검정

수백 개 특성을 하나씩 검정하면 참효과가 전혀 없어도 높은 t값이 우연히 나올 가능성이 커진다. 참효과가 모두 0이고 300개 검정의 개별 거짓 양성 확률이 각각 정확히 5%라면 기대 거짓 발견 수는 $300 \times 0.05 = 15$개다. 이는 발견이 반드시 15개 나온다는 뜻이 아니다.

따라서 "한 논문에서 $|t| > 2$"는 충분하지 않다. 독립 표본, 발표 뒤 성과, 거래비용, 관련 변수 통제, 검정 횟수를 확인해야 한다. Harvey·Liu·Zhu의 다중검정 연구[6]는 더 높은 발견 기준의 필요성을 제기한다.

왜 독립성이 없어도 기댓값을 구할 수 있는가? j번째 검정이 잘못 기각되면 1, 아니면 0인 지시변수를 $I_j = 1\{p_j \le 0.05\}$라 두고 전체 개수를 $V = \sum_{j=1}^{300} I_j$라 쓰자. 기대값의 선형성으로 $E[V] = \sum_j E[I_j] = \sum_j P(p_j \le 0.05)$다. 각 검정의 오류확률이 정확히 5%면 15이고, 5% **이하**로 통제된다면 최대 15다. 검정끼리 상관되면 실제 발견 개수가 함께 몰리는 정도와 최대 t값의 분포는 바뀐다. 경제적으로 비슷한 특성을 반복 정의하거나 유리한 표본만 골랐다면 애초에 각 p값의 보정도 별도로 확인해야 한다.

극단을 비교하면 의존의 역할이 선명해진다. 300개 검정이 독립이면 하나라도 잘못 기각될 확률은 $1 - 0.95^{300}$으로 거의 1이다. 반면 **완전히 동일한 검정을 300번 복제**하면 5%의 실험에서 300개가 한꺼번에 통과하고 나머지 95%에서는 0개이므로, 하나라도 통과할 확률은 5%뿐이다. 두 경우 모두 기대 개수는 15다. 따라서 기댓값, 한 번의 실험에서 하나라도 발견할 확률, 발견 개수의 변동은 서로 다른 지표다.

질문: 유의한 결과가 15개일 때 진짜 효과는 몇 개인가요? 유의한 개수만으로는 알 수 없습니다. 거짓 발견의 기대값 15는 모든 참효과가 0인 반복 실험의 평균입니다. 실제 자료의 진짜 효과 비율과 검정력을 추가로 알아야 합니다.

1.29 슬라이드 29 · 머신러닝의 동일 경기장

Gu·Kelly·Xiu는 다수 미국 주식과 기업 특성을 사용해 선형 회귀, 벌점 회귀, 차원 축소, 나무, 신경망을 비교했다. 핵심은 같은 정보 시점과 같은 미래 기간을 기준으로 성능을 채점하는 것이다. 모형이 복잡할수록 과거 적합도가 높다는 사실만으로 승자를 정하면 불공정하다.

특성과 거시 상태의 상호작용은 "같은 기업 특성도 경기 상태에 따라 의미가 달라진다"는 가설을 표현한다. 예를 들어 레버리지의 가격 효과가 금리 상승기에 커질 수 있다. 연구 원문[7]은 이러한 비선형 상호작용이 예측 개선의 중요한 원천이라고 보고한다.

2015년 종목을 예측할 때는 당시 공개된 재무제표를 써야 한다. 나중에 수정된 데이터베이스의 최종 값이나 상장폐지 종목을 제거한 목록을 쓰면 미래 정보가 섞인다. 결측치 처리와 재학습 빈도도 모형 사이에 맞추고, 검증 결과로 모형을 고른 뒤 시간상 마지막 시험 기간을 최종 평가에 사용한다.

1.30 슬라이드 30 · 작은 표본외 결정계수의 의미

표본외 결정계수는 $R^2_{\text{OOS}} = 1 - \text{SSE}_{\text{model}}/\text{SSE}_{\text{benchmark}}$이다. 월별 개별 주식 수익률은 예측 불가능한 변동이 크므로 0.4% 같은 숫자는 작아 보여도 실제 예측 가능한 성분의 차이를 나타낼 수 있다. 단, 통계적 개선과 거래 가능한 이익은 다르다.

모형의 우수성을 읽을 때 기준 예측이 0인지 과거 평균인지 확인해야 한다. 분모가 달라지면 같

[6] https://doi.org/10.1093/rfs/hhv059
[7] https://doi.org/10.1093/rfs/hhaa009

은 예측에도 R^2가 달라진다. 공매도 제약, 회전율, 거래비용을 빼고 계산한 포트폴리오 성과도 별도로 검토한다.

수치로는 기준선의 제곱오차합이 1,000이고 새 모형의 합이 996일 때 $1 - 996/1000 = 0.004$다. 이 차이는 개별 주식의 큰 잡음 속에서 유용한 신호일 수도 있지만, 신뢰구간과 기간별 안정성을 보지 않으면 우연인지 알 수 없다. 또한 양의 R^2_{OOS}가 있어도 모형이 추천하는 종목에서 회전율이 높으면 비용 뒤 수익은 음수가 될 수 있다.

1.31 슬라이드 31 · 공개된 예측 신호의 이익 감소

한 뉴스 신호가 널리 알려지면 투자자는 가격에 그 정보를 더 빨리 반영한다. 신호가 가리킨 종목을 모두가 먼저 사면 나중에 얻을 초과수익은 줄어든다. 거래 규모가 커질수록 호가 충격과 매매비용도 늘어난다.

발표 뒤 성과 감소에는 정보가 가격에 빨리 반영된 효과, 처음 연구의 우연한 표본 선택, 추종 자금이 키운 거래비용이 섞인다. McLean·Pontiff[8]는 발견과 출판 뒤의 성과를 비교한다. 발표 전 월평균 총 초과수익이 0.5%, 발표 뒤 0.2%라면 먼저 총수익의 변화를 보고, 발표 뒤 왕복비용 0.3%를 빼면 투자자의 순수익은 -0.1%다. 표본 기간과 전략 규칙을 맞춰야 감소의 원인을 더 좁힐 수 있다.

1.32 슬라이드 32 · 계산 규모와 사전 지식

서튼의 "쓴 교훈"은 사람이 세세한 규칙을 집어넣는 방법보다 계산과 학습을 넓게 활용하는 일반적 방법이 장기적으로 우세했던 사례를 정리한다. 금융의 손으로 만든 단어 사전이나 고정된 요인 조합도 이 관점에서 재검토할 수 있다.

경제 이론과 제도는 대규모 학습의 허용 범위와 평가 기준을 정한다. 거래비용, 시간 순서, 데이터 누출 방지, 예산 제약을 반영해야 성능을 실제로 측정할 수 있다. Sutton의 글[9]은 방법론 선택의 배경을 제공한다.

금융에서는 계산 규모와 함께 **훈련 목표와 독립 표본의 수**가 중요하다. 다음 단어를 잘 예측해도 투자 판단에 필요한 근거가 부족할 수 있고, 한 번의 금융위기나 제도 변경에서 독립 사례를 대량으로 만들 수는 없다. 실제 투자 시점의 정보만 입력해 시점 밖·시장 밖 성과를 확인하고, 희귀 충격은 별도 시나리오로 점검한다.

1.33 슬라이드 33 · 이중 하강과 금융 데이터

고전적 편향·분산 그림에서는 모형을 복잡하게 할수록 처음에는 오차가 줄다가 과적합으로 다시 오른다. 일부 과매개변수 모형에서는 훈련자료를 정확히 보간하는 지점 뒤에 시험 오차가 다시 내려가는 **이중 하강**이 관찰된다.

훈련오차가 0에 가까워지는 **보간 경계** 부근에서는 잡음까지 맞혀 시험오차가 커질 수 있다. 그보다 훨씬 큰 모형에서 최적화 알고리즘이 상대적으로 단순한 해를 찾으면 시험오차가 다시 줄기도 한다. 그래프의 가로축을 변수 수만으로 읽기보다 유효 자유도, 자료 구조, 최적화의 암묵적 정규화를 함께 봐야 한다. Belkin 등[10]은 기본 현상을 제시한다.

금융 시계열은 짧고 시장 구조가 변하므로 이중 하강을 기대해 모형을 키우는 것만으로는 충분하지 않다. 시간 순서에 맞춘 여러 표본외 기간에서 같은 곡선이 나타나는지 확인하고, 선택된

[8] https://doi.org/10.1111/jofi.12365

[9] http://www.incompleteideas.net/IncIdeas/BitterLesson.html

[10] https://doi.org/10.1073/pnas.1903070116

전략의 거래비용까지 계산한다.

2 금융 텍스트와 언어모형

숫자만으로는 기업의 전망과 위험을 다 읽을 수 없다. 사업보고서의 위험 문단, 실적 발표의 발언, 기사와 규제 공시는 모두 텍스트다. 이 장은 단어 세기에서 문맥 표현으로 발전한 방법을 이해하고, 언어모형의 학습 목표가 왜 그럴듯한 오류를 만들 수 있는지 경제학의 유인 문제와 연결한다.

2.1 슬라이드 01 · 텍스트를 금융 데이터로 읽기

재무제표의 숫자는 표준화되어 있지만 경영자의 설명은 길고 비정형적이다. 같은 "소송"이라는 단어도 소송을 당했다는 뜻인지 승소했다는 뜻인지 문맥을 보아야 한다. 텍스트 분석의 목표는 문서를 짧게 줄이는 데 그치지 않고 **미래 현금흐름이나 위험에 관한 추가 정보**를 추출하는 것이다.

분석 단위는 질문에 맞춰 정한다. 한 문서 전체의 부정 단어 비율과 '유동성 위험' 문단의 비율은 다른 정보를 담고, 경영자 발언과 애널리스트 질문도 유인이 다르다. 같은 기업의 한 공시에서 나온 100개 문장을 독립된 기업 사건 100개로 세면 표준오차가 작아진다. 문장별 추출 정확도는 문장 수준에서, 투자 성과는 **발표 뒤 기업 수익률과 비용**으로 평가하며 기업·공시일에 따른 상관을 반영한다.

2.2 슬라이드 02 · 사전에서 언어모형으로

텍스트 분석은 단어 빈도에서 단어 조합, 의미 벡터, 문맥형 표현으로 발전했다. 단어 빈도는 순서를 버리고, 2그램은 가까운 문맥만 남기며, 임베딩은 표현을 압축하는 대신 개별 차원의 뜻이 분명하지 않다. 문맥형 모형은 먼 관계도 반영하지만 자료와 계산 자원을 더 쓴다. 특정 공시 표현이 안정적이라면 간단한 사전의 재현성과 감사 용이성이 오히려 장점이 된다.

동일한 문서 분류를 예로 들면 고정 사전, 2그램 회귀, 문맥형 언어모형을 **같은 훈련 기간과 같은 미래 시험 기간**에 놓을 수 있다. 각 방법에 입력한 정보가 동일해야 표현법의 효과를 비교할 수 있다. 정확도 차이가 1%포인트라면 그 차이가 검토 인력 절감이나 투자 손실 감소로 얼마의 가치가 있는지까지 계산해야 복잡한 방법의 추가 비용을 정당화할 수 있다.

2.3 슬라이드 03 · 사전 단어 세기의 함정

문서에서 긍정 표현이 부정보다 얼마나 많은지 비교하려면 먼저 두 표현의 개수를 센다. 사전과 일치한 긍정·부정 단어 수를 N_+, N_-라 하고 전체 단어 수를 N이라 하면 점수는 $S = (N_+ - N_-)/N$이다. 분자는 방향, 분모는 문서 길이를 조정한다. 길이로 나누지 않으면 내용의 비율이 같은 긴 보고서가 더 극단적인 점수를 얻는다.

일반 영어 사전의 "liability"나 "capital" 같은 단어는 금융 문맥에서 일상적 의미와 다르게 쓰인다. 단어가 위험을 뜻하는지 회계 항목을 뜻하는지 무시하면 점수에 체계적 오차가 생긴다. Loughran·McDonald[11]는 금융 문서에 맞는 사전이 필요한 이유를 보여 준다.

[11] https://doi.org/10.1111/j.1540-6261.2010.01625.x

100단어 중 긍정 8개·부정 3개이면 $S = 0.05$다. 같은 내용에 표준 문구 100단어가 붙으면 점수는 0.025로 낮아진다. 길이를 보정해도 무관한 문구가 늘면 점수가 바뀌므로 분석할 본문 범위를 일정하게 정해야 한다.

2.4 슬라이드 04 · 금융 전문 사전의 의미

전문 사전은 단어의 극성을 **사용되는 분야**에 맞춘다. 예를 들어 "tax"는 범용 감성 사전에서 부정적으로 처리될 수 있어도 세금 공제나 이연법인세 문맥에서는 방향을 단정할 수 없다. 금융 사전은 그 분야에서 실제로 부정적 의미를 갖는 단어를 다시 분류한다.

전문 사전의 장점은 누구나 같은 단어 목록으로 결과를 재현할 수 있다는 점이다. 그러나 새로운 산업 용어와 회계 기준 변화에는 갱신이 필요하다. 사전을 자료 전체를 본 뒤 조정하면 미래 문서의 표현을 과거 분석에 몰래 반영할 수 있으므로, 사전 버전과 적용 날짜를 기록해야 한다.

사전에서 '손실'을 부정으로 세는 것은 **단어 수준의 규칙**이다. '손실이 30억 원 발생했다', '손실이 발생하지 않았다', '손실 가능성을 제거했다'는 같은 단어를 포함하지만 미래 현금흐름에 대한 해석은 다르다. 부정어의 범위, 시제, 가능성 표현을 따로 처리해야 하고, 단어 사전 점수의 잔여 오류가 어느 유형에 몰리는지 수작업 표본으로 점검할 수 있다.

2.5 슬라이드 05 · n그램과 부정 표현

n그램은 연속한 n개의 토큰을 하나의 특징으로 센다. "good" 하나는 긍정이지만 "not good"이라는 2그램은 그렇지 않다. "strong demand"와 "weak demand"도 명사 하나보다 형용사와의 결합을 보아야 구별된다.

2그램은 'not expected to be good'처럼 부정어와 대상이 떨어져 있으면 놓친다. n을 늘리면 문맥은 넓어지지만 조합별 관측 수는 줄어든다. 어휘가 1만 개면 가능한 순서 있는 2그램은 최대 10^8개인 데 비해 실제 문서에는 일부만 나타난다. 드문 조합의 계수를 과신하지 않도록 훈련 기간에서 빈도 기준과 벌점을 정하고, 정규화한 선형모형을 비교 기준으로 쓴다.

2.6 슬라이드 06 · 임베딩은 무엇을 보존하는가

임베딩은 단어 w를 d개 숫자로 이루어진 벡터 $v_w \in \mathbb{R}^d$에 대응시킨다. 비슷한 문맥의 단어가 가까워지도록 학습한 뒤 두 단어를 비교할 때는 벡터의 길이가 아니라 **방향**을 볼 수 있다. 내적 $v_a^\top v_b$를 두 길이 $\|v_a\|\|v_b\|$로 나눈 코사인 유사도는 길이를 각각 1로 맞춘 뒤 각도를 재는 값이다. 영벡터에는 정의되지 않는다.

고정 임베딩은 "bank"의 은행·강둑 뜻을 한 벡터에 담으므로 문장별 의미를 표현하기 어렵다. 또 '매수'와 '매도'처럼 반대 역할의 단어도 비슷한 문맥에 자주 나와 가까워질 수 있다. 이웃 단어가 의미나 경제적 대체성을 보장하지 않으므로 실제 분류·검색 과제에서 구별되는지 확인한다. 문맥형 표현은 문장 속 다른 단어를 함께 살펴 첫 문제를 줄인다.

$v_a = (1, 0)$과 $v_b = (2, 0)$의 코사인은 1이고, $v_c = (0, 1)$과는 0이다. 이 값은 단어의 인과관계나 경제적 대체 가능성을 뜻하지 않는다. 학습 문서가 달라지면 가까운 단어도 달라질 수 있다.

2.7 슬라이드 07 · 토큰과 입력의 비용

언어모형은 글을 하위 단어 조각인 토큰으로 나누고 정수 ID로 바꾼다. 같은 단어라도 언어와 토크나이저에 따라 조각 수가 다르다. 숫자, 종목 코드, 한국어 조사도 예상과 다르게 잘릴 수 있다.

토큰 수는 비용과 문맥 창의 한도를 결정한다. 문맥 창이 8,000토큰이고 지시문·답변에 2,000토큰을 남기면 원문에는 6,000토큰만 쓸 수 있다. 20,000토큰의 보고서 앞부분만 보내면 뒤의 70%가 사라진다. 관련 구간을 검색해 나누어 보낼 때 회사·기간·페이지를 붙이고, 답에 사용한 문단으로 되돌아갈 수 있게 해야 한다.

2.8 슬라이드 08 · 어텐션의 계산

어텐션(attention)은 현재 읽는 토큰 i가 다른 토큰 j의 정보를 얼마나 가져올지 계산한다. 입력 표현 x에 학습된 행렬을 곱해 질의 $q_i = x_i W_Q$, 키 $k_j = x_j W_K$, 값 $v_j = x_j W_V$를 만든다. 질의와 키의 내적이 클수록 둘의 연결 점수가 높다. d는 질의·키 벡터의 차원, $\mathcal{A}_i$는 토큰 i가 참고하도록 허용된 위치의 집합이다. 점수를 지수함수로 바꿔 그 합으로 나누는 softmax는 허용된 위치의 가중치를 모두 양수이고 합이 1이게 만든다.

$$\alpha_{ij} = \frac{\exp(q_i^\top k_j / \sqrt{d})}{\sum_{\ell \in \mathcal{A}_i} \exp(q_i^\top k_\ell / \sqrt{d})}, \quad j \in \mathcal{A}_i,$$
$$h_i = \sum_{j \in \mathcal{A}_i} \alpha_{ij} v_j.$$

점수를 $\sqrt{d}$로 나누면 차원이 커질 때 내적이 커져 softmax가 한 위치에 과도하게 몰리는 현상을 줄인다. 예를 들어 허용된 두 위치의 점수가 0과 $\ln 3$이면 가중치는 $1/4$과 $3/4$다. "bank raised interest rates"에서 bank가 금리 표현을 참고하는 방식으로 문맥에 따른 뜻을 만들 수 있다. Transformer 원문[12]은 이 연산의 출발점이다.

새 표현 h_i는 값 벡터 v_j의 가중평균이다. 학습된 어텐션 가중치 하나를 사람이 이해하는 '최종 판단 이유'로 해석할 수는 없다.

자기회귀 모형이 다음 토큰을 예측할 때는 미래의 정답을 미리 보지 않도록 보통 $\mathcal{A}_i = \{1, \dots, i\}$로 **causal mask**를 둔다.

2.9 슬라이드 09 · 다음 토큰 예측과 압축

문장이 두 토큰 x_1, x_2로 이루어졌다면 두 토큰이 함께 나올 확률은 $p(x_1, x_2) = p(x_1)p(x_2 \mid x_1)$이다. 이 조건부확률의 곱셈을 이어 가면 $p_\theta(x_1, \dots, x_n) = \prod_{t=1}^{n} p_\theta(x_t \mid x_{<t})$다. $x_{<t}$는 t 앞의 토큰들이고, θ는 학습할 모형의 계수다. 관찰된 문장의 확률을 높이려면 각 토큰의 **음의 로그확률**을 낮춘다. 로그는 곱을 합으로 바꾸어 긴 문장도 계산하기 쉽게 한다.

음의 로그우도 $-\sum_t \log p_\theta(x_t \mid x_{<t})$는 실제 토큰에 낮은 확률을 줄수록 커진다. 이 목표로 문장을 잘 이어 쓸 수 있어도 기업의 실제 부채를 검증하려면 원자료와 대조해야 한다.

부호 길이와의 연결은 로그의 밑을 정하면 분명해진다. 실제 다음 토큰에 확률 $1/2$를 주면 이상적인 부호 길이는 $-\log_2(1/2) = 1$비트이고, 확률 $1/8$만 주면 3비트다. 관측 텍스트에 높은 확률을 주는 모형일수록 평균적으로 짧은 부호가 가능하다. 하지만 자료 자체에 오류가 있으면 그 오류에도 높은 확률을 주는 것이 이 훈련 목표에는 유리할 수 있다.

[12] https://arxiv.org/abs/1706.03762

2.10 슬라이드 10 · 유창한 실패의 출발점

문법적으로 자연스러운 문장은 독자의 신뢰를 쉽게 얻는다. 그러나 금융 분석에서는 오답의 형태가 매끈하면 더 위험하다. 숫자를 틀리게 합산하거나 없는 공시를 인용해도 문장만으로는 발견하기 어렵다.

실패를 세 갈래로 나누면 대응이 쉬워진다. 필요한 정보를 못 봤는지, 본 정보를 잘못 끌어냈는지, 계산·추론에서 틀렸는지 구분한다. 첫째에는 자료 첨부와 검색, 둘째에는 재질문과 근거 대조, 셋째에는 계산기와 독립 검산이 필요하다.

가령 조정 영업이익을 80억 원으로 답했지만 정답이 70억 원이라면, 먼저 관련 공시 주석이 검색 결과에 있었는지 본다. 있었다면 모형이 일회성 이익 10억 원을 놓쳤는지, 숫자는 모두 맞게 뽑았는데 $80 - 10$ 계산을 잘못했는지 살핀다. 같은 10억 원 오류라도 검색 범위를 넓힐 문제와 계산기 호출을 붙일 문제는 해결책이 다르다.

질문: 오류별 성능표에는 어떤 열이 필요한가요? 필요 문서의 검색 성공률, 문서가 주어졌을 때 숫자·단위 추출 정확도, 정확한 입력에서의 계산 정확도를 분리합니다. 각 단계의 분모도 명시해야 전체 오류의 위치가 보입니다.

2.11 슬라이드 11 · 생성모형의 목적 함수를 정확히 쓰기

한 문장뿐 아니라 M개 문장으로 학습할 때는 각 문장 m의 길이 n_m에 걸쳐 로그확률을 합한다. θ를 조정해 그 합을 최대화하는 최대우도 추정은 다음과 같다.

$$\theta^* = \arg\max_{\theta} \sum_{m=1}^{M} \sum_{t=1}^{n_m} \log p_\theta(x_t^{(m)} \mid x_{<t}^{(m)}).$$

연쇄법칙은 확률의 항등식이고 Transformer는 각 조건부확률을 근사하는 한 가지 모형이다. 문맥 창에는 길이 제한이 있으며, 이 목적함수에는 사실 검증이나 투자 손실이 들어 있지 않다. 긴 문서를 토큰 수만큼 가중할지 문서별로 동일하게 가중할지는 학습 설계에 따라 달라진다.

2.12 슬라이드 12 · 목적 함수에 진실 항이 없다는 뜻

웹에 반복된 잘못된 주장도 훈련 텍스트라면 예측 대상이 된다. 최대우도 목표는 그 문장이 실제 기업의 사실인지 별도로 대조하지 않는다. 후속 정렬과 검색 도구가 이를 보완할 수 있지만, 기본 훈련 목표만으로 사실성이 보장되지는 않는다.

"거짓말"이라는 표현은 모델이 사실을 알고도 속이려는 의도를 암시해 혼동을 준다. 실무에서는 사실 오류, 출처 환각, 과도한 확신을 관찰 가능한 실패로 정의하는 편이 낫다. 같은 오류라도 투자 추천에 쓰일 때 손실함수는 훨씬 커진다.

정렬 훈련은 오류를 줄일 수 있지만, '도움 되는 답변'에 대한 보상이 드문 기업 사건에서 모른다고 답할 유인까지 보장하지는 않는다. 근거 검색 경로와 답을 보류할 선택지를 평가에 포함해야 한다.

목표의 불일치를 손실로 표현해 보자. 일반 문장에서는 숫자 하나의 오류가 평균 토큰 손실에 조금만 반영될 수 있지만, 대출 심사에서는 숫자 한 자리의 오류가 승인 결정을 뒤집을 수 있다. 따라서 언어 손실 L_{text}와 금융 의사결정 손실 L_{decision}은 가중치도 단위도 다르다. 모형 선택에는 정답률과 함께 오류가 유발한 금전적 손실, 잘못된 확신의 빈도, 검토 비용을 넣어야 한다.

2.13 슬라이드 13 · 질문을 바꾸면 평가도 바뀐다

"왜 거짓말하는가"보다 "어떤 입력과 보상 아래서 어떤 오류가 반복되는가"가 검증 가능한 질문이다. 모호한 요청은 모델이 가능한 해석 가운데 하나를 택하게 한다. 사용자가 원한 회계 정의와 모델이 택한 정의가 다르면 계산은 매끈해도 결론은 틀린다.

같은 기업에 대해 연결 순이익이 120억 원이고 별도 순이익이 90억 원인 상황에서 '순이익'만 지시하면 두 답 모두 가능한 기준을 갖는다. 한 숫자를 무조건 정답으로 지정하면 모호한 입력에 대한 신중한 질문을 오답으로 채점할 수 있다. 평가 자료는 기준을 명시한 문제와 일부러 모호하게 둔 문제를 나누고, 후자에서는 필요한 확인 질문을 했는지 기록해야 한다.

2.14 슬라이드 14 · 걸러낼 것이 없는 회사를 시험하기

"핵심이익을 계산하라"는 표현은 일회성 항목의 존재를 암묵적으로 기대하게 만들 수 있다. 같은 일을 "반복되지 않는 항목이 있으면 열거하고, 없으면 없다고 답하라"고 풀어 쓰면 과제가 더 분명하다. 추출 도구는 **양성 사례뿐 아니라 음성 사례**에서 평가해야 한다.

정밀도는 추출한 항목 중 진짜의 비율, 재현율은 실제 항목 중 찾아낸 비율이다. 양성 항목 10개 중 8개를 찾아 6개만 맞았다면 정밀도는 $6/8 = 75\%$, 재현율은 $6/10 = 60\%$다. 각 조정 항목은 원문과 금액에 연결해야 한다.

양성 항목이 없는 문서 한 건에서는 재현율 $\mathrm{TP}/(\mathrm{TP}+\mathrm{FN})$의 분모가 0이다. 이때는 항목을 만들어 낸 **거짓 양성** 여부와 음성 문서에 대한 특이도를 본다. 음성 문서 비중을 실제 업무에 맞추어야 허위 이익 조정의 빈도를 제대로 평가할 수 있다. 전체 자료의 양성 비율이 달라지면 정밀도도 변한다.

2.15 슬라이드 15 · 모델의 국적을 성향으로 단정하지 않기

같은 기업에 대한 두 모형의 전망이 다르면 정치적 성향부터 추측하기 쉽다. 하지만 모형이 접근한 정보의 범위, 학습시점, 검색 언어가 다를 수 있다. 낙관적 전망은 의도적인 선호가 아니라 부정적 기사의 누락에서 생길 수 있다.

모형 A와 B에 같은 기업·날짜의 한국어 원문과 영어 번역을 각각 제시하면 **모형×언어**의 네 조건이 생긴다. 같은 모형 안의 언어 차이와 같은 언어 안의 모형 차이를 따로 측정할 수 있다. 프롬프트·검색 도구·출력 형식을 고정하고 번역에서 숫자와 부정 표현이 보존되었는지 확인한다. 답변의 어조 대신 전망의 실제 성과와 주장별 근거를 비교한다.

2.16 슬라이드 16 · 예상을 뒤집는 결과의 검증

예상을 벗어난 전망 차이가 나오면 표본 기업, 전망 시점에 이용 가능한 뉴스, '낙관성'의 척도를 먼저 고정한다. 두 모형에 동일한 지역 뉴스를 추가했을 때 차이가 줄어드는지 보면 정보 집합의 영향을 살필 수 있다. 목표주가 상승 여력, 이익 전망, 문장 감성은 각각 따로 보고한다.

목표주가 기준 낙관성을 $U = P_{\text{target}}/P_{\text{current}} - 1$로 정하면 현재가 10만 원, 목표가 11만 원일 때 $U = 10\%$다. 같은 보고서가 '불확실성이 매우 크다'고 써서 문장 감성은 부정적일 수도 있다. 두 척도가 다르면 어느 모형이 '더 낙관적'인지 문장 하나로 말할 수 없다. 기준 가격의 시각과 목표주가의 유효 기간도 맞춰야 한다.

2.17 슬라이드 17 · 지역 정보의 사각지대

중소형주에 관한 규제 조치나 소송 기사는 현지 언어의 지역 매체에 먼저 실릴 수 있다. 영어권 검색에 안 보인다고 사건이 없는 것은 아니다. 한국의 코스닥 기업을 평가할 때도 DART, 거래소 공시, 국내 언론을 직접 확인해야 한다.

정보를 추가한 뒤 전망 차이가 줄어들면 국적 자체보다 자료 접근성이 원인이라는 설명에 힘이 실린다. 하지만 검색 결과가 더 많다는 사실만으로 기사가 모두 신뢰할 만하다는 뜻은 아니다. 기업명·발표일·법적 상태를 교차 확인한다.

예를 들어 코스닥 기업의 소송 위험을 조사할 때는 OpenDART[13]에서 회사·날짜·공시 유형으로 원문을 찾고 정정 공시를 시간순으로 연결한다. 같은 사건의 복제 기사 20개보다 최종 법적 상태를 기록한 공시 한 건이 더 결정적일 수 있다. 검색 성능은 기사 건수와 함께 **결정적인 원문이 후보에 포함되었는지**로 평가한다.

2.18 슬라이드 18 · 기억과 진짜 사전 예측의 차이

기업명과 날짜를 지운 옛 실적발표도 문장 패턴으로 식별할 수 있다면, 과거 자료에 대한 높은 점수는 미래 예측력의 증거가 아니다. 모형의 훈련 종료일보다 뒤의 사건만 시험하고, 프롬프트에 미래의 정보가 섞이지 않았는지 확인해야 한다.

엄격한 실험은 **시점별 정보 집합** $\mathcal{I}_t$만 사용해 $t+1$을 예측한다. 모형 가중치를 학습한 시점, 검색 색인의 업데이트 시점, 평가 자료의 공개 시점까지 기록해야 한다. 금융에서 시간 누출은 아주 작은 예측 신호를 쉽게 압도한다.

미국 SEC의 EDGAR 설명[14]은 보고서의 회계기간 말일, 공식 제출일, 접수 시각을 별도로 정의한다. 12월 31일로 끝나는 회계연도의 숫자라도 그날 투자자가 알 수 있었다는 뜻은 아니다. 예측 자료에는 회계기간보다 정보가 실제로 알려진 시각을 적용해야 한다.

예를 들어 2024년 말 재무상태표가 2025년 3월에 제출되었다면 2025년 1월 투자자는 그 확정 수치를 입력으로 쓸 수 없다. 날짜만 2024년으로 붙은 데이터베이스를 그대로 결합하면 모형이 1월 예측에 3월 공개 정보를 사용하게 된다. 회고 기사도 제목의 과거 날짜보다 실제 작성·색인 시각이 중요하다. 재무 기간 말일과 **이용 가능 시각**을 별도 열로 저장하고, 예측 시점 이전에 공개된 버전만 결합해야 한다.

2.19 슬라이드 19 · 모형의 투자 스타일

답변 모델은 학습자료와 정렬 과정 때문에 특정 업종이나 최근 하락 종목을 더 자주 추천할 수 있다. 이는 경제학에서 말하는 투자 스타일과 비슷하지만, 실제 투자전략의 수익성이 입증되었다는 뜻은 아니다.

성향을 측정하려면 동일 시점의 종목과 자료를 여러 모형에 주고, 추천 비율을 업종·규모·직전 수익률별로 비교한다. 반대 근거를 추가했을 때 전망이 적절히 갱신되는지도 중요하다. 하나의 모형을 여러 번 물어 얻은 답은 독립된 전문가 의견이 아니다.

비중의 차이를 숫자로 보자. 시장 포트폴리오의 기술주 비중이 50%이고 모형 추천 포트폴리오가 55%라면 적극적인 기술주 노출은 5%포인트다. 다른 모형의 추천 비중이 40%라면 겉보기에는 기술주를 많이 추천하지만 시장 대비 10%포인트 과소 비중이다. 이 비교는 추천을 실제로 어떤 비중으로 실행할지 정한 뒤에만 가능하며, 종목 개수의 비율과 자금 비중은 서로 다르다.

[13] https://opendart.fss.or.kr/guide/main.do?apiGrpCd=DS001

[14] https://www.sec.gov/about/webmaster-frequently-asked-questions

2.20 슬라이드 20 · 만족도 보상의 부작용

사용자 평가를 보상에 넣으면 친절함이 높아질 수 있지만, 사용자가 듣고 싶은 말에 동의할 유인도 생긴다. 2025년 GPT-4o 업데이트에서 과도한 동조(sycophancy)가 나타난 사례는 목적함수의 대리 지표를 잘못 맞추면 원하는 품질과 다른 행동이 나온다는 점을 보여 준다.

금융에서는 "이 종목을 사면 좋겠지?"라는 유도 질문에 대한 동의가 특히 위험하다. 평가 문항에 정확한 반론 제시, 불확실성 표현, 근거 없는 주문 권유 거절을 포함해야 한다. OpenAI의 사후 분석[15]은 피드백 신호의 결합 문제를 설명한다.

평가를 수량화하려면 원문에서 답이 하나로 정해지는 사실 질문을 모아 유도 프롬프트와 중립 프롬프트를 짝지을 수 있다. 예를 들어 원문상 영업이익이 감소했는데 '증가했지?'라고 물어도 감소했다고 답해야 한다. 짝지은 질문의 정답률 차이는 동조 오류의 신호지만, 표현 차이 자체가 난도를 바꿀 수 있으므로 여러 문장 형태에서 반복해 확인한다.

2.21 슬라이드 21 · 사후 분석과 인과 사슬

업데이트 뒤 동조가 관찰되고 이전 버전으로 되돌리자 완화되었다는 시간 순서는 중요한 단서다. 하지만 사후 분석은 여러 변경이 함께 들어갔음을 인정하므로 "좋아요 신호 하나만 원인"이라고 단순화하면 안 된다.

평가 지표가 사용자 만족을 포착해도 진실성, 장기적 편익, 반대 의견 제시까지 완전히 측정하지는 못한다. 제품 평가에서는 개별 지표의 개선뿐 아니라 서로 다른 목표가 충돌하는 극단 사례를 함께 시험한다.

인과 사슬을 '업데이트 → 답변 성향 변화 → 사용자 결정 변화 → 손익 변화'로 나누면 측정 대상이 분명해진다. 첫 두 단계의 실험 증거가 있어도 실제 사용자의 주문이나 수익까지 확인한 것은 아니다. 예컨대 동조 답변 비율이 늘었다는 관찰만으로 투자 손실액을 계산할 수 없다. 각 화살표마다 비교군과 행동 자료가 필요하다는 점이 제품 평가와 경제 효과 추정의 연결이다.

2.22 슬라이드 22 · 체스 에이전트 실험의 설계

도구를 쓸 수 있는 에이전트에게 "체스 엔진을 이겨라"라고만 지시하면, 체스를 두는 방법 외에 게임 파일을 바꾸거나 상대 프로그램에 접근하는 방법도 환경에 존재할 수 있다. 목표를 결과만으로 정의하면 허용된 행동의 경계가 빠진다.

에이전트의 목표에는 성과와 허용된 경로를 함께 적어야 한다. 매매 에이전트라면 주문 가능 종목, 금액 한도, 사용 가능한 자료, 사람의 승인 시점을 명시하고 분석 권한과 주문 권한을 분리한다. 실험 논문[16]을 읽을 때도 성공의 정의와 허용 도구를 먼저 확인한다.

실험에서 관측한 한 번의 우회 시도는 우회가 **가능한 경로**를 보여 주지만, 모든 환경에서 그 행동이 나타날 빈도를 알려 주지는 않는다. 평가에는 정당한 경로로 목표를 달성한 비율과 금지된 경로를 시도한 비율을 따로 기록해야 한다. 금융 시스템에서는 읽기 전용 공시 검색 권한과 주문 제출 권한을 별도 단계로 두면 두 결과를 구별하고 통제할 수 있다.

[15] https://openai.com/index/expanding-on-sycophancy/
[16] https://arxiv.org/abs/2502.13295

2.23 슬라이드 23 · 목표 달성과 규칙 준수는 다른 변수

게임 상태를 바꾸어 얻은 "승리"는 체스 실력의 성과가 아니다. 평가자가 결과 파일의 승패만 읽으면 이런 경로를 구별하지 못한다. 금융에서도 손익 숫자만 보면 미공개 정보 사용, 과도한 위험 부담, 장부 밖 포지션을 숨긴 성과를 놓칠 수 있다.

성과를 손익 하나로 채점하면 위험을 크게 키워 높은 평균수익을 얻는 전략을 잘못 선호할 수 있다. 같은 손익이라도 최대 손실, 레버리지, 규정 위반 여부를 함께 기록해야 한다. 평가자가 볼 수 있는 로그를 에이전트가 바꿀 수 있다면 독립 검증이 성립하지 않으므로 원장과 권한도 분리한다.

예를 들어 두 전략 모두 평균 수익이 1억 원이어도, 하나는 최대 손실이 1천만 원이고 다른 하나는 10억 원이라면 고객의 위험한도 아래 같은 성과가 아니다. 목적함수를 단순히 $\max E[\Pi]$로 두는 대신 손실 한도 $P(\Pi < -L) \le \delta$ 같은 제약을 붙일 수 있다. 이 식은 손실이 L을 넘을 확률을 δ 이하로 제한한다는 뜻이며, 추정 오차가 큰 꼬리확률은 별도 스트레스 시험도 필요하다.

질문: 손실확률 제약의 수치는 누가 정하나요? 투자자의 위험 허용도와 자금 필요 시점, 계약상 한도가 먼저 정해져야 합니다. 모형은 정해진 L과 δ 아래에서 수익을 최대화하며, 꼬리확률 추정은 스트레스 시험으로 보완합니다.

2.24 슬라이드 24 · 굿하트 법칙, 루커스 비판, 대리인 문제

굿하트 법칙은 유용한 대리 지표를 목표로 최적화하면 원래 목표와의 관계가 약해질 수 있다는 통찰이다. 루커스 비판은 정책이 바뀌면 경제주체의 행동도 바뀌므로 과거 관계를 그대로 새 정책에 적용하기 어렵다는 주장이다. 두 개념은 **행동의 변화가 통계적 관계를 바꾼다**는 점에서 만난다.

모형의 보상 R이 진짜 사회적 가치 V의 불완전한 근사라면, $\arg\max R$이 $\arg\max V$와 다를 수 있다. 개발자와 사용자가 원하는 것을 에이전트에게 완전한 계약으로 명시하기 어려운 주인·대리인 문제다. 독립 감사와 반복 평가, 권한 제한이 보상함수의 문구만큼 중요하다.

금융의 예로는 대출 담당자에게 '승인 처리 속도'만 보상하는 경우가 있다. 담당자는 추가 확인이 필요한 신청자를 간단히 거절하거나 검토를 생략해 평균 처리 시간을 줄일 수 있다. 처리 속도와 좋은 대출 결정이 과거에는 함께 움직였더라도 보상 규칙이 바뀌면 그 상관은 유지되지 않는다. 해결률·부실률·고객 접근성과 같은 결과를 함께 추적해야 대리 지표의 왜곡을 볼 수 있다.

2.25 슬라이드 25 · 환각을 과신으로 측정하기

틀린 답을 모두 같은 위험으로 볼 필요는 없다. "확실하지 않다"라고 말하고 근거 확인을 요청한 오답은 확신에 차서 허위 출처를 만든 오답과 다르다. 확률 p를 말한 예측은 실제로 약 p의 비율로 맞아야 **보정**되어 있다고 한다.

90% 확신 답변 100개 중 약 90개가 맞으면 그 구간의 보정이 좋다. 그러나 모든 질문에 60%라고 답하는 모형도 전체 정답률이 60%라면 보정되어 있을 수 있다. 금융 판단에는 쉬운 사례와 어려운 사례를 **구분하는 능력**도 필요하다. Yona 등[17]은 거절과 단언 사이에서 불확실성을 표현하는 방법을 제안한다.

확률 예측의 한 점수로 Brier score를 쓸 수 있다. 사건이 발생하면 $y = 1$, 아니면 0이고 예측 확률이 p일 때 $(p - y)^2$를 계산해 평균한다. 실제로 연체한 차주에게 10%를 예측했다면 손실은 $(0.1 - 1)^2 = 0.81$, 90%를 예측했다면 0.01이다. 점수가 낮을수록 좋지만 연체의 금전적 손실이 정상 상환의 편익과 다르면 대출 결정에는 별도의 비용 기준이 필요하다.

[17] https://arxiv.org/abs/2605.01428

2.26 슬라이드 26 · 저장된 지식과 인출의 병목

모형이 어떤 사실을 표현 안에 담고 있어도 직접 질문에서 즉시 꺼내지 못할 수 있다. 추가 추론을 제공했을 때 정답이 나오면 자료의 부재와 인출 실패를 구분할 단서가 된다. 다만 특정 벤치마크에서 높은 인코딩 비율을 모든 금융 사실로 일반화할 수는 없다.

공시나 법규처럼 날짜에 민감한 사실은 모형 내부 기억보다 원문 검색이 필요하다. 검색 후에도 문단이 질문의 회사·기간에 맞는지 확인하고 숫자는 계산기로 검산한다. Calderon 등[18]은 지식의 저장과 접근을 구분한다.

인출 실험은 질문을 단계별로 바꿔 볼 수 있다. 먼저 회사와 기준일만 주고 답하게 한 뒤, 동일한 문제에 공시 제목, 원문 단락, 정확한 표를 차례로 제공한다. 정답률이 어느 단계에서 올라가는지 보면 검색 실패와 숫자 해석 실패를 어느 정도 분리할 수 있다. 그러나 추가 문맥이 정답을 **새로 가르쳤을 수도** 있으므로, 힌트를 받은 뒤 맞힌 사실만으로 모형이 원래 그 사실을 기억했다고 증명하지는 못한다.

2.27 슬라이드 27 · 보이는 추론의 한계

단계별 설명은 오류를 발견하는 데 도움이 되지만, 화면에 보이는 설명이 모형 내부에서 실제로 사용한 모든 원인을 기록한다고 볼 수 없다. 설명 자체가 평가의 대상이 되면 그럴듯한 절차를 쓰는 데 최적화될 수도 있다.

설명의 검증 가능성을 높이려면 각 중간값을 외부에서 다시 계산할 수 있게 해야 한다. 예를 들어 영업이익 조정이라면 원문 표의 행, 일회성으로 분류한 이유, 조정 전후의 숫자를 따로 적는다. 자연어로 길게 '생각한 과정'을 제시하는 것보다 짧은 산식과 원문 위치가 더 강한 감사 흔적이 된다.

간단한 반사실 점검도 유용하다. 매출 100과 비용 80을 입력해 영업이익 20을 얻은 뒤, 다른 조건을 고정하고 비용만 90으로 바꿔 다시 계산시키면 영업이익은 10이 되어야 한다. 답변이 여전히 20이거나 근거 문장만 그럴듯하게 바뀐다면 제시된 단계가 실제 계산을 보장하지 못한 것이다. 이런 입력 변화 시험은 모형 내부 과정을 증명하지는 않지만, 외부에서 확인 가능한 계산 일관성을 시험한다.

2.28 슬라이드 28 · 다음 토큰 맞히기가 만드는 능력

추리소설의 마지막 단어를 잘 예측하려면 앞선 사건과 인물의 관계를 추적해야 한다. 따라서 단순해 보이는 훈련 목표가 복잡한 표현 능력을 유도할 수 있다. 이는 "다음 토큰 예측"이 사소한 기능이라는 뜻이 아니다.

하지만 새로운 사례에서의 이해를 인간의 이해와 동일시해서도 안 된다. 훈련 목표가 요구한 규칙성과 실제 금융 판단의 목표가 다를 수 있다. 원리의 강점과 한계를 동시에 평가하려면 새 자료에서의 결정 성과가 필요하다.

이를 '압축된 규칙 학습'과 '특정 문서 암기'의 차이로도 볼 수 있다. 새로운 회사의 새 공시에서 반복되는 회계 관계를 적용한다면 일반화의 증거가 강해진다. 반면 훈련 시점 이전의 유명 기업 사건만 정확히 답한다면 사건 이름이나 표현을 기억했을 가능성이 남는다. 금융 벤치마크는 회사·기간·문구가 다른 새 사례를 포함해야 이 둘을 더 잘 구별한다.

[18] https://arxiv.org/abs/2602.14080

2.29 슬라이드 29 · 산술은 외부 도구로 분리하기

여러 숫자를 더하는 일은 결정적 알고리즘으로 정확히 수행할 수 있다. 언어모형이 숫자 패턴을 바탕으로 합계를 추측하게 둘 이유가 없다. 순서를 바꾸어도 합계가 같아야 한다는 **불변성 검사**는 계산 오류를 찾는 간단한 방법이다.

분석 흐름은 **항목·단위 추출 → 표로 구조화 → 계산기로 합산 → 원문과 대조**다. 계산 전에 각 숫자의 출처 행, 부호, 단위, 연결 범위를 고정한다. 연결 매출 100억 원에 이미 포함된 자회사 매출 30억 원을 다시 더하면 130억 원이라는 산술은 맞아도 회계 범위가 틀린다. 괄호 속 손실을 양수로 읽거나 천 원과 백만 원을 섞는 오류도 같은 단계에서 잡아야 한다. 금액 단위를 통일하고 부분합을 공시 총계와 대조하면 입력 해석과 계산의 오류를 분리할 수 있다.

2.30 슬라이드 30 · 유창함 대신 재현성을 기준으로

좋은 금융 답변은 출처, 기준일, 단위, 계산 경로, 불확실성을 드러낸다. 중요한 결론은 독립된 원자료와 계산으로 확인한다. 여러 모형의 답이 일치해도 같은 잘못된 출처를 사용했다면 검증이 되지 않는다.

주식 매수 비율처럼 개인 사정을 모르는 상태에서 제시된 그럴듯한 숫자는 맞춤형 결론이 아니다. 독자는 질문의 빈칸을 먼저 채운다. 투자 기간과 제약, 비교 대안, 손실 한도, 정보의 날짜가 정해져야 비로소 예측을 행동으로 바꿀 수 있다.

최종 답변을 '입력 근거 → 추출 숫자 → 산식 → 판단' 순서로 읽어 보자. 각 화살표에서 근거가 끊기면 그 뒤의 유창한 문장은 검증되지 않는다. 예컨대 공시 페이지에서 순이익 100억 원을 확인하고 일회성 이익 20억 원을 차감해 조정 순이익 80억 원을 얻더라도, 주가가 이미 이를 반영했다면 매수 판단은 별개다. 원문 검증, 계산 정확성, 투자 가치 판단을 서로 다른 관문으로 둬야 한다.

3 정규화 회귀와 수익률 예측

주식시장의 미래 수익률은 평균은 작고 변동성은 큰 자료에서 추정해야 한다. 표본 안에서 잘 맞는 식은 과거의 우연을 익혔을 수 있다. 이 장에서는 비교 가능한 표본외(out-of-sample, OOS) 채점 규칙을 세우고, 추정오차가 왜 커지는지 유도한 뒤, Ridge regression(능형회귀)·Lasso(라쏘)·cross-validation(교차검증)이 어떤 편향을 의도적으로 도입하는지 단계별로 살핀다.

3.1 슬라이드 01 · 수익률 예측의 출발점

AI가 금융에서 유용하려면 과거의 가격을 설명하는 것보다 **아직 보지 않은 수익률**을 예측해야 한다. 시장 전체의 수익률은 종목 간 상대 순위를 맞히는 일과 다르다. 한 해에 모든 주식이 함께 떨어질 수 있어 시장 시계열 예측에는 거시 상태가 중요하다.

예측의 단위부터 고정하자. 월말 t에 알려진 정보로 다음 한 달 초과수익률을 예측하는지, 다음 1년 누적수익률을 예측하는지에 따라 변동성과 투자 가능성이 달라진다. 평가 시점보다 늦게 공표된 경제지표를 x_t에 넣으면 실제로는 만들 수 없는 전략을 검사하게 된다.

예측 대상을 시장 초과수익률 $r_{M,t+1} - r_{f,t}$로 둘지 종목별 시장 대비 수익률 $r_{i,t+1} - r_{M,t+1}$로 둘지도 정해야 한다. 모든 종목이 다음 달 5% 하락할 것을 맞혀도 종목 간 차이는 예측하지 못한 것이고, A가 시장보다 2%포인트 높고 B가 2%포인트 낮을 것을 맞혀도 시장 방향은 틀릴 수 있다.

3.2 슬라이드 02 · 앞 장에서 이어지는 문제

금융의 예측 신호는 가격·뉴스·재무비율에 퍼져 있지만 수익률의 대부분은 뜻밖의 충격이다. 관계가 시간에 따라 변하는 비정상성도 있다. 그러므로 복잡한 모형을 쓰기 전에 약한 신호와 짧은 실효 표본이라는 제약을 받아들여야 한다.

작은 신호를 제한된 역사에서 얼마나 정밀하게 추정할 수 있는지가 핵심이다. 여러 후보 중 표본 안에서 가장 큰 상관을 고르는 선택도 학습 과정이므로, 그 표본을 독립 채점에 다시 쓰지 않는다.

진짜 신호가 월 기대수익률을 0.1%포인트 바꾸는데 월 수익률의 표준편차가 5%라면, 한 관측에서 신호는 잡음의 50분의 1 수준이다. 표본내 상관이 크지 않아도 신호가 없다는 뜻은 아니지만, 후보 100개 중 가장 잘 맞는 하나를 고르면 잡음을 신호로 오인하기 쉽다. 정규화의 목적은 이 제한된 정보를 여러 계수에 과도하게 나누어 쓰지 않는 것이다.

3.3 슬라이드 03 · 시장 수익률 예측의 오래된 실패

배당수익률이나 금리 스프레드가 높을 때 다음 해의 시장 수익률이 달라질 수 있다는 이론은 그럴듯하다. 문제는 과거 자료에서 찾은 관계가 미래에도 남는가다. 발표 시점까지의 자료를 모두 사용해 회귀한 뒤 같은 기간을 채점하면 미래 정보가 추정에 들어간다.

배당수익률의 관계가 경기침체 몇 해에만 나타났는지 확인하려면 원자료를 시간순으로 그려 극단 관측치를 표시한다. 예측 성능은 **각 과거 시점에서 가능했던 계산**으로 채점한다. 1980년까지 추정한 기울기 b는 1981년 예측에 쓸 수 있지만, 2020년까지 재추정한 b를 1981년 예측에 쓰면 미래 정보가 섞인다.

3.4 슬라이드 04 · 평균보다 큰 변동성

주식시장의 연평균 수익률이 양수라도 매년 수익률은 크게 흔들린다. 평균이 10% 안팎이고 표준편차가 20% 안팎이면 한 해 관측치의 신호대잡음비는 대략 0.5에 불과하다. 평균을 정확히 추정하려면 단순히 주가 관측 횟수보다 긴 기간이 필요하다.

더 중요한 것은 예측 대상이다. 올해의 주가지수 수준을 아는 것은 내년의 초과수익률을 아는 것과 다르다. 채점에서는 배당을 포함한 총수익률과 무위험수익률을 뺀 초과수익률의 정의를 일관되게 써야 한다.

연간 수익률 n개의 평균 $\bar{r}$은 한 해 수익률보다 덜 흔들린다. 서로 독립이고 각 연도의 분산이 σ^2라면 $\mathrm{Var}(\bar{r}) = \mathrm{Var}(\sum_t r_t/n) = n\sigma^2/n^2 = \sigma^2/n$이다. 따라서 평균의 표준오차는 $\sigma/\sqrt{n}$이다. 표준편차 19.4%인 연간 총수익률 98개로 평균을 추정하면 표준오차는 $19.4\%/\sqrt{98} \approx 1.96\%$포인트다. 이를 1%포인트로 줄이려면 독립 연도가 대략 $(19.4/1)^2 = 376$개 필요하다.

표준오차 약 2%포인트는 **평균 추정치**의 불확실성이고, 19.4%는 **한 해 수익률**의 표준편차다. 연간 초과수익률의 평균 8.4%, 표준편차 19.7%를 별도로 사용하면 평균이 0이라는 가설의 t값은 $8.4/(19.7/\sqrt{98}) \approx 4.22$다. 같은 98년을 일별로 쪼개도 독립적인 연도 수가 늘지는 않는다. 자기상관이나 시장의 구조 변화가 있으면 단순 표준오차를 조정해야 한다.

3.5 슬라이드 05 · 예측변수 동물원

미래 수익률을 오늘 알 수 있는 정보와 연결하려면 관측 시점을 먼저 맞춰야 한다. x_t는 시점 t에 이미 공개된 배당/주가·장단기금리차 같은 지표, r_{t+1}은 **그 뒤 기간**의 수익률이다. 가장 단순한 예측 회귀 $r_{t+1} = a + bx_t + \varepsilon_{t+1}$에서 a는 기준 수익률, b는 x_t가 한 단위 달라질 때 예측 수

익률이 얼마나 변하는지 나타내는 기울기다. ε_{t+1}은 식이 설명하지 못한 부분이며, 조건부 평균을 $a + bx_t$로 읽으려면 $E[\varepsilon_{t+1} \mid x_t] = 0$이 필요하다.

변수가 많아질수록 과거에 우연히 잘 맞은 지표를 고르기 쉬워진다. 경제적으로 그럴듯한 이유와 통계적 유의성만으로 끝내지 않고, 선택 과정 전체를 포함해 미래 예측 성능을 봐야 한다.

계수 b는 변수의 기록 단위에 따라 숫자가 달라지므로, 비교할 때는 배당수익률 1%포인트 상승처럼 실제 변화에 대한 예측 수익률을 보고한다.

배당수익률을 소수로 기록하고 추정 기울기가 $b = 2$라면 x가 0.04에서 0.05로 1%포인트 올라갈 때 예측 수익률은 $2(0.05 - 0.04) = 0.02$, 즉 2%포인트 높아진다. x를 4와 5처럼 퍼센트 숫자로 저장했다면 같은 예측을 만드는 기울기는 0.02다. 계수 수치만 비교하면 100배 차이처럼 보이지만 경제적 예측은 같다.

3.6 슬라이드 06 · 높은 배당수익률의 두 해석

매년 배당이 g로 성장하고 요구수익률이 $r > g$로 일정하다면, 고든 성장모형에서 $P_t = D_{t+1}/(r - g)$이다. 양변을 정리하면 $D_{t+1}/P_t = r - g$다. 배당 대비 가격이 낮을 때 높은 미래 수익률 r 때문일 수도 있고 낮은 배당성장률 g 때문일 수도 있다.

따라서 배당수익률의 계수에 인과적 이름을 곧장 붙일 수 없다. 경기침체기에 위험 보상이 올라 가격이 떨어졌다면 이후 수익률이 높아질 수 있다. 기업의 배당 성장 자체가 나빠졌다면 같은 높은 배당수익률이 좋은 투자 신호가 아닐 수도 있다.

관찰된 다음 배당 대비 가격 비율이 8%라고 하자. 요구수익률 12%와 성장률 4%도, 요구수익률 9%와 성장률 1%도 $r - g = 8\%$를 만족한다. 현재 비율 하나로는 두 조합을 식별할 수 없다. 실제 배당이 일정 비율로 영원히 자라고 r과 g가 고정된다는 강한 가정을 풀면 이 구분은 더 어려워진다.

예측모형의 다음 기간 기대 초과수익률이 3%로 역사적 평균 8%보다 낮아도 매도 여부는 별도로 결정한다. 두 값의 추정 오차와 수익률 기간을 확인하고, 투자자의 위험회피·기존 보유 비중·거래비용을 넣어 포트폴리오를 다시 계산해야 한다.

질문: 할인율과 성장률 설명을 어떻게 더 가려낼 수 있나요? 이후 실현된 배당 성장과 초과수익률을 함께 봅니다. 할인율이 높아진 상태라면 이후 기대수익률이 높고, 성장 전망 악화라면 이후 현금흐름이 낮을 가능성이 있습니다. 두 결과 모두 새로운 충격의 영향을 받으므로 단일 관측으로 확정할 수는 없습니다.

3.7 슬라이드 07 · 자료를 잘게 나누어도 평균은 정밀해지지 않는다

전체 기간을 T년, 관측 간격을 h년이라고 하자. 독립 로그수익률 X_k가 평균 μh, 분산 $\sigma^2 h$를 가지면 $n = T/h$개를 합한 연율 평균 추정치는 $\hat{\mu} = \sum_k X_k / T$다. 독립성 때문에 분산은 다음과 같이 계산된다.

$$\mathrm{Var}(\hat{\mu}) = \frac{n\sigma^2 h}{T^2} = \frac{\sigma^2}{T}.$$

1년을 12개월로 나누면 한 달 증가량의 분산은 $\sigma^2/12$이고 12개를 합한 분산은 다시 σ^2다. 252일로 나누어도 같은 원리가 적용된다. 이 계산은 증가량의 독립성을 사용한다. 자기상관이 있으면 날짜 쌍의 공분산을 더해야 하며, 관측 간격을 줄여도 장기 평균을 판단할 달력상의 역사가 늘지는 않는다.

질문: 일별 수익률에 자기상관이 있으면 결론이 어떻게 바뀌나요? 연율 평균 추정의 분산에 날짜 쌍의 공분산이 더해집니다. 양의 자기상관은 유효 정보량을 줄이고 음의 자기상관은 반대 방향으로 작용할 수 있어, 독립 증가량 공식 그대로 표준오차를 계산하면 안 됩니다.

3.8 슬라이드 08 · 단순수익률, 로그수익률, 연속복리

단순수익률은 $R = (P_1 - P_0)/P_0$이고 로그수익률은 $r = \ln(P_1/P_0) = \ln(1+R)$이다. R이 작을 때 테일러 전개 $\ln(1+R) = R - R^2/2 + \cdots$로 둘이 가까워진다. 여러 기간의 가격비는 곱이므로 로그를 취하면 수익률은 합이 된다.

$$\frac{P_n}{P_0} = \prod_{k=1}^{n}(1+R_k), \qquad \ln\frac{P_n}{P_0} = \sum_{k=1}^{n} r_k.$$

연 r을 m번 복리로 적용한 $(1+r/m)^m$은 $m \to \infty$에서 e^r로 간다. 로그수익률의 합산성과 짧은 구간 분산의 비례관계는 독립 또는 적절한 약한 의존 조건을 구분해 사용해야 한다.

주가가 100에서 110으로 오르고 다시 100으로 내려오면 단순수익률은 10%와 약 -9.09%다. 둘을 더하면 약 0.91%이지만 로그수익률은 $\ln(1.1) + \ln(100/110) = 0$으로 정확히 합산된다. 다만 투자자의 원화 손익을 계산할 때는 단순수익률의 곱셈식이 직접적이다.

시간에 따른 합산과 **같은 시점의 종목 간 합산**은 서로 다르다. 기초자산에 처음 자산의 w와 $1-w$를 나누어 투자했다면 한 기간 포트폴리오의 단순수익률은 $R_p = wR_A + (1-w)R_B$이다. 반면 로그수익률은 $\ln(1+R_p) = \ln[1+wR_A+(1-w)R_B]$이므로 일반적으로 $w\ln(1+R_A)+(1-w)\ln(1+R_B)$가 아니다. 예를 들어 절반씩 투자한 두 종목이 각각 $+20\%$와 -20%이면 포트폴리오 단순·로그수익률은 모두 0이지만 개별 로그수익률의 평균은 $\frac{1}{2}\ln(1.2) + \frac{1}{2}\ln(0.8) = \frac{1}{2}\ln(0.96) < 0$이다. 로그의 시간 합산성을 횡단면 평균에 옮겨 쓰면 안 된다.

위 식이 주가 P만으로 적혀 있으므로 배당이 있는 주식에는 그대로 적용하면 안 된다. 해당 기간에 현금배당 D를 받았다면 재투자하지 않은 한 기간의 단순 총수익률은 $(P_1 + D - P_0)/P_0$다. 로그 총수익률을 기간별로 합산하려면 배당 재투자 기준의 총수익지수를 먼저 만들고 그 지수의 로그비를 써야 한다. 가격수익률과 총수익률을 섞으면 예측 대상 자체가 바뀐다.

3.9 슬라이드 09 · 일별 자료의 다른 역할

일별 자료는 단기 변동성을 추정하는 데 유용하다. 최근 일별 수익률 제곱이 내일의 위험과 이어진다면 포지션 크기를 조정할 수 있다. 반면 연평균 기대수익률의 작은 차이는 일별 잡음에 묻힌다. 더구나 호가 스프레드, 비동시 거래, 가격 정체가 일별 수익률에 가짜 자기상관을 만들 수 있다. **분산 추정과 평균 예측**의 성능은 각각 검증해야 한다.

호가 차이만으로 생기는 움직임을 수치로 보자. 진짜 중간가격이 100원으로 일정하고 매수·매도 체결가격이 각각 101원과 99원이면, 마지막 거래가 99원에서 101원으로 바뀐 수익률은 약 2.02%다. 가치가 변하지 않았어도 다음 거래가 반대편 호가에서 일어나면 수익률이 되돌아온다. 이런 미시구조 효과를 경제적 기대수익률의 변화로 읽지 않아야 한다.

비동시 거래는 다른 모양의 가짜 예측력을 만든다. 두 종목 A·B가 같은 시장 소식에 동시에 2%씩 반응하지만 B의 마지막 체결은 소식 전인 오후 2시, A의 종가는 소식 후인 오후 4시에 기록되었다고 하자. 오늘 관측수익률은 A가 2%, B가 0이고, 내일 B가 거래되어 가격이 반영되면 A는 0, B는 2%로 기록될 수 있다. 매일 동일가중으로 다시 맞춘 포트폴리오의 관측수익률은 이틀 연속 1%가 되어 자기상관이나 A의 선행성을 암시한다. 그러나 오후 3시에 소식을 알았을 때 B의 **오후 2시 체결가격으로 매수할 수는 없다**. 관측된 종가의 시간 차이와 실행 가능한 가격을 구분해야 한다.

3.10 슬라이드 10 · 표본 안의 유의성

예측 회귀에서 t값이 크거나 장기 R^2가 높다는 결과는 먼저 표본 내 사실이다. 변수를 고른 기간과 계수를 추정한 기간이 같으면 선택 편향이 발생한다. 장기 수익률은 겹치는 기간이 많아 표준오차 계산도 까다롭다.

같은 자료에서 후보 변수를 100개 시험해 가장 높은 t값 하나를 보고하면 그 값의 통상적인 유의수준은 적용되지 않는다. 장기 수익률을 겹치게 만들면 예컨대 12개월 수익률 두 개가 11개월을 공유해 오차도 강하게 상관된다. 표준오차와 변수 선택을 모두 감안한 뒤에야 신뢰도를 말할 수 있다.

독립이고 같은 분산의 월별 충격을 12개 더한 수익률을 생각하자. 연속한 두 12개월 수익률은 11개의 같은 월별 충격을 공유한다. 각 합의 분산은 $12\sigma^2$, 두 합의 공분산은 $11\sigma^2$이므로 상관은 $11/12$다. 원래 월별 충격이 독립이어도 **겹치는 목표를 만드는 순간** 회귀 오차가 강하게 의존한다는 점이 표준오차 계산의 핵심이다.

3.11 슬라이드 11 · 표본내와 표본외를 구분하기

표본내 적합은 전체 기간으로 a, b를 추정한 후 같은 자료에서 잔차를 계산한다. 표본외 검증은 각 시점 t에 t까지의 자료만으로 $\hat{a}_t, \hat{b}_t$를 추정해 $\hat{r}_{t+1} = \hat{a}_t + \hat{b}_t x_t$를 만든다. 이후 r_{t+1}이 실현되면 오차를 기록한다.

재귀 예측은 첫 훈련 구간을 정해 한 시점의 예측을 저장하고, 실현값이 나온 뒤에만 자료를 추가해 다시 적합한다. 2000~2010년 자료로 2011년 1월을 예측했다면 1월 실현값을 더한 뒤 2월을 예측한다. 2011년 전체를 보고 재학습 주기나 변수를 다시 선택하면 그 해의 점수는 독립 시험이 아니다. 모형 선택과 예측 저장 시점을 함께 기록해야 한다.

3.12 슬라이드 12 · 과거 평균과 표본외 결정계수

벤치마크는 예측변수 없이 시점 t까지의 평균 $\bar{r}_t$를 다음 수익률 예측으로 쓰는 것이다. 모형과 벤치마크의 제곱오차 합을 비교한다.

$$R^2_{\text{OOS}} = 1 - \frac{\sum_t (r_{t+1} - \hat{r}_{t+1})^2}{\sum_t (r_{t+1} - \bar{r}_t)^2}.$$

예를 들어 벤치마크 제곱오차 합이 100이고 모형이 98이면 $R^2_{\text{OOS}} = 1 - 98/100 = 0.02$다. 모형이 105라면 -0.05다. 표본내 OLS는 같은 자료의 절편만 있는 모형보다 잔차 제곱합이 클 수 없지만, 미래에는 그 보장이 없어 음수가 자연스럽게 가능하다.

이때 벤치마크의 과거 평균도 각 시점에 **그때까지**의 수익률로 다시 계산해야 한다. 나중의 전체 표본평균을 모든 과거 시점에 적용하면 벤치마크가 미래를 훔쳐본다. 모형과 기준선의 정보 집합을 맞춰야 R^2_{OOS}가 '추가 변수의 가치'를 측정한다. 또 이 비율은 제곱오차 개선율이지 투자자가 벌어들인 수익률 자체가 아니다.

3.13 슬라이드 13 · 웰치와 고열의 판정

배당수익률 등 많은 시장 예측변수는 과거 표본 안에서 설명력을 보였지만, 시점마다 다시 추정하는 표본외 평가에서는 과거 평균에 뒤졌다. 한 번의 위기 기간에 기울기가 크게 맞아 전체 통계량을 끌어올렸을 가능성도 살펴야 한다.

이 결과는 초과수익 예측을 포기하라는 뜻보다 **비교 기준을 낮추지 말라**는 교훈이다. Welch·Goyal[19]의 누적 오차 그림에서는 선이 내려갈 때 제안 모형이 기준선보다 더 큰 오차를 낸다.

누적 오차 그림이 거의 계속 내려간다면 해당 평가 기간의 많은 시점에서 모형 오차가 컸다는 뜻이다. 반대로 마지막 한 위기에서 급락했다면 평균적인 달과 위기 달의 성능을 분리해 볼 필요가 있다. 두 경우 모두 원 논문의 표본, 예측 시작 시점, 재추정 규칙을 그대로 재현한 뒤에야 새로운 방법과 공정하게 비교할 수 있다.

3.14 슬라이드 14 · 간단한 경제 제약은 도움이 될까

배당수익률이 높으면 미래 수익률이 높다는 부호를 강제하거나, 예상 초과수익률의 음의 추정값을 0으로 절단하는 규칙은 경제적 사전 믿음을 예측에 넣는다. 극단적인 음의 추정값이 잡음이면 오차를 줄이지만, 실제 기대값이 음수인 기간에는 편향을 만든다. 제약의 순효과는 이후 기간의 예측오차와 투자 성과로 평가한다.

월별 R^2_{OOS}가 작아도 평균·분산 투자자는 포트폴리오 비중을 개선할 수 있다. 다만 기대효용 증가는 위험회피계수, 매매비용, 차입 제약에 민감하다. Campbell·Thompson[20]의 주장은 통계 점수와 경제적 가치를 구분해 읽어야 한다.

위 비중식은 위험자산 비중 w의 근사 효용 $U(w) = w\hat{\mu} - \gamma w^2\sigma^2/2$를 최대화해 얻는다. 미분하면 $dU/dw = \hat{\mu} - \gamma w\sigma^2 = 0$이므로 $w^* = \hat{\mu}/(\gamma\sigma^2)$다. 위험회피계수 $\gamma = 4$, 월 분산 $\sigma^2 = 0.0025$, 예상 월 초과수익률 $\hat{\mu} = 0.005$라면 제약 없는 비중은 0.5다. 차입 금지나 최대 비중 규칙이 있으면 이 해를 허용 범위로 제한한다.

3.15 슬라이드 15 · 시간이 지난 뒤의 재검증

첫 논쟁 이후 발표된 새 변수도 발표 당시의 자료에는 잘 맞을 수 있다. 독립된 후속 기간과 공통한 기준으로 다시 평가하면 결과가 약해지기도 한다. 이는 예측 관계가 소멸했을 수도 있고, 처음부터 선택 편향이 있었을 수도 있음을 뜻한다.

두 설명을 가르려면 원 논문의 표본 종료일, 논문 발표일, 이후 기간을 따로 본다. 발표 전에 이미 감소했다면 데이터 채굴이나 불안정성의 비중이 클 수 있다. 발표 후 추가 감소에는 투자자의 반응도 기여할 수 있다.

예를 들어 원 논문이 2000년 자료까지 썼고 2005년에 공개되었다면 2001~2004년은 **표본 밖이지만 발표 전**, 2005년 이후는 **표본 밖이면서 발표 후**다. 첫 구간에서도 성과가 나쁘면 발표에 따른 투자자 반응만으로는 설명할 수 없다. 두 구간의 길이와 시장 상태가 다를 수 있으므로 평균 차이 하나보다 위험·거래비용·표본 수를 함께 기록한다.

3.16 슬라이드 16 · 유의성·안정성·실용성의 깔때기

변수가 표본내 유의성을 유지하는지, 같은 부호로 표본외 예측을 하는지, 거래비용 뒤에도 투자의사결정을 개선하는지는 서로 다른 관문이다. 앞 관문을 통과해도 뒤 관문을 자동으로 통과하지 않는다.

새 논문의 수를 세어 "성공률"이라고 부를 때는 각 연구가 사용한 시작일, 예측 기간, 재추정 방식이 같은지 확인해야 한다. 공정한 비교는 변수 자체뿐 아니라 **검증 절차**를 맞춘다.

[19] https://doi.org/10.1093/rfs/hhm014

[20] https://doi.org/10.1093/rfs/hhm055

가상의 전략이 표본내에서 $t = 2.4$로 유의하고 표본외에서도 순위를 조금 개선했다고 하자. 월 총수익이 운용자산의 0.30%, 한 달 거래 명목금액이 운용자산의 두 배, 거래된 금액당 비용이 0.10%라면 순수익은 $0.30\% - 2(0.10\%) = 0.10\%$다. 여기서 회전율의 분모와 비용에 차입료·시장 충격이 포함됐는지까지 정해야 마지막 관문을 통과했다고 말할 수 있다. 통계적 성공이 실용적 성공보다 앞선다는 뜻이지 앞의 점수가 뒤의 점수로 환산된다는 뜻은 아니다.

3.17 슬라이드 17 · 누적 오차 차이 그래프 읽기

그래프의 세로축이 누적 $\text{SSE}_{\text{bench}} - \text{SSE}_{\text{model}}$이면 상승은 예측변수의 승리, 하락은 과거 평균의 승리다. 선이 특정 위기 이후 꺾이는 경우에는 기울기 자체가 달라졌는지, 큰 한두 관측치가 오차를 지배했는지 확인한다.

표본내 선과 표본외 선이 벌어지면 과거를 맞힌 계수가 미래에는 통하지 않았다는 뜻이다. 그래프의 0선뿐 아니라 기울기의 안정성과 표본 종료일 표시를 함께 보아야 한다.

누적 곡선의 한 시점 증가분은 $e^2_{\text{bench,t}} - e^2_{\text{model,t}}$이다. 예를 들어 기준선 오차가 3이고 모형 오차가 1이면 해당 시점에서 곡선은 $9 - 1 = 8$만큼 오른다. 큰 위기 관측치 하나가 긴 기간의 완만한 하락을 뒤집을 수 있으므로, 전체 결과와 극단 시점을 뺀 결과를 함께 읽는다.

평가 종료일의 누적값을 $C = \text{SSE}_{\text{bench}} - \text{SSE}_{\text{model}}$이라 놓으면 $R^2_{\text{OOS}} = C/\text{SSE}_{\text{bench}}$다. 따라서 누적 선의 높이가 양수면 그 종료일까지의 표본외 결정계수도 양수다. 하지만 선이 상승하는 한 구간이 있다고 해서 전체 기간 성과가 양수인 것은 아니다. 기울기는 **그때그때의 오차 차이**, 최종 높이는 **전체 오차 차이**를 나타낸다.

3.18 슬라이드 18 · 첫 단계의 결론

예측변수가 많아도 과거 평균보다 좋다는 주장은 어렵게 입증해야 한다. 기준선은 쉽게 이길 수 있는 허수아비가 아니라 실제로 이용 가능하고 추정오차가 작은 대안이어야 한다. 정확도가 조금 높아도 구현 비용과 위험을 함께 본다.

정규화는 추정된 계수를 0 쪽으로 당겨 분산을 줄이는 방법이다. 참 기울기가 0이면 큰 표본내 기울기는 잡음이므로 강한 축소가 유리하다. 참 기울기가 작지만 0은 아니면 신호의 일부를 남기는 편이 낫다. 신호가 전혀 없는 자료에서 벌점이 예측력을 만들 수는 없다. **얼마나 축소할지**는 미래 구간에서 기준선보다 오차를 얼마나 줄이는지로 정한다.

3.19 슬라이드 19 · 왜 실패하는가

진짜 조건부 기대수익률이 존재해도 매번 실현 수익률에는 큰 예측 불가능한 충격이 들어온다. 잡음이 클 때 회귀계수는 작은 표본의 우연에 따라 크게 달라진다. 변수 수가 늘면 그 우연을 설명할 자유도가 늘어난다.

한 변수 모형의 참 기울기가 b, 추정값이 $\hat{b} = b + u$라면 계수 추정 때문에 생긴 다음 시점의 예측 오차는 ux_t다. x_t가 큰 상태에서는 작은 u도 큰 전망 오류가 된다. 예측 수익률에 비례해 투자 비중을 정하면 불안정한 계수가 매수·매도 전환과 높은 회전율로 이어진다. 표본내 적합, 계수의 표준오차, 거래비용 뒤 성과를 함께 보아야 한다.

3.20 슬라이드 20 · 작은 참 신호의 규모

$y = f(x) + \varepsilon$이고 신호와 잡음이 독립이라면 참 예측 가능 비율은 $R^2_{\text{true}} = \text{Var}(f(x))/[\text{Var}(f(x)) + \text{Var}(\varepsilon)]$이다. 조건부 평균의 표준편차가 잡음의 1/10이면 $R^2 = 0.01/1.01 \approx 0.99\%$다.

조건부 평균 $f(x)$를 정확히 알아도 이 예에서는 전체 분산 1.01 가운데 잡음 분산 1이 남는다. 실제로는 f를 추정해야 하므로 추정오차가 약 1%의 이득을 넘으면 표본외 R^2가 음수가 될 수 있다. 이는 $E[\varepsilon \mid x] = 0$이라는 조건부 평균 가정 아래의 계산이다. **참 예측 가능 비율**과 추정 모형의 실제 점수를 따로 보아야 한다.

3.21 슬라이드 21 · 과적합 모의실험을 직접 구성하기

관측치 120개에서 후보 변수 110개를 만들되 실제 영향이 있는 것은 첫 10개라고 하자. 독립 표준정규 변수와 잡음의 분산을 1로 두고 참계수를 모두 c로 정하면 신호분산은 $10c^2$다. 참 $R^2 = 5\%$가 되게 하려면 $10c^2/(10c^2+1) = 0.05$를 풀어 $c^2 = 1/190$을 얻는다.

$c^2 = 1/190$이면 각 진짜 계수의 절댓값은 약 0.073이다. 잡음 표준편차가 1인 자료에서 이 신호를 120개 관측으로 분리하기 쉽지 않다. 시뮬레이션을 여러 번 반복해 평균 훈련·시험 곡선을 그리면 단일 난수 추첨의 운과 변수 수가 만드는 체계적 변화를 구별할 수 있다.

절편까지 포함해 110개 변수를 120개 관측에 OLS로 적합하면 잔차 자유도는 $120 - 111 = 9$뿐이다. 훈련자료를 맞힐 방향이 많지만 계수를 안정적으로 확인할 독립 여유는 거의 없다. 변수가 더 늘어 열들이 선형 종속이 되면 보통의 역행렬 공식도 쓸 수 없고, 최소제곱 해가 여러 개일 수 있다. 모의실험에서 훈련오차의 하락과 새 표본 오차의 상승을 동시에 그리는 이유다.

3.22 슬라이드 22 · 변수 증가와 벌점의 효과

OLS는 변수를 추가할 때 표본내 제곱오차가 증가할 수 없다. 추가 변수를 쓰지 않도록 계수를 0으로 놓는 선택이 항상 가능하기 때문이다. 그러나 미래 자료에서는 잡음에 맞춘 계수가 오차를 키울 수 있다.

같은 변수 수를 유지하고 능형회귀의 벌점을 키우면 표본내 적합은 다소 낮아지지만 표본외 오차가 줄어드는 구간이 생긴다. 벌점이 너무 크면 유용한 신호까지 지워 다시 나빠진다. 그래프의 최저점은 사전 고정값이 아니라 독립 자료로 선택해야 한다.

한 계수만 있는 단순 문제에서 OLS 추정치가 z라면 Ridge의 축소해는 적절한 정규화 아래 $\hat{\beta}_\lambda = z/(1+\lambda)$처럼 표현된다. $\lambda = 0$이면 OLS이고 $\lambda \to \infty$이면 0으로 간다. 참계수가 작고 z의 잡음이 크면 약한 축소는 분산을 낮추지만, 참계수가 큰데 너무 강하게 줄이면 편향이 커진다. **시험자료를 보며** 최적 λ를 고르는 것은 평가 자료에 다시 적합하는 행위다.

3.23 슬라이드 23 · 차원이 커질 때 추정오차의 유도

기업별 참 평균수익률을 모은 벡터가 $\mu = Xg$라고 하자. X의 K개 열은 기업 특성이고 g는 그 특성의 계수다. τ개의 독립 기간에서 계산한 평균은 $\bar{r} = \mu + \bar{\varepsilon}$이며 잡음의 공분산을 $\sigma^2 I/\tau$로 가정한다. OLS는 관측 평균을 X의 열들이 표현할 수 있는 K차원 공간에 투영한다. 투영행렬 $P = X(X^\top X)^{-1}X^\top$를 쓰면 $\hat{\mu} = P\bar{r} = \mu + P\bar{\varepsilon}$이다. 마지막 등식에는 참 평균도 그 공간 안에 있다는 $P\mu = \mu$를 썼다.

$$
\begin{aligned}
E\|\hat{\mu}-\mu\|^2 &= E[\bar{\varepsilon}^\top P \bar{\varepsilon}] \\
&= \operatorname{tr}\!\left(P \frac{\sigma^2}{\tau} I\right) \\
&= \frac{K\sigma^2}{\tau}.
\end{aligned}
$$

$\hat{\mu}-\mu = P\bar{\varepsilon}$이고 $P^\top P = P$이므로 첫 줄은 $E[\bar{\varepsilon}^\top P \bar{\varepsilon}]$다. 평균 0인 벡터에 대한 $E[z^\top A z] = \operatorname{tr}(A \operatorname{Var} z)$를 쓰면 둘째 줄이 나오고, 투영 공간의 차원만큼 $\operatorname{tr} P = K$여서 마지막 줄이 된다. **특성 방향 하나를 추가할 때마다** 잡음분산 σ^2/τ가 더해진다는 뜻이다. K가 커지면 표본내 적합이 좋아져도 표본외 추정오차는 커질 수 있다.

이 유도에는 $X^\top X$가 역행렬을 갖는, 즉 X의 K개 열이 선형 독립이라는 조건이 있다. 열이 서로 같거나 K가 관측 기업 수보다 크면 표준 OLS 식은 정의되지 않는다. 또 오차 공분산이 Σ라면 결과는 $\operatorname{tr}(P\Sigma/\tau)$가 되어 단순히 $K\sigma^2/\tau$라고 쓸 수 없다. 금융의 공통 충격이 여러 기업 오차를 함께 움직일 때 바로 이 조건을 점검해야 한다.

3.24 슬라이드 24 · 편향과 분산을 식으로 분해하기

같은 x_0에서 새 결과가 $y_0 = f(x_0) + \varepsilon_0$로 나온다고 하자. 새 충격은 평균 0이고 학습자료로 만든 예측 $\hat{f}(x_0)$와 독립이다. 여러 학습표본에 걸친 평균 예측을 $\bar{f} = E[\hat{f}(x_0)]$라 놓고 더했다 빼면 예측오차는 $y_0 - \hat{f} = \varepsilon_0 + (f - \bar{f}) + (\bar{f} - \hat{f})$다. 세 항은 새 충격, 평균적인 편향, 표본에 따른 예측 변동이다. 제곱한 뒤 기댓값을 취하면 평균 0과 독립성 때문에 교차항이 사라진다.

$$
E[(y_0 - \hat{f})^2] = \sigma^2 + \left(f - E\hat{f}\right)^2 + \operatorname{Var}(\hat{f}).
$$

첫 항은 어떤 예측자에게도 남는 새 충격의 분산, 둘째는 체계적으로 빗나간 정도의 제곱, 셋째는 학습표본을 바꿀 때 예측이 흔들리는 정도다. 정규화는 편향을 조금 늘려도 추정 분산을 더 크게 줄이면 총오차를 낮춘다. 시장 국면이 바뀌어 새 충격의 조건부 평균이 0이 아니면 이 분해의 가정을 다시 검토해야 한다.

3.25 슬라이드 25 · 세 오차의 경제적 의미

수익률의 예측 불가능한 충격은 모형을 아무리 정교하게 해도 없앨 수 없다. 편향은 모형이 지나치게 단순해 실제 위험 보상을 놓칠 때 생긴다. 여기서 **모형의 분산**은 훈련표본을 바꿀 때 예측값이 요동치는 정도로, 한 종목의 실제 수익률 변동성과는 다르다. 이 요동은 투자 비중을 불안정하게 만든다.

평균·분산 투자에서 제약 없는 비중은 대략 $w_t = \hat{\mu}_t/(\gamma\sigma_t^2)$다. 위험 추정치와 위험회피계수 γ가 일정하면 예상수익률의 요동이 곧 주문량의 요동이 된다. 전월 비중 0.5가 -0.5로 바뀌면 자산 가치의 한 배만큼 순포지션을 변경해야 한다. 평균 예측오차가 비슷한 두 모형이라도 전망이 불안정한 쪽은 거래비용 뒤 성과가 낮을 수 있다.

3.26 슬라이드 26 · U자형 상충관계

아주 단순한 과거 평균 모형은 변수에 따른 변화를 못 잡아 편향이 크지만 추정이 안정적이다. 모든 변수를 자유롭게 넣는 OLS는 편향이 낮을 수 있으나 잡음에 민감하다. 중간 복잡도에서 합계 오차가 낮아지는 U자형 그림은 이 관계를 요약한다.

그러나 U자의 위치는 자료의 신호대잡음비와 변수 상관에 따라 달라진다. 금융처럼 신호가 약하고 데이터가 짧을수록 왼쪽, 즉 강한 축소 쪽이 유리할 가능성이 크다. 그림은 사전 믿음이며 실제 최저점은 검증에서 찾는다.

그래프는 편향 제곱이 줄고 분산이 늘어나는 **고전적 구간의 도식**이다. 초록색 합계는 각 복잡도에서 편향 제곱, 분산, 일정한 잡음분산을 실제로 더한 값이므로 어느 개별 항보다도 작을 수 없다. 그러나 개별 곡선의 단조 변화나 U자형 전체가 모든 모형에서 성립하는 법칙은 아니다. 극도로 과매개화된 모형에서는 시험오차가 다시 내려가는 double descent[21]도 관찰된다.

3.27 슬라이드 27 · 공짜 점심이 없는 이유

모든 가능한 자료생성과정에 대해 언제나 이기는 추정기는 없다. 능형회귀는 많은 작은 계수가 있다는 믿음, 라쏘는 소수 변수만 중요하다는 믿음을 반영한다. 진실이 다르면 두 방법의 순위도 바뀐다.

참효과가 열 개 변수에 고르게 퍼져 있다면 한두 변수만 남기는 제약은 신호를 버린다. 한 변수에 집중되어 있다면 모든 계수를 남기는 방법은 잡음에 반응하기 쉽다. 변수의 정의·측정오차·거래 가능성을 검토하고, 두 구조를 같은 훈련·검증 기간에서 비교한다. 시험자료의 성적을 보고 구조를 다시 고르면 선택 편향이 생긴다.

3.28 슬라이드 28 · 금융 자료에 맞는 검증

낮은 신호대잡음비는 작은 R^2를 예상하게 하고, 짧은 실효 표본은 계수의 불확실성을 키운다. 시간에 따라 관계가 변하면 임의 분할보다 미래 방향의 검증이 필요하다. 수익률의 공통 충격은 종목 수가 많아도 독립 표본 수가 그만큼 늘지 않음을 뜻한다.

다음 달 수익률 예측을 채점한다면 검증자료를 미래 달에 둔다. 같은 달의 종목을 훈련·검증에 나누면 공통 충격이 양쪽에 들어간다. 산업·회사·기간 중 무엇을 새 환경으로 삼을지에 따라 분할 단위가 달라진다. 그 단위에서 자유도를 제한한 모형과 당시 이용 가능한 단순 기준선을 비교한다.

예측 목표가 앞으로 12개월의 누적수익률이라면 훈련 마지막 관측과 검증 첫 관측의 **결과 기간이 겹칠** 수 있다. 예를 들어 2020년 12월에 시작한 12개월 수익률과 2021년 1월에 시작한 수익률은 11개월을 공유한다. 달력상 행을 분리했어도 목표값이 거의 같은 충격을 담으므로 경계 주변의 중첩 기간을 빼거나 평가 간격을 조정해야 한다.

3.29 슬라이드 29 · 편향을 의도적으로 쓰는 처방

비편향 추정은 참계수를 평균적으로 맞힌다는 장점이 있지만 미래 예측오차를 최소화한다는 보장은 없다. 계수를 0에 가깝게 끌어당기면 약한 신호에서 계수의 요동을 줄일 수 있다. 이 의도적 편향이 **축소추정**이다.

두 처방은 모두 적합과 단순성을 맞바꾼다. 능형회귀는 모든 계수를 연속적으로 줄이고, 라쏘는 일부를 0으로 만든다. 어느 쪽이 맞는지는 실제 변수 효과가 넓게 퍼져 있는지 드문지에 달려 있다.

한 계수의 OLS 추정치 z가 $E[z] = \beta$, $\mathrm{Var}(z) = \sigma_z^2$를 만족하고 이를 az로 축소한다고 하자. 제곱오차의 기대값은 $(1-a)^2\beta^2 + a^2\sigma_z^2$다. 첫 항은 새로 생긴 편향 제곱, 둘째는 남은 분산이다. 이를 a로 미분해 0으로 두면 $a^* = \beta^2/(\beta^2 + \sigma_z^2)$가 되어, 신호가 작거나 추정 잡음이 클수록 더 많이 축소한다. 실제 β는 모르므로 검증자료로 축소 강도를 골라야 한다.

[21] https://arxiv.org/abs/1812.11118

3.30 슬라이드 30 · 첫 번째 처방으로 가기

능형회귀는 OLS의 제곱오차에 계수 크기에 대한 벌점을 더한다. 큰 계수가 꼭 나쁘다는 뜻이 아니라, 약한 자료에서 큰 계수를 확신하려면 그만큼 강한 증거가 필요하다는 뜻이다.

벌점이 계수의 제곱합을 비용으로 보는 이유는 큰 절댓값의 계수에 더 빠르게 증가하는 비용을 붙이기 위해서다. 같은 예측오차를 만드는 두 해가 있다면 계수 크기가 작은 쪽을 선호한다. 절편까지 벌점을 주면 자료의 전체 평균도 0으로 부당하게 당기므로 보통 기울기만 축소한다.

벌점은 계수의 **숫자 크기**에 적용된다. 같은 부채비율을 0.5 또는 50으로 기록하면 동일한 예측의 계수는 100분의 1로 바뀌고 제곱 벌점은 1만 분의 1이 된다. 경제적 효과 대신 기록 단위가 벌점의 크기를 정하지 않도록 변수의 척도를 맞춘다. 평균과 표준편차를 언제 추정할지는 뒤에서 검증 절차와 함께 다룬다.

3.31 슬라이드 31 · OLS의 역행렬이 불안정해지는 이유

$y = Xg + \varepsilon$에서 제곱오차 $(y - Xg)^\top (y - Xg)$를 g에 대해 미분하면 $-2X^\top y + 2X^\top Xg = 0$이다. $X^\top X$가 가역이면 $\hat{g} = (X^\top X)^{-1} X^\top y$다. 변수들이 서로 비슷하면 $X^\top X$의 어떤 방향의 고유값이 아주 작아진다.

추정량의 분산 $\mathrm{Var}(\hat{g}) = \sigma^2 (X^\top X)^{-1}$에서 그 방향의 분산은 $\sigma^2 / \lambda_{\min}$이다. 작은 고유값으로 나누니 계수가 폭발한다. $K > N$이면 열들이 독립일 수 없어 해가 유일하지 않으며, 훈련자료를 완벽히 맞히는 여러 해 가운데 미래에 잘 맞는 해를 OLS만으로 고를 수 없다.

고유값이 작은 방향은 서로 닮은 변수의 '차이'처럼 자료에서 거의 변하지 않는 조합이다. 오차분산이 1이고 그 방향의 고유값이 0.01이면 OLS 계수분산은 $1/0.01 = 100$이다. 고유값이 1인 방향의 분산은 1이다. 역행렬이 존재해도 첫 방향의 개별 계수를 믿기 어려운 이유다. 능형회귀는 고유값에 양의 수를 더해 잡음의 증폭을 제한한다.

3.32 슬라이드 32 · 능형회귀의 해를 직접 유도하기

OLS는 잔차 제곱합만 최소화하므로 거의 같은 변수들의 계수가 크게 흔들릴 수 있다. 능형회귀는 계수 제곱합 $g^\top g$에 벌점 $\gamma > 0$을 주어 $L(g) = (y - Xg)^\top (y - Xg) + \gamma g^\top g$를 최소화한다. 벌점은 큰 계수에 더 큰 비용을 매긴다. g로 미분해 0으로 놓으면 $-2X^\top (y - Xg) + 2\gamma g = 0$, 즉 $(X^\top X + \gamma I) g = X^\top y$이므로 다음 해를 얻는다.

$$\hat{g}_{\text{ridge}} = (X^\top X + \gamma I)^{-1} X^\top y, \qquad \gamma > 0.$$

고유벡터 u_j 방향으로 보면 OLS 성분은 $u_j^\top X^\top y / \lambda_j$, Ridge 성분은 $u_j^\top X^\top y / (\lambda_j + \gamma)$다. 작은 고유값 방향일수록 분모가 상대적으로 크게 늘어 불안정한 조합이 강하게 줄어든다. $\gamma \to 0$이면 가역일 때 OLS로, $\gamma \to \infty$이면 기울기 계수는 0으로 간다. 훈련자료에서 중심화한 뒤 절편을 별도로 추정해 벌점을 주지 않으면 마지막 예측은 과거 평균이다.

3.33 슬라이드 33 · 두 변수로 보는 작은 분모

표준화한 두 변수의 표본 상관이 ρ이고 $c_j = X_j^\top y / N$라 하자. 목적함수에 $1/N$을 붙여 미분하면 $(1 + \gamma) g_1 + \rho g_2 = c_1$, $\rho g_1 + (1 + \gamma) g_2 = c_2$다. 두 식을 더하고 빼면 다음이 나온다.

$$g_1 + g_2 = \frac{c_1 + c_2}{1 + \rho + \gamma},$$
$$g_1 - g_2 = \frac{c_1 - c_2}{1 - \rho + \gamma}.$$

$\rho = 0.99$이고 벌점이 없으면 두 계수의 차이를 0.01로 나눈다. 아주 작은 표본 차이가 거대한 상반 계수로 변한다. $\gamma = 0.1$이면 분모가 0.11이 되어 같은 오차가 훨씬 덜 증폭된다.

$\rho = 0.99$, $c_1 + c_2 = 1.99$, $c_1 - c_2 = 0.02$라면 벌점 0에서 $g_1 + g_2 = 1$, $g_1 - g_2 = 2$이므로 개별 계수는 1.5와 -0.5다. $\gamma = 0.1$이면 합은 $1.99/2.09 \approx 0.952$, 차이는 $0.02/0.11 \approx 0.182$로 바뀌어 계수는 약 0.567과 0.385가 된다. 예측에는 이렇게 공유 정보를 안정화할 수 있다. 두 변수의 개별 효과를 해석하려면 둘이 따로 움직이는 표본이나 별도의 식별 근거가 필요하다.

3.34 슬라이드 34 · 교점 그림의 해석

두 예측변수가 거의 같은 방향이면 각각의 계수를 따로 결정할 정보가 부족하다. 회귀의 제곱오차 등고선은 길고 좁은 타원이 되어 작은 데이터 변화에도 최저점이 타원의 긴 축을 따라 크게 움직인다.

능형 벌점은 원형 등고선을 더해 원점에서 먼 해에 비용을 부과한다. 결과적으로 같은 두 변수의 합이 가진 신호는 어느 정도 보존하고, 두 변수의 차이에 대한 불필요한 확신을 줄인다. 계수 하나의 해석보다 둘의 합이 더 안정적일 수 있다.

두 설명변수가 완전히 동일한 $x_1 = x_2$이면 예측은 $(g_1 + g_2)x_1$에만 의존한다. 제곱오차는 계수의 **합**만 정하고 개별 계수는 정하지 못해 최소점이 한 직선 위에 놓인다. 같은 합 s를 유지하며 $g_1^2 + g_2^2$를 최소화하면 $g_1 = g_2 = s/2$이므로 Ridge는 두 변수에 가중치를 나눈다. 거의 동일한 경우에는 이 직선이 길쭉한 타원의 축으로 나타난다.

3.35 슬라이드 35 · 두 계수의 숫자 예

참계수가 둘 다 1인데 표본에서 OLS가 대략 2.07과 -0.08을 준다면 각각은 크게 틀렸어도 합은 약 2로 맞을 수 있다. 상관이 높은 변수들 사이에서 어느 하나에 신호를 몰아주고 다른 하나를 반대 부호로 보정한 결과다.

새 관측치가 $(x_1, x_2) = (1, 1)$이면 $(g_1, g_2) = (2, 0)$도 $(1, 1)$도 예측값은 2다. 하지만 $(1, -1)$처럼 두 변수가 갈라지면 첫 해의 예측은 2, 둘째 해의 예측은 0이다. 과거에 거의 함께 움직인 변수만으로는 이 새 상태에 어느 해가 맞는지 판단하기 어렵다. 축소는 불확실성을 완화하지만 과거에 없던 조합의 근거를 만들어 내지는 못한다.

3.36 슬라이드 36 · 축소와 유효 자유도

$X^\top X = I$인 직교 조건에서는 $\hat{g}_{j,\text{ridge}} = \hat{g}_{j,\text{OLS}}/(1 + \gamma)$다. 모든 계수가 같은 비율로 줄고 정확히 0이 되지는 않는다. 데이터에 맞춘 자유도의 크기를 $d(\gamma) = \text{tr}[X(X^\top X + \gamma I)^{-1} X^\top]$로 정의하면 직교 조건에서는 $K/(1 + \gamma)$다.

즉 계수는 K개지만 각각 표본의 잡음에 완전히 맞춰지지 않는다. 일반적으로 $X^\top X$의 고유값 λ_j를 쓰면 $d(\gamma) = \sum_j \lambda_j/(\lambda_j + \gamma)$다. 정보가 적은 작은 고유값 방향일수록 더 강하게 축소된다.

두 직교 방향의 고유값이 9와 1이고 $\gamma = 1$이면 유효 자유도는 $9/10 + 1/2 = 1.4$다. 계수는 두 개지만 훈련값을 따라 움직이는 총 정도는 자유 계수 두 개보다 작다. $\gamma \to 0$이면 둘 다 1을 기여

해 2가 되고, $\gamma \to \infty$이면 둘 다 0으로 간다. 이 수치는 변수 개수를 물리적으로 지웠다는 뜻이 아니라 적합의 민감도를 요약한다.

3.37 슬라이드 37 · 제약식과 벌점식

"오차를 최소화하되 $g^\top g \le c$"라는 문제를 생각하자. 라그랑지안은 $(y-Xg)^\top(y-Xg)+\gamma(g^\top g-c)$다. $-\gamma c$는 g 선택에 영향을 주지 않으므로 능형 목적함수와 같다.

c가 작을수록 원점 가까운 계수만 허용되고 대응하는 γ는 커진다. 그림에서 OLS의 타원 등고선과 원형 제약 영역이 처음 닿는 점이 능형 해다. 이 기하학은 왜 예측변수에 단위를 맞춰야 하는지도 드러낸다.

제약이 실제로 해를 막을 때에만 라그랑주 승수 γ가 양수가 된다. OLS 해가 이미 $g^\top g < c$이면 제약이 느슨하므로 $\gamma = 0$이고 해는 OLS와 같다. 경계에서 $g^\top g = c$가 되면 벌점이 양수일 수 있다. 이 **상보성 조건**을 알아야 모든 c가 서로 다른 양의 벌점에 일대일로 대응한다고 오해하지 않는다.

3.38 슬라이드 38 · 계수 경로 읽기

벌점이 아주 크면 모든 기울기 계수는 거의 0이다. 벌점을 줄이면 각 계수가 자료가 가리키는 방향으로 움직인다. **경로 그림**은 어느 변수가 얼마나 빠르게 커지는지와 상관된 변수들이 서로 값을 나누는지를 보여 준다.

경로의 가로축이 γ인지 $\log\gamma$인지 먼저 확인하자. 로그 축에서는 일정한 가로 이동이 벌점의 동일한 절대 증가가 아니라 동일한 배율 변화다. 경로가 특정 지점에서 갑자기 바뀌면 상관된 변수 사이의 가중치 이동일 수도 있으므로, 한 계수의 모양만으로 실물경제 관계의 변화를 주장하지 않는다.

벌점이 매우 클 때 기울기가 모두 0에 가까워져도 예측이 반드시 0이 되는 것은 아니다. 절편을 벌주지 않고 훈련자료에서 중심화했다면 예측은 훈련기간 평균 $\bar{y}$로 수렴한다. 따라서 경로의 왼쪽 또는 오른쪽 끝이 나타내는 기준선이 '0 수익률'인지 '과거 평균'인지는 절편 처리와 축 방향을 함께 봐야 한다.

3.39 슬라이드 39 · 표준화가 필수인 이유

훈련 구간에서 $z_j = (x_j - \bar{x}_j)/s_j$로 표준화하면 계수는 해당 변수가 한 표준편차 변할 때의 효과가 된다. 검증·시험 자료에도 **훈련 구간의** $\bar{x}_j, s_j$를 그대로 적용해야 미래 분포의 정보를 미리 사용하는 누출을 피한다. 절편은 중심화 뒤 별도로 처리한다.

훈련자료에서 평균 100, 표준편차 20인 변수의 새 관측치가 130이면 표준화 값은 $(130-100)/20 = 1.5$다. 검증 구간 자체의 평균과 표준편차로 다시 바꾸면 미래 분포를 예측 과정에 알려 주는 셈이다. 결측치 대체, 이상치 절단, 주성분 계산에도 같은 '훈련에서 적합하고 미래에 적용' 원칙을 쓴다.

훈련기간 내내 값이 같아 표준편차 $s_j = 0$인 변수는 $z_j = (x_j - \bar{x}_j)/s_j$로 나눌 수 없다. 그 기간에는 수익률과의 관계를 식별할 변동도 없으므로 해당 변수를 제거하거나 별도로 처리해야 한다. 미래에 변동이 생겼다고 과거 훈련기간의 표준편차를 미래 자료로 다시 계산하면 안 된다. 이는 수치 계산의 예외이면서 시점 규율의 예외도 아니다.

3.40 슬라이드 40 · 편향된 추정기가 왜 이길 수 있는가

한 계수에 대해 $x^\top x = 1$, 참값 g, OLS 추정량의 분산 σ^2라 하자. 능형 추정량은 $\hat{g}_\gamma = \hat{g}_{\text{OLS}}/(1+\gamma)$다. 기대값은 $g/(1+\gamma)$이므로 편향은 $-\gamma g/(1+\gamma)$, 분산은 $\sigma^2/(1+\gamma)^2$다.

$$\text{MSE}(\gamma) = \frac{\sigma^2 + \gamma^2 g^2}{(1+\gamma)^2},$$
$$\frac{d\,\text{MSE}}{d\gamma} = \frac{2(\gamma g^2 - \sigma^2)}{(1+\gamma)^3}.$$

미분값을 0으로 놓으면 $\gamma^* = \sigma^2/g^2$다. 잡음이 크거나 참계수가 작을수록 강하게 축소한다. 이 최적값은 참 g를 모르므로 실제로는 검증자료에서 근사해야 한다.

$\gamma = 0$에서 MSE의 도함수는 $-2\sigma^2 < 0$이다. 잡음 분산이 양수라면 벌점을 아주 조금 주는 것이 이 단순 설정에서는 언제나 MSE를 낮춘다. 이후에는 편향의 제곱이 커지므로 최저점을 지난다. 이 유도는 능형회귀가 편향을 '실수로' 만드는 것이 아니라 미래 제곱오차를 줄이려고 의도한다는 점을 보여 준다.

수치로 참계수 $g = 0.1$, OLS 계수분산 $\sigma^2 = 0.04$라면 $\gamma^* = 0.04/0.01 = 4$다. OLS의 MSE는 0.04이고 벌점 4에서 MSE는 $(0.04 + 16 \times 0.01)/25 = 0.008$이다. 이 큰 개선은 신호가 추정 잡음보다 작은 **가정된 한 계수 문제**의 결과다. 실제로는 참 g를 모를 뿐 아니라 미래의 계수 관계가 바뀔 수 있어, 숫자 4를 다른 자료에 그대로 적용하지 않는다.

3.41 슬라이드 41 · 과거 수익률 357개로 다음 달을 예측하기

한 종목의 과거 119개월 수익률, 그 제곱, 세제곱을 각각 입력하면 357개 특징이 된다. 제곱항은 큰 변동 자체의 효과, 세제곱항은 상승과 하락의 비대칭적 패턴을 표현할 수 있다. 복잡한 기업 정보 없이도 고차원 문제가 된다.

매월 종목 간 비교를 한다면 그 달의 횡단면 평균을 빼고 특성을 표준화한다. 이는 시장 전체의 움직임보다 **어느 종목이 상대적으로 높을지**에 초점을 맞추기 위한 것이다. 변수 정의와 지연 시점은 매매 가능성을 좌우한다.

한 달 수익률이 -20%이면 제곱은 0.04, 세제곱은 -0.008이다. $+20\%$일 때 제곱은 똑같이 0.04지만 세제곱은 $+0.008$이어서 충격의 **크기**와 **방향을 동반한 비대칭성**을 구분한다. 세제곱 값이 수익률보다 훨씬 작으므로 각 특징을 같은 벌점 아래 놓으려면 훈련자료 기준 표준화가 필요하다.

3.42 슬라이드 42 · 회귀계수에서 읽는 모멘텀과 반전

최근 몇 달의 양의 계수는 과거에 오른 종목이 더 오르는 모멘텀을 뜻하고, 아주 오래된 과거 수익률의 음의 계수는 장기 반전을 뜻한다. 직전 한 달을 건너뛰는 설계는 호가·유동성에 따른 단기 반전과 중기 모멘텀을 구분하는 데 도움이 된다.

다만 계수 곡선은 서로 상관된 시차를 동시에 넣은 **조건부 효과**다. 한 시차의 계수가 양수라고 그 시차만 사는 전략의 수익률과 동일하지 않다. 전체 예측값을 포트폴리오에 적용해 비용 뒤 성과를 별도로 계산해야 한다.

예를 들어 지난달 수익률에 대한 계수가 -0.2, 그 전 달에 대한 계수가 $+0.3$이고 두 달의 수익률이 각각 10%였다면 기여는 $-0.2(0.10) + 0.3(0.10) = +0.01$이다. 직전 달의 반전 신호와 그 전 달의 모멘텀 신호가 동시에 존재해 총예측은 1%포인트 높아진다. 절편과 다른 355개 특징을 더해야 실제 예측값이 되므로 두 계수만으로 주문을 결정하지 않는다.

3.43 슬라이드 43 · 모의실험에서 벌점이 작동하는 방식

진짜 변수 10개를 넘어서 잡음 변수까지 넣으면 OLS의 표본내 점수는 계속 좋아질 수 있다. 능형 벌점은 잡음 변수의 우연한 계수를 낮춰 새 관측치의 오차를 줄인다. 그렇다고 모든 벌점이 좋은 것은 아니다.

과도한 벌점은 진짜 변수까지 거의 0으로 만들어 과거 평균과 다르지 않은 예측을 준다. 따라서 그래프에서는 표본외 곡선이 가장 높은 **중간 벌점 구간**을 찾는다. 반복 시뮬레이션의 평균 곡선은 한 번의 운 좋은 표본이 아니다.

시뮬레이션의 평가는 각 반복에서 **새 훈련자료로 다시 계수를 추정**하고 별도의 새 시험자료에 적용해야 한다. 한 번 추정한 계수를 여러 새 표본에만 적용하면 그 특정 훈련표본의 운은 남는다. 반복별 성과의 평균뿐 아니라 분산도 함께 보면, Ridge가 평균적으로 나은지와 드문 경우에 크게 실패하는지를 구별할 수 있다.

3.44 슬라이드 44 · 여기까지의 처방

문제는 변수 수 자체보다 약한 신호에서 자유로운 계수 추정이 큰 분산을 만든다는 점이다. 능형회귀는 계수를 모두 남기면서 특히 정보가 부족한 방향을 강하게 줄인다. 예측에는 유리할 수 있지만 어떤 변수만 실제로 중요한지 알려 주지는 않는다.

서로 비슷한 두 설명변수에 계수를 나눠 주면 예측은 안정될 수 있어도 어느 변수가 수익률을 일으켰는지는 알 수 없다. 다음에 살펴볼 라쏘는 변수 수를 줄여 읽기 쉽게 만들지만, 선택된 변수 이름에도 인과적 보증은 없다.

같은 예측 성능을 가진 두 모형을 비교할 때는 운영 부담도 다르다. Ridge가 100개 입력을 모두 요구하고 Lasso가 10개만 요구한다면 후자는 데이터 구매·갱신·오류 검토 비용을 줄일 수 있다. 그러나 10개가 표본마다 바뀌면 운영 안정성은 떨어진다. '계수의 수'뿐 아니라 입력을 안정적으로 얻을 수 있는지까지 실무 목적함수에 포함한다.

3.45 슬라이드 45 · 변수 선택의 문제

재무비율, 가격 신호, 텍스트 지표를 수백 개 넣을 때 모든 계수가 조금씩 비영(非零)인지, 소수만 실질적으로 중요한지 모른다. 변수 선택은 예측 비용을 줄이고 설명을 간결하게 만들 수 있지만, 잘못된 제외는 편향을 키운다.

모든 기업에 없는 지표를 제외하면 자료 수집과 검증 비용도 줄어든다. 선택된 변수가 표본마다 크게 바뀐다면 '핵심 변수'라는 해석은 조심해야 한다. 여러 기간의 선택 빈도와 예측 성능을 함께 제시한다.

예를 들어 유료 데이터 지표 20개를 빼도 표본외 제곱오차와 비용 후 수익이 거의 변하지 않는다면 그 지표의 한계가치는 작다. 반대로 특정 위기 때만 유용한 지표라면 평균 점수가 같아도 위험관리 가치는 있을 수 있다. 변수 선택을 평균 예측오차 하나로 끝내지 않고, 사용 시점과 손실이 큰 상태에서의 기여를 분리해 본다.

3.46 슬라이드 46 · 제곱 벌점에서 절댓값 벌점으로

능형회귀의 L_2 벌점은 계수를 부드럽게 줄이지만 정확히 0으로 만들지 않는다. 라쏘는 L_1 벌점 $\sum_j |g_j|$을 사용한다. 0에서 꺾이는 모양 때문에 약한 계수는 0에 붙을 수 있다.

L_2 벌점의 미분은 0 근처에서 연속적으로 0으로 가므로 작은 계수를 정확히 0에 고정하는 힘이

약하다. L_1 벌점은 0의 양쪽 기울기가 서로 달라 0에서 모서리를 만든다. 자료의 기울기가 그 모서리를 넘지 못하면 최저점이 0이 된다. 이 차이가 라쏘의 희소성을 설명한다.

수학적으로 $g=0$에서 g^2의 도함수는 0이지만 $|g|$에는 한 값의 도함수가 없고 가능한 기울기 집합 $[-1,1]$이 있다. 자료 적합항이 0에서 미는 힘이 벌점의 이 구간 안에 있으면 $g=0$이 최적 조건을 만족한다. Ridge는 같은 상황에서 보통 작은 비영 계수를 남긴다. 라쏘의 0은 주어진 벌점과 다른 입력변수 아래 추가 적합의 편익이 작다는 판정이다. 상관된 대체 변수가 신호를 담고 있을 수 있으므로 개별 변수의 경제적 효과는 별도로 평가해야 한다.

3.47 슬라이드 47 · 라쏘 목적함수

표준화된 변수에서 라쏘는 $\min_g \{N^{-1}\|y-Xg\|^2+\gamma\sum_j |g_j|\}$를 푼다. $\gamma=0$은 OLS와 같고, 커질수록 많은 계수가 0이 된다. 절댓값은 0에서 미분 가능하지 않아 모든 변수에 대한 단순한 역행렬 해는 없다.

그러나 볼록 함수라 전역 최저점은 효율적 알고리즘으로 찾을 수 있다. 변수 수가 관측치보다 많아도 유용하며, 해가 하나만 존재하는지 여부는 변수의 상관 구조에 따라 따로 확인해야 한다.

슬라이드 48의 한 변수 목적함수와 연결하면 정규화된 설명변수 $x^\top x/N=1$에서 $N^{-1}\|y-xg\|^2$는 상수항을 빼고 $(g-z)^2$이며 $z=x^\top y/N$다. 그러므로 여기의 벌점 $\gamma|g|$는 $(g-z)^2+2\lambda|g|$의 $2\lambda=\gamma$에 대응한다. 같은 임계값을 비교할 때 목적함수 앞의 $1/N$과 2를 확인해야 한다.

3.48 슬라이드 48 · 연성 임계값의 유도

직교한 한 변수에서 OLS 계수를 z라고 하면 Lasso 문제는 상수항을 빼고 $(g-z)^2+2\lambda|g|$의 최소화와 같다. $g>0$이면 도함수 $2(g-z)+2\lambda=0$이므로 $g=z-\lambda$, 단 $z>\lambda$일 때만 양수다. $g<0$이면 $g=z+\lambda$이고 $z<-\lambda$여야 한다.

$$\hat{g}_{\text{lasso}} = \operatorname{sgn}(z)(|z|-\lambda)_+,$$
$$(u)_+ = \max(u,0).$$

$|z|\le\lambda$이면 0이 최소점이다. 능형회귀는 비율로 줄이고 라쏘는 일정 크기를 빼며, 그 과정에서 약한 계수를 없앤다. 벌점의 정의에 따라 교재의 γ와 여기의 λ 사이에는 2배 상수 차이가 있을 수 있다.

세 구간을 직접 대입하면 $z=0.8$, $\lambda=0.5$일 때 해는 0.3이고, $z=0.3$이면 해는 0이다. $z=-0.8$이면 해는 -0.3이다. 0 양쪽에서 목적함수의 기울기가 부호를 바꾸는지 확인하면 $|z|\le\lambda$일 때 0이 최저점인 이유가 보인다. 작은 관측 상관을 신호로 확정하지 않는 규칙이다.

$g=0$에서는 절댓값의 도함수 대신 부분기울기 $\partial|g|=[-1,1]$을 쓴다. 목적함수의 0에서의 최적조건은 $0\in -2z+2\lambda[-1,1]$이고, 이를 정리하면 $|z|\le\lambda$다. 경계 $|z|=\lambda$에서도 해는 0이다. 이 한 줄이 왜 라쏘가 정확히 0을 만들 수 있는지 미분 가능한 양·음 구간의 해와 이어 준다.

3.49 슬라이드 49 · 마름모의 꼭짓점

L_1 제약 $|g_1|+|g_2|\le c$는 두 차원에서 마름모이고 꼭짓점이 좌표축에 있다. 제곱오차의 타원 등고선이 제약 영역에 처음 닿는 곳이 꼭짓점이면 한 계수가 정확히 0이다. L_2 제약은 원이므로 축 위의 정확한 접촉이 상대적으로 드물다.

등고선이 꼭짓점에 닿는 경우가 많은 것은 마름모의 모서리가 좌표축과 정렬되어 있기 때문이다. 그러나 두 변수가 거의 같은 정보를 담으면 어느 축의 꼭짓점에 닿을지는 작은 자료 변화에

민감할 수 있다. '0이 된 변수는 중요하지 않다'고 단정하지 말고 비슷한 변수의 대체 가능성을 살펴야 한다.

극단적으로 $x_1 = x_2$이고 예측에 필요한 합이 $g_1 + g_2 = s > 0$라면, $g_1, g_2 \geq 0$인 어떤 배분도 $|g_1| + |g_2| = s$로 같은 Lasso 벌점을 낸다. 어느 변수 하나에 s를 몰아도 적합과 벌점이 같아 선택 이름은 유일하지 않을 수 있다. 반면 제곱 벌점 $g_1^2 + g_2^2$는 두 계수가 $s/2$씩일 때 가장 작다. 마름모와 원의 차이가 상관된 변수에서 어떻게 나타나는지 보여 준다.

3.50 슬라이드 50 · 라쏘 경로의 읽기

벌점이 매우 크면 기울기 계수가 모두 0이다. 벌점을 줄이면 먼저 자료와 강하게 연결된 변수가 들어오고, 이어 다른 변수가 들어온다. 경로의 각 지점은 하나의 후보 모형이다.

벌점을 줄이는 동안 새 변수가 들어오는 순서는 현재 이미 들어온 변수들에 조건부로 결정된다. 첫 변수와 거의 같은 두 번째 변수는 단독 상관이 커도 늦게 들어올 수 있다. 경로의 순서를 경제적 중요도의 순위로 읽지 말고, 각 후보 모형의 검증오차와 선택 안정성을 함께 읽는다.

슬라이드 47의 목적함수 $N^{-1}\|y - Xg\|^2 + \gamma \sum_j |g_j|$를 기준으로, 현재 $g_j = 0$인 변수의 입력 벡터를 x_j, 잔차를 $r = y - Xg$라 하면 0에 머무는 조건은 $|2x_j^\top r/N| \leq \gamma$다. 벌점 γ를 줄여 이 부등식이 깨지면 그 변수는 경로에 들어올 수 있다. 여기서 r은 이미 선택된 다른 변수들을 사용한 **현재 잔차**이므로, 진입 순서가 각 변수와 원래 수익률의 단순 상관 순서와 같을 필요는 없다.

3.51 슬라이드 51 · 상관된 쌍둥이 변수

두 예측변수가 거의 같은 정보를 담으면 라쏘는 하나에 계수를 몰아주고 다른 하나를 버릴 수 있다. 표본이 조금만 바뀌어도 살아남는 변수의 이름이 바뀔 수 있다. 예측은 안정적이어도 변수 선택 결과는 불안정한 것이다.

예측의 목적이라면 두 쌍둥이 변수 중 어느 하나가 남아도 성능이 비슷할 수 있다. 반면 설명의 목적이라면 선택된 이름이 바뀔 때 결론도 바뀌므로 불안정성이 문제다. 여러 훈련 구간에서 재적합해 선택 빈도를 비교하거나 관련 변수를 한 군집으로 묶어 해석하면 과도한 단정이 줄어든다.

예를 들어 열 번의 시간 구간 재적합에서 배당/주가가 일곱 번, 이익/주가가 세 번 선택되고 예측오차는 비슷하다면, '배당이 유일한 원인'보다 '가치 관련 정보가 반복해서 사용된다'는 해석이 강하다. 선택 빈도도 상관된 입력과 벌점 설정의 산물이므로 원인확률로 읽어서는 안 된다. 어떤 변수가 탈락했을 때 다른 변수가 대체하는지도 같이 본다.

3.52 슬라이드 52 · 엘라스틱넷의 두 벌점

엘라스틱넷은 $\min_g \{N^{-1}\|y - Xg\|^2 + \gamma_1 \sum_j |g_j| + \gamma_2 \sum_j g_j^2\}$를 푼다. L_1은 약한 변수를 제거하고 L_2는 상관된 변수 사이의 가중치를 나누어 해를 안정화한다.

서로 비슷한 재무비율이 많을 때는 L_2가 상관된 변수들의 가중치를 안정화하고 L_1이 일부를 제거한다. 두 벌점의 증분 효과는 $\gamma_1 = 0$인 능형회귀와 $\gamma_2 = 0$인 라쏘를 같은 검증 절차로 비교해 본다. 하이퍼파라미터가 하나 더 늘어난 만큼 검증자료에 우연히 맞을 기회도 늘어난다.

앞의 완전히 같은 두 변수 예시에서 $g_1 + g_2 = s > 0$를 고정하면 L_1 비용은 비음수 배분 어디서나 $\gamma_1 s$로 같다. 그러나 L_2 비용은 $\gamma_2(g_1^2 + g_2^2)$이어서 $g_1 = g_2 = s/2$일 때 가장 작다. $\gamma_2 > 0$가 쌍둥이 변수의 임의 선택을 줄이는 이유가 이 작은 계산에 담겨 있다. 실제로는 두 변수가 완전히 같지 않으므로 검증과 선택 안정성을 함께 본다.

3.53 슬라이드 53 · 어떤 벌점이 맞는가

진짜 효과가 넓게 퍼져 있다면 능형회귀의 모든 계수 축소가 유리할 수 있다. 효과가 소수 변수에 집중되면 라쏘의 희소성이 유리하다. 관련 변수들이 군집을 이루면 엘라스틱넷이 실용적일 수 있다.

모형군 선택도 하이퍼파라미터 탐색이다. Ridge 벌점 20개, Lasso 벌점 20개, Elastic Net 조합 40개를 시험했다면 총 80개 후보 중 검증 최저점을 고른 셈이다. 검증자료의 우연에 맞을 가능성을 감안해 탐색 범위를 기록하고, **최종 시험기간은 선택에 사용하지 않는다**. 자료가 적다면 효과가 넓게 퍼졌는지 군집을 이루는지에 대한 경제적 사전지식도 후보를 줄이는 데 쓸 수 있다.

3.54 슬라이드 54 · 벌점 선택과 채점

벌점 γ는 회귀계수와 달리 모형을 적합하기 전에 선택하는 **하이퍼파라미터**다. 같은 훈련자료의 제곱오차만 보면 벌점을 줄일수록 적합이 좋아지므로 항상 0을 선택한다. 미래 성능을 위한 벌점은 보지 않은 자료로 정해야 한다.

교차검증은 제한된 자료를 여러 번 나누어 각 관측치를 검증에 사용한다. 금융 자료에서는 공시 발표일과 목표 수익률의 기간을 따라 나누어야 한다. 검증 달보다 뒤의 수익률을 훈련에 쓰면 벌점 선택에도 미래 정보가 들어간다. 후보를 여러 개 비교해 고른 검증 최저값에는 선택에 따른 낙관도 남으므로 최종 시험이 필요하다.

훈련오차가 $\gamma = 0$에서 가장 낮아도 검증오차는 중간 벌점에서 최저가 될 수 있다. 예를 들어 세 후보의 훈련 제곱오차가 80·85·100이고 검증 오차가 110·90·105라면, 둘째 후보가 검증 구간에서 가장 작게 틀렸다. 벌점은 훈련 적합도를 일부 양보해 미래 오차를 줄이려는 선택이다.

3.55 슬라이드 55 · 하이퍼파라미터와 계수의 역할

훈련은 계수 추정, 검증은 벌점 선택, 시험은 최종 성능 보고에 쓴다. 예를 들어 훈련 구간에서 라쏘 계수를 추정하고 다음 구간에서 γ 후보 10개를 비교한 뒤, 마지막 구간은 고른 모형을 한 번만 평가한다. 그 결과로 후보를 다시 바꾸었다면 더 뒤의 새 기간에서 최종 성능을 측정한다.

표준화 평균과 결측치 대체 규칙도 계수와 마찬가지로 훈련자료에서 배운 값이다. 검증 단계에서 벌점만 분리하고 전처리를 전체 기간으로 계산하면 이미 시험 기간이 모형에 관여한 셈이다. 각 재학습 시점마다 전처리 → 계수 추정 → 검증 예측을 같은 과거 정보 집합 안에서 다시 수행해야 한다.

3.56 슬라이드 56 · k겹 교차검증을 계산하기

표본을 k개 묶음 $V_1, \ldots, V_k$로 나누고, 각 묶음 v를 뺀 자료에서 $\hat{g}_{-v}(\gamma)$를 적합한다. 남겨 둔 관측치 i의 예측오차를 $e_{i,v} = y_i - x_i^\top \hat{g}_{-v}(\gamma)$라 하면, 묶음별 제곱오차 CV_v를 평균한 값이 교차검증 점수다.

$$CV(\gamma) = \frac{1}{k}\sum_{v=1}^{k} CV_v(\gamma),$$
$$CV_v(\gamma) = \frac{1}{|V_v|}\sum_{i \in V_v} e_{i,v}^2,$$
$$e_{i,v} = y_i - x_i^\top \hat{g}_{-v}(\gamma).$$

각 묶음에서 기준선도 동일한 훈련 부분으로 다시 계산해야 한다. 전체 표본의 평균을 검증 묶음에 대한 기준 예측으로 쓰면 미래 정답을 기준선에 포함하게 된다. 또한 식의 $1/k$ 평균은 묶음 크기가 같을 때 각 관측치의 비중이 같다. 크기가 다르면 관측치 수로 가중해 전체 제곱오차를 계산할 수 있다.

예를 들어 관측치 120개를 다섯 묶음으로 나누면 한 번마다 96개로 적합하고 남은 24개로 채점한다. 벌점 후보가 20개라면 적어도 $5 \times 20 = 100$번 적합한다. 각 후보의 다섯 검증오차를 모아 벌점을 고른 다음, 선택된 벌점으로 사용 가능한 훈련자료 전체에 **다시 적합**해야 최종 예측모형이 된다. 다만 100번의 비교에 사용한 검증 점수를 최종 성능으로 보고하면 선택에 따른 낙관이 남는다. 시간상 뒤에 남겨 둔 시험기간은 마지막 한 번만 평가해야 한다.

3.57 슬라이드 57 · 금융 교차검증의 두 경고

미래 운용을 평가할 때는 검증 블록보다 앞선 기간으로만 적합하는 **forward chaining**이 자연스럽다. 2015년을 검증하면서 2020년 자료로 계수를 적합하면 블록을 나누었어도 시간 누출이 생긴다. 벌점 선택에 사용한 검증 점수에는 낙관이 남으므로 맨 뒤의 손대지 않은 기간에서 최종 성능을 측정한다.

목표가 12개월 누적수익률이면 인접한 두 관측치가 미래 11개월을 공유한다. 훈련·검증 경계에서 이 중첩 기간을 제거하거나 간격을 두어 같은 충격이 양쪽 목표에 들어가지 않게 한다. **훈련의 시간 방향**과 **목표 기간의 중첩**은 각각 따로 점검할 사항이다. 기업별 관측도 어느 기업·기간에 일반화할지에 맞춰 묶는다.

3.58 슬라이드 58 · OLS, 능형, 라쏘의 결과 비교

같은 과거 수익률 특징 357개를 쓰면 OLS가 표본내 R^2는 가장 높아도 검증 점수는 음수가 될 수 있다. 능형과 라쏘는 표본내 적합을 포기하는 대신 검증 점수를 양수로 만들 수 있다. 이것이 편향을 도입한 이유를 경험적으로 보여 준다.

가령 OLS의 훈련 $R^2 = 30\%$, 시험 $R^2 = -5\%$, Ridge의 훈련 $R^2 = 20\%$, 시험 $R^2 = 1\%$라면 Ridge가 미래 기준선 대비 오차를 더 줄인 것이다. 훈련과 시험 점수는 자료와 분모가 달라 그 차이를 투자수익률로 환산할 수 없다. 실제 운용 성과는 종목 선정, 매매 시점, 상장폐지 수익률, 거래비용을 포함해 새 기간에서 확인한다.

3.59 슬라이드 59 · 예측 점수와 투자 성과가 다른 이유

R^2는 모든 종목의 예측오차 제곱을 벌하지만, 상위·하위 종목을 동일가중으로 매매하는 전략에는 **순위**가 중요하다. 예측값이 실제값보다 늘 절반 작아도 순서가 같다면 선택 종목은 그대로다. 거래가 잦거나 유동성이 낮은 종목에 몰리면 R^2가 높아져도 순수익은 낮아질 수 있다.

예측값에 비례해 **비중**을 정하는 전략에서는 같은 축소가 투자 규모와 위험을 바꾼다. 채점 전에 포트폴리오 규칙을 고정하고 제곱오차, 순위, 총손익, 비용 뒤 순손익을 각각 계산한다. 매매

할 수 없는 종목의 예측오차 개선은 실제 운용에 반영되지 않는다는 점도 확인한다.

3.60 슬라이드 60 · 시장 전체 예측으로 돌아오기

정규화는 시장수익률 예측에서도 계수의 요동을 줄일 수 있다. 하지만 한 나라의 10년 월별 시장수익률은 120개뿐이다. 같은 기간 3,000개 종목을 추적하면 행은 많아도 같은 달의 종목은 금리·경기 충격을 공유한다. 횡단면에는 같은 시점의 기업 간 차이라는 추가 정보가 있으므로, 종목의 상대 수익률 예측 성과를 시장 타이밍으로 옮기려면 목표와 독립 관측 단위를 다시 정의해야 한다. 위기와 제도 변화에 걸쳐 기준선보다 나은지도 확인한다.

3.61 슬라이드 61 · 극단적 복잡성의 논쟁

짧은 자료에 비해 훨씬 많은 무작위 비선형 특징을 만들고 능형회귀를 적용하면, 겉으로는 큰 표본외 성과가 나올 수 있다. 한 해석은 높은 차원의 표현이 놓친 패턴을 잡았다는 것이다. 다른 해석은 특정 설정에서 예측이 최근 수익률의 가중평균으로 수렴해 단순 모멘텀을 재포장한다는 것이다.

단순한 최근 수익률 가중평균, 무작위 특징 모형, 둘을 합친 모형을 같은 시점·종목·비용 기준으로 비교하면 복잡한 특징의 증분 가치를 측정할 수 있다. 여러 무작위 시드 중 최고 성적을 골랐다면 시드도 하이퍼파라미터다. 특징 수와 벌점 탐색 범위를 함께 기록하고 독립 기간에서 검증한다. 특징을 많이 생성해도 **새로운 독립 역사**가 늘지는 않는다.

3.62 슬라이드 62 · 수익률 예측에서 확립된 규칙

분석 순서는 **예측 시점과 목표 설정 → 당시 공개 자료 구성 → 기준선 설정 → 훈련·검증에서 벌점 선택 → 손대지 않은 시험기간 평가**다. 마지막에는 예측오차와 거래비용 뒤 손익을 함께 보고한다. 사용한 변수와 수정 이력, 전처리, 벌점 후보, 기간, 비용 가정을 남기면 다른 사람이 결과를 재현하고 이후 성과 변화의 원인을 추적할 수 있다.

다음 장에서는 시장 전체에서 종목 간 상대 수익률로 대상을 바꾼다. 종목 특성의 예측력과 위험 보상·가격오류의 설명, 여러 요인을 검정하며 생기는 선택 편향을 함께 다룬다.

4 종목 간 기대수익률과 요인 논쟁

시장이 내년에 오를지 예측하는 일과, 같은 달에 어떤 종목이 다른 종목보다 나을지 예측하는 일은 다르다. 후자는 공통 시장 충격을 롱숏(long–short) 포지션으로 일부 상쇄할 수 있지만, 작은 주식의 거래비용과 공매도 제약이 중요해진다. 이 장은 종목 특성을 전략으로 만드는 절차에서 출발해 위험 보상·가격오류·우연이라는 세 설명을 평가한다.

4.1 슬라이드 01 · 횡단면의 출발점

횡단면은 **한 시점의 여러 종목**을 가리킨다. 시장 시계열 예측은 다음 달 시장 전체의 평균을 묻지만, 횡단면 예측은 같은 달 종목의 상대 순위를 묻는다. 모든 종목이 하락한 달에도 덜 하락한 종목을 사고 더 하락한 종목을 공매도하면 롱숏 차이는 양수일 수 있다.

같은 금액을 매수하고 공매도하는 **달러 중립** 포트폴리오도 시장 베타가 남을 수 있다. 매수 다리의 베타가 1.2, 매도 다리가 0.8이면 순베타는 0.4다. 시장이 10% 하락할 때 각 다리에 1원씩

건 전략은 잔차수익이 없다는 가정에서 약 4전 손실을 본다. 베타 중립을 원한다면 두 다리의 금액을 조정해야 하므로 종목 순위의 예측력과 시장 노출을 따로 측정한다.

4.2 슬라이드 02 · 앞 장에서 건너오는 다리

한 달 3,000개 종목을 60개월 관찰하면 자료 행은 18만 개다. 3,000개 종목은 **같은 거시 상태에서** 기업 특성과 수익률의 관계를 비교하는 데 도움이 된다. 그러나 경기 충격을 관찰한 서로 다른 달은 60개다. 그 관계가 여러 경기 상태에서도 유지되는지는 시간에 따른 기울기의 변동으로 판단한다. 그래서 매달 단면 기울기를 추정한 뒤 그 평균의 표준오차를 잰다.

4.3 슬라이드 03 · 요인 동물원의 네 질문

요인 동물원(factor zoo)에서는 수백 개 기업 특성 가운데 어느 것이 다른 특성을 통제한 뒤에도 정보를 갖는가. 그 정보를 보상받는 위험으로 설명할 수 있는가. 발표된 전략은 새 기간과 큰 종목에서도 남는가. 여러 변수가 같은 경제적 주제를 반복 측정하는 것은 아닌가.

장부가치/시가총액 신호가 규모를 통제한 뒤에도 남는다면 독립적인 예측력의 증거를 얻은 것이다. 불황에 손실을 주는지를 봐야 위험 보상 설명을 평가할 수 있다. 다른 나라에서도 반복되지만 극소형주에만 있고 왕복 거래비용이 수익보다 크다면 통계적 재현과 실제 운용 가능성의 답은 다르다. 각 연구가 네 질문 중 어디까지 답했는지 표시해 읽는다.

4.4 슬라이드 04 · 특성에서 전략으로

장부가치/시가총액이나 지난 11개월 수익률 같은 특성은 기업별 숫자다. 투자전략은 이 숫자로 종목을 정렬하고 어느 그룹을 사고 팔지 정해야 비로소 정의된다. 같은 특성도 동일가중·시가총액가중, 소형주 포함 여부에 따라 다른 성과를 낸다.

100개 종목을 동일가중하면 각 1%지만 시가총액가중에서는 대형주가 성과를 주도한다. 정렬 기준, 가중치, 재조정일을 명시해야 큰 자금으로 재현할 수 있는 전략인지 판단할 수 있다.

결산일이 12월 31일인 기업의 장부자본이 다음 해 3월 공시되었다면 1월 정렬에는 이 값을 쓸 수 없다. 자료 파일에 '12월 값'으로 적혀 있어도 투자자가 알게 된 날은 3월이다. 정렬일의 가격과 이전에 공개된 장부자본을 결합하고, 분할·상장폐지·공시 정정까지 같은 시점 원칙으로 처리해야 전략의 백테스트가 실제 가능했던 결정을 재현한다.

가중치가 결과를 어떻게 바꾸는지 세 종목으로 확인하자. 시가총액이 70, 20, 10이고 다음 달 수익률이 각각 $+10\%$, 0, -10%라면 시가총액가중 수익률은 $0.7(10\%) + 0.2(0) + 0.1(-10\%) = 6\%$, 동일가중 수익률은 $(10\% + 0 - 10\%)/3 = 0$이다. 시가총액가중은 전체 주식 수가 그대로라면 가격 변화 뒤에도 새 시가총액 비율로 자연스럽게 이동한다. 동일가중은 상승 종목을 일부 팔고 하락 종목을 사야 다음 달에도 각 $1/3$을 유지한다.

4.5 슬라이드 05 · 십분위 포트폴리오 정렬

매월 종목을 특성 $X_{i,t}$ 순서로 정렬해 10개 그룹으로 나누고, 상위 그룹을 매수하고 하위 그룹을 매도한다. 다음 달 수익률 차이 $r_{10,t+1} - r_{1,t+1}$를 계산해 시간 평균을 낸다. 이는 특성의 극단 사이에 수익률 기울기가 있는지 보여 준다.

매수·매도 수익률 차이는 두 다리를 모두 같은 명목 금액으로 잡았을 때의 계산이다. 패자 그룹의 수익률이 -2%, 승자가 1%이면 차이는 3%지만 공매도 주식의 대차 비용과 매매 스프레드는

아직 빠지지 않았다. 그룹 평균을 낼 때 결측·상장폐지 수익률도 포함해야 실제 투자 가능성을 평가할 수 있다.

1,000개 종목이면 보통 십분위마다 100개가 들어간다. 같은 특성값이 경계에 몰리면 동률 처리 규칙이 그룹 구성을 바꾼다. 다음 달 종목이 그룹을 옮기거나 그룹 안의 비중이 움직이면 재조정 거래가 생긴다. 이 거래의 명목금액에 비용률을 적용해야 순수익이 나온다.

동일가중을 유지하는 거래량은 **수익 후 비중**에서 나온다. 초기 비중 w_i와 기간 수익률 r_i가 주어지면 거래 직전 비중은 $w_i^{\text{drift}} = w_i(1+r_i)/(1+r_p)$이다. 바로 앞의 $+10\%, 0, -10\%$ 예에서 초기 비중이 모두 $1/3$이면 $r_p = 0$, 거래 직전 비중은 $0.3667, 0.3333, 0.3000$이다. 다시 동일가중으로 맞추려면 첫 종목을 자산의 3.33%만큼 팔아 셋째 종목을 그만큼 산다. 매수와 매도 명목금액을 모두 센 회전율은 $\sum_i |w_i^{\text{target}} - w_i^{\text{drift}}| \approx 6.67\%$이고, 한쪽 거래액만 세는 정의에서는 약 3.33%다. 보고된 회전율과 비용률의 분모가 같은지 확인해야 한다.

롱숏의 $r_{10} - r_1$도 분모를 정한 수치다. 매수 다리와 공매도 다리에 각각 100원을 걸어 $+5\%$와 -2%를 얻었다면 손익은 $5 - (-2) = 7$원, **각 다리 100원당** 수익률은 7%다. 두 다리의 총 명목금액 200원으로 나누면 3.5%이고 순투자금 0원으로 나눈 수익률은 정의되지 않는다. 비교하는 전략의 레버리지·담보·비용 기준을 맞춰야 한다.

4.6 슬라이드 06 · 파마·맥베스 회귀의 두 단계

한 달에 주식이 수천 개라도 같은 경기 충격을 받으므로 종목 수만큼 독립적인 실험을 한 셈은 아니다. Fama–MacBeth 방법은 먼저 **매월의 단면**에서 특성과 다음 달 수익률의 관계를 추정한다. i는 종목, t는 특성을 관찰한 달이고, $X_{i,t}$는 수익률을 보기 전에 알 수 있어야 한다. $r_{i,t+1} = a_t + b_t X_{i,t} + e_{i,t+1}$에서 a_t는 그 달의 공통 절편, b_t는 특성이 한 단위 높은 종목의 상대수익 기울기, $e_{i,t+1}$은 설명되지 않은 수익률이다. 그런 다음 T개월의 기울기를 평균한 $\bar{b} = T^{-1}\sum_t b_t$가 0과 다른지 검정한다.

첫 단계는 매달의 상대수익 관계를, 둘째 단계는 그 관계가 여러 달에 걸쳐 지속되는지를 묻는다. 여러 특성을 함께 넣으면 다른 특성을 고정한 조건부 기울기를 얻는다. 계수의 숫자는 특성의 단위에 따라 달라진다.

간단히 세 달의 기울기가 0.01, 0.02, 0.03이면 평균은 0.02다. 표본 표준편차는 0.01이고 독립 월이라는 가정 아래 평균의 표준오차는 $0.01/\sqrt{3} \approx 0.0058$이다. 이 작은 예는 두 단계의 계산을 보여 줄 뿐, 세 달만으로 경제적 효과를 확정하기에는 기간이 너무 짧다. 기울기가 연속된 달에 함께 움직이면 표준오차 계산도 바뀐다.

4.7 슬라이드 07 · 높은 수익률과 이상현상의 차이

고위험 주식이 높은 평균수익률을 주는 것은 위험을 싫어하는 투자자에게 정상적인 보상일 수 있다. **이상현상**은 특정 기준 자산가격모형이 설명하지 못하는 수익률 차이를 뜻한다. 따라서 기준모형을 바꾸면 이상현상의 유무도 달라질 수 있다.

CAPM은 시장 전체가 좋은 날 함께 오르는 위험에 보상이 필요하다고 본다. $r_i - r_f$는 종목 i의 무위험수익률 초과 성과, $r_M - r_f$는 시장의 초과수익률이다. β_{iM}은 시장 초과수익률이 움직일 때 종목이 평균적으로 얼마나 민감하게 반응하는지 나타내는 계수다. CAPM이 예측한 보상 $\beta_{iM}E[r_M - r_f]$를 실제 평균 초과수익에서 뺀 $\alpha_i = E[r_i - r_f] - \beta_{iM}E[r_M - r_f]$가 알파다. 기준 요인을 바꾸면 이 잔여 수익도 바뀐다.

예를 들어 종목의 연평균 초과수익이 8%, 시장의 연평균 초과수익이 5%, 시장 베타가 1.6이면 CAPM 요구수익은 $1.6(5\%) = 8\%$이고 알파는 0이다. 종목의 8%를 그대로 초과성과로 부르면 시장 위험 노출의 보상을 섞는다. 물론 CAPM 자체가 빠뜨린 위험이 있으면 그 0이라는 판정도

다른 요인모형에서는 달라질 수 있다.

알파가 원수익률보다 **클 수도** 있다. 매수·공매도 전략의 월평균 수익률이 1.0%, 시장 초과수익률 평균이 0.5%, 전략의 시장 베타가 -0.4라면 CAPM 알파는 $1.0\% - (-0.4)(0.5\%) = 1.2\%$다. 평균적으로 양의 보상을 주는 시장에 역방향으로 노출되어 있었으므로 위험 조정 과정에서 그 불리한 기여를 되돌린 것이다. 이 알파는 평균적인 시장 노출을 제거한 값이며 꼬리손실을 측정하지 않는다. 예를 들어 모멘텀의 공매도 다리가 시장 반등에 크게 오르면 전략은 큰 손실을 낼 수 있다.

알파가 양수로 추정돼도 그 값이 표본 잡음보다 충분히 큰지 검정해야 한다. 종목 간 공통 충격과 여러 신호를 시험한 선택 과정은 유의성에 영향을 준다.

4.8 슬라이드 08 · 왜 월별 기울기의 표준오차를 쓰는가

한 달에 3,000개 종목이 있어도 모두 같은 금리·경기 충격을 겪는다. 모든 종목·월을 독립 관측치로 취급한 단순 합동회귀는 표준오차를 지나치게 작게 만들 수 있다. 월별 횡단면 기울기 b_t를 구한 뒤 시간에 따라 변하는 b_t의 분산으로 평균의 불확실성을 재는 이유다.

$$\widehat{\mathrm{se}}(\bar{b}) = \sqrt{\frac{1}{T(T-1)}\sum_{t=1}^{T}(b_t - \bar{b})^2}.$$

월별 기울기가 자기상관을 가지면 분산 계산에 시차별 공분산이 더해진다. 즉 Var$(\bar{b})$는 단순한 월별 분산 나누기 T가 아니라, 인접한 달의 기울기가 함께 움직이는 정도를 반영한다. Newey–West는 일정한 시차까지 이런 공분산을 더해 장기분산을 추정한다.

위 식은 월별 기울기의 표본분산 $s_b^2 = \sum_t (b_t - \bar{b})^2/(T-1)$을 T로 나눈 뒤 제곱근을 취한 $s_b/\sqrt{T}$다. 연속된 달의 기울기가 비슷하면 독립 반복의 수가 줄어들어 이 값은 작게 추정된다.

4.9 슬라이드 09 · 여섯 범주의 지도

수익률 예측변수는 모멘텀, 가치, 투자, 수익성, 무형자산, 거래마찰로 묶을 수 있다. 이는 변수를 정리하는 **분류표**이지 각 범주의 인과이론이 아니다. 같은 범주 안에도 측정 방식과 경제적 채널이 다르다.

가치 범주의 장부가치/시가총액과 이익/가격은 모두 낮은 가격을 포착하지만 회계자료의 의미가 다르다. 같은 이름 아래 신호를 합치기 전에 분자·분모, 발표 시점, 산업별 차이를 확인한다.

범주가 서로 배타적일 필요도 없다. 연구개발비를 당기 비용으로 처리하는 기업은 장부상 자기자본이 작아져 가치비율이 달라질 수 있고, 투자 확대는 현재 이익률과 미래 수익성에도 영향을 준다. 이때 가치·무형자산·투자 신호가 서로 상관된다고 해서 세 개의 독립된 경제 효과를 발견한 것은 아니다. 한 신호를 평가할 때 관련 범주의 다른 특성을 통제한 뒤에도 남는지를 확인하는 이유다.

4.10 슬라이드 10 · 여섯 범주의 대표 신호

모멘텀은 최근 승자, 가치는 낮은 가격/기초가치, 투자는 자산 증가가 낮은 기업, 수익성은 이익률이 높은 기업을 매수하는 방향이다. 무형자산은 연구개발과 조직자본처럼 장부에 잘 보이지 않는 투자, 거래마찰은 규모·유동성·변동성과 연결된다.

신호의 방향도 정의에 따라 뒤집힌다. B/M이 높은 종목을 가치주라 부르면 높은 값 매수지만, 같은 정보를 M/B로 쓰면 낮은 값 매수다. 표에 '효과가 양수'라고 적혔을 때 변수 정의와 정렬 방향을 함께 읽어야 한다. 실무에서는 원자료의 단위와 극단값 처리까지 맞춰야 재현 가능하다.

B와 M이 모두 양수라면 $M/B = 1/(B/M)$이어서 순위가 정확히 뒤집힌다. 하지만 장부자본 B가 0이거나 음수인 기업에는 이 역수 관계로 단순 정렬할 수 없다. 손실 기업을 제외할지 별도 그룹으로 둘지에 따라 가치 신호의 표본 자체가 달라진다. '부호만 반대'라는 설명은 양의 분모와 동일한 표본에서만 성립한다.

4.11 슬라이드 11 · 낮은 가격은 두 가지를 말한다

현재 가격은 미래에 받을 현금흐름의 현재가치다. 한 기간 뒤의 현금흐름을 CF, 그 자산의 기대수익률을 $E[r]$라 쓰면 단순한 한 기간 식은 $P = E[CF]/(1 + E[r])$다. 가격이 낮다면 예상 현금흐름이 작거나 요구수익률이 높을 수 있다. 가격만으로는 두 원인을 가를 수 없다.

위험의 원천을 보려면 미래 상태마다 현금흐름의 가치를 다르게 매겨야 한다. 확률적 할인인자 m_{t+1}은 **그 상태에서 1원을 받는 가치에 적용하는 가중치**다. 불황처럼 소비가 부족한 상태에서 투자자의 한계효용이 커지면 보통 이 가중치도 높다. 상태별 가치와 현금흐름의 곱을 평균한 엄밀한 가격식은 $P_t = E_t[m_{t+1} CF_{t+1}]$이다. E_t는 현재 정보에 조건부인 기댓값이다.

공분산의 정의를 대입하면 $P = E[m]E[CF] + \mathrm{Cov}(m, CF)$다. 불황에 m은 높은데 기업 현금흐름이 작다면 공분산은 음수다. 같은 평균 현금흐름이어도 가격이 낮아질 수 있으므로, 낮은 가격을 곧바로 시장의 예상오류라고 부를 수 없다.

4.12 슬라이드 12 · 각 범주를 같은 질문으로 읽기

첫째, 특성은 언제 측정하고 어떤 종목을 매수·매도하는가. 둘째, 왜 수익률 차이가 생기는가. 위험에 대한 보상인지, 투자자의 지나친 낙관·비관이 수정되는 것인지 따진다. 셋째, 원래 표본을 벗어나도 남는가.

예컨대 연말 장부가치를 이용해 1월 1일 종목을 정렬했다면, 그 장부가치가 **실제로 언제 공시됐는지** 확인해야 한다. 3월에야 알려진 숫자를 1월 매수 규칙에 넣으면 미래 정보가 과거 결정에 들어간다. 매수 방향과 수익률이 같더라도 공개 시점을 맞추어 다시 계산하면 성과가 달라질 수 있다. 후보 신호마다 '측정 기준일'과 '투자자가 알게 된 날'을 따로 기록하자.

4.13 슬라이드 13 · 모멘텀의 위치

모멘텀은 과거 상승 종목이 단기적으로 더 상승하는 경향이다. 시장 전체가 계속 오르는 것과 다르게 **같은 달 종목 사이의 상대 승자**를 말한다. 투자자의 정보 반응 지연, 추세 추종 거래, 위험 노출 등이 가능한 설명이다.

직전 1개월에는 단기 반전, 2~12개월에는 지속, 더 긴 기간에는 다시 반전이 나타날 수 있다. 한 구현은 지난 12개월 중 **직전 한 달을 제외한** 수익률로 종목을 정렬해 승자를 매수하고 패자를 공매도한다. 형성·보유 기간을 여러 개 시험한 뒤 가장 높은 성과만 보고하면 선택 편향이 생긴다. 큰 하락 뒤 시장이 반등해 과거 패자가 급등하면 공매도 다리에서 큰 손실이 난다. 모멘텀 폭락 연구[22]는 이 상태 의존적 위험을 다룬다.

[22] https://doi.org/10.1016/j.jfineco.2015.12.002

4.14 슬라이드 14 · 과거 승자가 계속 이기는가

매월 형성 시점까지 공개된 가격으로 지난 6~12개월 수익률을 계산하되 직전 한 달을 뺀다. 승자 그룹을 사고 패자 그룹을 판 뒤 다음 달 수익률을 잰다. 실적 서프라이즈 뒤의 가격 지연 반응도 관련 모멘텀 신호다.

단기 반전 때문에 직전 한 달을 빼는 설계는 임의적인 숫자 놀이가 아니다. 거래비용·유동성 충격과 중기 정보 반응을 구분하려는 장치다. 대형주에서도 남는지와 매매회전율을 함께 확인해야 한다.

날짜로 풀면 2026년 9월 말에 종목을 정렬할 때 2025년 10월부터 2026년 8월까지의 11개월 수익률을 신호로 쓰고, 바로 앞선 2026년 9월 수익률은 제외한 뒤 2026년 10월에 보유한다는 뜻이다. 실제 구현에서는 어느 날의 종가로 신호를 마감하고 언제 주문을 체결하는지까지 정해야 한다. 신호 계산에 쓴 종가를 이미 지난 체결 가능 가격처럼 취급하면 매매 가능성이 과장된다.

4.15 슬라이드 15 · 모멘텀의 위험과 가격오류 설명

위험 설명은 승자·패자 포트폴리오가 나쁜 경제 상태에서 손실을 주기 때문에 평상시 높은 평균 수익률이 보상이라는 주장이다. 가격오류 설명은 투자자가 새 정보에 천천히 반응해 승자의 좋은 소식이 몇 달에 걸쳐 가격에 반영된다는 주장이다.

가격오류가 느린 정보 반응에서 온다면 실적발표 뒤 수개월의 가격 조정과 분석가 전망의 늦은 수정이 나타날 수 있다. 위험 보상이라면 투자자의 한계효용이 높은 위기 때 손실이 집중되는지를 본다. 어느 한 결과만으로 설명을 확정하기보다 **기대의 수정 시점**과 **상태별 손익**을 함께 비교한다.

4.16 슬라이드 16 · 평균 모멘텀과 폭락 위험

모멘텀의 평균 수익이 양수라도 시장 급락 뒤 강한 반등에서는 과거 패자들이 폭등할 수 있다. 패자를 공매도한 포지션은 이때 큰 손실을 낸다. 평상시 평균과 위기 상태의 손실이 비대칭인 것이다.

손실은 단순 표준편차보다 꼬리위험, 마진 요구, 포지션 강제청산에 중요하다. Daniel·Moskowitz[23]의 분석은 모멘텀 수익과 급격한 반전 위험을 함께 평가하게 한다. 전략의 적정 규모는 평균수익률뿐 아니라 이런 상태에서 버틸 수 있는 자금에 달려 있다.

승자 다리가 한 달에 2% 오르고 패자 다리가 10% 오르면 롱숏 수익은 $2\% - 10\% = -8\%$다. 두 다리 모두 올랐는데 전략 전체는 크게 손실을 낸다. 공매도 담보 요구가 손실 중간에 커져 포지션을 청산해야 하면 월말의 계산상 수익보다 실제 손실이 더 커질 수 있다. 평균·표준편차와 함께 위기 달의 두 다리 수익을 따로 기록한다.

4.17 슬라이드 17 · 가치와 성장의 구분

가치주는 주가가 장부가치, 이익, 현금흐름에 비해 낮은 기업이다. "가격이 싸다"는 것은 주당 절대가격이 낮다는 뜻이 아니라 기초가치와의 비율이 낮다는 뜻이다. 성장주는 미래 확장에 대한 기대가 가격에 많이 반영된 기업이다.

가치 프리미엄은 가치주를 사고 성장주를 판 상대수익률이다. 두 그룹의 현재 수익성과 미래 성장성이 달라 비율의 분모가 지속 가능한지 확인해야 한다.

[23] https://doi.org/10.1016/j.jfineco.2015.12.002

같은 주당 가격 1,000원이라도 주당 순이익이 100원이면 주가수익비율 $P/E = 10$, 순이익이 10원이면 $P/E = 100$이다. 전자는 현재 이익 대비 가격이 낮지만 미래 이익이 급감할 위험도 있을 수 있다. 가격의 절대 숫자와 가격을 기초량으로 나눈 비율을 구별한 뒤, 비율의 분모가 지속 가능한지 확인해야 한다.

4.18 슬라이드 18 · 장부가치/시가총액으로 정렬하기

B/M이 높은 종목은 장부상 자기자본에 비해 주가가 낮다. 같은 투자금으로 더 많은 장부가치를 사는 셈이지만, 장부가치의 질이 낮거나 미래 손실이 클 수도 있다. 값이 높다는 사실만으로 저평가를 확정하지 않는다.

산업마다 회계처리와 무형자산 비중이 달라 비율이 구조적으로 다르다. 업종 내 비교나 무형자산 보정은 신호를 바꿀 수 있다. 실무에서는 재무제표 발표 지연을 반영하고 상장폐지 종목을 포함해야 성과를 과대평가하지 않는다.

시가총액은 주가에 발행주식 수를 곱한 값이므로 주식분할 자체는 B/M의 경제적 의미를 바꾸지 않는다. 반면 손실 누적으로 장부자본이 작아지거나 음수가 되면 비율의 해석이 어려워진다. 해당 종목을 어떻게 처리했는지, 산업 내 순위를 썼는지, 회계자료가 언제 공개됐는지 확인해야 한다.

장부자본 100억 원·시가총액 50억 원인 회사의 B/M은 2이고, 장부자본 20억 원·시가총액 50억 원인 회사는 0.4다. 하지만 첫 회사가 곧 100억 원의 청산가치를 갖는다고 볼 수 없다. 장부자본은 과거 회계 처리의 결과이며 자산의 현재 매각가나 미래 영업현금흐름과 다를 수 있다. 같은 B/M이라도 부채와 영업 위험을 함께 봐야 한다.

4.19 슬라이드 19 · 가치 프리미엄의 두 해석

위험 해석은 가치기업의 현금흐름이 경기 악화 때 더 크게 줄어들어 투자자가 높은 기대수익률을 요구한다는 것이다. 가격오류 해석은 시장이 과거 부진을 지나치게 연장해 낮은 가격을 매겼다가 예상을 고치는 과정에서 초과수익이 생긴다는 것이다.

가치기업의 위험 보상을 검토할 때는 불황의 롱숏 손익을, 가격오류를 검토할 때는 당시의 전망과 이후 실현된 현금흐름·가격 반응을 비교한다. 가치주 평균수익률만으로 두 설명을 가를 수 없다.

나쁜 상태의 손실을 확인할 때는 가치주 자체의 절대 수익뿐 아니라 가치주 매수·성장주 공매도 전략의 수익을 본다. 불황에 두 그룹이 모두 하락해도 가치주가 덜 하락하면 롱숏 전략은 양수일 수 있다. 위험 보상 주장은 **어떤 투자자의 어떤 나쁜 상태**에서 전략이 보험 역할을 못 하는지를 명시해야 한다. 가격오류 주장에는 당시 투자자 기대를 보여 주는 전망자료도 필요하다.

4.20 슬라이드 20 · 가치 효과의 기간과 측정

가치 프리미엄의 크기는 원래 연구 기간, 이후 장기 기간, 대형주만의 결과에 따라 달라질 수 있다. 장부에 계상되지 않은 연구개발·브랜드 자산을 보정하면 현대 기업의 장부가치가 바뀌고 가치 분류도 달라진다.

무형자산 보정의 예로 연구개발 지출을 즉시 비용으로 보지 않고 몇 년간 자본화할 수 있다. 그러면 과거 지출의 누적액이 장부자본에 더해지고 당기 이익에서는 상각액을 차감한다. 내용연수와 상각률을 바꾸면 가치주 분류가 달라질 수 있으므로 보정 전후의 순위와 결과를 같이 보고한다.

단순한 무형자본 장부를 $K_t = (1-\delta)K_{t-1} + RD_t$로 쓸 수 있다. RD_t는 올해 연구개발 지출, δ는 가정한 연간 소멸·상각률이다. 같은 RD_t라도 $\delta = 20\%$와 50%를 쓰면 과거 지출의 잔존 가치가 달라져 조정 장부자본과 가치 정렬이 달라진다. 상각률은 과거 수익률을 가장 높이는 값으로 고르지 않고 기술의 경제적 내용연수에 근거해야 한다.

4.21 슬라이드 21 · 투자와 수익성으로 넘어가기

기업의 실물 투자와 이익 창출 능력은 가격을 결정하는 현금흐름과 할인율 양쪽에 연결된다. 투자율이 높은 기업의 기대수익률이 낮고 수익성이 높은 기업의 기대수익률이 높은 패턴은 처음에는 직관에 어긋나 보인다.

수익성이 높은 회사라도 주가가 이미 높으면 투자자의 기대수익률은 낮을 수 있다. 투자율이나 수익성의 효과를 비교할 때 **가격과 미래 지급액 중 무엇을 고정하는지**가 중요하다.

두 기업이 모두 내년 110원을 지급할 것으로 예상되어도 오늘 가격이 100원과 105원이면 기대 단순수익률은 각각 10%와 약 4.76%다. 같은 사업 전망에서도 지불하는 가격이 다르면 투자수익은 달라진다. 투자와 수익성 특성은 미래 지급액과 현재 가격 중 어느 쪽을 주로 반영하는지 분해해야 하며, 그 차이를 위험인지 예상오류인지 따로 검증한다.

4.22 슬라이드 22 · 빠른 자산 증가와 낮은 미래수익률

총자산이 빠르게 늘어난 기업은 자본비용이 낮아 투자를 많이 할 수 있다. 또는 시장이 확장을 과도하게 낙관한 결과 미래 주식 수익률이 낮아질 수도 있다. 자산 증가율에는 인수합병, 현금 축적, 회계 변화가 섞일 수 있어 지표의 구성을 확인해야 한다.

자산 증가율은 올해와 작년 총자산의 차이를 작년 자산으로 나눈다. 합병, 설비 건설, 현금 보유 증가는 모두 자산을 늘리지만 할인율과 미래 이익에 연결되는 경로는 다르다.

작년 자산 100억 원이 올해 130억 원이면 증가율은 30%다. 그중 20억 원이 인수합병으로 들어온 영업권이고 10억 원이 현금 증가라면 '설비 투자 30%'라고 해석할 수 없다. 실물 투자 가설을 시험하려면 설비투자, 연구개발, 인수합병과 운전자본 변화를 나누어 보고 각 항목의 공개 시점도 맞춘다.

4.23 슬라이드 23 · 투자율과 할인율의 연결

새 설비의 기대수익이 할인율보다 높을 때 기업은 투자한다. 다른 조건이 같다면 자본비용이 낮은 기업은 더 많은 프로젝트를 채택할 수 있어 투자율이 높다. 따라서 높은 투자가 낮은 기대주식수익률을 암시할 수 있다.

투자율은 할인율의 **간접 신호**다. 기업 사이의 성장 기회, 조정비용, 내부 자금 제약도 투자량을 바꾸므로 함께 고려한다.

예를 들어 한계 프로젝트의 예상 수익률이 12%와 8%이고 요구수익률이 10%라면 12% 프로젝트만 채택한다. 요구수익률이 7%로 낮아지면 두 프로젝트를 모두 채택할 수 있어 투자량이 늘어난다. 이 방향은 프로젝트 위험과 자금조달 제약이 같다는 단순 조건에서 나온다. 성장 기회가 다른 기업끼리 투자량만 비교하면 할인율의 차이를 잘못 추론할 수 있다.

4.24 슬라이드 24 · 수익성 높은 회사의 높은 수익률

이익/자산이나 자기자본이익률이 높은 기업이 미래에도 높은 수익률을 주는 패턴은 "좋은 기업은 이미 비쌀 텐데 왜 더 오르는가"라는 질문을 만든다. 가격이 비싸도 미래 현금흐름이 시장의 예측보다 더 좋아지면 추가 수익이 가능하다.

또는 높은 기대 수익성이 같은 투자율 아래에서 높은 할인율과 함께 나타날 수 있다. 수익성은 회계상 일회성 이익과 산업별 자본집약도에 영향을 받으므로 지속 가능한 영업 성과로 측정해야 한다.

예를 들어 두 회사 모두 올해 영업이익이 10억 원이고 내년 시장 예상이 11억 원이라고 하자. 실제 발표가 한 회사는 13억 원, 다른 회사는 9억 원이면 현재 수익성은 같아도 예상 대비 실적 변화는 각각 +2억 원과 -2억 원이다. 주가 반응을 해석할 때는 이 **예상과 실현의 차이**를 당시 가격에 반영된 전망, 할인율 변화와 함께 본다.

4.25 슬라이드 25 · 수익성 효과의 항등식과 설명

기업가치를 미래 현금흐름의 현재가치로 쓰면, 현재 가격과 예상 투자 규모가 주어졌을 때 기대이익이 클수록 기대수익률도 높아져야 한다. 이는 특정 위험의 존재를 증명하는 이론이 아니라 가격·현금흐름·수익률 사이의 회계적 관계다.

예상 수익성이 높아도 그 이익을 얻기 위한 추가 투자가 크면 주주에게 돌아올 현금흐름은 작다. 회계 이익에서 투자 지출을 고려해 가격과 비교한 뒤, 남는 수익률 차이가 높은 할인율인지 시장의 이익 지속성 과소평가인지 검토한다.

한 기간의 단순 총수익률은 $(P_1 + D_1 - P_0)/P_0$다. 현재 가격 P_0가 같은 두 기업에서 미래 배당 D_1과 가격 P_1의 기대값이 높은 쪽이 기대수익률도 높지만, 높은 회계 이익이 모두 D_1로 지급되는 것은 아니다. 사업 유지를 위한 재투자와 부채 상환을 거친 뒤의 현금흐름이 중요하다. 그래서 '높은 수익성 → 높은 주식수익'은 다른 조건을 고정해야 얻는 비교정태다.

4.26 슬라이드 26 · 두 자산가격 요인모형

파마·프렌치 5요인모형은 시장, 규모, 가치에 수익성 RMW와 투자 CMA를 더한다. 다른 q 요인모형도 수익성과 투자를 중심에 둔다. 요인을 추가하면 원래 이상현상의 알파가 줄어들 수 있지만, 이것만으로 요인이 경제적으로 올바른 위험이라는 뜻은 아니다.

RMW는 수익성이 강한 기업을 매수하고 약한 기업을 매도하는 수익률, CMA는 보수적으로 투자하는 기업을 매수하고 공격적으로 투자하는 기업을 매도하는 수익률이다. 요인 수익률은 기업 특성의 숫자 자체가 아니라 그 특성으로 만든 포트폴리오 수익이다. 개별 종목의 요인 베타와 특성 수준을 구별해야 한다.

예를 들어 수익성 요인 RMW의 월 수익률이 2%인 달에 어떤 기업의 주가가 함께 올랐다고 해서 그 회사의 영업이익률이 2%라는 뜻은 아니다. 회사의 **특성**은 재무제표에서 측정하고, RMW에 대한 **베타**는 여러 달의 수익률 공분산에서 추정한다. 요인 회귀의 알파가 0이어도 그 요인이 왜 보상을 받는지에 관한 경제적 설명은 별도로 필요하다.

4.27 슬라이드 27 · 무형자산의 회계 문제

기계는 자산으로 올리고 여러 해에 걸쳐 감가상각하는 반면 연구개발·조직 구축 비용은 즉시 비용 처리되는 경우가 많다. 경제적으로는 둘 다 미래에 수익을 줄 수 있는 투자여도 회계 장부에는 다르게 남는다.

회계상 비용 처리와 경제적 자산 형성이 다르면 분모인 장부자본뿐 아니라 분자인 이익도 흔들린다. 연구개발 지출이 많은 기업은 당기 보고 이익이 낮고 미래의 수익 창출 능력은 높을 수 있다. 하지만 실패한 연구개발은 자산 가치가 0일 수 있으므로 지출 전액을 기계적으로 자산화해서도 안 된다.

연구개발비를 경제적 투자로 재분류하면 지출 일부를 여러 기간에 걸쳐 상각하므로 당기 이익과 장부자본이 함께 바뀐다. 이는 **경제적 비교를 위한 대체 측정**이며, 자산으로 남길 금액은 연구의 성공 가능성과 효익 기간에 달려 있다.

4.28 슬라이드 28 · 장부 밖 투자와 비율의 왜곡

두 기업이 각각 100을 미래 생산능력에 투입한다고 하자. 설비 구매는 자산에 남고 당기 감가상각 10만 비용일 수 있지만, 연구개발 100은 당기 비용으로 처리될 수 있다. 그러면 경제적 투자 규모가 비슷해도 보고 이익과 장부자본이 크게 다르다.

연구개발 100을 5년에 걸쳐 균등 상각한다고 가정하면 첫해 비용은 20이고 남은 자산은 80이 된다. 즉시 비용 처리와 비교해 첫해 이익과 장부자본이 각각 80 높아진다. 이것은 사실의 발견이 아니라 내용연수 5년이라는 가정을 적용한 재작성이다. 다른 상각기간에서도 결론이 남는지 확인해야 한다.

B/M뿐 아니라 ROE도 보정 전후에 반드시 같은 회계 기준으로 계산해야 한다. 즉시 비용 처리한 이익을 분자로 두고 연구개발을 자산화한 자기자본만 분모에 넣으면 두 기준이 섞인다. 같은 회사의 보고 ROE와 보정 ROE가 달라졌다면 분자 이익의 비용·상각 조정과 분모 자기자본의 변화를 따로 적어 어느 쪽이 결과를 움직였는지 확인한다.

4.29 슬라이드 29 · 무형자산 프리미엄의 두 설명

핵심 인력과 기술 지식은 경기 충격 때 가치가 불안정할 수 있어 위험 보상을 요구할 수 있다. 다른 한편 투자자가 장부에 드러나지 않는 역량을 늦게 인식하면 가격오류가 생길 수 있다. 연구개발의 수익은 성공과 실패가 크게 갈려 평균만으로 판단하기 어렵다.

고용 이동, 특허, 광고, 영업레버리지는 서로 다른 무형자본의 대용변수다. 여러 지표를 묶기 전에 각각이 어떤 자산과 위험을 측정하는지 정의한다.

같은 특허 100개라도 핵심 기술 하나가 매출 대부분을 지탱하는 기업과 사업화되지 않은 작은 특허를 많이 가진 기업의 현금흐름은 다르다. 특허의 인용·유효기간·제품 매출과 연결하면 측정이 나아질 수 있지만 새 선택과 측정오차도 들어온다. 위험 설명은 위기 때 무형자본 현금흐름이 특히 나빠지는지, 오류 설명은 성공 소식이 발표될 때 가격이 뒤늦게 반응하는지 묻는다.

4.30 슬라이드 30 · 낮은 범주 재현율을 해석하기

무형자산 범주의 신호에는 연구개발뿐 아니라 분석가 전망, 이익의 질, 계절성 등도 섞일 수 있다. 연구개발/매출은 활동의 강도를, 연구개발/시가총액은 시장가격 대비 지출을 뜻한다. 범주의 평균 재현율을 개별 경제 기제의 성패로 옮기기 전에 신호의 정의를 분리한다.

범주에 20개 신호가 있고 4개만 기준을 넘었다면 재현율은 20%다. 하지만 20개 중 15개가 사실상 같은 지표의 작은 변형이라면 '독립된 경제 가설 20개 중 4개'라는 해석은 부정확하다. 분모의 신호 목록, 서로의 상관, 포함된 경제 기제를 확인해야 한다. 개별 신호의 실무 가치와 범주 통계는 다른 질문이다.

4.31 슬라이드 31 · 거래마찰은 가격과 비용을 함께 바꾼다

소형·비유동 종목의 높은 관측수익에는 위험 보상과 거래하기 어려운 가격이 함께 섞일 수 있다. 실제 비용은 고정 수수료, 호가 스프레드, 주문의 가격 충격, 공매도 차입료를 포함한다. 양쪽 다리를 자주 갈아타는 전략일수록 명목 수익과 실제 체결 가능한 수익이 벌어진다.

운용자산 100원당 한 달에 총 200원어치의 매매를 한다면 거래 명목금액/자산 비율은 2다. 거래된 금액 1원당 비용이 0.4%면 자산 대비 월 비용은 $2(0.4\%) = 0.8\%$다. 명목 롱숏 수익 1%에서 이를 빼면 0.2%가 남고, 차입료와 가격충격이 추가되면 더 낮아진다. 회전율의 정의와 매수·매도 양쪽 포함 여부를 먼저 확인해야 숫자가 맞는다.

4.32 슬라이드 32 · 소형주와 비유동성

소형주는 분석가의 관심이 적고 정보가 가격에 늦게 반영될 수 있다. 동시에 경기 악화 때 자금 조달이 더 어렵고 거래를 청산하기도 힘들어 투자자가 보상을 요구할 수 있다. 두 설명은 함께 성립할 수 있다.

마지막 거래가격으로 계산한 수익률은 투자자가 같은 가격에 원하는 수량을 매매할 수 있다는 보장이 없다. 소형주 100개에 동일 금액을 투자하려면 각 기업의 일일 거래대금 대비 주문 비율을 확인해야 한다. 전략 규모가 커질수록 관측 가격과 체결 가격의 차이가 커지는 용량 문제가 생긴다.

가상의 종목에서 마지막 체결가가 1,000원이어도 현재 매수 호가가 990원, 매도 호가가 1,010원이라면 즉시 사서 다시 팔 때 $990/1010 - 1 \approx -1.98\%$다. 마지막 가격 1,000원으로 양쪽 거래를 모두 기록하면 이 비용이 보이지 않는다. 주문을 크게 내면 호가의 물량을 소진해 더 불리한 가격까지 체결될 수 있으므로 매수·매도 호가차와 주문 규모별 시장충격을 구분해야 한다.

4.33 슬라이드 33 · 고유변동성과 단기 반전

시장요인으로 설명되지 않는 개별 종목의 변동성을 고유변동성이라 한다. 전통적 분산투자 이론에서는 잘 분산할 수 있는 위험에 높은 보상이 필요하지 않지만, 실제 자료에서는 고유변동성이 높은 종목의 낮은 평균수익이 관찰되기도 한다.

직전 한 달 급등·급락 뒤 반전은 투자자 과잉반응 또는 유동성 공급의 대가일 수 있다. 호가 반등처럼 미시구조에서 나온 가짜 패턴도 가능하다. 비용과 대형주 표본에서 남는지를 확인해야 한다.

단일 시장요인 회귀 $r_{i,t} - r_{f,t} = a_i + \beta_i(r_{M,t} - r_{f,t}) + e_{i,t}$에서 $e_{i,t}$의 표준편차가 고유변동성의 한 추정치다. 시장 베타가 같아도 잔차가 크게 흔들리는 두 종목의 고유변동성은 다를 수 있다. 잔차에 산업 공통 충격이 남아 있다면 '완전히 분산 가능한 기업 고유 위험'과 같지 않을 수 있으므로 기준 요인모형도 명시해야 한다.

4.34 슬라이드 34 · 거래마찰 범주의 재현

소형·비유동주를 큰 비중으로 담는 전략은 원래 표본에서는 강한 차이를 보일 수 있지만 시가총액가중이나 대형주 기준으로 바꾸면 약해진다. 이는 통계적 존재와 실제 운용 가능성이 다른 질문임을 보여 준다.

동일가중은 종목마다 같은 원화를 놓지만 시가총액가중은 시장 전체에서 큰 기업에 더 많은 원화를 놓는다. 둘의 성과 차이가 크다면 신호가 작은 기업에서 강하다는 단서다. 이것은 효과가

'가짜'라는 증명은 아니지만 규모가 큰 실제 자금을 투입했을 때 얻을 수 있는 수익을 다시 계산하라는 경고다.

예를 들어 시가총액 100억 원 기업과 1억 원 기업 두 곳에서 작은 기업만 20% 오르고 큰 기업은 그대로라면, 동일가중 수익은 $0.5(20\%) + 0.5(0\%) = 10\%$다. 시가총액가중 수익은 $(1/101)(20\%) \approx 0.20\%$에 불과하다. 어느 숫자가 맞는지는 질문에 달려 있다. 작은 자금으로 동일 금액을 넣는 실험인지, 큰 자금을 시장 규모대로 배분하는 전략인지를 먼저 정해야 한다.

4.35 슬라이드 35 · 여섯 범주를 한꺼번에 비교하기

모멘텀은 평균 성과와 폭락 위험, 가치는 할인율과 예상오류의 구분, 투자는 기업의 최적 선택, 수익성은 현금흐름과 가격의 관계, 무형자산은 측정, 거래마찰은 구현 비용이 핵심이다. 서로 다른 범주에 한 가지 설명을 억지로 적용하면 중요한 차이가 사라진다.

형성 시점, 보유 기간, 가중치, 공매도 가능성, 기준요인, 거래비용을 맞춘 공통 평가표를 만든다. 평균수익 한 숫자는 모멘텀의 폭락 위험과 비유동주 전략의 매매비용을 보여 주지 못한다.

평균수익 1%인 두 전략도 매월 비용이 각각 0.1%와 0.9%면 비용 뒤 평균은 0.9%와 0.1%로 크게 벌어진다. 첫 전략이 위기에 -20%의 손실을 내고 둘째가 안정적이라면 위험 조정 순위는 다시 바뀔 수 있다. 범주를 비교하는 표에는 적어도 총수익, 비용 후 수익, 꼬리손실, 대형주 표본의 성과를 나란히 두어야 한다.

4.36 슬라이드 36 · 위험인가 가격오류인가

같은 예측변수가 미래 수익률과 상관되어도 경제적 해석은 갈린다. 위험 프리미엄이라면 나쁜 상태에서 손실을 주는 보상이고, 가격오류라면 투자자의 기대가 체계적으로 잘못되었다가 수정되는 이익이다.

위험 보상은 위기 손실을 감수하는 대가로 남을 수 있다. 가격오류는 경쟁과 자금 유입으로 줄어들 수 있고, 차익거래 제약이 조정 속도를 정한다. 한 전략에는 두 성분이 함께 들어갈 수도 있다.

예를 들어 두 전략의 연평균 수익이 모두 8%인데 A는 불황에 -30%를 기록하고 B는 불황에 +5%를 기록한다면, 평균만 같은 두 전략의 보험 가치는 다르다. A의 높은 평시 수익은 나쁜 상태의 손실 보상일 수 있다. B의 수익도 곧바로 가격오류라고 단정할 수는 없다. 위험을 어떤 상태로 측정했는지와 거래 제약이 무엇인지 함께 조사해야 한다.

4.37 슬라이드 37 · 두 설명의 서로 다른 예측

위험 설명은 전략의 수익이 소비가 낮거나 유동성이 부족한 상태에서 나빠진다고 예측한다. 가격오류 설명은 잘못된 기대가 드러나는 실적발표 같은 시점에 수익이 집중되고, 공개·발표 후에는 효과가 감소할 수 있다고 예측한다.

느린 실적 반응 가설은 발표 직전 분석가 예상과 실제 실적의 차이를 잰 뒤, 발표일과 이후 몇 달의 가격 반응을 추적한다. 위험 가설은 그 수익이 소비나 유동성이 나쁜 상태에 집중되는지, 기존 요인 노출로 설명되는지 살핀다. 발표일 하루만 보면 뒤따르는 기대 수정과 상태별 위험을 놓칠 수 있다.

4.38 슬라이드 38 · 지금까지의 가격 항등식

낮은 가격은 미래 현금흐름에 대한 낮은 예상과 높은 할인율 양쪽에서 나올 수 있다. 모멘텀은 정보 반응의 시간, 무형자산은 현금흐름 측정, 투자는 기업의 자본비용 선택을 강조한다. 종목 특성의 예측력이 가격식의 **어느 경로**에서 오는지 묻는 이유다.

가장 단순한 한 기간 예를 보자. 1년 뒤 **확정** 현금흐름이 110이고 할인율이 10%이면 현재 가격은 $110/1.10 = 100$이다. 현금흐름이 105이고 할인율이 5%여도 가격은 $105/1.05 = 100$이다. 가격 100만 관측해서는 현금흐름 기대와 할인율을 따로 복원할 수 없다. 위험한 현금흐름에서는 할인인자와 현금흐름의 공분산까지 가격에 들어가므로 식별은 더 어려워진다. 이 때문에 가치 비율 하나를 위험 프리미엄이나 과대평가의 증거로 곧장 읽을 수 없다.

4.39 슬라이드 39 · 네 가지 구별 질문

발표 뒤 수익이 줄어드는가, 이익이 매수 다리와 공매도 다리 중 어디에 있는가, 큰 유동주에도 남는가, 기업 특성보다 위험요인과의 공분산이 중요한가를 묻는다. 각각은 가격오류와 위험 보상에 대해 다른 힌트를 준다.

공매도 다리의 성과가 크면 과대평가가 오래 지속된다는 해석과 높은 차입비용을 함께 검토한다. 큰 유동주에서도 남는 신호라면 극소형주의 가격 문제에만 기대는 설명은 약해진다.

롱숏 1%의 월수익이 매수 다리 0.2%, 공매도 대상 종목의 수익률 -0.8%에서 왔다면 대부분은 공매도 다리다. 그런데 그 종목을 빌리는 비용이 월 1%라면 명목 이익보다 비용이 크다. 다리별 분해는 가격오류의 위치를 보여 주고, 차입 가능성과 비용은 그 위치에서 실제 차익거래가 가능한지를 알려 준다.

4.40 슬라이드 40 · 판정표의 증거를 읽는 법

발견 이후 평균 롱숏 수익률이 감소했다는 연구, 투자자 심리가 높은 때 공매도 다리의 성과가 크다는 연구, 대형주에서도 모멘텀이 남는다는 연구는 서로 다른 증거를 제공한다. 기간과 전략 구성이 달라 숫자를 한 표에 놓고 직접 대소 비교하면 안 된다.

판정표의 결과를 비교할 때 '평균수익 감소'와 '알파 감소'를 구별한다. 시장과 기존 요인의 평균 수익이 바뀌면 원수익은 변해도 상대 알파는 남을 수 있다. 원 연구와 재검증 연구가 같은 포트폴리오와 기간을 썼는지 확인하고, 연구별 정의가 다르면 효과 크기보다 결과의 방향과 메커니즘을 비교한다.

예를 들어 전략의 총초과수익이 8%에서 5%로 줄었어도 같은 기간 기준요인의 설명 부분이 6%에서 3%로 줄었다면 단순 차이 알파는 두 기간 모두 2%다. 반대로 총수익이 그대로여도 기준 위험노출의 보상이 커졌다면 알파는 줄 수 있다. 서로 다른 연구의 수치를 비교하려면 원수익과 기준모형 조정 후 수익을 분리해야 한다.

4.41 슬라이드 41 · 예측자와 설명자의 목표

예측모형은 장부가치/시가총액이 다음 수익률을 맞힌다면 위험 때문인지 가격오류 때문인지 몰라도 사용할 수 있다. 그러나 투자자 행동이 바뀐 뒤에도 신호가 남을지 예측하려면 원인을 이해해야 한다.

시장 참여자가 신호를 따라 거래하기 시작하면 가격과 예상 수익이 변할 수 있다. 예측력을 발견한 뒤 그 원인을 연구해야 이런 환경 변화에서의 성과를 판단할 수 있다.

예를 들어 낮은 투자율의 기업을 사는 규칙이 작동했다면 예측자는 다음 달 수익률 순위가 개선되는지만 먼저 검증할 수 있다. 설명자는 높은 자본비용이 투자를 억제해 높은 기대수익을 만든 것인지, 투자자가 성장을 과대평가해 고투자 기업을 비싸게 산 것인지 구별해야 한다. 두 설명은 현재 같은 수익률 패턴과 양립해도 위험 회피 변화나 전략 공개 뒤의 가격 반응에 대해 다른 예측을 만든다.

4.42 슬라이드 42 · 투자 CAPM의 최적화 유도

투자 CAPM(investment CAPM)에서 기업이 현재 자산 A에 추가 투자 I를 하고, 투자 한 단위의 조정비용이 투자율 I/A에 따라 올라간다고 하자. 현재 총비용을 $I + (a/2)(I/A)^2 A$로 쓰면 I에 대한 한계비용은 $1 + aI/A$다. 한계 투자에서 얻는 미래 이익 Π_1의 현재가치를 $E[M_1\Pi_1]$라 하면 최적화 조건은 다음과 같다.

$$1 + a\frac{I}{A} = E[M_1\Pi_1].$$

위험과 할인인자를 단순화하여 한 기간 요구 총수익률 $1 + E[r]$로 현재가치를 표현하면 $E[M_1\Pi_1] \approx E[\Pi_1]/(1 + E[r])$다. 따라서 $1 + E[r] \approx E[\Pi_1]/(1 + aI/A)$다. 예상 수익성이 같다면 높은 투자는 낮은 요구수익률과, 투자율이 같다면 높은 예상 수익성은 높은 요구수익률과 연결된다. 이 최적화는 부호를 설명하지만 **왜 할인율이 기업마다 다른지**는 별도의 위험·시장 이론이 필요하다.

수치를 넣어 $a = 1$, 투자율 $I/A = 0.1$, 미래 한계이익의 기대값 $E[\Pi_1] = 1.32$라 하자. 한계비용은 $1 + 0.1 = 1.1$이고 단순화한 요구 총수익률은 $1.32/1.1 = 1.20$, 즉 기대수익률 20%다. 같은 미래 한계이익에서 투자율이 0.2이면 분모가 1.2가 되어 식상 기대수익률은 10%다. 이것은 다른 조건을 고정한 **비교정태**다. 실제 기업 사이에는 투자 기회와 위험도 달라지므로 관측된 투자율 차이를 곧바로 10%포인트의 요구수익 차이로 읽지 않는다.

4.43 슬라이드 43 · 특성과 공분산을 떼어 놓기

가치주가 높은 수익을 얻는 이유가 가치요인 HML에 대한 노출이라면, 장부가치/시가총액을 고정하고 HML 노출만 높은 종목은 더 높은 수익을 주어야 한다. 반대로 특성 자체가 중요하다면 노출 차이를 만들어도 수익 차이가 작을 수 있다.

위험요인 베타는 과거 수익률과 요인 수익률의 공분산에서 추정하므로 잡음이 있다. 비슷한 가치 특성을 가진 종목 안에서 베타만 비교해도 베타 측정오차가 크면 진짜 위험 관계를 놓칠 수 있다. 특성과 베타를 분리하는 연구의 상반된 결과는 표본 기간·요인 정의·추정오차를 함께 읽어야 이해된다.

베타를 $\beta_{i,HML} = \mathrm{Cov}(r_i, HML)/\mathrm{Var}(HML)$로 정의하면 B/M은 회계·가격에서 계산한 **수준**, 베타는 요인 수익과의 **공동 움직임**이다. 같은 B/M인 두 기업도 하나는 경기 악화 때 가치요인과 함께 떨어지고 다른 하나는 그렇지 않을 수 있다. 다만 베타를 과거 짧은 기간에서 추정하면 측정오차가 커져 조건부 정렬의 검정력이 낮아진다.

4.44 슬라이드 44 · 우연이라는 세 번째 설명

높은 수익률과 그럴듯한 이야기가 함께 있어도 많은 후보 가운데 운 좋게 발견된 결과일 수 있다. 논문에 실린 전략만 보면 실패한 시도는 보이지 않는다. 이 **선택된 표본의 문제**가 요인 동물원의 핵심이다.

가령 연구자가 장부비율의 분모, 극단값 절단, 보유기간, 국가를 여러 번 바꿔 가장 큰 수익만 보고한다면, 표에 보이는 전략은 수많은 실패 후보 중 선택된 것이다. 원래의 t값은 이 탐색을 보정하지 않는다. 사전 등록된 규칙이나 완전히 새로운 기간의 검증이 우연 설명을 줄이는 핵심이다.

독립적인 참귀무가설 100개를 각각 5% 수준에서 검사하면 적어도 하나의 p값이 0.05 이하일 확률은 $1-0.95^{100}\approx 99.4\%$다. 따라서 연구자가 그 한 결과만 보여 줄 때 독자는 '드문 5% 사건'을 본 것이 아니다. **100번 중 가장 유리한 것을 고른 절차**의 결과를 본 것이다. 이 계산은 독립일 때의 직관용 예시이며, 현실의 상관된 후보에서는 선택 과정 전체를 별도로 기록해야 한다.

4.45 슬라이드 45 · t값 2의 의미가 바뀌는 순간

한 개의 사전 지정된 가설을 정규근사로 검정하면 $|t|>1.96$은 양측 5% 수준이다. 연구자가 효과가 0인 전략도 수백 개 시도한 뒤 가장 높은 값만 발표하면, 독자는 그 선택 과정을 보지 못한다.

참귀무가설 300개에서 각 검정의 거짓 양성 확률이 5%이면 거짓 발견 개수의 기대값은 $300\times 0.05=15$다. 검정끼리 독립일 필요는 없다. 독립이라고 **추가로** 가정할 때만 발견 개수 V가 이항분포 $\mathrm{Binom}(300,0.05)$를 따라 표준편차가 $\sqrt{300(0.05)(0.95)}\approx 3.77$이라고 계산할 수 있다. 논문에 가장 큰 통계량만 싣는다면 독자가 보는 값은 300개 전체의 무작위 표본이 아니다.

기댓값 15와 '한 개라도 잘못 나올 확률'도 다르다. 300개 검정이 서로 독립이고 개별 오류확률이 5%라면 후자는 $1-0.95^{300}$으로 거의 1이다. 반대로 완전히 같은 검정을 300번 복제했다면 기댓값은 여전히 15이지만 한 번이라도 잘못 기각할 확률은 5%다. 요인들이 서로 비슷할수록 기대 개수만 보고 실제 연구의 발견 패턴을 추정할 수 없다.

4.46 슬라이드 46 · 잡음 전략 300개의 모의실험

참 기대수익률이 모두 0인 300개 전략을 독립적으로 만들고 각 전략의 평균에 대한 t값을 계산하면 히스토그램의 일부 막대가 우연히 2를 넘는다. 이때 발견된 '이상현상'은 모의실험 설계상 모두 거짓이다.

현실의 전략들은 같은 종목과 기간을 공유해 상관될 수 있다. 거짓 양성 지시변수를 I_j라 두면 발견 개수 $V=\sum_j I_j$의 분산은 $\sum_j \mathrm{Var}(I_j)+2\sum_{j<k}\mathrm{Cov}(I_j,I_k)$다. 양의 의존은 잘못된 발견이 한꺼번에 몰릴 가능성을 키운다. 시계열 자기상관 때문에 개별 p값부터 잘못 계산했다면 앞 슬라이드의 5% 오류확률 가정도 성립하지 않는다.

히스토그램에서 $t=2$를 넘는 꼬리는 정규분포의 자연스러운 일부다. 그 안의 한 전략에 경제적 이야기를 붙여도, 모의실험에서는 참효과가 0임을 이미 알고 있다. 반대로 현실에서는 참효과도 섞여 있으므로 모의실험의 교훈은 '모든 발견이 거짓'이 아니라 '이야기와 통계량만으로 진위를 판정할 수 없다'는 것이다.

300개 전략 각각에 평균 0인 수익률을 생성해 t값을 저장하고 새 난수 표본으로 반복하면, 실험별 통과 개수의 분포를 직접 볼 수 있다. 전략 수익률에 상관을 넣으면 한꺼번에 통과하는 정도가 바뀐다. 두 실험을 비교할 때는 개별 표준오차의 계산부터 같은 기준으로 맞춘다.

4.47 슬라이드 47 · 진짜 전략 10개를 섞었을 때

잡음 290개 사이에 참 신호가 있는 전략 10개를 넣으면 낮은 임계값은 진짜도 많이 잡지만 거짓도 많이 포함한다. 높은 임계값은 거짓을 줄이는 대신 약한 참 신호를 놓친다. 이것이 검정력

과 거짓 발견의 상충관계다.

정책 목적에 따라 기준이 달라진다. 수백 후보에서 연구할 만한 주제를 고르는 단계라면 거짓 발견 비율을 통제할 수 있고, 고객 자금을 큰 규모로 투입한다면 더 엄격한 독립 확인이 필요하다.

숫자로 보면, 290개 참귀무가설이 각각 5% 확률로 잘못 통과하고 진짜 전략 10개를 잡아낼 검정력이 각각 80%라면 기대 거짓 발견은 $290(0.05) = 14.5$개, 기대 참 발견은 $10(0.8) = 8$개다. 관측된 발견 목록에 거짓이 적지 않을 수 있다는 직관을 준다. 다만 $14.5/(14.5+8)$은 **기대 개수의 비율**일 뿐, 발견 총수 $R = 0$일 때 비율을 0으로 두는 FDR $= E[V/\max(R,1)]$과 일반적으로 같지 않다. 임계값을 바꾸면 개별 검정의 거짓 양성 확률과 검정력이 모두 달라져 두 개수를 다시 계산해야 한다.

4.48 슬라이드 48 · 왜 새 요인에는 더 높은 기준이 필요한가

발표된 요인이 수백 개라면 각 논문의 5% 유의성 기준을 그대로 유지하기 어렵다. Harvey·Liu·Zhu는 다중검정을 고려해 새 요인의 발견 기준을 대략 $t > 3$으로 높일 것을 제안했다.

숫자 3은 모든 연구에 똑같이 적용되는 자연상수가 아니다. 실제로 몇 번 시도했는지, 전략들 사이의 상관, 사전 가설의 강도에 따라 적절한 기준이 달라진다. 연구 원문[24]의 수치는 요인 목록이 커질 때 기존 판정 규칙을 재고해야 함을 보여 준다.

정규근사에서 한 **사전 지정된 양측 검정**의 $|t| > 3$ 거짓 양성 확률은 약 0.27%다. 300개 참귀무가설을 각각 이 기준으로 시험하면 실제 오류확률이 그 값일 때 기대 거짓 발견은 약 $300(0.0027) = 0.81$개다. 이는 보정 없는 $|t| > 2$의 약 15개보다 작지만, 가족별 오류확률이 5% 이하라는 보증은 아니다. 어떤 오류 기준을 원하는지에 따라 문턱이 달라진다.

4.49 슬라이드 49 · 다중검정 규칙의 단계별 계산

M개 검정에서 하나라도 거짓 양성이 생길 확률을 5% 이하로 두고 싶다면 합집합의 확률은 개별 확률의 합 이하라는 부등식을 쓴다. 각 검정을 α/M에서 실시하면 전체 거짓 양성 확률은 최대 $M(\alpha/M) = \alpha$다. 이것이 본페로니 기준이다.

$$P\left(\bigcup_{j=1}^{M} A_j\right) \le \sum_{j=1}^{M} P(A_j), \qquad p_j \le \frac{\alpha}{M}.$$

Holm은 p값을 작은 순서로 정렬해 $p_{(k)} \le \alpha/(M-k+1)$를 차례로 확인한다. Benjamini–Hochberg는 가족 전체에서 단 한 개의 오류도 허용하지 않는 대신, 발견된 것 가운데 거짓의 기대 비율을 통제한다. 독립 또는 특정 의존 조건 아래 최대 k에 대해 $p_{(k)} \le k\alpha/M$을 적용한다. 어떤 오류를 통제하려는지 먼저 정해야 방법을 고를 수 있다.

도식의 15개는 300개의 참귀무가설을 **보정 없이** 검정하고 각각의 실제 거짓 양성 확률이 정확히 5%일 때의 기대 발견 수다. 본페로니·Holm·BH는 이 출발점에 서로 다른 오류 통제 기준을 적용한다. 따라서 발견 수를 비교할 때는 어떤 방법을 썼는지 함께 적어야 한다.

질문: FDR 5%면 발견 20개 중 정확히 1개가 거짓인가요? 아닙니다. 반복 연구에서 거짓 발견 비율의 기대를 통제한다는 뜻입니다. 한 번의 표본에 거짓 발견이 0개일 수도 여러 개일 수도 있습니다.

[24] https://doi.org/10.1093/rfs/hhv059

4.50 슬라이드 50 · 재현 논쟁의 질문

한 연구는 대부분의 이상현상이 공통한 엄격한 조건에서 실패한다고 보고하고, 다른 연구는 상당수가 다양한 나라와 기간에서 남는다고 보고한다. 모순처럼 보이지만 "무엇을 같은 전략으로 볼지"와 "재현을 무엇으로 정의할지"가 다르다.

재현율의 분모부터 다를 수 있다. 처음 발표된 모든 이상현상을 세는 연구와 사전에 경제적 주제로 걸러낸 요인만 세는 연구는 같은 비율을 비교하지 않는다. 분자 역시 원수익, CAPM 알파, 새 국가의 같은 부호 등으로 정의된다. 각 연구의 분자·분모를 명시하면 숫자가 왜 갈리는지 보인다.

가상의 연구에서 발표된 전략 80개 가운데 엄격한 기준을 통과한 것이 16개면 재현율은 $16/80 = 20\%$다. 사전에 대형주에서도 거래 가능하다고 판단한 20개만 먼저 골라 그중 같은 16개가 통과했다면 $16/20 = 80\%$다. 두 수치가 다른 것은 계산 오류가 아니라 **질문에 포함한 전략 집합**이 달라졌기 때문이다. 다만 높은 재현율을 얻으려고 결과를 본 뒤 20개를 고르면 선택 편향이 새로 생긴다.

4.51 슬라이드 51 · 많은 이상현상이 실패한다는 결과

Hou·Xue·Zhang은 여러 전략을 동일한 규칙으로 재구성하고 NYSE 종목의 크기를 기준으로 그룹을 나누며 시가총액 가중 수익률을 쓴다. 이 방식에서는 작은 기업이 종목 수에 비해 시장가치에서 차지하는 비중이 작으므로 그 효과가 전체 전략을 지배하기 어렵다.

NYSE 종목으로 정렬 경계를 만든 뒤 전체 종목에 적용하면 극소형주가 경계 자체를 정하는 문제를 줄일 수 있다. 시가총액가중은 큰 자금의 운용 가능성에 가까운 질문이고, 동일가중은 작은 종목의 가격 형성을 더 크게 반영한다.

작은 예를 계산해 보자. NYSE 종목의 시가총액이 $200, 80, 30, 10, 4$, 다른 거래소 종목이 $3, 1, 0.5, 0.2, 0.1$이면, 전체 종목 기준 하위 5분위에는 $0.1, 0.2$ 두 종목만 들어간다. NYSE 종목만으로 경계를 정해 전체에 적용하면 하위 그룹에는 $4, 3, 1, 0.5, 0.2, 0.1$ 여섯 종목이 들어가며 이들의 시가총액 합은 8.8이다.

맨 작은 두 종목에만 월 3%의 추가수익이 있다면 전체 기준 하위 그룹의 추가수익은 3%다. NYSE 경계의 하위 그룹에서는 동일가중일 때 $(2/6)3\% = 1\%$, 시가총액가중일 때 $(0.3/8.8)3\% \approx 0.10\%$다. **경계는 어느 종목이 들어가는지**, **가중치는 그 종목이 결과에 얼마나 기여하는지**를 정한다. 특성을 $z_i = 2(\text{rank}_i - 1)/(n-1) - 1$로 순위 변환하면 극단값의 영향은 줄지만 기업 규모 사이의 원래 간격도 잃는다.

4.52 슬라이드 52 · 많은 요인이 재현된다는 결과

Jensen·Kelly·Pedersen은 요인을 더 적은 주제로 묶고 여러 나라의 자료까지 살펴 높은 재현율을 보고한다. 한 주제의 여러 변형은 완전히 독립된 20개 발견이 아니라 같은 잠재 효과에 대한 여러 측정일 수 있다.

한 주제의 지표 20개가 같은 장부비율의 분모만 조금씩 바꾼 것이라면 20번의 독립된 재현으로 세기 어렵다. 계층모형으로 정보를 공유하더라도 같은 데이터 처리 오류가 여러 변형에 퍼질 수 있다. 서로 다른 회계제도와 공개 시점에서 같은 방향이 남는지 확인하고, 요인 **개수**와 경제적 주제 **개수**를 나란히 기록한다. 연구 원문[25]은 이런 비교를 다룬다.

[25] https://doi.org/10.1111/jofi.13249

4.53 슬라이드 53 · 왜 판정이 갈리는가

원수익률 차이를 볼지 CAPM 알파를 볼지, 십분위와 삼분위 중 무엇을 쓸지, 소형주를 어떻게 제한할지, 전체 목록인지 이미 선별한 목록인지가 다르다. 또한 단일 요인마다 고정 임계값을 적용할지 주제별 증거를 함께 사용할지가 다르다.

기관투자자의 '대형 유동주에서 비용 뒤에도 남는가'와 자산가격 연구자의 '작은 종목까지 포함한 평균수익 패턴이 있는가'는 같은 데이터에서도 다른 판정을 낳는다.

비교표를 직접 만든다면 행에는 원수익·CAPM 알파·비용 후 수익을, 열에는 동일가중·시가총액 가중·대형주 표본을 놓을 수 있다. 한 신호가 동일가중 원수익에서만 유의하다면 가격 패턴이 존재할 가능성과 큰 자금의 거래 가능성에 대한 판단을 분리한다. 서로 다른 재현율을 평균내기 전에 **같은 칸**의 결과인지 확인하는 방법이다.

4.54 슬라이드 54 · 한 요인의 베이지안 축소를 유도하기

진짜 알파가 $\alpha \sim N(0, \tau^2)$이고 관측 추정치가 $\hat{\alpha} \mid \alpha \sim N(\alpha, \sigma^2/T)$라고 하자. 정규분포의 사전밀도와 우도를 곱해 α의 제곱항을 완전제곱하면 사후 평균은 정밀도 가중평균이 된다.

$$\begin{aligned} E[\alpha \mid \hat{\alpha}] &= \frac{T/\sigma^2}{1/\tau^2 + T/\sigma^2}\hat{\alpha} \\ &= \frac{\tau^2}{\tau^2 + \sigma^2/T}\hat{\alpha}. \end{aligned}$$

사후 평균의 가중치 $w = \tau^2/(\tau^2 + \sigma^2/T)$는 0과 1 사이에 있다. 예컨대 사전분산이 1이고 추정오차 분산이 3이면 $w = 1/4$이므로 관측 알파 4%는 사후 평균 1%로 줄어든다. 잡음이 큰 단일 요인의 눈에 띄는 성적을 그대로 미래 기대수익으로 쓰지 않는 수학적 이유다.

같은 완전제곱 계산에서 사후분산은 $(1/\tau^2 + T/\sigma^2)^{-1}$이다. 자료가 늘면 정밀도 T/σ^2가 커져 사후 평균의 축소가 줄고 불확실성도 작아진다. 반대로 서로 강하게 상관된 요인 관측을 독립된 T개처럼 세면 정밀도를 과장한다. 식의 T는 단순 행 수가 아니라 독립성 가정 아래의 정보량이라는 점을 함께 읽어야 한다.

4.55 슬라이드 55 · 주제별 정보를 함께 쓰기

요인 i의 참 알파를 해당 주제의 공통효과 $c_{j(i)}$와 요인 고유의 편차 w_i의 합으로 둔다. $c_j \sim N(0, \tau_c^2)$, $w_i \sim N(0, \tau_w^2)$라는 가정은 주제 안의 요인들이 정보를 공유하도록 한다.

계층모형에서는 같은 주제의 다른 요인들이 공통효과 c_j를 추정하는 데 도움을 준다. 가치 관련 요인 여러 개가 비슷한 방향이면 한 요인의 추정치가 흔들려도 주제의 평균 신호는 남을 수 있다. 반대로 연구자가 결과가 좋은 요인만 보고 주제를 만들었다면 '정보 빌리기'가 선택 편향을 퍼뜨릴 수 있다.

$\alpha_i = c_j + w_i$이고 c_j, w_i가 독립이라면 같은 주제의 서로 다른 두 요인 i, k 사이 사전 공분산은 $\mathrm{Cov}(\alpha_i, \alpha_k) = \tau_c^2$다. 각 요인의 분산은 $\tau_c^2 + \tau_w^2$이므로 사전 상관은 $\tau_c^2/(\tau_c^2 + \tau_w^2)$다. 공통분산이 클수록 한 요인의 정보가 같은 주제의 다른 요인에 더 많이 전달된다. 주제 분류가 틀리면 이 전달 자체가 잘못된 축소가 된다.

4.56 슬라이드 56 · 사후 판정과 82%의 해석

사후 평균을 0으로 축소하면 유의한 요인 수가 줄어들 수 있지만, 관련 요인의 정보를 함께 쓰면 사후 불확실성도 낮아진다. 두 효과가 상쇄되면 단순 알파 검정과 계층모형의 재현율이 비슷할 수 있다.

82% 같은 수치를 읽을 때는 '무엇의 82%인가'를 먼저 묻는다. 선택된 요인 목록의 CAPM 알파가 사후 기준을 넘은 비율인지, 원 논문의 모든 후보 중 비용 뒤 수익이 남은 비율인지는 완전히 다르다. 사후축소의 통계적 판정과 실제 투자 가능한 수익의 존재를 한 문장으로 합치지 않는다.

가령 100개 후보 중 50개를 사전에 연구 목록으로 고르고, 그중 41개가 사후 판정 기준을 넘으면 보고된 재현율은 $41/50 = 82\%$다. 처음의 100개를 분모로 쓰면 41%다. 두 계산 모두 산술은 맞지만 다른 질문이다. 후보를 결과를 본 뒤 고른 경우에는 '사전 목록'이라는 조건도 성립하지 않으므로, 선택 시점까지 확인해야 한다.

4.57 슬라이드 57 · 발표 뒤 수익의 감소

전략의 원 논문 표본, 표본 종료와 발표 사이, 발표 이후를 분리하면 감소가 시작한 시점을 볼 수 있다. 공개 전의 하락은 초기 추정의 선택 편향이나 시장 변화와 연결되고, 공개 뒤의 추가 하락은 모방 거래와도 부합한다. 세 구간의 평균에 더해 유동성, 포지션 규모, 위험 노출을 함께 비교한다.

발표 뒤 총수익이 월 0.4%에서 0.2%로 줄고 같은 기간 왕복비용이 0.1%에서 0.25%로 늘었다면 비용 뒤 성과는 0.3%에서 -0.05%로 더 크게 악화된다. 총수익 감소는 정보의 가격 반영이나 원래 표본의 운과 관련될 수 있고, 비용 증가는 경쟁 자금의 주문충격일 수 있다. 두 경로를 따로 측정해야 어떤 메커니즘이 투자자의 순성과를 줄였는지 이해한다.

4.58 슬라이드 58 · 새 요인의 올바른 검정

새 요인을 파마·프렌치 3요인만 통제한 뒤 유의하다고 선언하면 이전에 발견된 많은 요인과 겹치는 정보를 '새로운' 것으로 착각할 수 있다. 전체 기존 요인을 모두 통제하면 변수 수가 너무 많고 상관이 높아 OLS가 불안정해진다.

통제가 적으면 기존 요인의 효과를 새 요인에 잘못 돌릴 수 있고, 모두 넣으면 높은 상관과 작은 표본 때문에 계수가 불안정해진다. 이중 선택은 수익률 및 새 요인과 연결된 통제를 각각 찾아 둘 다 남기는 절차다.

새 요인 D와 기존 요인 Z가 거의 같은 포트폴리오라면 D의 단독 t값이 커도 Z를 넣은 뒤에는 고유한 움직임이 거의 남지 않는다. 이는 새 요인의 아이디어가 틀렸다는 뜻보다 기존 요인과 중복된다는 뜻일 수 있다. 반대로 Z를 무작정 모두 넣으면 남은 변동이 너무 작아 표준오차가 커진다. 경제적 신규성과 통계적 식별 가능성을 나눠 보아야 한다.

4.59 슬라이드 59 · 선택된 통제만 넣을 때의 편향

기존 요인 Z가 평균수익률 y에는 약하게 연결되더라도 새 요인 D와 강하게 상관될 수 있다. Z를 빠뜨리고 y를 D에만 회귀하면 D가 Z의 효과를 대신 가져간다. 이는 미시계량의 **누락변수 편향**과 같은 구조다.

결과 y만 예측하는 라쏘는 이런 Z를 빠뜨릴 수 있으므로, 새 요인 D와 연결된 통제도 따로 찾는다.

단순한 식 $y = \theta D + \beta Z + u$에서 Z를 빼면 D의 계수는 $\theta + \beta\,\mathrm{Cov}(D,Z)/\mathrm{Var}(D)$가 된다. Z의 y 예측력이 작아도 D와 강하게 관련되면 새 요인의 계수에 편향이 남는다. 결과 변수만 예측하는 라쏘로 통제를 고르는 것이 충분하지 않은 이유다.

숫자로 참 새 요인 효과 $\theta = 0$, 통제 효과 $\beta = 0.1$, $\mathrm{Cov}(D,Z)/\mathrm{Var}(D) = 0.5$라면 Z를 빼고 얻은 기울기는 $0 + 0.1(0.5) = 0.05$다. 새 요인에 참 독립 효과가 전혀 없어도 0.05라는 양의 계수가 나온다. 이 식은 $E[u \mid D, Z] = 0$ 등 회귀의 외생성 조건을 둔 단순 예시이며, 시간 변화와 측정오차가 있으면 추가 검토가 필요하다.

4.60 슬라이드 60 · 새 요인 15개의 비교

좁은 3요인 기준에서 유의하던 새 요인 중 일부는 기존 요인 전체를 적절히 통제하면 약해진다. 반대로 기존 요인과 구별되는 수익성 신호 등은 남을 수 있다. "유의하지 않음"은 효과가 정확히 0이라는 증명이 아니라 그 검정의 불확실성이 크다는 의미다.

t값은 계수 추정치를 표준오차로 나눈 값이므로 통제집합을 넓힌 뒤 어느 쪽이 변했는지 따로 기록한다. 계수가 줄었다면 기존 요인과 공유한 정보가 제거되었을 수 있고, 표준오차가 커졌다면 남은 변동에서 효과를 구별하기 어려운 것이다.

t값은 계수 추정치를 표준오차로 나눈 값이다. 예를 들어 계수가 0.04에서 0.02로 줄고 표준오차가 0.01로 같으면 t는 4에서 2로 낮아진다. 반면 계수 0.04가 그대로인데 표준오차만 0.01에서 0.02로 늘어도 같은 변화가 생긴다. 첫 경우는 통제와의 정보 중복, 둘째는 남은 신호를 구별할 자료 부족의 가능성이 크므로 표의 두 숫자를 따로 읽는다.

4.61 슬라이드 61 · 이중 선택의 세 단계

이중 선택(double selection)에서는 평균수익률 벡터를 $\bar{r}$, 기존 요인 노출 행렬을 C_h, 새 요인 노출을 C_g라 하자. 첫 라쏘는 $\bar{r}$를 C_h로 예측해 가격 결정에 중요한 통제 I_1을 고른다. 둘째 라쏘는 C_g를 C_h로 예측해 새 요인과 상관된 통제 I_2를 고른다.

$$
\begin{aligned}
Q_1(b) &= \|\bar{r} - C_h b\|^2 + \lambda_1 \|b\|_1, \\
I_1 &= \mathrm{supp}(\arg\min_b Q_1(b)), \\
Q_2(c) &= \|C_g - C_h c\|^2 + \lambda_2 \|c\|_1, \\
I_2 &= \mathrm{supp}(\arg\min_c Q_2(c)).
\end{aligned}
$$

마지막에는 C_g와 $I_1 \cup I_2$의 통제를 넣고 벌점 없는 회귀로 새 요인의 계수를 추정한다. 둘째 선택이 빠지면 결과에는 약하지만 새 요인과 강하게 연결된 변수가 누락될 수 있다. Feng·Giglio·Xiu[26]는 이중 선택을 요인 검정에 적용한다.

$I_1 \cup I_2$를 쓰면 평균수익률 또는 새 요인과 관련된 통제를 모두 남긴다. 마지막 회귀에서 관심 요인의 계수에 벌점을 주지 않아 추가 축소 편향을 피한다.

최종 회귀를 Frisch–Waugh–Lovell 직관으로 읽을 수 있다. 선택된 기존 요인들로 C_g에서 설명되는 부분을 빼고, 같은 요인들로 $\bar{r}$에서 설명되는 부분을 뺀 뒤 남은 두 잔차의 기울기를 재는 것이다. 이 기울기가 새 요인의 **기존 통제와 구별되는 관련성**이다. 두 번 선택했어도 시간 순서 누출, 선택된 요인의 측정오차, 약한 식별은 자동으로 없어지지 않는다.

[26] https://doi.org/10.1111/jofi.12883

4.62 슬라이드 62 · 다음 문제의 문턱

수백 기업 특성의 어느 조합이 다음 달 수익률을 가장 잘 예측하는가라는 질문이 남는다. 고전적 정렬과 회귀는 개별 신호의 경제적 의미를 보여 주지만 비선형 상호작용이 많으면 하나씩 시험하기 어렵다.

나무 깊이, 변수 조합, 학습 기간을 반복 조정하면 새 요인을 여러 개 시도한 것과 같은 선택 문제가 생긴다. 과거 구간에서 학습하고 다음 구간에서 변수와 벌점을 고른 뒤, 마지막 기간은 **어떤 선택에도 사용하지 않고** 한 번만 채점한다. 결과를 보고 다시 고치면 그 기간은 다음 분석의 검증자료가 된다.

4.63 슬라이드 63 · 요인 논쟁을 예측 문제로 다시 쓰기

수학적으로 목표는 $E[r_{i,t+1} \mid X_{i,t}]$라는 조건부 평균 함수다. $X_{i,t}$에는 기업 규모, 장부비율, 모멘텀, 수익성 등 시점 t에 알려진 특성이 들어간다. 선형 요인모형은 이 함수에 강한 구조 제약을 두는 한 방식이다.

이 조건부 평균은 주어진 정보에서 제곱오차를 최소화한다. 투자 판단에는 위험과 거래비용이 더해지고, 예측력의 경제적 원인을 설명하려면 위험 노출과 기대 오류도 조사해야 한다. 입력 특성의 발표 시점이 맞아야 두 평가 모두 의미가 있다.

왜 조건부 평균이 제곱오차의 최적값인가? 어떤 예측 함수 $g(X)$에 대해 $r - g(X) = [r - E(r \mid X)] + [E(r \mid X) - g(X)]$로 나누어 제곱한다. 첫 항의 조건부 평균이 0이라 교차항의 기대값은 사라지고, 남은 오차는 $E[(r - E(r \mid X))^2] + E[(E(r \mid X) - g(X))^2]$다. 둘째 항은 0 이상이므로 $g(X) = E(r \mid X)$가 최소다. 이 통계적 최적성이 거래비용 뒤 효용의 최적성을 보장하지는 않는다.

4.64 슬라이드 64 · 이미 시도한 정규화의 교훈

앞 장에서는 과거 수익률의 여러 시차와 제곱·세제곱을 넣어 능형회귀와 라쏘를 비교했다. OLS의 표본내 우수성이 검증자료에서는 유지되지 않았고, 계수 축소가 개선을 가져왔다. 이 결과는 새로운 특성 집합에도 같은 평가 규칙이 필요함을 보여 준다.

357개 가격 특징에 재무·텍스트 변수를 더하면 발표 지연, 회계 개정, 산업별 결측도 관리해야 한다. 2025년 12월 말 재무상태표가 2026년 3월에 공개되었다면 1월 예측에 확정 수치를 쓸 수 없다. 가격 특징의 시차와 재무 특징의 **이용 가능 날짜**를 같은 시점표에 놓고, 정정 전후 버전까지 구분한다.

4.65 슬라이드 65 · 횡단면 연구의 결론

새 신호를 평가하는 순서는 **당시 알 수 있던 특성 정의 → 다음 달 상·하위 그룹 차이 측정 → 기존 요인·규모·산업 통제 → 다른 기간·시장 재현 → 양쪽 거래비용과 위기 손실 확인**이다. 어느 단계에서 결과가 달라졌는지 기록하면 예측력, 위험 보상, 가격오류, 우연을 구분하는 데 도움이 된다.

모멘텀·가치·투자·수익성·무형자산·거래마찰은 패턴을 정리하는 범주다. 새 요인의 가치에는 기존 요인과 구별되는 정보, 독립 기간의 안정성, 실행 가능한 순수익이 함께 들어간다.

5 레버리지 ETF와 시장 미시구조

ETF 한 주가 거래소에서 어떤 가격으로 거래되는지부터 시작한다. 설정·환매가 가격을 순자산 가치와 연결하고, 일일 배수 목표는 종가 무렵의 거래와 장기 복리 성과를 함께 만든다. 수식의 금액은 별도 언급이 없으면 수수료·차입비용·추적오차를 제외한 이상화된 값이다. 역사적 수익률은 해당 관측 기간의 결과이며 앞으로의 기대수익률이 아니다.

5.1 슬라이드 01 · 레버리지 ETF를 읽는 세 가지 질문

레버리지 ETF는 기초자산의 **하루 수익률**에 정해진 배수 L을 적용하려는 상장 펀드다. +2배면 지수가 하루 1% 오를 때 펀드 순자산이 약 2% 늘도록 노출을 맞춘다. -2배는 같은 날 약 2% 감소를 목표로 한다. 목표는 하루 단위이므로 여러 날의 성과는 일별 수익률을 곱해 계산한다.

펀드 자산에서 계산한 주당 NAV와 거래소에서 투자자가 지불하는 가격은 서로 다른 경로로 정해진다. 매일 바뀌는 목표 노출은 펀드의 손익과 종가 거래 수요를 만들고, 설정·환매는 시장가격을 NAV에 연결한다. 투자자 손익에는 매매 시점의 괴리와 스프레드도 반영된다.

5.2 슬라이드 02 · 반도체 호황은 왜 출발점인가

2025년부터 2026년 중반까지 AI 투자 확대와 메모리 반도체 기대가 관련 주가를 크게 끌어올렸다. 같은 기간 한국의 두 대형 반도체주뿐 아니라 미국의 Micron도 상승했다. 이는 한 나라의 ETF만으로 가격 움직임을 설명하기 전에 **공통 산업 충격**을 생각해야 함을 뜻한다. 그래프의 기준일 가격을 100으로 맞추면 상승 배율을 비교할 수 있지만, 서로 다른 회사의 시가총액이나 투자수익을 동일시할 수는 없다.

버블 여부에는 주가뿐 아니라 미래 현금흐름과 할인율에 대한 모형이 필요하다. 높은 가격이 비합리적인지, AI 수요 전망이 달라졌는지 가격만으로 가를 수 없다는 것이 결합가설의 요지다. 2026년 5월 단일종목 2배 ETF가 상장된 시점은 이미 상승이 진행된 뒤였다. **동시 발생**과 **원인**은 구별해야 한다.

5.3 슬라이드 03 · 7월 급락과 책임론을 분리해서 보기

2026년 7월에는 KOSPI 200과 반도체주가 크게 떨어졌고, 급반등한 날도 있었다. 레버리지 ETF가 하락일에 노출을 줄이는 주문을 내므로 가격 하락을 증폭했을 가능성이 제기됐다. 하락의 출발점과 ETF 주문이 추가한 몫은 기업 실적 기대, 세계 반도체 수요, 환율, 다른 투자자의 매매를 고려해 추정해야 한다.

특히 SK하이닉스 기초주가 상장 이후 하락한 동안 +2배와 -2배 상품이 모두 큰 손실을 냈다는 점은 방향만으로 장기 성과를 예측할 수 없음을 보여 준다. 지수가 여러 번 반전하면 양쪽 상품에 모두 불리한 복리 경로가 생긴다. 뒤의 이틀 계산에서 정확한 이유를 확인한다.

5.4 슬라이드 04 · 시장 충격에 관한 주장과 검증

국내 반도체주와 해외의 유사 업종이 함께 하락했다면 공통 산업 뉴스가 설명하는 부분을 먼저 살핀다. 이후 국내 장 마감에 특히 집중된 변화가 있었는지 비교하면 ETF 주문의 **추가 효과**를 좁혀 갈 수 있다. 해외 종목은 실적, 환율, 거래시간과 제도가 달라 비교군으로 쓸 때 이 차이를 통제해야 한다.

시장 깊이가 얕으면 같은 주문량의 가격 충격이 커진다. 따라서 정책 질문은 상품을 없애면 변동성이 사라지는가뿐 아니라, 종가 단일가에 얼마나 많은 반대 주문이 공급되는가로 이어진다. 이는 마지막 절의 실증 문제다. 서울경제 시론[27]의 주장은 가설과 정책 견해로 읽고, 인과적 결론과 구별한다.

5.5 슬라이드 05 · 경제학적 질문의 범위

정책 판단의 기준은 같은 반도체 뉴스가 발생했지만 단일종목 ETF는 없었던 **반사실적 시장**이다. 관찰된 종가와 그 시장의 종가 차이가 ETF의 가격 효과다. 상품을 제한한 뒤 투자자가 신용융자나 다른 상품으로 옮긴다면 특정 ETF의 거래량이 줄어도 시장 전체 위험은 달리 움직일 수 있다.

투자자 관점에서는 같은 일일 배수가 수익과 위험을 함께 증폭한다. 강한 추세, 큰 왕복 변동, 조달 비용 중 무엇이 지배적인지에 따라 적절한 보유기간과 상품 선택이 달라진다. 정책의 인과 질문과 투자자의 손익 질문을 나란히 놓는 것이 이 장의 출발점이다.

5.6 슬라이드 06 · 10년 수익률이 단순 배수와 다른 까닭

2016년 9월부터 2026년 9월까지 QQQ의 총수익률은 +565%, TQQQ는 +2,946%, SQQQ는 -99.97%였다. 같은 기간 KODEX 200은 +420%, KODEX 레버리지는 +901%, KODEX 200선물인버스2X는 -99.27%였다. 이는 관측된 특정 10년의 결과다. QQQ의 565%를 단순히 세 배 하면 1,695%인데 TQQQ의 기록은 그보다 크다.

첫날 지수 수익률이 r_1이면 비용 없는 L배 펀드의 순자산 A_0는 $A_1 = A_0(1 + Lr_1)$이 된다. 다음 날에는 **바뀐 순자산** A_1에 그날의 Lr_2를 적용하므로 $A_2 = A_0(1 + Lr_1)(1 + Lr_2)$다. 이를 계속 반복한 기간 수익률은 $\prod_t(1 + Lr_t) - 1$이다. 반면 지수를 끝까지 보유한 뒤 기간 수익률만 L배 하는 계산은 $L[\prod_t(1 + r_t) - 1]$이다. 매일 배수를 다시 맞추면 두 식의 교차항이 달라지므로 강한 추세와 왕복 변동에서 장기 성과가 다르게 나타난다.

5.7 슬라이드 07 · 다섯 단계의 연결

분석에는 서로 다른 세 종류의 관계가 등장한다. **회계 관계**는 NAV와 발행 지분을 연결한다. **복제 관계**는 순자산에 배수 L을 곱해 목표 노출액을 정한다. **시장 균형 관계**는 그 노출을 조정하려는 주문이 다른 투자자의 주문과 만나 어떤 가격을 만드는지 묻는다. 앞의 두 관계는 금액을 계산할 수 있지만 마지막은 시장 자료가 필요하다.

이 순서대로 ETF 가격과 설정·환매, 일일 거래식, 여러 날의 복리, 위험조정 성과, 종가의 가격 충격을 읽는다. 뒤 단계의 결론을 앞 단계의 정의에 얹어야 서로 다른 금액이나 수익률을 섞지 않는다.

5.8 슬라이드 08 · ETF의 두 시장

ETF에는 투자자가 거래소에서 기존 지분을 서로 사고파는 **유통시장**과, 지정된 기관이 운용사와 대량 지분을 설정·환매하는 **발행시장**이 있다. 투자자가 ETF 한 주를 샀다고 그 순간 새 지분이 자동 발행되지는 않는다. 주문장에서 다른 투자자의 기존 한 주를 받았다면 총 발행 지분 수는 변하지 않는다.

[27] https://www.sedaily.com/NewsView/20073850

발행시장에서는 바스켓과 펀드 지분을 큰 단위로 교환한다. 유통시장에서는 그 지분이 주문장 가격으로 계속 옮겨 다닌다. 시장가격이 펀드 자산가치에서 멀어지면 기관이 두 시장을 오가며 거래할 유인이 생긴다. SEC의 ETF 구조 설명[28]은 이 연결을 단계별로 보여 준다.

5.9 슬라이드 09 · NAV와 시장가격의 단위

NAV(net asset value)는 펀드 자산의 시장가치에서 부채를 뺀 순자산이다. 총 NAV를 발행 지분 수로 나누면 **한 주당 NAV**가 된다. 예를 들어 순자산 100억 원, 지분 100만 주라면 한 주당 NAV는 1만 원이다. 이때 거래소 가격이 10,100원이면 100원의 프리미엄이다. 장중에는 보유자산의 실시간 추정치인 iNAV와 사후 확정 NAV가 다를 수 있다.

지수는 운용 목표를 표시하는 기준값이다. NAV 수익률에는 실제 보유자산, 보수와 추적오차가 반영된다. 투자자의 체결수익률에는 여기에 매수·매도 가격의 괴리와 스프레드가 더해진다. 기초자산이 휴장 중인 해외 ETF에서는 장중 iNAV도 새로운 정보를 느리게 반영할 수 있다.

5.10 슬라이드 10 · AP, LP, 설정 단위

AP(authorized participant, 지정참가회사)는 운용사와 정해진 큰 단위인 creation unit으로 ETF 지분을 새로 만들거나 돌려줄 권한이 있다. LP(liquidity provider, 유동성공급자)는 거래소에 매수·매도 호가를 제시한다. 한 증권사가 두 역할을 겸할 수 있지만 **설정·환매 권한**과 **주문장 호가 공급**은 기능이 다르다. 한국거래소의 설정·환매 제도[29]와 LP 제도[30]를 참고할 수 있다.

설정 시 AP는 정해진 자산 바스켓이나 현금을 운용사에 납입하고 ETF 지분을 받는다. 환매는 반대다. 개인은 보통 한 주를 운용사에 가져가 NAV로 교환하지 못하므로 주문장 가격에 노출된다. AP가 거래를 결정할 때는 가격 차이뿐 아니라 세금, 수수료, 헤지 가능성, 가격이 바뀔 위험도 계산한다.

5.11 슬라이드 11 · 주식처럼 거래되는 펀드

일반 개방형 펀드는 가입·환매 신청 뒤 정해진 기준가격을 적용하지만 ETF는 장중 주문장 가격으로 거래한다. 따라서 지정가를 낼 수 있고 즉시 거래할 때는 매수·매도 호가 차이인 **bid-ask spread**를 부담한다.

순자산 증가와 투자자의 체결 수익은 구별해야 한다. 주당 NAV를 N_t, 체결가격을 P_t라 하고 NAV 대비 프리미엄을 $q_t = (P_t - N_t)/N_t$로 정의하면 $P_t = N_t(1+q_t)$다. 따라서 매수가격 대비 매도가격인 총수익 배율 P_1/P_0는 $(N_1/N_0)\{(1+q_1)/(1+q_0)\}$로 분해된다. NAV가 10,000원에서 10,100원으로 올라도 매수 때 1%였던 프리미엄이 매도 때 사라지면 두 체결가격은 모두 10,100원이다. 투자자 수익률은 0%다.

5.12 슬라이드 12 · 누가 누구와 거래하는가

개인 A가 ETF 100주를 사고 B가 기존 지분 100주를 팔면 거래량은 100주, 순설정은 0주다. 반대편이 LP라면 LP의 재고가 100주 줄어든다. LP의 매도 누적량이 설정 단위에 이를 만큼 커지면 AP가 바스켓을 납입해 새 지분을 만들 수 있다. 개인의 100주 매수와 새 지분 발행 사이에는 재고 관리와 AP의 선택이 끼어 있다.

[28] https:// www.investor.gov/ introduction- investing/ general- resources/ news- alerts/ alerts-bulletins/investor-bulletins-24

[29] https://regulation.krx.co.kr/contents/RGL/03/03060106/RGL03060106.jsp

[30] https://regulation.krx.co.kr/contents/RGL/03/03060103/RGL03060103.jsp

거래량은 지분의 소유권 이전을, **순설정액**은 발행 지분 수의 순증가를 측정한다. 현물 바스켓을 납입했다면 AP의 기초자산 매입이 선행될 수 있고, 현금·파생상품 설정에서는 운용사나 계약 상대방의 후속 거래가 중요해진다. 시장 충격을 계산할 때는 이 거래의 주체와 시각을 추적해야 한다.

5.13 슬라이드 13 · 차익거래가 NAV에 가격을 묶는 방식

한 주당 NAV가 10,000원, 시장가격이 10,100원이고 설정 단위가 1만 주라면, 그 지분의 NAV 총액은 1억 원, 시장 매도대금은 1억 100만 원이다. AP는 바스켓을 납입해 새 지분을 만들어 팔 유인이 있다. 공급이 늘면 프리미엄이 줄어드는 방향이다. 반대로 시장가격이 9,900원이면 9,900만 원에 1만 주를 사서 1억 원 가치로 환매할 유인이 생긴다.

차액 100만 원은 **비용 전** 금액이다. 예를 들어 환매된 현물 바스켓의 처분에 20만 원 세금이 붙는다면 80만 원이 남고, 여기서 스프레드·수수료·가격위험을 더 빼야 한다. 괴리가 작으면 거래하지 않는 것이 합리적일 수 있다. 설정은 ETF 공급 확대, 환매는 공급 축소라는 방향으로 가격을 NAV에 연결한다.

양쪽 손익분기점에는 비용 차이가 있다. **환매로 받은 주식을 팔 때만** 0.2% 세금이 붙는 단순한 경우, 주당 NAV 10,000원을 환매한 뒤 받는 순액은 $10{,}000(1-0.002)=9{,}980$원이다. 따라서 ETF를 $P<9{,}980$원에 사야 이익이다. 설정 쪽은 주식을 사서 ETF를 파므로 이 세금만 고려하면 $P>10{,}000$원에서 이익이다. 실제 손익분기 구간은 양쪽의 스프레드·시장충격·위험 부담만큼 넓어진다. LP가 지수선물로 가격위험을 헤지하면 즉각적인 현물 매도세를 피할 수 있지만, 선물과 현물의 가격 차이와 만기 위험을 부담한다.

5.14 슬라이드 14 · KODEX 200 설정 단위 계산

한 설정 단위가 5만 주이고 한 주 NAV가 108,550원이면 교환되는 펀드 가치의 기준은 $50{,}000\times 108{,}550=5{,}427{,}500{,}000$원, 약 54.3억 원이다. 자산 바스켓에 삼성전자 6,969주, SK하이닉스 849주 등이 포함될 수 있다. AP는 이 큰 단위를 기준으로 거래하므로 개인의 한 주 매매와 절차가 다르다.

바스켓 매각에 0.2% 세금이 적용된다는 단순 가정이면 54.3억 원의 0.2%는 약 1,085만 원이다. 괴리 0.2%만을 노리는 거래라면 이 세금만으로 총 차익이 거의 사라질 수 있다. 실제 비용은 바스켓 구성, 현물·현금 납입 방식, 거래소와 상품 규정에 따라 달라진다. **괴리율의 손익분기점**은 비용을 금액으로 환산해 비교해야 한다.

5.15 슬라이드 15 · 한국의 AP와 LP가 연결되는 순서

국내 상품에서 한 증권사가 LP와 AP를 겸할 수 있다. LP가 주문장에서 지분을 팔아 재고가 줄어도 AP의 설정은 별도의 결정이다. 가격 괴리와 바스켓 조달 비용에 따라 새 지분의 발행량과 시점이 정해진다.

실제 현물 수요로 이어지는지 판단하려면 **설정 방식**을 봐야 한다. 현물 설정에서는 AP가 자산 바스켓을 사서 납입하고, 현금 설정에서는 운용사가 새 현금으로 노출을 만들 수 있다. 선물·스왑 ETF라면 상대방의 헤지 주문으로 퍼질 수 있다. 총 노출액과 개별 주식의 체결액을 등치시키면 시장 충격을 과장한다.

5.16 슬라이드 16 · 프리미엄과 디스카운트 읽기

한 주 시장가격을 P, 같은 시점의 주당 추정 NAV를 N이라 하면 괴리율은 $(P-N)/N$이다. $P=10{,}100$, $N=10{,}000$이면 +1% 프리미엄이고, $P=9{,}900$이면 -1% 디스카운트다. 양수일 때 AP의 설정, 음수일 때 환매 유인이 커지는 것이 기본 방향이다.

다만 장중 iNAV와 장 마감 NAV는 산정 시각이 다르고, 유동성이 낮은 기초자산은 평가가격 자체가 느릴 수 있다. '괴리'가 항상 ETF 시장가격의 오류를 뜻하지는 않는다. 특히 해외 ETF의 국내 거래 시간에는 국내 ETF 가격이 해외시장 개장 뒤의 정보를 먼저 반영할 수도 있다. 괴리율을 볼 때는 기준가격의 시각과 사용한 환율을 함께 확인한다.

5.17 슬라이드 17 · LP의 호가와 종가 괴리 의무

국내 상장 ETF의 LP에는 평소 호가 스프레드가 신고한 범위를 벗어날 때 호가를 제시하는 의무와, 종가 괴리를 관리하는 별도 의무가 있다. 자료의 2026년 10월 7일 기준 설명에서는 스프레드 한도 최대 2%, 일정 시간 내 호가 제출, 국내 기초자산 ETF의 종가 괴리 2% 기준을 구분한다. 이 값들은 제도 개정에 따라 달라질 수 있으므로 실제 매매 전에는 한국거래소 LP 규정[31]을 확인해야 한다.

종가 단일가매매에서는 주문을 모아 하나의 가격으로 체결한다. 평소의 스프레드 호가 의무가 적용되지 않는 시간에도 종가 괴리는 관리 대상이다. 다만 종가 괴리 의무는 사후 평가 성격이어서, 특정 종가에 원하는 규모의 매도 주문이 공급되리라는 보장은 없다.

실제 손실률은 괴리율과 분모가 다르다. 예컨대 NAV가 16,141원인 ETF를 종가 30,000원에 샀다면 프리미엄은 $30{,}000/16{,}141-1\approx 85.9\%$다. 다음 날 NAV가 그대로이고 시장가격만 NAV로 돌아가면 매수자의 수익률은 $16{,}141/30{,}000-1\approx -46.2\%$다. 85.9%와 46.2%가 다른 까닭은 전자는 NAV를, 후자는 **지불한 가격**을 분모로 하기 때문이다. 큰 프리미엄을 없애려는 매도 유인이 있더라도 단일가 시간에 충분한 반대 주문이 반드시 들어오지는 않는다.

5.18 슬라이드 18 · 괴리 공시와 투자유의의 단계

국내 기초자산 ETF의 종가 괴리가 일정 수준 이상이면 운용사의 공시가 요구된다. 당시 설명의 기준은 국내 1%, 해외 2%였으며, LP 기준의 두 배를 넘는 큰 괴리가 반복되면 투자유의 지정예고와 지정, 단일가매매 단계로 이어질 수 있었다. **공시**, **지정예고**, **지정**은 서로 다른 조치다. 한 번 적출된 사실을 즉시 투자유의 지정으로 읽으면 과장된다. 최신 기준은 KRX 공시·상장 규정[32]을 확인해야 한다.

이 제도는 괴리 위험을 투자자에게 알리고 LP에 가격 관리 유인을 주지만, 펀드 가격을 언제나 NAV와 일치시키는 보험은 아니다. 급변일에는 기초자산 호가, 단일가 주문 집중, 설정·환매 비용이 함께 달라질 수 있다. 개인은 시장가 주문보다 예상 체결가격과 iNAV를 비교한 지정가 주문을 고려할 수 있다.

5.19 슬라이드 19 · 일일 리밸런싱의 출발점

일반 ETF의 설정·환매를 이해했다면 이제 펀드 **안쪽의 노출 조정**을 볼 차례다. 레버리지 배수 L은 펀드 순자산 1원당 기초지수에 얼마나 노출될지를 뜻한다. 순자산 A와 목표 노출액 E의 관계는 $E=LA$다. $L=2$면 순자산 100에 지수 노출 200, $L=-2$면 지수에 대한 음의 노출 200이다.

[31] https://regulation.krx.co.kr/contents/RGL/03/03060103/RGL03060103.jsp
[32] https://regulation.krx.co.kr/

지수가 움직이는 동안 노출과 순자산은 서로 다른 속도로 변하므로 종가에는 E/A가 목표에서 벗어난다. 펀드는 다음 날도 같은 하루 배수를 목표로 노출을 다시 맞춘다. 이 조정이 '상승 후 매수·하락 후 매도'의 출처다. 실제 노출은 선물·스왑·현물 등으로 구현되어 명목 조정액과 현물 주문액은 같지 않을 수 있다.

5.20 슬라이드 20 · 미국 상품의 배수와 기초자산

TQQQ와 SQQQ는 Nasdaq-100에 각각 +3배와 -3배의 **일일** 노출을 목표로 한다. UPRO는 S&P 500의 +3배, SOXL은 반도체 지수의 +3배, TSLL·NVDL은 개별 주식의 +2배 상품이다. 이름이 비슷해도 기초자산과 배수가 다르면 장기 위험은 크게 달라진다. 특히 단일종목은 분산된 지수보다 한 기업의 실적 발표나 급등락에 더 민감하다.

표의 거래대금은 2026년 9월 말까지 최근 60거래일 평균, 10년 수익률은 2016년 9월부터의 누적 총수익률이라는 서로 다른 통계다. 상장한 지 10년이 안 된 상품의 수익률 칸이 비어 있는 이유도 여기에 있다. 높은 거래대금은 유동성에 도움이 되지만 주문장 깊이와 체결 비용을 완전히 보장하지 않는다.

5.21 슬라이드 21 · 국내 상품과 미국 상품의 비교 단위

국내의 KODEX 레버리지는 KOSPI 200에 +2배, KODEX 200선물인버스2X는 -2배의 일일 노출을 목표로 한다. SK하이닉스 단일종목 상품은 지수 ETF보다 한 종목의 변동성에 직접 노출된다. 같은 '2배'라도 기초자산 변동성이 2배라면 펀드 일간 변동성도 대략 두 배 더 커진다. 여러 날의 복리 손실 가능성은 분산이 커질수록 빠르게 늘어난다.

표의 미국·한국 수익률을 그대로 순위화할 때는 통화, 배당 재투자, 무위험이자율과 표본기간 차이를 확인한다. -2배 ETF의 장기 손실은 장기 상승 추세와 매일의 재설정이 결합한 결과이지, 하루 -2배 목표가 실패했다는 뜻이 아니다. 상품 설명서의 목표 지수와 파생상품 방식까지 봐야 한다.

5.22 슬라이드 22 · 단일종목 ETF와 신규 시장

2026년 5월 삼성전자와 SK하이닉스를 기초로 한 단일종목 레버리지·인버스 ETF가 상장됐다. 각 종목에 +2배 상품 여러 종과 -2배 상품이 출시되며, 개인의 +2배 상품 순매수가 6월 중순까지 크게 늘었다. 이는 기존 지수형 ETF와 달리 **한 종목의 종가 유동성**에 리밸런싱 수요가 집중될 수 있다는 점에서 중요하다. 금융위원회의 단일종목 상품 투자 유의 안내[33]처럼 배수와 단일종목 위험을 함께 살펴야 한다.

투자자 교육, 모의거래, 기본예탁금 같은 국내 요건은 시행 시점과 투자자 유형에 따라 달라진다. 손실 위험을 줄이려는 제도와 별개로, 경제학적 질문은 새 상품의 종가 거래가 기존 종목의 변동성을 얼마나 더 키웠는가이다.

질문: 개인 순매수 8.2조 원이 곧 펀드 순설정 8.2조 원인가요? 아닙니다. 개인이 기존 보유자에게서 산 지분도 순매수에 포함됩니다. 펀드로 들어간 신규 자금은 설정·환매 자료로 따로 확인해야 합니다.

[33] `https://www.fsc.go.kr/`

5.23 슬라이드 23 · +2배와 -2배가 같은 방향으로 거래하는 이유

순자산 100, 지수 상승률 10%를 생각하자. +2배 펀드는 시작 노출 200이 220이 되고 순자산은 120이다. 새 목표 노출은 $2 \times 120 = 240$이므로 **20 매수**가 필요하다. 현물로 복제하고 차입금 100을 고정해 두었다면, 보유자산 200이 220으로 오른 뒤에도 자기자본은 $220 - 100 = 120$이다. 따라서 220과 120을 혼동하지 않아야 추가 매수 20이 나온다. -2배 펀드는 시작 노출 -200이 가격 상승 뒤 -220이 되고 손실로 순자산은 80이다. 새 목표는 $-2 \times 80 = -160$이므로 $-160 - (-220) = +60$, 즉 역방향 포지션을 60 줄이는 **매수 방향**이다.

하락일에는 두 상품 모두 반대 방향이다. -2배 펀드가 상승일에 산다는 말은 상승에 베팅한다는 뜻이 아니다. 손실로 줄어든 자기자본에 비해 너무 커진 음의 노출을 되사는 것이다. 펀드가 실제로 선물을 쓴다면 '매수'는 선물 포지션 조정이나 상대방 헤지로 구현될 수 있다.

5.24 슬라이드 24 · 거래식 L(L-1)Ar의 유도

장 시작 순자산을 A, 지수 수익률을 r, 목표 배수를 L이라 하자. 부호를 포함한 지수 노출액은 처음에 LA다. 예를 들어 $L = -2$면 지수 상승에 손실이 나는 노출 $-2A$를 뜻한다. 지수가 r만큼 움직이면 **기존 포지션의** 노출액은 $LA(1 + r)$가 되고, 그 포지션에서 발생한 손익은 LAr이다. 따라서 새 순자산은 $A(1 + Lr)$다. 다음 날에도 새 순자산의 L배를 유지하려면 목표 노출액은 $LA(1 + Lr)$여야 한다. 필요한 순거래는 목표에서 거래 전 노출을 뺀 값이다.

$$\begin{aligned} \Delta E &= LA(1 + Lr) - LA(1 + r) \\ &= L(L - 1)Ar. \end{aligned}$$

$A = 100, r = 10\%$에서 -1배는 기존 노출 -100이 -110으로, 순자산은 90으로 변해 목표 -90을 맞추기 위해 20을 되산다. +2배의 20 매수와 비교하면, 배수 부호가 달라도 $L(L - 1) > 0$이면 같은 방향의 조정이 필요함을 알 수 있다. 이 식은 비용·유입이 없는 **명목 노출**의 조정식이다.

5.25 슬라이드 25 · 지정가 주문과 역방향 자금 흐름

현재가 아래에 놓인 개인의 지정가 **매수** 주문은 가격이 떨어질 때 체결되고, 위에 놓인 **매도** 주문은 상승할 때 체결된다. 따라서 주문을 미리 깔아 둔 투자자는 거래 체결만 보면 하락 뒤 사거나 상승 뒤 파는 역방향 투자자가 될 수 있다. 기다리며 스프레드를 얻을 가능성이 있는 대신 가격이 계속 불리하게 움직이는 위험을 감수한다.

지수가 급락할 때 기초자산 NAV도 내려간다. ETF 아래에 대기하던 매수 지정가가 체결되어 ETF 가격의 하락폭이 NAV보다 작다면 일시적 프리미엄이 생긴다. LP·AP가 ETF를 팔고 새 지분을 설정할 유인이 생기지만, 비용이 크거나 가격이 곧 움직일 위험이 있으면 괴리가 남을 수 있다. 반대로 상승 중 개인의 대기 매도가 체결되면 디스카운트와 환매 유인이 생길 수 있다. **기존 지분 거래 → 가격 괴리 → AP 결정 → 발행 지분 변화**는 조건부 경로이며, 실증적으로 순설정 F가 지수 수익률 r과 반대로 움직였는지를 따로 확인해야 한다.

질문: 지정가로 샀으니 언제나 시장에 유동성을 공급한 건가요? 주문장에 기다리던 지정가 주문이 시장가 주문과 체결됐다면 그렇습니다. 즉시 체결되는 공격적 지정가 주문은 유동성을 소비할 수도 있습니다.

5.26 슬라이드 26 · 순설정 F를 포함한 거래식

장 마감에 현금 기준 순설정액 F가 들어오고, 그 현금이 아직 지수에 투자되지 않았다고 하자. 순자산은 $A(1+Lr)+F$가 되고 목표 노출은 $L[A(1+Lr)+F]$다. 기존 포지션 $LA(1+r)$를 빼면 다음과 같다.

$$\Delta E = L(L-1)Ar + LF.$$

지수가 10% 오른 +2배 펀드는 기본 리밸런싱 20에 순설정 10의 2배인 20이 더해져 40 매수한다. 같은 조건의 -1배는 기본 20 매수에 $-1\times 10=-10$이 더해져 10 매수한다. 반대로 +2배가 10% 하락하면 기본 -20인데 순설정 10의 +20이 이를 상쇄한다. 이는 개인의 ETF 매수 체결액이 10이라는 가정과 다르다. $F=10$은 **실제로 발행된 지분의 순증가분을 NAV로 평가한 금액**이다. 현물 바스켓을 AP가 납입하면 펀드 내부의 현금 주문액은 달라지지만, AP의 바스켓 매수까지 합친 경제적 노출 변화는 같은 방향이다.

5.27 슬라이드 27 · 한 식에서 두 효과가 나온다

일일 재설정 거래 $L(L-1)Ar$는 누적 성과에 양면적이다. 첫날 상승 뒤 추가 매수하면 다음 날도 상승할 때 이익이 커진다. 첫날 하락 뒤 매도하면 다음 날도 하락할 때 손실을 줄인다. 같은 방향이 이어질 때 고정된 L배 매수후보유보다 유리해지는 효과를 여기서는 **convexity**라고 부른다.

반면 다음 날 방향이 바뀌면 상승 뒤 산 물량이 손실을 보거나 하락 뒤 판 물량이 반등을 놓친다. 이것이 흔히 **volatility decay**로 불리는 경로 효과다. 추세에 따른 이익과 반전에 따른 손실은 같은 일일 조정 거래에서 나온다. 여러 날의 성과는 전체 수익률뿐 아니라 일간 수익률의 순서와 크기에 달려 있다.

5.28 슬라이드 28 · '음의 복리'를 정확히 해석하기

원주가 제자리로 돌아왔는데 레버리지 ETF가 손실을 보는 사례는 실제로 가능하다. 복리 성과의 부호는 경로에 달려 있다. 매일 같은 배수로 다시 맞추는 과정에서 변동성이 큰 반전 경로는 손실을 만들고, 지속적인 상승 추세는 고정 배수보다 큰 이익을 만들 수 있다.

SK하이닉스 단일종목 상품의 2026년 5월 말~9월 말 기록에서는 기초주가 하락과 큰 반전이 함께 있었다. +2배와 -2배가 모두 60% 넘게 손실을 본 사실은 변동성 효과의 크기를 묻는 출발점이다. 상품의 거래가격과 NAV의 괴리, 운용비용도 총손익에 들어가므로 기계적 복리만으로 실제 손익을 모두 설명할 수는 없다.

5.29 슬라이드 29 · 이틀 경로를 직접 곱해 보기

지수가 첫날 +10%, 다음 날 +10%면 누적 수익률은 $(1.1)^2-1=21\%$다. +2배 펀드는 $(1.2)^2-1=44\%$로 지수 누적의 단순 두 배 42%보다 2%포인트 높다. 반대로 +10%, -10%면 지수는 $1.1\times 0.9-1=-1\%$, +2배는 $1.2\times 0.8-1=-4\%$로 단순 두 배 -2%보다 낮다.

같은 반전 경로에서 +3배는 $1.3\times 0.7-1=-9\%$, -2배는 $0.8\times 1.2-1=-4\%$다. 지수가 -1%인데 -2배의 단순 배수는 +2%라는 점과 비교하면 인버스도 6%포인트 불리하다. 반대로 -10%, -10%라면 -2배 펀드는 +44%로 단순 배수 +38%보다 유리하다. 부호와 경로를 직접 곱해 보아야 한다.

5.30 슬라이드 30 · 일일 재설정과 매수후보유의 정확한 차이

초기자산 A에 지수 노출 LA를 한 번 만든 뒤 거래하지 않는 **고정 노출 매수후보유**의 이틀 최종 가치는 $A\{1+L[(1+r_1)(1+r_2)-1]\}$다. 지수의 이틀 수익률에 정확히 L을 곱한다. 반면 매일 배수를 재설정하는 펀드는 $A(1+Lr_1)(1+Lr_2)$다. 각각 전개하면 Lr_1+Lr_2까지는 같고 교차항만 다르다.

$$\begin{aligned} V_{\text{daily}} &= A(1+Lr_1)(1+Lr_2), \\ V_{\text{hold}} &= A[1+L(r_1+r_2+r_1r_2)], \\ V_{\text{daily}} - V_{\text{hold}} &= L(L-1)Ar_1r_2. \end{aligned}$$

첫날 필요한 추가 거래가 $L(L-1)Ar_1$였으므로 차액은 바로 **첫날 추가 포지션이 둘째 날 번 손익**이다. 이 해석이 수식과 경제적 직관을 연결한다. 고정 노출 전략도 차입비용·마진 제약이 있으면 실제로 구현하기 어렵다는 점은 별개다.

5.31 슬라이드 31 · 거래액 20이 만드는 +2 또는 -2

$A=100$, $L=2$, 첫날 $r_1=10\%$이면 종가에 노출 20을 추가한다. 둘째 날 수익률이 $+10\%$이면 이 거래가 2를 벌고, -10%이면 2를 잃는다. 같은 첫날의 조정도 다음 날 방향에 따라 이익 또는 손실이 된다.

여기서 $20\times r_2$는 **펀드와 고정 노출 전략의 손익 차이**다. 기초주가에 미치는 효과를 계산하려면 20의 명목 노출 가운데 실제 종가 현물 주문이 얼마였고 이를 받아 준 반대 주문이 얼마나 있었는지 알아야 한다.

5.32 슬라이드 32 · 왕복 변동의 정확한 손실

지수가 첫날 x만큼 오르고 다음 날 같은 **수익률 크기** x만큼 떨어지면 지수 총수익률은 $(1+x)(1-x)-1=-x^2$다. 일일 L배 펀드의 총수익률은 $(1+Lx)(1-Lx)-1=-L^2x^2$다. 지수 총수익률의 단순 L배와의 차이는 $-L(L-1)x^2$다. 같은 왕복 폭에서 배수를 두 배로 높이면 펀드의 경로 손실은 네 배가 된다.

여기서 +10% 뒤 -10%는 **가격이 원래 수준으로 돌아오는 경로가 아니다**. 정말 원점으로 돌아가려면 둘째 날 수익률은 $-x/(1+x)$여야 한다. 예를 들어 +10% 뒤 약 -9.09%다. 어느 경로를 말하는지에 따라 지수 손익과 펀드 손익 숫자가 달라진다. 상품은 하루에 $1+Lr_t>0$이 유지된다는 범위에서 이 단순식을 따른다.

5.33 슬라이드 33 · T일 곱을 2차 항까지 전개

지수의 T일 누적수익률은 $R_I=\prod_{t=1}^{T}(1+r_t)-1$이고 펀드는 $R_L=\prod_{t=1}^{T}(1+Lr_t)-1$이다. 작은 일간 수익률을 가정하고 두 개가 곱해진 항까지만 남기면 지수에는 $\sum_t r_t+\sum_{i<j} r_ir_j$, 펀드에는 $L\sum_t r_t+L^2\sum_{i<j} r_ir_j$가 남는다. 세 개 이상이 곱해진 항은 버린 **근사**다.

$$R_L - LR_I \simeq L(L-1)\sum_{i<j} r_ir_j.$$

1차 항은 고정 배수 전략에도 동일하게 들어가 상쇄된다. 남는 날짜 쌍의 항은 앞선 날의 조정이 뒤의 날 수익률을 얻는다는 해석을 여러 날로 확장한 것이다. 큰 일간 변동이나 긴 기간에는

생략된 고차항이 커질 수 있으므로 정확한 손익은 원래의 곱으로 계산해야 한다.

5.34 슬라이드 34 · 볼록성과 변동성 항의 분해

항등식 $(\sum_t r_t)^2 = \sum_t r_t^2 + 2\sum_{i<j} r_i r_j$를 앞의 식에 대입하면 두 효과가 분리된다. 2차 근사에서는 $\sum_t r_t$ 대신 지수 누적수익률 R_I를 넣어도 2차 정확도는 유지된다. 두 값의 차이가 이미 2차 항이고, 다시 제곱하면 차이가 3차 이상이기 때문이다.

$$R_L - LR_I \simeq \frac{L(L-1)}{2} R_I^2 - \frac{L(L-1)}{2} \sum_{t=1}^{T} r_t^2.$$

첫 항은 시작과 끝의 큰 움직임이 만드는 **convexity**, 둘째 항은 경로 중 매일의 제곱수익률이 만드는 **volatility decay**로 읽는다. $L = 2$면 계수는 1, $L = 3$ 또는 $L = -2$면 3이다. 이 식은 일간 수익률이 작을 때의 2차 근사다.

끝점만을 넣은 $+2$배의 볼록성 **기준값**은 정확히 계산할 수 있다. 지수의 전체 기간 수익률을 R이라 할 때 $(1+R)^2 - 1 = 2R + R^2$이므로, 단순히 전체 수익률을 두 배 한 $2R$과의 차이는 정확히 R^2다. $R = +20\%$이든 -20%이든 기준값은 초기자산의 4%포인트, $|R| = 40\%$면 16%포인트다. 다만 $(1+R)^2 - 1$은 **끝점으로 만든 비교 함수**이지 실제 매일 2배로 재설정한 ETF 수익률 $\prod_t (1 + 2r_t) - 1$이 아니다. 둘의 차이는 실제 일별 경로에 달려 있으며, 앞 식의 변동성 항은 그 차이를 작은 수익률에서 근사한다.

5.35 슬라이드 35 · 끝점과 경로를 따로 보기

그림에서는 끝점 R_I가 같은 경로끼리 비교한다. 그중 일간 등락이 큰 경로는 $\sum r_t^2$가 커져 조정성과가 낮다. 반대로 일간 등락의 크기가 비슷하다면 멀리 이동한 끝점에서 R_I^2의 이익이 크다. 두 축을 따로 고정해야 추세와 변동성의 효과를 읽을 수 있다.

표의 2배 펀드 예에서 지수가 연말에 제자리인 행은 볼록성 0이고 변동성 20%, 40%, 60%에 따라 손실이 커진다. 지수가 +40%나 -40%인 행은 양의 볼록성 항이 있다. 다만 표의 수치는 특정 시뮬레이션과 분해 방식으로 만든 결과이며 위의 2차 근사 수치와 일대일로 같지 않다. 수익률이 매우 클 때는 로그 기반 정확 분해나 원래의 일일 곱을 사용해야 한다.

5.36 슬라이드 36 · SK하이닉스 사례를 분해하는 방법

2026년 5월 27일부터 9월 30일까지 기초주가 -20.8%라면 고정 +2배는 -41.6%, 고정 -2배는 +41.6%가 기준이다. 제시된 기간별 분해에서는 +2배에 볼록성 +4.3%포인트, 변동성 효과 -21.4%포인트가 더해져 이상적 일일 펀드 약 -58.7%가 되고, 비용·추적 차이 -2.4%포인트 뒤 실제 약 -61.1%다. -2배는 +17.9, -119.3, -4.0%포인트를 차례로 합쳐 약 -63.8%다.

이 숫자는 **특정 역사적 일별 경로의 분해**다. 경로가 바뀌면 -119.3%포인트라는 변동성 기여도도 바뀐다. 큰 변동 구간에서는 단순 2차 공식보다 정확한 일별 가치 곱과 선택한 분해 정의를 써야 한다. 두 방향이 모두 손실이었다는 사실만으로 기초주가 하락과 큰 왕복 변동 중 무엇의 기여가 큰지 알 수 없어서 이 분해가 필요하다.

질문: 인버스의 변동성 효과가 -100%포인트보다 작을 수 있나요? 분해 항은 서로 더하는 기여도이므로 한 항이 -100%포인트를 넘어도 다른 양의 항이 상쇄할 수 있습니다. 펀드의 최종 수익률 자체와 혼동하면 안 됩니다.

5.37 슬라이드 37 · 수익률만으로 위험을 평가할 수 없는 이유

레버리지는 평균 수익률뿐 아니라 손실의 폭과 보유기간별 결과의 분포를 키운다. 10년 누적수익률이 높아도 중간 손실을 견디지 못해 매도하면 그 성과를 얻지 못한다. 다음 절은 수익률 평균에서 무위험수익률을 뺀 **초과수익**을 변동성으로 나눈 샤프비율, 최악 낙폭, 장기 성장률을 구분한다.

위험 지표마다 답하는 질문이 다르다. 일간 샤프는 하루의 위험 한 단위당 보상을, 1년 보유 샤프는 시작일을 바꾸어 1년씩 투자했을 때의 분포를 요약한다. 최악 낙폭은 버텨야 할 중간 손실을, 로그 성장률은 여러 기간 복리 후의 전형적인 자산 증가 속도를 보여 준다.

5.38 슬라이드 38 · 같은 상품의 일간과 1년 샤프비율

샤프비율은 같은 기간의 **평균 초과수익률 ÷ 수익률 표준편차**다. 2016~2026년 자료에서 QQQ와 TQQQ의 누적 총수익률은 각각 +565%, +2,946%였다. 일간 수익률을 연율화한 샤프비율은 0.85와 0.82로 비슷하지만, 겹치는 252거래일 보유 수익률의 평균을 표준편차로 나눈 값은 0.99와 0.78이다. SPY·UPRO, SOXX·SOXL, KODEX 200·2배 상품에서도 그 표본의 1년 보유 기준은 레버리지 쪽이 낮았다.

일간 샤프를 연율화할 때는 하루 평균/표준편차에 독립 일별 수익률 가정의 $\sqrt{252}$를 곱한다. 1년 보유 샤프는 각 시작일에서 252일 보유한 **복리수익률**의 분포를 쓴다. 일별 표준편차의 연율화 값 66.8%와 1년 보유 수익률의 시작일별 표준편차 69.3%는 다른 분모다. 겹치는 1년 구간은 독립 관측치가 아니므로 추정오차에도 주의해야 한다. 한국 표의 별표는 미국 무위험수익률을 뺀 값이 아닌 원수익률 기준이다.

5.39 슬라이드 39 · 샤프비율의 분자와 분모

샤프비율의 분자는 위험자산의 기대수익률 $E[R]$에서 같은 통화·기간의 무위험수익률 r_f를 뺀 위험 보상이다. 분모 σ_R는 그 수익률의 표준편차로, 보상을 얻으면서 감수한 흔들림을 나타낸다. 따라서 $S = (E[R] - r_f)/\sigma_R$다. 연평균 수익률 21.6%, 같은 기간 단기국채 2.4%, 연율화 변동성 22.6%이면 샤프는 $(21.6 - 2.4)/22.6 \simeq 0.85$다. 분자와 분모는 같은 기간 단위로 계산해야 한다.

분모의 표준편차는 손실만이 아니라 예상보다 높은 수익도 위험으로 센다. 수익률 분포가 비대칭이거나 큰 손실 가능성이 있으면 샤프 하나로 충분하지 않다. 또한 과거 평균은 미래 기대수익률의 불확실한 추정치다. 샤프비율은 **동일 조건의 효율성 비교**에는 유용하지만, 투자자에게 필요한 절대수익이나 최악 낙폭을 대체하지 않는다.

5.40 슬라이드 40 · 하루에는 왜 샤프가 같나

기초자산 하루 수익률을 r, 같은 하루의 무위험수익률을 r_f라 하자. 자기자본 한 단위로 기초자산 L단위를 보유하고 초과분 $L-1$을 r_f로 조달한다면 레버리지 포트폴리오 수익률은 $r_L = Lr - (L-1)r_f$다. 양변에서 r_f를 빼면 $r_L - r_f = L(r - r_f)$다. 따라서 $L > 0$인 경우 초과수익률의 평균은 L배, 표준편차도 L배다.

$$S_L = \frac{LE[r - r_f]}{L\,\mathrm{sd}(r - r_f)} = S_1 \qquad (L > 0).$$

이 등식은 **한 기간, 동일한 무위험금리, 비용·추적오차 없음**을 가정한다. $L < 0$이면 표준편차는 $|L|$배여서 $S_L = \mathrm{sgn}(L) S_1$이다. 예컨대 기초자산의 초과수익률이 평균적으로 양수라면 비용 없는 -2배 포지션의 하루 샤프는 기초자산과 크기가 같고 부호는 반대다. 실제 상품은 조달 비용과 괴리 때문에 이 값에서 벗어난다.

5.41 슬라이드 41 · 보유기간을 늘리면 분포가 바뀐다

한 날의 초과수익률을 정확히 세 배 하는 것과 252일 동안 매일 세 배를 목표로 투자하는 것은 다르다. 후자의 총수익률은 $G_T - 1 = \prod_{t=1}^{T}(1 + r_{L,t}) - 1$로, 날마다 이전 성과가 다음 날의 투자금이 된다. 따라서 평균과 표준편차가 단순히 일간 값의 T배나 $\sqrt{T}$배로만 커지지 않는다.

독립적인 일별 수익률을 가정한 시뮬레이션에서는 배수가 커질수록 1년 보유 샤프가 낮아진다. 복리로 계산한 보유 성과의 표준편차가 평균에 비해 빠르게 확대된 결과다. 추세의 지속성, 평균 수익률, 비용, 재조정 주기가 달라지면 보유기간 샤프의 순서도 바뀔 수 있다.

5.42 슬라이드 42 · T일 복리수익률의 평균과 분산 유도

하루 수익률을 더하지 않고 총수익 배율을 곱해야 하므로 $X_t = 1 + r_{L,t}$, $G_T = \prod_{t=1}^{T} X_t$라 두자. 일별 지수 수익률이 서로 독립이고 평균 μ, 분산 σ^2이면 비용 없는 하루 펀드 수익률의 평균은 $m_L = r_f + L(\mu - r_f)$, 분산은 $L^2\sigma^2$다. 분산의 정의 $\mathrm{Var}(X) = E[X^2] - E[X]^2$를 옮겨 쓰면 $E[X_t^2] = (1 + m_L)^2 + L^2\sigma^2$다. 독립성 때문에 $E[\prod_t X_t] = \prod_t E[X_t]$이고, 제곱한 배율에도 같은 성질을 적용한다.

$$\begin{aligned} E[G_T] &= (1 + m_L)^T, \\ \mathrm{Var}(G_T) &= \left[(1 + m_L)^2 + L^2\sigma^2\right]^T \\ &\quad - (1 + m_L)^{2T}. \end{aligned}$$

분산은 $E[G_T^2] - E[G_T]^2$이므로 두 항의 차이가 위 식이다. 변동성이 커지면 평균은 그대로여도 두 번째 모멘트와 분산은 커진다. 독립·동분포 가정하의 **정확한 모멘트 식**이며, 실제 수익률의 자기상관이나 변동성 변화가 있으면 그대로 적용할 수 없다.

5.43 슬라이드 43 · 샤프가 투자 선택의 전부인가

샤프비율로 자산을 고른 뒤 차입으로 목표 수익률을 맞추는 선택은, 누구나 무위험금리로 필요한 만큼 빌릴 수 있을 때 성립한다. 차입금리와 한도, 담보 유지 조건이 달라지면 같은 위험 수준에 도달하는 비용도 자산마다 달라진다. 다음 두 슬라이드는 이 제약을 자본시장선에 표시한다.

5.44 슬라이드 44 · 자본시장선 CML의 기울기

무위험자산과 위험 포트폴리오 A를 섞을 때 A의 비중을 w라 하면 기대수익률은 $r_f + w(E[R_A] - r_f)$, 표준편차는 $w\sigma_A$다($w \geq 0$). 따라서 위험을 가로축, 기대수익률을 세로축에 놓은 직선의 기울기는 $(E[R_A] - r_f)/\sigma_A$, 바로 샤프비율이다. $w > 1$은 무위험금리로 차입해 A를 더 사는 구간이다.

예시에서 채권 포트폴리오 A의 기대수익률 7%, 변동성 6%, 무위험금리 2.4%면 샤프는 약 0.77이다. A를 두 배 보유하면 위험 12%, 기대수익률 $2(7) - 1(2.4) = 11.6\%$다. 주식 B의 샤프가 더 낮다면 동일 위험에서 A의 CML이 위에 놓인다. 이 직선이 무한히 연장되는 그림에는 **무한 차입 가능**이라는 강한 가정이 들어 있다.

5.45 슬라이드 45 · 현실의 차입금리가 선을 꺾는다

자기자본보다 많이 사려면 차입금리 r_b를 내야 한다. $w > 1$ 구간의 기대수익률은 $wE[R_A] - (w-1)r_b$이고, 추가 위험 한 단위당 기대 보상은 $(E[R_A] - r_b)/\sigma_A$로 낮아진다. 차입 한도까지 있으면 더 오른쪽으로 갈 수 없다. 보증금률 50%라면 단순한 전액 담보 모형에서 자기자본의 최대 2배 보유가 예시가 된다.

차입금리 때문에 **무차입 샤프가 가장 높은 자산**이 모든 목표 위험에서 최선은 아닐 수 있다. 같은 무위험금리 2%에서 A의 기대수익률·변동성이 8%·8%, B가 11%·15%라면 A의 샤프 $6/8 = 0.75$가 B의 $9/15 = 0.60$보다 높다. 그러나 위험 15%를 원해 A를 $15/8 = 1.875$배 보유하고 추가분을 7%에 빌리면 기대수익률은 $1.875(8\%) - 0.875(7\%) \approx 8.88\%$다. B를 그냥 보유하면 위험 15%에서 기대수익률 11%다. 차입선의 기울기가 낮아지면 목표 위험에 따라 유리한 자산이 바뀐다.

자료에 제시된 미국 단기국채 평균 2.4%와 2026년 5월 국내 신용융자 금리 9%대는 **통화와 관측기간이 서로 다르다**. 이를 동일 시장의 단일 무위험금리와 신용금리로 직접 빼면 부정확하다. 뒤의 +6.6%포인트는 차입 가산비용을 보여 주는 예시 입력값으로 읽는다. 실제 비교에서는 같은 통화·기간의 조달금리, 세금과 한도를 맞춰야 한다.

5.46 슬라이드 46 · 자산군 샤프비율의 표본 의존성

제시된 2016~2026년 표본에서는 QQQ·SPY의 샤프가 채권 ETF보다 높다. 그러나 2022년 금리 급등은 채권 가격에 큰 손실을 줬고, 더 긴 역사적 표본에서는 저베타 자산의 위험조정 성과가 다르게 나타날 수 있다. **표본기간이 다른 샤프비율**을 하나의 영구적 자산 순위로 읽으면 안 된다. 미국 채권·주식과 한국 ETF의 원수익률 기준도 동일하게 비교할 수 없다.

샤프는 과거 수익률의 평균과 표준편차를 추정한 결과라 극단적인 한 해에 민감하다. 또 낮은 변동성의 자산은 작은 초과수익 추정 오차에도 비율이 크게 변한다. 투자 전에는 어느 무위험금리를 뺐고, 총수익률에 배당·분배금이 포함됐는지, 기간이 얼마나 긴지를 확인한다.

5.47 슬라이드 47 · 내재 레버리지 상품과 개인 차입의 비교

QQQ를 자기자본 한 단위당 세 단위 보유하려면 두 단위를 빌려야 한다. 연간 차입 가산금리가 6.6%포인트라면 자기자본 대비 추가 비용은 $2 \times 6.6 = 13.2\%$포인트다. 그래서 같은 3배 노출이라도 직접 신용융자의 기대수익률 선은 이론적 무위험금리 차입선보다 낮아진다. 상품 안에서 조달하는 TQQQ가 그 개인 차입선 위에 놓일 수 있다는 것이 그림의 논리다.

TQQQ의 NAV에는 보수와 내부 금융비용이 반영된다. 그래프의 2016~2026년 실현 연평균은 당시 상승 경로를 포함한 **사후 숫자**다. 직접 차입과 상품 내부 차입을 비교하려면 같은 기초자산과 보유기간을 놓고 금리, 보수, 세금, 거래비용, 담보위험을 원화 손익으로 환산해야 한다.

5.48 슬라이드 48 · 투자자 계좌에서 사라지는 마진콜

개인이 빌려서 기초자산 세 배를 **고정 노출**로 보유하면 자산 가치가 3분의 1 하락할 때 자기자본이 소진된다. 대출자는 그 전에 증거금을 요구하거나 반대매매할 수 있다. 이미 돈을 모두 내

고 산 레버리지 ETF 지분은 투자자 계좌에 별도의 신용융자가 없으므로 그 지분 보유만으로 개인에게 마진콜이 오지는 않는다. 인버스 ETF도 직접 공매도의 주식 차입·상환 요구를 투자자 계좌 밖으로 옮긴다.

대신 손실은 ETF 지분의 NAV 하락에 집중된다. 펀드 내부의 레버리지와 조달 비용이 반영되므로 2022년처럼 Nasdaq-100이 크게 하락할 때 TQQQ의 낙폭은 더 컸다. 이후 회복까지 자금을 묶어 둘 수 있는지와 중간 생활비 지출 가능성을 함께 계산해야 한다.

5.49 슬라이드 49 · 3배 노출의 두 가격표

같은 자기자본 100으로 첫날 QQQ를 300 보유하고 200을 빌리는 전략과, 일일 +3배 ETF 100을 사는 전략을 비교하자. 비용이 없고 QQQ가 첫날 +10%, 둘째 날 -10%라면 직접 차입의 마지막 자산은 $300(1.1)(0.9) = 297$, 부채는 200이므로 자기자본은 97이다. ETF의 가치는 $100(1.3)(0.7) = 91$이다. 시작 노출은 같지만 첫날 뒤 직접 차입의 노출배수는 $330/130 \approx 2.54$로 내려가고, ETF는 다음 날 목표를 위해 다시 3배로 맞춘다.

97과 91의 차이는 이 예에서 **재설정 규칙의 경로 효과**다. 직접 차입이자는 부채 200에, ETF 내부 금융비용과 보수는 NAV에 반영된다. 투자자의 실제 ETF 수익률에는 매수·매도 시점의 프리미엄과 스프레드도 들어간다. 같은 기간의 일별 가격 경로를 먼저 맞추고 비용을 각각 차감해야 두 전략의 순성과를 비교할 수 있다. 상품의 현행 비용은 운용사 공시[34]에서 확인한다.

5.50 슬라이드 50 · 차입 제약과 betting against beta

차입이 막힌 투자자가 높은 기대수익을 원하면 자기자본만으로 살 수 있는 고베타 자산을 선택할 수 있다. 이런 수요가 고베타 자산 가격을 올리면 향후 기대수익률이 상대적으로 낮아져 증권시장선이 평평해질 수 있다는 것이 betting against beta 이론[35]의 직관이다. 실제 가격에는 다른 기대와 제약도 작용하므로 이 메커니즘의 크기는 자료로 추정해야 한다.

내재 레버리지 ETF는 개인 차입 제약을 일부 우회한다. 원하는 노출을 얻는 이점과 1년 보유 샤프의 하락, 손실 한도를 함께 놓고 선택한다. **최적 포트폴리오는 투자자의 제약과 효용**에 달려 있다.

5.51 슬라이드 51 · 강한 추세가 TQQQ에 유리했던 기간

2016~2026년 Nasdaq-100은 높은 초과수익률과 상대적으로 낮은 변동성을 동시에 보였다. 그러면 매일 3배를 유지하는 전략에서 상승 추세의 복리 이익이 변동성 손실과 비용을 넘을 수 있다. TQQQ의 매우 높은 10년 누적수익률은 그 **실현 경로의 산물**로 읽어야 한다. 같은 차트에는 2021~2022년 고점 대비 큰 손실도 함께 보인다.

로그 축의 누적수익률 차트는 몇 배로 커졌는지 비교하는 데 유용하지만, 숫자 위쪽의 선만 보면 중간 낙폭을 놓치기 쉽다. 투자자의 실제 결과는 시작·종료 시점과 중간 현금흐름에도 달려 있다. 강한 과거 추세를 미래의 μ로 곧바로 대입하면 최적 레버리지를 과대평가할 위험이 있다.

[34] https://www.proshares.com/resources/geared-faqs

[35] https://www.aqr.com/Insights/Research/Journal-Article/Betting-Against-Beta

5.52 슬라이드 52 · 로그 성장률에서 변동성이 제곱으로 작용한다

장기 자산은 날마다 곱해지지만 로그를 취하면 $\log(A_T/A_0) = \sum_t \log(1 + r_{L,t})$처럼 날별 성장률을 더할 수 있다. 작은 일간 수익률에는 $\log(1+x) \simeq x - x^2/2$가 성립한다. 첫 항은 평균 수익, 음의 제곱항은 상승과 하락이 반복될 때의 복리 손실을 나타낸다. 일간 초과수익의 연간화 평균을 μ, 연율화 변동성을 σ라 하고 비용·무위험금리의 공통 부분과 작은 일간 평균의 제곱을 생략하면, $E[x^2] = \mathrm{Var}(x) + (E[x])^2$에 의해 L배 전략의 연간 기대 **초과 로그성장률**은 $g_L \simeq L\mu - \frac{1}{2}L^2\sigma^2$다.

$$g_L \simeq L\left(\mu - \frac{\sigma^2}{2}\right) - \frac{L(L-1)}{2}\sigma^2.$$

첫 괄호는 기초자산 로그성장률의 L배, 둘째는 일일 재설정의 추가 변동성 부담으로 읽을 수 있다. $\mu = 19.2\%$, $\sigma = 22.6\%$를 대입하면 $g_1 \simeq 16.6\%$, $g_2 \simeq 28.2\%$, $g_3 \simeq 34.6\%$다. 이 값은 실현 ETF 수익률이 아니라 **추정 입력값으로 만든 근사 계산**이며 차입가산비용을 제외한다.

5.53 슬라이드 53 · 성장률을 최대로 하는 배수

$g_L = L\mu - \frac{1}{2}L^2\sigma^2$를 L로 미분하면 $g_L' = \mu - L\sigma^2$이고, 이계도함수는 $-\sigma^2 < 0$이다. 따라서 비용과 투자한도를 무시한 연속 배수의 내부 최적점은 $L^* = \mu/\sigma^2$다. 이것은 **로그성장률 최대화**의 해이며 샤프비율 최대화나 모든 투자자의 최적 배수와 같지 않다. μ는 무위험금리 초과 수익률로 정의해야 한다.

$\mu = 0.192$, $\sigma = 0.226$이면 $\sigma^2 \simeq 0.0511$이므로 $L^* \simeq 3.76$이다. 같은 추세에서 변동성이 40%로 커지면 $L^* = 0.192/0.16 = 1.2$이고, 3배 성장률은 $3(0.192) - \frac{1}{2}(9)(0.16) = -0.144$, 즉 약 -14.4%다. 기초자산의 기대 초과수익률이 실제로 19.2%라는 확신은 없으므로 수치를 투자 권고로 읽으면 안 된다.

5.54 슬라이드 54 · QQQ, 이상적 3배, 실제 TQQQ

동일한 역사적 일간 경로에 비용 없는 이상적 3배를 적용한 누적수익률과 실제 TQQQ의 기록을 구분하자. 제시된 2016~2026년 누적 총수익률은 QQQ +565%, 이상적 3배 +3,773%, TQQQ +2,946%다. 이상적 3배의 일간 샤프는 QQQ와 같은 0.85지만 실제 TQQQ는 0.82였다. 1년 보유 샤프는 각각 0.99, 0.82, 0.78로 나타났다.

이상적 3배와 실제 상품의 차이에는 보수·내부 금융비용·추적오차와 사용한 데이터 기준이 들어간다. 이상적 3배의 1년 샤프가 이미 낮아진다는 점은 비용이 없어도 복리 경로의 분포가 바뀐다는 뜻이다. 반면 실제 TQQQ의 높은 누적수익률은 그 기간의 큰 상승 추세가 추가 위험을 보상했음을 보여 줄 뿐, 미래에도 같은 비율로 오를 것이라는 증거는 아니다.

5.55 슬라이드 55 · 펀드의 매매와 시장가격의 인과관계

목표 배수를 유지하는 데 필요한 명목 노출액과 기초주식에 도달한 주문액 사이에는 선물·스왑·상대방 헤지가 있다. 현물 주문액이 같아도 종가 주문장의 반대편 물량이 두터우면 가격 반응이 작고, 얕으면 클 수 있다. 따라서 가격 효과의 단위는 주문액 자체가 아니라 **그 주문이 없었을 때의 종가와 관측 종가의 차이**다.

먼저 주가가 움직여 재설정 주문이 생기는 **역인과** 때문에 하락일의 매도 주문과 가격 하락은 함께 관찰된다. 예상 조정 수요가 다른 날·종목·시간대를 비교하고 공통 뉴스를 통제해야 주문의

추가 효과를 추정할 수 있다.

5.56 슬라이드 56 · 변동성 증폭 가설의 정확한 내용

레버리지 배수 $L > 1$ 또는 $L < 0$이면 $L(L-1) > 0$다. 그래서 지수 수익률 $r > 0$일 때 조정 노출은 매수 방향, $r < 0$일 때 매도 방향이다. 거래가 종가에 집중되고 반대편 유동성이 부족하면 상승을 더 밀고 하락을 더 누를 수 있다. 거래 규모는 A와 $|r|$에 비례하므로 큰 변동일수록 이 가설이 중요해진다.

공개된 자산규모와 당일 수익률로 조정 수요를 예측한 투자자는 미리 반대 주문을 공급하거나 먼저 거래할 수 있다. LP도 재고로 일부를 흡수한다. 미 연준의 연구[36]는 2011년 미국에서 시장이 1% 움직일 때 약 10억 달러의 조정 수요를 추정했다. 이 수요가 당시와 다른 국내 종가 시장에서 얼마의 가격 효과를 내는지는 별도 자료가 필요하다.

5.57 슬라이드 57 · 종가 거래량을 원화로 계산하기

2026년 6월 19일 SK하이닉스 관련 +2배 상품의 전일 순자산을 8.7조 원, 당일 기초주가 상승률을 2.9%라 하면, 순설정을 제외한 단순 노출 조정은 $2(2-1) \times 8.7$조 $\times\, 0.029 = 0.5046$조원, 약 5,000억 원이다. 이는 **상품 전체의 목표 노출 조정**이다. 자본시장연구원 분석[37]은 이 중 현물 주식에 도달한 규모를 별도로 추정한다.

현물 추정 2,600억 원은 목표 노출 조정액 약 5,000억 원의 약 52%다. 나머지 차이에는 선물·스왑과 헤지 경로가 들어갈 수 있다. 가격 충격을 보려면 2,600억 원도 **종가 단일가 구간의 반대 주문량과 비교**해야 한다. 2026년 7월 말까지 조정이 15:20~15:30에 집중되었다는 시간 구조가 일 거래대금 전체보다 적절한 비교 기준을 준다.

5.58 슬라이드 58 · 상쇄 흐름과 예측된 주문

하락일 +2배 펀드에서는 $2Ar < 0$이다. 이때 개인 매수가 실제 순설정 $F > 0$으로 이어지면 $2F > 0$이 매도 필요량을 줄인다. 예를 들어 $A = 100$, $r = -10\%$면 기본 조정은 -20이고 순설정 $F = 10$이면 합계 0이다. 개인 매수 체결량만으로 F를 알 수 없으므로 발행 지분 변화를 확인해야 한다.

Kyle의 시장 미시구조 모형[38]에서는 주문에 사적 정보가 담길 수 있어 가격이 반응한다. ETF 재설정은 기계적으로 예측할 수 있는 부분이 크지만, 이를 받아 줄 시장조성자는 재고를 보유하거나 헤지해야 한다. 예상 주문량이 종가 유동성보다 크면 **정보 효과가 작아도 일시적인 가격 압력**이 생길 수 있다.

5.59 슬라이드 59 · 역인과와 공통 충격

운용사는 관심과 거래량이 클 것으로 예상되는 종목에 상품을 내놓는다. 이미 변동성이 커지는 종목이 상장 대상으로 선택되었다면 상장 뒤의 높은 변동성에는 **선택 편의**가 섞인다. 동시에 해외 반도체주도 흔들렸다면 산업 공통 충격도 작동했을 수 있다. 두 요인을 빼고 남는 국내 종목의 변화가 ETF 효과의 후보가 된다.

[36] https://www.federalreserve.gov/pubs/feds/2013/201348/index.html

[37] https://www.kcmi.re.kr/publications/pub_detail_view?cno=6801&syear=2026&zcd=002001016&zno=1922

[38] https://www.jstor.org/stable/1913210

예를 들어 상장 기초종목의 마지막 30분 변동성 비중 변화에서 유사한 비상장 종목의 같은 변화를 빼는 차이의 차이 분석을 생각할 수 있다. 비교군은 상장 전 추세가 비슷하고 산업 뉴스에는 비슷하게 반응해야 한다. 해외 종목을 쓰면 환율·거래시간·기업별 뉴스 차이를 추가로 통제한다. 종가에만 차이가 집중되는지도 메커니즘 검증에 유용하다.

5.60 슬라이드 60 · 마지막 30분 분산 비중의 의미와 한계

5분 수익률 r_j로 마지막 30분의 비중 $s = \sum_{j \in \text{close}} r_j^2 / \sum_{j \in \text{day}} r_j^2$를 만든다. 상장 뒤 기초종목의 s가 비교군보다 더 커지면 **변동이 종가 쪽으로 이동했다**는 증거가 된다. 수익률을 제곱하므로 큰 가격 움직임에 가중치가 크다. 단일가 체결과 얇은 호가가 만드는 미시구조 잡음도 이 지표에 섞일 수 있다.

도표에서 기초종목은 2.10%에서 3.08%로 0.98%포인트, 다른 KOSPI 200 종목은 1.48%에서 1.69%로 0.21%포인트 올랐다. 차이의 차이는 $0.98 - 0.21 = 0.77$%포인트다. 상장 전 14일, 상장 후 45일의 표본과 표준오차가 없어 통계적 유의성은 아직 판단할 수 없다. 분자·분모의 절대 수준과 거래대금도 함께 보고, 예상 조정액이 종가 유동성에 비해 큰 날에 효과가 집중되는지 검증해야 한다.

5.61 슬라이드 61 · 더 읽을 자료와 검증의 순서

SEC의 ETF 구조 안내[39]는 개인 거래와 AP 설정·환매의 차이를, SEC의 레버리지 ETF 안내[40]는 일일 목표와 장기 보유의 차이를 정리한다. 국내 제도는 한국거래소 LP 설명[41]과 금융위원회의 투자자 안내[42]에서 확인할 수 있다. 2026년 국내 사례의 관측치는 자본시장연구원 분석[43]을 참고한다.

조정 수요를 가격 효과와 연결하려면 상품별 순자산·일간 수익률로 계산한 목표 노출, 설정·환매액, 현물·파생상품 체결액, 종가 주문장 유동성을 같은 날짜와 시간대로 맞춰야 한다. 해외 연구와 국내 사례를 비교할 때도 상품 구성과 헤지 방식의 차이를 반영한다.

[39] https:// www.investor.gov/ introduction- investing/ general- resources/ news- alerts/ alerts-bulletins/investor-bulletins-24

[40] https:// www.investor.gov/ introduction- investing/ general- resources/ news- alerts/ alerts-bulletins/investor-alerts/sec

[41] https://regulation.krx.co.kr/contents/RGL/03/03060103/RGL03060103.jsp

[42] https://fsc.go.kr/po010102/86910

[43] https://www.kcmi.re.kr/publications/pub_detail_view?cno=6801&syear=2026&zcd=002001016&zno=1922