AI 금융경제

슬라이드별 학습 가이드

값싼 예측에서 채권 위험프리미엄까지

2026년 2학기

목차

Session 1A · 값싼 예측과 AI의 경제학 **13**

슬라이드 01 · 강좌의 지도 13
슬라이드 02 · 왜 금융에서 AI를 배우는가 13
슬라이드 03 · 주식 매수 질문에 빠진 변수들 13
슬라이드 04 · AI 충격과 한국 주식시장의 집중 14
슬라이드 05 · 값싼 예측의 경제학 14
슬라이드 06 · 세 명제의 연결 14
슬라이드 07 · 의사결정을 바꾸지 않는 신호의 가치는 0 15
슬라이드 08 · 지도와 압축 15
슬라이드 09 · 한 결정에 맞춰 만든 지도 16
슬라이드 10 · 공시에서 글자가 이미지일 때 16
슬라이드 11 · 빠른 요약과 정확한 요약의 선택 16
슬라이드 12 · 암달의 법칙과 업무 병목 17
슬라이드 13 · 영상의학 사례가 알려 주는 것 17
슬라이드 14 · 암달 곡선의 평탄해짐 17
슬라이드 15 · 과업 생산성과 총량 효과의 차이 18
슬라이드 16 · 싸진 예측이 재평가하는 것 18
슬라이드 17 · 제번스 역설의 그림 18
슬라이드 18 · 탄력성으로 보는 반등 18
슬라이드 19 · 기술과 직업의 역사 19
슬라이드 20 · 약한 고리와 GDP 19
슬라이드 21 · 분석 가격이 내려갈 때 희소해지는 것 19
슬라이드 22 · 내 일의 위험을 평가하는 세 질문 20
슬라이드 23 · 데이터 모형에서 예측 모형으로 20
슬라이드 24 · 브라이먼의 두 문화 20
슬라이드 25 · 두 문화의 원문을 읽는 법 21
슬라이드 26 · 금융이 이론 중심 접근을 고수한 이유 21
슬라이드 27 · 요인모형의 언어 21
슬라이드 28 · 요인 동물원과 다중검정 22
슬라이드 29 · 머신러닝의 동일 경기장 22
슬라이드 30 · 작은 표본외 결정계수의 의미 22
슬라이드 31 · 공개된 예측 신호의 이익 감소 23
슬라이드 32 · 계산 규모와 사전 지식 23

슬라이드 33 · 이중 하강과 금융 데이터 23

Session 1B · 금융 텍스트와 언어모형 24

슬라이드 01 · 텍스트를 금융 데이터로 읽기 24
슬라이드 02 · 사전에서 언어모형으로 24
슬라이드 03 · 사전 단어 세기의 함정 24
슬라이드 04 · 금융 전문 사전의 의미 25
슬라이드 05 · n그램과 부정 표현 25
슬라이드 06 · 임베딩은 무엇을 보존하는가 25
슬라이드 07 · 토큰과 입력의 비용 25
슬라이드 08 · 어텐션의 계산 26
슬라이드 09 · 다음 토큰 예측과 압축 26
슬라이드 10 · 유창한 실패의 출발점 26
슬라이드 11 · 생성모형의 목적 함수를 정확히 쓰기 27
슬라이드 12 · 목적 함수에 진실 항이 없다는 뜻 27
슬라이드 13 · 질문을 바꾸면 평가도 바뀐다 27
슬라이드 14 · 걸러낼 것이 없는 회사를 시험하기 28
슬라이드 15 · 모델의 국적을 성향으로 단정하지 않기 28
슬라이드 16 · 예상을 뒤집는 결과의 검증 28
슬라이드 17 · 지역 정보의 사각지대 28
슬라이드 18 · 기억과 진짜 사전 예측의 차이 29
슬라이드 19 · 모형의 투자 스타일 29
슬라이드 20 · 만족도 보상의 부작용 29
슬라이드 21 · 사후 분석과 인과 사슬 30
슬라이드 22 · 체스 에이전트 실험의 설계 30
슬라이드 23 · 목표 달성과 규칙 준수는 다른 변수 30
슬라이드 24 · 굿하트 법칙, 루커스 비판, 대리인 문제 31
슬라이드 25 · 환각을 과신으로 측정하기 31
슬라이드 26 · 저장된 지식과 인출의 병목 31
슬라이드 27 · 보이는 추론의 한계 32
슬라이드 28 · 다음 토큰 맞히기가 만드는 능력 32
슬라이드 29 · 산술은 외부 도구로 분리하기 32
슬라이드 30 · 유창함 대신 재현성을 기준으로 32

Session 2 · 정규화 회귀와 수익률 예측 33

슬라이드 01 · 수익률 예측의 출발점 33

슬라이드 02 · 앞 장에서 이어지는 문제 33
슬라이드 03 · 시장 수익률 예측의 오래된 실패 34
슬라이드 04 · 평균보다 큰 변동성 34
슬라이드 05 · 예측변수 동물원 34
슬라이드 06 · 높은 배당수익률의 두 해석 34
슬라이드 07 · 자료를 잘게 나누어도 평균은 정밀해지지 않는다 35
슬라이드 08 · 단순수익률, 로그수익률, 연속복리 35
슬라이드 09 · 일별 자료의 다른 역할 36
슬라이드 10 · 표본 안의 유의성 36
슬라이드 11 · 표본내와 표본외를 구분하기 37
슬라이드 12 · 과거 평균과 표본외 결정계수 37
슬라이드 13 · 웰치와 고열의 판정 37
슬라이드 14 · 간단한 경제 제약은 도움이 될까 37
슬라이드 15 · 시간이 지난 뒤의 재검증 38
슬라이드 16 · 유의성·안정성·실용성의 깔때기 38
슬라이드 17 · 누적 오차 차이 그래프 읽기 38
슬라이드 18 · 첫 단계의 결론 39
슬라이드 19 · 왜 실패하는가 39
슬라이드 20 · 작은 참 신호의 규모 39
슬라이드 21 · 과적합 모의실험을 직접 구성하기 39
슬라이드 22 · 변수 증가와 벌점의 효과 40
슬라이드 23 · 차원이 커질 때 추정오차의 유도 40
슬라이드 24 · 편향과 분산을 식으로 분해하기 40
슬라이드 25 · 세 오차의 경제적 의미 41
슬라이드 26 · U자형 상충관계 41
슬라이드 27 · 공짜 점심이 없는 이유 41
슬라이드 28 · 금융 자료에 맞는 검증 42
슬라이드 29 · 편향을 의도적으로 쓰는 처방 42
슬라이드 30 · 첫 번째 처방으로 가기 42
슬라이드 31 · OLS의 역행렬이 불안정해지는 이유 42
슬라이드 32 · 능형회귀의 해를 직접 유도하기 43
슬라이드 33 · 두 변수로 보는 작은 분모 43
슬라이드 34 · 교점 그림의 해석 43
슬라이드 35 · 두 계수의 숫자 예 44
슬라이드 36 · 축소와 유효 자유도 44

슬라이드 37 · 제약식과 벌점식 44
슬라이드 38 · 계수 경로 읽기 45
슬라이드 39 · 표준화가 필수인 이유 45
슬라이드 40 · 편향된 추정기가 왜 이길 수 있는가 45
슬라이드 41 · 과거 수익률 357개로 다음 달을 예측하기 46
슬라이드 42 · 회귀계수에서 읽는 모멘텀과 반전 46
슬라이드 43 · 모의실험에서 벌점이 작동하는 방식 46
슬라이드 44 · 여기까지의 처방 47
슬라이드 45 · 변수 선택의 문제 47
슬라이드 46 · 제곱 벌점에서 절댓값 벌점으로 47
슬라이드 47 · 라쏘 목적함수 47
슬라이드 48 · 연성 임계값의 유도 48
슬라이드 49 · 마름모의 꼭짓점 48
슬라이드 50 · 라쏘 경로의 읽기 48
슬라이드 51 · 상관된 쌍둥이 변수 49
슬라이드 52 · 엘라스틱넷의 두 벌점 49
슬라이드 53 · 어떤 벌점이 맞는가 49
슬라이드 54 · 벌점 선택과 채점 49
슬라이드 55 · 하이퍼파라미터와 계수의 역할 50
슬라이드 56 · k겹 교차검증을 계산하기 50
슬라이드 57 · 금융 교차검증의 두 경고 50
슬라이드 58 · OLS, 능형, 라쏘의 결과 비교 51
슬라이드 59 · 예측 점수와 투자 성과가 다른 이유 51
슬라이드 60 · 시장 전체 예측으로 돌아오기 51
슬라이드 61 · 극단적 복잡성의 논쟁 51
슬라이드 62 · 수익률 예측에서 확립된 규칙 52

Session 4A · 종목 간 기대수익률과 요인 논쟁 **52**

슬라이드 01 · 횡단면의 출발점 52
슬라이드 02 · 앞 장에서 건너오는 다리 52
슬라이드 03 · 요인 동물원의 네 질문 52
슬라이드 04 · 특성에서 전략으로 53
슬라이드 05 · 십분위 포트폴리오 정렬 53
슬라이드 06 · 파마·맥베스 회귀의 두 단계 53
슬라이드 07 · 높은 수익률과 이상현상의 차이 54

슬라이드 08 · 왜 월별 기울기의 표준오차를 쓰는가 54
슬라이드 09 · 여섯 범주의 지도 54
슬라이드 10 · 여섯 범주의 대표 신호 55
슬라이드 11 · 낮은 가격은 두 가지를 말한다 55
슬라이드 12 · 각 범주를 같은 질문으로 읽기 55
슬라이드 13 · 모멘텀의 위치 56
슬라이드 14 · 과거 승자가 계속 이기는가 56
슬라이드 15 · 모멘텀의 위험과 가격오류 설명 56
슬라이드 16 · 평균 모멘텀과 폭락 위험 56
슬라이드 17 · 가치와 성장의 구분 57
슬라이드 18 · 장부가치/시가총액으로 정렬하기 57
슬라이드 19 · 가치 프리미엄의 두 해석 57
슬라이드 20 · 가치 효과의 기간과 측정 58
슬라이드 21 · 투자와 수익성으로 넘어가기 58
슬라이드 22 · 빠른 자산 증가와 낮은 미래수익률 58
슬라이드 23 · 투자율과 할인율의 연결 58
슬라이드 24 · 수익성 높은 회사의 높은 수익률 59
슬라이드 25 · 수익성 효과의 항등식과 설명 59
슬라이드 26 · 두 자산가격 요인모형 59
슬라이드 27 · 무형자산의 회계 문제 60
슬라이드 28 · 장부 밖 투자와 비율의 왜곡 60
슬라이드 29 · 무형자산 프리미엄의 두 설명 60
슬라이드 30 · 낮은 범주 재현율을 해석하기 60
슬라이드 31 · 거래마찰은 가격과 비용을 함께 바꾼다 61
슬라이드 32 · 소형주와 비유동성 61
슬라이드 33 · 고유변동성과 단기 반전 61
슬라이드 34 · 거래마찰 범주의 재현 62
슬라이드 35 · 여섯 범주를 한꺼번에 비교하기 62
슬라이드 36 · 위험인가 가격오류인가 62
슬라이드 37 · 두 설명의 서로 다른 예측 62
슬라이드 38 · 지금까지의 가격 항등식 63
슬라이드 39 · 네 가지 구별 질문 63
슬라이드 40 · 판정표의 증거를 읽는 법 63
슬라이드 41 · 예측자와 설명자의 목표 64
슬라이드 42 · 투자 CAPM의 최적화 유도 64

슬라이드 43 · 특성과 공분산을 떼어 놓기 64
슬라이드 44 · 우연이라는 세 번째 설명 65
슬라이드 45 · t값 2의 의미가 바뀌는 순간 65
슬라이드 46 · 잡음 전략 300개의 모의실험 65
슬라이드 47 · 진짜 전략 10개를 섞었을 때 66
슬라이드 48 · 왜 새 요인에는 더 높은 기준이 필요한가 66
슬라이드 49 · 다중검정 규칙의 단계별 계산 66
슬라이드 50 · 재현 논쟁의 질문 67
슬라이드 51 · 많은 이상현상이 실패한다는 결과 67
슬라이드 52 · 많은 요인이 재현된다는 결과 67
슬라이드 53 · 왜 판정이 갈리는가 68
슬라이드 54 · 한 요인의 베이지안 축소를 유도하기 68
슬라이드 55 · 주제별 정보를 함께 쓰기 68
슬라이드 56 · 사후 판정과 82%의 해석 69
슬라이드 57 · 발표 뒤 수익의 감소 69
슬라이드 58 · 새 요인의 올바른 검정 69
슬라이드 59 · 선택된 통제만 넣을 때의 편향 69
슬라이드 60 · 새 요인 15개의 비교 70
슬라이드 61 · 이중 선택의 세 단계 70
슬라이드 62 · 다음 문제의 문턱 71
슬라이드 63 · 요인 논쟁을 예측 문제로 다시 쓰기 71
슬라이드 64 · 이미 시도한 정규화의 교훈 71
슬라이드 65 · 횡단면 연구의 결론 71

Leveraged ETFs · 레버리지 ETF와 시장 미시구조 **72**

슬라이드 01 · 레버리지 ETF를 읽는 세 가지 질문 72
슬라이드 02 · 반도체 호황은 왜 출발점인가 72
슬라이드 03 · 7월 급락과 책임론을 분리해서 보기 72
슬라이드 04 · 시장 충격에 관한 주장과 검증 72
슬라이드 05 · 경제학적 질문의 범위 73
슬라이드 06 · 10년 수익률이 단순 배수와 다른 까닭 73
슬라이드 07 · 다섯 단계의 연결 73
슬라이드 08 · ETF의 두 시장 73
슬라이드 09 · NAV와 시장가격의 단위 74
슬라이드 10 · AP, LP, 설정 단위 74

슬라이드 11 · 주식처럼 거래되는 펀드 74
슬라이드 12 · 누가 누구와 거래하는가 74
슬라이드 13 · 차익거래가 NAV에 가격을 묶는 방식 75
슬라이드 14 · KODEX 200 설정 단위 계산 75
슬라이드 15 · 한국의 AP와 LP가 연결되는 순서 75
슬라이드 16 · 프리미엄과 디스카운트 읽기 75
슬라이드 17 · LP의 호가와 종가 괴리 의무 76
슬라이드 18 · 괴리 공시와 투자유의의 단계 76
슬라이드 19 · 일일 리밸런싱의 출발점 76
슬라이드 20 · 미국 상품의 배수와 기초자산 77
슬라이드 21 · 국내 상품과 미국 상품의 비교 단위 77
슬라이드 22 · 단일종목 ETF와 신규 시장 77
슬라이드 23 · +2배와 -2배가 같은 방향으로 거래하는 이유 77
슬라이드 24 · 거래식 L(L-1)Ar의 유도 78
슬라이드 25 · 지정가 주문과 역방향 자금 흐름 78
슬라이드 26 · 순설정 F를 포함한 거래식 78
슬라이드 27 · 한 식에서 두 효과가 나온다 79
슬라이드 28 · '음의 복리'를 정확히 해석하기 79
슬라이드 29 · 이틀 경로를 직접 곱해 보기 79
슬라이드 30 · 일일 재설정과 매수후보유의 정확한 차이 79
슬라이드 31 · 거래액 20이 만드는 +2 또는 -2 80
슬라이드 32 · 왕복 변동의 정확한 손실 80
슬라이드 33 · T일 곱을 2차 항까지 전개 80
슬라이드 34 · 볼록성과 변동성 항의 분해 80
슬라이드 35 · 끝점과 경로를 따로 보기 81
슬라이드 36 · SK하이닉스 사례를 분해하는 방법 81
슬라이드 37 · 수익률만으로 위험을 평가할 수 없는 이유 81
슬라이드 38 · 같은 상품의 일간과 1년 샤프비율 82
슬라이드 39 · 샤프비율의 분자와 분모 82
슬라이드 40 · 하루에는 왜 샤프가 같나 82
슬라이드 41 · 보유기간을 늘리면 분포가 바뀐다 83
슬라이드 42 · T일 복리수익률의 평균과 분산 유도 83
슬라이드 43 · 샤프가 투자 선택의 전부인가 83
슬라이드 44 · 자본시장선 CML의 기울기 83
슬라이드 45 · 현실의 차입금리가 선을 꺾는다 84

슬라이드 46 · 자산군 샤프비율의 표본 의존성 84
슬라이드 47 · 내재 레버리지 상품과 개인 차입의 비교 84
슬라이드 48 · 투자자 계좌에서 사라지는 마진콜 84
슬라이드 49 · 3배 노출의 두 가격표 85
슬라이드 50 · 차입 제약과 betting against beta 85
슬라이드 51 · 강한 추세가 TQQQ에 유리했던 기간 85
슬라이드 52 · 로그 성장률에서 변동성이 제곱으로 작용한다 85
슬라이드 53 · 성장률을 최대로 하는 배수 86
슬라이드 54 · QQQ, 이상적 3배, 실제 TQQQ 86
슬라이드 55 · 펀드의 매매와 시장가격의 인과관계 86
슬라이드 56 · 변동성 증폭 가설의 정확한 내용 86
슬라이드 57 · 종가 거래량을 원화로 계산하기 87
슬라이드 58 · 상쇄 흐름과 예측된 주문 87
슬라이드 59 · 역인과와 공통 충격 87
슬라이드 60 · 마지막 30분 분산 비중의 의미와 한계 87
슬라이드 61 · 더 읽을 자료와 검증의 순서 88

Session 4B · 수익률 예측의 도구 88

슬라이드 01 · 수익률 예측 방법의 지도 88
슬라이드 02 · 네 방법의 역할 88
슬라이드 03 · 모든 방법에 던질 세 질문 89
슬라이드 04 · 선형 방법의 출발점 89
슬라이드 05 · 선형 모형이 보는 효과 89
슬라이드 06 · 극단 수익률과 Huber 손실 89
슬라이드 07 · 입력을 압축하는 이유 90
슬라이드 08 · 긴 축과 짧은 축 90
슬라이드 09 · 모멘텀 두 지표의 숫자 예시 90
슬라이드 10 · 분산이 큰 성분이 예측도 잘할까 90
슬라이드 11 · 주성분의 가중치와 직교 90
슬라이드 12 · 주성분 회귀의 절차 91
슬라이드 13 · PCA를 공분산행렬로 쓰기 91
슬라이드 14 · 특성 PCA와 수익률 PCA 91
슬라이드 15 · 제1 주성분을 유도하기 91
슬라이드 16 · PCR, PLS, Ridge의 방향 선택 91
슬라이드 17 · 조건부 질문으로 넘어가기 92

슬라이드 18 · 회귀 나무의 구조 92
슬라이드 19 · 나무가 상호작용을 표현하는 방식 92
슬라이드 20 · 나무 깊이와 과적합 92
슬라이드 21 · 랜덤 포레스트의 두 무작위성 93
슬라이드 22 · 복원추출이 만드는 다른 적합자료 93
슬라이드 23 · 세 나무의 예측을 평균하기 93
슬라이드 24 · 부스팅은 남은 오차를 고친다 93
슬라이드 25 · 첫 나무가 줄인 제곱오차 93
슬라이드 26 · 두 번째 나무가 보는 목표 94
슬라이드 27 · 부스팅의 반복식을 읽기 94
슬라이드 28 · 나무를 평균하면 분산이 얼마나 줄까 94
슬라이드 29 · 계단에서 꺾인 함수로 94
슬라이드 30 · 신경망의 층과 모수 95
슬라이드 31 · 은닉 단위의 두 단계 95
슬라이드 32 · 작은 신경망을 손으로 계산하기 95
슬라이드 33 · 깊이와 너비를 정하기 95
슬라이드 34 · 한 가중치의 학습을 계산하기 95
슬라이드 35 · 반복 학습과 조기 종료 96
슬라이드 36 · 무엇을 조율하는가 96
슬라이드 37 · ReLU의 합이 꺾은선을 만드는 이유 96
슬라이드 38 · 역전파가 미분을 재사용하는 법 96
슬라이드 39 · 신경망의 과적합을 다스리기 96
슬라이드 40 · 층을 더해도 성능이 늘지 않은 이유 97
슬라이드 41 · 비교 기준을 다시 묶기 97
슬라이드 42 · 방법마다 조율할 값 97
슬라이드 43 · 예측 도구에서 실증 비교로 97

Session 4C · 머신러닝으로 본 횡단면 수익률 98
슬라이드 01 · 머신러닝과 횡단면 수익률 98
슬라이드 02 · 비교의 출발점 98
슬라이드 03 · 모든 종목에 적용하는 예측 함수 98
슬라이드 04 · 실험 설계의 순서 98
슬라이드 05 · 94개 기업 특성과 공시 시점 99
슬라이드 06 · 순위 변환과 920개 입력 99
슬라이드 07 · 선형 방법 세 가지 99

슬라이드 08 · 나무와 신경망의 예측 형태 99
슬라이드 09 · 시간 순서를 지킨 반복 검증 100
슬라이드 10 · 표본외 결정계수의 분자와 분모 100
슬라이드 11 · 왜 0을 기준 예측으로 쓰는가 100
슬라이드 12 · 예측오차 차이의 통계 검정 100
슬라이드 13 · 결과표를 읽는 기준 101
슬라이드 14 · 전체 주식의 월별 예측력 101
슬라이드 15 · 대형주에서 커지는 비선형 이득 101
슬라이드 16 · 어느 모형의 우위가 확실한가 101
슬라이드 17 · 예측 기간을 12개월로 늘리면 101
슬라이드 18 · 예측을 설명으로 옮기는 단계 102
슬라이드 19 · 중요한 특성은 무엇인가 102
슬라이드 20 · 1개월 반전의 경제적 직관 102
슬라이드 21 · 규모에 따라 달라지는 반전과 모멘텀 102
슬라이드 22 · 시장 상태도 특성 효과를 바꾼다 102
슬라이드 23 · 요인 동물원에서 무엇을 배웠나 103
슬라이드 24 · 적합된 모형의 그림을 읽는 법 103
슬라이드 25 · 예측에서 투자 성과까지 103
슬라이드 26 · 예측 상·하위 10분위 포트폴리오 103
슬라이드 27 · 예측값의 크기도 맞는가 104
슬라이드 28 · 예측력과 수익이 집중되는 곳 104
슬라이드 29 · 매도 다리를 따로 보는 이유 104
슬라이드 30 · 2000년 이후 매도 다리와 낙폭 104
슬라이드 31 · 회전율에 거래비용을 적용하면 104
슬라이드 32 · 머신러닝 결과의 경제적 범위 105
슬라이드 33 · 보정 기울기가 드러내는 차이 105
슬라이드 34 · 회전율 공식의 분모 105
슬라이드 35 · 무엇을 종합할 것인가 105
슬라이드 36 · 4C의 핵심 연결 106
슬라이드 37 · 특성을 공분산으로 읽는 다른 방법 106

Session 5 · 채권 위험프리미엄과 머신러닝 **106**

슬라이드 01 · 채권 위험프리미엄이라는 질문 106
슬라이드 02 · 예측과 보상의 경계 106
슬라이드 03 · 수익률곡선에서 출발하기 107

슬라이드 04 · 무이표채의 수익률곡선 107
슬라이드 05 · 곡선 모양 네 가지 107
슬라이드 06 · 수준·기울기·곡률 107
슬라이드 07 · 기울기의 시간 변화 107
슬라이드 08 · 곡선을 설명하는 세 관점 108
슬라이드 09 · 로그 금리와 가격의 관계 108
슬라이드 10 · 기대가설의 숫자 예시 108
슬라이드 11 · 오늘 고정하는 미래 1년 금리 108
슬라이드 12 · spot 곡선과 forward 곡선 108
슬라이드 13 · 선도금리의 기대와 보상 109
슬라이드 14 · 만기수익률과 1년 보유수익률 109
슬라이드 15 · 기대가설 아래의 보유수익률 109
슬라이드 16 · 기울기의 두 원인 109
슬라이드 17 · term spread와 risk premium 109
슬라이드 18 · 기대 초과수익률의 정확한 크기 110
슬라이드 19 · 장기채의 1년 가격 위험 110
슬라이드 20 · 스프레드의 회계적 분해 110
슬라이드 21 · Fama–Bliss 회귀 읽기 110
슬라이드 22 · 한국 국고채에서의 적용 110
슬라이드 23 · 선도금리 전체에서 찾는 공통 요인 111
슬라이드 24 · CP 결과의 표본 의존성 111
슬라이드 25 · PCA가 보는 것은 금리의 분산 111
슬라이드 26 · 분산이 작은 요인의 예측력 111
슬라이드 27 · 금리에서 거의 안 보이는 예측 요인 111
슬라이드 28 · 곡선 적합과 프리미엄 예측의 차이 112
슬라이드 29 · 위험 보상과 볼록성의 유도 112
슬라이드 30 · 금리 기울기와 수익률 항등식 112
슬라이드 31 · 스패닝 가설로 넘어가기 112
슬라이드 32 · 스패닝의 수학적 조건 113
슬라이드 33 · 성립하는 이유와 깨지는 두 길 113
슬라이드 34 · 거시 요인이 추가한 표본내 설명력 113
슬라이드 35 · 모형 속의 비스패닝 거시 위험 113
슬라이드 36 · 월마다 측정한 1년 수익률의 중첩 113
슬라이드 37 · 소표본 추론에 대한 반론 114
슬라이드 38 · 거짓 양성을 보여 주는 모의실험 114

슬라이드 39 · 왜 Newey–West만으로 끝나지 않는가 114
슬라이드 40 · 금리 변화 없이 움직이는 프리미엄 114
슬라이드 41 · 중첩 오차의 표준오차 114
슬라이드 42 · 곡선에 머신러닝을 적용하기 115
슬라이드 43 · 채권 기대수익률 함수의 형태 115
슬라이드 44 · 입력과 목표의 시점 115
슬라이드 45 · 시간 순서를 지키는 평가 115
슬라이드 46 · 극단 랜덤 트리의 분할 115
슬라이드 47 · 여러 나무의 평균 116
슬라이드 48 · 무작위성이 예측을 돕는 조건 116
슬라이드 49 · 순방향망과 순환망의 정보 집합 116
슬라이드 50 · 순환망의 이득과 비용 116
슬라이드 51 · 작은 채권 자료와 작은 신경망 116
슬라이드 52 · Dropout·벌점·조기 종료 117
슬라이드 53 · 여러 초기값을 평균하는 이유 117
슬라이드 54 · 하이브리드망: 곡선은 선형, 거시는 비선형 117
슬라이드 55 · 두 망을 더하는 구조 117
슬라이드 56 · 경제 그룹별 신경망 117
슬라이드 57 · 경제적 사전 지식의 역할 117
슬라이드 58 · 정정 전: 곡선만 사용한 결과 118
슬라이드 59 · 정정 전: 거시 변수를 더한 결과 118
슬라이드 60 · 경사하강과 momentum 118
슬라이드 61 · 초기화·정규화·공동 출력 118
슬라이드 62 · 조정 범위와 모수 수 118
슬라이드 63 · 정정 전 해석의 지위 118
슬라이드 64 · 정정문이 바꾸는 질문 119
슬라이드 65 · 누출된 한 행의 날짜 119
슬라이드 66 · 정정 후 곡선만 쓴 결과 119
슬라이드 67 · 거시 변수 효과의 정정 후 크기 119
슬라이드 68 · 예측 파이프라인의 시간 경계 120
슬라이드 69 · 채권 수익률의 중첩이 보이지 않는 이유 120
슬라이드 70 · 검정 결과를 다시 묶기 120
슬라이드 71 · 스패닝 논쟁의 현재 결론 120
슬라이드 72 · 채권 예측을 읽는 순서 120

Session 1A · 값싼 예측과 AI의 경제학

인공지능을 금융에 적용한다는 말은 먼저 **어떤 정보를 얻어 어떤 선택을 바꾸는가**를 묻는 일이다. 예측의 가치는 그 예측으로 피할 손실과 새로 얻을 편익으로 측정한다. 이 장은 예측의 경제학에서 과업의 보완관계, 가격 조정, 자산가격 예측으로 이어진다. 수학에서 필요한 것은 조건부기대값, 탄력성, 회귀의 기초이며, 각각을 아래에서 다시 정의한다.

슬라이드 01 · 강좌의 지도

금융에서 AI는 공시 읽기, 신용심사, 거래, 위험관리처럼 다양한 일에 쓰인다. 공통 질문은 **미래를 더 잘 예측하면 현재의 선택과 결과가 어떻게 달라지는가**다. 다음 분기 매출을 맞혀도 주가에 이미 반영된 전망과 거래비용을 고려해야 매수 여부를 정할 수 있다.

각 사례에서 **입력 시점 → 예측값 → 행동 규칙 → 비교 대상**을 순서대로 적어 보자. 월요일 개장 전 공개된 공시로 다음 한 달의 초과수익률을 추정한다면, 예측값이 거래비용과 요구 위험보상을 넘을 때 주문하고 같은 위험의 기준 포트폴리오와 성과를 비교한다. 보유 현금과 위험한도가 달라지면 같은 예측값도 다른 주문량으로 이어진다. 네 요소를 사전에 고정해야 모형의 개선을 평가할 수 있다.

슬라이드 02 · 왜 금융에서 AI를 배우는가

금융의 입력은 공시, 뉴스, 가격, 재무제표처럼 풍부하지만 목표인 **미래 초과수익률**은 매우 시끄럽다. 같은 기술이라도 영수증 분류에서는 높은 정확도가 곧 생산성으로 이어질 수 있지만, 투자에서는 작은 예측 오차가 큰 손실로 번진다.

금융 수익률은 기업 실적뿐 아니라 금리, 유동성, 투자자 기대가 동시에 움직인 결과다. 예측 모형이 기업의 실적을 잘 맞혀도 시장이 이미 그 정보를 가격에 넣었다면 투자수익은 늘지 않는다. **실적 예측 오차**와 **가격 대비 초과수익 예측 오차**를 별도로 기록해야 하는 이유가 여기에 있다.

가격은 이미 시장 참가자의 전망을 압축한 기준선이다. 매출 증가 확률을 70%로 예측했더라도 현재 가격이 그보다 더 낙관적인 전망을 반영한다면 매수 근거가 약하다. 반대로 확률 추정의 절대 정확도가 평범해도 시장 가격이 특정 위험을 과소평가했다면 유용할 수 있다. 그러므로 모형과 가격이 각각 **무엇을 예상하는지** 같은 단위로 비교해야 한다.

슬라이드 03 · 주식 매수 질문에 빠진 변수들

"삼성전자를 지금 사도 되는가"라는 질문은 답을 하나로 정할 수 없다. 투자 기간, 이미 가진 종목, 손실 감내 범위, 세금과 수수료가 빠졌기 때문이다. 같은 전망을 가진 두 사람도 현재 포트폴리오가 다르면 최적 행동이 다르다.

먼저 가능한 행동 a를 매수·보유처럼 정하고, 미래 상태 s마다 그 행동의 결과를 효용 $U(a,s)$로 평가한다. 효용은 돈의 액수와 같을 수도 있지만 위험을 싫어한다면 같은 금액의 이익과 손실을 다르게 평가할 수 있다. 상태 확률 $p(s)$로 효용을 가중해 더한 **기대효용**이 가장 큰 행동이 $a^* = \arg\max_a \sum_s p(s)U(a,s)$다. 여기서 arg max는 최대 기대효용의 값이 아니라 그 값을 만드는 **행동**을 돌려준다. AI의 예측은 주로 $p(s)$를 바꾸며, 목표와 투자 제약은 따로 정해야 한다.

효용식에 수치를 넣으면 결정 기준이 드러난다. 1만 원을 투자해 상승 시 2천 원을 얻고 하락 시 3천 원을 잃으며 두 상태만 가능하다면, 위험중립 투자자의 기대순이익은 $2{,}000p - 3{,}000(1-p) =$

$5{,}000p - 3{,}000$원이다. 거래비용이 없다면 $p > 0.6$에서만 매수한다. 상승 확률 60%는 정확히 무차별인 경계이고, 수수료나 위험 회피가 있으면 필요한 확률은 더 높아진다.

질문: 매매비용 100원이 추가되면 매수 확률 경계는? 기대순이익에서 100원을 빼면 $5{,}000p - 3{,}100$원입니다. 위험중립 투자자는 $p > 0.62$일 때 매수합니다. 비용이 커질수록 필요한 예측 확률도 높아집니다.

슬라이드 04 · AI 충격과 한국 주식시장의 집중

한국 주가지수는 시가총액 가중이므로 소수 반도체 대형주의 변동이 지수 전체에 크게 반영된다. 일정한 할인율 r로 단순화하면 주가는 미래 지급액의 현재가치 $P = \sum_{t \geq 1} E[CF_t]/(1+r)^t$다. CF_t는 t기의 주주 지급액이고 r은 위험을 반영한 할인율이다. 장기금리 상승은 할인율을 높이고, AI 투자 수익성에 대한 의문은 예상 현금흐름을 낮춘다. 먼 미래의 현금흐름에 가치가 집중된 기업일수록 할인율 변화에 민감하다.

AI 기업 사이의 투자·클라우드 구매·반도체 공급 계약은 서로의 매출을 키우지만 현금흐름의 독립성을 보장하지 않는다. 한 고리의 투자 축소가 다른 고리의 매출 전망을 낮추는 **공통 위험**이 될 수 있다. 단순한 "AI 수혜주" 분류보다 자금의 출처와 최종 고객 수요를 추적해야 한다.

한 기간의 지수 수익률은 시작 비중 w_i로 가중한 종목 수익률의 합 $\sum_i w_i r_i$다. 비중 20%인 종목이 5% 하락하고 나머지 80%가 평균 0.5% 상승하면 지수는 $0.2(-5\%) + 0.8(0.5\%) = -0.6\%$다. 다수 종목이 올라도 지수가 하락할 수 있으므로, 원인을 찾을 때 기업별 기여도와 공통 금리·환율 충격을 함께 본다.

슬라이드 05 · 값싼 예측의 경제학

예측은 아직 관찰하지 못한 값을 현재 정보로 추정하는 것이다. 비용이 내려가면 기업은 예전에는 예측 문제로 보지 않았던 업무까지 예측 가능한 조각으로 분해한다. 대출 심사에서는 "상환할까"뿐 아니라 "어떤 추가 서류가 판정을 바꿀까"도 예측 대상이 된다.

가격이 떨어진 재화의 사용량이 늘고, 함께 쓰는 보완재의 가치가 바뀐다는 미시경제학을 그대로 적용할 수 있다. 데이터 품질, 손실함수의 설계, 행동할 권한이 대표적인 보완재다. Prediction Machines[1]의 관점은 AI를 만능 지능으로 부르기보다 어떤 투입의 가격이 내려갔는지 묻게 한다.

예측의 수요는 예측 자체보다 **뒤따르는 행동의 손익**에서 나온다. 한 대출의 정상 상환 시 순이익이 10만 원이고 연체 시 손실이 90만 원이라면 기대순이익은 $(1-p)10 - p90 = 10 - 100p$만 원이어서 위험중립 기준 승인 경계는 $p = 10\%$다. 연체확률 추정치를 2%에서 1%로 고쳐도 결정은 그대로지만, 11%에서 9%로 고치면 승인 여부가 바뀐다. 자본규제와 간접비를 넣으면 실제 경계는 달라진다.

슬라이드 06 · 세 명제의 연결

첫째, 예측은 결정을 바꾸어야 가치가 있다. 둘째, 그 결정이 실제 결과로 이어지려면 업무의 다른 단계가 따라와야 한다. 셋째, 예측 비용이 충분히 내려가면 고객의 수요와 관련 노동·데이터의 가격이 조정된다.

세 명제는 개인의 선택, 기업의 생산과정, 시장 균형이라는 서로 다른 분석 수준이다. 한 건의 예측 성능을 기업의 총산출이나 시장 전체 편익으로 옮기려면 각 수준의 제약과 가격 변화를 계

[1] https://www.predictionmachines.ai/

산해야 한다.

세 수준을 연결하는 간단한 장부를 만들 수 있다. 개인 수준에서 한 건당 절감액이 v, 기업이 처리하는 건수가 q라면 직접 편익은 vq다. 그러나 도입 비용과 검토 인력이 필요하고, 시장에 서비스가 늘면 가격과 q 자체가 바뀐다. 한 건의 실험 효과를 전체 산업의 편익으로 곱할 때 이 변화를 빠뜨리지 않아야 한다.

예를 들어 분석 한 건에서 1만 원을 아껴도 승인 단계가 연간 1천 건으로 고정되어 있다면 직접 비용 절감은 최대 1천만 원이다. AI 덕분에 분석 가능한 후보가 1만 건으로 늘어도 승인 용량이 그대로라면 승인된 대출 수는 자동으로 늘지 않는다. 승인 인력이나 규칙을 바꾸어 용량이 커진 다음에는 수요와 부실 위험까지 새로 계산해야 한다.

슬라이드 07 · 의사결정을 바꾸지 않는 신호의 가치는 0

아직 신호 z를 보지 못하면 모든 상태에 대해 하나의 행동을 정해야 한다. 이때 최선의 기대효용은 $V_0 = \max_a E[U(a,s)]$다. 신호를 본 뒤에는 z에 따라 상태확률을 갱신하고, **신호마다** 가장 나은 행동을 고를 수 있다. 각 신호가 나올 확률로 그 결과를 평균한 값은 $V_1 = E_z[\max_a E[U(a,s) \mid z]]$다. max가 E_z의 안쪽에 있는 이유는 신호를 보고 행동을 바꿀 수 있기 때문이다. 원래 행동을 유지할 수도 있으므로 $V_1 \geq V_0$이고, 정보의 가치는 $V_1 - V_0$이다.

두 신호의 정답률이 달라도 최적 행동이 늘 같다면 행동 가치의 차이는 없다. 예컨대 투자 허용 범위가 좁아 항상 같은 보유량을 유지한다면 더 정밀한 전망의 즉각적 가치는 0이다. 반대로 드문 파산을 맞히는 신호는 전체 정확도가 낮아도 큰 손실을 피하게 해 가치가 클 수 있다. 이는 Blackwell의 정보 비교[2]를 금융 의사결정에 적용한 것이다. 신호 구매료가 c라면 순가치는 $V_1 - V_0 - c$다.

두 상태의 수치 예시를 보자. 매수하면 상승 시 $+2$, 하락 시 -3이고 보유하지 않으면 0이며, 사전 상승확률은 50%다. 매수의 기대값 $0.5(2) + 0.5(-3) = -0.5$이므로 원래는 매수하지 않는다. 신호가 '좋음'과 '나쁨'을 각각 절반의 확률로 내고, 그 조건부 상승확률이 각각 80%와 20%라면 좋을 때 매수의 기대값은 $0.8(2) + 0.2(-3) = 1$, 나쁠 때는 음수다. 신호를 보고 좋을 때만 사는 가치 $V_1 = 0.5(1) = 0.5$다. 이 값보다 신호 구매료가 높으면 사용하지 않는다.

슬라이드 08 · 지도와 압축

추상화는 정보를 버리는 일이다. 피카소의 황소 그림은 세부 묘사를 지우면서도 황소를 알아볼 특징을 남긴다. 지하철 노선도는 실제 거리와 방향을 왜곡해 환승 경로를 읽기 쉽게 한다.

좋은 압축은 **목표 결정에 필요한 차이**를 보존한다. 지하철 지도는 환승 경로에는 유용하지만 도보 시간에는 부정확할 수 있다. 금융 모형도 투자 손익을 좌우하는 꼬리위험과 발표 시점은 남겨야 한다.

두 회사의 실적을 모두 '순이익 20% 증가'로 압축해 보자. A는 본업의 반복 수익, B는 일회성 자산 매각 덕분이라면 내년 현금흐름 전망이 달라진다. 투자 결정을 위한 요약에는 이 차이가 남아야 한다. 과거 순이익 증가 여부만 분류한다면 같은 요약으로 충분하다. **좋은 압축의 기준은 사용할 결정**이 정한다.

[2] https://doi.org/10.1214/aoms/1177729032

슬라이드 09 · 한 결정에 맞춰 만든 지도

현실 x를 표현 $z = f(x)$로 압축하고 예측 $\hat{y} = g(z)$에 따라 행동 $a = h(\hat{y})$을 고른다고 하자. 같은 z를 가진 두 원문이 서로 다른 최적 행동을 요구한다면, 예측 모형을 아무리 개선해도 압축 단계에서 버린 정보는 복원하기 어렵다.

거대언어모형은 학습자료의 패턴을 압축해 답을 생성한다. 금융에서는 문장 요약의 매끄러움보다 의사결정에 필요한 수치, 부정문, 예외 조항, 기준일을 유지하는지가 중요하다. 공시의 "일회성 이익" 한 단어가 사라지면 이익의 지속성 평가가 달라진다.

계약금액, 종료일, 해지 조건, 연결대상 여부를 표로 추출하고 원문 위치를 붙이면 요약의 정확성을 항목별로 검증할 수 있다. 잘 읽히는 문장과 투자 판단에 충분한 기록을 각각 평가하는 방법이다.

결정에 충분한 표현은 같은 z로 압축된 원문들에서 가능한 행동의 기대손익 순위가 유지되어야 한다. 이는 모수 추정을 위한 충분통계량과 목적이 다르다. 손실이 큰 예외 조항 때문에 행동의 순위가 바뀌는 오류를 평균 정확도와 별도로 추적하면 압축의 약점을 찾을 수 있다.

슬라이드 10 · 공시에서 글자가 이미지일 때

문자 검색은 텍스트 층에 존재하는 글자를 찾는다. 실적 발표의 핵심 문단이 그림으로 삽입되면 사람이 보기에는 같은 문장이지만 기계의 단순 검색에서는 사라질 수 있다. 멀티모달 인식은 이미지의 글자를 읽어 이런 누락을 줄인다.

이미지에서 숫자를 추출한 뒤에는 회계적 의미와 투자 가치를 평가한다. 자산 매각 이익이 반복 가능한지, 현금 유입인지, 주가에 이미 반영됐는지는 원문 숫자만으로 결정되지 않는다.

OCR이 재무제표의 '(1,000)'을 '1,000'으로 읽으면 손실의 부호가 뒤집힌다. '1,000'의 단위를 원에서 백만 원으로 읽으면 금액은 백만 배 달라진다. 표의 행·열 제목과 회계기간까지 바뀌면 전년 대비 증가율도 거꾸로 계산된다. 값마다 원본 위치·단위·기간·부호를 저장하고, (당기 − 전기)/|전기|처럼 후속 계산을 정의해야 오류를 추적할 수 있다.

슬라이드 11 · 빠른 요약과 정확한 요약의 선택

분석가가 3일 걸려 오류율 1%인 결과를 내고 AI가 10초 걸려 오류율 5%인 결과를 낸다고 하자. "어느 쪽이 좋은가"는 오류 하나의 비용, 마감 시각, 사람이 후속 검토할 수 있는지에 달려 있다. 단순히 속도나 정확도 한 숫자로 고르지 않는다.

오류의 평균 비용을 L, 지연 비용을 D라 하면 총 기대비용의 단순형은 $C = p_{\text{err}}L + D$다. 중요한 공시를 잘못 읽어 큰 주문을 넣는 경우에는 L이 커서 검토 단계가 가치 있다. 반면 수천 개 문서에서 검토 후보만 찾는 1차 선별에는 빠른 도구가 유리할 수 있다.

사람의 확인이 오류 확률을 q에서 q'로 낮추고 오류 시 손실이 L, 확인 비용이 c라면 기대 순편익은 $(q - q')L - c$다. 오류 확률이 5%에서 1%로 줄고 오류 손실이 100만 원이면 기대손실은 4만 원 감소한다. 확인 비용이 2만 원이면 순편익은 2만 원이다. 이 판단에 쓰는 오류 확률은 별도 검증자료에서 확인해야 한다. 예를 들어 '95% 확신' 사례의 실제 오류율이 약 5%여야 그 숫자를 비용 계산에 쓸 수 있다.

슬라이드 12 · 암달의 법칙과 업무 병목

암달의 법칙(Amdahl's law)을 적용해 전체 처리시간을 1로 정규화하고, 자동화 가능한 부분이 p, 그 부분의 속도가 s배가 된다고 하자. 새 시간은 자동화하지 못한 $1-p$와 빨라진 p/s의 합이다. 따라서 전체 속도 증가는 다음과 같다.

$$S = \frac{1}{(1-p) + p/s}.$$

식의 분모를 직접 대입해 보자. 원래 100시간 중 30시간이 자동화 대상이고 이를 5배 빠르게 하면 새 총시간은 $70 + 30/5 = 76$시간, 속도는 $100/76 \approx 1.32$배다. '대상 과업이 5배 빨라졌다'와 '전체가 5배 빨라졌다'는 전혀 다르다. 새 병목인 70시간을 줄여야 다음 개선이 커진다.

$s \to \infty$일 때 전체 속도의 상한은 $1/(1-p)$다. 자동화 대상이 총시간의 30%라면 도구가 아무리 빨라져도 나머지 70%가 속도를 제한한다.

이 법칙은 **같은 작업량을 순서대로 처리하고**, 개선되지 않은 단계의 시간이 일정할 때 성립한다. 자동화 후 주문 후보가 더 많이 들어오거나 여러 업무가 병렬로 돌면 전체 처리량을 단순히 S배 할 수 없다. 특히 하루 승인 건수처럼 용량 제약을 묻는다면 작업 한 건의 소요시간과 대기열에 쌓이는 건수를 분리해 계산해야 한다.

슬라이드 13 · 영상의학 사례가 알려 주는 것

의사의 업무에는 영상 판독과 환자 상담, 협업, 시술, 법적 책임이 함께 있다. AI가 판독 시간을 줄이면 한 건당 필요한 사람의 시간과 검사 수요가 함께 변한다.

검사비가 낮아져 검사량이 늘면 상담·설명·후속 치료도 늘 수 있다. 고용 변화를 판단할 때는 한 건당 인력 절감률과 검사량 증가율을 같은 기간에 비교한다. 인구 고령화, 의료 수가, 양성 정원과 규제도 함께 바뀌므로 관찰된 고용 변화 전체를 AI의 효과로 돌릴 수는 없다.

필요한 총 노동시간을 $H = hQ$로 쓰면 h는 검사 한 건에 들어가는 사람의 시간, Q는 검사 건수다. AI로 h가 20% 줄고 Q가 10% 늘면 새 총시간은 $0.8 \times 1.1 = 0.88$배다. 검사량이 40% 늘면 $0.8 \times 1.4 = 1.12$배다. 이 산술은 고용의 가능한 방향을 보여 줄 뿐이고, 실제 인원은 근무시간 조정과 직무 재편에 따라 다시 달라진다.

슬라이드 14 · 암달 곡선의 평탄해짐

$p = 0.5$이면 자동화 부분을 무한히 빠르게 해도 전체는 최대 2배이고, $p = 0.9$라면 최대 10배다. 어느 단계가 전체 시간에서 큰 비중을 차지하는지에 따라 같은 도구의 효과가 달라진다.

거래 시스템에서 뉴스 분류를 빨리 해도 주문 한도 승인이나 결제 통제가 그대로면 총 처리량은 제한된다. 개선 전후에 각 단계의 소요시간을 재면 새 병목이 어디로 옮겨 갔는지 확인할 수 있다.

$S(s) = 1/(1-p+p/s)$를 s로 미분하면 $dS/ds = (p/s^2)/(1-p+p/s)^2 = p/[(1-p)s+p]^2 > 0$이다. $0 < p < 1$이면 분모가 s와 함께 커져 추가 개선은 작아진다. 이는 '더 큰 모형'에 투자할지 남아 있는 검토·집행 단계에 투자할지 고르는 기준이 된다.

예를 들어 $p = 0.5$이면 $s = 2$에서 전체 속도는 $1/(0.5+0.25) = 1.33$배, $s = 10$에서 $1/(0.5+0.05) = 1.82$배다. 자동화 부분을 2배에서 10배로 다섯 배 더 빠르게 해도 전체 증가는 약 0.49배에 그친다. $p = 1$이라면 남은 병목이 없으므로 $S = s$이고 이 평탄화 논리는 적용되지 않는다.

슬라이드 15 · 과업 생산성과 총량 효과의 차이

고객상담, 글쓰기, 소프트웨어 개발 같은 개별 과업에서 AI가 시간을 줄인다는 실험은 중요하다. 그러나 임금·고용·GDP는 기업의 도입률, 품질 검토, 수요 증가, 가격 하락, 다른 과업으로의 재배치가 합쳐진 균형 결과다. 개별 과업의 처리속도 증가를 총량 생산성 증가와 동일시할 수 없다.

측정에도 시차가 있다. 초기에는 설치·학습·프로세스 재설계 비용이 들고, 나중에야 보완투자가 이루어진다. 반대로 총량 지표에 변화가 아직 작다고 해서 미시적 편익이 없다는 뜻도 아니다. 생성형 AI와 상담 생산성 연구[3]는 과업 수준의 비교에 유용하다.

과업의 시간 비중, 기업의 도입률, 절감된 시간이 새 산출로 전환되는 비율이 총량 효과를 결정한다. 전체 노동시간의 10%를 차지하는 과업에서 시간을 40% 아끼고 기업의 절반이 도입했다면, 산출량이 고정된 상태에서 평균 노동시간의 직접 절감은 $0.1 \times 0.4 \times 0.5 = 0.02$, 즉 2%다. GDP 효과는 절감된 시간을 어디에 쓰는지, 산출 품질과 자본 투입이 어떻게 변하는지에 따라 달라진다.

슬라이드 16 · 싸진 예측이 재평가하는 것

예측 서비스의 한계비용이 내려가면 고객은 같은 예산으로 더 많은 예측을 이용할 수 있다. 이때 예측과 함께 쓰는 데이터·판단·집행 능력의 수요도 변한다. 그 가치가 누구에게 돌아가는지는 각 투입의 희소성과 공급 탄력성에 달려 있다.

노동은 한 덩어리가 아니다. 자동화된 과업을 많이 수행하는 노동과 예측을 해석·책임지는 노동은 보완 또는 대체 관계가 다르다. 따라서 "AI가 임금을 올린다/내린다"보다 어떤 과업의 수요가 늘고 공급이 얼마나 빨리 따라오는지 묻는 편이 정확하다.

예측과 사람의 예외 판단이 보완재라면 예측 가격 하락은 예외 판단의 **수요곡선**을 오른쪽으로 옮긴다. 판단 인력을 빠르게 양성할 수 있으면 고용량이 주로 늘고, 공급이 단기에 고정되어 있으면 임금이 더 오른다. 고유 데이터를 가진 기업이 모방을 막을 수 있다면 잉여를 얻지만, 정보가 표준화되어 쉽게 이동하면 경쟁을 통해 고객에게 편익이 돌아간다.

슬라이드 17 · 제번스 역설의 그림

에너지 효율이 개선되면 같은 이동 거리의 연료비가 내려간다. 비용이 낮아져 주행거리가 늘 수 있으므로 차량 한 대의 효율과 사회 전체의 연료 사용량은 반대 방향으로 움직일 수 있다. 그림의 혼잡한 도로는 **단위당 투입 감소와 총투입 증가가 양립**하는 경우를 보여 준다.

한 건의 자원투입을 e, 처리 건수를 Q라 두면 총투입은 $E = eQ$다. 효율 개선으로 건당 자원투입이 원래의 k배$(0 < k < 1)$가 되면, 건수가 $1/k$배를 **넘을 때** 총투입이 증가한다. 분석 시간이 10분에서 2분으로 줄었다면 건수 3배에서는 총시간이 0.6배, 8배에서는 1.6배가 된다. 건수가 정확히 5배면 총시간은 그대로다.

슬라이드 18 · 탄력성으로 보는 반등

앞 슬라이드의 총자원 항등식 $E = eQ$에서 e는 서비스 한 건당 자원, Q는 이용 건수다. 곱의 로그를 취하면 $\ln E = \ln e + \ln Q$이므로 작은 변화에 대해 $d\ln E = d\ln e + d\ln Q$다. 로그 변화는 퍼센트 변화에 가깝다. 서비스 가격 P가 내려갈 때 수요가 얼마나 늘어나는지는 양수로 정의한 가격탄력성 $\varepsilon = -d\ln Q / d\ln P$로 나타낸다. 건당 자원 e와 가격 P가 같은 비율로 낮아진다면 $d\ln e = d\ln P < 0$이고, 따라서 $d\ln E = (1-\varepsilon) d\ln P$다.

[3] https://doi.org/10.1093/qje/qjae044

$\varepsilon > 1$이면 $d\ln P < 0$에 대해 $d\ln E > 0$가 되어 반등이 효율 절감을 넘어선다. 의료영상 검사가 저렴해지면 검사 대상을 넓힐 수 있지만, 보험 규칙과 진료 지침이 수요를 제한할 수도 있다. 탄력성은 사례마다 추정해야 한다.

이 결론은 건당 자원 e의 감소가 같은 비율의 가격 하락으로 이어진다는 가정에 따른다. 인력·저장비용이나 가격 전가율이 달라지면 e와 P의 변화율도 달라진다. 또한 사용량 증가는 소득과 시장 규모의 변화에도 영향을 받으므로 관측된 총사용량만으로 가격탄력성을 추정할 수 없다.

탄력성이 일정하고 가격과 건당 자원이 모두 원래의 k배가 된다면 $Q_{\text{new}}/Q_{\text{old}} = k^{-\varepsilon}$, $E_{\text{new}}/E_{\text{old}} = k^{1-\varepsilon}$다. $k = 0.5$, $\varepsilon = 1.5$이면 총자원은 $0.5^{-0.5} = \sqrt{2}$배다. 이는 작은 변화의 미분식을 큰 변화에 적용할 때 필요한 **일정 탄력성** 가정을 보여 준다.

슬라이드 19 · 기술과 직업의 역사

증기기관, ATM, 스프레드시트는 모두 한 과업의 비용을 낮췄다. 은행 창구에서는 현금 인출 업무가 줄어도 지점 운영과 고객 상담의 상대적 중요성이 커질 수 있었다. 회계에서는 계산 자동화와 함께 감사·해석 업무가 늘었다.

과거 사례에서는 직업명보다 **어떤 과업이 줄고 남은 서비스의 수요가 얼마나 늘었는지**를 봐야 한다. ATM 도입 뒤 창구 인원이 늘었다 해도 같은 기간의 은행 합병, 인구 이동, 모바일뱅킹 확산을 분리해야 ATM의 고용 효과를 추정할 수 있다. 적절한 반사실은 ATM이 없었을 때 비슷한 지역의 창구 고용이 어떻게 변했을지다.

슬라이드 20 · 약한 고리와 GDP

경제 전체의 산출을 서로 보완적인 여러 부문의 함수로 보면 작은 부문의 생산성을 무한히 높여도 전체 산출은 다른 부문에 묶인다. 암달의 법칙이 시간의 합으로 이를 보여 준다면, 보완적인 생산함수는 **가치의 합과 대체 가능성**까지 고려한다.

대체탄력성 $\sigma < 1$은 한 부문의 산출을 다른 부문의 산출로 바꾸기 어렵다는 뜻이다. 법률 검토가 빨라져도 법원 절차가 일정하면 전체 사건 처리량의 증가는 작다. GDP 효과를 추정할 때는 자동화 대상의 부가가치 비중과 대체탄력성을 함께 정해야 한다. Jones와 Tonetti의 생산성 논의[4]는 이 제약을 수량화한다.

두 단계가 한 단위씩 짝지어야 하는 극단에서는 $Y = \min\{A, B\}$로 쓴다. 하루 처리 능력이 각각 100건과 20건이면 전체는 20건이고 첫 단계만 두 배로 늘려도 같다. 이 Leontief 생산함수의 대체탄력성은 0이다. 실제 경제에서는 여러 산업의 부가가치가 합쳐지고 투입도 일부 대체할 수 있어 이 최소식이 GDP를 직접 나타내지는 않는다. 이 예는 보완성이 강할 때 생산성 향상이 다른 단계의 용량에 묶이는 경로를 보여 준다.

슬라이드 21 · 분석 가격이 내려갈 때 희소해지는 것

공시의 숫자와 문장을 찾아 정리하는 비용이 크게 낮아지면 예전에는 전문 서비스 구매자만 하던 검색을 더 많은 사람이 할 수 있다. 연 2만 달러 서비스와 월 20달러 도구를 비교하면 연간 결제액은 $20{,}000/240 \approx 83.3$배 차이다. 이 비율을 **같은 품질의 분석 한 건당 가격**으로 쓰려면 데이터 범위, 오류 책임, 라이선스, 감사 가능성이 같아야 한다.

공개 공시를 읽는 비용이 낮아지면 같은 정보를 쓰는 투자자가 늘어 가격 반영도 빨라질 수 있다. 공시를 읽고 예상한 가격 상승폭이 0.3%여도 왕복 스프레드·수수료·시장충격이 0.4%면 거

[4] https://web.stanford.edu/~chadj/JonesTonetti_Automation.pdf

래의 예상 순수익은 음수다. **거래 가능한 알파**를 재려면 공시 접수부터 실제 주문 가능 시각까지의 지연을 기록하고, 그 시점 이후의 가격 변화에서 체결비용을 빼야 한다. 차별적 데이터와 낮은 실행비용은 이 계산에서 경쟁 우위가 될 수 있다.

슬라이드 22 · 내 일의 위험을 평가하는 세 질문

첫째, 일의 모든 과업을 자동화할 수 있는가. 둘째, 가격이 내려가면 그 서비스의 수요가 충분히 늘어나는가. 셋째, 남은 보완 과업의 공급이 제한되어 있는가. 세 질문을 함께 보아야 자동화와 임금의 방향을 추론할 수 있다.

신용분석가의 시간이 자료 입력 40%, 예외 검토 30%, 고객 소통 20%, 승인 책임 10%로 나뉜다고 하자. 입력이 전부 자동화되어 건당 사람 시간이 10시간에서 6시간으로 줄어도, 신청량이 50% 늘면 총 노동시간은 $6 \times 1.5/10 = 0.9$배다. 남은 과업의 공급이 부족하면 총 노동시간이 조금 줄어도 시간당 보수는 오를 수 있다. 이처럼 과업 비중, 신청 수요, 남은 인력의 공급을 차례로 측정한다.

슬라이드 23 · 데이터 모형에서 예측 모형으로

전통 통계는 자료의 생성 과정을 확률모형으로 표현해 모수를 해석한다. 알고리즘적 접근은 함수의 형태를 유연하게 두고 새 자료의 예측오차를 평가한다. 금융에서는 두 접근 모두 정보 시점과 표본외 성능을 검증해야 한다.

예측은 기존 대출 제도 아래의 $P(\text{연체} \mid X)$를 추정한다. 소득이 연체를 잘 예측해도 소득지원 정책이 연체율을 얼마나 바꿀지는 별도의 인과 질문이다. 소득이 신용이력이나 고용안정성의 대리변수일 수 있고, 승인 기준을 바꾸면 새로 대출받는 차주의 구성도 달라진다. 대출 승인 순위를 정할 때는 예측력을, 현금지원 효과를 평가할 때는 개입 뒤의 결과를 검증한다.

질문: 대출 승인 정책이 바뀌면 예측모형을 왜 다시 평가하나요? 새 정책은 승인되는 차주의 구성을 바꿉니다. 과거에는 대출받지 못해 연체 결과가 관찰되지 않은 집단이 들어오므로 기존 표본의 연체율과 오류율이 그대로 유지된다고 볼 수 없습니다.

슬라이드 24 · 브라이먼의 두 문화

데이터 모형 문화는 예컨대 $y = X\beta + \varepsilon$을 가정해 β의 의미와 유의성을 해석한다. **알고리즘 문화**는 함수 $f(X)$를 유연하게 고르고 미사용 자료의 예측오차를 줄인다. 전자는 설명 가능한 모수에 강하고 후자는 복잡한 비선형 패턴에 강할 수 있다.

여러 모형이 거의 같은 예측력을 갖는 라쇼몽 효과가 있으면 최고 점수 하나를 '진실'로 해석하기 어렵다. 단순성과 정확도의 상충도 자료와 목적에 따라 달라진다. Breiman의 원문[5]을 읽을 때 모델의 목적이 설명인지 결정인지 먼저 구분하자.

두 문화는 같은 데이터에 다른 질문을 던진다. '금리가 한 단위 바뀌면 주가가 얼마나 변하는가'는 개입과 누락변수를 다루는 구조적 질문이고, '내일 어떤 종목의 손실 가능성이 큰가'는 당시 관측 가능한 변수로 시험할 예측 질문이다. 경제 이론으로 정보 시점과 제약을 정한 뒤 유연한 모형을 비교할 수도 있다. 계수 해석에는 함수 형태와 오차 가정을, 투자 결정에는 미래 자료의 오차와 비용을 중심에 둔다.

[5] https://doi.org/10.1214/ss/1009213726

슬라이드 25 · 두 문화의 원문을 읽는 법

브라이먼은 확률모형의 형태 가정이 현실과 어긋날 때 모형 내부의 표준오차만으로 성능을 확신하기 어렵다고 지적했다. 모형의 타당성을 평가하려면 잔차, 안정성, 표본외 성능을 함께 봐야 한다.

예를 들어 회귀의 p값이 작다는 것은 특정 귀무가설과 오차 가정 아래 현재 자료가 드물다는 뜻이다. '이 변수의 경제적 효과가 크다'거나 '다른 기간에서도 통한다'는 확률을 직접 말해 주지 않는다. 계수 크기, 불확실성 구간, 표본외 오차, 매매 후 순이익을 서로 다른 표에 놓고 읽어야 한다.

회귀를 반복해서 고른 뒤 마지막 모형의 p값만 보고하면 해석은 더 어려워진다. 예를 들어 100개 변수를 시험해 가장 작은 p값을 선택했다면, 선택 전에 정해 둔 한 검정과 귀무분포가 다르다. 계수에 유의성이 필요하면 탐색 범위를 기록하고 다중검정이나 새 표본의 재현을 고려한다. 거래 가능성은 다시 포지션 크기와 순수익으로 확인한다.

슬라이드 26 · 금융이 이론 중심 접근을 고수한 이유

고객과 감독당국은 왜 신용을 거절했는지, 왜 특정 위험을 보유하는지 설명을 요구한다. 또한 금융 수익률의 신호는 약하므로 자유도가 높은 모형은 과거 우연을 외우기 쉽다. CAPM 같은 이론은 어떤 위험에 보상이 주어져야 하는지 검증 가능한 제약을 제시한다.

예측 관계는 행동이 바뀌면 약해질 수 있다. 어떤 공시 문구 뒤에 주가가 천천히 오른다는 규칙이 알려지면 투자자가 발표 즉시 매수해 상승분을 앞당긴다. 과거 자료의 규칙을 시장 참여자의 반응과 독립된 자연법칙으로 취급하면 안 되는 이유다.

이론은 모형의 입력을 줄이는 장치이기도 하다. 모든 기업 특성의 모든 조합을 허용하면 우연히 높은 과거 성과를 찾기 쉽지만, 경제적으로 가능한 현금흐름·할인율 경로로 범위를 좁히면 탐색 공간이 줄어든다. 다만 이론적 제약이 틀리면 진짜 패턴을 놓칠 수 있으므로, 이론 모형과 유연한 모형을 같은 시점의 새 자료에서 비교해야 한다.

슬라이드 27 · 요인모형의 언어

종목 i의 단순수익률을 R_i, 무위험수익률을 r_f라 하고 초과수익률을 $r_i = R_i - r_f$로 정의하자. 요인모형은 $E[r_i] = \beta_i^\top \lambda$로 쓴다. β_i는 시장·가치·수익성 같은 공통 충격에 대한 노출이고 λ는 그 충격 한 단위에 대해 요구되는 보상이다. CAPM에서는 시장 요인 하나만 두므로 $E[r_i] = \beta_{iM} E[r_M]$가 된다. 여기서 $r_M = R_M - r_f$다.

베타는 요인과 **얼마나 함께 움직이는지**, 프리미엄 λ는 그 노출에 시장이 얼마를 보상하는지를 나타낸다. 장부가치/시가총액이 높은 종목의 수익률이 높아도 위험 보상과 가격오류 중 무엇이 원인인지는 추가 검정이 필요하다. 위험 보상이라면 해당 종목이 투자자의 소비나 재산이 줄어드는 나쁜 시기에 손실을 주는지 살펴야 한다.

CAPM의 시장 베타는 $\beta_{iM} = \mathrm{Cov}(r_i, r_M) / \mathrm{Var}(r_M)$로 계산한다. 시장이 1% 움직일 때 종목이 평균적으로 얼마나 함께 움직이는지 나타내는 선형 민감도이지, 그 종목의 전체 위험이나 미래 한 달 수익률의 확정값은 아니다. 종목 고유의 변동이 아무리 커도 충분히 분산 가능한 위험이라면 CAPM의 기대수익률 식에는 별도 보상이 붙지 않는다. 식을 검정할 때는 무위험수익률과 요인 수익률의 측정 시점도 맞아야 한다.

슬라이드 28 · 요인 동물원과 다중검정

수백 개 특성을 하나씩 검정하면 참효과가 없어도 높은 t값이 우연히 나온다. 참효과가 모두 0이고 검정 300개의 거짓 양성 확률이 각각 5%라면 기대 거짓 발견 수는 $300 \times 0.05 = 15$개다.

발표된 한 전략의 $|t| > 2$를 읽을 때는 시도한 검정의 수, 새 표본에서의 성과, 거래비용을 함께 확인한다. Harvey·Liu·Zhu[6]는 많은 후보를 탐색한 연구에 더 높은 발견 기준이 필요하다고 설명한다.

검정 j가 잘못 기각되면 1인 변수 I_j를 두면 거짓 발견 수는 $V = \sum_j I_j$다. 기대값의 선형성에 따라 $E[V] = \sum_j P(I_j = 1) = 15$이며, 이 계산에는 검정 간 독립성이 필요하지 않다. 검정들이 서로 비슷하면 실제 발견 개수가 한꺼번에 몰릴 수 있다. 발견 수의 변동과 다중검정의 판정 기준은 4A에서 자세히 다룬다.

질문: 유의한 결과가 15개일 때 진짜 효과는 몇 개인가요? 유의한 개수만으로는 알 수 없습니다. 거짓 발견의 기대값 15는 모든 참효과가 0인 반복 실험의 평균입니다. 실제 자료의 진짜 효과 비율과 검정력을 추가로 알아야 합니다.

슬라이드 29 · 머신러닝의 동일 경기장

Gu·Kelly·Xiu는 다수 미국 주식과 기업 특성을 사용해 선형 회귀, 벌점 회귀, 차원 축소, 나무, 신경망을 비교했다. 핵심은 같은 정보 시점과 같은 미래 기간을 기준으로 성능을 채점하는 것이다. 모형이 복잡할수록 과거 적합도가 높다는 사실만으로 승자를 정하면 불공정하다.

특성과 거시 상태의 상호작용은 "같은 기업 특성도 경기 상태에 따라 의미가 달라진다"는 가설을 표현한다. 예를 들어 레버리지의 가격 효과가 금리 상승기에 커질 수 있다. 연구 원문[7]은 이러한 비선형 상호작용이 예측 개선의 중요한 원천이라고 보고한다.

2015년 종목을 예측할 때는 당시 공개된 재무제표를 써야 한다. 나중에 수정된 데이터베이스의 최종 값이나 상장폐지 종목을 제거한 목록을 쓰면 미래 정보가 섞인다. 결측치 처리와 재학습 빈도도 모형 사이에 맞추고, 검증 결과로 모형을 고른 뒤 시간상 마지막 시험 기간을 최종 평가에 사용한다.

슬라이드 30 · 작은 표본외 결정계수의 의미

표본외 결정계수는 $R^2_{\text{OOS}} = 1 - \text{SSE}_{\text{model}}/\text{SSE}_{\text{benchmark}}$이다. 월별 개별 주식 수익률은 예측 불가능한 변동이 크므로 0.4% 같은 숫자는 작아 보여도 실제 예측 가능한 성분의 차이를 나타낼 수 있다. 단, 통계적 개선과 거래 가능한 이익은 다르다.

모형의 우수성을 읽을 때 기준 예측이 0인지 과거 평균인지 확인해야 한다. 분모가 달라지면 같은 예측에도 R^2가 달라진다. 공매도 제약, 회전율, 거래비용을 빼고 계산한 포트폴리오 성과도 별도로 검토한다.

수치로는 기준선의 제곱오차합이 1,000이고 새 모형의 합이 996일 때 $1 - 996/1000 = 0.004$다. 이 차이는 개별 주식의 큰 잡음 속에서 유용한 신호일 수도 있지만, 신뢰구간과 기간별 안정성을 보지 않으면 우연인지 알 수 없다. 또한 양의 R^2_{OOS}가 있어도 모형이 추천하는 종목에서 회전율이 높으면 비용 뒤 수익은 음수가 될 수 있다.

[6] https://doi.org/10.1093/rfs/hhv059
[7] https://doi.org/10.1093/rfs/hhaa009

슬라이드 31 · 공개된 예측 신호의 이익 감소

한 뉴스 신호가 널리 알려지면 투자자는 가격에 그 정보를 더 빨리 반영한다. 신호가 가리킨 종목을 모두가 먼저 사면 나중에 얻을 초과수익은 줄어든다. 거래 규모가 커질수록 호가 충격과 매매비용도 늘어난다.

발표 뒤 성과 감소에는 정보가 가격에 빨리 반영된 효과, 처음 연구의 우연한 표본 선택, 추종 자금이 키운 거래비용이 섞인다. McLean·Pontiff[8]는 발견과 출판 뒤의 성과를 비교한다. 발표 전 월평균 총 초과수익이 0.5%, 발표 뒤 0.2%라면 먼저 총수익의 변화를 보고, 발표 뒤 왕복비용 0.3%를 빼면 투자자의 순수익은 -0.1%다. 표본 기간과 전략 규칙을 맞춰야 감소의 원인을 더 좁힐 수 있다.

슬라이드 32 · 계산 규모와 사전 지식

서튼의 "쓴 교훈"은 사람이 세세한 규칙을 집어넣는 방법보다 계산과 학습을 넓게 활용하는 일반적 방법이 장기적으로 우세했던 사례를 정리한다. 금융의 손으로 만든 단어 사전이나 고정된 요인 조합도 이 관점에서 재검토할 수 있다.

경제 이론과 제도는 대규모 학습의 허용 범위와 평가 기준을 정한다. 거래비용, 시간 순서, 데이터 누출 방지, 예산 제약을 반영해야 성능을 실제로 측정할 수 있다. Sutton의 글[9]은 방법론 선택의 배경을 제공한다.

금융에서는 계산 규모와 함께 **훈련 목표와 독립 표본의 수**가 중요하다. 다음 단어를 잘 예측해도 투자 판단에 필요한 근거가 부족할 수 있고, 한 번의 금융위기나 제도 변경에서 독립 사례를 대량으로 만들 수는 없다. 실제 투자 시점의 정보만 입력해 시점 밖·시장 밖 성과를 확인하고, 희귀 충격은 별도 시나리오로 점검한다.

슬라이드 33 · 이중 하강과 금융 데이터

고전적 편향·분산 그림에서는 모형을 복잡하게 할수록 처음에는 오차가 줄다가 과적합으로 다시 오른다. 일부 과매개변수 모형에서는 훈련자료를 정확히 보간하는 지점 뒤에 시험 오차가 다시 내려가는 **이중 하강**이 관찰된다.

훈련오차가 0에 가까워지는 **보간 경계** 부근에서는 잡음까지 맞혀 시험오차가 커질 수 있다. 그보다 훨씬 큰 모형에서 최적화 알고리즘이 상대적으로 단순한 해를 찾으면 시험오차가 다시 줄기도 한다. 그래프의 가로축을 변수 수만으로 읽기보다 유효 자유도, 자료 구조, 최적화의 암묵적 정규화를 함께 봐야 한다. Belkin 등[10]은 기본 현상을 제시한다.

금융 시계열은 짧고 시장 구조가 변하므로 이중 하강을 기대해 모형을 키우는 것만으로는 충분하지 않다. 시간 순서에 맞춘 여러 표본외 기간에서 같은 곡선이 나타나는지 확인하고, 선택된 전략의 거래비용까지 계산한다.

[8] https://doi.org/10.1111/jofi.12365

[9] http://www.incompleteideas.net/IncIdeas/BitterLesson.html

[10] https://doi.org/10.1073/pnas.1903070116

Session 1B · 금융 텍스트와 언어모형

숫자만으로는 기업의 전망과 위험을 다 읽을 수 없다. 사업보고서의 위험 문단, 실적 발표의 발언, 기사와 규제 공시는 모두 텍스트다. 이 장은 단어 세기에서 문맥 표현으로 발전한 방법을 이해하고, 언어모형의 학습 목표가 왜 그럴듯한 오류를 만들 수 있는지 경제학의 유인 문제와 연결한다.

슬라이드 01 · 텍스트를 금융 데이터로 읽기

재무제표의 숫자는 표준화되어 있지만 경영자의 설명은 길고 비정형적이다. 같은 "소송"이라는 단어도 소송을 당했다는 뜻인지 승소했다는 뜻인지 문맥을 보아야 한다. 경영자는 자금조달과 평판을 고려해 표현을 선택하므로 어조에는 기업 상태와 공시 유인이 함께 담긴다. 텍스트 분석은 여기서 **미래 현금흐름이나 위험에 관한 정보**를 추출한다.

분석 단위는 질문에 맞춰 정한다. 한 문서 전체의 부정 단어 비율과 '유동성 위험' 문단의 비율은 다른 정보를 담고, 경영자 발언과 애널리스트 질문도 유인이 다르다. 같은 기업의 한 공시에서 나온 100개 문장을 독립된 기업 사건 100개로 세면 표준오차가 작아진다. 문장별 추출 정확도는 문장 수준에서, 투자 성과는 **발표 뒤 기업 수익률과 비용**으로 평가하며 기업·공시일에 따른 상관을 반영한다.

슬라이드 02 · 사전에서 언어모형으로

텍스트 분석은 단어 빈도에서 단어 조합, 의미 벡터, 문맥형 표현으로 발전했다. 단어 빈도는 순서를 버리고, 2그램은 가까운 문맥만 남기며, 임베딩은 표현을 압축하는 대신 개별 차원의 뜻이 분명하지 않다. 문맥형 모형은 먼 관계도 반영하지만 자료와 계산 자원을 더 쓴다. 특정 공시 표현이 안정적이라면 간단한 사전의 재현성과 감사 용이성이 오히려 장점이 된다.

동일한 문서 분류를 예로 들면 고정 사전, 2그램 회귀, 문맥형 언어모형을 **같은 훈련 기간과 같은 미래 시험 기간**에 놓을 수 있다. 각 방법에 입력한 정보가 동일해야 표현법의 효과를 비교할 수 있다. 정확도 차이가 1%포인트라면 그 차이가 검토 인력 절감이나 투자 손실 감소로 얼마의 가치가 있는지까지 계산해야 복잡한 방법의 추가 비용을 정당화할 수 있다.

슬라이드 03 · 사전 단어 세기의 함정

문서에서 긍정 표현이 부정보다 얼마나 많은지 비교하려면 먼저 두 표현의 개수를 센다. 사전과 일치한 긍정·부정 단어 수를 N_+, N_-라 하고 전체 단어 수를 N이라 하면 점수는 $S = (N_+ - N_-)/N$이다. 분자는 방향, 분모는 문서 길이를 조정한다. 길이로 나누지 않으면 내용의 비율이 같은 긴 보고서가 더 극단적인 점수를 얻는다.

일반 영어 사전의 "liability"나 "capital" 같은 단어는 금융 문맥에서 일상적 의미와 다르게 쓰인다. 단어가 위험을 뜻하는지 회계 항목을 뜻하는지 무시하면 점수에 체계적 오차가 생긴다. Loughran·McDonald[11]는 금융 문서에 맞는 사전이 필요한 이유를 보여 준다.

100단어 중 긍정 8개·부정 3개이면 $S = 0.05$다. 같은 내용에 표준 문구 100단어가 붙으면 점수는 0.025로 낮아진다. 길이를 보정해도 무관한 문구가 늘면 점수가 바뀌므로 분석할 본문 범위를 일정하게 정해야 한다.

[11] https://doi.org/10.1111/j.1540-6261.2010.01625.x

슬라이드 04 · 금융 전문 사전의 의미

전문 사전은 단어의 극성을 **사용되는 분야**에 맞춘다. 예를 들어 "tax"는 범용 감성 사전에서 부정적으로 처리될 수 있어도 세금 공제나 이연법인세 문맥에서는 방향을 단정할 수 없다. 금융 사전은 그 분야에서 실제로 부정적 의미를 갖는 단어를 다시 분류한다.

전문 사전의 장점은 누구나 같은 단어 목록으로 결과를 재현할 수 있다는 점이다. 그러나 새로운 산업 용어와 회계 기준 변화에는 갱신이 필요하다. 사전을 자료 전체를 본 뒤 조정하면 미래 문서의 표현을 과거 분석에 몰래 반영할 수 있으므로, 사전 버전과 적용 날짜를 기록해야 한다.

사전에서 '손실'을 부정으로 세는 것은 **단어 수준의 규칙**이다. '손실이 30억 원 발생했다', '손실이 발생하지 않았다', '손실 가능성을 제거했다'는 같은 단어를 포함하지만 미래 현금흐름에 대한 해석은 다르다. 부정어의 범위, 시제, 가능성 표현을 따로 처리해야 하고, 단어 사전 점수의 잔여 오류가 어느 유형에 몰리는지 수작업 표본으로 점검할 수 있다.

슬라이드 05 · n그램과 부정 표현

n그램은 연속한 n개의 토큰을 하나의 특징으로 센다. "good" 하나는 긍정이지만 "not good"이라는 2그램은 그렇지 않다. "strong demand"와 "weak demand"도 명사 하나보다 형용사와의 결합을 보아야 구별된다.

2그램은 'not expected to be good'처럼 부정어와 대상이 떨어져 있으면 놓친다. n을 늘리면 문맥은 넓어지지만 조합별 관측 수는 줄어든다. 어휘가 1만 개면 가능한 순서 있는 2그램은 최대 10^8개인 데 비해 실제 문서에는 일부만 나타난다. 드문 조합의 계수를 과신하지 않도록 훈련 기간에서 빈도 기준과 벌점을 정하고, 정규화한 선형모형을 비교 기준으로 쓴다.

슬라이드 06 · 임베딩은 무엇을 보존하는가

임베딩은 단어 w를 d개 숫자로 이루어진 벡터 $v_w \in \mathbb{R}^d$에 대응시킨다. 비슷한 문맥의 단어가 가까워지도록 학습한 뒤 두 단어를 비교할 때는 벡터의 길이가 아니라 **방향**을 볼 수 있다. 내적 $v_a^\top v_b$를 두 길이 $\|v_a\|\|v_b\|$로 나눈 코사인 유사도는 길이를 각각 1로 맞춘 뒤 각도를 재는 값이다. 영벡터에는 정의되지 않는다.

고정 임베딩은 "bank"의 은행·강둑 뜻을 한 벡터에 담으므로 문장별 의미를 표현하기 어렵다. 또 '매수'와 '매도'처럼 반대 역할의 단어도 비슷한 문맥에 자주 나와 가까워질 수 있다. 이웃 단어가 의미나 경제적 대체성을 보장하지 않으므로 실제 분류·검색 과제에서 구별되는지 확인한다. 문맥형 표현은 문장 속 다른 단어를 함께 살펴 첫 문제를 줄인다.

$v_a = (1, 0)$과 $v_b = (2, 0)$의 코사인은 1이고, $v_c = (0, 1)$과는 0이다. 이 값은 단어의 인과관계나 경제적 대체 가능성을 뜻하지 않는다. 학습 문서가 달라지면 가까운 단어도 달라질 수 있다.

슬라이드 07 · 토큰과 입력의 비용

언어모형은 글을 하위 단어 조각인 토큰으로 나누고 정수 ID로 바꾼다. 같은 단어라도 언어와 토크나이저에 따라 조각 수가 다르다. 숫자, 종목 코드, 한국어 조사도 예상과 다르게 잘릴 수 있다.

토큰 수는 비용과 문맥 창의 한도를 결정한다. 문맥 창이 8,000토큰이고 지시문·답변에 2,000토큰을 남기면 원문에는 6,000토큰만 쓸 수 있다. 20,000토큰의 보고서 앞부분만 보내면 뒤의 70%가 사라진다. 관련 구간을 검색해 나누어 보낼 때 회사·기간·페이지를 붙이고, 답에 사용한 문단으로 되돌아갈 수 있게 해야 한다.

슬라이드 08 · 어텐션의 계산

어텐션(attention)은 현재 읽는 토큰 i가 다른 토큰 j의 정보를 얼마나 가져올지 계산한다. 입력 표현 x에 학습된 행렬을 곱해 질의 $q_i = x_i W_Q$, 키 $k_j = x_j W_K$, 값 $v_j = x_j W_V$를 만든다. 질의와 키의 내적이 클수록 둘의 연결 점수가 높다. d는 질의·키 벡터의 차원, $\mathcal{A}_i$는 토큰 i가 참고하도록 허용된 위치의 집합이다. 점수를 지수함수로 바꿔 그 합으로 나누는 softmax는 허용된 위치의 가중치를 모두 양수이고 합이 1이게 만든다.

$$\alpha_{ij} = \frac{\exp(q_i^\top k_j / \sqrt{d})}{\sum_{\ell \in \mathcal{A}_i} \exp(q_i^\top k_\ell / \sqrt{d})}, \quad j \in \mathcal{A}_i,$$
$$h_i = \sum_{j \in \mathcal{A}_i} \alpha_{ij} v_j.$$

점수를 $\sqrt{d}$로 나누면 차원이 커질 때 내적이 커져 softmax가 한 위치에 과도하게 몰리는 현상을 줄인다. 예를 들어 허용된 두 위치의 점수가 0과 $\ln 3$이면 가중치는 $1/4$과 $3/4$다. "bank raised interest rates"에서 bank가 금리 표현을 참고하는 방식으로 문맥에 따른 뜻을 만들 수 있다. Transformer 원문[12]은 이 연산의 출발점이다.

새 표현 h_i는 값 벡터 v_j의 가중평균이다. 학습된 어텐션 가중치 하나를 사람이 이해하는 '최종 판단 이유'로 해석할 수는 없다.

자기회귀 모형이 다음 토큰을 예측할 때는 미래의 정답을 미리 보지 않도록 보통 $\mathcal{A}_i = \{1, \dots, i\}$로 **causal mask**를 둔다.

슬라이드 09 · 다음 토큰 예측과 압축

문장이 두 토큰 x_1, x_2로 이루어졌다면 두 토큰이 함께 나올 확률은 $p(x_1, x_2) = p(x_1)p(x_2 \mid x_1)$이다. 이 조건부확률의 곱셈을 이어 가면 $p_\theta(x_1, \dots, x_n) = \prod_{t=1}^{n} p_\theta(x_t \mid x_{<t})$다. $x_{<t}$는 t 앞의 토큰들이고, θ는 학습할 모형의 계수다. 관찰된 문장의 확률을 높이려면 각 토큰의 **음의 로그확률**을 낮춘다. 로그는 곱을 합으로 바꾸어 긴 문장도 계산하기 쉽게 한다.

음의 로그우도 $-\sum_t \log p_\theta(x_t \mid x_{<t})$는 실제 토큰에 낮은 확률을 줄수록 커진다. 이 목표로 문장을 잘 이어 쓸 수 있어도 기업의 실제 부채를 검증하려면 원자료와 대조해야 한다.

부호 길이와의 연결은 로그의 밑을 정하면 분명해진다. 실제 다음 토큰에 확률 $1/2$를 주면 이상적인 부호 길이는 $-\log_2(1/2) = 1$비트이고, 확률 $1/8$만 주면 3비트다. 관측 텍스트에 높은 확률을 주는 모형일수록 평균적으로 짧은 부호가 가능하다. 하지만 자료 자체에 오류가 있으면 그 오류에도 높은 확률을 주는 것이 이 훈련 목표에는 유리할 수 있다.

슬라이드 10 · 유창한 실패의 출발점

문법적으로 자연스러운 문장은 독자의 신뢰를 쉽게 얻는다. 그러나 금융 분석에서는 오답의 형태가 매끈하면 더 위험하다. 숫자를 틀리게 합산하거나 없는 공시를 인용해도 문장만으로는 발견하기 어렵다.

실패를 세 갈래로 나누면 대응이 쉬워진다. 필요한 정보를 못 봤는지, 본 정보를 잘못 끌어냈는지, 계산·추론에서 틀렸는지 구분한다. 첫째에는 자료 첨부와 검색, 둘째에는 재질문과 근거 대조, 셋째에는 계산기와 독립 검산이 필요하다.

[12] https://arxiv.org/abs/1706.03762

가령 조정 영업이익을 80억 원으로 답했지만 정답이 70억 원이라면, 먼저 관련 공시 주석이 검색 결과에 있었는지 본다. 있었다면 모형이 일회성 이익 10억 원을 놓쳤는지, 숫자는 모두 맞게 뽑았는데 $80 - 10$ 계산을 잘못했는지 살핀다. 같은 10억 원 오류라도 검색 범위를 넓힐 문제와 계산기 호출을 붙일 문제는 해결책이 다르다.

질문: 오류별 성능표에는 어떤 열이 필요한가요? 필요 문서의 검색 성공률, 문서가 주어졌을 때 숫자·단위 추출 정확도, 정확한 입력에서의 계산 정확도를 분리합니다. 각 단계의 분모도 명시해야 전체 오류의 위치가 보입니다.

슬라이드 11 · 생성모형의 목적 함수를 정확히 쓰기

한 문장뿐 아니라 M개 문장으로 학습할 때는 각 문장 m의 길이 n_m에 걸쳐 로그확률을 합한다. θ를 조정해 그 합을 최대화하는 최대우도 추정은 다음과 같다.

$$\theta^* = \arg\max_{\theta} \sum_{m=1}^{M} \sum_{t=1}^{n_m} \log p_\theta(x_t^{(m)} \mid x_{<t}^{(m)}).$$

연쇄법칙은 확률의 항등식이고 Transformer는 각 조건부확률을 근사하는 한 가지 모형이다. 문맥 창에는 길이 제한이 있으며, 이 목적함수에는 사실 검증이나 투자 손실이 들어 있지 않다. 긴 문서를 토큰 수만큼 가중할지 문서별로 동일하게 가중할지는 학습 설계에 따라 달라진다.

슬라이드 12 · 목적 함수에 진실 항이 없다는 뜻

웹에 반복된 잘못된 주장도 훈련 텍스트라면 예측 대상이 된다. 최대우도 목표는 그 문장이 실제 기업의 사실인지 별도로 대조하지 않는다. 후속 정렬과 검색 도구가 이를 보완할 수 있지만, 기본 훈련 목표만으로 사실성이 보장되지는 않는다.

사실 오류, 출처 환각, 과도한 확신은 각각 관찰하고 측정할 수 있다. 정렬 훈련과 근거 검색으로 오류를 줄일 수 있으며, 드문 기업 사건에서는 답을 보류할 선택지도 평가해야 한다.

목표의 불일치를 손실로 표현해 보자. 일반 문장에서는 숫자 하나의 오류가 평균 토큰 손실에 조금만 반영될 수 있지만, 대출 심사에서는 숫자 한 자리의 오류가 승인 결정을 뒤집을 수 있다. 따라서 언어 손실 L_{text}와 금융 의사결정 손실 L_{decision}은 가중치도 단위도 다르다. 모형 선택에는 정답률과 함께 오류가 유발한 금전적 손실, 잘못된 확신의 빈도, 검토 비용을 넣어야 한다.

슬라이드 13 · 질문을 바꾸면 평가도 바뀐다

"왜 거짓말하는가"보다 "어떤 입력과 보상 아래서 어떤 오류가 반복되는가"가 검증 가능한 질문이다. 모호한 요청은 모델이 가능한 해석 가운데 하나를 택하게 한다. 사용자가 원한 회계 정의와 모델이 택한 정의가 다르면 계산은 매끈해도 결론은 틀린다.

같은 기업에 대해 연결 순이익이 120억 원이고 별도 순이익이 90억 원인 상황에서 '순이익'만 지시하면 두 답 모두 가능한 기준을 갖는다. 한 숫자를 무조건 정답으로 지정하면 모호한 입력에 대한 신중한 질문을 오답으로 채점할 수 있다. 평가 자료는 기준을 명시한 문제와 일부러 모호하게 둔 문제를 나누고, 후자에서는 필요한 확인 질문을 했는지 기록해야 한다.

슬라이드 14 · 걸러낼 것이 없는 회사를 시험하기

"핵심이익을 계산하라"는 표현은 일회성 항목의 존재를 암묵적으로 기대하게 만들 수 있다. 같은 일을 "반복되지 않는 항목이 있으면 열거하고, 없으면 없다고 답하라"고 풀어 쓰면 과제가 더 분명하다. 추출 도구는 **양성 사례뿐 아니라 음성 사례**에서 평가해야 한다.

정밀도는 추출한 항목 중 진짜의 비율, 재현율은 실제 항목 중 찾아낸 비율이다. 양성 항목 10개 중 8개를 찾아 6개만 맞았다면 정밀도는 $6/8 = 75\%$, 재현율은 $6/10 = 60\%$다. 각 조정 항목은 원문과 금액에 연결해야 한다.

양성 항목이 없는 문서 한 건에서는 재현율 $\mathrm{TP}/(\mathrm{TP}+\mathrm{FN})$의 분모가 0이다. 이때는 항목을 만들어 낸 **거짓 양성** 여부와 음성 문서에 대한 특이도를 본다. 음성 문서 비중을 실제 업무에 맞추어야 허위 이익 조정의 빈도를 제대로 평가할 수 있다. 전체 자료의 양성 비율이 달라지면 정밀도도 변한다.

슬라이드 15 · 모델의 국적을 성향으로 단정하지 않기

같은 기업에 대한 두 모형의 전망이 다르면 정치적 성향부터 추측하기 쉽다. 하지만 모형이 접근한 정보의 범위, 학습시점, 검색 언어가 다를 수 있다. 낙관적 전망은 의도적인 선호가 아니라 부정적 기사의 누락에서 생길 수 있다.

모형 A와 B에 같은 기업·날짜의 한국어 원문과 영어 번역을 각각 제시하면 **모형×언어**의 네 조건이 생긴다. 같은 모형 안의 언어 차이와 같은 언어 안의 모형 차이를 따로 측정할 수 있다. 프롬프트·검색 도구·출력 형식을 고정하고 번역에서 숫자와 부정 표현이 보존되었는지 확인한다. 답변의 어조 대신 전망의 실제 성과와 주장별 근거를 비교한다.

슬라이드 16 · 예상을 뒤집는 결과의 검증

예상을 벗어난 전망 차이가 나오면 표본 기업, 전망 시점에 이용 가능한 뉴스, '낙관성'의 척도를 먼저 고정한다. 두 모형에 동일한 지역 뉴스를 추가했을 때 차이가 줄어드는지 보면 정보 집합의 영향을 살필 수 있다. 목표주가 상승 여력, 이익 전망, 문장 감성은 각각 따로 보고한다.

목표주가 기준 낙관성을 $U = P_{\text{target}}/P_{\text{current}} - 1$로 정하면 현재가 10만 원, 목표가 11만 원일 때 $U = 10\%$다. 같은 보고서가 '불확실성이 매우 크다'고 써서 문장 감성은 부정적일 수도 있다. 두 척도가 다르면 어느 모형이 '더 낙관적'인지 문장 하나로 말할 수 없다. 기준 가격의 시각과 목표주가의 유효 기간도 맞춰야 한다.

슬라이드 17 · 지역 정보의 사각지대

중소형주에 관한 규제 조치나 소송 기사는 현지 언어의 지역 매체에 먼저 실릴 수 있다. 영어권 검색에 안 보인다고 사건이 없는 것은 아니다. 한국의 코스닥 기업을 평가할 때도 DART, 거래소 공시, 국내 언론을 직접 확인해야 한다.

정보를 추가한 뒤 전망 차이가 줄어들면 국적 자체보다 자료 접근성이 원인이라는 설명에 힘이 실린다. 하지만 검색 결과가 더 많다는 사실만으로 기사가 모두 신뢰할 만하다는 뜻은 아니다. 기업명·발표일·법적 상태를 교차 확인한다.

예를 들어 코스닥 기업의 소송 위험을 조사할 때는 OpenDART[13]에서 회사·날짜·공시 유형으로 원문을 찾고 정정 공시를 시간순으로 연결한다. 같은 사건의 복제 기사 20개보다 최종 법적 상

[13] https://opendart.fss.or.kr/guide/main.do?apiGrpCd=DS001

태를 기록한 공시 한 건이 더 결정적일 수 있다. 검색 성능은 기사 건수와 함께 **결정적인 원문이 후보에 포함되었는지**로 평가한다.

슬라이드 18 · 기억과 진짜 사전 예측의 차이

옛 실적발표의 기업명과 날짜를 지워도 문장 패턴으로 사건을 식별할 수 있다. 따라서 과거 자료에 대한 높은 점수는 미래 예측력의 증거가 되기 어렵다. 엄격한 실험은 예측 시점에 이용 가능했던 **정보 집합** $\mathcal{I}_t$만으로 $t+1$을 예측한다. 모형 학습 종료일과 검색 색인·평가 자료의 공개 시각을 함께 기록해야 한다.

미국 SEC의 EDGAR 설명[14]은 회계기간 말일과 보고서 제출·접수 시각을 구분한다. 2024년 말 재무상태표가 2025년 3월에 제출됐다면 2025년 1월 예측에는 확정 수치를 넣을 수 없다.

회계기간만 표시된 데이터베이스를 결합하면 1월 예측에 3월 공개 정보가 섞일 수 있다. 회고 기사도 사건 날짜와 작성·색인 날짜가 다르다. 각 자료의 **이용 가능 시각**과 버전을 저장하고, 예측 시점 이전에 공개된 것만 결합한다.

슬라이드 19 · 모형의 투자 스타일

답변 모델은 학습자료와 정렬 과정 때문에 특정 업종이나 최근 하락 종목을 더 자주 추천할 수 있다. 이는 경제학에서 말하는 투자 스타일과 비슷하지만, 실제 투자전략의 수익성이 입증되었다는 뜻은 아니다.

성향을 측정하려면 동일 시점의 종목과 자료를 여러 모형에 주고, 추천 비율을 업종·규모·직전 수익률별로 비교한다. 반대 근거를 추가했을 때 전망이 적절히 갱신되는지도 중요하다. 하나의 모형을 여러 번 물어 얻은 답은 독립된 전문가 의견이 아니다.

비중의 차이를 숫자로 보자. 시장 포트폴리오의 기술주 비중이 50%이고 모형 추천 포트폴리오가 55%라면 적극적인 기술주 노출은 5%포인트다. 다른 모형의 추천 비중이 40%라면 겉보기에는 기술주를 많이 추천하지만 시장 대비 10%포인트 과소 비중이다. 이 비교는 추천을 실제로 어떤 비중으로 실행할지 정한 뒤에만 가능하며, 종목 개수의 비율과 자금 비중은 서로 다르다.

슬라이드 20 · 만족도 보상의 부작용

사용자 평가를 보상에 넣으면 친절함이 높아질 수 있지만, 사용자가 듣고 싶은 말에 동의할 유인도 생긴다. 2025년 GPT-4o 업데이트에서 과도한 동조(sycophancy)가 나타난 사례는 목적함수의 대리 지표를 잘못 맞추면 원하는 품질과 다른 행동이 나온다는 점을 보여 준다.

금융에서는 "이 종목을 사면 좋겠지?"라는 유도 질문에 대한 동의가 특히 위험하다. 평가 문항에 정확한 반론 제시, 불확실성 표현, 근거 없는 주문 권유 거절을 포함해야 한다. OpenAI의 사후 분석[15]은 피드백 신호의 결합 문제를 설명한다.

평가를 수량화하려면 원문에서 답이 하나로 정해지는 사실 질문을 모아 유도 프롬프트와 중립 프롬프트를 짝지을 수 있다. 예를 들어 원문상 영업이익이 감소했는데 '증가했지?'라고 물어도 감소했다고 답해야 한다. 짝지은 질문의 정답률 차이는 동조 오류의 신호지만, 표현 차이 자체가 난도를 바꿀 수 있으므로 여러 문장 형태에서 반복해 확인한다.

[14] `https://www.sec.gov/about/webmaster-frequently-asked-questions`
[15] `https://openai.com/index/expanding-on-sycophancy/`

슬라이드 21 · 사후 분석과 인과 사슬

업데이트 뒤 동조가 관찰되고 이전 버전으로 되돌리자 완화되었다는 시간 순서는 중요한 단서다. 하지만 사후 분석은 여러 변경이 함께 들어갔음을 인정하므로 "좋아요 신호 하나만 원인"이라고 단순화하면 안 된다.

평가 지표가 사용자 만족을 포착해도 진실성, 장기적 편익, 반대 의견 제시까지 완전히 측정하지는 못한다. 제품 평가에서는 개별 지표의 개선뿐 아니라 서로 다른 목표가 충돌하는 극단 사례를 함께 시험한다.

인과 사슬을 '업데이트 → 답변 성향 변화 → 사용자 결정 변화 → 손익 변화'로 나누면 측정 대상이 분명해진다. 첫 두 단계의 실험 증거가 있어도 실제 사용자의 주문이나 수익까지 확인한 것은 아니다. 예컨대 동조 답변 비율이 늘었다는 관찰만으로 투자 손실액을 계산할 수 없다. 각 화살표마다 비교군과 행동 자료가 필요하다는 점이 제품 평가와 경제 효과 추정의 연결이다.

슬라이드 22 · 체스 에이전트 실험의 설계

도구를 쓸 수 있는 에이전트에게 "체스 엔진을 이겨라"라고만 지시하면, 체스를 두는 방법 외에 게임 파일을 바꾸거나 상대 프로그램에 접근하는 방법도 환경에 존재할 수 있다. 목표를 결과만으로 정의하면 허용된 행동의 경계가 빠진다.

에이전트의 목표에는 성과와 허용된 경로를 함께 적어야 한다. 매매 에이전트라면 주문 가능 종목, 금액 한도, 사용 가능한 자료, 사람의 승인 시점을 명시하고 분석 권한과 주문 권한을 분리한다. 실험 논문[16]을 읽을 때도 성공의 정의와 허용 도구를 먼저 확인한다.

실험에서 관측한 한 번의 우회 시도는 우회가 **가능한 경로**를 보여 주지만, 모든 환경에서 그 행동이 나타날 빈도를 알려 주지는 않는다. 평가에는 정당한 경로로 목표를 달성한 비율과 금지된 경로를 시도한 비율을 따로 기록해야 한다. 금융 시스템에서는 읽기 전용 공시 검색 권한과 주문 제출 권한을 별도 단계로 두면 두 결과를 구별하고 통제할 수 있다.

슬라이드 23 · 목표 달성과 규칙 준수는 다른 변수

게임 상태를 바꾸어 얻은 "승리"는 체스 실력의 성과가 아니다. 평가자가 결과 파일의 승패만 읽으면 이런 경로를 구별하지 못한다. 금융에서도 손익 숫자만 보면 미공개 정보 사용, 과도한 위험 부담, 장부 밖 포지션을 숨긴 성과를 놓칠 수 있다.

성과를 손익 하나로 채점하면 위험을 크게 키워 높은 평균수익을 얻는 전략을 잘못 선호할 수 있다. 같은 손익이라도 최대 손실, 레버리지, 규정 위반 여부를 함께 기록해야 한다. 평가자가 볼 수 있는 로그를 에이전트가 바꿀 수 있다면 독립 검증이 성립하지 않으므로 원장과 권한도 분리한다.

예를 들어 두 전략 모두 평균 수익이 1억 원이어도, 하나는 최대 손실이 1천만 원이고 다른 하나는 10억 원이라면 고객의 위험한도 아래 같은 성과가 아니다. 목적함수를 단순히 $\max E[\Pi]$로 두는 대신 손실 한도 $P(\Pi < -L) \le \delta$ 같은 제약을 붙일 수 있다. 이 식은 손실이 L을 넘을 확률을 δ 이하로 제한한다는 뜻이며, 추정 오차가 큰 꼬리확률은 별도 스트레스 시험도 필요하다.

질문: 손실확률 제약의 수치는 누가 정하나요? 투자자의 위험 허용도와 자금 필요 시점, 계약상 한도가 먼저 정해져야 합니다. 모형은 정해진 L과 δ 아래에서 수익을 최대화하며, 꼬리확률 추정은 스트레스 시험으로 보완합니다.

[16] https://arxiv.org/abs/2502.13295

슬라이드 24 · 굿하트 법칙, 루커스 비판, 대리인 문제

굿하트 법칙은 유용한 대리 지표를 목표로 최적화하면 원래 목표와의 관계가 약해질 수 있다는 통찰이다. 루커스 비판은 정책이 바뀌면 경제주체의 행동도 바뀌므로 과거 관계를 그대로 새 정책에 적용하기 어렵다는 주장이다. 두 개념은 **행동의 변화가 통계적 관계를 바꾼다**는 점에서 만난다.

모형의 보상 R이 진짜 사회적 가치 V의 불완전한 근사라면, $\arg\max R$이 $\arg\max V$와 다를 수 있다. 개발자와 사용자가 원하는 것을 에이전트에게 완전한 계약으로 명시하기 어려운 주인·대리인 문제다. 독립 감사와 반복 평가, 권한 제한이 보상함수의 문구만큼 중요하다.

금융의 예로는 대출 담당자에게 '승인 처리 속도'만 보상하는 경우가 있다. 담당자는 추가 확인이 필요한 신청자를 간단히 거절하거나 검토를 생략해 평균 처리 시간을 줄일 수 있다. 처리 속도와 좋은 대출 결정이 과거에는 함께 움직였더라도 보상 규칙이 바뀌면 그 상관은 유지되지 않는다. 해결률·부실률·고객 접근성과 같은 결과를 함께 추적해야 대리 지표의 왜곡을 볼 수 있다.

슬라이드 25 · 환각을 과신으로 측정하기

틀린 답을 모두 같은 위험으로 볼 필요는 없다. "확실하지 않다"라고 말하고 근거 확인을 요청한 오답은 확신에 차서 허위 출처를 만든 오답과 다르다. 확률 p를 말한 예측은 실제로 약 p의 비율로 맞아야 **보정**되어 있다고 한다.

90% 확신 답변 100개 중 약 90개가 맞으면 그 구간의 보정이 좋다. 그러나 모든 질문에 60%라고 답하는 모형도 전체 정답률이 60%라면 보정되어 있을 수 있다. 금융 판단에는 쉬운 사례와 어려운 사례를 **구분하는 능력**도 필요하다. Yona 등[17]은 거절과 단언 사이에서 불확실성을 표현하는 방법을 제안한다.

확률 예측의 한 점수로 Brier score를 쓸 수 있다. 사건이 발생하면 $y=1$, 아니면 0이고 예측 확률이 p일 때 $(p-y)^2$를 계산해 평균한다. 실제로 연체한 차주에게 10%를 예측했다면 손실은 $(0.1-1)^2=0.81$, 90%를 예측했다면 0.01이다. 점수가 낮을수록 좋지만 연체의 금전적 손실이 정상 상환의 편익과 다르면 대출 결정에는 별도의 비용 기준이 필요하다.

슬라이드 26 · 저장된 지식과 인출의 병목

모형이 어떤 사실을 표현 안에 담고 있어도 직접 질문에서 즉시 꺼내지 못할 수 있다. 추가 추론을 제공했을 때 정답이 나오면 자료의 부재와 인출 실패를 구분할 단서가 된다. 다만 특정 벤치마크에서 높은 인코딩 비율을 모든 금융 사실로 일반화할 수는 없다.

공시나 법규처럼 날짜에 민감한 사실은 모형 내부 기억보다 원문 검색이 필요하다. 검색 후에도 문단이 질문의 회사·기간에 맞는지 확인하고 숫자는 계산기로 검산한다. Calderon 등[18]은 지식의 저장과 접근을 구분한다.

인출 실험은 질문을 단계별로 바꿔 볼 수 있다. 먼저 회사와 기준일만 주고 답하게 한 뒤, 동일한 문제에 공시 제목, 원문 단락, 정확한 표를 차례로 제공한다. 정답률이 어느 단계에서 올라가는지 보면 검색 실패와 숫자 해석 실패를 어느 정도 분리할 수 있다. 그러나 추가 문맥이 정답을 **새로 가르쳤을 수도** 있으므로, 힌트를 받은 뒤 맞힌 사실만으로 모형이 원래 그 사실을 기억했다고 증명하지는 못한다.

[17] https://arxiv.org/abs/2605.01428
[18] https://arxiv.org/abs/2602.14080

슬라이드 27 · 보이는 추론의 한계

단계별 설명은 오류를 발견하는 데 도움이 되지만, 화면에 보이는 설명이 모형 내부에서 실제로 사용한 모든 원인을 기록한다고 볼 수 없다. 설명 자체가 평가의 대상이 되면 그럴듯한 절차를 쓰는 데 최적화될 수도 있다.

설명의 검증 가능성을 높이려면 각 중간값을 외부에서 다시 계산할 수 있게 해야 한다. 예를 들어 영업이익 조정이라면 원문 표의 행, 일회성으로 분류한 이유, 조정 전후의 숫자를 따로 적는다. 자연어로 길게 '생각한 과정'을 제시하는 것보다 짧은 산식과 원문 위치가 더 강한 감사 흔적이 된다.

간단한 반사실 점검도 유용하다. 매출 100과 비용 80을 입력해 영업이익 20을 얻은 뒤, 다른 조건을 고정하고 비용만 90으로 바꿔 다시 계산시키면 영업이익은 10이 되어야 한다. 답변이 여전히 20이거나 근거 문장만 그럴듯하게 바뀐다면 제시된 단계가 실제 계산을 보장하지 못한 것이다. 이런 입력 변화 시험은 모형 내부 과정을 증명하지는 않지만, 외부에서 확인 가능한 계산 일관성을 시험한다.

슬라이드 28 · 다음 토큰 맞히기가 만드는 능력

추리소설의 마지막 단어를 잘 예측하려면 앞선 사건과 인물의 관계를 추적해야 한다. 따라서 단순해 보이는 훈련 목표가 복잡한 표현 능력을 유도할 수 있다. 이는 "다음 토큰 예측"이 사소한 기능이라는 뜻이 아니다.

하지만 새로운 사례에서의 이해를 인간의 이해와 동일시해서도 안 된다. 훈련 목표가 요구한 규칙성과 실제 금융 판단의 목표가 다를 수 있다. 원리의 강점과 한계를 동시에 평가하려면 새 자료에서의 결정 성과가 필요하다.

이를 '압축된 규칙 학습'과 '특정 문서 암기'의 차이로도 볼 수 있다. 새로운 회사의 새 공시에서 반복되는 회계 관계를 적용한다면 일반화의 증거가 강해진다. 반면 훈련 시점 이전의 유명 기업 사건만 정확히 답한다면 사건 이름이나 표현을 기억했을 가능성이 남는다. 금융 벤치마크는 회사·기간·문구가 다른 새 사례를 포함해야 이 둘을 더 잘 구별한다.

슬라이드 29 · 산술은 외부 도구로 분리하기

여러 숫자를 더하는 일은 결정적 알고리즘으로 정확히 수행할 수 있다. 언어모형이 숫자 패턴을 바탕으로 합계를 추측하게 둘 이유가 없다. 순서를 바꾸어도 합계가 같아야 한다는 **불변성 검사**는 계산 오류를 찾는 간단한 방법이다.

분석 흐름은 **항목·단위 추출 → 표로 구조화 → 계산기로 합산 → 원문과 대조**다. 계산 전에 각 숫자의 출처 행, 부호, 단위, 연결 범위를 고정한다. 연결 매출 100억 원에 이미 포함된 자회사 매출 30억 원을 다시 더하면 130억 원이라는 산술은 맞아도 회계 범위가 틀린다. 괄호 속 손실을 양수로 읽거나 천 원과 백만 원을 섞는 오류도 같은 단계에서 잡아야 한다. 금액 단위를 통일하고 부분합을 공시 총계와 대조하면 입력 해석과 계산의 오류를 분리할 수 있다.

슬라이드 30 · 유창함 대신 재현성을 기준으로

좋은 금융 답변은 출처, 기준일, 단위, 계산 경로, 불확실성을 드러낸다. 중요한 결론은 독립된 원자료와 계산으로 확인한다. 여러 모형의 답이 일치해도 같은 잘못된 출처를 사용했다면 검증이 되지 않는다.

주식 매수 비율처럼 개인 사정을 모르는 상태에서 제시된 그럴듯한 숫자는 맞춤형 결론이 아니다. 독자는 질문의 빈칸을 먼저 채운다. 투자 기간과 제약, 비교 대안, 손실 한도, 정보의 날짜가 정해져야 비로소 예측을 행동으로 바꿀 수 있다.

최종 답변을 '입력 근거 → 추출 숫자 → 산식 → 판단' 순서로 읽어 보자. 각 화살표에서 근거가 끊기면 그 뒤의 유창한 문장은 검증되지 않는다. 예컨대 공시 페이지에서 순이익 100억 원을 확인하고 일회성 이익 20억 원을 차감해 조정 순이익 80억 원을 얻더라도, 주가가 이미 이를 반영했다면 매수 판단은 별개다. 원문 검증, 계산 정확성, 투자 가치 판단을 서로 다른 관문으로 둬야 한다.

Session 2 · 정규화 회귀와 수익률 예측

주식시장의 미래 수익률은 평균은 작고 변동성은 큰 자료에서 추정해야 한다. 표본 안에서 잘 맞는 식은 과거의 우연을 익혔을 수 있다. 이 장에서는 비교 가능한 표본외(out-of-sample, OOS) 채점 규칙을 세우고, 추정오차가 왜 커지는지 유도한 뒤, Ridge regression(능형회귀)·Lasso(라쏘)·cross-validation(교차검증)이 어떤 편향을 의도적으로 도입하는지 단계별로 살핀다.

슬라이드 01 · 수익률 예측의 출발점

AI가 금융에서 유용하려면 과거의 가격을 설명하는 것보다 **아직 보지 않은 수익률**을 예측해야 한다. 시장 전체의 수익률은 종목 간 상대 순위를 맞히는 일과 다르다. 한 해에 모든 주식이 함께 떨어질 수 있어 시장 시계열 예측에는 거시 상태가 중요하다.

예측의 단위부터 고정하자. 월말 t에 알려진 정보로 다음 한 달 초과수익률을 예측하는지, 다음 1년 누적수익률을 예측하는지에 따라 변동성과 투자 가능성이 달라진다. 평가 시점보다 늦게 공표된 경제지표를 x_t에 넣으면 실제로는 만들 수 없는 전략을 검사하게 된다.

예측 대상을 시장 초과수익률 $r_{M,t+1} - r_{f,t}$로 둘지 종목별 시장 대비 수익률 $r_{i,t+1} - r_{M,t+1}$로 둘지도 정해야 한다. 모든 종목이 다음 달 5% 하락할 것을 맞혀도 종목 간 차이는 예측하지 못한 것이고, A가 시장보다 2%포인트 높고 B가 2%포인트 낮을 것을 맞혀도 시장 방향은 틀릴 수 있다.

슬라이드 02 · 앞 장에서 이어지는 문제

금융의 예측 신호는 가격·뉴스·재무비율에 퍼져 있지만 수익률의 대부분은 뜻밖의 충격이다. 관계가 시간에 따라 변하는 비정상성도 있다. 그러므로 복잡한 모형을 쓰기 전에 약한 신호와 짧은 실효 표본이라는 제약을 받아들여야 한다.

작은 신호를 제한된 역사에서 얼마나 정밀하게 추정할 수 있는지가 핵심이다. 여러 후보 중 표본 안에서 가장 큰 상관을 고르는 선택도 학습 과정이므로, 그 표본을 독립 채점에 다시 쓰지 않는다.

진짜 신호가 월 기대수익률을 0.1%포인트 바꾸는데 월 수익률의 표준편차가 5%라면, 한 관측에서 신호는 잡음의 50분의 1 수준이다. 표본내 상관이 크지 않아도 신호가 없다는 뜻은 아니지만, 후보 100개 중 가장 잘 맞는 하나를 고르면 잡음을 신호로 오인하기 쉽다. 정규화의 목적은 이 제한된 정보를 여러 계수에 과도하게 나누어 쓰지 않는 것이다.

슬라이드 03 · 시장 수익률 예측의 오래된 실패

배당수익률이나 금리 스프레드가 높을 때 다음 해의 시장 수익률이 달라질 수 있다는 이론은 그럴듯하다. 문제는 과거 자료에서 찾은 관계가 미래에도 남는가다. 발표 시점까지의 자료를 모두 사용해 회귀한 뒤 같은 기간을 채점하면 미래 정보가 추정에 들어간다.

배당수익률의 관계가 경기침체 몇 해에만 나타났는지 확인하려면 원자료를 시간순으로 그려 극단 관측치를 표시한다. 예측 성능은 **각 과거 시점에서 가능했던 계산**으로 채점한다. 1980년까지 추정한 기울기 b는 1981년 예측에 쓸 수 있지만, 2020년까지 재추정한 b를 1981년 예측에 쓰면 미래 정보가 섞인다.

슬라이드 04 · 평균보다 큰 변동성

주식시장의 연평균 수익률이 양수라도 매년 수익률은 크게 흔들린다. 평균이 10% 안팎이고 표준편차가 20% 안팎이면 한 해 관측치의 신호대잡음비는 대략 0.5에 불과하다. 평균을 정확히 추정하려면 단순히 주가 관측 횟수보다 긴 기간이 필요하다.

더 중요한 것은 예측 대상이다. 올해의 주가지수 수준을 아는 것은 내년의 초과수익률을 아는 것과 다르다. 채점에서는 배당을 포함한 총수익률과 무위험수익률을 뺀 초과수익률의 정의를 일관되게 써야 한다.

연간 수익률 n개의 평균 $\bar{r}$은 한 해 수익률보다 덜 흔들린다. 서로 독립이고 각 연도의 분산이 σ^2라면 $\mathrm{Var}(\bar{r}) = \mathrm{Var}(\sum_t r_t/n) = n\sigma^2/n^2 = \sigma^2/n$이다. 따라서 평균의 표준오차는 $\sigma/\sqrt{n}$이다. 표준편차 19.4%인 연간 총수익률 98개로 평균을 추정하면 표준오차는 $19.4\%/\sqrt{98} \approx 1.96\%$포인트다. 이를 1%포인트로 줄이려면 독립 연도가 대략 $(19.4/1)^2 = 376$개 필요하다.

표준오차 약 2%포인트는 **평균 추정치**의 불확실성이고, 19.4%는 **한 해 수익률**의 표준편차다. 연간 초과수익률의 평균 8.4%, 표준편차 19.7%를 별도로 사용하면 평균이 0이라는 가설의 t값은 $8.4/(19.7/\sqrt{98}) \approx 4.22$다. 같은 98년을 일별로 쪼개도 독립적인 연도 수가 늘지는 않는다. 자기상관이나 시장의 구조 변화가 있으면 단순 표준오차를 조정해야 한다.

슬라이드 05 · 예측변수 동물원

미래 수익률을 오늘 알 수 있는 정보와 연결하려면 관측 시점을 먼저 맞춰야 한다. x_t는 시점 t에 이미 공개된 배당/주가·장단기금리차 같은 지표, r_{t+1}은 **그 뒤 기간**의 수익률이다. 가장 단순한 예측 회귀 $r_{t+1} = a + bx_t + \varepsilon_{t+1}$에서 a는 기준 수익률, b는 x_t가 한 단위 달라질 때 예측 수익률이 얼마나 변하는지 나타내는 기울기다. ε_{t+1}은 식이 설명하지 못한 부분이며, 조건부 평균을 $a + bx_t$로 읽으려면 $E[\varepsilon_{t+1} \mid x_t] = 0$이 필요하다.

변수가 많아질수록 과거에 우연히 잘 맞은 지표를 고르기 쉬워진다. 경제적으로 그럴듯한 이유와 통계적 유의성만으로 끝내지 않고, 선택 과정 전체를 포함해 미래 예측 성능을 봐야 한다.

계수 b는 변수의 기록 단위에 따라 숫자가 달라진다. 배당수익률을 소수로 기록하고 $b = 2$라면 x가 0.04에서 0.05로 1%포인트 올라갈 때 예측 수익률은 $2(0.05 - 0.04) = 0.02$, 즉 2%포인트 높아진다. x를 4와 5처럼 퍼센트 숫자로 저장했다면 같은 예측을 만드는 계수는 0.02다. 따라서 계수 숫자만 비교하기보다 실제 변화에 대한 예측 차이를 보고한다.

슬라이드 06 · 높은 배당수익률의 두 해석

매년 배당이 g로 성장하고 요구수익률이 $r > g$로 일정하다면, 고든 성장모형에서 $P_t = D_{t+1}/(r-g)$이다. 양변을 정리하면 $D_{t+1}/P_t = r - g$다. 배당 대비 가격이 낮을 때 높은 미래 수

익률 r 때문일 수도 있고 낮은 배당성장률 g 때문일 수도 있다.

따라서 배당수익률의 계수에 인과적 이름을 곧장 붙일 수 없다. 경기침체기에 위험 보상이 올라 가격이 떨어졌다면 이후 수익률이 높아질 수 있다. 기업의 배당 성장 자체가 나빠졌다면 같은 높은 배당수익률이 좋은 투자 신호가 아닐 수도 있다.

관찰된 다음 배당 대비 가격 비율이 8%라고 하자. 요구수익률 12%와 성장률 4%도, 요구수익률 9%와 성장률 1%도 $r - g = 8\%$를 만족한다. 현재 비율 하나로는 두 조합을 식별할 수 없다. 실제 배당이 일정 비율로 영원히 자라고 r과 g가 고정된다는 강한 가정을 풀면 이 구분은 더 어려워진다.

질문: 할인율과 성장률 설명을 어떻게 더 가려낼 수 있나요? 이후 실현된 배당 성장과 초과수익률을 함께 봅니다. 할인율이 높아진 상태라면 이후 기대수익률이 높고, 성장 전망 악화라면 이후 현금흐름이 낮을 가능성이 있습니다. 두 결과 모두 새로운 충격의 영향을 받으므로 단일 관측으로 확정할 수는 없습니다.

슬라이드 07 · 자료를 잘게 나누어도 평균은 정밀해지지 않는다

전체 기간을 T년, 관측 간격을 h년이라고 하자. 독립 로그수익률 X_k가 평균 μh, 분산 $\sigma^2 h$를 가지면 $n = T/h$개를 합한 연율 평균 추정치는 $\hat{\mu} = \sum_k X_k / T$다. 독립성 때문에 분산은 다음과 같이 계산된다.

$$\mathsf{Var}(\hat{\mu}) = \frac{n\sigma^2 h}{T^2} = \frac{\sigma^2}{T}.$$

1년을 12개월로 나누면 한 달 증가량의 분산은 $\sigma^2/12$이고 12개를 합한 분산은 다시 σ^2다. 252일로 나누어도 같은 원리가 적용된다. 이 계산은 증가량의 독립성을 사용한다. 자기상관이 있으면 날짜 쌍의 공분산을 더해야 하며, 관측 간격을 줄여도 장기 평균을 판단할 달력상의 역사가 늘지는 않는다.

질문: 일별 수익률에 자기상관이 있으면 결론이 어떻게 바뀌나요? 연율 평균 추정의 분산에 날짜 쌍의 공분산이 더해집니다. 양의 자기상관은 유효 정보량을 줄이고 음의 자기상관은 반대 방향으로 작용할 수 있어, 독립 증가량 공식 그대로 표준오차를 계산하면 안 됩니다.

슬라이드 08 · 단순수익률, 로그수익률, 연속복리

단순수익률은 $R = (P_1 - P_0)/P_0$이고 로그수익률은 $r = \ln(P_1/P_0) = \ln(1+R)$이다. R이 작을 때 테일러 전개 $\ln(1+R) = R - R^2/2 + \cdots$로 둘이 가까워진다. 여러 기간의 가격비는 곱이므로 로그를 취하면 수익률은 합이 된다.

$$\frac{P_n}{P_0} = \prod_{k=1}^{n} (1 + R_k), \qquad \ln \frac{P_n}{P_0} = \sum_{k=1}^{n} r_k.$$

연 r을 m번 복리로 적용한 $(1 + r/m)^m$은 $m \to \infty$에서 e^r로 간다. 로그수익률의 합산성과 짧은 구간 분산의 비례관계는 독립 또는 적절한 약한 의존 조건을 구분해 사용해야 한다.

주가가 100에서 110으로 오르고 다시 100으로 내려오면 단순수익률은 10%와 약 -9.09%다. 둘을 더하면 약 0.91%이지만 로그수익률은 $\ln(1.1) + \ln(100/110) = 0$으로 정확히 합산된다. 다만 투자자의 원화 손익을 계산할 때는 단순수익률의 곱셈식이 직접적이다.

시간에 따른 합산과 **같은 시점의 종목 간 합산**은 서로 다르다. 기초자산에 처음 자산의 w와 $1-w$를 나누어 투자했다면 한 기간 포트폴리오의 단순수익률은 $R_p = wR_A + (1-w)R_B$이다. 반면 로그수익률은 $\ln(1+R_p) = \ln[1+wR_A+(1-w)R_B]$이므로 일반적으로 $w\ln(1+R_A)+(1-w)\ln(1+R_B)$가 아니다. 예를 들어 절반씩 투자한 두 종목이 각각 $+20\%$와 -20%이면 포트폴리오 단순·로그수익률은 모두 0이지만 개별 로그수익률의 평균은 $\frac{1}{2}\ln(1.2)+\frac{1}{2}\ln(0.8) = \frac{1}{2}\ln(0.96) < 0$이다. 로그의 시간 합산성을 횡단면 평균에 옮겨 쓰면 안 된다.

위 식이 주가 P만으로 적혀 있으므로 배당이 있는 주식에는 그대로 적용하면 안 된다. 해당 기간에 현금배당 D를 받았다면 재투자하지 않은 한 기간의 단순 총수익률은 $(P_1 + D - P_0)/P_0$다. 로그 총수익률을 기간별로 합산하려면 배당 재투자 기준의 총수익지수를 먼저 만들고 그 지수의 로그비를 써야 한다. 가격수익률과 총수익률을 섞으면 예측 대상 자체가 바뀐다.

슬라이드 09 · 일별 자료의 다른 역할

일별 자료는 단기 변동성을 추정하는 데 유용하다. 최근 일별 수익률 제곱이 내일의 위험과 이어진다면 포지션 크기를 조정할 수 있다. 반면 연평균 기대수익률의 작은 차이는 일별 잡음에 묻힌다. 더구나 호가 스프레드, 비동시 거래, 가격 정체가 일별 수익률에 가짜 자기상관을 만들 수 있다. **분산 추정과 평균 예측**의 성능은 각각 검증해야 한다.

호가 차이만으로 생기는 움직임을 수치로 보자. 진짜 중간가격이 100원으로 일정하고 매수·매도 체결가격이 각각 101원과 99원이면, 마지막 거래가 99원에서 101원으로 바뀐 수익률은 약 2.02%다. 가치가 변하지 않았어도 다음 거래가 반대편 호가에서 일어나면 수익률이 되돌아온다. 이런 미시구조 효과를 경제적 기대수익률의 변화로 읽지 않아야 한다.

비동시 거래는 다른 모양의 가짜 예측력을 만든다. 두 종목 A·B가 같은 시장 소식에 동시에 2%씩 반응하지만 B의 마지막 체결은 소식 전인 오후 2시, A의 종가는 소식 후인 오후 4시에 기록되었다고 하자. 오늘 관측수익률은 A가 2%, B가 0이고, 내일 B가 거래되어 가격이 반영되면 A는 0, B는 2%로 기록될 수 있다. 매일 동일가중으로 다시 맞춘 포트폴리오의 관측수익률은 이틀 연속 1%가 되어 자기상관이나 A의 선행성을 암시한다. 그러나 오후 3시에 소식을 알았을 때 B의 **오후 2시 체결가격으로 매수할 수는 없다**. 관측된 종가의 시간 차이와 실행 가능한 가격을 구분해야 한다.

슬라이드 10 · 표본 안의 유의성

예측 회귀에서 t값이 크거나 장기 R^2가 높다는 결과는 먼저 표본 내 사실이다. 변수를 고른 기간과 계수를 추정한 기간이 같으면 선택 편향이 발생한다. 장기 수익률은 겹치는 기간이 많아 표준오차 계산도 까다롭다.

같은 자료에서 후보 변수를 100개 시험해 가장 높은 t값 하나를 보고하면 그 값의 통상적인 유의수준은 적용되지 않는다. 장기 수익률을 겹치게 만들면 예컨대 12개월 수익률 두 개가 11개월을 공유해 오차도 강하게 상관된다. 표준오차와 변수 선택을 모두 감안한 뒤에야 신뢰도를 말할 수 있다.

독립이고 같은 분산의 월별 충격을 12개 더한 수익률을 생각하자. 연속한 두 12개월 수익률은 11개의 같은 월별 충격을 공유한다. 각 합의 분산은 $12\sigma^2$, 두 합의 공분산은 $11\sigma^2$이므로 상관은 $11/12$다. 원래 월별 충격이 독립이어도 **겹치는 목표를 만드는 순간** 회귀 오차가 강하게 의존한다는 점이 표준오차 계산의 핵심이다.

슬라이드 11 · 표본내와 표본외를 구분하기

표본내 적합은 전체 기간으로 a, b를 추정한 후 같은 자료에서 잔차를 계산한다. 표본외 검증은 각 시점 t에 t까지의 자료만으로 $\hat{a}_t, \hat{b}_t$를 추정해 $\hat{r}_{t+1} = \hat{a}_t + \hat{b}_t x_t$를 만든다. 이후 r_{t+1}이 실현되면 오차를 기록한다.

재귀 예측은 첫 훈련 구간을 정해 한 시점의 예측을 저장하고, 실현값이 나온 뒤에만 자료를 추가해 다시 적합한다. 2000~2010년 자료로 2011년 1월을 예측했다면 1월 실현값을 더한 뒤 2월을 예측한다. 2011년 전체를 보고 재학습 주기나 변수를 다시 선택하면 그 해의 점수는 독립 시험이 아니다. 모형 선택과 예측 저장 시점을 함께 기록해야 한다.

슬라이드 12 · 과거 평균과 표본외 결정계수

벤치마크는 예측변수 없이 시점 t까지의 평균 $\bar{r}_t$를 다음 수익률 예측으로 쓰는 것이다. 모형과 벤치마크의 제곱오차 합을 비교한다.

$$R^2_{\text{OOS}} = 1 - \frac{\sum_t (r_{t+1} - \hat{r}_{t+1})^2}{\sum_t (r_{t+1} - \bar{r}_t)^2}.$$

예를 들어 벤치마크 제곱오차 합이 100이고 모형이 98이면 $R^2_{\text{OOS}} = 1 - 98/100 = 0.02$다. 모형이 105라면 -0.05다. 표본내 OLS는 같은 자료의 절편만 있는 모형보다 잔차 제곱합이 클 수 없지만, 미래에는 그 보장이 없어 음수가 자연스럽게 가능하다.

이때 벤치마크의 과거 평균도 각 시점에 **그때까지**의 수익률로 다시 계산해야 한다. 나중의 전체 표본평균을 모든 과거 시점에 적용하면 벤치마크가 미래를 훔쳐본다. 모형과 기준선의 정보 집합을 맞춰야 R^2_{OOS}가 '추가 변수의 가치'를 측정한다. 또 이 비율은 제곱오차 개선율이지 투자자가 벌어들인 수익률 자체가 아니다.

슬라이드 13 · 웰치와 고열의 판정

배당수익률 등 많은 시장 예측변수는 과거 표본 안에서 설명력을 보였지만, 시점마다 다시 추정하는 표본외 평가에서는 과거 평균에 뒤졌다. 한 번의 위기 기간에 기울기가 크게 맞아 전체 통계량을 끌어올렸을 가능성도 살펴야 한다.

이 결과는 초과수익 예측을 포기하라는 뜻보다 **비교 기준을 낮추지 말라**는 교훈이다. Welch·Goyal[19]의 누적 오차 그림에서는 선이 내려갈 때 제안 모형이 기준선보다 더 큰 오차를 낸다.

누적 오차 그림이 거의 계속 내려간다면 해당 평가 기간의 많은 시점에서 모형 오차가 컸다는 뜻이다. 반대로 마지막 한 위기에서 급락했다면 평균적인 달과 위기 달의 성능을 분리해 볼 필요가 있다. 두 경우 모두 원 논문의 표본, 예측 시작 시점, 재추정 규칙을 그대로 재현한 뒤에야 새로운 방법과 공정하게 비교할 수 있다.

슬라이드 14 · 간단한 경제 제약은 도움이 될까

배당수익률이 높으면 미래 수익률이 높다는 부호를 강제하거나, 예상 초과수익률의 음의 추정값을 0으로 절단하는 규칙은 경제적 사전 믿음을 예측에 넣는다. 극단적인 음의 추정값이 잡음

[19] https://doi.org/10.1093/rfs/hhm014

이면 오차를 줄이지만, 실제 기대값이 음수인 기간에는 편향을 만든다. 제약의 순효과는 이후 기간의 예측오차와 투자 성과로 평가한다.

월별 R^2_{OOS}가 작아도 평균·분산 투자자는 포트폴리오 비중을 개선할 수 있다. 다만 기대효용 증가는 위험회피계수, 매매비용, 차입 제약에 민감하다. Campbell·Thompson[20]의 주장은 통계 점수와 경제적 가치를 구분해 읽어야 한다.

위 비중식은 위험자산 비중 w의 근사 효용 $U(w) = w\hat{\mu} - \gamma w^2\sigma^2/2$를 최대화해 얻는다. 미분하면 $dU/dw = \hat{\mu} - \gamma w\sigma^2 = 0$이므로 $w^* = \hat{\mu}/(\gamma\sigma^2)$다. 위험회피계수 $\gamma = 4$, 월 분산 $\sigma^2 = 0.0025$, 예상 월 초과수익률 $\hat{\mu} = 0.005$라면 제약 없는 비중은 0.5다. 차입 금지나 최대 비중 규칙이 있으면 이 해를 허용 범위로 제한한다.

슬라이드 15 · 시간이 지난 뒤의 재검증

첫 논쟁 이후 발표된 새 변수도 발표 당시의 자료에는 잘 맞을 수 있다. 독립된 후속 기간과 공통한 기준으로 다시 평가하면 결과가 약해지기도 한다. 이는 예측 관계가 소멸했을 수도 있고, 처음부터 선택 편향이 있었을 수도 있음을 뜻한다.

두 설명을 가르려면 원 논문의 표본 종료일, 논문 발표일, 이후 기간을 따로 본다. 발표 전에 이미 감소했다면 데이터 채굴이나 불안정성의 비중이 클 수 있다. 발표 후 추가 감소에는 투자자의 반응도 기여할 수 있다.

예를 들어 원 논문이 2000년 자료까지 썼고 2005년에 공개되었다면 2001~2004년은 **표본 밖이지만 발표 전**, 2005년 이후는 **표본 밖이면서 발표 후**다. 첫 구간에서도 성과가 나쁘면 발표에 따른 투자자 반응만으로는 설명할 수 없다. 두 구간의 길이와 시장 상태가 다를 수 있으므로 평균 차이 하나보다 위험·거래비용·표본 수를 함께 기록한다.

슬라이드 16 · 유의성·안정성·실용성의 깔때기

변수가 표본내 유의성을 유지하는지, 같은 부호로 표본외 예측을 하는지, 거래비용 뒤에도 투자의사결정을 개선하는지는 서로 다른 관문이다. 앞 관문을 통과해도 뒤 관문을 자동으로 통과하지 않는다.

새 논문의 수를 세어 "성공률"이라고 부를 때는 각 연구가 사용한 시작일, 예측 기간, 재추정 방식이 같은지 확인해야 한다. 공정한 비교는 변수 자체뿐 아니라 **검증 절차**를 맞춘다.

가상의 전략이 표본내에서 $t = 2.4$로 유의하고 표본외에서도 순위를 조금 개선했다고 하자. 월 총수익이 운용자산의 0.30%, 한 달 거래 명목금액이 운용자산의 두 배, 거래된 금액당 비용이 0.10%라면 순수익은 $0.30\% - 2(0.10\%) = 0.10\%$다. 여기서 회전율의 분모와 비용에 차입료·시장충격이 포함됐는지까지 정해야 마지막 관문을 통과했다고 말할 수 있다. 통계적 성공이 실용적 성공보다 앞선다는 뜻이지 앞의 점수가 뒤의 점수로 환산된다는 뜻은 아니다.

슬라이드 17 · 누적 오차 차이 그래프 읽기

그래프의 세로축이 누적 $\text{SSE}_{\text{bench}} - \text{SSE}_{\text{model}}$이면 상승은 예측변수의 승리, 하락은 과거 평균의 승리다. 선이 특정 위기 이후 꺾이는 경우에는 기울기 자체가 달라졌는지, 큰 한두 관측치가 오차를 지배했는지 확인한다.

표본내 선과 표본외 선이 벌어지면 과거를 맞힌 계수가 미래에는 통하지 않았다는 뜻이다. 그래프의 0선뿐 아니라 기울기의 안정성과 표본 종료일 표시를 함께 보아야 한다.

[20] https://doi.org/10.1093/rfs/hhm055

누적 곡선의 한 시점 증가분은 $e^2_{\text{bench,t}} - e^2_{\text{model,t}}$이다. 예를 들어 기준선 오차가 3이고 모형 오차가 1이면 해당 시점에서 곡선은 $9 - 1 = 8$만큼 오른다. 큰 위기 관측치 하나가 긴 기간의 완만한 하락을 뒤집을 수 있으므로, 전체 결과와 극단 시점을 뺀 결과를 함께 읽는다.

평가 종료일의 누적값을 $C = \text{SSE}_{\text{bench}} - \text{SSE}_{\text{model}}$이라 놓으면 $R^2_{\text{OOS}} = C/\text{SSE}_{\text{bench}}$다. 따라서 누적 선의 높이가 양수면 그 종료일까지의 표본외 결정계수도 양수다. 하지만 선이 상승하는 한 구간이 있다고 해서 전체 기간 성과가 양수인 것은 아니다. 기울기는 **그때그때의 오차 차이**, 최종 높이는 **전체 오차 차이**를 나타낸다.

슬라이드 18 · 첫 단계의 결론

예측변수가 많아도 과거 평균보다 좋다는 주장은 어렵게 입증해야 한다. 기준선은 쉽게 이길 수 있는 허수아비가 아니라 실제로 이용 가능하고 추정오차가 작은 대안이어야 한다. 정확도가 조금 높아도 구현 비용과 위험을 함께 본다.

정규화는 추정된 계수를 0 쪽으로 당겨 분산을 줄이는 방법이다. 참 기울기가 0이면 큰 표본내 기울기는 잡음이므로 강한 축소가 유리하다. 참 기울기가 작지만 0은 아니면 신호의 일부를 남기는 편이 낫다. 신호가 전혀 없는 자료에서 벌점이 예측력을 만들 수는 없다. **얼마나 축소할지**는 미래 구간에서 기준선보다 오차를 얼마나 줄이는지로 정한다.

슬라이드 19 · 왜 실패하는가

진짜 조건부 기대수익률이 존재해도 매번 실현 수익률에는 큰 예측 불가능한 충격이 들어온다. 잡음이 클 때 회귀계수는 작은 표본의 우연에 따라 크게 달라진다. 변수 수가 늘면 그 우연을 설명할 자유도가 늘어난다.

한 변수 모형의 참 기울기가 b, 추정값이 $\hat{b} = b + u$라면 계수 추정 때문에 생긴 다음 시점의 예측 오차는 ux_t다. x_t가 큰 상태에서는 작은 u도 큰 전망 오류가 된다. 예측 수익률에 비례해 투자 비중을 정하면 불안정한 계수가 매수·매도 전환과 높은 회전율로 이어진다. 표본내 적합, 계수의 표준오차, 거래비용 뒤 성과를 함께 보아야 한다.

슬라이드 20 · 작은 참 신호의 규모

$y = f(x) + \varepsilon$이고 신호와 잡음이 독립이라면 참 예측 가능 비율은 $R^2_{\text{true}} = \text{Var}(f(x))/[\text{Var}(f(x)) + \text{Var}(\varepsilon)]$이다. 조건부 평균의 표준편차가 잡음의 1/10이면 $R^2 = 0.01/1.01 \approx 0.99\%$다.

조건부 평균 $f(x)$를 정확히 알아도 이 예에서는 전체 분산 1.01 가운데 잡음 분산 1이 남는다. 실제로는 f를 추정해야 하므로 추정오차가 약 1%의 이득을 넘으면 표본외 R^2가 음수가 될 수 있다. 이는 $E[\varepsilon \mid x] = 0$이라는 조건부 평균 가정 아래의 계산이다. **참 예측 가능 비율**과 추정 모형의 실제 점수를 따로 보아야 한다.

슬라이드 21 · 과적합 모의실험을 직접 구성하기

관측치 120개에서 후보 변수 110개를 만들되 실제 영향이 있는 것은 첫 10개라고 하자. 독립 표준정규 변수와 잡음의 분산을 1로 두고 참계수를 모두 c로 정하면 신호분산은 $10c^2$다. 참 $R^2 = 5\%$가 되게 하려면 $10c^2/(10c^2 + 1) = 0.05$를 풀어 $c^2 = 1/190$을 얻는다.

$c^2 = 1/190$이면 각 진짜 계수의 절댓값은 약 0.073이다. 잡음 표준편차가 1인 자료에서 이 신호를 120개 관측으로 분리하기 쉽지 않다. 시뮬레이션을 여러 번 반복해 평균 훈련·시험 곡선을 그리면 단일 난수 추첨의 운과 변수 수가 만드는 체계적 변화를 구별할 수 있다.

절편까지 포함해 110개 변수를 120개 관측에 OLS로 적합하면 잔차 자유도는 $120 - 111 = 9$뿐이다. 훈련자료를 맞힐 방향이 많지만 계수를 안정적으로 확인할 독립 여유는 거의 없다. 변수가 더 늘어 열들이 선형 종속이 되면 보통의 역행렬 공식도 쓸 수 없고, 최소제곱 해가 여러 개일 수 있다. 모의실험에서 훈련오차의 하락과 새 표본 오차의 상승을 동시에 그리는 이유다.

슬라이드 22 · 변수 증가와 벌점의 효과

OLS는 변수를 추가할 때 표본내 제곱오차가 증가할 수 없다. 추가 변수를 쓰지 않도록 계수를 0으로 놓는 선택이 항상 가능하기 때문이다. 그러나 미래 자료에서는 잡음에 맞춘 계수가 오차를 키울 수 있다.

같은 변수 수를 유지하고 능형회귀의 벌점을 키우면 표본내 적합은 다소 낮아지지만 표본외 오차가 줄어드는 구간이 생긴다. 벌점이 너무 크면 유용한 신호까지 지워 다시 나빠진다. 그래프의 최저점은 사전 고정값이 아니라 독립 자료로 선택해야 한다.

한 계수만 있는 단순 문제에서 OLS 추정치가 z라면 Ridge의 축소해는 적절한 정규화 아래 $\hat{\beta}_\lambda = z/(1+\lambda)$처럼 표현된다. $\lambda = 0$이면 OLS이고 $\lambda \to \infty$이면 0으로 간다. 참계수가 작고 z의 잡음이 크면 약한 축소는 분산을 낮추지만, 참계수가 큰데 너무 강하게 줄이면 편향이 커진다. **시험자료를 보며** 최적 λ를 고르는 것은 평가 자료에 다시 적합하는 행위다.

슬라이드 23 · 차원이 커질 때 추정오차의 유도

기업별 참 평균수익률을 모은 벡터가 $\mu = Xg$라고 하자. X의 K개 열은 기업 특성이고 g는 그 특성의 계수다. τ개의 독립 기간에서 계산한 평균은 $\bar{r} = \mu + \bar{\varepsilon}$이며 잡음의 공분산을 $\sigma^2 I/\tau$로 가정한다. OLS는 관측 평균을 X의 열들이 표현할 수 있는 K차원 공간에 투영한다. 투영행렬 $P = X(X^\top X)^{-1}X^\top$를 쓰면 $\hat{\mu} = P\bar{r} = \mu + P\bar{\varepsilon}$이다. 마지막 등식에는 참 평균도 그 공간 안에 있다는 $P\mu = \mu$를 썼다.

$$
\begin{aligned}
E\|\hat{\mu} - \mu\|^2 &= E[\bar{\varepsilon}^\top P \bar{\varepsilon}] \\
&= \operatorname{tr}\!\left(P \frac{\sigma^2}{\tau} I\right) \\
&= \frac{K\sigma^2}{\tau}.
\end{aligned}
$$

$\hat{\mu} - \mu = P\bar{\varepsilon}$이고 $P^\top P = P$이므로 첫 줄은 $E[\bar{\varepsilon}^\top P \bar{\varepsilon}]$다. 평균 0인 벡터에 대한 $E[z^\top A z] = \operatorname{tr}(A \operatorname{Var} z)$를 쓰면 둘째 줄이 나오고, 투영 공간의 차원만큼 $\operatorname{tr} P = K$여서 마지막 줄이 된다. **특성 방향 하나를 추가할 때마다** 잡음분산 σ^2/τ가 더해진다는 뜻이다. K가 커지면 표본내 적합이 좋아져도 표본외 추정오차는 커질 수 있다.

이 유도에는 $X^\top X$가 역행렬을 갖는, 즉 X의 K개 열이 선형 독립이라는 조건이 있다. 열이 서로 같거나 K가 관측 기업 수보다 크면 표준 OLS 식은 정의되지 않는다. 또 오차 공분산이 Σ라면 결과는 $\operatorname{tr}(P\Sigma/\tau)$가 되어 단순히 $K\sigma^2/\tau$라고 쓸 수 없다. 금융의 공통 충격이 여러 기업 오차를 함께 움직일 때 바로 이 조건을 점검해야 한다.

슬라이드 24 · 편향과 분산을 식으로 분해하기

같은 x_0에서 새 결과가 $y_0 = f(x_0) + \varepsilon_0$로 나온다고 하자. 새 충격은 평균 0이고 학습자료로 만든 예측 $\hat{f}(x_0)$와 독립이다. 여러 학습표본에 걸친 평균 예측을 $\bar{f} = E[\hat{f}(x_0)]$라 놓고 더했다 빼

면 예측오차는 $y_0 - \hat{f} = \varepsilon_0 + (f - \bar{f}) + (\bar{f} - \hat{f})$다. 세 항은 새 충격, 평균적인 편향, 표본에 따른 예측 변동이다. 제곱한 뒤 기댓값을 취하면 평균 0과 독립성 때문에 교차항이 사라진다.

$$E[(y_0 - \hat{f})^2] = \sigma^2 + \left(f - E\hat{f}\right)^2 + \mathrm{Var}(\hat{f}).$$

첫 항은 어떤 예측자에게도 남는 새 충격의 분산, 둘째는 체계적으로 빗나간 정도의 제곱, 셋째는 학습표본을 바꿀 때 예측이 흔들리는 정도다. 정규화는 편향을 조금 늘려도 추정 분산을 더 크게 줄이면 총오차를 낮춘다. 시장 국면이 바뀌어 새 충격의 조건부 평균이 0이 아니면 이 분해의 가정을 다시 검토해야 한다.

슬라이드 25 · 세 오차의 경제적 의미

수익률의 예측 불가능한 충격은 모형을 아무리 정교하게 해도 없앨 수 없다. 편향은 모형이 지나치게 단순해 실제 위험 보상을 놓칠 때 생긴다. 여기서 **모형의 분산**은 훈련표본을 바꿀 때 예측값이 요동치는 정도로, 한 종목의 실제 수익률 변동성과는 다르다. 이 요동은 투자 비중을 불안정하게 만든다.

평균·분산 투자에서 제약 없는 비중은 대략 $w_t = \hat{\mu}_t / (\gamma \sigma_t^2)$다. 위험 추정치와 위험회피계수 γ가 일정하면 예상수익률의 요동이 곧 주문량의 요동이 된다. 전월 비중 0.5가 -0.5로 바뀌면 자산 가치의 한 배만큼 순포지션을 변경해야 한다. 평균 예측오차가 비슷한 두 모형이라도 전망이 불안정한 쪽은 거래비용 뒤 성과가 낮을 수 있다.

슬라이드 26 · U자형 상충관계

아주 단순한 과거 평균 모형은 변수에 따른 변화를 못 잡아 편향이 크지만 추정이 안정적이다. 모든 변수를 자유롭게 넣는 OLS는 편향이 낮을 수 있으나 잡음에 민감하다. 중간 복잡도에서 합계 오차가 낮아지는 U자형 그림은 이 관계를 요약한다.

그러나 U자의 위치는 자료의 신호대잡음비와 변수 상관에 따라 달라진다. 금융처럼 신호가 약하고 데이터가 짧을수록 왼쪽, 즉 강한 축소 쪽이 유리할 가능성이 크다. 그림은 사전 믿음이며 실제 최저점은 검증에서 찾는다.

그래프는 편향 제곱이 줄고 분산이 늘어나는 **고전적 구간의 도식**이다. 초록색 합계는 각 복잡도에서 편향 제곱, 분산, 일정한 잡음분산을 실제로 더한 값이므로 어느 개별 항보다도 작을 수 없다. 그러나 개별 곡선의 단조 변화나 U자형 전체가 모든 모형에서 성립하는 법칙은 아니다. 극도로 과매개화된 모형에서는 시험오차가 다시 내려가는 double descent[21]도 관찰된다.

슬라이드 27 · 공짜 점심이 없는 이유

모든 가능한 자료생성과정에 대해 언제나 이기는 추정기는 없다. 능형회귀는 많은 작은 계수가 있다는 믿음, 라쏘는 소수 변수만 중요하다는 믿음을 반영한다. 진실이 다르면 두 방법의 순위도 바뀐다.

참효과가 열 개 변수에 고르게 퍼져 있다면 한두 변수만 남기는 제약은 신호를 버린다. 한 변수에 집중되어 있다면 모든 계수를 남기는 방법은 잡음에 반응하기 쉽다. 변수의 정의·측정오차·거래 가능성을 검토하고, 두 구조를 같은 훈련·검증 기간에서 비교한다. 시험자료의 성적을 보고 구조를 다시 고르면 선택 편향이 생긴다.

[21] https://arxiv.org/abs/1812.11118

슬라이드 28 · 금융 자료에 맞는 검증

낮은 신호대잡음비는 작은 R^2를 예상하게 하고, 짧은 실효 표본은 계수의 불확실성을 키운다. 시간에 따라 관계가 변하면 임의 분할보다 미래 방향의 검증이 필요하다. 수익률의 공통 충격은 종목 수가 많아도 독립 표본 수가 그만큼 늘지 않음을 뜻한다.

다음 달 수익률 예측을 채점한다면 검증자료를 미래 달에 둔다. 같은 달의 종목을 훈련·검증에 나누면 공통 충격이 양쪽에 들어간다. 산업·회사·기간 중 무엇을 새 환경으로 삼을지에 따라 분할 단위가 달라진다. 그 단위에서 자유도를 제한한 모형과 당시 이용 가능한 단순 기준선을 비교한다.

예측 목표가 앞으로 12개월의 누적수익률이라면 훈련 마지막 관측과 검증 첫 관측의 **결과 기간이 겹칠** 수 있다. 예를 들어 2020년 12월에 시작한 12개월 수익률과 2021년 1월에 시작한 수익률은 11개월을 공유한다. 달력상 행을 분리했어도 목표값이 거의 같은 충격을 담으므로 경계 주변의 중첩 기간을 빼거나 평가 간격을 조정해야 한다.

슬라이드 29 · 편향을 의도적으로 쓰는 처방

비편향 추정은 참계수를 평균적으로 맞힌다는 장점이 있지만 미래 예측오차를 최소화한다는 보장은 없다. 계수를 0에 가깝게 끌어당기면 약한 신호에서 계수의 요동을 줄일 수 있다. 이 의도적 편향이 **축소추정**이다.

두 처방은 모두 적합과 단순성을 맞바꾼다. 능형회귀는 모든 계수를 연속적으로 줄이고, 라쏘는 일부를 0으로 만든다. 어느 쪽이 맞는지는 실제 변수 효과가 넓게 퍼져 있는지 드문지에 달려 있다.

한 계수의 OLS 추정치 z가 $E[z] = \beta$, $\mathrm{Var}(z) = \sigma_z^2$를 만족하고 이를 az로 축소한다고 하자. 제곱오차의 기대값은 $(1-a)^2\beta^2 + a^2\sigma_z^2$다. 첫 항은 새로 생긴 편향 제곱, 둘째는 남은 분산이다. 이를 a로 미분해 0으로 두면 $a^* = \beta^2/(\beta^2 + \sigma_z^2)$가 되어, 신호가 작거나 추정 잡음이 클수록 더 많이 축소한다. 실제 β는 모르므로 검증자료로 축소 강도를 골라야 한다.

슬라이드 30 · 첫 번째 처방으로 가기

능형회귀는 OLS의 제곱오차에 계수 크기에 대한 벌점을 더한다. 큰 계수가 꼭 나쁘다는 뜻이 아니라, 약한 자료에서 큰 계수를 확신하려면 그만큼 강한 증거가 필요하다는 뜻이다.

벌점이 계수의 제곱합을 비용으로 보는 이유는 큰 절댓값의 계수에 더 빠르게 증가하는 비용을 붙이기 위해서다. 같은 예측오차를 만드는 두 해가 있다면 계수 크기가 작은 쪽을 선호한다. 절편까지 벌점을 주면 자료의 전체 평균도 0으로 부당하게 당기므로 보통 기울기만 축소한다.

벌점은 계수의 **숫자 크기**에 적용된다. 같은 부채비율을 0.5 또는 50으로 기록하면 동일한 예측의 계수는 100분의 1로 바뀌고 제곱 벌점은 1만 분의 1이 된다. 경제적 효과 대신 기록 단위가 벌점의 크기를 정하지 않도록 변수의 척도를 맞춘다. 평균과 표준편차를 언제 추정할지는 뒤에서 검증 절차와 함께 다룬다.

슬라이드 31 · OLS의 역행렬이 불안정해지는 이유

$y = Xg + \varepsilon$에서 제곱오차 $(y - Xg)^\top (y - Xg)$를 g에 대해 미분하면 $-2X^\top y + 2X^\top Xg = 0$이다. $X^\top X$가 가역이면 $\hat{g} = (X^\top X)^{-1} X^\top y$다. 변수들이 서로 비슷하면 $X^\top X$의 어떤 방향의 고유값이 아주 작아진다.

추정량의 분산 $\mathrm{Var}(\hat{g}) = \sigma^2 (X^\top X)^{-1}$에서 그 방향의 분산은 $\sigma^2 / \lambda_{\min}$이다. 작은 고유값으로 나누니 계수가 폭발한다. $K > N$이면 열들이 독립일 수 없어 해가 유일하지 않으며, 훈련자료를 완벽히 맞히는 여러 해 가운데 미래에 잘 맞는 해를 OLS만으로 고를 수 없다.

고유값이 작은 방향은 서로 닮은 변수의 '차이'처럼 자료에서 거의 변하지 않는 조합이다. 오차분산이 1이고 그 방향의 고유값이 0.01이면 OLS 계수분산은 $1/0.01 = 100$이다. 고유값이 1인 방향의 분산은 1이다. 역행렬이 존재해도 첫 방향의 개별 계수를 믿기 어려운 이유다. 능형회귀는 고유값에 양의 수를 더해 잡음의 증폭을 제한한다.

슬라이드 32 · 능형회귀의 해를 직접 유도하기

OLS는 잔차 제곱합만 최소화하므로 거의 같은 변수들의 계수가 크게 흔들릴 수 있다. 능형회귀는 계수 제곱합 $g^\top g$에 벌점 $\gamma > 0$을 주어 $L(g) = (y - Xg)^\top (y - Xg) + \gamma g^\top g$를 최소화한다. 벌점은 큰 계수에 더 큰 비용을 매긴다. g로 미분해 0으로 놓으면 $-2X^\top (y - Xg) + 2\gamma g = 0$, 즉 $(X^\top X + \gamma I) g = X^\top y$이므로 다음 해를 얻는다.

$$\hat{g}_{\text{ridge}} = (X^\top X + \gamma I)^{-1} X^\top y, \qquad \gamma > 0.$$

고유벡터 u_j 방향으로 보면 OLS 성분은 $u_j^\top X^\top y / \lambda_j$, Ridge 성분은 $u_j^\top X^\top y / (\lambda_j + \gamma)$다. 작은 고유값 방향일수록 분모가 상대적으로 크게 늘어 불안정한 조합이 강하게 줄어든다. $\gamma \to 0$이면 가역일 때 OLS로, $\gamma \to \infty$이면 기울기 계수는 0으로 간다. 훈련자료에서 중심화한 뒤 절편을 별도로 추정해 벌점을 주지 않으면 마지막 예측은 과거 평균이다.

슬라이드 33 · 두 변수로 보는 작은 분모

표준화한 두 변수의 표본 상관이 ρ이고 $c_j = X_j^\top y / N$라 하자. 목적함수에 $1/N$을 붙여 미분하면 $(1+\gamma) g_1 + \rho g_2 = c_1$, $\rho g_1 + (1+\gamma) g_2 = c_2$다. 두 식을 더하고 빼면 다음이 나온다.

$$g_1 + g_2 = \frac{c_1 + c_2}{1 + \rho + \gamma},$$
$$g_1 - g_2 = \frac{c_1 - c_2}{1 - \rho + \gamma}.$$

$\rho = 0.99$이고 벌점이 없으면 두 계수의 차이를 0.01로 나눈다. 아주 작은 표본 차이가 거대한 상반 계수로 변한다. $\gamma = 0.1$이면 분모가 0.11이 되어 같은 오차가 훨씬 덜 증폭된다.

$\rho = 0.99$, $c_1 + c_2 = 1.99$, $c_1 - c_2 = 0.02$라면 벌점 0에서 $g_1 + g_2 = 1$, $g_1 - g_2 = 2$이므로 개별 계수는 1.5와 -0.5다. $\gamma = 0.1$이면 합은 $1.99/2.09 \approx 0.952$, 차이는 $0.02/0.11 \approx 0.182$로 바뀌어 계수는 약 0.567과 0.385가 된다. 예측에는 이렇게 공유 정보를 안정화할 수 있다. 두 변수의 개별 효과를 해석하려면 둘이 따로 움직이는 표본이나 별도의 식별 근거가 필요하다.

슬라이드 34 · 교점 그림의 해석

두 예측변수가 거의 같은 방향이면 각각의 계수를 따로 결정할 정보가 부족하다. 회귀의 제곱오차 등고선은 길고 좁은 타원이 되어 작은 데이터 변화에도 최저점이 타원의 긴 축을 따라 크게 움직인다.

능형 벌점은 원형 등고선을 더해 원점에서 먼 해에 비용을 부과한다. 결과적으로 같은 두 변수의 합이 가진 신호는 어느 정도 보존하고, 두 변수의 차이에 대한 불필요한 확신을 줄인다. 계수 하나의 해석보다 둘의 합이 더 안정적일 수 있다.

두 설명변수가 완전히 동일한 $x_1 = x_2$이면 예측은 $(g_1 + g_2)x_1$에만 의존한다. 제곱오차는 계수의 **합**만 정하고 개별 계수는 정하지 못해 최소점이 한 직선 위에 놓인다. 같은 합 s를 유지하며 $g_1^2 + g_2^2$를 최소화하면 $g_1 = g_2 = s/2$이므로 Ridge는 두 변수에 가중치를 나눈다. 거의 동일한 경우에는 이 직선이 길쭉한 타원의 축으로 나타난다.

슬라이드 35 · 두 계수의 숫자 예

참계수가 둘 다 1인데 표본에서 OLS가 대략 2.07과 -0.08을 준다면 각각은 크게 틀렸어도 합은 약 2로 맞을 수 있다. 상관이 높은 변수들 사이에서 어느 하나에 신호를 몰아주고 다른 하나를 반대 부호로 보정한 결과다.

새 관측치가 $(x_1, x_2) = (1, 1)$이면 $(g_1, g_2) = (2, 0)$도 $(1, 1)$도 예측값은 2다. 하지만 $(1, -1)$처럼 두 변수가 갈라지면 첫 해의 예측은 2, 둘째 해의 예측은 0이다. 과거에 거의 함께 움직인 변수만으로는 이 새 상태에 어느 해가 맞는지 판단하기 어렵다. 축소는 불확실성을 완화하지만 과거에 없던 조합의 근거를 만들어 내지는 못한다.

슬라이드 36 · 축소와 유효 자유도

$X^\top X = I$인 직교 조건에서는 $\hat{g}_{j,\text{ridge}} = \hat{g}_{j,\text{OLS}}/(1+\gamma)$다. 모든 계수가 같은 비율로 줄고 정확히 0이 되지는 않는다. 데이터에 맞춘 자유도의 크기를 $d(\gamma) = \text{tr}[X(X^\top X + \gamma I)^{-1} X^\top]$로 정의하면 직교 조건에서는 $K/(1+\gamma)$다.

즉 계수는 K개지만 각각 표본의 잡음에 완전히 맞춰지지 않는다. 일반적으로 $X^\top X$의 고유값 λ_j를 쓰면 $d(\gamma) = \sum_j \lambda_j/(\lambda_j + \gamma)$다. 정보가 적은 작은 고유값 방향일수록 더 강하게 축소된다.

두 직교 방향의 고유값이 9와 1이고 $\gamma = 1$이면 유효 자유도는 $9/10 + 1/2 = 1.4$다. 계수는 두 개지만 훈련값을 따라 움직이는 총 정도는 자유 계수 두 개보다 작다. $\gamma \to 0$이면 둘 다 1을 기여해 2가 되고, $\gamma \to \infty$이면 둘 다 0으로 간다. 이 수치는 변수 개수를 물리적으로 지웠다는 뜻이 아니라 적합의 민감도를 요약한다.

슬라이드 37 · 제약식과 벌점식

"오차를 최소화하되 $g^\top g \le c$"라는 문제를 생각하자. 라그랑지안은 $(y - Xg)^\top (y - Xg) + \gamma(g^\top g - c)$다. $-\gamma c$는 g 선택에 영향을 주지 않으므로 능형 목적함수와 같다.

c가 작을수록 원점 가까운 계수만 허용되고 대응하는 γ는 커진다. 그림에서 OLS의 타원 등고선과 원형 제약 영역이 처음 닿는 점이 능형 해다. 이 기하학은 왜 예측변수에 단위를 맞춰야 하는지도 드러낸다.

제약이 실제로 해를 막을 때에만 라그랑주 승수 γ가 양수가 된다. OLS 해가 이미 $g^\top g < c$이면 제약이 느슨하므로 $\gamma = 0$이고 해는 OLS와 같다. 경계에서 $g^\top g = c$가 되면 벌점이 양수일 수 있다. 이 **상보성 조건**을 알아야 모든 c가 서로 다른 양의 벌점에 일대일로 대응한다고 오해하지 않는다.

슬라이드 38 · 계수 경로 읽기

벌점이 아주 크면 모든 기울기 계수는 거의 0이다. 벌점을 줄이면 각 계수가 자료가 가리키는 방향으로 움직인다. **경로 그림**은 어느 변수가 얼마나 빠르게 커지는지와 상관된 변수들이 서로 값을 나누는지를 보여 준다.

경로의 가로축이 γ인지 $\log\gamma$인지 먼저 확인하자. 로그 축에서는 일정한 가로 이동이 벌점의 동일한 절대 증가가 아니라 동일한 배율 변화다. 경로가 특정 지점에서 갑자기 바뀌면 상관된 변수 사이의 가중치 이동일 수도 있으므로, 한 계수의 모양만으로 실물경제 관계의 변화를 주장하지 않는다.

벌점이 매우 클 때 기울기가 모두 0에 가까워져도 예측이 반드시 0이 되는 것은 아니다. 절편을 벌주지 않고 훈련자료에서 중심화했다면 예측은 훈련기간 평균 $\bar{y}$로 수렴한다. 따라서 경로의 왼쪽 또는 오른쪽 끝이 나타내는 기준선이 '0 수익률'인지 '과거 평균'인지는 절편 처리와 축 방향을 함께 봐야 한다.

슬라이드 39 · 표준화가 필수인 이유

훈련 구간에서 $z_j = (x_j - \bar{x}_j)/s_j$로 표준화하면 계수는 해당 변수가 한 표준편차 변할 때의 효과가 된다. 검증·시험 자료에도 **훈련 구간의** $\bar{x}_j, s_j$를 그대로 적용해야 미래 분포의 정보를 미리 사용하는 누출을 피한다. 절편은 중심화 뒤 별도로 처리한다.

훈련자료에서 평균 100, 표준편차 20인 변수의 새 관측치가 130이면 표준화 값은 $(130-100)/20 = 1.5$다. 검증 구간 자체의 평균과 표준편차로 다시 바꾸면 미래 분포를 예측 과정에 알려 주는 셈이다. 결측치 대체, 이상치 절단, 주성분 계산에도 같은 '훈련에서 적합하고 미래에 적용' 원칙을 쓴다.

훈련기간 내내 값이 같아 표준편차 $s_j = 0$인 변수는 $z_j = (x_j - \bar{x}_j)/s_j$로 나눌 수 없다. 그 기간에는 수익률과의 관계를 식별할 변동도 없으므로 해당 변수를 제거하거나 별도로 처리해야 한다. 미래에 변동이 생겼다고 과거 훈련기간의 표준편차를 미래 자료로 다시 계산하면 안 된다. 이는 수치 계산의 예외이면서 시점 규율의 예외도 아니다.

슬라이드 40 · 편향된 추정기가 왜 이길 수 있는가

한 계수에 대해 $x^\top x = 1$, 참값 g, OLS 추정량의 분산 σ^2라 하자. 능형 추정량은 $\hat{g}_\gamma = \hat{g}_{\text{OLS}}/(1+\gamma)$다. 기대값은 $g/(1+\gamma)$이므로 편향은 $-\gamma g/(1+\gamma)$, 분산은 $\sigma^2/(1+\gamma)^2$다.

$$\text{MSE}(\gamma) = \frac{\sigma^2 + \gamma^2 g^2}{(1+\gamma)^2},$$
$$\frac{d\,\text{MSE}}{d\gamma} = \frac{2(\gamma g^2 - \sigma^2)}{(1+\gamma)^3}.$$

미분값을 0으로 놓으면 $\gamma^* = \sigma^2/g^2$다. 잡음이 크거나 참계수가 작을수록 강하게 축소한다. 이 최적값은 참 g를 모르므로 실제로는 검증자료에서 근사해야 한다.

$\gamma = 0$에서 MSE의 도함수는 $-2\sigma^2 < 0$이다. 잡음 분산이 양수라면 벌점을 아주 조금 주는 것이 이 단순 설정에서는 언제나 MSE를 낮춘다. 이후에는 편향의 제곱이 커지므로 최저점을 지난다. 이 유도는 능형회귀가 편향을 '실수로' 만드는 것이 아니라 미래 제곱오차를 줄이려고 의도한다는 점을 보여 준다.

수치로 참계수 $g = 0.1$, OLS 계수분산 $\sigma^2 = 0.04$라면 $\gamma^* = 0.04/0.01 = 4$다. OLS의 MSE는 0.04이고 벌점 4에서 MSE는 $(0.04 + 16\times 0.01)/25 = 0.008$이다. 이 큰 개선은 신호가 추정 잡음보다

작은 **가정된 한 계수 문제**의 결과다. 실제로는 참 g를 모를 뿐 아니라 미래의 계수 관계가 바뀔 수 있어, 숫자 4를 다른 자료에 그대로 적용하지 않는다.

슬라이드 41 · 과거 수익률 357개로 다음 달을 예측하기

한 종목의 과거 119개월 수익률, 그 제곱, 세제곱을 각각 입력하면 357개 특징이 된다. 제곱항은 큰 변동 자체의 효과, 세제곱항은 상승과 하락의 비대칭적 패턴을 표현할 수 있다. 복잡한 기업 정보 없이도 고차원 문제가 된다.

매월 종목 간 비교를 한다면 그 달의 횡단면 평균을 빼고 특성을 표준화한다. 이는 시장 전체의 움직임보다 **어느 종목이 상대적으로 높을지**에 초점을 맞추기 위한 것이다. 변수 정의와 지연 시점은 매매 가능성을 좌우한다.

한 달 수익률이 -20%이면 제곱은 0.04, 세제곱은 -0.008이다. $+20\%$일 때 제곱은 똑같이 0.04지만 세제곱은 $+0.008$이어서 충격의 **크기**와 **방향을 동반한 비대칭성**을 구분한다. 세제곱 값이 수익률보다 훨씬 작으므로 각 특징을 같은 벌점 아래 놓으려면 훈련자료 기준 표준화가 필요하다.

슬라이드 42 · 회귀계수에서 읽는 모멘텀과 반전

최근 몇 달의 양의 계수는 과거에 오른 종목이 더 오르는 모멘텀을 뜻하고, 아주 오래된 과거 수익률의 음의 계수는 장기 반전을 뜻한다. 직전 한 달을 건너뛰는 설계는 호가·유동성에 따른 단기 반전과 중기 모멘텀을 구분하는 데 도움이 된다.

다만 계수 곡선은 서로 상관된 시차를 동시에 넣은 **조건부 효과**다. 한 시차의 계수가 양수라고 그 시차만 사는 전략의 수익률과 동일하지 않다. 전체 예측값을 포트폴리오에 적용해 비용 뒤 성과를 별도로 계산해야 한다.

예를 들어 지난달 수익률에 대한 계수가 -0.2, 그 전 달에 대한 계수가 $+0.3$이고 두 달의 수익률이 각각 10%였다면 기여는 $-0.2(0.10)+0.3(0.10)=+0.01$이다. 직전 달의 반전 신호와 그 전 달의 모멘텀 신호가 동시에 존재해 총예측은 1%포인트 높아진다. 절편과 다른 355개 특징을 더해야 실제 예측값이 되므로 두 계수만으로 주문을 결정하지 않는다.

슬라이드 43 · 모의실험에서 벌점이 작동하는 방식

진짜 변수 10개를 넘어서 잡음 변수까지 넣으면 OLS의 표본내 점수는 계속 좋아질 수 있다. 능형 벌점은 잡음 변수의 우연한 계수를 낮춰 새 관측치의 오차를 줄인다. 그렇다고 모든 벌점이 좋은 것은 아니다.

과도한 벌점은 진짜 변수까지 거의 0으로 만들어 과거 평균과 다르지 않은 예측을 준다. 따라서 그래프에서는 표본외 곡선이 가장 높은 **중간 벌점 구간**을 찾는다. 반복 시뮬레이션의 평균 곡선은 한 번의 운 좋은 표본이 아니다.

시뮬레이션의 평가는 각 반복에서 **새 훈련자료로 다시 계수를 추정**하고 별도의 새 시험자료에 적용해야 한다. 한 번 추정한 계수를 여러 새 표본에만 적용하면 그 특정 훈련표본의 운은 남는다. 반복별 성과의 평균뿐 아니라 분산도 함께 보면, Ridge가 평균적으로 나은지와 드문 경우에 크게 실패하는지를 구별할 수 있다.

슬라이드 44 · 여기까지의 처방

약한 신호에서 많은 계수를 자유롭게 추정하면 추정분산이 커진다. 능형회귀는 계수를 모두 남기면서 정보가 부족한 방향을 더 강하게 줄여 예측을 안정시킨다.

다음에 살펴볼 라쏘는 일부 계수를 0으로 만들어 입력을 줄인다. 같은 예측력을 낸다면 적은 입력은 자료 수집·검토 비용을 낮출 수 있다. 어떤 변수가 선택되는지와 그 선택이 기간에 따라 안정적인지는 별도로 확인한다.

슬라이드 45 · 변수 선택의 문제

재무비율, 가격 신호, 텍스트 지표를 수백 개 넣을 때 모든 계수가 조금씩 비영(非零)인지, 소수만 실질적으로 중요한지 모른다. 변수 선택은 예측 비용을 줄이고 설명을 간결하게 만들 수 있지만, 잘못된 제외는 편향을 키운다.

모든 기업에 없는 지표를 제외하면 자료 수집과 검증 비용도 줄어든다. 선택된 변수가 표본마다 크게 바뀐다면 '핵심 변수'라는 해석은 조심해야 한다. 여러 기간의 선택 빈도와 예측 성능을 함께 제시한다.

예를 들어 유료 데이터 지표 20개를 빼도 표본외 제곱오차와 비용 후 수익이 거의 변하지 않는다면 그 지표의 한계가치는 작다. 반대로 특정 위기 때만 유용한 지표라면 평균 점수가 같아도 위험관리 가치는 있을 수 있다. 변수 선택을 평균 예측오차 하나로 끝내지 않고, 사용 시점과 손실이 큰 상태에서의 기여를 분리해 본다.

슬라이드 46 · 제곱 벌점에서 절댓값 벌점으로

능형회귀의 L_2 벌점은 계수를 부드럽게 줄이지만 정확히 0으로 만들지 않는다. 라쏘는 L_1 벌점 $\sum_j |g_j|$을 사용한다. 0에서 꺾이는 모양 때문에 약한 계수는 0에 붙을 수 있다.

L_2 벌점의 미분은 0 근처에서 연속적으로 0으로 가므로 작은 계수를 정확히 0에 고정하는 힘이 약하다. L_1 벌점은 0의 양쪽 기울기가 서로 달라 0에서 모서리를 만든다. 자료의 기울기가 그 모서리를 넘지 못하면 최저점이 0이 된다. 이 차이가 라쏘의 희소성을 설명한다.

수학적으로 $g=0$에서 g^2의 도함수는 0이지만 $|g|$에는 한 값의 도함수가 없고 가능한 기울기 집합 $[-1,1]$이 있다. 자료 적합항이 0에서 미는 힘이 벌점의 이 구간 안에 있으면 $g=0$이 최적 조건을 만족한다. Ridge는 같은 상황에서 보통 작은 비영 계수를 남긴다. 라쏘의 0은 주어진 벌점과 다른 입력변수 아래 추가 적합의 편익이 작다는 판정이다. 상관된 대체 변수가 신호를 담고 있을 수 있으므로 개별 변수의 경제적 효과는 별도로 평가해야 한다.

슬라이드 47 · 라쏘 목적함수

표준화된 변수에서 라쏘는 $\min_g\{N^{-1}\|y-Xg\|^2+\gamma\sum_j|g_j|\}$를 푼다. $\gamma=0$은 OLS와 같고, 커질수록 많은 계수가 0이 된다. 절댓값은 0에서 미분 가능하지 않아 모든 변수에 대한 단순한 역행렬 해는 없다.

그러나 볼록 함수라 전역 최저점은 효율적 알고리즘으로 찾을 수 있다. 변수 수가 관측치보다 많아도 유용하며, 해가 하나만 존재하는지 여부는 변수의 상관 구조에 따라 따로 확인해야 한다.

슬라이드 48의 한 변수 목적함수와 연결하면 정규화된 설명변수 $x^\top x/N=1$에서 $N^{-1}\|y-xg\|^2$는 상수항을 빼고 $(g-z)^2$이며 $z=x^\top y/N$다. 그러므로 여기의 벌점 $\gamma|g|$는 $(g-z)^2+2\lambda|g|$의 $2\lambda=\gamma$에 대응한다. 같은 임계값을 비교할 때 목적함수 앞의 $1/N$과 2를 확인해야 한다.

슬라이드 48 · 연성 임계값의 유도

직교한 한 변수에서 OLS 계수를 z라고 하면 Lasso 문제는 상수항을 빼고 $(g-z)^2 + 2\lambda|g|$의 최소화와 같다. $g>0$이면 도함수 $2(g-z)+2\lambda=0$이므로 $g=z-\lambda$, 단 $z>\lambda$일 때만 양수다. $g<0$이면 $g=z+\lambda$이고 $z<-\lambda$여야 한다.

$$\hat{g}_{\text{lasso}} = \operatorname{sgn}(z)(|z|-\lambda)_+,$$
$$(u)_+ = \max(u, 0).$$

$|z|\le\lambda$이면 0이 최소점이다. 능형회귀는 비율로 줄이고 라쏘는 일정 크기를 빼며, 그 과정에서 약한 계수를 없앤다. 벌점의 정의에 따라 교재의 γ와 여기의 λ 사이에는 2배 상수 차이가 있을 수 있다.

세 구간을 직접 대입하면 $z=0.8$, $\lambda=0.5$일 때 해는 0.3이고, $z=0.3$이면 해는 0이다. $z=-0.8$이면 해는 -0.3이다. 0 양쪽에서 목적함수의 기울기가 부호를 바꾸는지 확인하면 $|z|\le\lambda$일 때 0이 최저점인 이유가 보인다. 작은 관측 상관을 신호로 확정하지 않는 규칙이다.

$g=0$에서는 절댓값의 도함수 대신 부분기울기 $\partial|g| = [-1,1]$을 쓴다. 목적함수의 0에서의 최적 조건은 $0 \in -2z + 2\lambda[-1,1]$이고, 이를 정리하면 $|z|\le\lambda$다. 경계 $|z|=\lambda$에서도 해는 0이다. 이 한 줄이 왜 라쏘가 정확히 0을 만들 수 있는지 미분 가능한 양·음 구간의 해와 이어 준다.

슬라이드 49 · 마름모의 꼭짓점

L_1 제약 $|g_1|+|g_2|\le c$는 두 차원에서 마름모이고 꼭짓점이 좌표축에 있다. 제곱오차의 타원 등고선이 제약 영역에 처음 닿는 곳이 꼭짓점이면 한 계수가 정확히 0이다. L_2 제약은 원이므로 축 위의 정확한 접촉이 상대적으로 드물다.

등고선이 꼭짓점에 닿는 경우가 많은 것은 마름모의 모서리가 좌표축과 정렬되어 있기 때문이다. 그러나 두 변수가 거의 같은 정보를 담으면 어느 축의 꼭짓점에 닿을지는 작은 자료 변화에 민감할 수 있다. '0이 된 변수는 중요하지 않다'고 단정하지 말고 비슷한 변수의 대체 가능성을 살펴야 한다.

극단적으로 $x_1 = x_2$이고 예측에 필요한 합이 $g_1+g_2=s>0$라면, $g_1, g_2 \ge 0$인 어떤 배분도 $|g_1|+|g_2|=s$로 같은 Lasso 벌점을 낸다. 어느 변수 하나에 s를 몰아도 적합과 벌점이 같아 선택 이름은 유일하지 않을 수 있다. 반면 제곱 벌점 $g_1^2+g_2^2$는 두 계수가 $s/2$씩일 때 가장 작다. 마름모와 원의 차이가 상관된 변수에서 어떻게 나타나는지 보여 준다.

슬라이드 50 · 라쏘 경로의 읽기

벌점이 매우 크면 기울기 계수가 모두 0이다. 벌점을 줄이면 먼저 자료와 강하게 연결된 변수가 들어오고, 이어 다른 변수가 들어온다. 경로의 각 지점은 하나의 후보 모형이다.

벌점을 줄이는 동안 새 변수가 들어오는 순서는 현재 이미 들어온 변수들에 조건부로 결정된다. 첫 변수와 거의 같은 두 번째 변수는 단독 상관이 커도 늦게 들어올 수 있다. 경로의 순서를 경제적 중요도의 순위로 읽지 말고, 각 후보 모형의 검증오차와 선택 안정성을 함께 읽는다.

슬라이드 47의 목적함수 $N^{-1}\|y-Xg\|^2 + \gamma\sum_j|g_j|$를 기준으로, 현재 $g_j=0$인 변수의 입력 벡터를 x_j, 잔차를 $r=y-Xg$라 하면 0에 머무는 조건은 $|2x_j^\top r/N| \le \gamma$다. 벌점 γ를 줄여 이 부등식이 깨지면 그 변수는 경로에 들어올 수 있다. 여기서 r은 이미 선택된 다른 변수들을 사용한 **현재 잔차**이므로, 진입 순서가 각 변수와 원래 수익률의 단순 상관 순서와 같을 필요는 없다.

슬라이드 51 · 상관된 쌍둥이 변수

두 예측변수가 거의 같은 정보를 담으면 라쏘는 하나에 계수를 몰아주고 다른 하나를 버릴 수 있다. 표본이 조금만 바뀌어도 살아남는 변수의 이름이 바뀔 수 있다. 예측은 안정적이어도 변수 선택 결과는 불안정한 것이다.

예측의 목적이라면 두 쌍둥이 변수 중 어느 하나가 남아도 성능이 비슷할 수 있다. 반면 설명의 목적이라면 선택된 이름이 바뀔 때 결론도 바뀌므로 불안정성이 문제다. 여러 훈련 구간에서 재적합해 선택 빈도를 비교하거나 관련 변수를 한 군집으로 묶어 해석하면 과도한 단정이 줄어든다.

예를 들어 열 번의 시간 구간 재적합에서 배당/주가가 일곱 번, 이익/주가가 세 번 선택되고 예측오차는 비슷하다면, '배당이 유일한 원인'보다 '가치 관련 정보가 반복해서 사용된다'는 해석이 강하다. 선택 빈도도 상관된 입력과 벌점 설정의 산물이므로 원인확률로 읽어서는 안 된다. 어떤 변수가 탈락했을 때 다른 변수가 대체하는지도 같이 본다.

슬라이드 52 · 엘라스틱넷의 두 벌점

엘라스틱넷은 $\min_g\{N^{-1}\|y-Xg\|^2+\gamma_1\sum_j|g_j|+\gamma_2\sum_j g_j^2\}$를 푼다. L_1은 약한 변수를 제거하고 L_2는 상관된 변수 사이의 가중치를 나누어 해를 안정화한다.

서로 비슷한 재무비율이 많을 때는 L_2가 상관된 변수들의 가중치를 안정화하고 L_1이 일부를 제거한다. 두 벌점의 증분 효과는 $\gamma_1=0$인 능형회귀와 $\gamma_2=0$인 라쏘를 같은 검증 절차로 비교해 본다. 하이퍼파라미터가 하나 더 늘어난 만큼 검증자료에 우연히 맞을 기회도 늘어난다.

앞의 완전히 같은 두 변수 예시에서 $g_1+g_2=s>0$를 고정하면 L_1 비용은 비음수 배분 어디서나 $\gamma_1 s$로 같다. 그러나 L_2 비용은 $\gamma_2(g_1^2+g_2^2)$이어서 $g_1=g_2=s/2$일 때 가장 작다. $\gamma_2>0$가 쌍둥이 변수의 임의 선택을 줄이는 이유가 이 작은 계산에 담겨 있다. 실제로는 두 변수가 완전히 같지 않으므로 검증과 선택 안정성을 함께 본다.

슬라이드 53 · 어떤 벌점이 맞는가

진짜 효과가 넓게 퍼져 있다면 능형회귀의 모든 계수 축소가 유리할 수 있다. 효과가 소수 변수에 집중되면 라쏘의 희소성이 유리하다. 관련 변수들이 군집을 이루면 엘라스틱넷이 실용적일 수 있다.

모형군 선택도 하이퍼파라미터 탐색이다. Ridge 벌점 20개, Lasso 벌점 20개, Elastic Net 조합 40개를 시험했다면 총 80개 후보 중 검증 최저점을 고른 셈이다. 검증자료의 우연에 맞을 가능성을 감안해 탐색 범위를 기록하고, **최종 시험기간은 선택에 사용하지 않는다**. 자료가 적다면 효과가 넓게 퍼졌는지 군집을 이루는지에 대한 경제적 사전지식도 후보를 줄이는 데 쓸 수 있다.

슬라이드 54 · 벌점 선택과 채점

벌점 γ는 회귀계수와 달리 모형을 적합하기 전에 선택하는 **하이퍼파라미터**다. 같은 훈련자료의 제곱오차만 보면 벌점을 줄일수록 적합이 좋아지므로 항상 0을 선택한다. 미래 성능을 위한 벌점은 보지 않은 자료로 정해야 한다.

교차검증은 제한된 자료를 여러 번 나누어 각 관측치를 검증에 사용한다. 금융 자료에서는 공시 발표일과 목표 수익률의 기간을 따라 나누어야 한다. 검증 달보다 뒤의 수익률을 훈련에 쓰

면 벌점 선택에도 미래 정보가 들어간다. 후보를 여러 개 비교해 고른 검증 최저값에는 선택에 따른 낙관도 남으므로 최종 시험이 필요하다.

훈련오차가 $\gamma = 0$에서 가장 낮아도 검증오차는 중간 벌점에서 최저가 될 수 있다. 예를 들어 세 후보의 훈련 제곱오차가 80·85·100이고 검증 오차가 110·90·105라면, 둘째 후보가 검증 구간에서 가장 작게 틀렸다. 벌점은 훈련 적합도를 일부 양보해 미래 오차를 줄이려는 선택이다.

슬라이드 55 · 하이퍼파라미터와 계수의 역할

훈련은 계수 추정, 검증은 벌점 선택, 시험은 최종 성능 보고에 쓴다. 예를 들어 훈련 구간에서 라쏘 계수를 추정하고 다음 구간에서 γ 후보 10개를 비교한 뒤, 마지막 구간은 고른 모형을 한 번만 평가한다. 그 결과로 후보를 다시 바꾸었다면 더 뒤의 새 기간에서 최종 성능을 측정한다.

표준화 평균과 결측치 대체 규칙도 계수와 마찬가지로 훈련자료에서 배운 값이다. 검증 단계에서 벌점만 분리하고 전처리를 전체 기간으로 계산하면 이미 시험 기간이 모형에 관여한 셈이다. 각 재학습 시점마다 전처리 → 계수 추정 → 검증 예측을 같은 과거 정보 집합 안에서 다시 수행해야 한다.

슬라이드 56 · k겹 교차검증을 계산하기

표본을 k개 묶음 $V_1, \dots, V_k$로 나누고, 각 묶음 v를 뺀 자료에서 $\hat{g}_{-v}(\gamma)$를 적합한다. 남겨 둔 관측치 i의 예측오차를 $e_{i,v} = y_i - x_i^\top \hat{g}_{-v}(\gamma)$라 하면, 묶음별 제곱오차 CV_v를 평균한 값이 교차검증 점수다.

$$
\begin{aligned}
CV(\gamma) &= \frac{1}{k} \sum_{v=1}^{k} CV_v(\gamma), \\
CV_v(\gamma) &= \frac{1}{|V_v|} \sum_{i \in V_v} e_{i,v}^2, \\
e_{i,v} &= y_i - x_i^\top \hat{g}_{-v}(\gamma).
\end{aligned}
$$

각 묶음에서 기준선도 동일한 훈련 부분으로 다시 계산해야 한다. 전체 표본의 평균을 검증 묶음에 대한 기준 예측으로 쓰면 미래 정답을 기준선에 포함하게 된다. 또한 식의 $1/k$ 평균은 묶음 크기가 같을 때 각 관측치의 비중이 같다. 크기가 다르면 관측치 수로 가중해 전체 제곱오차를 계산할 수 있다.

예를 들어 관측치 120개를 다섯 묶음으로 나누면 한 번마다 96개로 적합하고 남은 24개로 채점한다. 벌점 후보가 20개라면 적어도 $5 \times 20 = 100$번 적합한다. 각 후보의 다섯 검증오차를 모아 벌점을 고른 다음, 선택된 벌점으로 사용 가능한 훈련자료 전체에 **다시 적합**해야 최종 예측모형이 된다. 다만 100번의 비교에 사용한 검증 점수를 최종 성능으로 보고하면 선택에 따른 낙관이 남는다. 시간상 뒤에 남겨 둔 시험기간은 마지막 한 번만 평가해야 한다.

슬라이드 57 · 금융 교차검증의 두 경고

미래 운용을 평가할 때는 검증 블록보다 앞선 기간으로만 적합하는 **forward chaining**이 자연스럽다. 2015년을 검증하면서 2020년 자료로 계수를 적합하면 블록을 나누었어도 시간 누출이 생긴다. 벌점 선택에 사용한 검증 점수에는 낙관이 남으므로 맨 뒤의 손대지 않은 기간에서 최종 성능을 측정한다.

목표가 12개월 누적수익률이면 인접한 두 관측치가 미래 11개월을 공유한다. 훈련·검증 경계에서 이 중첩 기간을 제거하거나 간격을 두어 같은 충격이 양쪽 목표에 들어가지 않게 한다. **훈련의 시간 방향**과 **목표 기간의 중첩**은 각각 따로 점검할 사항이다. 기업별 관측도 어느 기업·기간에 일반화할지에 맞춰 묶는다.

슬라이드 58 · OLS, 능형, 라쏘의 결과 비교

같은 과거 수익률 특징 357개를 쓰면 OLS가 표본내 R^2는 가장 높아도 검증 점수는 음수가 될 수 있다. 능형과 라쏘는 표본내 적합을 포기하는 대신 검증 점수를 양수로 만들 수 있다. 이것이 편향을 도입한 이유를 경험적으로 보여 준다.

가령 OLS의 훈련 $R^2 = 30\%$, 시험 $R^2 = -5\%$, Ridge의 훈련 $R^2 = 20\%$, 시험 $R^2 = 1\%$라면 Ridge가 미래 기준선 대비 오차를 더 줄인 것이다. 훈련과 시험 점수는 자료와 분모가 달라 그 차이를 투자수익률로 환산할 수 없다. 실제 운용 성과는 종목 선정, 매매 시점, 상장폐지 수익률, 거래비용을 포함해 새 기간에서 확인한다.

슬라이드 59 · 예측 점수와 투자 성과가 다른 이유

R^2는 모든 종목의 예측오차 제곱을 벌하지만, 상위·하위 종목을 동일가중으로 매매하는 전략에는 **순위**가 중요하다. 예측값이 실제값보다 늘 절반 작아도 순서가 같다면 선택 종목은 그대로다. 거래가 잦거나 유동성이 낮은 종목에 몰리면 R^2가 높아져도 순수익은 낮아질 수 있다.

예측값에 비례해 **비중**을 정하는 전략에서는 같은 축소가 투자 규모와 위험을 바꾼다. 채점 전에 포트폴리오 규칙을 고정하고 제곱오차, 순위, 총손익, 비용 뒤 순손익을 각각 계산한다. 매매할 수 없는 종목의 예측오차 개선은 실제 운용에 반영되지 않는다는 점도 확인한다.

슬라이드 60 · 시장 전체 예측으로 돌아오기

정규화는 시장수익률 예측에서도 계수의 요동을 줄일 수 있다. 하지만 한 나라의 10년 월별 시장수익률은 120개뿐이다. 같은 기간 3,000개 종목을 추적하면 행은 많아도 같은 달의 종목은 금리·경기 충격을 공유한다. 횡단면에는 같은 시점의 기업 간 차이라는 추가 정보가 있으므로, 종목의 상대 수익률 예측 성과를 시장 타이밍으로 옮기려면 목표와 독립 관측 단위를 다시 정의해야 한다. 위기와 제도 변화에 걸쳐 기준선보다 나은지도 확인한다.

슬라이드 61 · 극단적 복잡성의 논쟁

짧은 자료에 비해 훨씬 많은 무작위 비선형 특징을 만들고 능형회귀를 적용하면, 겉으로는 큰 표본외 성과가 나올 수 있다. 한 해석은 높은 차원의 표현이 놓친 패턴을 잡았다는 것이다. 다른 해석은 특정 설정에서 예측이 최근 수익률의 가중평균으로 수렴해 단순 모멘텀을 재포장한다는 것이다.

단순한 최근 수익률 가중평균, 무작위 특징 모형, 둘을 합친 모형을 같은 시점·종목·비용 기준으로 비교하면 복잡한 특징의 증분 가치를 측정할 수 있다. 여러 무작위 시드 중 최고 성적을 골랐다면 시드도 하이퍼파라미터다. 특징 수와 벌점 탐색 범위를 함께 기록하고 독립 기간에서 검증한다. 특징을 많이 생성해도 **새로운 독립 역사**가 늘지는 않는다.

슬라이드 62 · 수익률 예측에서 확립된 규칙

분석 순서는 **예측 시점과 목표 설정 → 당시 공개 자료 구성 → 기준선 설정 → 훈련·검증에서 벌점 선택 → 손대지 않은 시험기간 평가**다. 마지막에는 예측오차와 거래비용 뒤 손익을 함께 보고한다. 사용한 변수와 수정 이력, 전처리, 벌점 후보, 기간, 비용 가정을 남기면 다른 사람이 결과를 재현하고 이후 성과 변화의 원인을 추적할 수 있다.

다음 장에서는 시장 전체에서 종목 간 상대 수익률로 대상을 바꾼다. 종목 특성의 예측력과 위험 보상·가격오류의 설명, 여러 요인을 검정하며 생기는 선택 편향을 함께 다룬다.

Session 4A · 종목 간 기대수익률과 요인 논쟁

시장이 내년에 오를지 예측하는 일과, 같은 달에 어떤 종목이 다른 종목보다 나을지 예측하는 일은 다르다. 후자는 공통 시장 충격을 롱숏(long–short) 포지션으로 일부 상쇄할 수 있지만, 작은 주식의 거래비용과 공매도 제약이 중요해진다. 이 장은 종목 특성을 전략으로 만드는 절차에서 출발해 위험 보상·가격오류·우연이라는 세 설명을 평가한다.

슬라이드 01 · 횡단면의 출발점

횡단면은 **한 시점의 여러 종목**을 가리킨다. 시장 시계열 예측은 다음 달 시장 전체의 평균을 묻지만, 횡단면 예측은 같은 달 종목의 상대 순위를 묻는다. 모든 종목이 하락한 달에도 덜 하락한 종목을 사고 더 하락한 종목을 공매도하면 롱숏 차이는 양수일 수 있다.

같은 금액을 매수하고 공매도하는 **달러 중립** 포트폴리오도 시장 베타가 남을 수 있다. 매수 다리의 베타가 1.2, 매도 다리가 0.8이면 순베타는 0.4다. 시장이 10% 하락할 때 각 다리에 1원씩 건 전략은 잔차수익이 없다는 가정에서 약 4전 손실을 본다. 베타 중립을 원한다면 두 다리의 금액을 조정해야 하므로 종목 순위의 예측력과 시장 노출을 따로 측정한다.

슬라이드 02 · 앞 장에서 건너오는 다리

한 달 3,000개 종목을 60개월 관찰하면 자료 행은 18만 개다. 3,000개 종목은 **같은 거시 상태에서** 기업 특성과 수익률의 관계를 비교하는 데 도움이 된다. 그러나 경기 충격을 관찰한 서로 다른 달은 60개다. 그 관계가 여러 경기 상태에서도 유지되는지는 시간에 따른 기울기의 변동으로 판단한다. 그래서 매달 단면 기울기를 추정한 뒤 그 평균의 표준오차를 잰다.

슬라이드 03 · 요인 동물원의 네 질문

요인 동물원(factor zoo)에서는 수백 개 기업 특성 가운데 어느 것이 다른 특성을 통제한 뒤에도 정보를 갖는가. 그 정보를 보상받는 위험으로 설명할 수 있는가. 발표된 전략은 새 기간과 큰 종목에서도 남는가. 여러 변수가 같은 경제적 주제를 반복 측정하는 것은 아닌가.

장부가치/시가총액 신호가 규모를 통제한 뒤에도 남는다면 독립적인 예측력의 증거를 얻은 것이다. 불황에 손실을 주는지를 봐야 위험 보상 설명을 평가할 수 있다. 다른 나라에서도 반복되지만 극소형주에만 있고 왕복 거래비용이 수익보다 크다면 통계적 재현과 실제 운용 가능성의 답은 다르다. 각 연구가 네 질문 중 어디까지 답했는지 표시해 읽는다.

슬라이드 04 · 특성에서 전략으로

장부가치/시가총액이나 지난 11개월 수익률 같은 특성은 기업별 숫자다. 투자전략은 이 숫자로 종목을 정렬하고 어느 그룹을 사고 팔지 정해야 비로소 정의된다. 같은 특성도 동일가중·시가총액가중, 소형주 포함 여부에 따라 다른 성과를 낸다.

100개 종목을 동일가중하면 각 1%지만 시가총액가중에서는 대형주가 성과를 주도한다. 정렬 기준, 가중치, 재조정일을 명시해야 큰 자금으로 재현할 수 있는 전략인지 판단할 수 있다.

결산일이 12월 31일인 기업의 장부자본이 다음 해 3월 공시되었다면 1월 정렬에는 이 값을 쓸 수 없다. 자료 파일에 '12월 값'으로 적혀 있어도 투자자가 알게 된 날은 3월이다. 정렬일의 가격과 이전에 공개된 장부자본을 결합하고, 분할·상장폐지·공시 정정까지 같은 시점 원칙으로 처리해야 전략의 백테스트가 실제 가능했던 결정을 재현한다.

가중치가 결과를 어떻게 바꾸는지 세 종목으로 확인하자. 시가총액이 70, 20, 10이고 다음 달 수익률이 각각 $+10\%$, 0, -10%라면 시가총액가중 수익률은 $0.7(10\%) + 0.2(0) + 0.1(-10\%) = 6\%$, 동일가중 수익률은 $(10\% + 0 - 10\%)/3 = 0$이다. 시가총액가중은 전체 주식 수가 그대로라면 가격 변화 뒤에도 새 시가총액 비율로 자연스럽게 이동한다. 동일가중은 상승 종목을 일부 팔고 하락 종목을 사야 다음 달에도 각 $1/3$을 유지한다.

슬라이드 05 · 십분위 포트폴리오 정렬

매월 종목을 특성 $X_{i,t}$ 순서로 10개 그룹에 나눈다. 상위 그룹을 매수하고 하위 그룹을 공매도한 뒤 다음 달 수익률 차이 $r_{10,t+1} - r_{1,t+1}$를 시간 평균한다. 종목이 1,000개면 보통 그룹마다 100개가 들어가며, 경계의 동률 처리와 그룹 안의 가중치를 정해야 전략이 완성된다.

수익률 차이는 **매수와 공매도에 각각 같은 금액을 건 경우** 한쪽 금액당 손익이다. 각 다리에 100원씩 걸어 매수 그룹이 5%, 공매도 그룹이 -2%를 기록하면 손익은 7원이다. 한쪽 100원당 7%, 총 명목금액 200원당 3.5%다. 순투자금이 0원이므로 이를 분모로 나눈 수익률은 정의되지 않는다.

재정렬할 때에는 가격 변화로 이미 움직인 비중과 새 목표 비중을 비교한다. 거래 직전 비중은 $w_i^{\text{drift}} = w_i(1 + r_i)/(1 + r_p)$이고, 양쪽 거래액을 세는 회전율은 $\sum_i |w_i^{\text{target}} - w_i^{\text{drift}}|$이다. 동일가중 세 종목의 수익률이 $+10\%, 0, -10\%$라면 거래 직전 비중은 $0.3667, 0.3333, 0.3000$이므로 회전율은 약 6.67%다. 순수익을 구할 때는 이 거래액에 스프레드·대차 비용을 적용하고 상장폐지 수익률도 포함한다.

슬라이드 06 · 파마·맥베스 회귀의 두 단계

한 달에 주식이 수천 개라도 같은 경기 충격을 받으므로 종목 수만큼 독립적인 실험을 한 셈은 아니다. Fama–MacBeth 방법은 먼저 **매월의 단면**에서 특성과 다음 달 수익률의 관계를 추정한다. i는 종목, t는 특성을 관찰한 달이고, $X_{i,t}$는 수익률을 보기 전에 알 수 있어야 한다. $r_{i,t+1} = a_t + b_t X_{i,t} + e_{i,t+1}$에서 a_t는 그 달의 공통 절편, b_t는 특성이 한 단위 높은 종목의 상대수익 기울기, $e_{i,t+1}$은 설명되지 않은 수익률이다. 그런 다음 T개월의 기울기를 평균한 $\bar{b} = T^{-1}\sum_t b_t$가 0과 다른지 검정한다.

첫 단계는 매달의 상대수익 관계를, 둘째 단계는 그 관계가 여러 달에 걸쳐 지속되는지를 묻는다. 여러 특성을 함께 넣으면 다른 특성을 고정한 조건부 기울기를 얻는다. 계수의 숫자는 특성의 단위에 따라 달라진다.

간단히 세 달의 기울기가 0.01, 0.02, 0.03이면 평균은 0.02다. 표본 표준편차는 0.01이고 독립월이라는 가정 아래 평균의 표준오차는 $0.01/\sqrt{3} \approx 0.0058$이다. 이 작은 예는 두 단계의 계산을

보여 줄 뿐, 세 달만으로 경제적 효과를 확정하기에는 기간이 너무 짧다. 기울기가 연속된 달에 함께 움직이면 표준오차 계산도 바뀐다.

슬라이드 07 · 높은 수익률과 이상현상의 차이

불황처럼 돈이 절실한 때 함께 하락하는 주식에는 투자자가 더 높은 기대수익률을 요구한다. 이것이 **위험 보상**의 경제적 이유다. **이상현상**은 기준 자산가격모형이 그 보상을 계산한 뒤에도 남는 수익률 차이며, 판정은 어떤 위험을 기준에 넣었는지에 달려 있다.

CAPM에서는 시장과 함께 움직이는 정도인 베타 β_{iM}에 시장의 평균 초과수익률을 곱해 위험 보상을 계산한다. 종목 수익률 r_i와 무위험수익률 r_f의 차이에서 그 보상을 빼면 알파다.

$$\alpha_i = E[r_i - r_f] - \beta_{iM} E[r_M - r_f].$$

종목의 연평균 초과수익이 8%, 시장의 초과수익이 5%, 베타가 1.6이면 CAPM의 위험 보상은 $1.6(5\%) = 8\%$이고 알파는 0이다. 높은 원수익률이 전부 시장 노출에서 왔다는 판정이다. 다른 요인모형을 쓰면 알파가 달라질 수 있다.

시장 베타가 음수라면 알파가 원평균보다 클 수도 있다. 월평균 수익률 1.0%, 시장 초과수익 평균 0.5%, 베타 -0.4인 전략의 알파는 $1.0\% - (-0.4)(0.5\%) = 1.2\%$다. 시장에 역방향으로 노출된 불리한 기여를 위험 조정에서 되돌린 결과다. 알파의 불확실성은 표준오차로, 급격한 손실 가능성은 별도의 위험지표로 평가한다.

슬라이드 08 · 왜 월별 기울기의 표준오차를 쓰는가

한 달에 3,000개 종목이 있어도 모두 같은 금리·경기 충격을 겪는다. 모든 종목·월을 독립 관측치로 취급한 단순 합동회귀는 표준오차를 지나치게 작게 만들 수 있다. 월별 횡단면 기울기 b_t를 구한 뒤 시간에 따라 변하는 b_t의 분산으로 평균의 불확실성을 재는 이유다.

$$\widehat{\mathsf{se}}(\bar{b}) = \sqrt{\frac{1}{T(T-1)} \sum_{t=1}^{T} (b_t - \bar{b})^2}.$$

월별 기울기가 자기상관을 가지면 분산 계산에 시차별 공분산이 더해진다. 즉 $\mathrm{Var}(\bar{b})$는 단순한 월별 분산 나누기 T가 아니라, 인접한 달의 기울기가 함께 움직이는 정도를 반영한다. Newey–West는 일정한 시차까지 이런 공분산을 더해 장기분산을 추정한다.

위 식은 월별 기울기의 표본분산 $s_b^2 = \sum_t (b_t - \bar{b})^2/(T-1)$을 T로 나눈 뒤 제곱근을 취한 $s_b/\sqrt{T}$다. 연속된 달의 기울기가 비슷하면 독립 반복의 수가 줄어들어 이 값은 작게 추정된다.

슬라이드 09 · 여섯 범주의 지도

수익률 예측변수는 모멘텀, 가치, 투자, 수익성, 무형자산, 거래마찰로 묶을 수 있다. 이는 변수를 정리하는 **분류표**이지 각 범주의 인과이론이 아니다. 같은 범주 안에도 측정 방식과 경제적 채널이 다르다.

가치 범주의 장부가치/시가총액과 이익/가격은 모두 낮은 가격을 포착하지만 회계자료의 의미가 다르다. 같은 이름 아래 신호를 합치기 전에 분자·분모, 발표 시점, 산업별 차이를 확인한다.

범주가 서로 배타적일 필요도 없다. 연구개발비를 당기 비용으로 처리하는 기업은 장부상 자기자본이 작아져 가치비율이 달라질 수 있고, 투자 확대는 현재 이익률과 미래 수익성에도 영향을 준다. 이때 가치·무형자산·투자 신호가 서로 상관된다고 해서 세 개의 독립된 경제 효과를 발견한 것은 아니다. 한 신호를 평가할 때 관련 범주의 다른 특성을 통제한 뒤에도 남는지를 확인하는 이유다.

슬라이드 10 · 여섯 범주의 대표 신호

모멘텀은 최근 승자, 가치는 낮은 가격/기초가치, 투자는 자산 증가가 낮은 기업, 수익성은 이익률이 높은 기업을 매수하는 방향이다. 무형자산은 연구개발과 조직자본처럼 장부에 잘 보이지 않는 투자, 거래마찰은 규모·유동성·변동성과 연결된다.

신호의 방향도 정의에 따라 뒤집힌다. B/M이 높은 종목을 가치주라 부르면 높은 값 매수지만, 같은 정보를 M/B로 쓰면 낮은 값 매수다. 표에 '효과가 양수'라고 적혔을 때 변수 정의와 정렬 방향을 함께 읽어야 한다. 실무에서는 원자료의 단위와 극단값 처리까지 맞춰야 재현 가능하다.

B와 M이 모두 양수라면 $M/B = 1/(B/M)$이어서 순위가 정확히 뒤집힌다. 하지만 장부자본 B가 0이거나 음수인 기업에는 이 역수 관계로 단순 정렬할 수 없다. 손실 기업을 제외할지 별도 그룹으로 둘지에 따라 가치 신호의 표본 자체가 달라진다. '부호만 반대'라는 설명은 양의 분모와 동일한 표본에서만 성립한다.

슬라이드 11 · 낮은 가격은 두 가지를 말한다

현재 가격은 미래에 받을 현금흐름의 현재가치다. 한 기간 뒤의 현금흐름을 CF, 그 자산의 기대수익률을 $E[r]$라 쓰면 단순한 한 기간 식은 $P = E[CF]/(1 + E[r])$다. 가격이 낮다면 예상 현금흐름이 작거나 요구수익률이 높을 수 있다. 가격만으로는 두 원인을 가를 수 없다.

위험의 원천을 보려면 미래 상태마다 현금흐름의 가치를 다르게 매겨야 한다. 확률적 할인인자 m_{t+1}은 **그 상태에서 1원을 받는 가치에 적용하는 가중치**다. 불황처럼 소비가 부족한 상태에서 투자자의 한계효용이 커지면 보통 이 가중치도 높다. 상태별 가치와 현금흐름의 곱을 평균한 엄밀한 가격식은 $P_t = E_t[m_{t+1}CF_{t+1}]$이다. E_t는 현재 정보에 조건부인 기댓값이다.

공분산의 정의를 대입하면 $P = E[m]E[CF] + \mathrm{Cov}(m, CF)$다. 불황에 m은 높은데 기업 현금흐름이 작다면 공분산은 음수다. 같은 평균 현금흐름이어도 가격이 낮아질 수 있으므로, 낮은 가격을 곧바로 시장의 예상오류라고 부를 수 없다.

슬라이드 12 · 각 범주를 같은 질문으로 읽기

첫째, 특성은 언제 측정하고 어떤 종목을 매수·매도하는가. 둘째, 왜 수익률 차이가 생기는가. 위험에 대한 보상인지, 투자자의 지나친 낙관·비관이 수정되는 것인지 따진다. 셋째, 원래 표본을 벗어나도 남는가.

예컨대 연말 장부가치를 이용해 1월 1일 종목을 정렬했다면, 그 장부가치가 **실제로 언제 공시됐는지** 확인해야 한다. 3월에야 알려진 숫자를 1월 매수 규칙에 넣으면 미래 정보가 과거 결정에 들어간다. 매수 방향과 수익률이 같더라도 공개 시점을 맞추어 다시 계산하면 성과가 달라질 수 있다. 후보 신호마다 '측정 기준일'과 '투자자가 알게 된 날'을 따로 기록하자.

슬라이드 13 · 모멘텀의 위치

모멘텀은 과거 상승 종목이 단기적으로 더 상승하는 경향이다. 시장 전체가 계속 오르는 것과 다르게 **같은 달 종목 사이의 상대 승자**를 말한다. 투자자의 정보 반응 지연, 추세 추종 거래, 위험 노출 등이 가능한 설명이다.

직전 1개월에는 단기 반전, 2~12개월에는 지속, 더 긴 기간에는 다시 반전이 나타날 수 있다. 한 구현은 지난 12개월 중 **직전 한 달을 제외한** 수익률로 종목을 정렬해 승자를 매수하고 패자를 공매도한다. 형성·보유 기간을 여러 개 시험한 뒤 가장 높은 성과만 보고하면 선택 편향이 생긴다. 큰 하락 뒤 시장이 반등해 과거 패자가 급등하면 공매도 다리에서 큰 손실이 난다. 모멘텀 폭락 연구[22]는 이 상태 의존적 위험을 다룬다.

슬라이드 14 · 과거 승자가 계속 이기는가

매월 형성 시점까지 공개된 가격으로 지난 6~12개월 수익률을 계산하되 직전 한 달을 뺀다. 승자 그룹을 사고 패자 그룹을 판 뒤 다음 달 수익률을 잰다. 실적 서프라이즈 뒤의 가격 지연 반응도 관련 모멘텀 신호다.

단기 반전 때문에 직전 한 달을 빼는 설계는 임의적인 숫자 놀이가 아니다. 거래비용·유동성 충격과 중기 정보 반응을 구분하려는 장치다. 대형주에서도 남는지와 매매회전율을 함께 확인해야 한다.

날짜로 풀면 2026년 9월 말에 종목을 정렬할 때 2025년 10월부터 2026년 8월까지의 11개월 수익률을 신호로 쓰고, 바로 앞선 2026년 9월 수익률은 제외한 뒤 2026년 10월에 보유한다는 뜻이다. 실제 구현에서는 어느 날의 종가로 신호를 마감하고 언제 주문을 체결하는지까지 정해야 한다. 신호 계산에 쓴 종가를 이미 지난 체결 가능 가격처럼 취급하면 매매 가능성이 과장된다.

슬라이드 15 · 모멘텀의 위험과 가격오류 설명

위험 설명은 승자·패자 포트폴리오가 나쁜 경제 상태에서 손실을 주기 때문에 평상시 높은 평균 수익률이 보상이라는 주장이다. 가격오류 설명은 투자자가 새 정보에 천천히 반응해 승자의 좋은 소식이 몇 달에 걸쳐 가격에 반영된다는 주장이다.

가격오류가 느린 정보 반응에서 온다면 실적발표 뒤 수개월의 가격 조정과 분석가 전망의 늦은 수정이 나타날 수 있다. 위험 보상이라면 투자자의 한계효용이 높은 위기 때 손실이 집중되는지를 본다. 어느 한 결과만으로 설명을 확정하기보다 **기대의 수정 시점**과 **상태별 손익**을 함께 비교한다.

슬라이드 16 · 평균 모멘텀과 폭락 위험

모멘텀의 평균 수익이 양수라도 시장 급락 뒤 강한 반등에서는 과거 패자들이 폭등할 수 있다. 패자를 공매도한 포지션은 이때 큰 손실을 낸다. 평상시 평균과 위기 상태의 손실이 비대칭인 것이다.

손실은 단순 표준편차보다 꼬리위험, 마진 요구, 포지션 강제청산에 중요하다. Daniel·Moskowitz[23]의 분석은 모멘텀 수익과 급격한 반전 위험을 함께 평가하게 한다. 전략의 적정 규모는 평균수익률뿐 아니라 이런 상태에서 버틸 수 있는 자금에 달려 있다.

[22] https://doi.org/10.1016/j.jfineco.2015.12.002
[23] https://doi.org/10.1016/j.jfineco.2015.12.002

승자 다리가 한 달에 2% 오르고 패자 다리가 10% 오르면 롱숏 수익은 $2\% - 10\% = -8\%$다. 두 다리 모두 올랐는데 전략 전체는 크게 손실을 낸다. 공매도 담보 요구가 손실 중간에 커져 포지션을 청산해야 하면 월말의 계산상 수익보다 실제 손실이 더 커질 수 있다. 평균·표준편차와 함께 위기 달의 두 다리 수익을 따로 기록한다.

슬라이드 17 · 가치와 성장의 구분

가치주는 주가가 장부가치, 이익, 현금흐름에 비해 낮은 기업이다. "가격이 싸다"는 것은 주당 절대가격이 낮다는 뜻이 아니라 기초가치와의 비율이 낮다는 뜻이다. 성장주는 미래 확장에 대한 기대가 가격에 많이 반영된 기업이다.

가치 프리미엄은 가치주를 사고 성장주를 판 상대수익률이다. 두 그룹의 현재 수익성과 미래 성장성이 달라 비율의 분모가 지속 가능한지 확인해야 한다.

같은 주당 가격 1,000원이라도 주당 순이익이 100원이면 주가수익비율 $P/E = 10$, 순이익이 10원이면 $P/E = 100$이다. 전자는 현재 이익 대비 가격이 낮지만 미래 이익이 급감할 위험도 있을 수 있다. 가격의 절대 숫자와 가격을 기초량으로 나눈 비율을 구별한 뒤, 비율의 분모가 지속 가능한지 확인해야 한다.

슬라이드 18 · 장부가치/시가총액으로 정렬하기

B/M은 장부상 자기자본 B를 시가총액 M으로 나눈 값이다. $B = 100$억 원, $M = 50$억 원인 기업의 값은 2이고, $B = 20$억 원에 같은 시가총액인 기업의 값은 0.4다. 높은 값은 장부자본에 비해 가격이 낮다는 뜻이며, **청산가치가 높다거나 저평가됐다는 판정**까지 담고 있지는 않다.

장부자본은 과거 회계처리의 결과라 현재 매각가나 미래 현금흐름과 다를 수 있다. 산업별 무형자산 비중도 달라 업종 내 정렬이나 무형자산 보정이 결과를 바꾼다. 성과를 계산할 때는 재무제표가 공개된 시점과 상장폐지 수익률을 반영한다.

장부자본이 0 이하인 기업은 비율의 순위 해석이 어려우므로 제외하거나 별도 그룹에 두는 규칙이 필요하다. 주식분할은 가격과 주식 수를 반대로 바꾸어 시가총액을 유지하므로 그 자체로 B/M을 바꾸지 않는다.

슬라이드 19 · 가치 프리미엄의 두 해석

위험 해석은 가치기업의 현금흐름이 경기 악화 때 더 크게 줄어들어 투자자가 높은 기대수익률을 요구한다는 것이다. 가격오류 해석은 시장이 과거 부진을 지나치게 연장해 낮은 가격을 매겼다가 예상을 고치는 과정에서 초과수익이 생긴다는 것이다.

가치기업의 위험 보상을 검토할 때는 불황의 롱숏 손익을, 가격오류를 검토할 때는 당시의 전망과 이후 실현된 현금흐름·가격 반응을 비교한다. 가치주 평균수익률만으로 두 설명을 가를 수 없다.

나쁜 상태의 손실을 확인할 때는 가치주 자체의 절대 수익뿐 아니라 가치주 매수·성장주 공매도 전략의 수익을 본다. 불황에 두 그룹이 모두 하락해도 가치주가 덜 하락하면 롱숏 전략은 양수일 수 있다. 위험 보상 주장은 **어떤 투자자의 어떤 나쁜 상태**에서 전략이 보험 역할을 못 하는지를 명시해야 한다. 가격오류 주장에는 당시 투자자 기대를 보여 주는 전망자료도 필요하다.

슬라이드 20 · 가치 효과의 기간과 측정

가치 프리미엄의 크기는 원래 연구 기간, 이후 장기 기간, 대형주만의 결과에 따라 달라질 수 있다. 장부에 계상되지 않은 연구개발·브랜드 자산을 보정하면 현대 기업의 장부가치가 바뀌고 가치 분류도 달라진다.

무형자산 보정의 예로 연구개발 지출을 즉시 비용으로 보지 않고 몇 년간 자본화할 수 있다. 그러면 과거 지출의 누적액이 장부자본에 더해지고 당기 이익에서는 상각액을 차감한다. 내용연수와 상각률을 바꾸면 가치주 분류가 달라질 수 있으므로 보정 전후의 순위와 결과를 같이 보고한다.

단순한 무형자본 장부를 $K_t = (1-\delta)K_{t-1} + RD_t$로 쓸 수 있다. RD_t는 올해 연구개발 지출, δ는 가정한 연간 소멸·상각률이다. 같은 RD_t라도 $\delta = 20\%$와 50%를 쓰면 과거 지출의 잔존 가치가 달라져 조정 장부자본과 가치 정렬이 달라진다. 상각률은 과거 수익률을 가장 높이는 값으로 고르지 않고 기술의 경제적 내용연수에 근거해야 한다.

슬라이드 21 · 투자와 수익성으로 넘어가기

기업의 실물 투자와 이익 창출 능력은 가격을 결정하는 현금흐름과 할인율 양쪽에 연결된다. 투자율이 높은 기업의 기대수익률이 낮고 수익성이 높은 기업의 기대수익률이 높은 패턴은 처음에는 직관에 어긋나 보인다.

수익성이 높은 회사라도 주가가 이미 높으면 투자자의 기대수익률은 낮을 수 있다. 투자율이나 수익성의 효과를 비교할 때 **가격과 미래 지급액 중 무엇을 고정하는지**가 중요하다.

두 기업이 모두 내년 110원을 지급할 것으로 예상되어도 오늘 가격이 100원과 105원이면 기대 단순수익률은 각각 10%와 약 4.76%다. 같은 사업 전망에서도 지불하는 가격이 다르면 투자수익은 달라진다. 투자와 수익성 특성은 미래 지급액과 현재 가격 중 어느 쪽을 주로 반영하는지 분해해야 하며, 그 차이를 위험인지 예상오류인지 따로 검증한다.

슬라이드 22 · 빠른 자산 증가와 낮은 미래수익률

총자산이 빠르게 늘어난 기업은 자본비용이 낮아 투자를 많이 할 수 있다. 또는 시장이 확장을 과도하게 낙관한 결과 미래 주식 수익률이 낮아질 수도 있다. 자산 증가율에는 인수합병, 현금 축적, 회계 변화가 섞일 수 있어 지표의 구성을 확인해야 한다.

자산 증가율은 올해와 작년 총자산의 차이를 작년 자산으로 나눈다. 합병, 설비 건설, 현금 보유 증가는 모두 자산을 늘리지만 할인율과 미래 이익에 연결되는 경로는 다르다.

작년 자산 100억 원이 올해 130억 원이면 증가율은 30%다. 그중 20억 원이 인수합병으로 들어온 영업권이고 10억 원이 현금 증가라면 '설비 투자 30%'라고 해석할 수 없다. 실물 투자 가설을 시험하려면 설비투자, 연구개발, 인수합병과 운전자본 변화를 나누어 보고 각 항목의 공개 시점도 맞춘다.

슬라이드 23 · 투자율과 할인율의 연결

새 설비의 기대수익이 할인율보다 높을 때 기업은 투자한다. 다른 조건이 같다면 자본비용이 낮은 기업은 더 많은 프로젝트를 채택할 수 있어 투자율이 높다. 따라서 높은 투자가 낮은 기대주식수익률을 암시할 수 있다.

투자율은 할인율의 **간접 신호**다. 기업 사이의 성장 기회, 조정비용, 내부 자금 제약도 투자량을 바꾸므로 함께 고려한다.

예를 들어 한계 프로젝트의 예상 수익률이 12%와 8%이고 요구수익률이 10%라면 12% 프로젝트만 채택한다. 요구수익률이 7%로 낮아지면 두 프로젝트를 모두 채택할 수 있어 투자량이 늘어난다. 이 방향은 프로젝트 위험과 자금조달 제약이 같다는 단순 조건에서 나온다. 성장 기회가 다른 기업끼리 투자량만 비교하면 할인율의 차이를 잘못 추론할 수 있다.

슬라이드 24 · 수익성 높은 회사의 높은 수익률

이익/자산이나 자기자본이익률이 높은 기업이 미래에도 높은 수익률을 주는 패턴은 "좋은 기업은 이미 비쌀 텐데 왜 더 오르는가"라는 질문을 만든다. 가격이 비싸도 미래 현금흐름이 시장의 예측보다 더 좋아지면 추가 수익이 가능하다.

또는 높은 기대 수익성이 같은 투자율 아래에서 높은 할인율과 함께 나타날 수 있다. 수익성은 회계상 일회성 이익과 산업별 자본집약도에 영향을 받으므로 지속 가능한 영업 성과로 측정해야 한다.

예를 들어 두 회사 모두 올해 영업이익이 10억 원이고 내년 시장 예상이 11억 원이라고 하자. 실제 발표가 한 회사는 13억 원, 다른 회사는 9억 원이면 현재 수익성은 같아도 예상 대비 실적 변화는 각각 +2억 원과 -2억 원이다. 주가 반응을 해석할 때는 이 **예상과 실현의 차이**를 당시 가격에 반영된 전망, 할인율 변화와 함께 본다.

슬라이드 25 · 수익성 효과의 항등식과 설명

기업가치를 미래 현금흐름의 현재가치로 쓰면, 현재 가격과 예상 투자 규모가 주어졌을 때 기대이익이 클수록 기대수익률도 높아져야 한다. 이는 특정 위험의 존재를 증명하는 이론이 아니라 가격·현금흐름·수익률 사이의 회계적 관계다.

예상 수익성이 높아도 그 이익을 얻기 위한 추가 투자가 크면 주주에게 돌아올 현금흐름은 작다. 회계 이익에서 투자 지출을 고려해 가격과 비교한 뒤, 남는 수익률 차이가 높은 할인율인지 시장의 이익 지속성 과소평가인지 검토한다.

한 기간의 단순 총수익률은 $(P_1 + D_1 - P_0)/P_0$다. 현재 가격 P_0가 같은 두 기업에서 미래 배당 D_1과 가격 P_1의 기대값이 높은 쪽이 기대수익률도 높지만, 높은 회계 이익이 모두 D_1로 지급되는 것은 아니다. 사업 유지를 위한 재투자와 부채 상환을 거친 뒤의 현금흐름이 중요하다. 그래서 '높은 수익성 → 높은 주식수익'은 다른 조건을 고정해야 얻는 비교정태다.

슬라이드 26 · 두 자산가격 요인모형

파마·프렌치 5요인모형은 시장, 규모, 가치에 수익성 RMW와 투자 CMA를 더한다. 다른 q 요인모형도 수익성과 투자를 중심에 둔다. 요인을 추가하면 원래 이상현상의 알파가 줄어들 수 있지만, 이것만으로 요인이 경제적으로 올바른 위험이라는 뜻은 아니다.

RMW는 수익성이 강한 기업을 매수하고 약한 기업을 매도하는 수익률, CMA는 보수적으로 투자하는 기업을 매수하고 공격적으로 투자하는 기업을 매도하는 수익률이다. 요인 수익률은 기업 특성의 숫자 자체가 아니라 그 특성으로 만든 포트폴리오 수익이다. 개별 종목의 요인 베타와 특성 수준을 구별해야 한다.

예를 들어 수익성 요인 RMW의 월 수익률이 2%인 달에 어떤 기업의 주가가 함께 올랐다고 해서 그 회사의 영업이익률이 2%라는 뜻은 아니다. 회사의 **특성**은 재무제표에서 측정하고, RMW에 대한 **베타**는 여러 달의 수익률 공분산에서 추정한다. 요인 회귀의 알파가 0이어도 그 요인이 왜 보상을 받는지에 관한 경제적 설명은 별도로 필요하다.

슬라이드 27 · 무형자산의 회계 문제

기계는 자산으로 올리고 여러 해에 걸쳐 감가상각하는 반면 연구개발·조직 구축 비용은 즉시 비용 처리되는 경우가 많다. 경제적으로는 둘 다 미래에 수익을 줄 수 있는 투자여도 회계 장부에는 다르게 남는다.

회계상 비용 처리와 경제적 자산 형성이 다르면 분모인 장부자본뿐 아니라 분자인 이익도 흔들린다. 연구개발 지출이 많은 기업은 당기 보고 이익이 낮고 미래의 수익 창출 능력은 높을 수 있다. 하지만 실패한 연구개발은 자산 가치가 0일 수 있으므로 지출 전액을 기계적으로 자산화해서도 안 된다.

연구개발비를 경제적 투자로 재분류하면 지출 일부를 여러 기간에 걸쳐 상각하므로 당기 이익과 장부자본이 함께 바뀐다. 이는 **경제적 비교를 위한 대체 측정**이며, 자산으로 남길 금액은 연구의 성공 가능성과 효익 기간에 달려 있다.

슬라이드 28 · 장부 밖 투자와 비율의 왜곡

두 기업이 각각 100을 미래 생산능력에 투입한다고 하자. 설비 구매는 자산에 남고 당기 감가상각 10만 비용일 수 있지만, 연구개발 100은 당기 비용으로 처리될 수 있다. 그러면 경제적 투자 규모가 비슷해도 보고 이익과 장부자본이 크게 다르다.

연구개발 100을 5년에 걸쳐 균등 상각한다고 가정하면 첫해 비용은 20이고 남은 자산은 80이 된다. 즉시 비용 처리와 비교해 첫해 이익과 장부자본이 각각 80 높아진다. 이것은 사실의 발견이 아니라 내용연수 5년이라는 가정을 적용한 재작성이다. 다른 상각기간에서도 결론이 남는지 확인해야 한다.

B/M뿐 아니라 ROE도 보정 전후에 반드시 같은 회계 기준으로 계산해야 한다. 즉시 비용 처리한 이익을 분자로 두고 연구개발을 자산화한 자기자본만 분모에 넣으면 두 기준이 섞인다. 같은 회사의 보고 ROE와 보정 ROE가 달라졌다면 분자 이익의 비용·상각 조정과 분모 자기자본의 변화를 따로 적어 어느 쪽이 결과를 움직였는지 확인한다.

슬라이드 29 · 무형자산 프리미엄의 두 설명

핵심 인력과 기술 지식은 경기 충격 때 가치가 불안정할 수 있어 위험 보상을 요구할 수 있다. 다른 한편 투자자가 장부에 드러나지 않는 역량을 늦게 인식하면 가격오류가 생길 수 있다. 연구개발의 수익은 성공과 실패가 크게 갈려 평균만으로 판단하기 어렵다.

고용 이동, 특허, 광고, 영업레버리지는 서로 다른 무형자본의 대용변수다. 여러 지표를 묶기 전에 각각이 어떤 자산과 위험을 측정하는지 정의한다.

같은 특허 100개라도 핵심 기술 하나가 매출 대부분을 지탱하는 기업과 사업화되지 않은 작은 특허를 많이 가진 기업의 현금흐름은 다르다. 특허의 인용·유효기간·제품 매출과 연결하면 측정이 나아질 수 있지만 새 선택과 측정오차도 들어온다. 위험 설명은 위기 때 무형자본 현금흐름이 특히 나빠지는지, 오류 설명은 성공 소식이 발표될 때 가격이 뒤늦게 반응하는지 묻는다.

슬라이드 30 · 낮은 범주 재현율을 해석하기

무형자산 범주의 신호에는 연구개발뿐 아니라 분석가 전망, 이익의 질, 계절성 등도 섞일 수 있다. 연구개발/매출은 활동의 강도를, 연구개발/시가총액은 시장가격 대비 지출을 뜻한다. 범주의 평균 재현율을 개별 경제 기제의 성패로 옮기기 전에 신호의 정의를 분리한다.

범주에 20개 신호가 있고 4개만 기준을 넘었다면 재현율은 20%다. 하지만 20개 중 15개가 사실상 같은 지표의 작은 변형이라면 '독립된 경제 가설 20개 중 4개'라는 해석은 부정확하다. 분모의 신호 목록, 서로의 상관, 포함된 경제 기제를 확인해야 한다. 개별 신호의 실무 가치와 범주 통계는 다른 질문이다.

슬라이드 31 · 거래마찰은 가격과 비용을 함께 바꾼다

소형·비유동 종목의 높은 관측수익에는 위험 보상과 거래하기 어려운 가격이 함께 섞일 수 있다. 실제 비용은 고정 수수료, 호가 스프레드, 주문의 가격 충격, 공매도 차입료를 포함한다. 양쪽 다리를 자주 갈아타는 전략일수록 명목 수익과 실제 체결 가능한 수익이 벌어진다.

운용자산 100원당 한 달에 총 200원어치의 매매를 한다면 거래 명목금액/자산 비율은 2다. 거래된 금액 1원당 비용이 0.4%면 자산 대비 월 비용은 $2(0.4\%) = 0.8\%$다. 명목 롱숏 수익 1%에서 이를 빼면 0.2%가 남고, 차입료와 가격충격이 추가되면 더 낮아진다. 회전율의 정의와 매수·매도 양쪽 포함 여부를 먼저 확인해야 숫자가 맞는다.

슬라이드 32 · 소형주와 비유동성

소형주는 분석가의 관심이 적고 정보가 가격에 늦게 반영될 수 있다. 동시에 경기 악화 때 자금 조달이 더 어렵고 거래를 청산하기도 힘들어 투자자가 보상을 요구할 수 있다. 두 설명은 함께 성립할 수 있다.

마지막 거래가격으로 계산한 수익률은 투자자가 같은 가격에 원하는 수량을 매매할 수 있다는 보장이 없다. 소형주 100개에 동일 금액을 투자하려면 각 기업의 일일 거래대금 대비 주문 비율을 확인해야 한다. 전략 규모가 커질수록 관측 가격과 체결 가격의 차이가 커지는 용량 문제가 생긴다.

가상의 종목에서 마지막 체결가가 1,000원이어도 현재 매수 호가가 990원, 매도 호가가 1,010원이라면 즉시 사서 다시 팔 때 $990/1010 - 1 \approx -1.98\%$다. 마지막 가격 1,000원으로 양쪽 거래를 모두 기록하면 이 비용이 보이지 않는다. 주문을 크게 내면 호가의 물량을 소진해 더 불리한 가격까지 체결될 수 있으므로 매수·매도 호가차와 주문 규모별 시장충격을 구분해야 한다.

슬라이드 33 · 고유변동성과 단기 반전

시장요인으로 설명되지 않는 개별 종목의 변동성을 고유변동성이라 한다. 전통적 분산투자 이론에서는 잘 분산할 수 있는 위험에 높은 보상이 필요하지 않지만, 실제 자료에서는 고유변동성이 높은 종목의 낮은 평균수익이 관찰되기도 한다.

직전 한 달 급등·급락 뒤 반전은 투자자 과잉반응 또는 유동성 공급의 대가일 수 있다. 호가 반등처럼 미시구조에서 나온 가짜 패턴도 가능하다. 비용과 대형주 표본에서 남는지를 확인해야 한다.

단일 시장요인 회귀 $r_{i,t} - r_{f,t} = a_i + \beta_i(r_{M,t} - r_{f,t}) + e_{i,t}$에서 $e_{i,t}$의 표준편차가 고유변동성의 한 추정치다. 시장 베타가 같아도 잔차가 크게 흔들리는 두 종목의 고유변동성은 다를 수 있다. 잔차에 산업 공통 충격이 남아 있다면 '완전히 분산 가능한 기업 고유 위험'과 같지 않을 수 있으므로 기준 요인모형도 명시해야 한다.

슬라이드 34 · 거래마찰 범주의 재현

소형·비유동주를 큰 비중으로 담는 전략은 원래 표본에서는 강한 차이를 보일 수 있지만 시가총액가중이나 대형주 기준으로 바꾸면 약해진다. 이는 통계적 존재와 실제 운용 가능성이 다른 질문임을 보여 준다.

동일가중은 종목마다 같은 원화를 놓지만 시가총액가중은 시장 전체에서 큰 기업에 더 많은 원화를 놓는다. 둘의 성과 차이가 크다면 신호가 작은 기업에서 강하다는 단서다. 이것은 효과가 '가짜'라는 증명은 아니지만 규모가 큰 실제 자금을 투입했을 때 얻을 수 있는 수익을 다시 계산하라는 경고다.

예를 들어 시가총액 100억 원 기업과 1억 원 기업 두 곳에서 작은 기업만 20% 오르고 큰 기업은 그대로라면, 동일가중 수익은 $0.5(20\%) + 0.5(0\%) = 10\%$다. 시가총액가중 수익은 $(1/101)(20\%) \approx 0.20\%$에 불과하다. 어느 숫자가 맞는지는 질문에 달려 있다. 작은 자금으로 동일 금액을 넣는 실험인지, 큰 자금을 시장 규모대로 배분하는 전략인지를 먼저 정해야 한다.

슬라이드 35 · 여섯 범주를 한꺼번에 비교하기

모멘텀은 평균 성과와 폭락 위험, 가치는 할인율과 예상오류의 구분, 투자는 기업의 최적 선택, 수익성은 현금흐름과 가격의 관계, 무형자산은 측정, 거래마찰은 구현 비용이 핵심이다. 서로 다른 범주에 한 가지 설명을 억지로 적용하면 중요한 차이가 사라진다.

형성 시점, 보유 기간, 가중치, 공매도 가능성, 기준요인, 거래비용을 맞춘 공통 평가표를 만든다. 평균수익 한 숫자는 모멘텀의 폭락 위험과 비유동주 전략의 매매비용을 보여 주지 못한다.

평균수익 1%인 두 전략도 매월 비용이 각각 0.1%와 0.9%면 비용 뒤 평균은 0.9%와 0.1%로 크게 벌어진다. 첫 전략이 위기에 -20%의 손실을 내고 둘째가 안정적이라면 위험 조정 순위는 다시 바뀔 수 있다. 범주를 비교하는 표에는 적어도 총수익, 비용 후 수익, 꼬리손실, 대형주 표본의 성과를 나란히 두어야 한다.

슬라이드 36 · 위험인가 가격오류인가

같은 예측변수가 미래 수익률과 상관되어도 경제적 해석은 갈린다. 위험 프리미엄이라면 나쁜 상태에서 손실을 주는 보상이고, 가격오류라면 투자자의 기대가 체계적으로 잘못되었다가 수정되는 이익이다.

위험 보상은 위기 손실을 감수하는 대가로 남을 수 있다. 가격오류는 경쟁과 자금 유입으로 줄어들 수 있고, 차익거래 제약이 조정 속도를 정한다. 한 전략에는 두 성분이 함께 들어갈 수도 있다.

예를 들어 두 전략의 연평균 수익이 모두 8%인데 A는 불황에 -30%를 기록하고 B는 불황에 +5%를 기록한다면, 평균만 같은 두 전략의 보험 가치는 다르다. A의 높은 평시 수익은 나쁜 상태의 손실 보상일 수 있다. B의 수익도 곧바로 가격오류라고 단정할 수는 없다. 위험을 어떤 상태로 측정했는지와 거래 제약이 무엇인지 함께 조사해야 한다.

슬라이드 37 · 두 설명의 서로 다른 예측

위험 설명은 전략의 수익이 소비가 낮거나 유동성이 부족한 상태에서 나빠진다고 예측한다. 가격오류 설명은 잘못된 기대가 드러나는 실적발표 같은 시점에 수익이 집중되고, 공개·발표 후에는 효과가 감소할 수 있다고 예측한다.

느린 실적 반응 가설은 발표 직전 분석가 예상과 실제 실적의 차이를 잰 뒤, 발표일과 이후 몇 달의 가격 반응을 추적한다. 위험 가설은 그 수익이 소비나 유동성이 나쁜 상태에 집중되는지, 기존 요인 노출로 설명되는지 살핀다. 발표일 하루만 보면 뒤따르는 기대 수정과 상태별 위험을 놓칠 수 있다.

슬라이드 38 · 지금까지의 가격 항등식

낮은 가격은 미래 현금흐름에 대한 낮은 예상과 높은 할인율 양쪽에서 나올 수 있다. 모멘텀은 정보 반응의 시간, 무형자산은 현금흐름 측정, 투자는 기업의 자본비용 선택을 강조한다. 종목 특성의 예측력이 가격식의 **어느 경로**에서 오는지 묻는 이유다.

가장 단순한 한 기간 예를 보자. 1년 뒤 **확정** 현금흐름이 110이고 할인율이 10%이면 현재 가격은 $110/1.10 = 100$이다. 현금흐름이 105이고 할인율이 5%여도 가격은 $105/1.05 = 100$이다. 가격 100만 관측해서는 현금흐름 기대와 할인율을 따로 복원할 수 없다. 위험한 현금흐름에서는 할인인자와 현금흐름의 공분산까지 가격에 들어가므로 식별은 더 어려워진다. 이 때문에 가치 비율 하나를 위험 프리미엄이나 과대평가의 증거로 곧장 읽을 수 없다.

슬라이드 39 · 네 가지 구별 질문

발표 뒤 수익이 줄어드는가, 이익이 매수 다리와 공매도 다리 중 어디에 있는가, 큰 유동주에도 남는가, 기업 특성보다 위험요인과의 공분산이 중요한가를 묻는다. 각각은 가격오류와 위험 보상에 대해 다른 힌트를 준다.

공매도 다리의 성과가 크면 과대평가가 오래 지속된다는 해석과 높은 차입비용을 함께 검토한다. 큰 유동주에서도 남는 신호라면 극소형주의 가격 문제에만 기대는 설명은 약해진다.

롱숏 1%의 월수익이 매수 다리 0.2%, 공매도 대상 종목의 수익률 -0.8%에서 왔다면 대부분은 공매도 다리다. 그런데 그 종목을 빌리는 비용이 월 1%라면 명목 이익보다 비용이 크다. 다리별 분해는 가격오류의 위치를 보여 주고, 차입 가능성과 비용은 그 위치에서 실제 차익거래가 가능한지를 알려 준다.

슬라이드 40 · 판정표의 증거를 읽는 법

발견 이후 평균 롱숏 수익률이 감소했다는 연구, 투자자 심리가 높은 때 공매도 다리의 성과가 크다는 연구, 대형주에서도 모멘텀이 남는다는 연구는 서로 다른 증거를 제공한다. 기간과 전략 구성이 달라 숫자를 한 표에 놓고 직접 대소 비교하면 안 된다.

판정표의 결과를 비교할 때 '평균수익 감소'와 '알파 감소'를 구별한다. 시장과 기존 요인의 평균 수익이 바뀌면 원수익은 변해도 상대 알파는 남을 수 있다. 원 연구와 재검증 연구가 같은 포트폴리오와 기간을 썼는지 확인하고, 연구별 정의가 다르면 효과 크기보다 결과의 방향과 메커니즘을 비교한다.

예를 들어 전략의 총초과수익이 8%에서 5%로 줄었어도 같은 기간 기준요인의 설명 부분이 6%에서 3%로 줄었다면 단순 차이 알파는 두 기간 모두 2%다. 반대로 총수익이 그대로여도 기준 위험노출의 보상이 커졌다면 알파는 줄 수 있다. 서로 다른 연구의 수치를 비교하려면 원수익과 기준모형 조정 후 수익을 분리해야 한다.

슬라이드 41 · 예측자와 설명자의 목표

예측모형은 장부가치/시가총액이 다음 수익률을 맞힌다면 위험 때문인지 가격오류 때문인지 몰라도 사용할 수 있다. 그러나 투자자 행동이 바뀐 뒤에도 신호가 남을지 예측하려면 원인을 이해해야 한다.

시장 참여자가 신호를 따라 거래하기 시작하면 가격과 예상 수익이 변할 수 있다. 예측력을 발견한 뒤 그 원인을 연구해야 이런 환경 변화에서의 성과를 판단할 수 있다.

예를 들어 낮은 투자율의 기업을 사는 규칙이 작동했다면 예측자는 다음 달 수익률 순위가 개선되는지만 먼저 검증할 수 있다. 설명자는 높은 자본비용이 투자를 억제해 높은 기대수익을 만든 것인지, 투자자가 성장을 과대평가해 고투자 기업을 비싸게 산 것인지 구별해야 한다. 두 설명은 현재 같은 수익률 패턴과 양립해도 위험 회피 변화나 전략 공개 뒤의 가격 반응에 대해 다른 예측을 만든다.

슬라이드 42 · 투자 CAPM의 최적화 유도

투자 CAPM(investment CAPM)에서 기업이 현재 자산 A에 추가 투자 I를 하고, 투자 한 단위의 조정비용이 투자율 I/A에 따라 올라간다고 하자. 현재 총비용을 $I + (a/2)(I/A)^2 A$로 쓰면 I에 대한 한계비용은 $1 + aI/A$다. 한계 투자에서 얻는 미래 이익 Π_1의 현재가치를 $E[M_1 \Pi_1]$라 하면 최적화 조건은 다음과 같다.

$$1 + a\frac{I}{A} = E[M_1 \Pi_1].$$

위험과 할인인자를 단순화하여 한 기간 요구 총수익률 $1 + E[r]$로 현재가치를 표현하면 $E[M_1 \Pi_1] \approx E[\Pi_1]/(1 + E[r])$다. 따라서 $1 + E[r] \approx E[\Pi_1]/(1 + aI/A)$다. 예상 수익성이 같다면 높은 투자는 낮은 요구수익률과, 투자율이 같다면 높은 예상 수익성은 높은 요구수익률과 연결된다. 이 최적화는 부호를 설명하지만 **왜 할인율이 기업마다 다른지**는 별도의 위험·시장 이론이 필요하다.

수치를 넣어 $a = 1$, 투자율 $I/A = 0.1$, 미래 한계이익의 기대값 $E[\Pi_1] = 1.32$라 하자. 한계비용은 $1 + 0.1 = 1.1$이고 단순화한 요구 총수익률은 $1.32/1.1 = 1.20$, 즉 기대수익률 20%다. 같은 미래 한계이익에서 투자율이 0.2이면 분모가 1.2가 되어 식상 기대수익률은 10%다. 이것은 다른 조건을 고정한 **비교정태**다. 실제 기업 사이에는 투자 기회와 위험도 달라지므로 관측된 투자율 차이를 곧바로 10%포인트의 요구수익 차이로 읽지 않는다.

슬라이드 43 · 특성과 공분산을 떼어 놓기

가치주가 높은 수익을 얻는 이유가 가치요인 HML에 대한 노출이라면, 장부가치/시가총액을 고정하고 HML 노출만 높은 종목은 더 높은 수익을 주어야 한다. 반대로 특성 자체가 중요하다면 노출 차이를 만들어도 수익 차이가 작을 수 있다.

위험요인 베타는 과거 수익률과 요인 수익률의 공분산에서 추정하므로 잡음이 있다. 비슷한 가치 특성을 가진 종목 안에서 베타만 비교해도 베타 측정오차가 크면 진짜 위험 관계를 놓칠 수 있다. 특성과 베타를 분리하는 연구의 상반된 결과는 표본 기간·요인 정의·추정오차를 함께 읽어야 이해된다.

베타를 $\beta_{i,HML} = \mathrm{Cov}(r_i, HML)/\mathrm{Var}(HML)$로 정의하면 B/M은 회계·가격에서 계산한 **수준**, 베타는 요인 수익과의 **공동 움직임**이다. 같은 B/M인 두 기업도 하나는 경기 악화 때 가치요인과 함께 떨어지고 다른 하나는 그렇지 않을 수 있다. 다만 베타를 과거 짧은 기간에서 추정하면 측정오차가 커져 조건부 정렬의 검정력이 낮아진다.

슬라이드 44 · 우연이라는 세 번째 설명

높은 수익률과 그럴듯한 이야기가 함께 있어도 많은 후보 가운데 운 좋게 발견된 결과일 수 있다. 논문에 실린 전략만 보면 실패한 시도는 보이지 않는다. 이 **선택된 표본의 문제**가 요인 동물원의 핵심이다.

가령 연구자가 장부비율의 분모, 극단값 절단, 보유기간, 국가를 여러 번 바꿔 가장 큰 수익만 보고한다면, 표에 보이는 전략은 수많은 실패 후보 중 선택된 것이다. 원래의 t값은 이 탐색을 보정하지 않는다. 사전 등록된 규칙이나 완전히 새로운 기간의 검증이 우연 설명을 줄이는 핵심이다.

독립적인 참귀무가설 100개를 각각 5% 수준에서 검사하면 적어도 하나의 p값이 0.05 이하일 확률은 $1-0.95^{100}\approx 99.4\%$다. 따라서 연구자가 그 한 결과만 보여 줄 때 독자는 '드문 5% 사건'을 본 것이 아니다. **100번 중 가장 유리한 것을 고른 절차**의 결과를 본 것이다. 이 계산은 독립일 때의 직관용 예시이며, 현실의 상관된 후보에서는 선택 과정 전체를 별도로 기록해야 한다.

슬라이드 45 · t값 2의 의미가 바뀌는 순간

한 개의 사전 지정된 가설을 정규근사로 검정하면 $|t|>1.96$은 양측 5% 수준이다. 연구자가 효과가 0인 전략도 수백 개 시도한 뒤 가장 높은 값만 발표하면, 독자는 그 선택 과정을 보지 못한다.

참귀무가설 300개에서 각 검정의 거짓 양성 확률이 5%이면 거짓 발견 개수의 기대값은 $300\times 0.05=15$다. 검정끼리 독립일 필요는 없다. 독립이라고 **추가로** 가정할 때만 발견 개수 V가 이항분포 $\mathrm{Binom}(300,0.05)$를 따라 표준편차가 $\sqrt{300(0.05)(0.95)}\approx 3.77$이라고 계산할 수 있다. 논문에 가장 큰 통계량만 싣는다면 독자가 보는 값은 300개 전체의 무작위 표본이 아니다.

기댓값 15와 '한 개라도 잘못 나올 확률'도 다르다. 300개 검정이 서로 독립이고 개별 오류확률이 5%라면 후자는 $1-0.95^{300}$으로 거의 1이다. 반대로 완전히 같은 검정을 300번 복제했다면 기댓값은 여전히 15이지만 한 번이라도 잘못 기각할 확률은 5%다. 요인들이 서로 비슷할수록 기대 개수만 보고 실제 연구의 발견 패턴을 추정할 수 없다.

슬라이드 46 · 잡음 전략 300개의 모의실험

참 기대수익률이 모두 0인 300개 전략을 독립적으로 만들고 각 전략의 평균에 대한 t값을 계산하면 히스토그램의 일부 막대가 우연히 2를 넘는다. 이때 발견된 '이상현상'은 모의실험 설계상 모두 거짓이다.

현실의 전략들은 같은 종목과 기간을 공유해 상관될 수 있다. 거짓 양성 지시변수를 I_j라 두면 발견 개수 $V=\sum_j I_j$의 분산은 $\sum_j \mathrm{Var}(I_j)+2\sum_{j<k}\mathrm{Cov}(I_j,I_k)$다. 양의 의존은 잘못된 발견이 한꺼번에 몰릴 가능성을 키운다. 시계열 자기상관 때문에 개별 p값부터 잘못 계산했다면 앞 슬라이드의 5% 오류확률 가정도 성립하지 않는다.

히스토그램에서 $t=2$를 넘는 꼬리는 정규분포의 자연스러운 일부다. 그 안의 한 전략에 경제적 이야기를 붙여도, 모의실험에서는 참효과가 0임을 이미 알고 있다. 반대로 현실에서는 참효과도 섞여 있으므로 모의실험의 교훈은 '모든 발견이 거짓'이 아니라 '이야기와 통계량만으로 진위를 판정할 수 없다'는 것이다.

슬라이드 47 · 진짜 전략 10개를 섞었을 때

잡음 290개 사이에 참 신호가 있는 전략 10개를 넣으면 낮은 임계값은 진짜도 많이 잡지만 거짓도 많이 포함한다. 높은 임계값은 거짓을 줄이는 대신 약한 참 신호를 놓친다. 이것이 검정력과 거짓 발견의 상충관계다.

정책 목적에 따라 기준이 달라진다. 수백 후보에서 연구할 만한 주제를 고르는 단계라면 거짓 발견 비율을 통제할 수 있고, 고객 자금을 큰 규모로 투입한다면 더 엄격한 독립 확인이 필요하다.

숫자로 보면, 290개 참귀무가설이 각각 5% 확률로 잘못 통과하고 진짜 전략 10개를 잡아낼 검정력이 각각 80%라면 기대 거짓 발견은 $290(0.05) = 14.5$개, 기대 참 발견은 $10(0.8) = 8$개다. 관측된 발견 목록에 거짓이 적지 않을 수 있다는 직관을 준다. 다만 $14.5/(14.5+8)$은 **기대 개수의 비율**일 뿐, 발견 총수 $R = 0$일 때 비율을 0으로 두는 FDR $= E[V/\max(R,1)]$과 일반적으로 같지 않다. 임계값을 바꾸면 개별 검정의 거짓 양성 확률과 검정력이 모두 달라져 두 개수를 다시 계산해야 한다.

슬라이드 48 · 왜 새 요인에는 더 높은 기준이 필요한가

발표된 요인이 수백 개라면 각 논문의 5% 유의성 기준을 그대로 유지하기 어렵다. Harvey·Liu·Zhu는 다중검정을 고려해 새 요인의 발견 기준을 대략 $t > 3$으로 높일 것을 제안했다.

숫자 3은 모든 연구에 똑같이 적용되는 자연상수가 아니다. 실제로 몇 번 시도했는지, 전략들 사이의 상관, 사전 가설의 강도에 따라 적절한 기준이 달라진다. 연구 원문[24]의 수치는 요인 목록이 커질 때 기존 판정 규칙을 재고해야 함을 보여 준다.

정규근사에서 한 **사전 지정된 양측 검정**의 $|t| > 3$ 거짓 양성 확률은 약 0.27%다. 300개 참귀무가설을 각각 이 기준으로 시험하면 실제 오류확률이 그 값일 때 기대 거짓 발견은 약 $300(0.0027) = 0.81$개다. 이는 보정 없는 $|t| > 2$의 약 15개보다 작지만, 가족별 오류확률이 5% 이하라는 보증은 아니다. 어떤 오류 기준을 원하는지에 따라 문턱이 달라진다.

슬라이드 49 · 다중검정 규칙의 단계별 계산

M개 검정에서 하나라도 거짓 양성이 생길 확률을 5% 이하로 두고 싶다면 합집합의 확률은 개별 확률의 합 이하라는 부등식을 쓴다. 각 검정을 α/M에서 실시하면 전체 거짓 양성 확률은 최대 $M(\alpha/M) = \alpha$다. 이것이 본페로니 기준이다.

$$P\left(\bigcup_{j=1}^{M} A_j\right) \le \sum_{j=1}^{M} P(A_j), \qquad p_j \le \frac{\alpha}{M}.$$

Holm은 p값을 작은 순서로 정렬해 $p_{(k)} \le \alpha/(M-k+1)$를 차례로 확인한다. Benjamini–Hochberg는 가족 전체에서 단 한 개의 오류도 허용하지 않는 대신, 발견된 것 가운데 거짓의 기대 비율을 통제한다. 독립 또는 특정 의존 조건 아래 최대 k에 대해 $p_{(k)} \le k\alpha/M$을 적용한다. 어떤 오류를 통제하려는지 먼저 정해야 방법을 고를 수 있다.

도식의 15개는 300개의 참귀무가설을 **보정 없이** 검정하고 각각의 실제 거짓 양성 확률이 정확히 5%일 때의 기대 발견 수다. 본페로니·Holm·BH는 이 출발점에 서로 다른 오류 통제 기준을 적용한다. 따라서 발견 수를 비교할 때는 어떤 방법을 썼는지 함께 적어야 한다.

[24] https://doi.org/10.1093/rfs/hhv059

질문: FDR 5%면 발견 20개 중 정확히 1개가 거짓인가요? 아닙니다. 반복 연구에서 거짓 발견 비율의 기대를 통제한다는 뜻입니다. 한 번의 표본에 거짓 발견이 0개일 수도 여러 개일 수도 있습니다.

슬라이드 50 · 재현 논쟁의 질문

한 연구는 대부분의 이상현상이 공통한 엄격한 조건에서 실패한다고 보고하고, 다른 연구는 상당수가 다양한 나라와 기간에서 남는다고 보고한다. 모순처럼 보이지만 "무엇을 같은 전략으로 볼지"와 "재현을 무엇으로 정의할지"가 다르다.

재현율의 분모부터 다를 수 있다. 처음 발표된 모든 이상현상을 세는 연구와 사전에 경제적 주제로 걸러낸 요인만 세는 연구는 같은 비율을 비교하지 않는다. 분자 역시 원수익, CAPM 알파, 새 국가의 같은 부호 등으로 정의된다. 각 연구의 분자·분모를 명시하면 숫자가 왜 갈리는지 보인다.

가상의 연구에서 발표된 전략 80개 가운데 엄격한 기준을 통과한 것이 16개면 재현율은 $16/80 = 20\%$다. 사전에 대형주에서도 거래 가능하다고 판단한 20개만 먼저 골라 그중 같은 16개가 통과했다면 $16/20 = 80\%$다. **처음부터 어떤 전략을 평가 대상으로 삼았는지**가 재현율을 바꾼다. 결과를 본 뒤 유리한 20개를 고르면 선택 편향이 생긴다.

슬라이드 51 · 많은 이상현상이 실패한다는 결과

Hou·Xue·Zhang은 여러 전략을 동일한 규칙으로 재구성하고 NYSE 종목의 크기를 기준으로 그룹을 나누며 시가총액 가중 수익률을 쓴다. 이 방식에서는 작은 기업이 종목 수에 비해 시장가치에서 차지하는 비중이 작으므로 그 효과가 전체 전략을 지배하기 어렵다.

NYSE 종목으로 정렬 경계를 만든 뒤 전체 종목에 적용하면 극소형주가 경계 자체를 정하는 문제를 줄일 수 있다. 시가총액가중은 큰 자금의 운용 가능성에 가까운 질문이고, 동일가중은 작은 종목의 가격 형성을 더 크게 반영한다.

작은 예를 계산해 보자. NYSE 종목의 시가총액이 $200, 80, 30, 10, 4$, 다른 거래소 종목이 $3, 1, 0.5, 0.2, 0.1$이면, 전체 종목 기준 하위 5분위에는 $0.1, 0.2$ 두 종목만 들어간다. NYSE 종목만으로 경계를 정해 전체에 적용하면 하위 그룹에는 $4, 3, 1, 0.5, 0.2, 0.1$ 여섯 종목이 들어가며 이들의 시가총액 합은 8.8이다.

맨 작은 두 종목에만 월 3%의 추가수익이 있다면 전체 기준 하위 그룹의 추가수익은 3%다. NYSE 경계의 하위 그룹에서는 동일가중일 때 $(2/6)3\% = 1\%$, 시가총액가중일 때 $(0.3/8.8)3\% \approx 0.10\%$다. **경계는 어느 종목이 들어가는지**, **가중치는 그 종목이 결과에 얼마나 기여하는지**를 정한다.

슬라이드 52 · 많은 요인이 재현된다는 결과

Jensen·Kelly·Pedersen은 요인을 더 적은 주제로 묶고 여러 나라의 자료까지 살펴 높은 재현율을 보고한다. 한 주제의 여러 변형은 완전히 독립된 20개 발견이 아니라 같은 잠재 효과에 대한 여러 측정일 수 있다.

한 주제의 지표 20개가 같은 장부비율의 분모만 조금씩 바꾼 것이라면 20번의 독립된 재현으로 세기 어렵다. 계층모형으로 정보를 공유하더라도 같은 데이터 처리 오류가 여러 변형에 퍼질 수 있다. 서로 다른 회계제도와 공개 시점에서 같은 방향이 남는지 확인하고, 요인 **개수**와 경제적 주제 **개수**를 나란히 기록한다. 연구 원문[25]은 이런 비교를 다룬다.

[25] https://doi.org/10.1111/jofi.13249

슬라이드 53 · 왜 판정이 갈리는가

원수익률 차이를 볼지 CAPM 알파를 볼지, 십분위와 삼분위 중 무엇을 쓸지, 소형주를 어떻게 제한할지, 전체 목록인지 이미 선별한 목록인지가 다르다. 또한 단일 요인마다 고정 임계값을 적용할지 주제별 증거를 함께 사용할지가 다르다.

기관투자자의 '대형 유동주에서 비용 뒤에도 남는가'와 자산가격 연구자의 '작은 종목까지 포함한 평균수익 패턴이 있는가'는 같은 데이터에서도 다른 판정을 낳는다.

비교표를 직접 만든다면 행에는 원수익·CAPM 알파·비용 후 수익을, 열에는 동일가중·시가총액 가중·대형주 표본을 놓을 수 있다. 한 신호가 동일가중 원수익에서만 유의하다면 가격 패턴이 존재할 가능성과 큰 자금의 거래 가능성에 대한 판단을 분리한다. 서로 다른 재현율을 평균내기 전에 **같은 칸**의 결과인지 확인하는 방법이다.

슬라이드 54 · 한 요인의 베이지안 축소를 유도하기

진짜 알파가 $\alpha \sim N(0, \tau^2)$이고 관측 추정치가 $\hat{\alpha} \mid \alpha \sim N(\alpha, \sigma^2/T)$라고 하자. 정규분포의 사전밀도와 우도를 곱해 α의 제곱항을 완전제곱하면 사후 평균은 정밀도 가중평균이 된다.

$$\begin{aligned} E[\alpha \mid \hat{\alpha}] &= \frac{T/\sigma^2}{1/\tau^2 + T/\sigma^2}\hat{\alpha} \\ &= \frac{\tau^2}{\tau^2 + \sigma^2/T}\hat{\alpha}. \end{aligned}$$

사후 평균의 가중치 $w = \tau^2/(\tau^2 + \sigma^2/T)$는 0과 1 사이에 있다. 예컨대 사전분산이 1이고 추정 오차 분산이 3이면 $w = 1/4$이므로 관측 알파 4%는 사후 평균 1%로 줄어든다. 잡음이 큰 단일 요인의 눈에 띄는 성적을 그대로 미래 기대수익으로 쓰지 않는 수학적 이유다.

같은 완전제곱 계산에서 사후분산은 $(1/\tau^2 + T/\sigma^2)^{-1}$이다. 자료가 늘면 정밀도 T/σ^2가 커져 사후 평균의 축소가 줄고 불확실성도 작아진다. 반대로 서로 강하게 상관된 요인 관측을 독립된 T개처럼 세면 정밀도를 과장한다. 식의 T는 단순 행 수가 아니라 독립성 가정 아래의 정보량이라는 점을 함께 읽어야 한다.

슬라이드 55 · 주제별 정보를 함께 쓰기

요인 i의 참 알파를 해당 주제의 공통효과 $c_{j(i)}$와 요인 고유의 편차 w_i의 합으로 둔다. $c_j \sim N(0, \tau_c^2)$, $w_i \sim N(0, \tau_w^2)$라는 가정은 주제 안의 요인들이 정보를 공유하도록 한다.

계층모형에서는 같은 주제의 다른 요인들이 공통효과 c_j를 추정하는 데 도움을 준다. 가치 관련 요인 여러 개가 비슷한 방향이면 한 요인의 추정치가 흔들려도 주제의 평균 신호는 남을 수 있다. 반대로 연구자가 결과가 좋은 요인만 보고 주제를 만들었다면 '정보 빌리기'가 선택 편향을 퍼뜨릴 수 있다.

$\alpha_i = c_j + w_i$이고 c_j, w_i가 독립이라면 같은 주제의 서로 다른 두 요인 i, k 사이 사전 공분산은 $\mathrm{Cov}(\alpha_i, \alpha_k) = \tau_c^2$다. 각 요인의 분산은 $\tau_c^2 + \tau_w^2$이므로 사전 상관은 $\tau_c^2/(\tau_c^2 + \tau_w^2)$다. 공통분산이 클수록 한 요인의 정보가 같은 주제의 다른 요인에 더 많이 전달된다. 주제 분류가 틀리면 이 전달 자체가 잘못된 축소가 된다.

슬라이드 56 · 사후 판정과 82%의 해석

사후 평균을 0으로 축소하면 유의한 요인 수가 줄어들 수 있지만, 관련 요인의 정보를 함께 쓰면 사후 불확실성도 낮아진다. 두 효과가 상쇄되면 단순 알파 검정과 계층모형의 재현율이 비슷할 수 있다.

82% 같은 수치를 읽을 때는 '무엇의 82%인가'를 먼저 묻는다. 선택된 요인 목록의 CAPM 알파가 사후 기준을 넘은 비율인지, 원 논문의 모든 후보 중 비용 뒤 수익이 남은 비율인지는 완전히 다르다. 사후축소의 통계적 판정과 실제 투자 가능한 수익의 존재를 한 문장으로 합치지 않는다.

가령 100개 후보 중 50개를 사전에 연구 목록으로 고르고, 그중 41개가 사후 판정 기준을 넘으면 보고된 재현율은 $41/50 = 82\%$다. 처음의 100개를 분모로 쓰면 41%다. 두 계산 모두 산술은 맞지만 다른 질문이다. 후보를 결과를 본 뒤 고른 경우에는 '사전 목록'이라는 조건도 성립하지 않으므로, 선택 시점까지 확인해야 한다.

슬라이드 57 · 발표 뒤 수익의 감소

전략의 원 논문 표본, 표본 종료와 발표 사이, 발표 이후를 분리하면 감소가 시작한 시점을 볼 수 있다. 공개 전의 하락은 초기 추정의 선택 편향이나 시장 변화와 연결되고, 공개 뒤의 추가 하락은 모방 거래와도 부합한다. 세 구간의 평균에 더해 유동성, 포지션 규모, 위험 노출을 함께 비교한다.

발표 뒤 총수익이 월 0.4%에서 0.2%로 줄고 같은 기간 왕복비용이 0.1%에서 0.25%로 늘었다면 비용 뒤 성과는 0.3%에서 -0.05%로 더 크게 악화된다. 총수익 감소는 정보의 가격 반영이나 원래 표본의 운과 관련될 수 있고, 비용 증가는 경쟁 자금의 주문충격일 수 있다. 두 경로를 따로 측정해야 어떤 메커니즘이 투자자의 순성과를 줄였는지 이해한다.

슬라이드 58 · 새 요인의 올바른 검정

새 요인을 파마·프렌치 3요인만 통제한 뒤 유의하다고 선언하면 이전에 발견된 많은 요인과 겹치는 정보를 '새로운' 것으로 착각할 수 있다. 전체 기존 요인을 모두 통제하면 변수 수가 너무 많고 상관이 높아 OLS가 불안정해진다.

통제가 적으면 기존 요인의 효과를 새 요인에 잘못 돌릴 수 있고, 모두 넣으면 높은 상관과 작은 표본 때문에 계수가 불안정해진다. 이중 선택은 수익률 및 새 요인과 연결된 통제를 각각 찾아 둘 다 남기는 절차다.

새 요인 D와 기존 요인 Z가 거의 같은 포트폴리오라면 D의 단독 t값이 커도 Z를 넣은 뒤에는 고유한 움직임이 거의 남지 않는다. 이는 새 요인의 아이디어가 틀렸다는 뜻보다 기존 요인과 중복된다는 뜻일 수 있다. 반대로 Z를 무작정 모두 넣으면 남은 변동이 너무 작아 표준오차가 커진다. 경제적 신규성과 통계적 식별 가능성을 나눠 보아야 한다.

슬라이드 59 · 선택된 통제만 넣을 때의 편향

기존 요인 Z가 평균수익률 y에는 약하게 연결되더라도 새 요인 D와 강하게 상관될 수 있다. Z를 빠뜨리고 y를 D에만 회귀하면 D가 Z의 효과를 대신 가져간다. 이는 미시계량의 **누락변수 편향**과 같은 구조다.

결과 y만 예측하는 라쏘는 이런 Z를 빠뜨릴 수 있으므로, 새 요인 D와 연결된 통제도 따로 찾는다.

단순한 식 $y = \theta D + \beta Z + u$에서 Z를 빼면 D의 계수는 $\theta + \beta \,\mathrm{Cov}(D,Z)/\mathrm{Var}(D)$가 된다. Z의 y 예측력이 작아도 D와 강하게 관련되면 새 요인의 계수에 편향이 남는다. 결과 변수만 예측하는 라쏘로 통제를 고르는 것이 충분하지 않은 이유다.

숫자로 참 새 요인 효과 $\theta = 0$, 통제 효과 $\beta = 0.1$, $\mathrm{Cov}(D,Z)/\mathrm{Var}(D) = 0.5$라면 Z를 빼고 얻은 기울기는 $0 + 0.1(0.5) = 0.05$다. 새 요인에 참 독립 효과가 전혀 없어도 0.05라는 양의 계수가 나온다. 이 식은 $E[u \mid D, Z] = 0$ 등 회귀의 외생성 조건을 둔 단순 예시이며, 시간 변화와 측정오차가 있으면 추가 검토가 필요하다.

슬라이드 60 · 새 요인 15개의 비교

좁은 3요인 기준에서 유의하던 새 요인 중 일부는 기존 요인 전체를 적절히 통제하면 약해진다. 반대로 기존 요인과 구별되는 수익성 신호 등은 남을 수 있다. "유의하지 않음"은 효과가 정확히 0이라는 증명이 아니라 그 검정의 불확실성이 크다는 의미다.

t값은 계수 추정치를 표준오차로 나눈 값이므로 통제집합을 넓힌 뒤 어느 쪽이 변했는지 따로 기록한다. 계수가 줄었다면 기존 요인과 공유한 정보가 제거되었을 수 있고, 표준오차가 커졌다면 남은 변동에서 효과를 구별하기 어려운 것이다.

t값은 계수 추정치를 표준오차로 나눈 값이다. 예를 들어 계수가 0.04에서 0.02로 줄고 표준오차가 0.01로 같으면 t는 4에서 2로 낮아진다. 반면 계수 0.04가 그대로인데 표준오차만 0.01에서 0.02로 늘어도 같은 변화가 생긴다. 첫 경우는 통제와의 정보 중복, 둘째는 남은 신호를 구별할 자료 부족의 가능성이 크므로 표의 두 숫자를 따로 읽는다.

슬라이드 61 · 이중 선택의 세 단계

이중 선택(double selection)에서는 평균수익률 벡터를 $\bar{r}$, 기존 요인 노출 행렬을 C_h, 새 요인 노출을 C_g라 하자. 첫 라쏘는 $\bar{r}$를 C_h로 예측해 가격 결정에 중요한 통제 I_1을 고른다. 둘째 라쏘는 C_g를 C_h로 예측해 새 요인과 상관된 통제 I_2를 고른다.

$$
\begin{aligned}
Q_1(b) &= \|\bar{r} - C_h b\|^2 + \lambda_1 \|b\|_1, \\
I_1 &= \mathrm{supp}(\arg\min_b Q_1(b)), \\
Q_2(c) &= \|C_g - C_h c\|^2 + \lambda_2 \|c\|_1, \\
I_2 &= \mathrm{supp}(\arg\min_c Q_2(c)).
\end{aligned}
$$

마지막에는 C_g와 $I_1 \cup I_2$의 통제를 넣고 벌점 없는 회귀로 새 요인의 계수를 추정한다. 둘째 선택이 빠지면 결과에는 약하지만 새 요인과 강하게 연결된 변수가 누락될 수 있다. Feng·Giglio·Xiu[26]는 이중 선택을 요인 검정에 적용한다.

$I_1 \cup I_2$를 쓰면 평균수익률 또는 새 요인과 관련된 통제를 모두 남긴다. 마지막 회귀에서 관심 요인의 계수에 벌점을 주지 않아 추가 축소 편향을 피한다.

최종 회귀를 Frisch–Waugh–Lovell 직관으로 읽을 수 있다. 선택된 기존 요인들로 C_g에서 설명되는 부분을 빼고, 같은 요인들로 $\bar{r}$에서 설명되는 부분을 뺀 뒤 남은 두 잔차의 기울기를 재는 것이다. 이 기울기가 새 요인의 **기존 통제와 구별되는 관련성**이다. 두 번 선택했어도 시간 순서 누출, 선택된 요인의 측정오차, 약한 식별은 자동으로 없어지지 않는다.

[26] https://doi.org/10.1111/jofi.12883

슬라이드 62 · 다음 문제의 문턱

수백 기업 특성의 어느 조합이 다음 달 수익률을 가장 잘 예측하는가라는 질문이 남는다. 고전적 정렬과 회귀는 개별 신호의 경제적 의미를 보여 주지만 비선형 상호작용이 많으면 하나씩 시험하기 어렵다.

나무 깊이, 변수 조합, 학습 기간을 반복 조정하면 새 요인을 여러 개 시도한 것과 같은 선택 문제가 생긴다. 과거 구간에서 학습하고 다음 구간에서 변수와 벌점을 고른 뒤, 마지막 기간은 **어떤 선택에도 사용하지 않고** 한 번만 채점한다. 결과를 보고 다시 고치면 그 기간은 다음 분석의 검증자료가 된다.

슬라이드 63 · 요인 논쟁을 예측 문제로 다시 쓰기

수학적으로 목표는 $E[r_{i,t+1} \mid X_{i,t}]$라는 조건부 평균 함수다. $X_{i,t}$에는 기업 규모, 장부비율, 모멘텀, 수익성 등 시점 t에 알려진 특성이 들어간다. 선형 요인모형은 이 함수에 강한 구조 제약을 두는 한 방식이다.

이 조건부 평균은 주어진 정보에서 제곱오차를 최소화한다. 투자 판단에는 위험과 거래비용이 더해지고, 예측력의 경제적 원인을 설명하려면 위험 노출과 기대 오류도 조사해야 한다. 입력 특성의 발표 시점이 맞아야 두 평가 모두 의미가 있다.

왜 조건부 평균이 제곱오차의 최적값인가? 어떤 예측 함수 $g(X)$에 대해 $r - g(X) = [r - E(r \mid X)] + [E(r \mid X) - g(X)]$로 나누어 제곱한다. 첫 항의 조건부 평균이 0이라 교차항의 기대값은 사라지고, 남은 오차는 $E[(r - E(r \mid X))^2] + E[(E(r \mid X) - g(X))^2]$다. 둘째 항은 0 이상이므로 $g(X) = E(r \mid X)$가 최소다.

슬라이드 64 · 이미 시도한 정규화의 교훈

앞 장에서는 과거 수익률의 여러 시차와 제곱·세제곱을 넣어 능형회귀와 라쏘를 비교했다. OLS의 표본내 우수성이 검증자료에서는 유지되지 않았고, 계수 축소가 개선을 가져왔다. 이 결과는 새로운 특성 집합에도 같은 평가 규칙이 필요함을 보여 준다.

357개 가격 특징에 재무·텍스트 변수를 더하면 발표 지연, 회계 개정, 산업별 결측도 관리해야 한다. 2025년 12월 말 재무상태표가 2026년 3월에 공개되었다면 1월 예측에 확정 수치를 쓸 수 없다. 가격 특징의 시차와 재무 특징의 **이용 가능 날짜**를 같은 시점표에 놓고, 정정 전후 버전까지 구분한다.

슬라이드 65 · 횡단면 연구의 결론

새 신호를 평가하는 순서는 **당시 알 수 있던 특성 정의 → 다음 달 상·하위 그룹 차이 측정 → 기존 요인·규모·산업 통제 → 다른 기간·시장 재현 → 양쪽 거래비용과 위기 손실 확인**이다. 어느 단계에서 결과가 달라졌는지 기록하면 예측력, 위험 보상, 가격오류, 우연을 구분하는 데 도움이 된다.

모멘텀·가치·투자·수익성·무형자산·거래마찰은 패턴을 정리하는 범주다. 새 요인의 가치에는 기존 요인과 구별되는 정보, 독립 기간의 안정성, 실행 가능한 순수익이 함께 들어간다.

Leveraged ETFs · 레버리지 ETF와 시장 미시구조

ETF 한 주가 거래소에서 어떤 가격으로 거래되는지부터 시작한다. 설정·환매가 가격을 순자산 가치와 연결하고, 일일 배수 목표는 종가 무렵의 거래와 장기 복리 성과를 함께 만든다. 수식의 금액은 별도 언급이 없으면 수수료·차입비용·추적오차를 제외한 이상화된 값이다. 역사적 수익률은 해당 관측 기간의 결과이며 앞으로의 기대수익률이 아니다.

슬라이드 01 · 레버리지 ETF를 읽는 세 가지 질문

레버리지 ETF는 기초자산의 **하루 수익률**에 정해진 배수 L을 적용하려는 상장 펀드다. +2배면 지수가 하루 1% 오를 때 펀드 순자산이 약 2% 늘도록 노출을 맞춘다. -2배는 같은 날 약 2% 감소를 목표로 한다. 목표는 하루 단위이므로 여러 날의 성과는 일별 수익률을 곱해 계산한다.

펀드 자산에서 계산한 주당 NAV와 거래소에서 투자자가 지불하는 가격은 서로 다른 경로로 정해진다. 매일 바뀌는 목표 노출은 펀드의 손익과 종가 거래 수요를 만들고, 설정·환매는 시장가격을 NAV에 연결한다. 투자자 손익에는 매매 시점의 괴리와 스프레드도 반영된다.

슬라이드 02 · 반도체 호황은 왜 출발점인가

2025년부터 2026년 중반까지 AI 투자 확대와 메모리 반도체 기대가 관련 주가를 크게 끌어올렸다. 한국의 두 대형 반도체주와 미국 Micron이 함께 상승했으므로 **공통 산업 충격**을 먼저 살핀다. 그래프의 시작 가격을 100으로 맞춘 값은 각 주가의 상승 배율을 비교하는 지표다.

2026년 5월 단일종목 2배 ETF는 주가 상승이 이미 진행된 뒤 상장됐다. ETF가 이후 가격에 미친 영향을 추정하려면 산업 수요, 미래 현금흐름 전망, 할인율 변화와 ETF 주문을 분리해야 한다. 버블 여부 역시 미래 현금흐름과 할인율에 대한 가정에 따라 판정이 달라진다. 이것이 가격 검정의 **결합가설** 문제다.

슬라이드 03 · 7월 급락과 책임론을 분리해서 보기

2026년 7월에는 KOSPI 200과 반도체주가 크게 떨어졌고, 급반등한 날도 있었다. 레버리지 ETF가 하락일에 노출을 줄이는 주문을 내므로 가격 하락을 증폭했을 가능성이 제기됐다. 하락의 출발점과 ETF 주문이 추가한 몫은 기업 실적 기대, 세계 반도체 수요, 환율, 다른 투자자의 매매를 고려해 추정해야 한다.

특히 SK하이닉스 기초주가 상장 이후 하락한 동안 +2배와 -2배 상품이 모두 큰 손실을 냈다는 점은 방향만으로 장기 성과를 예측할 수 없음을 보여 준다. 지수가 여러 번 반전하면 양쪽 상품에 모두 불리한 복리 경로가 생긴다. 뒤의 이틀 계산에서 정확한 이유를 확인한다.

슬라이드 04 · 시장 충격에 관한 주장과 검증

국내 반도체주와 해외의 유사 업종이 함께 하락했다면 공통 산업 뉴스가 설명하는 부분을 먼저 살핀다. 이후 국내 장 마감에 특히 집중된 변화가 있었는지 비교하면 ETF 주문의 **추가 효과**를 좁혀 갈 수 있다. 해외 종목은 실적, 환율, 거래시간과 제도가 달라 비교군으로 쓸 때 이 차이를 통제해야 한다.

종가에 ETF 매도 주문이 몰리면 이를 받아 줄 매수 주문을 끌어내기 위해 가격이 내려갈 수 있다. 반대편 주문이 적은 시장일수록 같은 매도량의 가격 충격이 크다. 마지막 절에서는 종가의

주문 집중과 가격 변화를 비교한다. 서울경제 시론[27]의 주장은 검정할 가설로 둔다.

슬라이드 05 · 경제학적 질문의 범위

정책 판단의 기준은 같은 반도체 뉴스가 발생했지만 단일종목 ETF는 없었던 **반사실적 시장**이다. 관찰된 종가와 그 시장의 종가 차이가 ETF의 가격 효과다. 상품을 제한한 뒤 투자자가 신용융자나 다른 상품으로 옮긴다면 특정 ETF의 거래량이 줄어도 시장 전체 위험은 달리 움직일 수 있다.

투자자 관점에서는 같은 일일 배수가 수익과 위험을 함께 증폭한다. 강한 추세, 큰 왕복 변동, 조달 비용 중 무엇이 지배적인지에 따라 적절한 보유기간과 상품 선택이 달라진다. 정책의 인과 질문과 투자자의 손익 질문을 나란히 놓는 것이 이 장의 출발점이다.

슬라이드 06 · 10년 수익률이 단순 배수와 다른 까닭

2016년 9월부터 2026년 9월까지 QQQ의 총수익률은 +565%, TQQQ는 +2,946%, SQQQ는 -99.97%였다. 같은 기간 KODEX 200은 +420%, KODEX 레버리지는 +901%, KODEX 200선물인버스2X는 -99.27%였다. 이는 관측된 특정 10년의 결과다. QQQ의 565%를 단순히 세 배 하면 1,695%인데 TQQQ의 기록은 그보다 크다.

첫날 지수 수익률이 r_1이면 비용 없는 L배 펀드의 순자산 A_0는 $A_1 = A_0(1 + Lr_1)$이 된다. 다음 날에는 **바뀐 순자산** A_1에 그날의 Lr_2를 적용하므로 $A_2 = A_0(1 + Lr_1)(1 + Lr_2)$다. 이를 계속 반복한 기간 수익률은 $\prod_t (1 + Lr_t) - 1$이다. 반면 지수를 끝까지 보유한 뒤 기간 수익률만 L배 하는 계산은 $L[\prod_t (1 + r_t) - 1]$이다. 매일 배수를 다시 맞추면 두 식의 교차항이 달라지므로 강한 추세와 왕복 변동에서 장기 성과가 다르게 나타난다.

슬라이드 07 · 다섯 단계의 연결

분석에는 서로 다른 세 종류의 관계가 등장한다. **회계 관계**는 NAV와 발행 지분을 연결한다. **복제 관계**는 순자산에 배수 L을 곱해 목표 노출액을 정한다. **시장 균형 관계**는 그 노출을 조정하려는 주문이 다른 투자자의 주문과 만나 어떤 가격을 만드는지 묻는다. 앞의 두 관계는 금액을 계산할 수 있지만 마지막은 시장 자료가 필요하다.

이 순서대로 ETF 가격과 설정·환매, 일일 거래식, 여러 날의 복리, 위험조정 성과, 종가의 가격 충격을 읽는다. 뒤 단계의 결론을 앞 단계의 정의에 얹어야 서로 다른 금액이나 수익률을 섞지 않는다.

슬라이드 08 · ETF의 두 시장

ETF에는 투자자가 거래소에서 기존 지분을 서로 사고파는 **유통시장**과, 지정된 기관이 운용사와 대량 지분을 설정·환매하는 **발행시장**이 있다. 투자자가 ETF 한 주를 샀다고 그 순간 새 지분이 자동 발행되지는 않는다. 주문장에서 다른 투자자의 기존 한 주를 받았다면 총 발행 지분 수는 변하지 않는다.

발행시장에서는 바스켓과 펀드 지분을 큰 단위로 교환한다. 유통시장에서는 그 지분이 주문장 가격으로 계속 옮겨 다닌다. 시장가격이 펀드 자산가치에서 멀어지면 기관이 두 시장을 오가며 거래할 유인이 생긴다. SEC의 ETF 구조 설명[28]은 이 연결을 단계별로 보여 준다.

[27] https://www.sedaily.com/NewsView/20073850

[28] https:// www.investor.gov/ introduction- investing/ general- resources/ news- alerts/ alerts-bulletins/investor-bulletins-24

슬라이드 09 · NAV와 시장가격의 단위

NAV(net asset value)는 펀드 자산의 시장가치에서 부채를 뺀 순자산이다. 총 NAV를 발행 지분 수로 나누면 **한 주당 NAV**가 된다. 예를 들어 순자산 100억 원, 지분 100만 주라면 한 주당 NAV는 1만 원이다. 이때 거래소 가격이 10,100원이면 100원의 프리미엄이다. 장중에는 보유자산의 실시간 추정치인 iNAV와 사후 확정 NAV가 다를 수 있다.

지수는 운용 목표를 표시하는 기준값이다. NAV 수익률에는 실제 보유자산, 보수와 추적오차가 반영된다. 투자자의 체결수익률에는 여기에 매수·매도 가격의 괴리와 스프레드가 더해진다. 기초자산이 휴장 중인 해외 ETF에서는 장중 iNAV도 새로운 정보를 느리게 반영할 수 있다.

슬라이드 10 · AP, LP, 설정 단위

AP(authorized participant, 지정참가회사)는 운용사와 정해진 큰 단위인 creation unit으로 ETF 지분을 새로 만들거나 돌려줄 권한이 있다. LP(liquidity provider, 유동성공급자)는 거래소에 매수·매도 호가를 제시한다. 한 증권사가 두 역할을 겸할 수 있지만 **설정·환매 권한**과 **주문장 호가 공급**은 기능이 다르다. 한국거래소의 설정·환매 제도[29]와 LP 제도[30]를 참고할 수 있다.

설정 시 AP는 정해진 자산 바스켓이나 현금을 운용사에 납입하고 ETF 지분을 받는다. 환매는 반대다. 개인은 보통 한 주를 운용사에 가져가 NAV로 교환하지 못하므로 주문장 가격에 노출된다. AP가 거래를 결정할 때는 가격 차이뿐 아니라 세금, 수수료, 헤지 가능성, 가격이 바뀔 위험도 계산한다.

슬라이드 11 · 주식처럼 거래되는 펀드

일반 개방형 펀드는 가입·환매 신청 뒤 정해진 기준가격을 적용하지만 ETF는 장중 주문장 가격으로 거래한다. 따라서 지정가를 낼 수 있고 즉시 거래할 때는 매수·매도 호가 차이인 **bid-ask spread**를 부담한다.

순자산 증가와 투자자의 체결 수익은 구별해야 한다. 주당 NAV를 N_t, 체결가격을 P_t라 하고 NAV 대비 프리미엄을 $q_t = (P_t - N_t)/N_t$로 정의하면 $P_t = N_t(1+q_t)$다. 따라서 매수가격 대비 매도가격인 총수익 배율 P_1/P_0는 $(N_1/N_0)\{(1+q_1)/(1+q_0)\}$로 분해된다. NAV가 10,000원에서 10,100원으로 올라도 매수 때 1%였던 프리미엄이 매도 때 사라지면 두 체결가격은 모두 10,100원이다. 투자자 수익률은 0%다.

슬라이드 12 · 누가 누구와 거래하는가

개인 A가 ETF 100주를 사고 B가 기존 지분 100주를 팔면 거래량은 100주, 순설정은 0주다. 반대편이 LP라면 LP의 재고가 100주 줄어든다. LP의 매도 누적량이 설정 단위에 이를 만큼 커지면 AP가 바스켓을 납입해 새 지분을 만들 수 있다. 개인의 100주 매수와 새 지분 발행 사이에는 재고 관리와 AP의 선택이 끼어 있다.

거래량은 지분의 소유권 이전을, **순설정액**은 발행 지분 수의 순증가를 측정한다. 현물 바스켓을 납입했다면 AP의 기초자산 매입이 선행될 수 있고, 현금·파생상품 설정에서는 운용사나 계약 상대방의 후속 거래가 중요해진다. 시장 충격을 계산할 때는 이 거래의 주체와 시각을 추적해야 한다.

[29] https://regulation.krx.co.kr/contents/RGL/03/03060106/RGL03060106.jsp
[30] https://regulation.krx.co.kr/contents/RGL/03/03060103/RGL03060103.jsp

슬라이드 13 · 차익거래가 NAV에 가격을 묶는 방식

한 주당 NAV가 10,000원, 시장가격이 10,100원이고 설정 단위가 1만 주라면, 그 지분의 NAV 총액은 1억 원, 시장 매도대금은 1억 100만 원이다. AP는 바스켓을 납입해 새 지분을 만들어 팔 유인이 있다. 공급이 늘면 프리미엄이 줄어드는 방향이다. 반대로 시장가격이 9,900원이면 9,900만 원에 1만 주를 사서 1억 원 가치로 환매할 유인이 생긴다.

차액 100만 원은 **비용 전** 금액이다. 예를 들어 환매된 현물 바스켓의 처분에 20만 원 세금이 붙는다면 80만 원이 남고, 여기서 스프레드·수수료·가격위험을 더 빼야 한다. 괴리가 작으면 거래하지 않는 것이 합리적일 수 있다. 설정은 ETF 공급 확대, 환매는 공급 축소라는 방향으로 가격을 NAV에 연결한다.

양쪽 손익분기점에는 비용 차이가 있다. **환매로 받은 주식을 팔 때만** 0.2% 세금이 붙는 단순한 경우, 주당 NAV 10,000원을 환매한 뒤 받는 순액은 $10{,}000(1-0.002)=9{,}980$원이다. 따라서 ETF를 $P<9{,}980$원에 사야 이익이다. 설정 쪽은 주식을 사서 ETF를 파므로 이 세금만 고려하면 $P>10{,}000$원에서 이익이다. 실제 손익분기 구간은 양쪽의 스프레드·시장충격·위험 부담만큼 넓어진다. LP가 지수선물로 가격위험을 헤지하면 즉각적인 현물 매도세를 피할 수 있지만, 선물과 현물의 가격 차이와 만기 위험을 부담한다.

슬라이드 14 · KODEX 200 설정 단위 계산

한 설정 단위가 5만 주이고 한 주 NAV가 108,550원이면 교환되는 펀드 가치의 기준은 $50{,}000\times 108{,}550=5{,}427{,}500{,}000$원, 약 54.3억 원이다. 자산 바스켓에 삼성전자 6,969주, SK하이닉스 849주 등이 포함될 수 있다. AP는 이 큰 단위를 기준으로 거래하므로 개인의 한 주 매매와 절차가 다르다.

바스켓 매각에 0.2% 세금이 적용된다는 단순 가정이면 54.3억 원의 0.2%는 약 1,085만 원이다. 괴리 0.2%만을 노리는 거래라면 이 세금만으로 총 차익이 거의 사라질 수 있다. 실제 비용은 바스켓 구성, 현물·현금 납입 방식, 거래소와 상품 규정에 따라 달라진다. **괴리율의 손익분기점**은 비용을 금액으로 환산해 비교해야 한다.

슬라이드 15 · 한국의 AP와 LP가 연결되는 순서

국내 상품에서 한 증권사가 LP와 AP를 겸할 수 있다. LP가 주문장에서 지분을 팔아 재고가 줄어도 AP의 설정은 별도의 결정이다. 가격 괴리와 바스켓 조달 비용에 따라 새 지분의 발행량과 시점이 정해진다.

실제 현물 수요로 이어지는지 판단하려면 **설정 방식**을 봐야 한다. 현물 설정에서는 AP가 자산 바스켓을 사서 납입하고, 현금 설정에서는 운용사가 새 현금으로 노출을 만들 수 있다. 선물·스왑 ETF라면 상대방의 헤지 주문으로 퍼질 수 있다. 총 노출액과 개별 주식의 체결액을 등치시키면 시장 충격을 과장한다.

슬라이드 16 · 프리미엄과 디스카운트 읽기

한 주 시장가격을 P, 같은 시점의 주당 추정 NAV를 N이라 하면 괴리율은 $(P-N)/N$이다. $P=10{,}100$, $N=10{,}000$이면 +1% 프리미엄이고, $P=9{,}900$이면 -1% 디스카운트다. 양수일 때 AP의 설정, 음수일 때 환매 유인이 커지는 것이 기본 방향이다.

다만 장중 iNAV와 장 마감 NAV는 산정 시각이 다르고, 유동성이 낮은 기초자산은 평가가격 자체가 느릴 수 있다. '괴리'가 항상 ETF 시장가격의 오류를 뜻하지는 않는다. 특히 해외 ETF의 국

내 거래 시간에는 국내 ETF 가격이 해외시장 개장 뒤의 정보를 먼저 반영할 수도 있다. 괴리율을 볼 때는 기준가격의 시각과 사용한 환율을 함께 확인한다.

슬라이드 17 · LP의 호가와 종가 괴리 의무

국내 상장 ETF의 LP에는 평소 호가 스프레드가 신고한 범위를 벗어날 때 호가를 제시하는 의무와, 종가 괴리를 관리하는 별도 의무가 있다. 자료의 2026년 10월 7일 기준 설명에서는 스프레드 한도 최대 2%, 일정 시간 내 호가 제출, 국내 기초자산 ETF의 종가 괴리 2% 기준을 구분한다. 이 값들은 제도 개정에 따라 달라질 수 있으므로 실제 매매 전에는 한국거래소 LP 규정[31]을 확인해야 한다.

종가 단일가매매에서는 주문을 모아 하나의 가격으로 체결한다. 평소의 스프레드 호가 의무가 적용되지 않는 시간에도 종가 괴리는 관리 대상이다. 다만 종가 괴리 의무는 사후 평가 성격이어서, 특정 종가에 원하는 규모의 매도 주문이 공급되리라는 보장은 없다.

실제 손실률은 괴리율과 분모가 다르다. 예컨대 NAV가 16,141원인 ETF를 종가 30,000원에 샀다면 프리미엄은 $30{,}000/16{,}141 - 1 \approx 85.9\%$다. 다음 날 NAV가 그대로이고 시장가격만 NAV로 돌아가면 매수자의 수익률은 $16{,}141/30{,}000 - 1 \approx -46.2\%$다. 85.9%와 46.2%가 다른 까닭은 전자는 NAV를, 후자는 **지불한 가격**을 분모로 하기 때문이다. 큰 프리미엄을 없애려는 매도 유인이 있더라도 단일가 시간에 충분한 반대 주문이 반드시 들어오지는 않는다.

슬라이드 18 · 괴리 공시와 투자유의의 단계

국내 기초자산 ETF의 종가 괴리가 일정 수준 이상이면 운용사의 공시가 요구된다. 당시 설명의 기준은 국내 1%, 해외 2%였으며, LP 기준의 두 배를 넘는 큰 괴리가 반복되면 투자유의 지정예고와 지정, 단일가매매 단계로 이어질 수 있었다. **공시**, **지정예고**, **지정**은 서로 다른 조치다. 한 번 적출된 사실을 즉시 투자유의 지정으로 읽으면 과장된다. 최신 기준은 KRX 공시·상장 규정[32]을 확인해야 한다.

이 제도는 괴리 위험을 투자자에게 알리고 LP에 가격 관리 유인을 주지만, 펀드 가격을 언제나 NAV와 일치시키는 보험은 아니다. 급변일에는 기초자산 호가, 단일가 주문 집중, 설정·환매 비용이 함께 달라질 수 있다. 개인은 시장가 주문보다 예상 체결가격과 iNAV를 비교한 지정가 주문을 고려할 수 있다.

슬라이드 19 · 일일 리밸런싱의 출발점

일반 ETF의 설정·환매를 이해했다면 이제 펀드 **안쪽의 노출 조정**을 볼 차례다. 레버리지 배수 L은 펀드 순자산 1원당 기초지수에 얼마나 노출될지를 뜻한다. 순자산 A와 목표 노출액 E의 관계는 $E = LA$다. $L = 2$면 순자산 100에 지수 노출 200, $L = -2$면 지수에 대한 음의 노출 200이다.

지수가 움직이는 동안 노출과 순자산은 서로 다른 속도로 변하므로 종가에는 E/A가 목표에서 벗어난다. 펀드는 다음 날도 같은 하루 배수를 목표로 노출을 다시 맞춘다. 이 조정이 '상승 후 매수·하락 후 매도'의 출처다. 실제 노출은 선물·스왑·현물 등으로 구현되어 명목 조정액과 현물 주문액은 같지 않을 수 있다.

[31] https://regulation.krx.co.kr/contents/RGL/03/03060103/RGL03060103.jsp
[32] https://regulation.krx.co.kr/

슬라이드 20 · 미국 상품의 배수와 기초자산

TQQQ와 SQQQ는 Nasdaq-100에 각각 +3배와 -3배의 **일일** 노출을 목표로 한다. UPRO는 S&P 500의 +3배, SOXL은 반도체 지수의 +3배, TSLL·NVDL은 개별 주식의 +2배 상품이다. 이름이 비슷해도 기초자산과 배수가 다르면 장기 위험은 크게 달라진다. 특히 단일종목은 분산된 지수보다 한 기업의 실적 발표나 급등락에 더 민감하다.

표의 거래대금은 2026년 9월 말까지 최근 60거래일 평균, 10년 수익률은 2016년 9월부터의 누적 총수익률이라는 서로 다른 통계다. 상장한 지 10년이 안 된 상품의 수익률 칸이 비어 있는 이유도 여기에 있다. 높은 거래대금은 유동성에 도움이 되지만 주문장 깊이와 체결 비용을 완전히 보장하지 않는다.

슬라이드 21 · 국내 상품과 미국 상품의 비교 단위

국내의 KODEX 레버리지는 KOSPI 200에 +2배, KODEX 200선물인버스2X는 -2배의 일일 노출을 목표로 한다. SK하이닉스 단일종목 상품은 지수 ETF보다 한 종목의 변동성에 직접 노출된다. 같은 '2배'라도 기초자산 변동성이 2배라면 펀드 일간 변동성도 대략 두 배 더 커진다. 여러 날의 복리 손실 가능성은 분산이 커질수록 빠르게 늘어난다.

표의 미국·한국 수익률을 그대로 순위화할 때는 통화, 배당 재투자, 무위험이자율과 표본기간 차이를 확인한다. -2배 ETF의 장기 손실은 장기 상승 추세와 매일의 재설정이 결합한 결과이지, 하루 -2배 목표가 실패했다는 뜻이 아니다. 상품 설명서의 목표 지수와 파생상품 방식까지 봐야 한다.

슬라이드 22 · 단일종목 ETF와 신규 시장

2026년 5월 삼성전자와 SK하이닉스를 기초로 한 단일종목 레버리지·인버스 ETF가 상장됐다. 각 종목에 +2배 상품 여러 종과 -2배 상품이 출시되며, 개인의 +2배 상품 순매수가 6월 중순까지 크게 늘었다. 이는 기존 지수형 ETF와 달리 **한 종목의 종가 유동성**에 리밸런싱 수요가 집중될 수 있다는 점에서 중요하다. 금융위원회의 단일종목 상품 투자 유의 안내[33]처럼 배수와 단일종목 위험을 함께 살펴야 한다.

투자자 교육, 모의거래, 기본예탁금 같은 국내 요건은 시행 시점과 투자자 유형에 따라 달라진다. 손실 위험을 줄이려는 제도와 별개로, 경제학적 질문은 새 상품의 종가 거래가 기존 종목의 변동성을 얼마나 더 키웠는가이다.

질문: 개인 순매수 8.2조 원이 곧 펀드 순설정 8.2조 원인가요? 아닙니다. 개인이 기존 보유자에게서 산 지분도 순매수에 포함됩니다. 펀드로 들어간 신규 자금은 설정·환매 자료로 따로 확인해야 합니다.

슬라이드 23 · +2배와 -2배가 같은 방향으로 거래하는 이유

순자산 100, 지수 상승률 10%를 생각하자. +2배 펀드는 시작 노출 200이 220이 되고 순자산은 120이다. 새 목표 노출은 $2 \times 120 = 240$이므로 **20 매수**가 필요하다. 현물로 복제하고 차입금 100을 고정해 두었다면, 보유자산 200이 220으로 오른 뒤에도 자기자본은 $220 - 100 = 120$이다. 따라서 220과 120을 혼동하지 않아야 추가 매수 20이 나온다. -2배 펀드는 시작 노출 -200이 가격 상승 뒤 -220이 되고 손실로 순자산은 80이다. 새 목표는 $-2 \times 80 = -160$이므로 $-160 - (-220) = +60$, 즉 역방향 포지션을 60 줄이는 **매수 방향**이다.

[33] https://www.fsc.go.kr/

하락일에는 두 상품 모두 반대 방향이다. -2배 펀드가 상승일에 산다는 말은 상승에 베팅한다는 뜻이 아니다. 손실로 줄어든 자기자본에 비해 너무 커진 음의 노출을 되사는 것이다. 펀드가 실제로 선물을 쓴다면 '매수'는 선물 포지션 조정이나 상대방 헤지로 구현될 수 있다.

슬라이드 24 · 거래식 L(L-1)Ar의 유도

장 시작 순자산을 A, 지수 수익률을 r, 목표 배수를 L이라 하자. 부호를 포함한 지수 노출액은 처음에 LA다. 예를 들어 $L=-2$면 지수 상승에 손실이 나는 노출 $-2A$를 뜻한다. 지수가 r만큼 움직이면 **기존 포지션의** 노출액은 $LA(1+r)$가 되고, 그 포지션에서 발생한 손익은 LAr이다. 따라서 새 순자산은 $A(1+Lr)$다. 다음 날에도 새 순자산의 L배를 유지하려면 목표 노출액은 $LA(1+Lr)$여야 한다. 필요한 순거래는 목표에서 거래 전 노출을 뺀 값이다.

$$\begin{aligned}\Delta E &= LA(1+Lr) - LA(1+r)\\ &= L(L-1)Ar.\end{aligned}$$

$A=100, r=10\%$에서 -1배는 기존 노출 -100이 -110으로, 순자산은 90으로 변해 목표 -90을 맞추기 위해 20을 되산다. +2배의 20 매수와 비교하면, 배수 부호가 달라도 $L(L-1)>0$이면 같은 방향의 조정이 필요함을 알 수 있다. 이 식은 비용·유입이 없는 **명목 노출**의 조정식이다.

슬라이드 25 · 지정가 주문과 역방향 자금 흐름

현재가 아래에 놓인 개인의 지정가 **매수** 주문은 가격이 떨어질 때 체결되고, 위에 놓인 **매도** 주문은 상승할 때 체결된다. 따라서 주문을 미리 깔아 둔 투자자는 거래 체결만 보면 하락 뒤 사거나 상승 뒤 파는 역방향 투자자가 될 수 있다. 기다리며 스프레드를 얻을 가능성이 있는 대신 가격이 계속 불리하게 움직이는 위험을 감수한다.

지수가 급락할 때 기초자산 NAV도 내려간다. ETF 아래에 대기하던 매수 지정가가 체결되어 ETF 가격의 하락폭이 NAV보다 작다면 일시적 프리미엄이 생긴다. LP·AP가 ETF를 팔고 새 지분을 설정할 유인이 생기지만, 비용이 크거나 가격이 곧 움직일 위험이 있으면 괴리가 남을 수 있다. 반대로 상승 중 개인의 대기 매도가 체결되면 디스카운트와 환매 유인이 생길 수 있다. **기존 지분 거래 → 가격 괴리 → AP 결정 → 발행 지분 변화**는 조건부 경로이며, 실증적으로 순설정 F가 지수 수익률 r과 반대로 움직였는지를 따로 확인해야 한다.

질문: 지정가로 샀으니 언제나 시장에 유동성을 공급한 건가요? 주문장에 기다리던 지정가 주문이 시장가 주문과 체결됐다면 그렇습니다. 즉시 체결되는 공격적 지정가 주문은 유동성을 소비할 수도 있습니다.

슬라이드 26 · 순설정 F를 포함한 거래식

장 마감에 현금 기준 순설정액 F가 들어오고, 그 현금이 아직 지수에 투자되지 않았다고 하자. 순자산은 $A(1+Lr)+F$가 되고 목표 노출은 $L[A(1+Lr)+F]$다. 기존 포지션 $LA(1+r)$를 빼면 다음과 같다.

$$\Delta E = L(L-1)Ar + LF.$$

지수가 10% 오른 +2배 펀드는 기본 리밸런싱 20에 순설정 10의 2배인 20이 더해져 40 매수한다. 같은 조건의 -1배는 기본 20 매수에 $-1\times 10=-10$이 더해져 10 매수한다. 반대로 +2배가 10% 하락하면 기본 -20인데 순설정 10의 +20이 이를 상쇄한다. 이는 개인의 ETF 매수 체결액

이 10이라는 가정과 다르다. $F = 10$은 **실제로 발행된 지분의 순증가분을 NAV로 평가한 금액**이다. 현물 바스켓을 AP가 납입하면 펀드 내부의 현금 주문액은 달라지지만, AP의 바스켓 매수까지 합친 경제적 노출 변화는 같은 방향이다.

슬라이드 27 · 한 식에서 두 효과가 나온다

일일 재설정 거래 $L(L-1)Ar$는 누적 성과에 양면적이다. 첫날 상승 뒤 추가 매수하면 다음 날도 상승할 때 이익이 커진다. 첫날 하락 뒤 매도하면 다음 날도 하락할 때 손실을 줄인다. 같은 방향이 이어질 때 고정된 L배 매수후보유보다 유리해지는 효과를 여기서는 **convexity**라고 부른다.

반면 다음 날 방향이 바뀌면 상승 뒤 산 물량이 손실을 보거나 하락 뒤 판 물량이 반등을 놓친다. 이것이 흔히 **volatility decay**로 불리는 경로 효과다. 추세에 따른 이익과 반전에 따른 손실은 같은 일일 조정 거래에서 나온다. 여러 날의 성과는 전체 수익률뿐 아니라 일간 수익률의 순서와 크기에 달려 있다.

슬라이드 28 · '음의 복리'를 정확히 해석하기

원주가 제자리로 돌아왔는데 레버리지 ETF가 손실을 보는 사례는 실제로 가능하다. 복리 성과의 부호는 경로에 달려 있다. 매일 같은 배수로 다시 맞추는 과정에서 변동성이 큰 반전 경로는 손실을 만들고, 지속적인 상승 추세는 고정 배수보다 큰 이익을 만들 수 있다.

SK하이닉스 단일종목 상품의 2026년 5월 말~9월 말 기록에서는 기초주가 하락과 큰 반전이 함께 있었다. +2배와 -2배가 모두 60% 넘게 손실을 본 사실은 변동성 효과의 크기를 묻는 출발점이다. 상품의 거래가격과 NAV의 괴리, 운용비용도 총손익에 들어가므로 기계적 복리만으로 실제 손익을 모두 설명할 수는 없다.

슬라이드 29 · 이틀 경로를 직접 곱해 보기

지수가 첫날 +10%, 다음 날 +10%면 누적 수익률은 $(1.1)^2 - 1 = 21\%$다. +2배 펀드는 $(1.2)^2 - 1 = 44\%$로 지수 누적의 단순 두 배 42%보다 2%포인트 높다. 반대로 +10%, -10%면 지수는 $1.1 \times 0.9 - 1 = -1\%$, +2배는 $1.2 \times 0.8 - 1 = -4\%$로 단순 두 배 -2%보다 낮다.

같은 반전 경로에서 +3배는 $1.3 \times 0.7 - 1 = -9\%$, -2배는 $0.8 \times 1.2 - 1 = -4\%$다. 지수가 -1%인데 -2배의 단순 배수는 +2%라는 점과 비교하면 인버스도 6%포인트 불리하다. 반대로 -10%, -10%라면 -2배 펀드는 +44%로 단순 배수 +38%보다 유리하다. 부호와 경로를 직접 곱해 보아야 한다.

슬라이드 30 · 일일 재설정과 매수후보유의 정확한 차이

초기자산 A에 지수 노출 LA를 한 번 만든 뒤 거래하지 않는 **고정 노출 매수후보유**의 이틀 최종 가치는 $A\{1 + L[(1+r_1)(1+r_2) - 1]\}$다. 지수의 이틀 수익률에 정확히 L을 곱한다. 반면 매일 배수를 재설정하는 펀드는 $A(1+Lr_1)(1+Lr_2)$다. 각각 전개하면 $Lr_1 + Lr_2$까지는 같고 교차항만 다르다.

$$
\begin{aligned}
V_{\text{daily}} &= A(1+Lr_1)(1+Lr_2), \\
V_{\text{hold}} &= A[1 + L(r_1 + r_2 + r_1 r_2)], \\
V_{\text{daily}} - V_{\text{hold}} &= L(L-1)Ar_1 r_2.
\end{aligned}
$$

첫날 필요한 추가 거래가 $L(L-1)Ar_1$였으므로 차액은 바로 **첫날 추가 포지션이 둘째 날 번 손익**이다. 이 해석이 수식과 경제적 직관을 연결한다. 고정 노출 전략도 차입비용·마진 제약이 있으면 실제로 구현하기 어렵다는 점은 별개다.

슬라이드 31 · 거래액 20이 만드는 +2 또는 -2

$A = 100$, $L = 2$, 첫날 $r_1 = 10\%$이면 종가에 노출 20을 추가한다. 둘째 날 수익률이 $+10\%$이면 이 거래가 2를 벌고, -10%이면 2를 잃는다. 같은 첫날의 조정도 다음 날 방향에 따라 이익 또는 손실이 된다.

여기서 $20 \times r_2$는 **펀드와 고정 노출 전략의 손익 차이**다. 기초주가에 미치는 효과를 계산하려면 20의 명목 노출 가운데 실제 종가 현물 주문이 얼마였고 이를 받아 준 반대 주문이 얼마나 있었는지 알아야 한다.

슬라이드 32 · 왕복 변동의 정확한 손실

지수가 첫날 x만큼 오르고 다음 날 같은 **수익률 크기** x만큼 떨어지면 지수 총수익률은 $(1+x)(1-x)-1 = -x^2$다. 일일 L배 펀드의 총수익률은 $(1+Lx)(1-Lx)-1 = -L^2x^2$다. 지수 총수익률의 단순 L배와의 차이는 $-L(L-1)x^2$다. 같은 왕복 폭에서 배수를 두 배로 높이면 펀드의 경로 손실은 네 배가 된다.

여기서 +10% 뒤 -10%는 **가격이 원래 수준으로 돌아오는 경로가 아니다**. 정말 원점으로 돌아가려면 둘째 날 수익률은 $-x/(1+x)$여야 한다. 예를 들어 +10% 뒤 약 -9.09%다. 어느 경로를 말하는지에 따라 지수 손익과 펀드 손익 숫자가 달라진다. 상품은 하루에 $1 + Lr_t > 0$이 유지된다는 범위에서 이 단순식을 따른다.

슬라이드 33 · T일 곱을 2차 항까지 전개

지수의 T일 누적수익률은 $R_I = \prod_{t=1}^{T}(1+r_t) - 1$이고 펀드는 $R_L = \prod_{t=1}^{T}(1+Lr_t) - 1$이다. 작은 일간 수익률을 가정하고 두 개가 곱해진 항까지만 남기면 지수에는 $\sum_t r_t + \sum_{i<j} r_i r_j$, 펀드에는 $L\sum_t r_t + L^2 \sum_{i<j} r_i r_j$가 남는다. 세 개 이상이 곱해진 항은 버린 **근사**다.

$$R_L - LR_I \simeq L(L-1)\sum_{i<j} r_i r_j.$$

1차 항은 고정 배수 전략에도 동일하게 들어가 상쇄된다. 남는 날짜 쌍의 항은 앞선 날의 조정이 뒤의 날 수익률을 얻는다는 해석을 여러 날로 확장한 것이다. 큰 일간 변동이나 긴 기간에는 생략된 고차항이 커질 수 있으므로 정확한 손익은 원래의 곱으로 계산해야 한다.

슬라이드 34 · 볼록성과 변동성 항의 분해

항등식 $(\sum_t r_t)^2 = \sum_t r_t^2 + 2\sum_{i<j} r_i r_j$를 앞의 식에 대입하면 두 효과가 분리된다. 2차 근사에서는 $\sum_t r_t$ 대신 지수 누적수익률 R_I를 넣어도 2차 정확도는 유지된다. 두 값의 차이가 이미 2차 항이고, 다시 제곱하면 차이가 3차 이상이기 때문이다.

$$R_L - L R_I \simeq \frac{L(L-1)}{2} R_I^2 - \frac{L(L-1)}{2} \sum_{t=1}^{T} r_t^2 .$$

첫 항은 시작과 끝의 큰 움직임이 만드는 **convexity**, 둘째 항은 경로 중 매일의 제곱수익률이 만드는 **volatility decay**로 읽는다. $L = 2$면 계수는 1, $L = 3$ 또는 $L = -2$면 3이다. 이 식은 일간 수익률이 작을 때의 2차 근사다.

끝점만을 넣은 $+2$배의 볼록성 **기준값**은 정확히 계산할 수 있다. 지수의 전체 기간 수익률을 R이라 할 때 $(1+R)^2 - 1 = 2R + R^2$이므로, 단순히 전체 수익률을 두 배 한 $2R$과의 차이는 정확히 R^2다. $R = +20\%$이든 -20%이든 기준값은 초기자산의 4%포인트, $|R| = 40\%$면 16%포인트다. 다만 $(1+R)^2 - 1$은 **끝점으로 만든 비교 함수**이지 실제 매일 2배로 재설정한 ETF 수익률 $\prod_t (1 + 2r_t) - 1$이 아니다. 둘의 차이는 실제 일별 경로에 달려 있으며, 앞 식의 변동성 항은 그 차이를 작은 수익률에서 근사한다.

슬라이드 35 · 끝점과 경로를 따로 보기

그림에서는 끝점 R_I가 같은 경로끼리 비교한다. 그중 일간 등락이 큰 경로는 $\sum r_t^2$가 커져 조정 성과가 낮다. 반대로 일간 등락의 크기가 비슷하다면 멀리 이동한 끝점에서 R_I^2의 이익이 크다. 두 축을 따로 고정해야 추세와 변동성의 효과를 읽을 수 있다.

표의 2배 펀드 예에서 지수가 연말에 제자리인 행은 볼록성 0이고 변동성 20%, 40%, 60%에 따라 손실이 커진다. 지수가 +40%나 -40%인 행은 양의 볼록성 항이 있다. 다만 표의 수치는 특정 시뮬레이션과 분해 방식으로 만든 결과이며 위의 2차 근사 수치와 일대일로 같지 않다. 수익률이 매우 클 때는 로그 기반 정확 분해나 원래의 일일 곱을 사용해야 한다.

슬라이드 36 · SK하이닉스 사례를 분해하는 방법

2026년 5월 27일부터 9월 30일까지 기초주가 -20.8%라면 고정 +2배는 -41.6%, 고정 -2배는 +41.6%가 기준이다. 제시된 기간별 분해에서는 +2배에 볼록성 +4.3%포인트, 변동성 효과 -21.4%포인트가 더해져 이상적 일일 펀드 약 -58.7%가 되고, 비용·추적 차이 -2.4%포인트 뒤 실제 약 -61.1%다. -2배는 +17.9, -119.3, -4.0%포인트를 차례로 합쳐 약 -63.8%다.

이 숫자는 **특정 역사적 일별 경로의 분해**다. 경로가 바뀌면 -119.3%포인트라는 변동성 기여도도 바뀐다. 큰 변동 구간에서는 단순 2차 공식보다 정확한 일별 가치 곱과 선택한 분해 정의를 써야 한다. 두 방향이 모두 손실이었다는 사실만으로 기초주가 하락과 큰 왕복 변동 중 무엇의 기여가 큰지 알 수 없어서 이 분해가 필요하다.

질문: 인버스의 변동성 효과가 -100%포인트보다 작을 수 있나요? 분해 항은 서로 더하는 기여도이므로 한 항이 -100%포인트를 넘어도 다른 양의 항이 상쇄할 수 있습니다. 펀드의 최종 수익률 자체와 혼동하면 안 됩니다.

슬라이드 37 · 수익률만으로 위험을 평가할 수 없는 이유

레버리지는 평균 수익률뿐 아니라 손실의 폭과 보유기간별 결과의 분포를 키운다. 10년 누적수익률이 높아도 중간 손실을 견디지 못해 매도하면 그 성과를 얻지 못한다. 다음 절은 수익률 평균에서 무위험수익률을 뺀 **초과수익**을 변동성으로 나눈 샤프비율, 최악 낙폭, 장기 성장률을 구분한다.

위험 지표마다 답하는 질문이 다르다. 일간 샤프는 하루의 위험 한 단위당 보상을, 1년 보유 샤프는 시작일을 바꾸어 1년씩 투자했을 때의 분포를 요약한다. 최악 낙폭은 버텨야 할 중간 손실을, 로그 성장률은 여러 기간 복리 후의 전형적인 자산 증가 속도를 보여 준다.

슬라이드 38 · 같은 상품의 일간과 1년 샤프비율

샤프비율은 같은 기간의 **평균 초과수익률 ÷ 수익률 표준편차**다. 2016~2026년 자료에서 QQQ와 TQQQ의 누적 총수익률은 각각 +565%, +2,946%였다. 일간 수익률을 연율화한 샤프비율은 0.85와 0.82로 비슷하지만, 겹치는 252거래일 보유 수익률의 평균을 표준편차로 나눈 값은 0.99와 0.78이다. SPY·UPRO, SOXX·SOXL, KODEX 200·2배 상품에서도 그 표본의 1년 보유 기준은 레버리지 쪽이 낮았다.

일간 샤프를 연율화할 때는 하루 평균/표준편차에 독립 일별 수익률 가정의 $\sqrt{252}$를 곱한다. 1년 보유 샤프는 각 시작일에서 252일 보유한 **복리수익률**의 분포를 쓴다. 일별 표준편차의 연율화 값 66.8%와 1년 보유 수익률의 시작일별 표준편차 69.3%는 다른 분모다. 겹치는 1년 구간은 독립 관측치가 아니므로 추정오차에도 주의해야 한다. 한국 표의 별표는 미국 무위험수익률을 뺀 값이 아닌 원수익률 기준이다.

슬라이드 39 · 샤프비율의 분자와 분모

샤프비율의 분자는 위험자산의 기대수익률 $E[R]$에서 같은 통화·기간의 무위험수익률 r_f를 뺀 위험 보상이다. 분모 σ_R는 그 수익률의 표준편차로, 보상을 얻으면서 감수한 흔들림을 나타낸다. 따라서 $S = (E[R] - r_f)/\sigma_R$다. 연평균 수익률 21.6%, 같은 기간 단기국채 2.4%, 연율화 변동성 22.6%이면 샤프는 $(21.6 - 2.4)/22.6 \simeq 0.85$다. 분자와 분모는 같은 기간 단위로 계산해야 한다.

분모의 표준편차는 손실만이 아니라 예상보다 높은 수익도 위험으로 센다. 수익률 분포가 비대칭이거나 큰 손실 가능성이 있으면 샤프 하나로 충분하지 않다. 또한 과거 평균은 미래 기대수익률의 불확실한 추정치다. 샤프비율은 **동일 조건의 효율성 비교**에는 유용하지만, 투자자에게 필요한 절대수익이나 최악 낙폭을 대체하지 않는다.

슬라이드 40 · 하루에는 왜 샤프가 같나

기초자산 하루 수익률을 r, 같은 하루의 무위험수익률을 r_f라 하자. 자기자본 한 단위로 기초자산 L단위를 보유하고 초과분 $L-1$을 r_f로 조달한다면 레버리지 포트폴리오 수익률은 $r_L = Lr - (L-1)r_f$다. 양변에서 r_f를 빼면 $r_L - r_f = L(r - r_f)$다. 따라서 $L > 0$인 경우 초과수익률의 평균은 L배, 표준편차도 L배다.

$$S_L = \frac{LE[r - r_f]}{L\,\mathsf{sd}(r - r_f)} = S_1 \qquad (L > 0).$$

이 등식은 **한 기간, 동일한 무위험금리, 비용·추적오차 없음**을 가정한다. $L < 0$이면 표준편차는 $|L|$배여서 $S_L = \mathsf{sgn}(L)S_1$이다. 예컨대 기초자산의 초과수익률이 평균적으로 양수라면 비용 없는 -2배 포지션의 하루 샤프는 기초자산과 크기가 같고 부호는 반대다. 실제 상품은 조달 비용과 괴리 때문에 이 값에서 벗어난다.

슬라이드 41 · 보유기간을 늘리면 분포가 바뀐다

한 날의 초과수익률을 정확히 세 배 하는 것과 252일 동안 매일 세 배를 목표로 투자하는 것은 다르다. 후자의 총수익률은 $G_T - 1 = \prod_{t=1}^{T}(1 + r_{L,t}) - 1$로, 날마다 이전 성과가 다음 날의 투자금이 된다. 따라서 평균과 표준편차가 단순히 일간 값의 T배나 $\sqrt{T}$배로만 커지지 않는다.

독립적인 일별 수익률을 가정한 시뮬레이션에서는 배수가 커질수록 1년 보유 샤프가 낮아진다. 복리로 계산한 보유 성과의 표준편차가 평균에 비해 빠르게 확대된 결과다. 추세의 지속성, 평균 수익률, 비용, 재조정 주기가 달라지면 보유기간 샤프의 순서도 바뀔 수 있다.

슬라이드 42 · T일 복리수익률의 평균과 분산 유도

하루 수익률을 더하지 않고 총수익 배율을 곱해야 하므로 $X_t = 1 + r_{L,t}$, $G_T = \prod_{t=1}^{T} X_t$라 두자. 일별 지수 수익률이 서로 독립이고 평균 μ, 분산 σ^2이면 비용 없는 하루 펀드 수익률의 평균은 $m_L = r_f + L(\mu - r_f)$, 분산은 $L^2\sigma^2$다. 분산의 정의 $\mathrm{Var}(X) = E[X^2] - E[X]^2$를 옮겨 쓰면 $E[X_t^2] = (1 + m_L)^2 + L^2\sigma^2$다. 독립성 때문에 $E[\prod_t X_t] = \prod_t E[X_t]$이고, 제곱한 배율에도 같은 성질을 적용한다.

$$
\begin{aligned}
E[G_T] &= (1 + m_L)^T, \\
\mathrm{Var}(G_T) &= \left[(1 + m_L)^2 + L^2\sigma^2\right]^T \\
&\quad - (1 + m_L)^{2T}.
\end{aligned}
$$

분산은 $E[G_T^2] - E[G_T]^2$이므로 두 항의 차이가 위 식이다. 변동성이 커지면 평균은 그대로여도 두 번째 모멘트와 분산은 커진다. 독립·동분포 가정하의 **정확한 모멘트 식**이며, 실제 수익률의 자기상관이나 변동성 변화가 있으면 그대로 적용할 수 없다.

슬라이드 43 · 샤프가 투자 선택의 전부인가

샤프비율로 자산을 고른 뒤 차입으로 목표 수익률을 맞추는 선택은, 누구나 무위험금리로 필요한 만큼 빌릴 수 있을 때 성립한다. 차입금리와 한도, 담보 유지 조건이 달라지면 같은 위험 수준에 도달하는 비용도 자산마다 달라진다. 다음 두 슬라이드는 이 제약을 자본시장선에 표시한다.

슬라이드 44 · 자본시장선 CML의 기울기

무위험자산과 위험 포트폴리오 A를 섞을 때 A의 비중을 w라 하면 기대수익률은 $r_f + w(E[R_A] - r_f)$, 표준편차는 $w\sigma_A$다($w \geq 0$). 따라서 위험을 가로축, 기대수익률을 세로축에 놓은 직선의 기울기는 $(E[R_A] - r_f)/\sigma_A$, 바로 샤프비율이다. $w > 1$은 무위험금리로 차입해 A를 더 사는 구간이다.

예시에서 채권 포트폴리오 A의 기대수익률 7%, 변동성 6%, 무위험금리 2.4%면 샤프는 약 0.77이다. A를 두 배 보유하면 위험 12%, 기대수익률 $2(7) - 1(2.4) = 11.6\%$다. 주식 B의 샤프가 더 낮다면 동일 위험에서 A의 CML이 위에 놓인다. 이 직선이 무한히 연장되는 그림에는 **무한 차입 가능**이라는 강한 가정이 들어 있다.

슬라이드 45 · 현실의 차입금리가 선을 꺾는다

자기자본보다 많이 사려면 차입금리 r_b를 내야 한다. $w > 1$ 구간의 기대수익률은 $wE[R_A] - (w-1)r_b$이고, 추가 위험 한 단위당 기대 보상은 $(E[R_A] - r_b)/\sigma_A$로 낮아진다. 차입 한도까지 있으면 더 오른쪽으로 갈 수 없다. 보증금률 50%라면 단순한 전액 담보 모형에서 자기자본의 최대 2배 보유가 예시가 된다.

차입금리 때문에 **무차입 샤프가 가장 높은 자산**이 모든 목표 위험에서 최선은 아닐 수 있다. 같은 무위험금리 2%에서 A의 기대수익률·변동성이 8%·8%, B가 11%·15%라면 A의 샤프 $6/8 = 0.75$가 B의 $9/15 = 0.60$보다 높다. 그러나 위험 15%를 원해 A를 $15/8 = 1.875$배 보유하고 추가분을 7%에 빌리면 기대수익률은 $1.875(8\%) - 0.875(7\%) \approx 8.88\%$다. B를 그냥 보유하면 위험 15%에서 기대수익률 11%다. 차입선의 기울기가 낮아지면 목표 위험에 따라 유리한 자산이 바뀐다.

자료에 제시된 미국 단기국채 평균 2.4%와 2026년 5월 국내 신용융자 금리 9%대는 **통화와 관측기간이 서로 다르다**. 이를 동일 시장의 단일 무위험금리와 신용금리로 직접 빼면 부정확하다. 뒤의 +6.6%포인트는 차입 가산비용을 보여 주는 예시 입력값으로 읽는다. 실제 비교에서는 같은 통화·기간의 조달금리, 세금과 한도를 맞춰야 한다.

슬라이드 46 · 자산군 샤프비율의 표본 의존성

제시된 2016~2026년 표본에서는 QQQ·SPY의 샤프가 채권 ETF보다 높다. 그러나 2022년 금리 급등은 채권 가격에 큰 손실을 줬고, 더 긴 역사적 표본에서는 저베타 자산의 위험조정 성과가 다르게 나타날 수 있다. **표본기간이 다른 샤프비율**을 하나의 영구적 자산 순위로 읽으면 안 된다. 미국 채권·주식과 한국 ETF의 원수익률 기준도 동일하게 비교할 수 없다.

샤프는 과거 수익률의 평균과 표준편차를 추정한 결과라 극단적인 한 해에 민감하다. 또 낮은 변동성의 자산은 작은 초과수익 추정 오차에도 비율이 크게 변한다. 투자 전에는 어느 무위험금리를 뺐고, 총수익률에 배당·분배금이 포함됐는지, 기간이 얼마나 긴지를 확인한다.

슬라이드 47 · 내재 레버리지 상품과 개인 차입의 비교

QQQ를 자기자본 한 단위당 세 단위 보유하려면 두 단위를 빌려야 한다. 연간 차입 가산금리가 6.6%포인트라면 자기자본 대비 추가 비용은 $2 \times 6.6 = 13.2\%$포인트다. 그래서 같은 3배 노출이라도 직접 신용융자의 기대수익률 선은 이론적 무위험금리 차입선보다 낮아진다. 상품 안에서 조달하는 TQQQ가 그 개인 차입선 위에 놓일 수 있다는 것이 그림의 논리다.

TQQQ의 NAV에는 보수와 내부 금융비용이 반영된다. 그래프의 2016~2026년 실현 연평균은 당시 상승 경로를 포함한 **사후 숫자**다. 직접 차입과 상품 내부 차입을 비교하려면 같은 기초자산과 보유기간을 놓고 금리, 보수, 세금, 거래비용, 담보위험을 원화 손익으로 환산해야 한다.

슬라이드 48 · 투자자 계좌에서 사라지는 마진콜

개인이 빌려서 기초자산 세 배를 **고정 노출**로 보유하면 자산 가치가 3분의 1 하락할 때 자기자본이 소진된다. 대출자는 그 전에 증거금을 요구하거나 반대매매할 수 있다. 이미 돈을 모두 내고 산 레버리지 ETF 지분은 투자자 계좌에 별도의 신용융자가 없으므로 그 지분 보유만으로 개인에게 마진콜이 오지는 않는다. 인버스 ETF도 직접 공매도의 주식 차입·상환 요구를 투자자 계좌 밖으로 옮긴다.

대신 손실은 ETF 지분의 NAV 하락에 집중된다. 펀드 내부의 레버리지와 조달 비용이 반영되므로 2022년처럼 Nasdaq-100이 크게 하락할 때 TQQQ의 낙폭은 더 컸다. 이후 회복까지 자금을 묶어 둘 수 있는지와 중간 생활비 지출 가능성을 함께 계산해야 한다.

슬라이드 49 · 3배 노출의 두 가격표

같은 자기자본 100으로 첫날 QQQ를 300 보유하고 200을 빌리는 전략과, 일일 +3배 ETF 100을 사는 전략을 비교하자. 비용이 없고 QQQ가 첫날 +10%, 둘째 날 -10%라면 직접 차입의 마지막 자산은 $300(1.1)(0.9) = 297$, 부채는 200이므로 자기자본은 97이다. ETF의 가치는 $100(1.3)(0.7) = 91$이다. 시작 노출은 같지만 첫날 뒤 직접 차입의 노출배수는 $330/130 \approx 2.54$로 내려가고, ETF는 다음 날 목표를 위해 다시 3배로 맞춘다.

97과 91의 차이는 이 예에서 **재설정 규칙의 경로 효과**다. 직접 차입이자는 부채 200에, ETF 내부 금융비용과 보수는 NAV에 반영된다. 투자자의 실제 ETF 수익률에는 매수·매도 시점의 프리미엄과 스프레드도 들어간다. 같은 기간의 일별 가격 경로를 먼저 맞추고 비용을 각각 차감해야 두 전략의 순성과를 비교할 수 있다. 상품의 현행 비용은 운용사 공시[34]에서 확인한다.

슬라이드 50 · 차입 제약과 betting against beta

차입이 막힌 투자자가 높은 기대수익을 원하면 자기자본만으로 살 수 있는 고베타 자산을 선택할 수 있다. 이런 수요가 고베타 자산 가격을 올리면 향후 기대수익률이 상대적으로 낮아져 증권시장선이 평평해질 수 있다는 것이 betting against beta 이론[35]의 직관이다. 실제 가격에는 다른 기대와 제약도 작용하므로 이 메커니즘의 크기는 자료로 추정해야 한다.

내재 레버리지 ETF는 개인 차입 제약을 일부 우회한다. 원하는 노출을 얻는 이점과 1년 보유 샤프의 하락, 손실 한도를 함께 놓고 선택한다. **최적 포트폴리오는 투자자의 제약과 효용**에 달려 있다.

슬라이드 51 · 강한 추세가 TQQQ에 유리했던 기간

2016~2026년 Nasdaq-100은 높은 초과수익률과 상대적으로 낮은 변동성을 동시에 보였다. 그러면 매일 3배를 유지하는 전략에서 상승 추세의 복리 이익이 변동성 손실과 비용을 넘을 수 있다. TQQQ의 매우 높은 10년 누적수익률은 그 **실현 경로의 산물**로 읽어야 한다. 같은 차트에는 2021~2022년 고점 대비 큰 손실도 함께 보인다.

로그 축의 누적수익률 차트는 몇 배로 커졌는지 비교하는 데 유용하지만, 숫자 위쪽의 선만 보면 중간 낙폭을 놓치기 쉽다. 투자자의 실제 결과는 시작·종료 시점과 중간 현금흐름에도 달려 있다. 강한 과거 추세를 미래의 μ로 곧바로 대입하면 최적 레버리지를 과대평가할 위험이 있다.

슬라이드 52 · 로그 성장률에서 변동성이 제곱으로 작용한다

장기 자산은 날마다 곱해지지만 로그를 취하면 $\log(A_T/A_0) = \sum_t \log(1 + r_{L,t})$처럼 날별 성장률을 더할 수 있다. 작은 일간 수익률에는 $\log(1+x) \simeq x - x^2/2$가 성립한다. 첫 항은 평균 수익, 음의 제곱항은 상승과 하락이 반복될 때의 복리 손실을 나타낸다. 일간 초과수익의 연간화 평균을 μ, 연율화 변동성을 σ라 하고 비용·무위험금리의 공통 부분과 작은 일간 평균의 제곱을 생략하면, $E[x^2] = \mathrm{Var}(x) + (E[x])^2$에 의해 L배 전략의 연간 기대 **초과 로그성장률**은 $g_L \simeq L\mu - \frac{1}{2}L^2\sigma^2$다.

$$g_L \simeq L\left(\mu - \frac{\sigma^2}{2}\right) - \frac{L(L-1)}{2}\sigma^2.$$

[34] https://www.proshares.com/resources/geared-faqs

[35] https://www.aqr.com/Insights/Research/Journal-Article/Betting-Against-Beta

첫 괄호는 기초자산 로그성장률의 L배, 둘째는 일일 재설정의 추가 변동성 부담으로 읽을 수 있다. $\mu = 19.2\%$, $\sigma = 22.6\%$를 대입하면 $g_1 \simeq 16.6\%$, $g_2 \simeq 28.2\%$, $g_3 \simeq 34.6\%$다. 이 값은 실현 ETF 수익률이 아니라 **추정 입력값으로 만든 근사 계산**이며 차입가산비용을 제외한다.

슬라이드 53 · 성장률을 최대로 하는 배수

$g_L = L\mu - \frac{1}{2}L^2\sigma^2$를 L로 미분하면 $g_L' = \mu - L\sigma^2$이고, 이계도함수는 $-\sigma^2 < 0$이다. 따라서 비용과 투자한도를 무시한 연속 배수의 내부 최적점은 $L^* = \mu/\sigma^2$다. 이것은 **로그성장률 최대화**의 해이며 샤프비율 최대화나 모든 투자자의 최적 배수와 같지 않다. μ는 무위험금리 초과 수익률로 정의해야 한다.

$\mu = 0.192$, $\sigma = 0.226$이면 $\sigma^2 \simeq 0.0511$이므로 $L^* \simeq 3.76$이다. 같은 추세에서 변동성이 40%로 커지면 $L^* = 0.192/0.16 = 1.2$이고, 3배 성장률은 $3(0.192) - \frac{1}{2}(9)(0.16) = -0.144$, 즉 약 -14.4%다. 기초자산의 기대 초과수익률이 실제로 19.2%라는 확신은 없으므로 수치를 투자 권고로 읽으면 안 된다.

슬라이드 54 · QQQ, 이상적 3배, 실제 TQQQ

동일한 역사적 일간 경로에 비용 없는 이상적 3배를 적용한 누적수익률과 실제 TQQQ의 기록을 구분하자. 제시된 2016~2026년 누적 총수익률은 QQQ +565%, 이상적 3배 +3,773%, TQQQ +2,946%다. 이상적 3배의 일간 샤프는 QQQ와 같은 0.85지만 실제 TQQQ는 0.82였다. 1년 보유 샤프는 각각 0.99, 0.82, 0.78로 나타났다.

이상적 3배와 실제 상품의 차이에는 보수·내부 금융비용·추적오차와 사용한 데이터 기준이 들어간다. 이상적 3배의 1년 샤프가 이미 낮아진다는 점은 비용이 없어도 복리 경로의 분포가 바뀐다는 뜻이다. 반면 실제 TQQQ의 높은 누적수익률은 그 기간의 큰 상승 추세가 추가 위험을 보상했음을 보여 줄 뿐, 미래에도 같은 비율로 오를 것이라는 증거는 아니다.

슬라이드 55 · 펀드의 매매와 시장가격의 인과관계

목표 배수를 유지하는 데 필요한 명목 노출액과 기초주식에 도달한 주문액 사이에는 선물·스왑·상대방 헤지가 있다. 현물 주문액이 같아도 종가 주문장의 반대편 물량이 두터우면 가격 반응이 작고, 얕으면 클 수 있다. 따라서 가격 효과의 단위는 주문액 자체가 아니라 **그 주문이 없었을 때의 종가와 관측 종가의 차이**다.

먼저 주가가 움직여 재설정 주문이 생기는 **역인과** 때문에 하락일의 매도 주문과 가격 하락은 함께 관찰된다. 예상 조정 수요가 다른 날·종목·시간대를 비교하고 공통 뉴스를 통제해야 주문의 추가 효과를 추정할 수 있다.

슬라이드 56 · 변동성 증폭 가설의 정확한 내용

레버리지 배수 $L > 1$ 또는 $L < 0$이면 $L(L-1) > 0$다. 그래서 지수 수익률 $r > 0$일 때 조정 노출은 매수 방향, $r < 0$일 때 매도 방향이다. 거래가 종가에 집중되고 반대편 유동성이 부족하면 상승을 더 밀고 하락을 더 누를 수 있다. 거래 규모는 A와 $|r|$에 비례하므로 큰 변동일수록 이 가설이 중요해진다.

공개된 자산규모와 당일 수익률로 조정 수요를 예측한 투자자는 미리 반대 주문을 공급하거나 먼저 거래할 수 있다. LP도 재고로 일부를 흡수한다. 미 연준의 연구[36]는 2011년 미국에서 시장

[36] https://www.federalreserve.gov/pubs/feds/2013/201348/index.html

이 1% 움직일 때 약 10억 달러의 조정 수요를 추정했다. 이 수요가 당시와 다른 국내 종가 시장에서 얼마의 가격 효과를 내는지는 별도 자료가 필요하다.

슬라이드 57 · 종가 거래량을 원화로 계산하기

2026년 6월 19일 SK하이닉스 관련 +2배 상품의 전일 순자산을 8.7조 원, 당일 기초주가 상승률을 2.9%라 하면, 순설정을 제외한 단순 노출 조정은 $2(2-1)\times 8.7$조 $\times\, 0.029 = 0.5046$조원, 약 5,000억 원이다. 이는 **상품 전체의 목표 노출 조정**이다. 자본시장연구원 분석[37]은 이 중 현물 주식에 도달한 규모를 별도로 추정한다.

현물 추정 2,600억 원은 목표 노출 조정액 약 5,000억 원의 약 52%다. 나머지 차이에는 선물·스왑과 헤지 경로가 들어갈 수 있다. 가격 충격을 보려면 2,600억 원도 **종가 단일가 구간의 반대 주문량과 비교**해야 한다. 2026년 7월 말까지 조정이 15:20~15:30에 집중되었다는 시간 구조가 일 거래대금 전체보다 적절한 비교 기준을 준다.

슬라이드 58 · 상쇄 흐름과 예측된 주문

하락일 +2배 펀드에서는 $2Ar < 0$이다. 이때 개인 매수가 실제 순설정 $F > 0$으로 이어지면 $2F > 0$이 매도 필요량을 줄인다. 예를 들어 $A = 100$, $r = -10\%$면 기본 조정은 -20이고 순설정 $F = 10$이면 합계 0이다. 개인 매수 체결량만으로 F를 알 수 없으므로 발행 지분 변화를 확인해야 한다.

Kyle의 시장 미시구조 모형[38]에서는 주문에 사적 정보가 담길 수 있어 가격이 반응한다. ETF 재설정은 기계적으로 예측할 수 있는 부분이 크지만, 이를 받아 줄 시장조성자는 재고를 보유하거나 헤지해야 한다. 예상 주문량이 종가 유동성보다 크면 **정보 효과가 작아도 일시적인 가격 압력**이 생길 수 있다.

슬라이드 59 · 역인과와 공통 충격

운용사는 관심과 거래량이 클 것으로 예상되는 종목에 상품을 내놓는다. 이미 변동성이 커지는 종목이 상장 대상으로 선택되었다면 상장 뒤의 높은 변동성에는 **선택 편의**가 섞인다. 동시에 해외 반도체주도 흔들렸다면 산업 공통 충격도 작동했을 수 있다. 두 요인을 빼고 남는 국내 종목의 변화가 ETF 효과의 후보가 된다.

예를 들어 상장 기초종목의 마지막 30분 변동성 비중 변화에서 유사한 비상장 종목의 같은 변화를 빼는 차이의 차이 분석을 생각할 수 있다. 비교군은 상장 전 추세가 비슷하고 산업 뉴스에는 비슷하게 반응해야 한다. 해외 종목을 쓰면 환율·거래시간·기업별 뉴스 차이를 추가로 통제한다. 종가에만 차이가 집중되는지도 메커니즘 검증에 유용하다.

슬라이드 60 · 마지막 30분 분산 비중의 의미와 한계

5분 수익률 r_j로 마지막 30분의 비중 $s = \sum_{j\in\text{close}} r_j^2 / \sum_{j\in\text{day}} r_j^2$를 만든다. 상장 뒤 기초종목의 s가 비교군보다 더 커지면 **변동이 종가 쪽으로 이동했다**는 증거가 된다. 수익률을 제곱하므로 큰 가격 움직임에 가중치가 크다. 단일가 체결과 얇은 호가가 만드는 미시구조 잡음도 이 지표에 섞일 수 있다.

[37] https://www.kcmi.re.kr/publications/pub_detail_view?cno=6801&syear=2026&zcd=002001016&zno=1922
[38] https://www.jstor.org/stable/1913210

도표에서 기초종목은 2.10%에서 3.08%로 0.98%포인트, 다른 KOSPI 200 종목은 1.48%에서 1.69%로 0.21%포인트 올랐다. 차이의 차이는 $0.98 - 0.21 = 0.77$%포인트다. 상장 전 14일, 상장 후 45일의 표본과 표준오차가 없어 통계적 유의성은 아직 판단할 수 없다. 분자·분모의 절대 수준과 거래대금도 함께 보고, 예상 조정액이 종가 유동성에 비해 큰 날에 효과가 집중되는지 검증해야 한다.

슬라이드 61 · 더 읽을 자료와 검증의 순서

SEC의 ETF 구조 안내[39]는 개인 거래와 AP 설정·환매의 차이를, SEC의 레버리지 ETF 안내[40]는 일일 목표와 장기 보유의 차이를 정리한다. 국내 제도는 한국거래소 LP 설명[41]과 금융위원회의 투자자 안내[42]에서 확인할 수 있다. 2026년 국내 사례의 관측치는 자본시장연구원 분석[43]을 참고한다.

조정 수요를 가격 효과와 연결하려면 상품별 순자산·일간 수익률로 계산한 목표 노출, 설정·환매액, 현물·파생상품 체결액, 종가 주문장 유동성을 같은 날짜와 시간대로 맞춰야 한다. 해외 연구와 국내 사례를 비교할 때도 상품 구성과 헤지 방식의 차이를 반영한다.

Session 4B · 수익률 예측의 도구

기업 특성으로 다음 달 수익률을 예측하는 함수가 어떤 모양을 가질 수 있는지 살핀다. 선형 모형의 계수 축소, PCA의 입력 압축, 나무의 조건부 분할, 신경망의 비선형 결합을 하나의 기준으로 비교한다. 각 방법은 적합 기간과 그보다 뒤의 검증 기간을 나누어 복잡도를 정한다.

슬라이드 01 · 수익률 예측 방법의 지도

종목마다 규모·가치·모멘텀 등 수백 가지 특성이 있다. 공개 정보가 가격에 반영되고 새로운 뉴스가 수익률을 흔들기 때문에 남는 예측 신호는 약하다. 이 장은 그 신호를 안정적으로 추리는 선형 모형, 주성분 회귀, 나무 앙상블, 신경망을 연결한다.

방법이 복잡해질수록 만들 수 있는 예측 함수의 범위가 넓어진다. 그 대가로 우연한 과거 패턴까지 학습하기 쉽다. 따라서 방법의 이름보다 **어떤 관계를 표현할 수 있는지**와 **미래 기간에서 그 관계가 유지되는지**가 중요하다.

슬라이드 02 · 네 방법의 역할

선형 모형은 각 특성의 효과를 더하고, elastic net은 불필요한 계수를 줄인다. 주성분 회귀는 비슷하게 움직이는 특성들을 소수의 공통 성분으로 압축한다. 나무는 특성값에 따라 종목을 나누어 조건부 효과를 찾는다. 신경망은 여러 특성을 함께 섞은 뒤 활성화 함수를 거쳐 굽은 예측 함수를 만든다.

[39] https:// www.investor.gov/ introduction- investing/ general- resources/ news- alerts/ alerts-bulletins/investor-bulletins-24

[40] https:// www.investor.gov/ introduction- investing/ general- resources/ news- alerts/ alerts-bulletins/investor-alerts/sec

[41] https://regulation.krx.co.kr/contents/RGL/03/03060103/RGL03060103.jsp

[42] https://fsc.go.kr/po010102/86910

[43] https://www.kcmi.re.kr/publications/pub_detail_view?cno=6801&syear=2026&zcd=002001016&zno=1922

예컨대 소형주에서만 모멘텀이 강하다면 규모와 모멘텀의 **상호작용**을 표현해야 한다. 선형 회귀에는 곱셈 항을 명시적으로 넣을 수 있고, 나무와 신경망은 분할이나 은닉 단위를 통해 이런 관계를 자료에서 찾는다.

슬라이드 03 · 모든 방법에 던질 세 질문

첫째, 예측 함수가 그릴 수 있는 모양은 무엇인가. 직선은 일정한 기울기, 나무는 계단, ReLU 신경망은 여러 꺾은선을 결합한 모양이다. 둘째, 함수의 복잡도를 무엇이 제한하는가. 벌점, 주성분 수, 나무 깊이, 신경망의 층 수가 대표적인 **초매개변수**다.

셋째, 초매개변수를 어떤 자료로 고르는가. 과거 자료로 모형을 적합하고 그 뒤의 검증 기간에서 예측오차를 비교한다. 단순한 모형은 조건부 수익률 차이를 놓치고, 유연한 모형은 과거 잡음에도 반응한다. **이후 기간의 성과**로 두 위험을 조절한다.

슬라이드 04 · 선형 방법의 출발점

선형 예측은 특성벡터 $z_i = (z_{i1}, \dots, z_{iP})$에 대해 $\hat{r}_i = a + \sum_{j=1}^{P} b_j z_{ij}$처럼 쓴다. 계수 b_j는 다른 특성을 고정했을 때 특성 j가 한 단위 바뀌는 데 따른 예측 수익률의 변화다. 수백 개 계수를 추정하면 그중 약한 신호의 추정오차가 예측에 함께 들어간다.

앞서 배운 Ridge는 계수를 부드럽게 줄이고 Lasso는 일부를 정확히 0으로 만든다. 이제 **특성들의 결합을 어떤 형태로 표현할지** 살핀다.

슬라이드 05 · 선형 모형이 보는 효과

덧셈형 선형 모형 $\hat{r} = a + b\,\text{mom} + c\,\text{size}$에서는 모멘텀의 기울기 b가 모든 규모에서 같다. 소형주에서 모멘텀이 더 강한지를 보려면 $d(\text{mom} \times \text{size})$를 추가한다. 그러면 모멘텀의 한계효과는 $b + d\,\text{size}$가 된다.

특성 100개에서 가능한 두 변수 조합만 $100 \cdot 99/2 = 4{,}950$개다. 모든 곱을 넣으면 추정할 계수가 빠르게 늘어난다. 경제학적 근거가 있는 몇 개의 상호작용을 직접 설계할 수 있지만, 어느 조합이 중요한지 넓게 탐색할 때는 나무와 신경망의 표현력이 유용하다. Elastic net의 벌점은 계수를 줄이지만 입력에 없는 곱셈 항을 스스로 만들어 내지는 않는다.

슬라이드 06 · 극단 수익률과 Huber 손실

제곱오차는 오차 e가 두 배면 손실이 네 배가 된다. 드문 급등·급락 종목 몇 개가 계수 추정을 지배할 수 있다. Huber 손실은 작은 오차에는 제곱, 절댓값이 임계값 ξ를 넘는 오차에는 선형 비용을 적용한다.

$$H(e;\xi) = \begin{cases} e^2, & |e| \le \xi, \\ 2\xi|e| - \xi^2, & |e| > \xi. \end{cases}$$

두 구간은 $|e| = \xi$에서 값과 기울기가 이어진다. 바깥 구간의 기울기는 크기가 2ξ로 제한되어 큰 오차 한 건의 영향이 계속 커지지 않는다. Gu·Kelly·Xiu[44]는 여러 모형에 Huber 손실을 적용했다. 이는 극단 관측치의 영향을 줄이는 장치이며, 변수가 많을 때 생기는 추정오차에는 별도의 정규화가 필요하다.

[44] https://doi.org/10.1093/rfs/hhaa009

슬라이드 07 · 입력을 압축하는 이유

비슷한 모멘텀 지표 여러 개가 함께 움직이면 개별 계수는 불안정해도 공통 방향은 비교적 안정적으로 측정할 수 있다. PCA는 특성을 버리는 대신, 특성들의 **가중합**으로 좌표축을 새로 만든다. 가장 크게 변하는 방향부터 순서대로 성분을 얻는다.

Ridge와 Lasso는 원래 특성의 계수를 조정한다. PCA는 먼저 특성 공간 자체를 회전한 뒤 일부 축만 사용한다. 어떤 축이 수익률을 잘 예측하는지는 PCA 단계의 기준에 들어 있지 않다는 점이 뒤 예시의 핵심이다.

슬라이드 08 · 긴 축과 짧은 축

두 특성을 가로·세로축에 놓고 종목을 점으로 그리면, 함께 오르는 두 지표는 대각선 방향으로 길게 퍼진다. 제1 주성분은 그 긴 축 위의 위치다. 각 종목의 두 수치를 하나의 숫자로 줄여도 관측치 사이의 큰 차이를 보존한다.

짧은 축의 제2 주성분은 두 지표가 서로 얼마나 다른지 나타낸다. 두 성분은 직각을 이루고 PCA가 만든 성분끼리는 표본에서 무상관이다. 분산이 작은 축을 버리면 압축은 잘되지만, 작은 차이가 수익률을 예측하는 경우에는 중요한 신호를 잃을 수 있다.

슬라이드 09 · 모멘텀 두 지표의 숫자 예시

12개월 모멘텀 z_1과 6개월 모멘텀 z_2가 각각 분산 2, 상관 0.8이면 공분산은 $0.8\sqrt{2\cdot 2} = 1.6$이다. 합과 차이의 분산은 각각 $\mathrm{Var}(z_1+z_2) = 2+2+2(1.6) = 7.2$, $\mathrm{Var}(z_1-z_2) = 2+2-2(1.6) = 0.8$이다.

가중치 길이를 1로 맞춘 두 성분은 $(z_1+z_2)/\sqrt{2}$와 $(z_1-z_2)/\sqrt{2}$이고 분산은 3.6과 0.4다. 전체 4 가운데 첫 성분이 $3.6/4 = 90\%$를 담는다. 따라서 첫 성분만 남기면 **특성의 분산**은 대부분 보존한다. 이 비율만으로 미래 수익률의 예측력을 평가할 수는 없다.

슬라이드 10 · 분산이 큰 성분이 예측도 잘할까

앞 슬라이드의 다섯 종목에서 합은 $3, 3, 0, -3, -3$이고 차이는 $1, -1, 0, 1, -1$이다. 다음 달 수익률을 각각 $+1\%, -1\%, 0, +1\%, -1\%$로 놓으면 수익률은 차이에 정확히 비례한다. 반면 합과 수익률의 표본공분산은 0이다.

PCA가 90%의 입력 분산을 보존하려고 합만 남기면 수익률 예측은 모든 종목에서 0이 된다. 분산 10%짜리 차이를 남기면 이 가상 예시에서는 수익률을 정확히 맞힌다. **입력에서 흔한 변화**와 **예측대상에 중요한 변화**는 서로 다른 기준이다.

슬라이드 11 · 주성분의 가중치와 직교

특성벡터 z의 한 성분을 $w^\top z$로 정의한다. w의 길이 $\|w\|^2 = \sum_j w_j^2 = 1$로 제한해야 가중치를 임의로 크게 키워 분산을 무한히 늘리는 문제가 없다. 제1 성분은 이 제약 아래 $\mathrm{Var}(w^\top z)$를 최대화한다.

제2 성분의 가중치는 제1 성분 가중치와 직교하는 방향에서 고른다. 두 특성 예시의 가중치 $(1,1)/\sqrt{2}$와 $(1,-1)/\sqrt{2}$는 내적이 0이다. **PCA의 고유벡터로 선택한 경우**에는 서로 다른 성분의 공분산도 0이다. 임의의 직교 가중치만으로는 원자료의 공분산이 0이라고 보장되지 않는다.

슬라이드 12 · 주성분 회귀의 절차

주성분 회귀(PCR)는 훈련자료의 특성에서 주성분을 구하고, 앞의 k개 성분만으로 수익률을 회귀한다. k가 작으면 변동이 작은 방향의 계수 추정 잡음을 버리고, 너무 작으면 예측 신호도 잃는다. **주성분 수 k는 훈련 뒤의 검증 기간**에서 결정한다.

검증자료에 주성분 점수를 만들 때에는 훈련자료에서 구한 중심·척도·가중치를 그대로 적용한다. 검증 기간까지 포함해 PCA 축을 다시 구하면 미래의 입력 분포가 과거 모형 선택에 들어간다. 모든 성분을 남기고 행렬이 완전한 계수를 가지면 좌표만 바꾼 OLS와 같은 적합값을 얻는다.

슬라이드 13 · PCA를 공분산행렬로 쓰기

중심을 맞춘 특성벡터의 공분산행렬을 $\Sigma = \mathrm{Var}(z)$라 하면, 가중합의 분산은 $\mathrm{Var}(w^\top z) = w^\top \Sigma w$다. 길이 1인 가중치 중 이 값을 가장 크게 만드는 w_1은 $\Sigma w_1 = \lambda_1 w_1$을 만족한다. 이때 $\lambda_1 = w_1^\top \Sigma w_1$은 첫 성분의 분산이다.

나머지 고유벡터는 앞의 성분과 직교하면서 각각 다음으로 큰 분산을 담는다. 고유값들의 합은 $\mathrm{tr}(\Sigma)$, 즉 원래 특성별 분산의 합이다. λ_1**이 크다**는 말은 입력이 그 방향으로 많이 움직인다는 뜻이다.

슬라이드 14 · 특성 PCA와 수익률 PCA

무엇을 행렬의 열에 넣는지에 따라 PCA의 경제적 의미가 달라진다. 이 장에서는 종목·월을 행, 기업 특성을 열로 놓아 많은 특성을 소수의 예측 입력으로 압축한다. 이 경우 가중치는 특성에 붙고 성분 점수는 각 종목·월마다 하나씩 계산된다.

여러 종목의 수익률을 열로 놓는 PCA에서는 가중치가 **종목에 붙어 포트폴리오**를 만든다. 그 성분은 시간에 따른 포트폴리오 수익률이므로 잠재 요인을 추출하는 용도로 쓰인다. 둘 다 고유벡터 계산이지만 하나는 예측 입력의 압축, 다른 하나는 공통 수익률 움직임의 추출이다.

슬라이드 15 · 제1 주성분을 유도하기

$w^\top \Sigma w$를 $w^\top w = 1$ 아래 최대화한다. 라그랑주 함수를 $\mathcal{L} = w^\top \Sigma w - \lambda(w^\top w - 1)$로 두고 w로 미분하면 $2\Sigma w - 2\lambda w = 0$, 따라서 $\Sigma w = \lambda w$다. 이 식의 양변에 $w^\top$를 곱하면 최대화한 분산이 $w^\top \Sigma w = \lambda$다.

대칭 공분산행렬의 고유벡터 중 가장 큰 고유값에 대응하는 방향을 고르면 첫 성분이 된다. 다음 성분에는 앞 방향과 직교한다는 제약을 더한다. 주성분 수를 줄일 때 원자료의 제곱 복원오차가 최소가 되는 것도 같은 고유값 순서에서 나온다. 특성별 단위가 크게 다르면 큰 단위의 변수가 축을 지배하므로 중심화와 척도 조정이 선행되어야 한다.

슬라이드 16 · PCR, PLS, Ridge의 방향 선택

PCR은 특성의 분산만 보고 방향을 고른다. Partial Least Squares(PLS)는 수익률과 함께 움직이는 방향을 찾으므로 낮은 분산에 숨은 예측 신호를 살릴 수 있다. 예측대상을 사용해 방향을 고른 만큼, 성분 수와 방법 선택을 검증자료에서 평가해야 과적합을 제어할 수 있다.

Ridge는 특성의 모든 주성분 방향을 남기되, 고유값이 작은 방향의 계수를 더 강하게 줄인다. PCR은 앞의 k개 방향을 남기고 나머지를 버린다. 두 방법은 상관된 특성의 잡음을 다스리는 방식이 다르며, 어느 쪽이 더 좋은지는 예측대상과 검증 기간의 성과가 결정한다.

슬라이드 17 · 조건부 질문으로 넘어가기

선형 모형은 계수와 곱셈 항으로 예측 함수를 구성한다. 나무 모형은 먼저 종목을 특성값으로 나눈 뒤, 각 집단의 수익률을 따로 예측한다. "소형주인가?"에 대한 답에 따라 다음 질문을 바꾸므로 규모와 모멘텀의 상호작용을 자연스럽게 표현한다.

이 접근의 대가는 집단이 작아질수록 표본평균이 불안정해진다는 점이다. 한 그루의 깊은 나무, 여러 나무를 평균한 랜덤 포레스트, 앞선 나무의 오차를 순서대로 고치는 부스팅을 구분해 읽는다.

슬라이드 18 · 회귀 나무의 구조

나무의 한 분할은 "특성 z_j가 기준값 c보다 작은가?"라는 질문이다. 첫 질문은 root node, 이어지는 경로는 branch, 마지막 집단은 leaf다. 새 종목은 답을 따라 정확히 하나의 leaf에 도착하고, 회귀 나무의 예측치는 적합 기간에 그 leaf에 들어온 종목들의 **평균 다음 달 수익률**이다.

예시에서는 소형·고모멘텀 집단의 예측이 $+1.2\%$, 소형·저모멘텀 집단은 -0.6%다. 분할 기준과 leaf의 평균은 모두 과거 적합자료로 구한다. 다음 달 수익률을 미리 사용해 현재 종목의 경로를 정하면 예측 실험이 성립하지 않는다.

슬라이드 19 · 나무가 상호작용을 표현하는 방식

선형식 $r = a + b\,\text{mom} + c\,\text{size} + d(\text{mom} \times \text{size})$에서 모멘텀의 효과는 $b + d\,\text{size}$다. 곱셈 항이 있어야 규모에 따라 기울기가 바뀐다. 나무는 규모를 먼저 나누고 양쪽 가지에서 모멘텀 질문을 따로 던져 같은 구조를 집단별 평균으로 표현한다.

그림의 가상 수치에서 소형주의 고·저모멘텀 예측 차이는 $1.2 - (-0.6) = 1.8\%$포인트, 대형주는 $0.3 - 0.1 = 0.2\%$포인트다. 이 차이는 나무가 상호작용을 **표현한 예시**이며, 실제 투자 가능한 효과인지 판단하려면 독립된 뒤 기간에서 확인해야 한다.

슬라이드 20 · 나무 깊이와 과적합

나무가 깊어질수록 더 작은 leaf를 만들고 적합자료의 수익률을 세밀하게 따라간다. 그림의 가상 자료에서는 깊이 1의 적합·뒤 기간 오차가 각각 0.16·0.17, 깊이 3에서는 0.09·0.10이다. 관측치마다 leaf를 만들면 적합오차는 0이지만 뒤 기간 오차는 0.18로 올라간다.

너무 큰 leaf는 서로 다른 종목을 뭉쳐 편향을 만든다. 너무 작은 leaf는 소수 관측치의 우연한 수익률을 미래 평균으로 착각해 분산을 키운다. 나무 깊이와 leaf의 최소 표본 수는 미래에 가까운 검증 기간으로 정한다.

슬라이드 21 · 랜덤 포레스트의 두 무작위성

랜덤 포레스트[45]는 나무마다 적합 관측치를 복원추출하고, 분할할 때마다 후보 특성의 일부만 보게 한다. 서로 다른 자료와 질문으로 만든 나무들의 예측을 평균하면 한 나무의 불안정성이 줄어든다.

모든 나무가 항상 같은 가장 강한 특성으로 첫 분할을 하면 예측이 비슷해져 평균의 이점이 작아진다. 특성 후보의 무작위 제한은 나무 사이의 상관을 낮추려는 장치다. 깊이와 분할당 후보 특성 수는 검증으로 정하고, 나무 수는 평균이 안정될 만큼 늘린다.

슬라이드 22 · 복원추출이 만드는 다른 적합자료

가상 종목·월 A부터 E까지 다섯 개에서 한 나무의 적합자료를 다섯 번 **복원추출**한다. 나무 1이 A, C, C, D, E를 뽑았다면 C는 두 번 반영되고 B는 이번 나무의 적합자료에서 빠진다. 다음 나무는 다른 다섯 번의 추출을 수행한다.

복원추출은 새로운 기업을 만들어 내는 절차가 아니다. 동일한 과거 관측치의 포함 횟수를 바꾸어 나무의 분할이 얼마나 달라지는지 이용한다. 금융에서는 같은 달의 종목들이 공통 충격을 받으므로 검증을 설계할 때 종목·월 관측치를 독립적으로 무작위 분할하는 문제와 나무 학습 내부의 재표집을 구별해야 한다.

슬라이드 23 · 세 나무의 예측을 평균하기

새 종목 F가 소형·고모멘텀·가치주라면 그림의 세 나무에서 각각 1.5%, 2.0%, 1.0%가 나온다. 포레스트의 예측은 산술평균 $(1.5 + 2.0 + 1.0)/3 = 1.5\%$다. 각 나무의 leaf 평균은 **그 나무가 뽑은 자료**에서 계산했으며, 복원추출로 중복된 관측치는 중복 횟수만큼 반영된다.

다른 나무 하나가 우연히 큰 값을 내더라도 평균에서 그 영향은 줄어든다. 다만 모든 나무가 공통의 잘못된 관계를 배우면 평균만으로 편향을 제거할 수 없다.

슬라이드 24 · 부스팅은 남은 오차를 고친다

Gradient boosting[46]은 작은 나무를 순서대로 더한다. 첫 나무의 예측을 만든 뒤 각 관측치의 잔차 $u_i = r_i - \hat{r}_i$를 구하고, 다음 나무가 그 잔차의 패턴을 찾는다. 새 나무의 출력을 학습률 ν만큼 더해 예측을 갱신한다.

포레스트의 나무들은 서로 다른 적합자료에서 병렬로 자라 평균된다. 부스팅의 다음 나무는 **앞선 나무가 남긴 오차**에 의존한다. 깊이, 추가할 나무 수 B, 학습률 ν가 유연성을 정한다. 나무를 계속 더하면 적합오차가 줄어도 검증오차는 다시 커질 수 있다.

슬라이드 25 · 첫 나무가 줄인 제곱오차

가상 자료의 다섯 종목 수익률이 $3, -1, 1, 2, 1\%$이고 초기 예측이 모두 0이면 오차제곱합은 $9 + 1 + 1 + 4 + 1 = 16$이다. 첫 나무는 모멘텀이 높은 A·D·E의 평균 2%, 낮은 B·C의 평균 0을 낸다. 학습률 $\nu = 0.5$이므로 실제 예측에 더하는 값은 각각 1%와 0이다.

[45] https://doi.org/10.1023/A:1010933404324

[46] https://doi.org/10.1214/aos/1013203451

갱신 뒤 잔차는 A부터 E까지 $2, -1, 1, 1, 0$%이고 제곱합은 $4+1+1+1+0=7$이다. 학습률을 적용하면 한 나무의 가상 표본 적합을 절반만 반영한다. 단위는 모두 퍼센트포인트이며 제곱오차 16과 7은 그 단위의 제곱합이다.

슬라이드 26 · 두 번째 나무가 보는 목표

둘째 나무의 입력은 같은 종목 특성이지만, 맞혀야 할 값은 원래 수익률이 아니라 첫 나무 뒤에 남은 잔차 $2, -1, 1, 1, 0$%다. 가치주 A·C의 잔차 평균은 1.5%, 나머지 B·D·E의 평균은 0이다. 다시 학습률 0.5를 적용하므로 A·C의 예측에 0.75%포인트가 더해진다.

새 종목 F가 고모멘텀이면서 가치주면 첫 나무의 기여 $0.5(2.0) = 1.0$%와 둘째 나무의 기여 $0.5(1.5) = 0.75$%를 합쳐 1.75%를 예측한다. 훈련자료의 오차제곱합은 약 3.6으로 줄지만, 이후 자료에서도 개선되는지는 별도 검증이 필요하다.

슬라이드 27 · 부스팅의 반복식을 읽기

b번째 나무를 더하기 전의 예측 함수를 $\hat{g}_{b-1}(z)$라 하자. 각 관측치의 잔차 $u_i = r_i - \hat{g}_{b-1}(z_i)$를 구해 얕은 나무 $f_b(z)$를 적합하고 $\hat{g}_b(z) = \hat{g}_{b-1}(z) + \nu f_b(z)$로 갱신한다. ν는 한 번의 수정 폭, B는 총 수정 횟수다.

제곱오차 $(r-\hat{g})^2$를 예측값 $\hat{g}$로 미분하면 $-2(r-\hat{g})$이다. 따라서 잔차 방향으로 나무를 더하는 일은 손실을 줄이는 **음의 기울기 방향**으로 움직이는 것과 같다. Huber 손실을 쓰면 큰 잔차의 기울기를 제한한다. 부스팅이 편향을 줄이는 동안 뒤 기간 오차가 다시 상승하기 전의 B를 택한다.

슬라이드 28 · 나무를 평균하면 분산이 얼마나 줄까

나무 B그루의 예측오차가 각각 분산 σ^2이고 서로 다른 두 나무의 오차 상관이 ρ로 같다고 하자. 평균 예측의 분산은 자기 분산 항 $B\sigma^2/B^2$와 서로 다른 나무의 공분산 항 $B(B-1)\rho\sigma^2/B^2$를 더해 얻는다.

$$\mathrm{Var}\left(\frac{1}{B}\sum_{b=1}^{B}\hat{g}_b\right) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2.$$

B가 커지면 둘째 항은 작아지지만 공통 오차 $\rho\sigma^2$는 남는다. 같은 나무를 복사해 평균하면 $\rho = 1$이라 이득이 없다. 분할 때 후보 특성을 무작위로 줄이는 이유가 여기에 있다. 이 식은 동일 분산·동일 쌍별 상관이라는 단순화 아래의 비교다.

슬라이드 29 · 계단에서 꺾인 함수로

나무는 기준값에서 집단을 갈라 예측이 계단처럼 바뀐다. 신경망은 여러 입력의 가중합을 만들고 활성화 함수를 적용한다. ReLU 활성화 함수는 음수 부분을 0으로 잘라내므로, 은닉 단위 여러 개를 합치면 꺾인 직선이나 곡면을 만들 수 있다.

금융에서 중요한 점은 높은 표현력 자체보다 규모·모멘텀·유동성의 **조건부 결합**을 검증 가능한 방식으로 포착하는 것이다. 다음 슬라이드들은 손으로 계산하는 작은 신경망에서 시작해 학습과 정규화로 이어진다.

슬라이드 30 · 신경망의 층과 모수

입력층에는 기업 특성, 은닉층에는 특성의 조합, 출력층에는 다음 달 수익률 예측이 놓인다. 은닉 단위 하나는 입력마다 가중치 하나와 절편 하나를 갖는다. 은닉 단위가 여러 개면 출력층에서도 각 단위에 붙는 가중치와 절편을 추정한다.

입력 특성 5개, 은닉 단위 3개, 출력 1개인 한 은닉층 신경망의 모수는 입력 가중치 $5 \times 3 = 15$, 은닉 절편 3, 출력 가중치 3, 출력 절편 1로 **22개**다. 입력과 단위를 더하면 표현력과 함께 추정할 모수도 늘어난다. 훈련 표본과 검증 설계가 이를 감당하는지 확인해야 한다.

슬라이드 31 · 은닉 단위의 두 단계

은닉 단위 k는 특성 $z_1, \ldots, z_P$의 가중합 $u_k = b_k + \sum_{j=1}^{P} a_{kj} z_j$를 만들고, $h_k = \text{ReLU}(u_k) = \max(0, u_k)$를 출력한다. 가중합이 양수인 종목에서 단위가 작동하고, 음수인 종목에서는 0이 된다.

최종 예측은 $\hat{r} = c + \sum_k w_k h_k$다. 예를 들어 $u = 0.1 - 0.9\,\text{size} - 0.8\,\text{mom}$이면 규모와 모멘텀의 부호·크기에 따라 이 단위가 켜지는 종목이 달라진다. 여러 단위가 서로 다른 종목 집단에서 켜지며 조건부 예측을 만든다.

슬라이드 32 · 작은 신경망을 손으로 계산하기

소형 여부와 고모멘텀 여부를 각각 0·1로 입력하고, 세 단위를 $h_1 = \text{ReLU}(\text{small} + \text{mom} - 1)$, $h_2 = \text{ReLU}(\text{small} - \text{mom})$, $h_3 = \text{ReLU}(\text{mom} - \text{small})$로 만들자. 출력은 $\hat{r} = 0.1 + 1.1h_1 - 0.7h_2 + 0.2h_3$이고 단위는 %다.

소형·고모멘텀은 $(h_1, h_2, h_3) = (1, 0, 0)$이라 1.2%, 소형·저모멘텀은 $(0, 1, 0)$이라 -0.6%다. 대형·고모멘텀은 0.3%, 대형·저모멘텀은 0.1%다. 모멘텀 차이가 소형주에서는 1.8%포인트, 대형주에서는 0.2%포인트로 나타난다. 이 예시는 **표현 가능한 함수**를 보여 주며 가중치는 손으로 정한 것이다.

슬라이드 33 · 깊이와 너비를 정하기

한 층의 은닉 단위 수가 **너비**, 은닉층 수가 **깊이**다. 다음 층은 앞 층의 출력을 다시 가중합하고 ReLU를 적용한다. 예컨대 32개, 16개, 8개로 좁아지는 세 층은 앞쪽에서 여러 패턴을 만들고 뒤쪽에서 조합한다.

층 수와 단위 수는 어떤 함수를 만들 수 있는지 정한다. 가중치 벌점, 검증오차에 따른 조기 종료, 서로 다른 초기값에서 학습한 신경망의 평균은 표본 잡음에 대한 민감도를 줄인다. 초매개변수는 모두 미래에 가까운 검증 기간에서 비교해야 한다.

슬라이드 34 · 한 가중치의 학습을 계산하기

앞의 작은 신경망에서 소형·고모멘텀 종목의 $h_1 = 1$, 참수익률은 1.2%라고 하자. 출력 절편은 0.1이고 h_1의 출력 가중치가 0.5에서 시작하면 예측은 0.6%, 오차 $e = 1.2 - 0.6 = 0.6\%$포인트다. 제곱오차 $(r - \hat{r})^2$를 가중치로 미분하면 $-2eh_1$이다.

경사하강의 한 걸음은 $w_{\text{new}} = w_{\text{old}} + \eta(2eh_1)$다. 학습률 $\eta = 0.25$이면 w는 $0.5 + 0.25(2)(0.6) = 0.8$로, 예측은 0.9%로 이동한다. 다음 걸음에서 오차가 0.3이므로 $w = 0.95$, 예측은 1.05%다. 이 예시에서는 다른 가중치를 고정했으며 실제 학습에서는 모두 갱신한다.

슬라이드 35 · 반복 학습과 조기 종료

실제 신경망은 가중치를 무작위로 시작하고 여러 관측치의 작은 묶음(batch)에서 손실의 기울기를 계산한다. 기울기 반대 방향으로 조금 움직이는 일을 반복하며, 훈련자료를 한 번 모두 사용하면 한 epoch가 끝난다.

훈련오차는 계속 낮아져도 뒤 기간의 검증오차가 상승하기 시작하면 학습을 멈춘다. 이를 **early stopping**이라 한다. 출발점에 따라 다른 해를 찾을 수 있으므로 여러 번 학습한 예측을 평균하기도 한다. 검증 기간은 멈출 시점을 정하는 데 사용되며 최종 성능 평가는 그보다 뒤의 시험 기간에서 한다.

슬라이드 36 · 무엇을 조율하는가

층 수·너비, 가중치 벌점, 학습을 멈출 epoch는 예측 함수의 복잡도를 직접 바꾼다. 학습률과 batch 크기는 같은 목적함수의 계수를 얼마나 안정적으로 찾는지에도 영향을 준다. 모형 설계 후보를 사전에 정한 뒤 적합 기간과 그다음 검증 기간으로 고른다.

월별 수익률을 무작위로 섞으면 미래에 알려진 종목 특성의 분포나 겹치는 수익률 구간이 과거 적합에 들어갈 수 있다. 모든 후보에 같은 시간 순서를 적용해야 성능을 비교할 수 있다. 검증 결과를 반복해서 보며 후보를 계속 늘리면 그 기간에도 과적합하므로 마지막 시험 기간을 남겨 둔다.

슬라이드 37 · ReLU의 합이 꺾은선을 만드는 이유

한 입력 x에 대해 ReLU$(x-c)$는 $x \le c$에서 0이고 $x > c$에서 기울기 1인 직선이다. 서로 다른 기준점 c의 단위들을 가중합하면 각 기준점에서 기울기가 바뀌는 **조각별 선형 함수**가 된다. 단위 수를 늘리면 더 많은 굴곡을 근사할 수 있다.

입력이 여러 특성이면 각 단위의 $b + \sum_j a_j z_j = 0$이 특성 공간의 경계가 된다. 경계 한쪽에서만 단위가 작동하므로 규모와 모멘텀을 함께 포함한 조건부 효과가 가능하다. 같은 유연성이 잡음에도 맞춰질 수 있어 너비·벌점·조기 종료의 검증이 필요하다.

슬라이드 38 · 역전파가 미분을 재사용하는 법

신경망은 층별 함수를 합성해 $\hat{r} = f_L(\cdots f_2(f_1(z;\theta_1);\theta_2)\cdots;\theta_L)$를 만든다. 손실의 특정 층 가중치에 대한 미분에는 **연쇄법칙**을 쓴다. 출력에서 계산한 손실 기울기를 바로 아래 층에 전달하고, 그 층의 활성화 함수와 가중치에 대한 미분을 곱해 계속 뒤로 보낸다.

같은 중간 기울기를 각 가중치마다 처음부터 다시 계산하지 않으므로 많은 모수를 효율적으로 갱신할 수 있다. ReLU는 양수 입력에서 미분이 1, 음수에서 0이어서 꺼진 단위에는 해당 관측치의 기울기가 전달되지 않는다. 경계 0에서의 미분값은 구현에서 한 값을 정해 사용한다.

슬라이드 39 · 신경망의 과적합을 다스리기

가중치 제곱합에 벌점을 주는 weight decay는 Ridge와 같은 논리다. 절댓값 벌점은 일부 가중치를 0으로 만들 수 있다. Early stopping은 훈련자료의 잔차를 끝까지 추적하기 전에 멈추고, 서로 다른 초기값의 예측 평균은 추정의 불안정성을 줄인다.

Batch normalization은 층 안의 활성값 척도를 조정해 학습을 돕고, dropout은 훈련 때 단위 일부를 무작위로 끈다. Gu·Kelly·Xiu[47]의 비교는 이런 설정과 고정된 신경망 구조 아래에서 이루어졌다. 방법 간 성능차를 해석할 때는 알고리즘의 이름과 함께 적용한 정규화·튜닝 범위를 봐야 한다.

슬라이드 40 · 층을 더해도 성능이 늘지 않은 이유

Gu·Kelly·Xiu의 월간 표본외 R^2는 은닉층 수가 1~5인 신경망에서 각각 0.33, 0.39, 0.40, 0.39, 0.36%였다. 이 설계에서는 세 층 이후의 깊이가 뚜렷한 개선을 만들지 않았다. 차이도 통계적으로 분명하지 않다.

월별 개별주식 수익률의 예측 신호가 작으면 더 복잡한 함수가 잡음을 배우기 쉽다. 이 비교에서는 피라미드형 구조 때문에 깊이를 늘려도 모수 수는 약 29,505에서 30,185로만 변했다. 결과는 **이 자료와 이 구조에서 깊이의 추가 이득이 작았다**는 뜻이다. 다른 표본 크기와 아키텍처의 결과를 자동으로 결정하지 않는다.

슬라이드 41 · 비교 기준을 다시 묶기

네 방법은 모두 기업 특성에서 기대수익률로 가는 함수를 추정한다. 선형 모형은 입력의 효과를 더하고, PCA는 상관된 입력을 압축한다. 나무는 그룹별 조건을, 신경망은 여러 조건이 겹칠 때 달라지는 효과를 표현한다. **함수의 모양과 복잡도**가 다르므로 같은 자료와 기간에서 비교해야 한다.

슬라이드 42 · 방법마다 조율할 값

Elastic net은 벌점 크기와 L_1·L_2 혼합 비율, PCR과 PLS는 성분 수 k를 정한다. 단일 나무는 깊이, 랜덤 포레스트는 깊이와 분할당 후보 특성 수, 부스팅은 깊이·나무 수·학습률을 조율한다. 신경망에는 층·너비·벌점·종료 시점이 더해진다.

모든 값에 공통된 절차는 **과거로 적합하고 이후로 검증**하는 것이다. 후보를 여러 개 시험할수록 검증 기간의 우연에도 맞출 수 있으므로 후보 집합을 기록하고 최종 시험 기간을 따로 둔다. 서로 다른 방법을 비교할 때 입력 특성과 손실함수까지 같게 맞춰야 방법의 효과를 읽을 수 있다.

슬라이드 43 · 예측 도구에서 실증 비교로

다음 장의 실증 비교는 세 질문으로 이어진다. 월별 주식 수익률의 예측오차가 얼마나 줄었는가. 어떤 종목과 특성에서 개선됐는가. 예측으로 만든 포트폴리오의 성과가 거래비용 뒤에도 남는가. 통계적 정확도, 신호의 위치, 투자 성과를 차례로 확인한다.

[47] https://doi.org/10.1093/rfs/hhaa009

Session 4C · 머신러닝으로 본 횡단면 수익률

기업 특성으로 개별 주식의 다음 수익률을 예측하면 통계적 정확도와 투자 성과를 따로 물어야 한다. Gu·Kelly·Xiu(2020)[48]의 미국 주식 연구를 따라 입력 구성, 시간 순서를 지킨 검증, 예측 결과의 해석, 거래비용까지 연결한다.

슬라이드 01 · 머신러닝과 횡단면 수익률

횡단면 예측은 같은 달 여러 주식의 다음 수익률을 비교한다. 규모·가치·과거 수익률 같은 기업 특성을 입력으로, 선형 모형부터 신경망까지 같은 자료와 평가 기간에서 시험한다. 예측이 개선된 종목과 그 예측을 매매로 옮겼을 때의 성과를 함께 살핀다.

슬라이드 02 · 비교의 출발점

4A의 특성별 정렬은 한 변수의 높은 그룹과 낮은 그룹이 얼마나 다른지를 보여준다. 4B의 방법은 여러 특성이 동시에 들어올 때 예측 함수를 만드는 도구다. 여기서는 그 함수들을 같은 주식 표본에서 비교한다.

읽을 때 세 숫자를 구분하자. 표본외 R^2는 개별 주식 수익률 예측오차, Sharpe ratio는 예측으로 만든 포트폴리오의 수익 대비 변동성, 비용 후 수익은 실제 매매 가능성에 관한 값이다. 한 숫자가 높다고 다른 숫자도 높아야 하는 것은 아니다.

슬라이드 03 · 모든 종목에 적용하는 예측 함수

종목 i의 t월 말 정보벡터를 $z_{i,t}$라 하면 다음 달 수익률을

$$r_{i,t+1} = g^*(z_{i,t}) + \varepsilon_{i,t+1},$$
$$E_t[r_{i,t+1}] = g^*(z_{i,t}).$$

로 쓴다. g^*는 알려지지 않은 조건부 기대수익률 함수이고, ε는 그 시점 정보로 미리 알 수 없는 부분이다. 같은 함수를 모든 종목과 달에 적용하므로 종목별·월별 차이는 입력 $z_{i,t}$가 담는다. 이 가정은 자료를 모아 추정력을 높이지만, 특성으로 표현되지 않는 구조 변화까지 포착하지는 못한다.

OLS-3, PCR, elastic net은 주어진 입력에 선형으로 반응한다. Random forest와 boosted trees는 조건부 분할을, 신경망은 여러 특성의 비선형 결합을 허용한다. 예를 들어 소형주에서만 단기 반전이 강하다면 **규모와 과거 수익률의 상호작용**이 필요하다.

슬라이드 04 · 실험 설계의 순서

예측 연구는 모형부터 비교하기 전에 자료가 언제 투자자에게 알려졌는지, 입력을 어떻게 가공했는지, 어느 기간으로 학습했는지를 정해야 한다. 미래에 공개될 회계자료가 과거 예측에 섞이면 높은 성과도 사용할 수 없는 정보에서 나온다.

이후의 흐름은 **특성 수집 → 동일한 입력 척도 → 훈련·검증·시험 분리 → 통계적 점수 → 포트폴리오 점수**다. 이 순서가 유지되어야 모형 간 차이를 방법의 차이로 해석할 수 있다.

[48] https://doi.org/10.1093/rfs/hhaa009

슬라이드 05 · 94개 기업 특성과 공시 시점

표본은 1957–2016년 NYSE·AMEX·NASDAQ에 상장된 미국 주식 약 3만 종목이며 한 달 평균 약 6,200종목을 관찰한다. 종목별 94개 특성은 규모, 유동성, 가치, 수익성, 투자, 변동성, 단기 반전과 모멘텀 등을 포함한다. 산업 구분 74개와 시장 전체 상태를 나타내는 변수 8개도 사용한다.

기업의 회계연도 말과 자료를 사용할 수 있는 날짜는 다르다. 예를 들어 12월 결산 수익성 수치는 공시가 끝나기 전 1월 말의 정보집합에 넣으면 안 된다. 연구는 공개된 뒤의 특성만 사용하고 누락된 특성은 그 달의 중앙값으로 채운다. 중앙값 대치는 표본을 유지하지만, 결측 자체가 신호일 가능성은 별도로 검토할 여지가 있다.

슬라이드 06 · 순위 변환과 920개 입력

특성 x를 같은 달의 종목 사이에서 정렬해 순위 $q_i \in \{1, \dots, n\}$를 준 뒤 $z_i = 2(q_i - 1)/(n-1) - 1$로 바꾼다. 최솟값은 -1, 최댓값은 1, 가운데 종목은 0 근처다. 규모가 0.1과 200인 종목도 **순위 간격**으로 비교되므로 큰 원자료 값이 회귀를 지배하기 어렵다. 대신 규모 차이가 몇 배인지는 사라진다. 4A에서 살핀 분할 기준과 가중치가 포트폴리오에 영향을 주는 것과는 다른, **모형 입력의 척도**를 정하는 단계다.

94개 순위 특성 각각에 시장 변수 8개와 상수 1을 곱해 $94(8+1) = 846$개를 만들고 산업 지표 74개를 더해 920개를 얻는다. 예를 들어 $z_{i,t}^{\text{mom}} M_t$를 넣으면 모멘텀의 기울기가 시장 상태 M_t에 따라 바뀔 수 있다. 입력의 수가 920개라고 해서 920개의 독립적인 경제 현상이 발견된 뜻은 아니다.

슬라이드 07 · 선형 방법 세 가지

OLS-3은 규모, 장부가/시가, 모멘텀 세 특성으로 최소제곱 회귀를 적합한다. PCR은 920개 입력을 소수의 주성분으로 바꾼 뒤 그 성분으로 회귀한다. Elastic net은 원래 입력 전체를 쓰되 계수에 L_1·L_2 벌점을 가한다.

$$\min_{a,b} \quad \sum_{i,t} (r_{i,t+1} - a - z_{i,t}' b)^2 \\ + \gamma_1 \sum_j |b_j| + \gamma_2 \sum_j b_j^2.$$

L_1은 일부 계수를 0으로 만들어 변수를 고르고, L_2는 상관된 변수의 계수를 함께 줄인다. 세 방법 모두 제공된 입력의 가중합이다. 규모와 모멘텀의 곱을 입력에 명시하지 않았다면 모멘텀의 기울기를 규모별로 다르게 만들 수 없다. 4B의 상호작용 논의가 이 한계를 설명한다.

슬라이드 08 · 나무와 신경망의 예측 형태

Random forest는 표본과 분할 후보를 달리한 여러 나무를 만들고 예측을 평균한다. Boosted trees는 앞선 모형이 남긴 오차를 줄이는 작은 나무를 순서대로 더한다. 신경망은 층마다 입력의 가중합에 ReLU 같은 활성화 함수를 적용한다. 이 연구의 NN1–NN5는 은닉층 수가 1–5개다.

나무는 "규모가 작고 지난달 많이 하락한 주식"처럼 조건을 연속해 묻는다. 신경망은 여러 은닉 단위의 출력을 합쳐 같은 상호작용을 부드러운 조각별 함수로 나타낸다. 표현력이 넓어지므로 복잡도와 학습 기간은 뒤의 검증 자료로 정해야 한다.

슬라이드 09 · 시간 순서를 지킨 반복 검증

첫 시험 연도인 1987년에는 1957–1974년으로 계수를 적합하고 1975–1986년으로 초매개변수를 고른다. 선택한 모형으로 1987년의 월별 수익률을 예측한다. 다음 해에는 훈련과 검증 구간을 한 해씩 늘리거나 옮겨 1988년을 예측한다. 이를 2016년까지 반복하면 시험 기간 30년이 생긴다.

한 달의 종목을 무작위로 훈련·시험에 섞으면 미래 시점의 가격 관계가 과거 모형 선택에 새어 들어올 수 있다. 여기서 보존해야 하는 경계는 **종목 번호보다 달력 시간**이다. 검증 구간에서 선택한 모형도 그 뒤의 시험 연도 자료를 보기 전에 확정해야 한다.

슬라이드 10 · 표본외 결정계수의 분자와 분모

시험 기간의 모든 종목·월 관측치를 모아

$$R^2_{\text{OOS}} = 1 - \frac{\sum_{(i,t)\in\mathcal{T}} (r_{i,t+1} - \hat{r}_{i,t+1})^2}{\sum_{(i,t)\in\mathcal{T}} r_{i,t+1}^2}$$

를 계산한다. 분자는 모형의 제곱예측오차, 분모는 매번 0을 예측했을 때의 제곱오차다. $R^2_{\text{OOS}} = 0.004$는 0 예측보다 전체 제곱오차가 **0.4% 줄었다**는 뜻이다. 개별 주식의 월별 수익률에는 우연한 변동이 크므로 작은 R^2도 많은 종목의 순위를 유의미하게 바꿀 수 있다.

이 값은 학습자료의 평균을 빼고 계산하는 통상적인 회귀 R^2와 기준점이 다르다. 포트폴리오 평가는 매월 예측 상위 10분위 매수, 하위 10분위 매도 수익률의 평균과 Sharpe ratio로 별도 계산한다.

슬라이드 11 · 왜 0을 기준 예측으로 쓰는가

시장 전체의 장기 평균 초과수익률은 여러 해의 관측을 공유하므로 유용한 기준 예측이 될 수 있다. 개별 주식의 평균 수익률은 관측기간이 짧고 종목별 변동성이 커 추정오차가 크다. 그 불안정한 과거 평균을 기준으로 삼으면 모형이 좋은지보다 **기준이 얼마나 나쁜지**가 점수에 섞인다.

같은 OLS-3 예측도 0 기준으로는 월별 $R^2 = 0.16\%$, 과거 평균 기준으로는 3.74%라고 보고된다. 분자에 들어간 모형 오차가 바뀐 것이 아니라 분모의 기준 오차가 커진 결과다. 서로 다른 연구의 R^2를 비교할 때는 분모가 0 예측인지 역사적 평균인지 먼저 확인한다.

슬라이드 12 · 예측오차 차이의 통계 검정

모형 A와 B의 매달 횡단면 평균 제곱오차 차이를 $d_t = \overline{e^2_{A,t}} - \overline{e^2_{B,t}}$라 두자. d_t의 시간 평균이 0인지 검정하면 두 모형의 표본외 예측력이 구별되는지 물을 수 있다. Diebold–Mariano 통계량은 평균 차이를 그 표준오차로 나눈 값이며, 월별 d_t의 자기상관이 있으면 표준오차도 그에 맞게 조정해야 한다.

여러 모형을 쌍별 비교하면 우연히 큰 차이가 나온 쌍을 발견할 가능성이 높아진다. 12개 모형의 66쌍을 모두 한 가족으로 Bonferroni 보정하는 **단측 5% 검정**이라면 각 쌍의 유의수준은 $0.05/66$, 정규 근사 임계값은 약 3.17이다. 2.64는 더 작은 검정 집합에 해당하므로 보고된 숫자를 읽을 때 보정 범위를 확인한다. NN3와 OLS-3의 통계량 2.13은 일반적인 5% 기준은 넘지만 66쌍 보정 기준에는 못 미친다.

슬라이드 13 · 결과표를 읽는 기준

같은 표본과 검증 구간으로 여러 모형을 비교하면 순위가 생긴다. 그러나 막대 높이만으로 "신경망 층을 하나 더 쌓으면 성과가 오른다"처럼 결론을 내리기 어렵다. 점수 차이의 크기, 표본 기간의 불확실성, 거래 전략으로 바꾸었을 때의 크기를 순서대로 확인한다.

이 절에서는 전체 주식의 월별 R^2, 대형주·소형주별 점수, 연간 수익률 예측을 나누어 살핀다. 어느 집단에서 개선되는지가 예측의 경제적 해석을 바꾼다.

슬라이드 14 · 전체 주식의 월별 예측력

표본외 월별 R^2는 OLS-3 0.16%, PCR 0.26%, elastic net 0.11%, random forest 0.33%, boosted trees 0.34%다. 신경망은 대략 0.33–0.40%이며 NN3이 0.40%로 가장 높다. 920개를 제한 없이 최소제곱에 넣으면 -3.46%다.

음의 R^2는 모형이 0 예측보다 제곱오차를 더 크게 냈다는 뜻이다. 입력이 많을수록 표본내 적합은 좋아질 수 있지만, 미래 예측에서는 계수 추정오차가 커진다. Elastic net의 벌점, PCR의 차원 축소, 나무의 평균, 신경망의 검증 절차가 모두 그 문제를 다루는 서로 다른 방식이다.

슬라이드 15 · 대형주에서 커지는 비선형 이득

같은 학습 모형을 시가총액 상위 1,000종목에만 채점하면 NN3의 월별 R^2는 0.70%, random forest는 0.63%이고 선형 방법은 최대 0.31%다. 하위 1,000종목에서도 예측력은 있지만 방법 간 격차는 더 작다.

대형주는 거래가 상대적으로 쉬운 편이다. 따라서 비선형 개선이 **오직** 거래가 어려운 초소형주를 맞힌 결과라는 해석과는 맞지 않는다. 다만 R^2의 크기가 곧 거래 가능한 수익률의 크기는 아니다. 대형주에서 예측오차를 조금 줄여도 예측 상·하위 포트폴리오의 수익률 격차가 작을 수 있다.

슬라이드 16 · 어느 모형의 우위가 확실한가

제한 없는 920변수 OLS는 다른 방법에 비해 표본외 오차가 크다. 비선형 모형과 선형 모형의 차이는 개별 비교에서 관찰되지만, 많은 비교를 한꺼번에 보정하면 해석이 조심스러워진다. Random forest, boosted trees, 신경망들 사이의 작은 점수 차이는 통계적으로 구분하기 어렵다.

따라서 NN3의 막대가 NN2보다 조금 높다는 사실은 층 수 3이 최적이라는 일반 법칙이 아니다. 확실하게 읽을 수 있는 방향은 **특성 간 조건부 관계를 허용하면 예측이 개선된다**는 것이다. 특정 비선형 알고리즘의 승리를 주장하려면 별도의 검증 자료가 더 필요하다.

슬라이드 17 · 예측 기간을 12개월로 늘리면

12개월 뒤까지의 누적 수익률을 예측할 때 NN4의 표본외 R^2는 3.60%이고 선형 방법은 1.78–3.08%다. 한 달의 규모나 가치 지표가 여러 달 지속되어 기대수익률 차이를 반복해서 만든다면, 12개월 누적 신호는 대략 12배 쌓이는 동안 독립적인 월별 충격의 표준편차는 $\sqrt{12}$배로 늘어난다. 그래서 수익률 수준의 신호대잡음비가 높아질 수 있다.

이 설명은 특성과 기대수익률이 충분히 지속되고 월별 충격의 상관이 작다는 직관적 근사다. 실제 R^2를 월별 값의 12배로 계산할 수 있다는 항등식은 아니다. 단기 반전처럼 한 달 안에 사라지는 신호의 기여가 작아져 비선형 방법과 선형 방법의 차이도 줄어든다.

슬라이드 18 · 예측을 설명으로 옮기는 단계

예측력이 있다는 결과 다음에는 모형이 **어떤 입력에 반응했는지**를 확인한다. 중요도는 변수를 바꾸었을 때 모형 점수가 얼마나 움직이는지를, 한계효과 그림은 입력을 변화시켰을 때 예측 수익률이 어떤 모양으로 변하는지를 요약한다.

두 도구 모두 이미 적합된 함수의 행동을 읽는 방법이다. 위험 보상과 가격오류를 구별하려면 거래 가능성, 경기 상태, 공매도 제약 같은 증거를 더 살펴야 한다.

슬라이드 19 · 중요한 특성은 무엇인가

한 특성을 모든 관측치에서 0으로 놓고 적합된 모형의 설명력이 얼마나 떨어지는지 계산하면 그 특성의 중요도를 얻는다. 0은 순위 변환 뒤의 중간값에 가깝다. Elastic net과 NN3 모두 지난달 수익률의 **1개월 반전**을 중요하게 사용한다. NN3는 규모, 변동성, 거래량, 유동성 특성에도 반응한다.

특성끼리 상관돼 있으면 하나를 0으로 만들어도 다른 특성이 유사한 정보를 대체할 수 있다. 따라서 중요도는 이 모형·이 입력 집합 안에서의 **추가 기여**로 읽는다.

슬라이드 20 · 1개월 반전의 경제적 직관

지난달 크게 하락한 주식이 다음 달 상대적으로 반등하고 크게 상승한 주식은 되돌아오는 현상을 단기 반전이라 한다. 급히 현금이 필요한 투자자의 매도가 일시적으로 가격을 밀어 내리고, 이를 받아주는 매수자는 가격 회복에서 보상을 받을 수 있다. 매도자가 나쁜 정보를 알고 있을 가능성 때문에 매수자는 충분히 낮은 가격을 요구하므로 유동성 공급에는 위험이 따른다.

이 설명이면 거래가 어렵거나 시장이 혼란스러운 때 반전이 더 커질 수 있다. 4A에서 동일가중 성과가 시가총액가중보다 큰 것도 작은 종목의 영향과 연결된다. 반전 관측만으로 모든 가격변화를 일시적 압력으로 단정할 수는 없으므로 뉴스 반영과 거래비용을 함께 살핀다.

슬라이드 21 · 규모에 따라 달라지는 반전과 모멘텀

적합된 NN3에서 다른 입력을 중간값에 두고 지난달 수익률을 바꾸면 소형주 곡선의 기울기가 더 가파르게 음수다. 소형주일수록 1개월 반전이 강하다는 뜻이다. 12개월 과거 수익률을 바꾼 그림에서는 대형주의 양의 기울기, 즉 모멘텀이 두드러진다.

단순식 $\hat{r} = a + b_1 \text{mom} + b_2 \text{size}$라면 모멘텀 기울기 b_1은 규모와 무관하다. $b_3 \text{mom} \times \text{size}$가 있어야 기울기가 $b_1 + b_3 \text{size}$로 달라진다. 신경망 그림은 이런 상호작용이 실제 자료에서 유용한지 살펴보는 방법이다.

슬라이드 22 · 시장 상태도 특성 효과를 바꾼다

시장 전체의 장부가/시가 비율이 높은 달과 낮은 달에 동일한 소형주 신호가 같은 수익률 차이를 내리라는 보장은 없다. 모형의 두 변수 그림에서는 시장 전체의 장부가/시가가 높거나 순주

식발행이 적을 때 작은 기업의 상대적 기대수익률이 더 높다.

입력 $z_{i,t}^{\text{size}} M_t$의 계수를 생각하면, 규모 효과는 $b_1 + b_2 M_t$처럼 시장 상태에 따라 바뀐다. M_t는 같은 달 모든 기업에 공통이지만 기업별 규모와 곱해지므로 **기업 간 차이**를 만든다. 시간 변화가 어디서 들어오는지 이해하는 열쇠다.

슬라이드 23 · 요인 동물원에서 무엇을 배웠나

많은 특성이 발표됐다는 사실과 각각이 독립적인 새 수익 원천이라는 주장은 다르다. 표본외 중요도에서는 과거 수익률, 규모, 유동성, 변동성, 가치 등 익숙한 특성들이 큰 역할을 한다. 개선은 새로운 변수의 긴 목록보다 기존 신호를 **조건에 맞게 결합한 방식**에서 나온다.

서로 유사한 20개의 특성이 같은 경제적 현상을 측정한다면, 모형이 한 개만 남겨도 나머지 19개의 연구가 무의미해지는 것은 아니다. 반대로 새 변수가 기존 특성 위에 안정적 추가 예측력을 내지 못하면 별개의 이상현상으로 세기 어렵다. 표본외 비교가 이 질문에 유용하다.

슬라이드 24 · 적합된 모형의 그림을 읽는 법

한계효과 그림은 한 입력을 -1부터 1까지 바꾸고 나머지 입력을 중간값에 고정한 채 $\hat{g}(z)$를 그린다. 두 입력을 동시에 바꾸면 상호작용 표면이 된다. 기울기가 구간마다 달라지면 선형 모형의 일정한 한계효과로 요약하기 어렵다.

이는 **모형의 반응 그림**이다. 실제 기업에서는 작은 규모, 높은 유동성, 낮은 변동성 같은 조합이 드물 수 있다. 관측 자료가 거의 없는 영역의 곡선은 외삽이므로 신중하게 읽는다. 특성 중요도 역시 다른 변수와의 상관 및 0으로 바꾸는 기준에 영향을 받는다.

슬라이드 25 · 예측에서 투자 성과까지

좋은 주식별 예측은 정렬 전략의 출발점이다. 그러나 투자 성과는 어떤 종목을 상·하위 그룹에 넣는지, 각 그룹의 가중치를 어떻게 주는지, 얼마나 자주 다시 사고파는지에 달린다. 앞의 R^2는 이 세 선택을 평가하지 않았다.

이제 예측으로 만든 매수·매도 포트폴리오의 총수익, 보정 정도, 성과가 집중된 곳, 비용을 차례로 읽는다. 같은 예측 논문에서도 통계적 점수와 거래 후 점수가 다르게 움직일 수 있다.

슬라이드 26 · 예측 상·하위 10분위 포트폴리오

매월 말 예측 수익률로 종목을 정렬하고 상위 10%를 매수, 하위 10%를 공매도해 다음 달 보유한다. 각 다리를 시가총액가중으로 만들면 1987–2016년 NN4의 매수·매도 수익은 월평균 2.26%, 연율 Sharpe ratio 1.35다. 선형 방법의 Sharpe ratio는 0.39–0.88이다.

시장·규모·가치·수익성·투자·모멘텀 여섯 요인에 전략 수익률을 회귀한 절편 α는 NN4에서 월 1.76%다. 이 값은 여섯 요인의 **선형 노출로 설명되지 않는 평균**이며, 위험 보상이 전혀 없다는 증명은 아니다. 모형에 없는 위험과 거래비용은 여전히 남는다.

슬라이드 27 · 예측값의 크기도 맞는가

종목을 예측값 10분위로 나누고 각 그룹의 평균 예측수익률을 가로축, 실현수익률을 세로축에 놓는다. 예측값이 수익률의 크기까지 맞으면 점들이 45도선에 가까워진다. 그룹별 $\bar{r}_d = c + s\bar{\hat{r}}_d + u_d$의 기울기 $s = 1$, 절편 $c = 0$이 이상적 보정이다.

NN4의 기울기는 약 1.09로 그룹 간 수익률 격차의 크기가 대체로 맞는다. OLS-3은 0.54여서 실제 격차가 예측 격차의 절반 정도다. 순위만 잘 맞히는 모형과 **얼마나 벌어질지도** 맞히는 모형은 다르다. 다만 열 점은 서로 독립적인 무작위 표본이 아니며 극단 그룹에서 차이가 남는다.

슬라이드 28 · 예측력과 수익이 집중되는 곳

NN4의 매수·매도 Sharpe ratio는 동일가중 2.45, 시가총액가중 1.35다. NYSE 규모 하위 20% 종목을 제외한 뒤에도 1.69다. 종목별 R^2의 비선형 개선이 대형주에서 컸다는 앞의 결과와 함께 읽으면, **예측오차 개선의 위치와 포트폴리오 수익의 위치가 다르다**는 점이 보인다.

소형주는 수익률 격차가 크지만 거래량·공매도 가능 주식 수가 적어 실행 비용도 크다. NN4의 월간 회전율은 시가총액가중 포트폴리오에서 약 127%로 OLS-3의 약 58%보다 높다. 높은 총수익을 순수익으로 옮길 때 이 차이가 중요해진다.

슬라이드 29 · 매도 다리를 따로 보는 이유

매수·매도 수익은 $R_L - R_S$다. 따라서 성과가 좋은 종목을 잘 사서 벌었는지, 수익이 낮을 종목을 잘 골라 공매도해서 벌었는지를 분리할 수 있다. 과대평가가 공매도 제약 때문에 오래 남는다는 설명이라면 두 번째 다리가 큰 역할을 할 수 있다.

공매도에는 주식 대여 수수료, 담보, 주식 회수 위험, 가격 급등 시 손실이 있다. 예측한 하락이 실제로 발생해도 주식을 빌릴 수 없으면 그 수익을 실현하기 어렵다. 매도 다리의 역사적 수익은 **전략이 실현할 수 있었던 수익**과 함께 평가해야 한다.

슬라이드 30 · 2000년 이후 매도 다리와 낙폭

누적 수익 그림에서 여러 모형의 매수 다리는 계속 오르지만 매도 다리는 2000년 이후 대체로 평탄하다. 이는 같은 자료에서 여러 알고리즘이 공유한 변화이므로 특정 신경망 구조만의 문제로 보기 어렵다. 공매도 수익의 약화는 시장 참여자의 적응, 거래비용 변화, 신호의 확산 등 여러 가설과 양립한다.

최대낙폭은 과거 고점의 **포트폴리오 가치**에서 이후 저점까지의 최대 하락률이다. 논문 표의 NN4 최대낙폭은 약 52%, OLS-3은 약 70%다. 누적 **로그**수익의 고점과 저점 차이가 0.52라면 단순 수익률 낙폭은 $1 - e^{-0.52} \approx 40.5\%$이므로, 로그 좌표 차이를 그대로 52% 낙폭으로 읽어서는 안 된다.

슬라이드 31 · 회전율에 거래비용을 적용하면

시가총액가중 NN4의 월간 총수익 2.26%, 회전율 1.27에 모든 매매의 편도 비용 c가 같다고 두면 순수익은 대략 $2.26\% - 1.27c$다. $c = 0.20\%$이면 2.01%, 총수익이 0이 되는 비용은 $2.26\%/1.27 \approx 1.78\%$, 즉 178bp다.

이 계산은 비용이 모든 주식과 달에 같다는 단순화다. 신호가 강한 소형주나 공매도 다리에는 더 큰 비용이 들 수 있다. 반대로 거래 속도와 비중을 조정하면 회전율을 낮출 수도 있다. 따라서 손익분기 비용은 **주어진 매매 규칙의 민감도**이지 실제 순수익의 확정치가 아니다.

슬라이드 32 · 머신러닝 결과의 경제적 범위

같은 특성 자료에서 상호작용을 허용하는 모형이 선형 방법보다 예측오차를 줄이고, 예측 순위로 만든 포트폴리오도 높은 총수익을 냈다. 그러나 나무와 신경망 사이의 작은 차이는 통계적으로 명확하지 않고, 예측력은 위험 보상과 가격오류를 자동으로 구별하지 않는다.

대형주에서도 보이는 예측력, 소형주에 집중된 수익, 약해진 매도 다리, 높은 회전율은 함께 설명해야 할 사실들이다. 한 가지 기제로 모두 정리하기보다 **어떤 관측이 각 설명과 맞는지**를 확인하는 편이 정확하다.

슬라이드 33 · 보정 기울기가 드러내는 차이

예측 10분위의 실현 평균을 예측 평균에 회귀한 기울기는 OLS-3 0.54, PCR 0.46, elastic net 0.34, random forest 1.72, NN3 1.10, NN4 1.09로 보고된다. 기울기가 1보다 작으면 예측의 그룹 간 간격에 비해 실현 간격이 좁다. 1보다 크면 예측 간격이 실제보다 압축되어 있다.

나무 잎의 과거 평균을 합치는 forest는 훈련 자료 밖의 극단적인 수익률 수준을 외삽하기 어렵다. 따라서 점수 R^2가 비슷해도 **수익률 수준을 정하는 성질**이 신경망과 다를 수 있다. 기울기 하나만으로 모형의 모든 보정 문제가 해결되는 것은 아니며, 절편과 극단 10분위의 오차도 함께 본다.

슬라이드 34 · 회전율 공식의 분모

지난달 비중 $w_{i,t}$의 주식을 거래 없이 보유하면 다음 달 매매 직전 비중은

$$w_{i,t+1}^{\text{drift}} = \frac{w_{i,t}(1 + r_{i,t+1})}{1 + \sum_j w_{j,t} r_{j,t+1}}$$

이다. 분자는 해당 종목의 가치 성장, 분모는 포트폴리오 전체의 가치 성장이다. 새 목표 비중 $w_{i,t+1}^{\text{target}}$과의 차이를 합한 $\sum_i |w_{i,t+1}^{\text{target}} - w_{i,t+1}^{\text{drift}}|$가 논문에서 쓰는 양방향 거래량 기준 회전율이다. 단순히 가격 상승 때문에 늘어난 비중은 거래로 세지 않는다.

이 정의에서는 매수 금액과 매도 금액을 모두 더한다. 완전 투자 포트폴리오라면 두 금액이 같아, 회전율 1.27은 매수 0.635와 매도 0.635의 합으로 읽을 수 있다. 비용식의 c가 **각 편도의 거래비용**이라면 두 편도의 거래량 합에 곱한다. 다른 연구가 회전율을 절반으로 정의할 때에는 비용의 단위도 맞춰야 한다.

슬라이드 35 · 무엇을 종합할 것인가

예측력, 보정, 매수·매도 수익, 낙폭, 회전율은 서로 다른 질문에 답한다. 같은 모형이 한 기준에서는 앞서고 다른 기준에서는 뒤질 수 있다. 모형 선택을 위해서는 투자자가 실제로 쓸 목표, 예를 들어 종목별 수익률 예측인지 비용 후 롱숏 수익인지부터 정한다.

평가에 사용한 표본이 끝난 이후에도 성과가 지속되는지는 별도 시험이다. 연구 결과를 실제 전략으로 옮길 때는 이후 기간, 시장, 비용 가정을 공개하고 재검증해야 한다.

슬라이드 36 · 4C의 핵심 연결

94개 기업 특성과 시장 상태의 곱으로 920개 입력을 만들고, 시간 순서에 따라 훈련·검증·시험을 분리했다. 0 예측을 기준으로 한 월별 R^2는 작지만, 비선형 모형은 조건부 효과를 포착해 예측오차를 줄였다. 중요한 입력에는 단기 반전, 규모, 유동성, 변동성처럼 앞서 배운 특성이 많다.

예측으로 만든 포트폴리오의 총수익은 높았으나 성과의 소형주 집중과 높은 회전율은 거래 후 평가를 요구한다. 통계적 예측, 경제적 메커니즘, 실행 가능한 수익을 차례로 구별하면 연구의 강점과 한계를 같은 틀에서 읽을 수 있다.

슬라이드 37 · 특성을 공분산으로 읽는 다른 방법

특성이 기대수익률을 예측할 때 그 효과가 공통 위험요인에 대한 민감도에서 오는지 물을 수 있다. Kelly·Pruitt·Su(2019)[49]의 instrumented PCA는 수익률을 $r_{i,t+1} = \alpha_{i,t} + \beta'_{i,t} f_{t+1} + \epsilon_{i,t+1}$로 나누고, 특성 $z_{i,t}$가 $\beta_{i,t}$와 $\alpha_{i,t}$를 설명하도록 적합한다. 여기서 f는 여러 종목이 공유하는 잠재 요인 충격, β는 종목의 요인 노출이다.

특성이 β를 예측한다면 그 종목은 공통 충격과 함께 움직이는 방식이 달라진다. 특성이 α에도 남는다면 사용한 요인의 공분산 구조로 설명되지 않는 평균 차이가 있다. 잔여 절편이 곧 가격 오류라는 결론은 추가 가정이 필요하다. 이 접근은 "어느 주식이 오를까"라는 예측 질문을 "왜 그 수익률을 요구할까"라는 위험 질문과 연결한다.

Session 5 · 채권 위험프리미엄과 머신러닝

국채는 만기 상환액이 정해져 있어도 **중간에 팔 가격**은 정해져 있지 않다. 만기별 금리에서 선도금리와 보유수익률을 유도하고, 그 차이에서 기대 금리 변화와 위험 보상을 구분한다. 이어서 수익률곡선 밖의 거시 정보가 예측에 도움이 되는지 살피되, 중첩 수익률의 통계적 문제와 미래 정보 누출을 함께 확인한다. 수치 결과를 읽을 때는 Cochrane–Piazzesi(2005)[50], Bauer–Hamilton(2018)[51], Bianchi–Büchner–Tamoni(2021)[52]와 정정문[53]을 구분한다.

슬라이드 01 · 채권 위험프리미엄이라는 질문

10년 만기 국채를 1년 보유하면 1년 뒤에는 9년 만기 채권을 판다. 처음 약속된 상환액은 안전해도 1년 뒤 매도가격은 그때의 금리에 따라 달라진다. 따라서 이 장의 대상은 만기수익률 자체가 아니라 **1년 보유수익률에서 오늘 확정할 수 있는 1년 금리를 뺀 초과수익률**이다.

슬라이드 02 · 예측과 보상의 경계

장기 금리가 단기 금리보다 높을 때 장기채가 유리하다고 바로 결론 낼 수 없다. 높은 장기 금리는 앞으로 단기 금리가 오를 것이라는 기대와, 중간에 팔 때의 가격 위험에 대한 보상을 함께 담는다. 먼저 두 부분을 분리하는 항등식을 만든 뒤 실제 수익률 자료와 예측모형으로 어느 쪽이 중요한지 판단한다.

[49] https://doi.org/10.1016/j.jfineco.2019.05.001
[50] https://doi.org/10.1257/0002828053828581
[51] https://doi.org/10.1093/rfs/hhx096
[52] https://doi.org/10.1093/rfs/hhaa062
[53] https://doi.org/10.1093/rfs/hhaa098

슬라이드 03 · 수익률곡선에서 출발하기

수익률곡선은 **같은 시점**에 거래되는 여러 만기의 금리를 나란히 놓은 것이다. 이 절에서는 무이표채 가격으로부터 만기별 금리와 선도금리를 정의한 다음, 1년 후 팔았을 때의 수익률을 계산한다. 이 순서를 지켜야 금리의 기울기를 수익률의 기울기와 혼동하지 않는다.

슬라이드 04 · 무이표채의 수익률곡선

무이표채는 중간 쿠폰 없이 만기에 액면금액 한 번만 지급한다. 액면 1의 n년물 가격을 $P_t^{(n)}$라 하고 연속복리 금리를 $y_t^{(n)}$라 하면 $P_t^{(n)} = e^{-n y_t^{(n)}}$다. 가격이 낮을수록 같은 1을 받기 위해 요구하는 금리는 높다. n을 바꿔 그린 $y_t^{(n)}$의 모임이 spot yield curve다. 쿠폰채의 표면금리나 만기수익률을 그대로 연결한 곡선과 구분해야 한다.

10년물과 1년물 금리의 차이 $y_t^{(10)} - y_t^{(1)}$는 흔히 장단기금리차 또는 term spread라고 부른다. 값 하나는 곡선의 양 끝만 요약하므로 중간 만기의 굴곡은 별도로 보아야 한다. Liu–Wu 무이표금리 자료[54]는 이런 비교에 쓰이는 월별 곡선을 제공한다.

슬라이드 05 · 곡선 모양 네 가지

우상향·우하향은 양 끝 금리의 상대적 높이로, 가운데가 솟거나 꺼진 모양은 중간 만기가 양 끝을 잇는 선에서 얼마나 벗어났는지로 읽는다. 같은 10년물과 1년물 금리라도 5년물의 높이가 다르면 선도금리와 채권 가격의 반응이 달라진다. 역전된 곡선이 경기 둔화와 자주 함께 관찰되어도 한 달의 모양만으로 침체를 확정할 수는 없다.

슬라이드 06 · 수준·기울기·곡률

수준(level)은 모든 만기 금리가 함께 오르내리는 방향이고, 기울기(slope)는 장단기 금리차다. 곡률(curvature)은 중간 만기의 상대적 볼록함으로, 예를 들어 $2y^{(5)} - y^{(1)} - y^{(10)}$처럼 잡을 수 있다. 이 값이 양수면 5년 금리가 양 끝의 평균보다 높다. 연구마다 만기 선택과 부호가 달라 **정의한 식을 먼저 확인**해야 한다.

금리가 함께 1%포인트 올라가면 수준은 바뀌지만 장단기 차이는 그대로다. 반대로 양 끝 금리가 같아도 5년물만 움직이면 곡률이 달라진다. 세 방향을 분리하면 곡선의 움직임을 적은 수의 변수로 설명할 수 있다.

슬라이드 07 · 기울기의 시간 변화

표본에서 우상향 곡선이 많은 것은 사실이지만, 양의 장단기금리차가 항상 향후 금리 상승을 뜻하지는 않는다. 장기채 보유 위험에 대한 보상이 양수라면 미래 단기 금리가 그대로이거나 내려갈 것으로 예상해도 곡선이 우상향할 수 있다. 경기침체 전 역전도 단기금리 기대와 위험 보상이 동시에 움직인 결과일 수 있다.

[54] https://sites.google.com/view/jingcynthiawu/yield-data

슬라이드 08 · 곡선을 설명하는 세 관점

기대가설(EH)의 핵심은 장기채와 단기채를 차례로 굴리는 전략의 **기대 초과수익률이 일정하다**는 것이다. 여기서는 그 상수를 0으로 두는 간명한 경우를 쓴다. 유동성선호 관점은 장기채의 중도 매도 가격 위험에 대한 보상을 더한다. 선호지대(preferred habitat)는 보험사·연기금처럼 특정 만기를 선호하는 투자자와 채권 공급의 균형을 강조한다.

우상향 곡선 하나로 세 설명을 식별할 수 없다. 금리의 미래 경로 또는 실현된 채권 초과수익률이 추가로 필요하다.

슬라이드 09 · 로그 금리와 가격의 관계

무이표채 가격 $P_t^{(n)} = e^{-n y_t^{(n)}}$의 로그를 취하면 $p_t^{(n)} \equiv \log P_t^{(n)} = -n y_t^{(n)}$다. 곱셈을 덧셈으로 바꿔 주므로 두 가격의 비율인 보유수익률을 금리의 차이로 정확히 쓸 수 있다. 다음 식들의 수익률은 **로그 수익률**이다.

$$
\begin{aligned}
f_t^{(n-1,n)} &= n y_t^{(n)} - (n-1) y_t^{(n-1)}, \\
r_{t+1}^{(n)} &= p_{t+1}^{(n-1)} - p_t^{(n)}, \\
&= n y_t^{(n)} - (n-1) y_{t+1}^{(n-1)}.
\end{aligned}
$$

$f_t^{(n-1,n)}$는 $n-1$년 뒤부터 1년간 적용되는 선도금리다. 연속복리 4%를 1년 실효수익률로 바꾸면 $e^{0.04} - 1 \approx 4.08\%$다. 단위를 바꾸지 않고 두 수치를 섞어 비교하지 않는다.

슬라이드 10 · 기대가설의 숫자 예시

오늘 1년 금리가 3%, 내년 1년 금리가 확실히 5%라면 1년 채권을 두 번 굴린 로그 수익은 $0.03 + 0.05 = 0.08$이다. 같은 2년 동안 지급액이 같은 2년 무이표채의 총 로그 수익도 0.08이어야 차익거래가 없으므로 연 금리는 $0.08/2 = 4\%$다. 불확실성이 있을 때는 내년 금리의 **기대값**으로 바꾸되, 위험 보상이 없다거나 일정하다는 추가 가정이 필요하다.

슬라이드 11 · 오늘 고정하는 미래 1년 금리

2년간 빌려주고 1년간 빌리면 첫해의 현금흐름이 상쇄되어 두 번째 해에만 돈을 빌려주는 거래가 남는다. 그 거래의 1년 선도금리는 $f_t^{(1,2)} = 2y_t^{(2)} - y_t^{(1)}$다. 1년 2%, 2년 3%이면 $2(3\%) - 2\% = 4\%$다. 이것은 **오늘 계약 가능한 금리**이지, 내년 실제 1년 금리의 무조건적 예측값은 아니다.

슬라이드 12 · spot 곡선과 forward 곡선

n년 가격과 $n-1$년 가격의 비율에서 마지막 한 해의 금리를 얻는다. 식을 1년부터 n년까지 더하면 중간 항이 소거되어 $n y_t^{(n)} = \sum_{j=1}^{n} f_t^{(j-1,j)}$다. 따라서 n년 spot 금리는 처음 n개 1년 선도금리의 평균이다. 새로 더해진 n번째 선도금리가 기존 평균보다 높아야 n년 금리가 $n-1$년 금리보다 오른다.

슬라이드 13 · 선도금리의 기대와 보상

2년물 선도금리를 $f_t^{(1,2)} = E_t[y_{t+1}^{(1)}] + \pi_t^f$로 분해한다. 기대가설에서 $\pi_t^f = 0$이면 선도금리가 내년 단기금리의 예측값이다. 위험 보상이 있으면 π_t^f만큼 선도금리가 기대 단기금리보다 높을 수 있다. 오늘 1년 금리보다 선도금리가 높다는 관찰만으로 내년 단기금리 상승을 단정하면 이 두 항을 섞는 셈이다.

슬라이드 14 · 만기수익률과 1년 보유수익률

액면 100의 3년 무이표채를 금리 5%에 사면 가격은 $100e^{-3(0.05)} \approx 86.07$이다. 1년 뒤 남은 만기 2년의 금리가 7%라면 매도가격은 $100e^{-2(0.07)} \approx 86.94$이고 로그 보유수익률은 $0.15 - 0.14 = 1\%$다. 금리가 5%면 $0.15 - 0.10 = 5\%$다. 처음 본 5%는 **3년 보유 시의 연 수익률**이고, 1년 보유수익률은 1년 뒤의 2년물 금리에 달린다.

비교 대상은 오늘 1년 채권으로 확정할 수 있는 $y_t^{(1)}$다. $rx_{t+1}^{(n)} = r_{t+1}^{(n)} - y_t^{(1)}$로 두면 위험을 더 떠안고 장기채를 선택한 대가를 측정한다.

슬라이드 15 · 기대가설 아래의 보유수익률

오늘 1·2·3년 금리가 각각 2·3·4%이면 둘째 해 선도금리는 4%, 셋째 해는 6%다. 위험 보상과 예상 밖 충격이 없을 때 내년 1년 금리는 4%, 내년 2년 금리는 $(4+6)/2 = 5\%$로 예상된다. 그러면 2년물의 예상 1년 수익은 $2(3) - 4 = 2\%$, 3년물은 $3(4) - 2(5) = 2\%$로 오늘 1년 금리와 같다. **실현 수익률까지 일정하다**는 뜻은 아니다. 내년 금리가 예상과 다르면 장기채 가격은 더 크게 움직인다.

슬라이드 16 · 기울기의 두 원인

n년 금리를 향후 n개 1년 단기금리 기대의 평균과 나머지 $\pi_t^{(n)}$로 나누어 보자. 기대가설은 나머지를 0 또는 일정한 값으로 제한한다. 같은 우상향 곡선도 단기금리 상승 전망만으로, 또는 단기금리 하락 전망보다 큰 위험 보상으로 만들어질 수 있다. 곡선 모양을 통화정책 전망으로 직역하지 말아야 하는 이유다.

슬라이드 17 · term spread와 risk premium

향후 단기금리 기대의 평균을 $A_t^{(n)}$로 쓰면 장단기금리차를 짧게 전개할 수 있다.

$$A_t^{(n)} \equiv \frac{1}{n}\sum_{j=0}^{n-1} E_t[y_{t+j}^{(1)}],$$

$$y_t^{(n)} - y_t^{(1)} = (A_t^{(n)} - y_t^{(1)}) + \pi_t^{(n)}.$$

왼쪽은 **관찰되는 term spread**, 첫 괄호는 기대 단기금리의 변화, 마지막은 기대 경로를 뺀 잔여 보상이다. 슬라이드에서는 왼쪽을 term premium이라고 부르지만, 채권 문헌에서 term premium을 마지막 $\pi_t^{(n)}$의 뜻으로 쓰는 경우도 많다. 이름보다 식에서 어느 항을 말하는지 확인하는 편이 안전하다.

슬라이드 18 · 기대 초과수익률의 정확한 크기

2년물 금리를 $y_t^{(2)} = \{y_t^{(1)} + E_t[y_{t+1}^{(1)}]\}/2 + \pi_t$라 두자. 1년 후 1년물로 팔 때의 초과수익률에 대입하면

$$\begin{aligned} rx_{t+1}^{(2)} &= 2y_t^{(2)} - y_{t+1}^{(1)} - y_t^{(1)} \\ &= 2\pi_t + E_t[y_{t+1}^{(1)}] - y_{t+1}^{(1)}, \\ E_t[rx_{t+1}^{(2)}] &= 2\pi_t = f_t^{(1,2)} - E_t[y_{t+1}^{(1)}]. \end{aligned}$$

둘째 줄의 마지막 두 항은 예측 오차라 조건부 평균이 0이다. **수익률에 대한 위험 보상**은 $2\pi_t$이고, π_t는 2년물 금리에 연 단위로 나누어 들어간 부분이다. 둘을 같은 숫자로 놓으면 만기 배율을 잃는다. 슬라이드 표본의 장기 평균에서 2년물 선도 스프레드 약 0.39%포인트와 실현 초과수익률 약 0.39%는 일치하지만, 이는 **기간 평균**이지 매달 정확히 같은 수익을 얻었다는 뜻은 아니다.

슬라이드 19 · 장기채의 1년 가격 위험

10년 무이표채를 1년 뒤 9년물로 팔면 그 사이의 금리 변화가 가격에 크게 반영된다. 작은 금리 변화 Δy에 대해 가격의 로그 변화는 대략 $-9\Delta y$이므로, 남은 만기가 길수록 같은 1%포인트 금리 충격이 수익률에 크게 작용한다. 국채의 **만기 지급 위험이 작다**는 말과 **중간 매도 가격이 안정적이다**는 말은 다르다.

슬라이드 20 · 스프레드의 회계적 분해

2년물은 $rx_{t+1}^{(2)} = f_t^{(1,2)} - y_{t+1}^{(1)}$이므로 다음 항등식이 성립한다.

$$f_t^{(1,2)} - y_t^{(1)} = \left(y_{t+1}^{(1)} - y_t^{(1)}\right) + rx_{t+1}^{(2)}.$$

오늘 아는 선도 스프레드가 2%포인트일 때 내년 단기금리가 정확히 2%포인트 오르면 초과수익은 0이고, 단기금리가 그대로면 초과수익은 2%다. 실제로는 두 몫이 섞인다. 따라서 스프레드가 미래 금리 변화를 더 잘 예측하는지, 장기채 보상을 더 잘 예측하는지 자료로 살핀다.

슬라이드 21 · Fama–Bliss 회귀 읽기

$rx_{t+1}^{(n)} = \alpha + \beta\{f_t^{(n-1,n)} - y_t^{(1)}\} + \varepsilon_{t+1}$를 추정한다. $\beta = 0$이면 스프레드의 움직임이 초과수익률과 관계없고, $\beta = 1$이면 스프레드 변화가 거의 전부 보상 쪽에 나타난다. 2년물의 항등식에서 금리변화 회귀계수와 초과수익률 회귀계수의 합은 정확히 1이어야 한다. 표본의 값 0.24와 0.76이 그렇게 더해진다. 5년물의 추정치 1.16은 0보다 크지만, $R^2 \approx 0.09$라 개별 연도 수익률의 대부분은 여전히 설명하지 못한다. **예측 방향의 유의성**과 **예측오차의 크기**는 다른 질문이다.

슬라이드 22 · 한국 국고채에서의 적용

한국 국고채 자료의 5년물 회귀에서는 기울기 약 1.75, $R^2 \approx 0.15$가 관찰된다. 1을 넘는다는 것은 선도 스프레드가 넓은 때 향후 단기금리가 오르기보다 내려가는 경향까지 함께 추정된다는 뜻이다. 다만 지표금리는 쿠폰채 시장에서 얻으므로 무이표 금리로의 변환이 필요하고, 일부 만

기는 과거 구간에서 보간된다. 표본을 2010년 이후로 좁히면 같은 결과가 뚜렷하지 않으므로 한국의 보편적 법칙으로 일반화하지 않는다.

슬라이드 23 · 선도금리 전체에서 찾는 공통 요인

한 채권에 선도 스프레드 하나만 쓰면 오늘의 곡선이 담은 나머지 정보를 버린다. Cochrane–Piazzesi[55]는 2~5년물 평균 초과수익률을 여러 선도금리에 함께 회귀하고, 계수의 **가운데가 솟은 조합**을 예측 요인으로 만들었다. 표본내 R^2는 약 0.35로 단일 스프레드의 약 0.09~0.18보다 높다. 그 요인 하나를 만기별 계수로 확대하면 여러 채권의 초과수익률을 함께 예측한다. 이는 각 만기의 기대수익률이 완전히 같다는 뜻이 아니라, 움직이는 공통 성분이 크다는 뜻이다.

슬라이드 24 · CP 결과의 표본 의존성

원 논문의 연도에 맞추면 tent 모양과 표본내 $R^2 \approx 0.31$이 어느 정도 재현된다. 기간을 뒤로 늘리거나 1990년 이후만 쓰면 설명력은 약 0.18로 낮아지고 계수 모양도 바뀐다. **원 논문의 그림이 다른 금리 추정 자료와 다른 기간에도 그대로 나타나는가**는 별도 검증이다. 반면 만기가 길수록 공통 요인의 수익률 반응이 커지는 패턴은 비교적 남는다. 표본내 R^2를 미래 예측 성과로 읽지 않는다.

슬라이드 25 · PCA가 보는 것은 금리의 분산

만기별 금리 벡터 y_t의 주성분은 $z_{k,t} = w_k^\top (y_t - \bar{y})$다. 첫 가중치 w_1은 $\|w_1\| = 1$ 아래 $\mathrm{Var}(z_1)$을 최대화하고, 다음 가중치는 앞의 것들과 직교하면서 남은 분산을 최대화한다. 그래서 흔히 수준·기울기·곡률에 해당하는 세 방향이 나온다. 이 자료의 금리 변동에서 셋의 비중은 각각 약 98.6%, 1.3%, 0.1%다. 그러나 최적화 대상은 **오늘 금리의 분산**이지 내년 채권 수익률의 예측오차가 아니다.

슬라이드 26 · 분산이 작은 요인의 예측력

수준 요인만 쓰면 평균 초과수익률의 R^2가 약 0.02지만 기울기를 더하면 0.24, 곡률까지 더하면 0.25가 된다. 네 번째 주성분은 금리 변동의 약 0.01%만 차지해도 원 표본에서는 R^2를 약 0.06 더한다. PCA가 분산순으로 정렬한다고 해서 예측력순으로 정렬되는 것은 아니다. 이 작은 성분의 추가 설명력은 뒤의 기간에서 유지되지 않아 **기간을 바꾼 검증**이 특히 중요하다.

슬라이드 27 · 금리에서 거의 안 보이는 예측 요인

CP 요인을 금리 자체의 가중합으로 바꾸면 전형적인 수준·기울기·곡률과 다른 작은 굴곡을 강조한다. 이것이 말하는 것은 평균 금리가 거의 움직이지 않아도 만기 사이의 미세한 상대가격이 기대 초과수익률 정보를 담을 수 있다는 점이다. 작은 금리 변화가 큰 수익률 예측으로 이어질 수 있어 측정오차와 곡선 평활화 방식이 중요하다.

[55] https://doi.org/10.1257/0002828053828581

슬라이드 28 · 곡선 적합과 프리미엄 예측의 차이

세 주성분이 오늘의 곡선을 거의 완벽하게 재현해도, 버린 작은 성분에 미래 수익률 정보가 남을 수 있다. **금리 재구성오차가 작다**는 사실만으로 **수익률 예측에 충분하다**고 결론 낼 수 없다. 다음 절은 다른 질문을 던진다. 곡선에 담긴 모든 성분을 허용해도 거시 변수의 정보가 추가로 남는가?

슬라이드 29 · 위험 보상과 볼록성의 유도

2년물 가격을 $P_t^{(2)} = e^{-y_t^{(1)}} E_t[P_{t+1}^{(1)}] e^{-\lambda}$로 놓자. 미래 1년 금리가 평균 μ, 분산 V의 정규분포라면 $P_{t+1}^{(1)} = e^{-y_{t+1}^{(1)}}$와 정규분포의 지수 적률에서 $E_t[P_{t+1}^{(1)}] = e^{-\mu + V/2}$다. 양변에 로그를 취해 정리하면

$$
\begin{aligned}
y_t^{(2)} &= \frac{y_t^{(1)} + \mu}{2} + \frac{\lambda}{2} - \frac{V}{4}, \\
E_t[rx_{t+1}^{(2)}] &= \lambda - \frac{V}{2}.
\end{aligned}
$$

λ는 요구 보상으로 장기 금리를 올린다. $-V/4$는 **볼록성 효과**다. 금리가 내려가 가격이 오르는 폭이 같은 크기의 금리 상승 때 가격이 내리는 폭보다 커서, 미래 금리가 더 불안정하면 미래 가격의 기대값이 올라간다. 이 가격 이익이 오늘 장기 금리를 낮춘다. 위험 보상과 볼록성은 서로 다른 힘이다.

슬라이드 30 · 금리 기울기와 수익률 항등식

로그 가격을 대입하고 항을 묶으면

$$
\begin{aligned}
rx_{t+1}^{(n)} = y_t^{(n)} - y_t^{(1)} \\
\quad - (n-1)\big(y_{t+1}^{(n-1)} - y_t^{(n)}\big).
\end{aligned}
$$

오늘 기울기가 높은데 이후 장기 금리가 그만큼 오르지 않으면 장기채의 초과수익률이 높다. 기대가설은 금리 변화가 기울기를 상쇄한다고 본다. Campbell–Shiller(1991)[56]의 회귀는 이 상쇄가 실제로 일어나는지 묻는다. 금리 변화를 예측하는 외부 변수도 이 항등식을 통해 채권 초과수익률 예측에 연결된다.

슬라이드 31 · 스패닝 가설로 넘어가기

수익률곡선은 오늘 채권 가격들의 집합이다. 이제 질문은 **이 곡선을 충분히 알고도** 산업생산·고용·물가 같은 거시 변수에서 미래 채권 수익률에 관한 추가 정보를 얻을 수 있는가이다. 이는 곡선이 거시경제를 완전히 설명하느냐는 질문과 다르다. 검정 대상은 어디까지나 **조건부 기대 초과수익률**이다.

[56] https://doi.org/10.2307/2298008

슬라이드 32 · 스패닝의 수학적 조건

아핀 기간구조 모형에서 만기별 금리 벡터를 $y_t = A + Bx_t$로 쓴다. x_t는 금리와 위험 보상을 결정하는 K개 상태변수, B는 만기별 반응을 모은 행렬이다. 관측한 금리가 K개 이상이고 B의 열이 서로 독립이면 $x_t = (B^\top B)^{-1} B^\top (y_t - A)$로 상태를 복원할 수 있다. 기대 초과수익률이 x_t의 함수라면 오늘의 곡선만으로도 그 기대값을 표현할 수 있다.

이것이 스패닝(spanning)의 직관이다. 다만 **수준·기울기·곡률 세 개만 쓰는 검정**은 완전한 곡선의 스패닝보다 강한 차원 축소 가정까지 얹는다. 작은 네 번째 요인이 중요하면 세 주성분 검정의 기각은 완전한 스패닝의 기각과 같지 않다.

슬라이드 33 · 성립하는 이유와 깨지는 두 길

경쟁적인 투자자가 오늘 얻을 수 있는 정보로 채권을 평가한다면, 미래 단기금리나 위험 보상에 중요한 상태는 현재 가격에 반영될 가능성이 있다. 그러나 어떤 거시 충격이 기대 단기금리를 높이면서 위험 보상을 같은 크기로 낮추면 **오늘 금리는 그대로인데 기대 보유수익률은 변할 수 있다**. 또 가격에는 반영되어 있어도 영향이 매우 작아 금리 측정오차나 곡선 평활화가 그 신호를 가릴 수 있다. 경제적 비스패닝과 통계적 측정 문제를 구별해야 한다.

슬라이드 34 · 거시 요인이 추가한 표본내 설명력

Ludvigson–Ng(2009)[57]는 많은 거시 시계열을 소수 요인으로 압축해 선도금리 요인에 더했다. 실물활동과 물가 관련 요인을 넣자 2년물 초과수익률 회귀의 수정 R^2가 약 0.26에서 0.45로 올랐다. 이는 **이미 본 기간의 수익률 변동**을 더 설명한다는 결과다. 추가 요인이 실제로 곡선 밖 정보를 담는지 판단하려면 높은 지속성과 중첩 수익률 때문에 왜곡될 수 있는 검정, 그리고 이후 기간의 예측력을 따로 살펴야 한다.

슬라이드 35 · 모형 속의 비스패닝 거시 위험

Joslin–Priebsch–Singleton(2014)[58]은 성장률·인플레이션 같은 거시 상태가 미래 금리와 프리미엄의 움직임을 예측하지만 현재 수익률곡선에는 직접 나타나지 않는 모형을 제시했다. 이런 상태는 **가격에는 안 보이지만 기대수익률에는 보이는** unspanned risk다. 오늘 금리에서 성장률을 잘 복원하지 못한다는 사실만으로 그 성장이 채권 수익률을 예측한다고 결론 낼 수는 없다. 두 관계를 모두 검정해야 한다.

슬라이드 36 · 월마다 측정한 1년 수익률의 중첩

t월부터 12개월간의 수익률과 $t+1$월부터 12개월간의 수익률은 11개월의 경제적 충격을 공유한다. 독립적인 월별 충격을 단순 합산해도 이 두 값의 상관은 대략 $11/12 \approx 0.92$다. 월별 관측치 480개를 독립된 연간 경험 480개처럼 취급하면 표준오차가 작아진다. 다만 "독립적인 40년"은 중첩의 크기를 이해시키는 근사이며, 정확한 유효 표본수는 자기상관 구조에 달려 있다.

이 강한 중첩은 날짜를 잘못 붙인 학습행 하나가 미래 정답과 거의 같은 정보를 담게 하는 이유이기도 하다. 같은 표본을 **추론**과 **예측 파이프라인**에서 각각 다르게 위험하게 만든다.

[57] https://doi.org/10.1093/rfs/hhp081
[58] https://doi.org/10.1111/jofi.12131

슬라이드 37 · 소표본 추론에 대한 반론

Bauer–Hamilton(2018)[59]은 지속적인 거시 설명변수, 지속적인 금리 요인, 중첩된 연간 수익률을 함께 쓰면 보통의 유의성 검정이 실제보다 자주 스패닝을 기각할 수 있음을 보였다. 스패닝이 참인 자료를 만들어 동일한 회귀를 반복하는 bootstrap은 **귀무가설이 참일 때도 이 정도 t값이 얼마나 자주 나오는가**를 직접 추정한다. 연구가 재검토한 검정에서는 명목 5%의 실제 기각률이 8~61%로 나타났다. 따라서 $p < 0.05$만으로 추가 예측변수를 확립할 수 없다. 원래의 거시변수 효과가 완전히 없다는 증명도 아니다.

슬라이드 38 · 거짓 양성을 보여 주는 모의실험

모의실험에서는 채권 기대수익률을 세 금리 요인만 결정하게 만들고, 추가 거시 변수의 진짜 계수를 정확히 0으로 둔다. 그런데 지속계수 $\rho = 0.99$인 거시 변수와 중첩 1년 수익률을 함께 쓰면 2,000번 반복 중 약 19%에서 $|t| > 1.96$이 나온다. 거시 변수를 매달 독립으로 만들면 약 7%, 중첩하지 않는 월별 수익률로 바꾸면 약 9%다. 이 수치는 **설계된 예시의 기각률**이지 모든 채권 회귀에서 19%의 오류가 난다는 일반 법칙이 아니다.

슬라이드 39 · 왜 Newey–West만으로 끝나지 않는가

Newey–West 표준오차는 이웃한 오차들이 함께 움직이는 공분산을 더해 큰 표본에서 유효한 분산을 추정한다. 지속적인 예측변수와 중첩 수익률이 있는 짧은 기간에서는 그 큰 표본 근사가 충분히 정확하지 않을 수 있다. 따라서 표본내 유의성만으로 스패닝을 기각하지 말고, 날짜를 지킨 표본외 예측에서 기존 곡선 모형의 오차가 줄어드는지도 보아야 한다. 표본외 평가 역시 데이터 구성에 미래 정보가 섞이지 않았다는 확인이 선행돼야 한다.

슬라이드 40 · 금리 변화 없이 움직이는 프리미엄

$y_t^{(n)} = n^{-1}\sum_{j=0}^{n-1} E_t[y_{t+j}^{(1)}] + \pi_t^{(n)}$라 하자. 거시 상태 m_t가 바뀔 때 첫 항의 변화와 $\pi_t^{(n)}$의 변화가 정확히 반대면 $\partial y_t^{(n)}/\partial m_t = 0$이면서 $\partial \pi_t^{(n)}/\partial m_t \neq 0$일 수 있다. 그 거시 상태는 오늘의 금리에서 복원되지 않지만 기대수익률에는 중요하다. 반대로 금리에 작은 측정오차가 있으면 **원래 곡선에 담긴 상태도** 복원이 불완전해져 겉보기 비스패닝이 생긴다.

슬라이드 41 · 중첩 오차의 표준오차

평균적인 예측오차 $\bar{u}$의 분산을 생각하면 독립 표본에서는 대략 γ_0/T지만, 월별 12개월 수익률의 오차에는 여러 시차의 공분산 $\gamma_k = \mathrm{Cov}(u_t, u_{t-k})$가 더해진다. 예를 들어 Bartlett 가중치를 쓰는 추정은

$$\widehat{\mathrm{Var}}(\bar{u}) = \frac{1}{T}\left(\hat{\gamma}_0 + 2\sum_{k=1}^{L} w_k \hat{\gamma}_k\right),$$
$$w_k = 1 - \frac{k}{L+1}.$$

[59] https://doi.org/10.1093/rfs/hhx096

형태다. 양의 자기상관을 무시하면 분산을 낮게 본다. Hansen–Hodrick은 관련 시차를 가중치 없이 합치고, Newey–West는 먼 시차를 점차 낮게 가중한다. 어느 방법도 지속적인 설명변수의 소표본 왜곡까지 자동으로 해결하지는 않는다.

슬라이드 42 · 곡선에 머신러닝을 적용하기

스패닝 논쟁은 거시 변수가 곡선을 **선형으로 통제한 뒤**에도 유용한가에서 출발했다. 곡선 자체의 비선형 관계를 놓친 것이 원인이라면 거시 변수의 이득이 과장될 수 있다. 이 절에서는 같은 예측 시점에 이용 가능한 금리와 거시 자료를 넣어, 선형·나무·신경망을 동일한 미래 기간에서 비교하는 설계를 살핀다.

슬라이드 43 · 채권 기대수익률 함수의 형태

상태벡터 x_t를 알 때 만기 n의 기대 초과수익률을 $E_t[rx_{t+1}^{(n)}] = g_n(x_t)$로 쓴다. 아핀 모형은 g_n을 대체로 선형으로 제한하지만, 금리 하한 근처나 경기 국면별로 위험 보상이 달라지면 같은 선형 기울기로 설명하기 어렵다. 머신러닝은 g_n의 형태를 유연하게 추정한다. 유연성이 새 경제 정보를 만들어 주지는 않는다. **곡선만으로 비선형성을 허용한 뒤에도 거시 입력이 오차를 줄이는가**가 스패닝의 실증 질문이다.

슬라이드 44 · 입력과 목표의 시점

입력의 첫 묶음은 오늘의 1년 금리와 2년째부터 10년째까지의 1년 선도금리 아홉 개다. 둘째 묶음에는 생산·고용·물가·금융시장 등의 월별 거시 시계열을 더한다. 목표는 2·3·4·5·7·10년 국채를 **앞으로 1년** 보유했을 때의 초과수익률이다. 앞 절의 $t+1$은 1년 후를 뜻했지만 월별 실증 자료에서는 같은 시점을 $t+12$로 쓴다. FRED-MD[60] 같은 자료를 사용할 때 각 시계열의 발표 시점과 사후 수정(revision)을 확인해야 한다. t월에 관찰 가능하지 않은 값은 t월 예측의 입력이 될 수 없다.

슬라이드 45 · 시간 순서를 지키는 평가

예측 시작월 t부터 12개월간의 초과수익률을 R_t, 그달에 만든 예측을 $\hat{R}_t$라고 쓰자. 표본외 R^2는 과거 평균 예측의 제곱오차를 기준으로 모형의 제곱오차가 얼마나 줄었는지 측정한다.

$$R^2_{\text{OOS}} = 1 - \frac{\sum_{t\in\mathcal{T}}(R_t - \hat{R}_t)^2}{\sum_{t\in\mathcal{T}}(R_t - \bar{R}_{t,\text{past}})^2}.$$

매달 학습창을 늘리고 그 안의 앞 기간으로 모수를, 뒤 기간으로 초매개변수를 고른 뒤 다음 예측을 만든다. $\bar{R}_{t,\text{past}}$도 **그 시점까지 수익률이 완전히 실현된 과거**에서 계산해야 한다. 분모가 잘못 미래를 포함하면 점수 자체가 오염된다. 이 점은 뒤의 정정문에서 핵심이 된다.

슬라이드 46 · 극단 랜덤 트리의 분할

보통 회귀나무는 한 마디에서 가능한 특성과 분할점을 많이 시험해 제곱오차가 가장 작아지는 질문을 고른다. 극단 랜덤 트리(Extra Trees)는 후보 특성마다 분할점을 무작위로 뽑은 뒤 그 후

[60] https://www.stlouisfed.org/research/economists/mccracken/fred-databases

보 중 좋은 질문을 택한다. 예를 들어 선도 스프레드를 1.88%에서 자르는 대신 몇 개의 임의 경계로 나누어 본다. 하나의 최적 경계에 과거 잡음이 반영되는 위험을 낮추는 대신, 나무 한 그루의 적합도는 약해질 수 있다.

슬라이드 47 · 여러 나무의 평균

새 무작위 분할점을 사용해 여러 나무를 만들고 예측을 평균한다. 예시의 200그루는 한 나무의 들쭉날쭉한 계단을 부드럽게 만든다. Random forest는 보통 관측치를 bootstrap으로 다시 뽑고 후보 특성도 무작위로 제한하는 반면, Extra Trees는 분할 경계 자체를 무작위로 만들며 구현에 따라 원 표본 전체를 쓴다. 둘 다 **나무 사이 오차의 상관을 낮추고 평균으로 분산을 줄인다**는 목적을 공유한다.

슬라이드 48 · 무작위성이 예측을 돕는 조건

나무 B그루의 오차 분산이 각각 σ^2, 두 나무 사이 상관이 ρ라면 평균 오차의 분산은 대략 $\sigma^2\{\rho + (1-\rho)/B\}$다. 평균의 분산에 들어가는 자기 분산 B개와 나무 사이 공분산 $B(B-1)$개를 각각 B^2로 나누면 이 식이 나온다. 그루 수를 늘려도 ρ가 높으면 분산이 크게 줄지 않는다. 무작위 분할은 개별 나무를 다소 약하게 하더라도 나무 사이의 닮음을 줄일 수 있다. 원 논문의 높은 Extra Trees 성과는 **정정 전 숫자**여서 마지막 절의 결과로 평가해야 한다.

슬라이드 49 · 순방향망과 순환망의 정보 집합

순방향망은 $h_t = \phi(W x_t + b)$, $\hat{y}_t = v^{\mathsf{T}} h_t$처럼 그 시점의 입력에서 출력을 만든다. 순환망은 $h_t = \phi(W x_t + U h_{t-1} + b)$로 지난달의 은닉상태도 사용한다. 따라서 현재 곡선이 같아도 과거 경로가 다르면 순환망의 예측은 달라질 수 있다. 이것은 **과거가 현재 곡선에 모두 요약되어 있는가**라는 스패닝 질문과 직접 연결된다.

슬라이드 50 · 순환망의 이득과 비용

순환망은 시간 순서가 중요한 자료에서 과거 입력을 스스로 압축한다. 같은 가중치를 여러 시점에 반복 적용하므로 학습 때는 시간을 따라 펼쳐 역전파한다. 긴 수열에서 기울기가 작아지는 문제를 LSTM·GRU의 gate가 완화한다. 월별 채권 자료에서는 관측 기간이 짧고 현재 곡선이 과거의 일부 정보를 이미 요약할 수 있어, 추가 기억 능력이 모수 증가를 정당화하는지는 **표본 외 비교**로 판단해야 한다. 순환망이 원리상 정보를 더할 수 없다는 뜻은 아니다.

슬라이드 51 · 작은 채권 자료와 작은 신경망

주식의 종목×월 패널과 달리 국채 수익률곡선은 한 달에 곡선 한 개다. 입력 10개와 초기 학습 기간 약 178개월에서 거대한 망을 쓰면 조정할 가중치 수에 비해 독립적인 시간 정보가 부족하다. 은닉 단위 3개, 출력 만기 6개인 가장 작은 순방향망의 가중치와 절편은 $10 \times 3 + 3 + 3 \times 6 + 6 = 57$개다. **57개 모수와 178개월**도 넉넉한 비율은 아니므로 정규화와 시간순 검증이 중요하다.

슬라이드 52 · Dropout·벌점·조기 종료

Dropout은 학습 중 은닉 단위 일부를 무작위로 꺼 특정 단위의 동시 작동에 지나치게 기대지 않게 한다. ℓ_1 또는 ℓ_2 벌점은 큰 가중치의 비용을 높여 모형을 단순하게 만들고, 조기 종료는 학습 오차가 계속 내려가도 **검증 오차가 개선되지 않으면** 학습을 멈춘다. 세 방법은 우연한 과거 패턴을 외우는 정도를 줄이지만, 잘못 만들어진 목표 수익률에 미래 가격이 들어온 문제는 해결하지 못한다.

슬라이드 53 · 여러 초기값을 평균하는 이유

신경망의 목적함수는 비볼록이어서 초기 가중치가 달라지면 다른 예측에 도달할 수 있다. 자료가 적을수록 이 차이는 커진다. 연구는 예측 시점마다 여러 초기값으로 학습한 뒤 검증 손실이 좋은 일부 모형의 예측을 평균한다. 이는 한 번의 무작위 시작에 좌우되는 결과를 줄인다. 다만 같은 검증 기간을 여러 번 사용해 **가장 좋은 시작과 구조를 고르는 선택 효과**는 남으므로, 정정문이 제시한 전체 구조의 평균 성과도 함께 읽어야 한다.

슬라이드 54 · 하이브리드망: 곡선은 선형, 거시는 비선형

하이브리드 구조의 예측을 $\hat{r x} = b^{\top} f + h(m)$로 쓸 수 있다. f는 선도금리, m은 거시 변수, h는 신경망이다. 곡선의 효과는 선형으로 고정하고 거시 변수의 비선형 효과만 학습한다. 따라서 이 모형이 거시 입력에서 이득을 보이면 **곡선을 선형으로 제한했기 때문일 가능성**도 남는다. 곡선 자체를 비선형으로 허용한 모형과 비교해야 한다.

슬라이드 55 · 두 망을 더하는 구조

$\hat{r x} = g(f) + h(m)$에서는 선도금리와 거시 변수에 각각 작은 신경망을 적용하고 출력을 더한다. 두 묶음 안에서는 비선형 관계를 표현하지만, 예를 들어 **경기침체일 때만 기울기의 효과가 달라진다**는 교차 상호작용은 직접 표현하지 못한다. 그 제한 덕분에 입력 138개를 한꺼번에 완전연결하는 망보다 모수가 적다. 정확도와 해석 가능성 사이의 모델링 선택이다.

슬라이드 56 · 경제 그룹별 신경망

생산·고용·물가 등 경제적으로 가까운 변수끼리 작은 망을 만들고, 각 망의 출력을 더하는 구조다. 수식으로는 $\hat{r x} = g_f(f) + \sum_{k=1}^{K} g_k(m_k)$다. 한 그룹 안의 변수는 복잡하게 상호작용할 수 있지만 그룹 사이 상호작용은 제한된다. 여러 예측기를 합친다는 뜻의 ensemble과, 그룹 효과를 합한다는 뜻의 additive structure가 함께 들어 있다.

슬라이드 57 · 경제적 사전 지식의 역할

그룹 사이 연결을 막으면 신경망이 시도할 수 있는 함수가 줄어든다. 생산과 물가의 복잡한 교차효과가 실제로 중요하다면 손해지만, 짧은 시계열에서 그 효과를 안정적으로 추정하기 어렵다면 오히려 표본외 오차가 낮아질 수 있다. 비교한 구조의 모수는 그룹망 약 250개, 큰 하이브리드망 약 4,900개다. **경제 이론이 어떤 상호작용을 허용할지 정하는 것**도 정규화의 한 형태다.

슬라이드 58 · 정정 전: 곡선만 사용한 결과

원 논문의 발표 수치에서는 선형 모형의 표본외 R^2가 약 0~1%인 반면 Extra Trees 17.9%, 가장 좋은 신경망 23.0%였다. 이 표만 보면 곡선에 비선형성을 허용하는 이득이 크다. 그러나 이 값은 미래 수익률이 학습에 섞였던 **정정 전 결과**다. 특히 나무 모형의 우수성은 정정 뒤 유지되지 않았다. 결과 표를 읽을 때 모형 순위보다 먼저 데이터의 시점이 맞는지 확인한다.

슬라이드 59 · 정정 전: 거시 변수를 더한 결과

원 논문에서는 곡선과 거시 변수를 함께 쓴 그룹 앙상블의 R^2가 34.0%로, 곡선만 쓴 최고 신경망 23.0%를 넘었다. 같은 데이터 구축 오류가 두 실험에 영향을 주었으므로 **34.0과 23.0의 차이**를 깨끗한 거시 변수의 기여라고 확정할 수 없다. 다음 절의 정정 수치에서 이득이 남는지 확인해야 한다.

슬라이드 60 · 경사하강과 momentum

학습 손실을 $L(\theta)$라 하면 경사하강은 가중치 θ를 $-\eta\nabla L(\theta)$ 방향으로 조금 이동시킨다. η는 learning rate다. Momentum은 이전 이동 방향을 누적해 같은 방향의 작은 기울기를 키우고 방향이 자주 바뀌는 움직임을 줄인다. Nesterov 방식은 **현재 위치에서가 아니라 관성으로 향할 위치를 미리 보고** 기울기를 계산한다. 최적화 알고리즘은 주어진 학습 자료에서 손실을 낮추는 방법일 뿐, 미래 정보가 섞인 자료를 고쳐 주지 못한다.

슬라이드 61 · 초기화·정규화·공동 출력

ReLU 은닉층의 He 초기화는 입력 연결 수가 d일 때 가중치 분산을 대략 $2/d$로 잡아 층을 통과하는 신호 규모가 지나치게 커지거나 작아지는 것을 줄인다. Batch normalization은 묶음별 활성값을 표준화한 뒤 학습된 척도와 위치를 적용한다. 출력 노드 여섯 개는 같은 은닉표현에서 만기 2·3·4·5·7·10년의 수익률을 함께 예측한다. 만기마다 완전히 별개의 망을 학습하는 것보다 공통 정보를 공유한다는 장점이 있으나, 모든 만기의 위험 보상 함수가 같다는 뜻은 아니다.

슬라이드 62 · 조정 범위와 모수 수

Dropout 비율, 벌점 강도, 학습 중단 시점, 층과 단위 수를 검증 기간에서 고른다. 모형 구조가 커질수록 표현력은 늘지만 초기에 완전히 관찰된 학습 기간은 약 178개월뿐이다. 약 57개 모수의 작은 곡선망과 수천 모수의 큰 거시 망을 같은 자료 크기에서 비교할 때는 **훈련 오차가 아니라 미래 예측오차**가 기준이다. 여러 시작값의 평균은 최적화의 불안정성을 낮추지만, 같은 검증 블록에서 많은 구조를 반복 선택하는 문제까지 없애지는 않는다.

슬라이드 63 · 정정 전 해석의 지위

원 논문은 은닉 단위가 미래 금리 수준·기울기를 설명하고, 어떤 거시 변수군이 만기별로 중요한지 분석했다. 예를 들어 예측 함수를 입력에 대해 미분해 민감도를 변수 중요도로 읽었다. 하지만 그 분석은 오류가 있던 예측 결과 위에서 이루어졌고, 정정문은 일부 핵심 성과표를 다시 계산했을 뿐 이러한 메커니즘 표를 모두 재검증하지 않았다. 따라서 **흥미로운 가설**로는 읽되, 정정 후에도 확립된 경제적 사실로 인용하지 않는다.

슬라이드 64 · 정정문이 바꾸는 질문

앞의 높은 표본외 성과가 실제로 미래를 맞힌 것인지부터 다시 확인한다. 정정문[61]은 예측 시점에 아직 실현되지 않은 1년 채권 수익률 한 행이 학습창에 들어갔음을 밝힌다. 이 절은 오류의 날짜, 왜 중첩 수익률에서 영향이 컸는지, 다시 계산한 성과 중 무엇이 남았는지를 순서대로 살핀다.

슬라이드 65 · 누출된 한 행의 날짜

t월 말에 $t \to t+12$ 수익률을 예측한다고 하자. 학습에 쓸 수 있는 가장 최근 1년 수익률은 $t-12 \to t$**까지**다. 원 코드에는 $t-1 \to t+11$ 수익률이 들어갔다. 이 값은 예측 시점보다 11개월 뒤의 가격이 있어야 계산된다. 목표 $t \to t+12$와 12개월 중 11개월을 겹치므로 강한 상관을 가진다. 잘못된 행이 매달 새 학습창에 다시 들어가면 하나의 오탈자 수준을 넘어 예측 성과 전체를 밀어 올릴 수 있다.

과거 평균 benchmark도 완전히 실현된 수익률만으로 계산해야 한다. 입력 변수와 목표뿐 아니라 **비교 기준의 날짜**까지 감사해야 하는 이유다.

슬라이드 66 · 정정 후 곡선만 쓴 결과

곡선만 입력한 최고 신경망의 표본외 R^2는 정정 전 23.0%에서 6.2%로 낮아졌다. 여러 신경망의 예측을 평균하면 4.9%다. 선형·나무 계열의 점수는 이 비교에서 대부분 0 아래로 내려가 과거 평균 예측보다 큰 제곱오차를 냈다. $R^2_{\text{OOS}} < 0$은 수익률이 음수라는 뜻이 아니라 **그 모형의 예측이 benchmark보다 못했다**는 뜻이다. 정정 전의 "나무가 크게 우수하다"는 결론은 유지되지 않는다.

슬라이드 67 · 거시 변수 효과의 정정 후 크기

같은 오류를 고친 뒤에도 거시 변수를 더한 신경망은 곡선만 쓴 신경망보다 좋은 성과를 냈다.

비교	곡선만	곡선 + 거시
1년, 최고 개별망	6.2%	19.6%
1년, 여러 망의 평균	4.9%	20.3%
중첩 없는 월간 수익률	1.4%	5.5%

원 논문의 그룹 앙상블 34.0%는 정정 뒤 13.3%가 되어 최고 구조도 바뀌었다. 표의 **여러 신경망 평균** 20.3%는 개별 구조를 사후에 고른 숫자보다 비교에 안정적이다. 월간 비중첩 실험의 거시 입력 이득은 중첩 1년 수익률의 누출이 결과를 전부 설명하지는 못함을 보여준다.

[61] https://doi.org/10.1093/rfs/hhaa098

슬라이드 68 · 예측 파이프라인의 시간 경계

시간순으로 학습·검증·시험을 나누어도, **나누기 전에 만든 행**에 미래 수익률이 포함돼 있으면 모든 블록이 오염될 수 있다. 목표를 계산하는 데 필요한 마지막 가격일, 거시 지표의 발표일, 사후 수정 여부를 각 행에 붙여 예측 기준일과 비교해야 한다. 또 스무 구조 가운데 최고 성과만 보고하면 우연히 잘 맞은 구조를 고르는 다중비교 문제가 생긴다. 구조 전체의 평균과 미리 정한 비교 지표를 함께 제시하는 이유다.

슬라이드 69 · 채권 수익률의 중첩이 보이지 않는 이유

주식의 12개월 수익률을 한 달씩 밀어 쓰면 같은 주가 경로의 11개월을 공유한다는 것이 눈에 보인다. 무이표채는 시간이 지나며 남은 만기가 줄어, n개월물의 12개월 수익률은 $P_{t+12}^{(n-12)}/P_t^{(n)}$처럼 **서로 다른 만기 가격**을 잇는다. 인접한 출발월의 식에는 동일한 가격 기호가 그대로 반복되지 않을 수 있지만, 경제적으로 거의 같은 금리 충격과 보유 구간을 공유한다. 수식의 가격 기호가 달라 보인다고 독립 표본으로 취급하면 안 된다. 수정된 학습창은 모든 수익률의 끝 시점이 예측 시점 이내가 되게 만든다.

슬라이드 70 · 검정 결과를 다시 묶기

이제 세 층을 분리할 수 있다. **가격 항등식**은 언제나 성립하고, Fama–Bliss·CP의 회귀는 특정 기간의 통계적 관계이며, 머신러닝의 표본외 성과는 데이터 생성과 코드의 시간 경계까지 맞아야 성립한다. 이 구분을 지키면 수익률곡선의 경제적 의미를 연구 결과의 강도에 맞춰 해석할 수 있다.

슬라이드 71 · 스패닝 논쟁의 현재 결론

정정 후 곡선만 사용한 신경망 평균 R^2 4.9%와 거시 변수를 더한 평균 20.3% 사이에는 뚜렷한 예측오차 차이가 남는다. 이는 **이 연구의 입력·기간·모형 집합에서** 거시 자료가 곡선 너머의 예측 정보를 제공한다는 증거다. Bauer–Hamilton의 소표본 t검정 비판과는 다른 종류의 근거지만, 표본외 점수도 표본 선택과 모형 비교의 불확실성에서 자유롭지 않다. 더구나 예측 이득만으로 거시 충격이 곡선에 전혀 반영되지 않는 구조적 unspanned risk라고 확정할 수는 없다.

슬라이드 72 · 채권 예측을 읽는 순서

첫째, 금리와 가격의 관계에서 선도금리·1년 초과수익률을 직접 계산한다. 둘째, 우상향 곡선의 **금리 기대와 위험 보상**을 분리한다. 셋째, PCA의 금리 설명력과 미래 수익률 예측력을 따로 평가한다. 넷째, 거시 변수의 추가 효과를 검정할 때 지속성·중첩·작은 표본을 살핀다. 마지막으로 표본외 결과를 읽기 전에 각 학습행의 정보 이용 가능일을 확인하고, 정정 전 최고 모형보다 **정정 후의 여러 모형 평균**을 중심에 둔다.