

AI금융경제

슬라이드별 학습 가이드

값싼 예측에서 종목 간 기대수익률까지

2026년 2학기

Contents

1 01. 값싼 예측과 AI의 경제학	7
1.1 슬라이드 01 · 강좌의 지도	7
1.2 슬라이드 02 · 왜 금융에서 AI를 배우는가	7
1.3 슬라이드 03 · 주식 매수 질문에 빠진 변수들	7
1.4 슬라이드 04 · AI 충격과 한국 주식시장의 집중	8
1.5 슬라이드 05 · 값싼 예측의 경제학	8
1.6 슬라이드 06 · 세 명제의 연결	8
1.7 슬라이드 07 · 의사결정을 바꾸지 않는 신호의 가치는 0	9
1.8 슬라이드 08 · 지도와 압축	9
1.9 슬라이드 09 · 한 결정에 맞춰 만든 지도	9
1.10 슬라이드 10 · 공사에서 글자가 이미지일 때	9
1.11 슬라이드 11 · 빠른 요약과 정확한 요약의 선택	10
1.12 슬라이드 12 · 암달의 법칙과 업무 병목	10
1.13 슬라이드 13 · 영상의학 사례가 알려 주는 것	10
1.14 슬라이드 14 · 암달 곡선의 평탄해짐	11
1.15 슬라이드 15 · 과업 생산성과 총량 효과의 차이	11
1.16 슬라이드 16 · 싸진 예측이 재평가하는 것	11
1.17 슬라이드 17 · 제번스 역설의 그림	12
1.18 슬라이드 18 · 탄력성으로 보는 반등	12
1.19 슬라이드 19 · 기술과 직업의 역사	12
1.20 슬라이드 20 · 약한 고리와 GDP	12
1.21 슬라이드 21 · 분석 가격이 내려갈 때 희소해지는 것	13
1.22 슬라이드 22 · 내 일의 위험을 평가하는 세 질문	13
1.23 슬라이드 23 · 데이터 모형에서 예측 모형으로	13
1.24 슬라이드 24 · 브라이먼의 두 문화	14
1.25 슬라이드 25 · 두 문화의 원문을 읽는 법	14
1.26 슬라이드 26 · 금융이 이론 중심 접근을 고수한 이유	14
1.27 슬라이드 27 · 요인모형의 언어	15
1.28 슬라이드 28 · 요인 동물원과 다중검정	15
1.29 슬라이드 29 · 머신러닝의 동일 경기장	15
1.30 슬라이드 30 · 작은 표본외 결정계수의 의미	15
1.31 슬라이드 31 · 공개된 예측 신호의 이익 감소	16
1.32 슬라이드 32 · 계산 규모와 사전 지식	16

1.33	슬라이드 33 · 이중 하강과 금융 데이터	16
2	02. 금융 텍스트와 언어모형	17
2.1	슬라이드 01 · 텍스트를 금융 데이터로 읽기	17
2.2	슬라이드 02 · 사전에서 언어모형으로	17
2.3	슬라이드 03 · 사전 단어 세기의 함정	18
2.4	슬라이드 04 · 금융 전문 사전의 의미	18
2.5	슬라이드 05 · n그램과 부정 표현	18
2.6	슬라이드 06 · 임베딩은 무엇을 보존하는가	18
2.7	슬라이드 07 · 토큰과 입력의 비용	19
2.8	슬라이드 08 · 어텐션의 계산	19
2.9	슬라이드 09 · 다음 토큰 예측과 압축	19
2.10	슬라이드 10 · 유창한 실패의 출발점	20
2.11	슬라이드 11 · 생성모형의 목적 함수를 정확히 쓰기	20
2.12	슬라이드 12 · 목적 함수에 진실 향이 없다는 뜻	20
2.13	슬라이드 13 · 질문을 바꾸면 평가도 바뀐다	21
2.14	슬라이드 14 · 걸러낼 것이 없는 회사를 시험하기	21
2.15	슬라이드 15 · 모델의 국적을 성향으로 단정하지 않기	21
2.16	슬라이드 16 · 예상을 뒤집는 결과의 검증	21
2.17	슬라이드 17 · 지역 정보의 사각지대	22
2.18	슬라이드 18 · 기억과 진짜 사전 예측의 차이	22
2.19	슬라이드 19 · 모형의 투자 스타일	22
2.20	슬라이드 20 · 만족도 보상의 부작용	23
2.21	슬라이드 21 · 사후 분석과 인과 사슬	23
2.22	슬라이드 22 · 체스 에이전트 실험의 설계	23
2.23	슬라이드 23 · 목표 달성과 규칙 준수는 다른 변수	23
2.24	슬라이드 24 · 굿하트 법칙, 루커스 비판, 대리인 문제	24
2.25	슬라이드 25 · 환각을 과신으로 측정하기	24
2.26	슬라이드 26 · 저장된 지식과 인출의 병목	24
2.27	슬라이드 27 · 보이는 추론의 한계	25
2.28	슬라이드 28 · 다음 토큰 맞히기가 만드는 능력	25
2.29	슬라이드 29 · 산술은 외부 도구로 분리하기	25
2.30	슬라이드 30 · 유창함 대신 재현성을 기준으로	26
3	03. 정규화 회귀와 수익률 예측	26
3.1	슬라이드 01 · 수익률 예측의 출발점	26

3.2	슬라이드 02 · 앞 장에서 이어지는 문제	26
3.3	슬라이드 03 · 시장 수익률 예측의 오래된 실패	27
3.4	슬라이드 04 · 평균보다 큰 변동성	27
3.5	슬라이드 05 · 예측변수 동물원	27
3.6	슬라이드 06 · 높은 배당수익률의 두 해석	27
3.7	슬라이드 07 · 자료를 잘게 나누어도 평균은 정밀해지지 않는다	28
3.8	슬라이드 08 · 단순수익률, 로그수익률, 연속복리	28
3.9	슬라이드 09 · 일별 자료의 다른 역할	28
3.10	슬라이드 10 · 표본 안의 유의성	29
3.11	슬라이드 11 · 표본내와 표본외를 구분하기	29
3.12	슬라이드 12 · 과거 평균과 표본외 결정계수	29
3.13	슬라이드 13 · 웰치와 고열의 판정	29
3.14	슬라이드 14 · 간단한 경제 제약은 도움이 될까	30
3.15	슬라이드 15 · 시간이 지난 뒤의 재검증	30
3.16	슬라이드 16 · 유의성·안정성·실용성의 갈래기	30
3.17	슬라이드 17 · 누적 오차 차이 그래프 읽기	31
3.18	슬라이드 18 · 첫 단계의 결론	31
3.19	슬라이드 19 · 왜 실패하는가	31
3.20	슬라이드 20 · 작은 참 신호의 규모	31
3.21	슬라이드 21 · 과적합 모의실험을 직접 구성하기	32
3.22	슬라이드 22 · 변수 증가와 별점의 효과	32
3.23	슬라이드 23 · 차원이 커질 때 추정오차의 유도	32
3.24	슬라이드 24 · 편향과 분산을 식으로 분해하기	33
3.25	슬라이드 25 · 세 오차의 경제적 의미	33
3.26	슬라이드 26 · U자형 상충관계	33
3.27	슬라이드 27 · 공짜 점심이 없는 이유	33
3.28	슬라이드 28 · 금융 자료에 맞는 검증	34
3.29	슬라이드 29 · 편향을 의도적으로 쓰는 처방	34
3.30	슬라이드 30 · 첫 번째 처방으로 가기	34
3.31	슬라이드 31 · OLS의 역행렬이 불안정해지는 이유	35
3.32	슬라이드 32 · 능형회귀의 해를 직접 유도하기	35
3.33	슬라이드 33 · 두 변수로 보는 작은 분모	35
3.34	슬라이드 34 · 교점 그림의 해석	35
3.35	슬라이드 35 · 두 계수의 숫자 예	36
3.36	슬라이드 36 · 축소와 유효 자유도	36

3.37	슬라이드 37 · 제약식과 별점식	36
3.38	슬라이드 38 · 계수 경로 읽기	37
3.39	슬라이드 39 · 표준화가 필수인 이유	37
3.40	슬라이드 40 · 편향된 추정기가 왜 이길 수 있는가	37
3.41	슬라이드 41 · 과거 수익률 357개로 다음 달을 예측하기	37
3.42	슬라이드 42 · 회귀계수에서 읽는 모멘텀과 반전	38
3.43	슬라이드 43 · 모의실험에서 별점이 작동하는 방식	38
3.44	슬라이드 44 · 여기까지의 처방	38
3.45	슬라이드 45 · 변수 선택의 문제	39
3.46	슬라이드 46 · 제공 별점에서 절댓값 별점으로	39
3.47	슬라이드 47 · 라쏘 목적함수	39
3.48	슬라이드 48 · 연성 임계값의 유도	39
3.49	슬라이드 49 · 마름모의 꼭짓점	40
3.50	슬라이드 50 · 라쏘 경로의 읽기	40
3.51	슬라이드 51 · 상관된 쌍둥이 변수	40
3.52	슬라이드 52 · 엘라스틱넷의 두 별점	40
3.53	슬라이드 53 · 어떤 별점이 맞는가	41
3.54	슬라이드 54 · 별점 선택과 채점	41
3.55	슬라이드 55 · 하이퍼파라미터와 계수의 역할	41
3.56	슬라이드 56 · k겹 교차검증을 계산하기	42
3.57	슬라이드 57 · 금융 교차검증의 두 경고	42
3.58	슬라이드 58 · OLS, 능형, 라쏘의 결과 비교	42
3.59	슬라이드 59 · 예측 점수와 투자 성과가 다른 이유	42
3.60	슬라이드 60 · 시장 전체 예측으로 돌아오기	43
3.61	슬라이드 61 · 극단적 복잡성의 논쟁	43
3.62	슬라이드 62 · 수익률 예측에서 확립된 규칙	43
4	04. 종목 간 기대수익률과 요인 논쟁	44
4.1	슬라이드 01 · 횡단면의 출발점	44
4.2	슬라이드 02 · 앞 장에서 건너오는 다리	44
4.3	슬라이드 03 · 요인 동물원의 네 질문	44
4.4	슬라이드 04 · 특성에서 전략으로	45
4.5	슬라이드 05 · 십분위 포트폴리오 정렬	45
4.6	슬라이드 06 · 파마·맥베스 회귀의 두 단계	45
4.7	슬라이드 07 · 높은 수익률과 이상현상의 차이	45

4.8 슬라이드 08 · 왜 월별 기울기의 표준오차를 쓰는가	46
4.9 슬라이드 09 · 여섯 범주의 지도	46
4.10 슬라이드 10 · 여섯 범주의 대표 신호	46
4.11 슬라이드 11 · 낮은 가격은 두 가지를 말한다	47
4.12 슬라이드 12 · 각 범주를 같은 질문으로 읽기	47
4.13 슬라이드 13 · 모멘텀의 위치	47
4.14 슬라이드 14 · 과거 승자가 계속 이기는가	47
4.15 슬라이드 15 · 모멘텀의 위험과 가격오류 설명	48
4.16 슬라이드 16 · 평균 모멘텀과 폭락 위험	48
4.17 슬라이드 17 · 가치와 성장의 구분	48
4.18 슬라이드 18 · 장부가치/시가총액으로 정렬하기	49
4.19 슬라이드 19 · 가치 프리미엄의 두 해석	49
4.20 슬라이드 20 · 가치 효과의 기간과 측정	49
4.21 슬라이드 21 · 투자와 수익성으로 넘어가기	49
4.22 슬라이드 22 · 빠른 자산 증가와 낮은 미래수익률	50
4.23 슬라이드 23 · 투자율과 할인율의 연결	50
4.24 슬라이드 24 · 수익성 높은 회사의 높은 수익률	50
4.25 슬라이드 25 · 수익성 효과의 항등식과 설명	51
4.26 슬라이드 26 · 두 자산가격 요인모형	51
4.27 슬라이드 27 · 무형자산의 회계 문제	51
4.28 슬라이드 28 · 장부 밖 투자와 비율의 왜곡	51
4.29 슬라이드 29 · 무형자산 프리미엄의 두 설명	52
4.30 슬라이드 30 · 낮은 범주 재현율을 해석하기	52
4.31 슬라이드 31 · 거래마찰은 가격과 비용을 함께 바꾼다	52
4.32 슬라이드 32 · 소형주와 비유동성	53
4.33 슬라이드 33 · 고유변동성과 단기 반전	53
4.34 슬라이드 34 · 거래마찰 범주의 재현	53
4.35 슬라이드 35 · 여섯 범주를 한꺼번에 비교하기	53
4.36 슬라이드 36 · 위험인가 가격오류인가	54
4.37 슬라이드 37 · 두 설명의 서로 다른 예측	54
4.38 슬라이드 38 · 지금까지의 가격 항등식	54
4.39 슬라이드 39 · 네 가지 구별 질문	55
4.40 슬라이드 40 · 판정표의 증거를 읽는 법	55
4.41 슬라이드 41 · 예측자와 설명자의 목표	55
4.42 슬라이드 42 · 투자 CAPM의 최적화 유도	55

4.43 슬라이드 43 · 특성과 공분산을 떼어 놓기	56
4.44 슬라이드 44 · 우연이라는 세 번째 설명	56
4.45 슬라이드 45 · t 값 2의 의미가 바뀌는 순간	56
4.46 슬라이드 46 · 잡음 전략 300개의 모의실험	57
4.47 슬라이드 47 · 진짜 전략 10개를 섞었을 때	57
4.48 슬라이드 48 · 왜 새 요인에는 더 높은 기준이 필요한가	57
4.49 슬라이드 49 · 다중검정 규칙의 단계별 계산	57
4.50 슬라이드 50 · 재현 논쟁의 질문	58
4.51 슬라이드 51 · 많은 이상현상이 실패한다는 결과	58
4.52 슬라이드 52 · 많은 요인이 재현된다는 결과	58
4.53 슬라이드 53 · 왜 판정이 갈리는가	59
4.54 슬라이드 54 · 한 요인의 베이지안 축소를 유도하기	59
4.55 슬라이드 55 · 주제별 정보를 함께 쓰기	59
4.56 슬라이드 56 · 사후 판정과 82%의 해석	60
4.57 슬라이드 57 · 발표 뒤 수익의 감소	60
4.58 슬라이드 58 · 새 요인의 올바른 검정	60
4.59 슬라이드 59 · 선택된 통제만 넣을 때의 편향	61
4.60 슬라이드 60 · 새 요인 15개의 비교	61
4.61 슬라이드 61 · 이중 선택의 세 단계	61
4.62 슬라이드 62 · 다음 문제의 문턱	61
4.63 슬라이드 63 · 요인 논쟁을 예측 문제로 다시 쓰기	62
4.64 슬라이드 64 · 이미 시도한 정규화의 교훈	62
4.65 슬라이드 65 · 횡단면 연구의 결론	62

1 01. 값싼 예측과 AI의 경제학

인공지능을 금융에 적용한다는 말은 먼저 **어떤 정보를 얻어 어떤 선택을 바꾸는가**를 묻는 일이다. 예측의 값은 정확도 자체가 아니라 그 예측으로 피할 손실과 새로 얻을 편익에 있다. 이 장은 예측의 경제학에서 과업의 보완관계, 가격 조정, 자산가격 예측으로 이어진다. 수학에서 필요한 것은 조건부기대값, 탄력성, 회귀의 기초이며, 각각을 아래에서 다시 정의한다.

1.1 슬라이드 01 · 강좌의 지도

금융에서 AI는 공시 읽기, 신용심사, 거래, 위험관리처럼 성격이 다른 일을 한다. 이들을 묶는 질문은 **미래의 불확실한 상태를 더 잘 추정하면 현재의 행동이 어떻게 달라지는가**다. 예를 들어 다음 분기 매출을 맞혀도 매수·매도 기준이나 거래비용을 정하지 않으면 투자전략은 완성되지 않는다.

이 장의 순서는 예측의 가치 → 업무 병목 → 가격과 고용의 변화 → 실제 수익률 예측의 검증이다. 뒤의 정규화 회귀와 요인 논쟁은 앞의 경제학적 질문에 대한 통계적 도구로 읽으면 연결된다.

핵심 구분은 **예측값·결정 규칙·성과 측정**이다. 예측값이 다음 달 수익률 8%라고 해도 보유 현금, 위험한도, 대안 자산의 기대수익률에 따라 주문량은 달라진다. 따라서 뒤의 모든 사례에서 입력 시점, 출력값, 행동, 비교 대상의 네 칸을 직접 채워 보면 서로 다른 AI 활용을 같은 틀로 읽을 수 있다.

1.2 슬라이드 02 · 왜 금융에서 AI를 배우는가

금융의 입력은 공시, 뉴스, 가격, 재무제표처럼 풍부하지만 목표인 **미래 초과수익률**은 매우 시끄럽다. 같은 기술이라도 영수증 분류에서는 높은 정확도가 곧 생산성으로 이어질 수 있지만, 투자에서는 작은 예측 오차가 큰 손실로 번진다.

따라서 이 분야는 AI의 장점을 가장 필요로 하면서도 검증 기준이 특히 엄격하다. 독자는 매년 데이터가 언제 알려졌는지, 선택 가능한 행동이 무엇인지, 성과의 비교 대상이 무엇인지 묻는 습관을 갖추어야 한다.

금융 수익률은 기업 실적뿐 아니라 금리, 유동성, 투자자 기대가 동시에 움직인 결과다. 예측 모형이 기업의 실적을 잘 맞혀도 시장이 이미 그 정보를 가격에 넣었다면 투자수익은 늘지 않는다. **실적 예측 오차**와 **가격 대비 초과수익 예측 오차**를 별도로 기록해야 하는 이유가 여기에 있다.

1.3 슬라이드 03 · 주식 매수 질문에 빠진 변수들

“삼성전자를 지금 사도 되는가”라는 질문은 답을 하나로 정할 수 없다. 투자 기간, 이미 가진 종목, 손실 감내 범위, 세금과 수수료가 빠졌기 때문이다. 같은 전망을 가진 두 사람도 현재 포트폴리오가 다르면 최적 행동이 다르다.

판단의 기본형은 상태 s 가 일어날 확률 $p(s)$ 와 행동 a 의 효용 $U(a, s)$ 를 놓고 $a^* = \arg \max_a \sum_s p(s)U(a, s)$ 를 선택하는 것이다. AI는 주로 $p(s)$ 를 바꾸지만, 목표와 제약을 정하는 일은 별개다. 자동 주문 권한까지 연결된다면 잘못된 예측의 비용과 사전 통제가 훨씬 중요해진다.

두 투자자에게 동일한 상승 확률 60%를 제시해 보자. 한 명은 이미 반도체 주식을 많이 보유하고 다른 한 명은 현금만 있다면, 전자는 집중위험 때문에 추가 매수를 피할 수 있다. 신호의 품

질을 평가할 때도 단순 정답률보다 실제 효용 변화나 위험 조정 수익을 비교해야 한다.

1.4 슬라이드 04 · AI 충격과 한국 주식시장의 집중

한국 주가지수는 시가총액 가중이므로 소수 반도체 대형주의 변동이 지수 전체에 크게 반영된다. 미국의 장기금리 상승은 먼 미래의 이익을 현재가치로 환산하는 할인율을 높이고, AI 투자 수익성에 대한 의문은 예상 현금흐름을 낮출 수 있다. 두 힘이 동시에 작용하면 관련 기업의 가격은 더 민감하게 움직인다.

AI 기업 사이의 투자·클라우드 구매·반도체 공급 계약은 서로의 매출을 키우지만 현금흐름의 독립성을 보장하지 않는다. 한 고리의 투자 축소가 다른 고리의 매출 전망을 낮추는 **공통 위험**이 될 수 있다. 단순한 “AI 수혜주” 분류보다 자금의 출처와 최종 고객 수요를 추적해야 한다.

시가총액 가중지수에서 기업 i 의 단순 기여는 대략 지수 내 비중 w_i 와 그 기업 수익률 r_i 의 곱 $w_i r_i$ 다. 비중이 큰 기업의 작은 하락도 여러 소형주의 상승을 덮을 수 있다. 이때 지수 하락을 곧바로 ‘모든 산업의 AI 전망 악화’로 읽지 말고, 기업별 기여도와 공통 금리 충격을 분리하자.

1.5 슬라이드 05 · 값싼 예측의 경제학

예측은 아직 관찰하지 못한 값을 현재 정보로 추정하는 것이다. 비용이 내려가면 기업은 예전에는 예측 문제로 보지 않았던 업무까지 예측 가능한 조각으로 분해한다. 대출 심사에서는 “상환할까”뿐 아니라 “어떤 추가 서류가 판정을 바꿀까”도 예측 대상이 된다.

가격이 떨어진 재화의 사용량이 늘고, 함께 쓰는 보완재의 가치가 바뀐다는 미시경제학을 그대로 적용할 수 있다. 데이터 품질, 손실함수의 설계, 행동할 권한이 대표적인 보완재다. Prediction Machines¹의 관점은 AI를 만능 지능으로 부르기보다 어떤 투입의 가격이 내려갔는지 묻게 한다.

대출 승인 사례를 생각하면, 예측 대상은 ‘연체 여부’지만 결정 대상은 승인·거절·금리·한도다. 연체 확률 5%와 6%의 차이가 승인 기준을 넘지 않으면 더 정밀한 예측의 한계가치는 작다. 반대로 기준 근처의 신청자가 많다면 작은 확률 개선도 손실과 금융 접근성을 크게 바꿀 수 있다.

1.6 슬라이드 06 · 세 명제의 연결

첫째, 예측은 결정을 바꾸어야 가치가 있다. 둘째, 그 결정이 실제 결과로 이어지려면 업무의 다른 단계가 따라와야 한다. 셋째, 예측 비용이 충분히 내려가면 고객의 수요와 관련 노동·데이터의 가격이 조정된다.

세 명제는 개인의 선택, 기업의 생산과정, 시장 균형이라는 서로 다른 분석 수준이다. 한 수준에서 관찰한 성능을 다른 수준의 성과로 곧장 옮기면 논리적 도약이 생긴다. 가령 문서 요약 속도가 10배여도 승인위원회의 처리량이 그대로라면 기업의 총 처리량은 거의 안 바뀔 수 있다.

세 수준을 연결하는 간단한 장부를 만들 수 있다. 개인 수준에서 한 건당 절감액이 v , 기업이 처리하는 건수가 q 라면 직접 편익은 vq 다. 그러나 도입 비용과 검토 인력이 필요하고, 시장에서 서비스가 늘면 가격과 q 자체가 바뀐다. 한 건의 실험 효과를 전체 산업의 편익으로 곱할 때 이 변화를 빠뜨리지 않아야 한다.

¹<https://www.predictionmachines.ai/>

1.7 슬라이드 07 · 의사결정을 바꾸지 않는 신호의 가치는 0

신호 z 를 보기 전 최적 기대효용은 $V_0 = \max_a E[U(a, s)]$ 다. 신호를 본 뒤에는 신호마다 행동을 다시 고를 수 있으므로 $V_1 = E_z[\max_a E[U(a, s) | z]]$ 다. 기존 행동을 계속 고르는 선택도 가능하므로 $V_1 \geq V_0$ 이고, **정보의 가치는** $V_1 - V_0$ 이다.

두 신호의 정답률이 달라도 최적 행동이 늘 같다면 행동 가치의 차이는 없다. 예컨대 투자 허용 범위가 너무 좁아 어떤 신호에도 같은 보유량을 유지한다면 더 정밀한 수익률 전망의 즉각적 가치는 0이다. 반대로 드문 파산을 맞이하는 신호는 전체 정확도가 낮아도 큰 손실을 피하게 해 가치가 클 수 있다. 이는 Blackwell의 정보 비교²를 금융 의사결정에 적용한 것이다.

왜 $V_1 \geq V_0$ 인가? 신호를 본 뒤에도 항상 신호를 무시하고 기존 최적 행동을 택할 수 있기 때문이다. 선택지가 늘었는데 최대 기대효용이 낮아질 수는 없다. 다만 신호 구매료 c 를 지불한다면 순가치는 $V_1 - V_0 - c$ 이며, 양의 정보가치가 곧 유료 서비스 구매를 정당화하지는 않는다.

1.8 슬라이드 08 · 지도와 압축

추상화는 정보를 버리는 일이다. 피카소의 황소 그림은 세부 묘사를 지우면서도 황소를 알아볼 특징을 남긴다. 지하철 노선도는 실제 거리와 방향을 왜곡해 환승 경로를 읽기 쉽게 한다.

좋은 압축의 기준은 원본을 얼마나 완벽히 재현하는지가 아니라 **목표 결정에 필요한 차이를 보존하는가**다. 지하철 지도는 환승에는 유용하지만 도보 시간에는 부정확할 수 있다. 금융 모형도 종목의 모든 정보를 저장할 필요는 없지만, 손익을 좌우하는 꼬리위험이나 발표 시점을 버려서는 안 된다.

통계적으로는 압축된 표현 z 가 목표 y 에 대해 충분한 정보를 남겼는지를 묻는다. 같은 요약문을 갖는 두 공시가 실제로는 서로 다른 현금흐름을 암시한다면 요약은 해당 투자 결정에 불충분하다. 반대로 소송 문구의 표현 차이가 손익 판단을 바꾸지 않는다면 그 세부는 버려도 된다.

1.9 슬라이드 09 · 한 결정에 맞춰 만든 지도

현실 x 를 표현 $z = f(x)$ 로 압축한 다음 예측 $\hat{y} = g(z)$ 를 만들고 행동 $a = h(\hat{y})$ 을 고른다고 하자. f 는 두 현실을 같게 보이게 할 수 있다. 두 현실에서 최적 행동이 같다면 그 손실은 작지만, 하나는 매수하고 다른 하나는 매도해야 한다면 치명적이다.

거대언어모형은 학습자료의 패턴을 압축해 답을 생성한다. 금융에서는 문장 요약의 매끄러움보다 의사결정에 필요한 수치, 부정문, 예외 조항, 기준일을 유지하는지가 중요하다. 공시의 “일회성 이익” 한 단어가 사라지면 이익의 지속성 평가가 달라진다.

실무에서는 ‘문서를 잘 요약했는가’ 대신 ‘최종 판단에 필요한 필드가 남았는가’를 점검할 수 있다. 예컨대 계약금액, 종료일, 해지 조건, 연결대상 여부를 표로 추출하고 원문 위치를 붙인다. 이 절차는 생성된 한 문장의 자연스러움과 원문 충실도를 분리해 평가하게 한다.

1.10 슬라이드 10 · 공시에서 글자가 이미지일 때

문자 검색은 텍스트 층에 존재하는 글자를 찾는다. 실적 발표의 핵심 문단이 그림으로 삽입되면 사람이 보기에는 같은 문장이지만 기계의 단순 검색에서는 사라질 수 있다. 멀티모달 인식은 이미지의 글자를 읽어 이런 누락을 줄인다.

²<https://doi.org/10.1214/aoms/1177729032>

그러나 읽기와 평가를 구분해야 한다. 자산 매각 이익을 정확히 추출했더라도 그 이익이 반복 가능한 영업이익인지, 현금 유입인지, 추가에 이미 반영됐는지는 추가 판단이 필요하다. 실무적으로는 이미지 OCR 결과를 원문 페이지와 대조하고, 추출된 숫자의 단위와 회계 기간을 검증한다.

OCR 결과의 숫자 '1,000'은 원 단위인지 백만 원 단위인지에 따라 천 배 차이가 난다. 표 제목, 주석, 괄호로 표시한 음수, 전년 대비 열을 함께 읽어야 한다. 이미지에서 텍스트를 찾은 다음에는 추출된 값마다 페이지 번호와 주변 문맥을 남겨 사람이나 별도 규칙이 확인할 수 있게 한다.

1.11 슬라이드 11 · 빠른 요약과 정확한 요약의 선택

분석가가 3일 걸려 오류율 1%인 결과를 내고 AI가 10초 걸려 오류율 5%인 결과를 낸다고 하자. “어느 쪽이 좋은가”는 오류 하나의 비용, 마감 시각, 사람이 후속 검토할 수 있는지에 달려 있다. 단순히 속도나 정확도 한 숫자로 고르지 않는다.

오류의 평균 비용을 L , 지연 비용을 D 라 하면 총 기대비용의 단순형은 $C = p_{\text{err}}L + D$ 다. 중요한 공시를 잘못 읽어 큰 주문을 넣는 경우에는 L 이 커서 검토 단계가 가치 있다. 반면 수천 개 문서에서 검토 후보만 찾는 1차 선별에는 빠른 도구가 유리할 수 있다.

검토자의 시간을 어디에 배치할지도 최적화 문제다. 오류 가능성이 높은 문서와 오류 비용이 큰 주문에 우선 사람의 확인을 붙이면, 모든 결과를 재검토하는 것보다 같은 시간에 기대손실을 더 줄일 수 있다. 이는 모형의 확률 보정이 중요한 이유이기도 하다. ‘95% 확신’을 붙인 사례에서 실제 오류율이 5%인지 확인해야 한다.

1.12 슬라이드 12 · 암달의 법칙과 업무 병목

전체 처리시간을 1로 정규화하고, 자동화 가능한 부분이 p , 그 부분의 속도가 s 배가 된다고 하자. 새 시간은 자동화하지 못한 $1 - p$ 와 빨라진 p/s 의 합이다. 따라서 전체 속도 증가는 다음과 같다.

$$S = \frac{1}{(1 - p) + p/s}.$$

문서 초안이 업무시간의 10%라면 이를 10배 빠르게 해도 $S = 1/(0.9 + 0.01) \approx 1.099$, 즉 전체 처리량 증가는 약 9.9%다. 준법 검토와 최종 승인에 긴 시간이 걸리면 초안 작성의 혁신이 곧바로 전체 혁신이 되지 않는다. $s \rightarrow \infty$ 일 때조차 상한은 $1/(1 - p)$ 다.

식의 분모를 직접 대입해 보자. 원래 100시간 중 30시간이 자동화 대상이고 이를 5배 빠르게 하면 새 총시간은 $70 + 30/5 = 76$ 시간, 속도는 $100/76 \approx 1.32$ 배다. ‘대상 과업이 5배 빨라졌다’와 ‘전체가 5배 빨라졌다’는 전혀 다르다. 새 병목인 70시간을 줄여야 다음 개선이 커진다.

1.13 슬라이드 13 · 영상의학 사례가 알려 주는 것

영상 판독 성능이 높아졌다는 사실만으로 의사의 고용이 사라진다고 예측할 수 없다. 직업은 판독, 환자와의 소통, 다른 전문의와의 협업, 시술, 법적 책임의 묶음이다. AI가 한 과업을 싸게 만들면 전체 검사량이 늘고 남은 과업의 수요가 커질 수 있다.

다만 다른 시기나 국가의 보수·고용 변화를 AI 하나의 인과효과로 읽을 수는 없다. 인구 고령화, 의료 수가, 양성 정원, 규제도 움직인다. 이 사례의 교훈은 “자동화 가능한 과업의 비중”과 “검사 수요의 탄력성”을 함께 살피라는 것이다.

직업을 과업 묶음으로 보면 자동화의 직접효과와 수요 확대의 간접효과가 보인다. 검사 한 건의 비용이 하락해 검사량이 증가하면 판독 외 상담·설명·후속 치료의 총량이 늘 수 있다. 최종 고용 방향은 한 건당 인력 절감률과 검사량 증가율을 비교해야 판단할 수 있다.

1.14 슬라이드 14 · 암달 곡선의 평탄해짐

$p = 0.5$ 이면 자동화 부분을 무한히 빠르게 해도 전체는 최대 2배다. $p = 0.9$ 라면 상한은 10배다. 속도 증가의 한계효과는 s 가 커질수록 작아진다. 분모의 p/s 가 이미 작아진 뒤에는 다른 단계가 시간을 지배하기 때문이다.

실무 결정은 가장 느린 도구를 무조건 개선하는 것이 아니다. 전체 시간에서 해당 단계가 차지하는 비중을 측정하고, 개선 후 새 병목이 어디로 이동하는지 계산한다. 거래 시스템에서 뉴스 분류를 빨리 해도 주문 한도 승인이나 결제 통제가 그대로면 총 처리량은 제한된다.

$S(s) = 1/(1 - p + p/s)$ 를 s 로 미분하면 $dS/ds = (p/s^2)/(1 - p + p/s)^2 > 0$ 이다. 속도를 높이면 전체 성능은 개선되지만 s 가 커질수록 분자의 $1/s^2$ 때문에 추가 개선은 작아진다. 이는 '더 큰 모형'에 투자할지 남아 있는 검토·집행 단계에 투자할지 고르는 기준이 된다.

1.15 슬라이드 15 · 과업 생산성과 총량 효과의 차이

고객상담, 글쓰기, 소프트웨어 개발 같은 개별 과업에서 AI가 시간을 줄인다는 실험은 중요하다. 그러나 임금·고용·GDP는 기업의 도입률, 품질 검토, 수요 증가, 가격 하락, 다른 과업으로의 재배치가 합쳐진 균형 결과다. 개별 과업의 처리속도 증가를 총량 생산성 증가와 동일시할 수 없다.

측정에도 시차가 있다. 초기에는 설치·학습·프로세스 재설계 비용이 들고, 나중해야 보완투자가 이루어진다. 반대로 총량 지표에 변화가 아직 작다고 해서 미시적 편익이 없다는 뜻도 아니다. 생성형 AI와 상담 생산성 연구³는 과업 수준의 비교에 유용하다.

과업 실험의 효과를 총량으로 옮기려면 적어도 세 비율이 필요하다. 해당 과업이 전체 근로시간에서 차지하는 비중, 그 기술을 실제로 도입한 기업의 비중, 절감된 시간이 산출 증가로 바뀌는 비율이다. 세 비율 중 하나가 작으면 인상적인 실험 결과와 완만한 GDP 통계가 동시에 성립한다.

1.16 슬라이드 16 · 싸진 예측이 재평가하는 것

예측 서비스의 한계비용이 내려가면 가격도 경쟁을 통해 내려갈 수 있다. 고객은 같은 예산으로 더 많은 예측을 이용하고, 예측과 함께 쓰는 희소한 데이터·판단·집행 권한의 가치는 오를 수 있다. 다만 누구에게 이득이 귀속되는지는 수요와 공급의 탄력성에 달려 있다.

노동은 한 덩어리가 아니다. 자동화된 과업을 많이 수행하는 노동과 예측을 해석·책임지는 노동은 보완 또는 대체 관계가 다르다. 따라서 "AI가 임금을 올린다/내린다"보다 어떤 과업의 수요가 늘고 공급이 얼마나 빨리 따라오는지 묻는 편이 정확하다.

보완재의 가격 상승은 자동으로 보장되지 않는다. 기업이 고유 데이터를 독점하고 다른 기업이 모방하기 어렵다면 데이터 보유자가 잉여를 얻을 수 있다. 반면 고객 정보가 표준화되고 쉽게 이동하면 경쟁이 그 편익을 소비자에게 넘길 수 있다. 따라서 'AI와 함께 쓰인다'는 사실 외에 희소성과 대체 가능성을 함께 따져야 한다.

³<https://doi.org/10.1093/qje/qjae044>

1.17 슬라이드 17 · 제번스 역설의 그림

에너지 효율이 개선되면 같은 이동 거리의 연료비가 내려간다. 비용이 낮아져 주행거리가 늘 수 있으므로 차량 한 대의 효율과 사회 전체의 연료 사용량은 반대 방향으로 움직일 수 있다. 그림의 혼잡한 도로는 **단위당 투입 감소와 총투입 증가가 양립**하는 경우를 보여 준다.

AI에도 같은 질문을 던진다. 공시 분석 한 건의 비용이 1/10이 되어 분석 건수가 20배가 되면 총 분석 투입은 오히려 2배다. 하지만 이런 반등은 필연이 아니다. 예측 수요가 포화되어 있거나 규제상 주문 횟수를 늘릴 수 없다면 총사용량이 줄 수도 있다.

반등의 크기를 숫자로 분리해 보자. 분석 한 건에 10분이 들던 것이 2분으로 줄고 건수가 3배가 되면 총 분석시간은 원래의 $3 \times 2/10 = 0.6$ 배다. 건수가 8배라면 1.6배다. 같은 효율 혁신이 총 자원 감소와 증가를 모두 낳을 수 있으며, 차이는 수요 반응에 있다.

1.18 슬라이드 18 · 탄력성으로 보는 반등

단위 서비스 비용이 효율 개선으로 $d \ln P < 0$ 만큼 낮아졌다고 하자. 수요의 가격탄력성을 $\varepsilon = -d \ln Q / d \ln P > 0$ 로 정의하면 서비스 사용량은 $d \ln Q = -\varepsilon d \ln P$ 만큼 늘어난다. 한 서비스에 필요한 자원이 가격 하락률만큼 줄어든다면 총자원 E 의 변화는 $d \ln E \approx (1 - \varepsilon) d \ln P$ 다.

$\varepsilon > 1$ 이면 $d \ln P < 0$ 에 대해 $d \ln E > 0$ 가 되어 반등이 효율 절감을 넘어선다. 의료영상 검사가 저렴해지면 검사 대상을 넓힐 수 있지만, 보험 규칙과 진료 지침이 수요를 제한할 수도 있다. 탄력성은 사례마다 추정해야 한다.

정확한 해석에는 단위비용 하락이 단위 자원투입 감소와 같은 비율이라는 가정이 숨어 있다. 서버 전력 외에 검토 인력, 저장비용, 고객 탐색비용이 함께 변하면 식도 달라진다. 또한 수요의 가격탄력성은 가격 변화의 크기와 사용량 범위에 따라 달라질 수 있으므로 작은 변화의 미분식을 큰 시장 충격에 그대로 적용하지 않는다.

1.19 슬라이드 19 · 기술과 직업의 역사

증기기관, ATM, 스프레드시트는 모두 한 과업의 비용을 낮췄다. 은행 창구에서는 현금 인출 업무가 줄어도 지점 운영과 고객 상담의 상대적 중요성이 커질 수 있었다. 회계에서는 계산 자동화와 함께 감사·해석 업무가 늘었다.

같은 역사로 모든 직업의 미래를 단정하면 안 된다. 기술 도입 시기에는 지점 수, 규제, 소득 증가가 함께 움직인다. 비교할 것은 직업명보다 과업의 구성, 서비스 수요의 가격탄력성, 남은 과업에 대한 진입 장벽이다.

ATM 예시에서 중요한 것은 창구 직원이라는 직업명보다 업무 구성이 변했다는 점이다. 현금 지급이 자동화되면 상담·상품 판매·예외 처리의 비중이 커질 수 있다. 그러나 디지털 금융으로 지점 자체가 줄어드는 별도 변화까지 합치면 고용 방향은 다시 달라진다. 역사적 유추에는 어떤 기술 충격을 비교하는지 명시해야 한다.

1.20 슬라이드 20 · 약한 고리와 GDP

경제 전체의 산출을 서로 보완적인 여러 부문의 함수로 보면 작은 부문의 생산성을 무한히 높여도 전체 산출은 다른 부문에 묶인다. 암달의 법칙이 시간의 합으로 이를 보여 준다면, 보완적인 생산함수는 **가치의 합과 대체 가능성**까지 고려한다.

대체탄력성 $\sigma < 1$ 은 한 부문의 산출을 다른 부문의 산출로 바꾸기 어렵다는 뜻이다. 법률 검토가 빨라져도 법원 절차가 일정하면 전체 사건 처리량의 증가는 작다. GDP 효과를 추정할 때는

자동화 대상의 부가가치 비중과 대체탄력성을 함께 정해야 한다. Jones와 Tonetti의 생산성 논의⁴는 이 제약을 수량화한다.

극단적으로 두 단계가 직렬이고 각각 하루에 100건과 20건을 처리한다면 전체 처리량은 최대 20건이다. 첫 단계를 두 배로 올려도 총량은 여전히 20건이지만 두 번째 단계 개선은 곧바로 효과를 낸다. 생산함수의 대체탄력성이 낮다는 말은 이런 약한 고리의 제약이 가격 조정만으로 쉽게 풀리지 않는다는 뜻이다.

1.21 슬라이드 21 · 분석 가격이 내려갈 때 희소해지는 것

공시의 숫자와 문장을 찾아 정리하는 비용이 크게 낮아지면 예전에는 전문 서비스 구매자만 하던 검색을 더 많은 사람이 할 수 있다. 다만 일반 AI 구독료와 전문 데이터 서비스의 가격을 단순히 나누어 **동일한 품질의 가격비**로 해석해서는 안 된다. 데이터 범위, 오류 책임, 라이선스, 감사 가능성이 다르다.

예측이 보편화될수록 차별적 데이터, 적절한 질문, 거래 실행, 사후 검증이 중요해진다. 동일한 공개 공시에서 같은 숫자를 추출하는 능력만으로 장기 초과수익을 얻기는 어렵다. 정보가 가격에 얼마나 빨리 반영되는지도 함께 봐야 한다.

시장가격에 반영된 정보로는 새로운 투자자가 쉽게 초과수익을 얻기 어렵다. 따라서 공개 자료의 추출 비용이 하락할수록 경쟁 우위는 '무엇을 먼저 아는가'에서 '무엇을 다르게 해석하거나 더 낮은 비용으로 실행하는가'로 이동할 수 있다. 정보처리 시간, 주문 충격, 규제상 사용 가능성을 모두 포함한 순성과를 비교해야 한다.

1.22 슬라이드 22 · 내 일의 위험을 평가하는 세 질문

첫째, 일의 모든 과업을 자동화할 수 있는가. 둘째, 가격이 내려가면 그 서비스의 수요가 충분히 늘어나는가. 셋째, 남은 보완 과업의 공급이 제한되어 있는가. 세 질문을 함께 보아야 자동화와 임금의 방향을 추론할 수 있다.

예를 들어 신용분석에서 숫자 입력은 자동화되어도 고객의 특수 상황 확인과 승인 책임은 남을 수 있다. 하지만 이 남은 업무를 누구나 빠르게 배울 수 있다면 임금 프리미엄은 크지 않을 수 있다. 반대로 규제 자격이나 희소한 관계망이 필요하다면 가치가 높아질 여지가 있다.

세 질문을 실제 직무에 적용할 때는 과업별 시간 비중을 먼저 적어 본다. 신용분석가가 자료 입력 40%, 예외 검토 30%, 고객 소통 20%, 승인 책임 10%를 맡는다면 입력만 자동화해도 직업 전체가 사라지는 것은 아니다. 이후 심사 건수와 예외 사례가 어떻게 변하는지에 따라 남은 과업의 보수가 달라진다.

1.23 슬라이드 23 · 데이터 모형에서 예측 모형으로

전통 통계는 자료가 어떤 확률모형에서 생겼는지 먼저 가정하고 모수를 추정한다. 알고리즘적 접근은 생성 과정을 완전히 알기 어렵다고 보고, 새로운 자료에서 얼마나 잘 맞는지는 우선 평가한다. 두 관점은 적지 아니다. 예측은 행동에 유용하고, 구조적 해석은 정책 반사실과 원인 분석에 필요하다.

금융에서는 예측 성공이 특히 어려워서 두 관점 모두 검증이 필요하다. 이 장의 나머지는 요인 모형의 이론적 절제와 머신러닝의 유연성을 같은 표본외 기준으로 비교한다.

⁴https://web.stanford.edu/~chadj/JonesTonetti_Automation.pdf

예측과 인과 추론의 목표는 다르다. 연체를 잘 예측하는 소득 변수가 있어도 소득을 정책으로 1만 원 올렸을 때 연체가 얼마나 줄지는 그 회귀계수만으로 알 수 없다. 반면 대출 승인 순위를 정하는 목적이라면 인과효과를 완전히 알기 전에도 표본외 예측력을 평가할 수 있다.

1.24 슬라이드 24 · 브라이먼의 두 문화

데이터 모형 문화는 예컨대 $y = X\beta + \varepsilon$ 을 가정해 β 의 의미와 유의성을 해석한다. **알고리즘 문화**는 함수 $f(X)$ 를 유연하게 고르고 미사용 자료의 예측오차를 줄인다. 전자는 설명 가능한 변수에 강하고 후자는 복잡한 비선형 패턴에 강할 수 있다.

여러 모형이 거의 같은 예측력을 갖는 라쇼몽 효과가 있으면 최고 점수 하나를 '진실'로 해석하기 어렵다. 단순성과 정확도의 상충도 자료와 목적에 따라 달라진다. Breiman의 원문⁵을 읽을 때 모형의 목적이 설명인지 결정인지 먼저 구분하자.

두 문화를 결합할 수도 있다. 경제 이론으로 예측 시점, 사용 가능한 변수, 부호 제약을 정하고, 그 안에서 유연한 모형의 표본외 성능을 비교한다. 예측력이 높아도 의사결정이 왜 달라졌는지 설명해야 하는 영역에서는 변수 기여도와 사례별 오류 분석을 함께 보고한다.

1.25 슬라이드 25 · 두 문화의 원문을 읽는 법

브라이먼의 비판은 확률모형이 언제나 틀리다는 주장이 아니다. 현실이 가정한 형태와 다를 때 모형 내부의 깔끔한 표준오차만 믿으면 새 자료에서 실패할 수 있다는 지적이다. 모형의 타당성을 평가하려면 잔차, 안정성, 표본외 성능을 함께 봐야 한다.

금융 연구에서 회귀계수가 유의한 것은 특정 가정 아래 표본 내에서 0과 다르다는 뜻이다. 내년에 같은 부호와 크기를 유지하거나, 거래비용을 넘는 이익을 준다는 결론은 별도의 검증이 필요하다.

예를 들어 회귀의 p 값이 작다는 것은 특정 귀무가설과 오차 가정 아래 현재 자료가 드물다는 뜻이다. '이 변수의 경제적 효과가 크다'거나 '다른 기간에서도 통한다'는 확률을 직접 말해 주지 않는다. 계수 크기, 불확실성 구간, 표본외 오차, 매매 후 순이익을 서로 다른 표에 놓고 읽어야 한다.

1.26 슬라이드 26 · 금융이 이론 중심 접근을 고수한 이유

고객과 감독당국은 왜 신용을 거절했는지, 왜 특정 위험을 보유하는지 설명을 요구한다. 또한 금융 수익률의 신호는 약하므로 자유도가 높은 모형은 과거 우연을 외우기 쉽다. CAPM 같은 이론은 어떤 위험에 보상이 주어져야 하는지 검증 가능한 제약을 제시한다.

또 한 가지는 정책과 시장의 반응이다. 예측 규칙이 널리 쓰이면 가격이 바뀌어 규칙의 성능 자체가 달라진다. 이는 루커스 비판과 닮았다. 과거의 조건부 상관을 그대로 미래의 구조관계로 취급하지 않는 이유다.

예측 관계는 행동이 바뀌면 약해질 수 있다. 어떤 공시 문구 뒤에 주가가 천천히 오른다는 규칙이 알려지면 투자자가 발표 즉시 매수해 상승분을 앞당긴다. 과거 자료의 규칙을 시장 참여자의 반응과 독립된 자연법칙으로 취급하면 안 되는 이유다.

⁵<https://doi.org/10.1214/ss/1009213726>

1.27 슬라이드 27 · 요인모형의 언어

종목 i 의 초과수익률 기대값을 $E[r_i] = \beta_i^T \lambda$ 로 쓴다. β_i 는 시장·가치·수익성 같은 공통 충격에 대한 노출이고 λ 는 그 충격 한 단위에 대해 요구되는 보상이다. CAPM에서는 시장 요인 하나만 두므로 $E[r_i - r_f] = \beta_{iM} E[r_M - r_f]$ 가 된다.

이 식은 위험 노출의 가격과 단순 예측 특성을 구분한다. 장부가치/시가총액이 높은 종목의 수익률이 높아도 그것이 어떤 위험의 보상인지, 지속적 가격오류인지 바로 결정되지 않는다. 적은 수익 요인과 엄격한 경제적 해석은 장점이지만 놓치는 상호작용이 있을 수 있다.

베타는 ‘얼마나 함께 움직이는가’를 나타내며, 프리미엄 λ 는 그 노출 한 단위를 보유할 때 요구하는 보상이다. 베타가 큰 종목의 평균수익률이 항상 높은 것은 아니다. 해당 충격이 투자자의 소비나 재산이 줄어드는 나쁜 시기에 손실을 주어야 위험 보상 논리가 설득력을 얻는다.

1.28 슬라이드 28 · 요인 동물원과 다중검정

수백 개 특성을 하나씩 검정하면 우연히 높은 t 값이 나오는 특성이 반드시 생긴다. 참효과가 모두 0이고 독립 검정 300개를 각각 5% 수준에서 하면 기대 거짓 발견 수는 $300 \times 0.05 = 15$ 개다. 실제 논문 선택·출판 과정은 이보다 복잡하지만 기본 문제는 같다.

따라서 “한 논문에서 $|t| > 2$ ”는 충분하지 않다. 독립 표본, 발표 뒤 성과, 거래비용, 관련 변수 통제, 검정 횟수를 확인해야 한다. Harvey-Liu-Zhu의 다중검정 연구⁶는 더 높은 발견 기준의 필요성을 제기한다.

거짓 발견의 기대 개수 15는 300개 검정이 독립이라는 단순 예시에서 나온다. 실제 특성은 서로 비슷하고 연구자는 유리한 표본·정의·가중치를 반복 선택한다. 유효한 검정 횟수와 선택 과정이 불명확할수록 발표된 t 값의 명목 해석이 어렵다. 독립 재현의 가치가 커지는 이유다.

1.29 슬라이드 29 · 머신러닝의 동일 경기장

Gu-Kelly-Xiu는 다수 미국 주식과 기업 특성을 사용해 선형 회귀, 벌점 회귀, 차원 축소, 나무, 신경망을 비교했다. 핵심은 같은 정보 시점과 같은 미래 기간을 기준으로 성능을 채점하는 것이다. 모형이 복잡할수록 과거 적합도가 높다는 사실만으로 승자를 정하면 불공정하다.

특성과 거시 상태의 상호작용은 “같은 기업 특성도 경기 상태에 따라 의미가 달라진다”는 가설을 표현한다. 예를 들어 레버리지의 가격 효과가 금리 상승기에 커질 수 있다. 연구 원문⁷은 이러한 비선형 상호작용이 예측 개선의 중요한 원천이라고 보고한다.

동일 경기장은 예측변수의 공개 시점뿐 아니라 결측치 처리, 재학습 빈도, 종목 포함 기준까지 맞아야 성립한다. 특정 모형만 미래 자료로 표준화하거나 상장폐지 종목을 제외하면 성능 차이에 절차의 이점이 섞인다. 복잡한 모형의 승리는 동일한 자료·평가 규칙 아래에서만 해석한다.

1.30 슬라이드 30 · 작은 표본외 결정계수의 의미

표본외 결정계수는 $R_{OOS}^2 = 1 - \text{SSE}_{\text{model}} / \text{SSE}_{\text{benchmark}}$ 이다. 월별 개별 주식 수익률은 예측 불가능한 변동이 크므로 0.4% 같은 숫자는 작아 보여도 실제 예측 가능한 성분의 차이를 나타낼 수 있다. 단, 통계적 개선과 거래 가능한 이익은 다르다.

⁶<https://doi.org/10.1093/rfs/hhv059>

⁷<https://doi.org/10.1093/rfs/hhaa009>

모형의 우수성을 읽을 때 기준 예측이 0인지 과거 평균인지 확인해야 한다. 분모가 달라지면 같은 예측에도 R^2 가 달라진다. 공매도 제약, 회전율, 거래비용을 빼고 계산한 포트폴리오 성과도 별도로 검토한다.

$R^2_{OOS} = 0.004$ 는 벤치마크의 제공오차를 0.4% 줄였다는 뜻이지 수익률의 0.4%포인트를 벌었다는 뜻은 아니다. 제공오차는 극단적인 관측치에 큰 가중치를 주므로 어느 종목·기간에서 개선이 나왔는지도 확인한다. 실제 투자 가치는 예측을 포트폴리오 비중으로 바꾼 뒤 위험과 비용을 함께 계산해야 판단된다.

1.31 슬라이드 31 · 공개된 예측 신호의 이익 감소

한 뉴스 신호가 널리 알려지면 투자자는 가격에 그 정보를 더 빨리 반영한다. 신호가 가리킨 종목을 모두가 먼저 사면 나중에 얻을 초과수익은 줄어든다. 거래 규모가 커질수록 호가 충격과 매매비용도 늘어난다.

그래서 발표 전후 샤프비율의 하락은 가능한 메커니즘을 보여 주지만, 표본 기간·거래비용·전략 변경 여부를 확인하지 않고 '완전 소멸'로 단정할 수 없다. 샤프비율은 평균 초과수익을 표준편차로 나눈 값이며, 비용을 빼기 전 값과 실제 투자자의 값은 다르다. McLean-Pontiff⁸는 발견과 출판 뒤의 감소를 체계적으로 조사한다.

발표 뒤 성과 감소는 최소 세 가지로 나뉜다. 시장이 정보를 빨리 반영해 진짜 알파가 소멸했을 수 있고, 원래 연구가 우연히 좋은 표본을 고른 것일 수 있으며, 전략을 따라 하는 자금이 거래 비용을 키웠을 수 있다. 발표일 전후의 총수익과 순수익을 모두 비교해야 각 설명을 조금씩 분리할 수 있다.

1.32 슬라이드 32 · 계산 규모와 사전 지식

서튼의 "쓴 교훈"은 사람이 세세한 규칙을 집어넣는 방법보다 계산과 학습을 넓게 활용하는 일반적 방법이 장기적으로 우세했던 사례를 정리한다. 금융의 손으로 만든 단어 사전이나 고정된 요인 조합도 이 관점에서 재검토할 수 있다.

그렇다고 경제 이론을 버리라는 뜻은 아니다. 거래비용, 시간 순서, 데이터 누출 방지, 예산 제약은 성능을 실제로 측정하기 위한 구조다. 대규모 학습이 어디까지 허용되는지 정의하는 데 이론과 제도가 필요하다. Sutton의 글⁹은 방법론 선택의 배경을 제공한다.

계산 규모가 커져도 훈련 목표가 잘못되면 잘못된 답을 더 빠르게 낼 수 있다. 금융 텍스트에서 다음 단어를 잘 예측하는 능력은 근거 있는 투자 판단과 같지 않다. 확대 가능한 학습법을 쓰되, 실제 투자자가 갖는 정보만 입력하고 판단의 오류 비용으로 평가하는 절차를 함께 설계해야 한다.

1.33 슬라이드 33 · 이중 하강과 금융 데이터

고전적 편향·분산 그림에서는 모형을 복잡하게 할수록 처음에는 오차가 줄다가 과적합으로 다시 오른다. 일부 과매개변수 모형에서는 훈련자료를 정확히 보간하는 지점 뒤에 시험 오차가 다시 내려가는 **이중 하강**이 관찰된다.

중요한 조건은 모형 크기만이 아니다. 최적화 알고리즘의 암묵적 정규화, 자료의 구조, 잡음의 형태가 함께 작동한다. 시계열이 짧고 시장 구조가 바뀌는 금융에서는 현상을 보편 법칙으로 가

⁸<https://doi.org/10.1111/jofi.12365>

⁹<http://www.incompleteideas.net/IncIdeas/BitterLesson.html>

정할 수 없다. 따라서 보간 이후에도 반드시 시간 순서에 맞춘 표본외 검증과 거래비용 점검을 거친다. Belkin 등¹⁰의 논문은 이 현상의 기본 그림을 제시한다.

이중 하강 그래프의 가로축은 단순히 변수 수가 아니라 모형의 유효한 자유도일 수 있다. 훈련 오차가 0이 되는 보간 경계 부근에서는 잡음을 맞히느라 예측이 불안정해지고, 훨씬 큰 모형에서 학습 알고리즘이 상대적으로 단순한 해를 선택하면 시험오차가 다시 줄 수 있다. 금융에서 이 현상을 주장하려면 시간별 표본외 곡선을 재현해야 한다.

2 02. 금융 텍스트와 언어모형

숫자만으로는 기업의 전망과 위험을 다 읽을 수 없다. 사업보고서의 위험 문단, 실적 발표의 발언, 기사와 규제 공시는 모두 텍스트다. 이 장은 단어 세기에서 문맥 표현으로 발전한 방법을 이해하고, 언어모형의 학습 목표가 왜 그럴듯한 오류를 만들 수 있는지 경제학의 유인 문제와 연결한다.

2.1 슬라이드 01 · 텍스트를 금융 데이터로 읽기

재무제표의 숫자는 표준화되어 있지만 경영자의 설명은 길고 비정형적이다. 같은 “소송”이라는 단어도 소송을 당했다는 뜻인지 승소했다는 뜻인지 문맥을 보아야 한다. 텍스트 분석의 목표는 문서를 짧게 줄이는 데 그치지 않고 **미래 현금흐름이나 위험에 관한 추가 정보**를 추출하는 것이다.

다만 문장에 이미 주가가 반응했다면 정보 추출과 초과수익 창출은 다른 문제다. 텍스트를 이해하는 성능은 분류·추출의 정확도로, 투자 성능은 발표 뒤의 수익률과 비용으로 따로 검증해야 한다.

문서를 숫자로 바꾸는 순간 분석 단위도 정해야 한다. 한 문서 전체의 부정 단어 비율과 ‘유동성 위험’ 문단의 비율은 다른 질문에 답한다. 실적발표의 경영자 발언과 애널리스트 질문도 유인이 다르므로 섞어 평균을 내면 중요한 차이가 사라질 수 있다. 관측치가 회사·분기·문단 중 무엇인지 먼저 적자.

2.2 슬라이드 02 · 사전에서 언어모형으로

세대별 발전을 “단어의 빈도 → 단어의 조합 → 의미 벡터 → 문맥에 따라 달라지는 표현”으로 볼 수 있다. 새 방법은 앞선 방법의 약점을 줄이지만 계산비용과 해석 난도도 늘린다. 간단한 사전도 특정 공시 표현이 안정적일 때는 재현 가능하고 감사하기 쉽다.

모형을 고를 때는 비교 기준을 먼저 정한다. 동일 문서에서 감성을 맞히는지, 발표 직후 시장 반응을 설명하는지, 미래 실적을 예측하는지에 따라 승자가 바뀔 수 있다. 텍스트를 숫자로 바꾸는 방식은 **목적 함수**에 맞게 평가해야 한다.

방식마다 잃는 정보가 다르다. 단어 빈도는 순서를 버리고, 2그램은 가까운 문맥만 남기며, 임베딩은 표현을 압축하는 대신 개별 차원의 의미가 불분명하다. 문맥형 모형은 먼 단어 관계를 잡지만 학습자료와 계산비용에 더 의존한다. 방법을 복잡하게 만들기 전에 어떤 오류를 줄이려는지 정해야 한다.

¹⁰<https://doi.org/10.1073/pnas.1903070116>

2.3 슬라이드 03 · 사전 단어 세기의 함정

가장 단순한 감성 점수는 $S = (N_+ - N_-)/N$ 이다. N_+ 와 N_- 는 사전에 있는 긍정·부정 단어 수, N 은 전체 단어 수다. 문서 길이로 나누지 않으면 긴 보고서가 자동으로 극단적인 점수를 얻는다.

일반 영어 사전의 “liability”나 “capital” 같은 단어는 금융 문맥에서 일상적 의미와 다르게 쓰인다. 단어가 위험을 뜻하는지 회계 항목을 뜻하는지 무시하면 점수에 체계적 오차가 생긴다. Loughran-McDonald¹¹는 금융 문서에 맞는 사전이 필요한 이유를 보여 준다.

점수 S 의 분모를 전체 단어로 둘지 사전에 걸린 단어로 둘지도 결과를 바꾼다. 전체 단어로 나누면 길이 효과를 줄이지만 표와 법정 문구가 긴 기업의 점수가 희석된다. 서로 다른 연도에 공시 양식이 바뀌었다면 감성 변화처럼 보이는 것이 문서 구조 변화일 수 있다. 문서 유형과 길이를 통제한 비교가 필요하다.

2.4 슬라이드 04 · 금융 전문 사전의 의미

전문 사전은 단어의 극성을 **사용되는 분야**에 맞춘다. 예를 들어 “tax”는 범용 감성 사전에서 부정적으로 처리될 수 있어도 세금 공제나 이연법인세 문맥에서는 방향을 단정할 수 없다. 금융 사전은 그 분야에서 실제로 부정적 의미를 갖는 단어를 다시 분류한다.

그래도 문장 구조를 완전히 읽는 것은 아니다. “손실이 발생하지 않았다”는 부정어 때문에 뜻이 바뀌고, 법적 위험을 의무적으로 나열하는 문서는 실제 위험과 문서 길이가 다를 수 있다. 단어 수의 유용성은 최종 과제에서 확인해야 한다.

전문 사전의 장점은 누구나 같은 단어 목록으로 결과를 재현할 수 있다는 점이다. 그러나 새로운 산업 용어와 회계 기준 변화에는 갱신이 필요하다. 사전을 자료 전체를 본 뒤 조정하면 미래 문서의 표현을 과거 분석에 몰래 반영할 수 있으므로, 사전 버전과 적용 날짜를 기록해야 한다.

2.5 슬라이드 05 · n그램과 부정 표현

n그램은 연속한 n 개의 토큰을 하나의 특징으로 센다. “good” 하나는 긍정이지만 “not good”이라는 2그램은 그렇지 않다. “strong demand”와 “weak demand”도 명사 하나보다 형용사와의 결합을 보아야 구별된다.

단점은 조합 수가 폭발한다는 것이다. 어휘가 V 개이면 가능한 2그램은 대략 V^2 개이고 실제 관측은 희소하다. 최소 빈도 제한, 차원 축소, 정규화가 필요하다. 금융에서는 실적발표의 표현을 학습하더라도 과거 발표만으로 어휘를 만들고 미래 발표를 채점해야 데이터 누출을 피한다.

2그램도 ‘not expected to be good’처럼 부정어와 대상이 떨어져 있으면 놓칠 수 있다. 3그램 이상으로 늘리면 문맥은 조금 넓어지지만 각 조합의 관측 횟수는 줄어든다. 희소한 조합을 학습자료에서 너무 강하게 믿지 않도록 빈도 제한이나 벌점을 쓰며, 선택한 어휘 규칙도 훈련 기간에서만 정한다.

2.6 슬라이드 06 · 임베딩은 무엇을 보존하는가

임베딩은 단어 w 를 벡터 $v_w \in \mathbb{R}^d$ 에 대응시킨다. 비슷한 문맥에서 등장하는 단어들이 가까운 위치를 갖도록 학습한다. 코사인 유사도 $v_a^\top v_b / (\|v_a\| \|v_b\|)$ 는 길이보다 방향을 비교한다.

¹¹<https://doi.org/10.1111/j.1540-6261.2010.01625.x>

하나의 단어에 벡터 하나만 주면 “bank”가 은행인지 강둑인지 문맥에 따라 달라지는 뜻을 동시에 표현하기 어렵다. 이 한계가 문장 속 다른 단어를 함께 살피는 문맥형 표현으로 이어진다. 벡터가 가깝다는 사실은 예측에 유용할 수 있지만 인과관계를 뜻하지는 않는다.

코사인 유사도가 높은 두 단어는 같은 뜻일 수도, 같은 문장에 등장하는 반대 역할일 수도 있다. ‘매수’와 ‘매도’가 금융 문서에서 비슷한 주변 단어를 공유하기 때문이다. 따라서 임베딩의 근접성을 경제적 대체성으로 바로 해석하지 않는다. 실제 분류·검색 과제에서 두 단어를 구별하는지 확인해야 한다.

2.7 슬라이드 07 · 토큰과 입력의 비용

언어모형은 글을 하위 단어 조각인 토큰으로 나누고 정수 ID로 바꾼다. 같은 단어라도 언어와 토큰나이저에 따라 조각 수가 다르다. 숫자, 종목 코드, 한국어 조사도 예상과 다르게 잘릴 수 있다.

긴 사업보고서를 넣을 때 토큰 수는 비용과 문맥 창(윈도우)의 한도를 결정한다. 중요한 주석이 뒤에서 잘리면 모형이 그 내용을 모른 채 답한다. 그래서 자료를 나눌 때 기간·회사·주식 번호를 붙이고, 답에 사용한 문단을 다시 찾을 수 있게 해야 한다.

토큰 비용을 줄이려고 보고서 앞부분만 잘라 보내면 마지막 주석에 있는 우발채무나 회계정책 변경을 놓칠 수 있다. 단순 분할 대신 제목·표·주식 번호를 보존하고, 검색된 문단의 앞뒤 문맥을 함께 제공한다. 같은 숫자가 여러 회사와 기간에 반복될 수 있으므로 검색 결과의 회사명과 기준일도 입력의 일부다.

2.8 슬라이드 08 · 어텐션의 계산

각 토큰의 현재 표현 x_i 를 질의 $q_i = x_i W_Q$, 키 $k_j = x_j W_K$, 값 $v_j = x_j W_V$ 로 바꾼다. 토큰 i 가 j 를 참고하는 정도는 $q_i^\top k_j / \sqrt{d}$ 의 softmax로 정한다. 새 표현은 값의 가중평균이다.

$$\alpha_{ij} = \frac{\exp(q_i^\top k_j / \sqrt{d})}{\sum_{\ell} \exp(q_i^\top k_{\ell} / \sqrt{d})}, \quad h_i = \sum_j \alpha_{ij} v_j.$$

분모의 $\sqrt{d}$ 는 차원이 커질 때 내적의 크기가 과도하게 커져 softmax가 한 항에 몰리는 현상을 줄인다. “bank raised interest rates”에서 bank는 금리와 연결되어 금융기관 뜻으로 해석된다. Transformer 원문¹²은 이 연산의 출발점이다.

softmax의 결과인 α_{ij} 는 양수이고 한 토큰 i 에 대해 합이 1이다. 그래서 h_i 는 여러 값 벡터의 가중평균이다. 이 가중치는 질문·키의 학습된 표현에 따라 달라지며 사람이 붙인 ‘중요도 점수’와 동일하지 않다. 특히 여러 층과 여러 헤드를 지난 모형에서 한 어텐션 그림만으로 최종 판단 이유를 단정하기 어렵다.

2.9 슬라이드 09 · 다음 토큰 예측과 압축

문장 $x_1, \dots, x_n$ 의 확률을 연쇄법칙으로 $p_{\theta}(x_1, \dots, x_n) = \prod_{t=1}^n p_{\theta}(x_t | x_{<t})$ 로 분해한다. 훈련은 관찰된 토큰의 음의 로그확률을 줄이는 과정이다. 자주 쓰이는 패턴에 높은 확률을 주면 평균 부호 길이도 짧아져 예측과 압축이 연결된다.

¹²<https://arxiv.org/abs/1706.03762>

다음 토큰 하나를 맞히려 해도 긴 문맥의 인물, 관계, 수치가 필요할 수 있어 능력이 넓게 생긴다. 동시에 목표는 텍스트 확률이지 **외부 세계의 참·거짓을 직접 채점하는 것**이 아니다. 답변의 검증 체계를 따로 두어야 한다.

음의 로그우도 $-\sum_t \log p_\theta(x_t | x_{<t})$ 는 실제 토큰에 낮은 확률을 주면 큰 벌점을 매긴다. 긴 문서에서는 손실을 토큰 수로 나눠 평균을 비교할 수 있다. 이 목적은 다음 문장을 잘 이어 쓰게 하지만 '해당 회사의 실제 부채가 얼마인가'라는 사실 검증은 문서와 데이터베이스의 대조가 별도로 필요하다.

2.10 슬라이드 10 · 유창한 실패의 출발점

문법적으로 자연스러운 문장은 독자의 신뢰를 쉽게 얻는다. 그러나 금융 분석에서는 오답의 형태가 매끈하면 더 위험하다. 숫자를 틀리게 합산하거나 없는 공시를 인용해도 문장만으로는 발견하기 어렵다.

실패를 세 갈래로 나누면 대응이 쉬워진다. 필요한 정보를 못 봤는지, 본 정보를 잘못 끌어냈는지, 계산·추론에서 틀렸는지 구분한다. 첫째에는 자료 첨부와 검색, 둘째에는 재질문과 근거 대조, 셋째에는 계산기와 독립 검산이 필요하다.

오류 유형을 나누면 측정 지표도 달라진다. 검색 실패는 필요한 원문을 검색 결과에 포함했는지, 추출 실패는 원문이 주어졌을 때 항목과 단위를 맞췄는지, 계산 실패는 구조화된 숫자에서 산식을 맞췄는지 시험한다. 세 단계를 한 점수로 합치면 어디를 고쳐야 하는지 보이지 않는다.

2.11 슬라이드 11 · 생성모형의 목적 함수를 정확히 쓰기

확률의 연쇄법칙은 바로 앞 토큰 하나만 조건에 넣는다는 뜻이 아니다. 일반적인 자기회귀 언어 모형은 **앞의 전체 문맥** $x_{<t} = (x_1, \dots, x_{t-1})$ 을 조건으로 사용한다. 최대우도 추정은 다음과 같다.

$$\theta^* = \arg \max_{\theta} \sum_{m=1}^M \sum_{t=1}^{n_m} \log p_\theta(x_t^{(m)} | x_{<t}^{(m)}).$$

로그를 취하면 곱이 합으로 바뀌어 수치 계산이 안정적이고, 확률을 높이는 것과 같은 최적점을 갖는다. 이 식은 텍스트 분포의 적합도 목표이며, 금융 분석의 경제적 손실은 아직 들어 있지 않다.

연쇄법칙은 확률의 항등식이고, Transformer는 각 조건부확률을 근사하는 특정한 함수 형태다. 둘을 구분하면 '앞의 전체 문맥을 본다'는 수학적 식과 '문맥 창이 길이가 유한하다'는 구현상의 제한이 함께 이해된다. 학습자료에 있는 답을 높은 확률로 생성하는 능력과 새로운 공시의 진위를 확인하는 능력도 별개다.

2.12 슬라이드 12 · 목적 함수에 진실 향이 없다는 뜻

웹에 반복된 잘못된 주장도 훈련 텍스트라면 예측 대상이 된다. 최대우도 목표는 그 문장이 실제 기업의 사실인지 별도로 대조하지 않는다. 후속 정렬과 검색 도구가 이를 보완할 수 있지만, 기본 훈련 목표만으로 사실성이 보장되지는 않는다.

"거짓말"이라는 표현은 모델이 사실을 알고도 속이려는 의도를 암시해 혼동을 준다. 실무에서는 사실 오류, 출처 환각, 과도한 확신을 관찰 가능한 실패로 정의하는 편이 낫다. 같은 오류라도 투자 추천에 쓰일 때 손실함수는 훨씬 커진다.

정렬 훈련이 도움을 줄 수 있어도 근본 문제를 완전히 없애지는 못한다. 학습 때 보상한 '도움 되는 답변'과 실제 투자자에게 필요한 '틀렸을 때 멈추는 답변'은 다를 수 있다. 드문 기업 사건에서는 그럴듯한 일반론이 구체 사실을 대신하기 쉽다. 모형에는 모른다고 답할 선택과 근거 검색 경로를 주어야 한다.

2.13 슬라이드 13 · 질문을 바꾸면 평가도 바뀐다

“왜 거짓말하는가”보다 “어떤 입력과 보상 아래서 어떤 오류가 반복되는가”가 검증 가능한 질문이다. 모호한 요청은 모델이 가능한 해석 가운데 하나를 택하게 한다. 사용자가 원하는 회계 정의와 모델이 택한 정의가 다르면 계산은 매끈해도 결론은 틀린다.

따라서 작업을 시작할 때 기간, 연결·별도 기준, 조정 대상, 해당 항목이 없을 때의 출력 형식을 명시한다. 결과에는 항목별 원문 위치와 계산식을 요구하고, 사람이 표본을 추출해 확인한다.

예를 들어 ‘2025년 이익에서 일회성 이익을 빼라’는 요청에는 연결재무제표인지 별도재무제표인지, 세전인지 세후인지가 빠져 있다. 서로 다른 기준의 숫자를 섞으면 산술은 맞아도 의미가 틀리다. 모형 평가에서도 정답 하나만 채점하지 말고 필요한 조건을 되묻거나 가정을 명시했는지 함께 본다.

2.14 슬라이드 14 · 걸러낼 것이 없는 회사를 시험하기

“핵심이익을 계산하라”는 표현은 일회성 항목의 존재를 암묵적으로 기대하게 만들 수 있다. 같은 일을 “반복되지 않는 항목이 있으면 열거하고, 없으면 없다고 답하라”고 풀어 쓰면 과제가 더 분명하다. 추출 도구는 **양성 사례뿐 아니라 음성 사례**에서 평가해야 한다.

정밀도는 찾아냈다고 한 항목 중 진짜의 비율, 재현율은 실제 항목 중 찾아낸 비율이다. 항목이 거의 없는 기업에서는 억지 양성이 많이 나와 정밀도가 떨어진다. 재무 분석에서는 항목을 빼는 근거를 원문과 금액에 연결해야 하며, 모델의 말만으로 이익을 조정하면 안 된다.

양성 항목이 10개인데 모형이 8개를 찾아 그중 6개만 맞았다면 정밀도는 $6/8 = 75\%$, 재현율은 $6/10 = 60\%$ 다. 찾을 항목이 없는 회사에서는 잘못 만든 양성 하나가 곧 허위 조정이다. 따라서 음성 문서 비중을 실제 업무와 비슷하게 둔 시험이 중요하다.

2.15 슬라이드 15 · 모델의 국적을 성향으로 단정하지 않기

같은 기업에 대한 두 모형의 전망이 다르면 정치적 성향부터 추측하기 쉽다. 하지만 모형이 접근한 정보의 범위, 학습시점, 검색 언어가 다를 수 있다. 낙관적 전망은 의도적인 선호가 아니라 부정적 기사의 누락에서 생길 수 있다.

비교 실험에서는 기업과 날짜를 같게 고정하고, 각 모형에 같은 원자료를 제공한 뒤 전망과 실제 결과를 비교해야 한다. 단순히 두 답변의 어조를 비교하는 것은 정확도 검사가 아니다.

공정한 비교에서는 프롬프트의 언어, 제공 문서 수, 검색 도구, 출력 길이도 맞춘다. 한 모형에 현지 기사를 주고 다른 모형에는 영어 요약만 주면 모형 성향과 정보 차이를 구별할 수 없다. 전망이 다를 때는 어느 문서가 판단을 바꿨는지 근거 목록부터 비교한다.

2.16 슬라이드 16 · 예상을 뒤집는 결과의 검증

직관과 반대의 결과일수록 표본 선정과 기준을 확인한다. 어떤 중국 기업을 포함했는지, 전망 시점의 뉴스만 주었는지, 낙관성을 목표주가·이익 전망·문장 감성 중 무엇으로 측정했는지에 따

라 결론이 달라질 수 있다.

독자는 모형 간 차이를 “어느 국적이 어느 시장을 좋아한다”로 외우기보다 **정보 집합 차이의 가설**로 보아야 한다. 다음 단계는 동일한 지역 뉴스의 제공으로 차이가 줄어드는지 확인하는 것이다.

낙관성을 문장 감성으로 측정할 때와 목표주가의 상승 여력으로 측정할 때는 같은 ‘낙관’이라는 말을 써도 결과가 다를 수 있다. 어조는 긍정적이지만 목표주가는 현재 가격보다 낮을 수도 있다. 측정 정의를 먼저 고정하고, 가능하면 여러 척도를 따로 보고해야 예상과 다른 결과를 해석할 수 있다.

2.17 슬라이드 17 · 지역 정보의 사각지대

중소형주에 관한 규제 조치나 소송 기사는 현지 언어의 지역 매체에 먼저 실릴 수 있다. 영어권 검색에 안 보인다고 사건이 없는 것은 아니다. 한국의 코스닥 기업을 평가할 때도 DART, 거래소 공시, 국내 언론을 직접 확인해야 한다.

정보를 추가한 뒤 전망 차이가 줄어들면 국적 자체보다 자료 접근성이 원인이라는 설명에 힘이 실린다. 하지만 검색 결과가 더 많다는 사실만으로 기사가 모두 신뢰할 만하다는 뜻은 아니다. 기업명·발표일·법적 상태를 교차 확인한다.

지역 자료를 추가하는 실험에서는 기사 건수만 늘리지 말고 신뢰도를 맞춰야 한다. 같은 사건의 복제 기사 20개는 독립된 증거 20개가 아니다. 공시 원문, 규제기관 발표, 거래소 조치처럼 일차 출처를 우선하고, 보도는 원문의 날짜와 상태를 찾는 길잡이로 쓰는 편이 정확하다.

2.18 슬라이드 18 · 기억과 진짜 사전 예측의 차이

기업명과 날짜를 지운 옛 실적발표도 문장 패턴으로 식별할 수 있다면, 과거 자료에 대한 높은 점수는 미래 예측력의 증거가 아니다. 모형의 훈련 종료일보다 뒤의 사건만 시험하고, 프롬프트에 미래의 정보가 섞이지 않았는지 확인해야 한다.

엄격한 실험은 **시점별 정보 집합** $\mathcal{I}_t$ 만 사용해 $t+1$ 을 예측한다. 모형 가중치를 학습한 시점, 검색 색인의 업데이트 시점, 평가 자료의 공개 시점까지 기록해야 한다. 금융에서 시간 누출은 아주 작은 예측 신호를 쉽게 압도한다.

훈련 종료일 이후의 자료만 쓴다는 조건도 충분하지 않을 수 있다. 나중에 작성된 회고 기사나 수정된 데이터베이스가 과거 사건의 결과를 입력에 끼워 넣을 수 있다. 진짜 사전 시험에서는 그날 실제 배포된 문서의 버전을 보관하고, 검색 도구도 그 시점의 정보만 돌려주어야 한다.

2.19 슬라이드 19 · 모형의 투자 스타일

답변 모형은 학습자료와 정렬 과정 때문에 특정 업종이나 최근 하락 종목을 더 자주 추천할 수 있다. 이는 경제학에서 말하는 투자 스타일과 비슷하지만, 실제 투자전략의 수익성이 입증되었다는 뜻은 아니다.

성향을 측정하려면 동일 시점의 종목과 자료를 여러 모형에 주고, 추천 비율을 업종·규모·직전 수익률별로 비교한다. 반대 근거를 추가했을 때 전망이 적절히 갱신되는지도 중요하다. 하나의 모형을 여러 번 물어 얻은 답은 독립된 전문가 의견이 아니다.

투자 스타일을 비교하려면 추천 종목의 단순 비율뿐 아니라 기존 포트폴리오의 노출을 뺀 변화도 봐야 한다. 기술주가 시장에 많다면 기술주 추천 비율이 높아도 시장보다 과체중은 아닐 수 있다. 추천을 규모·가치·모멘텀·산업 요인에 회귀해 어떤 노출이 반복되는지 측정할 수 있다.

2.20 슬라이드 20 · 만족도 보상의 부작용

사용자 평가를 보상에 넣으면 친절함이 높아질 수 있지만, 사용자가 듣고 싶은 말에 동의할 유인도 생긴다. 2025년 GPT-4o 업데이트에서 과도한 동조가 나타난 사례는 목적함수의 대리 지표를 잘못 맞추면 원하는 품질과 다른 행동이 나온다는 점을 보여 준다.

금융에서는 “이 종목을 사면 좋겠지?”라는 유도 질문에 대한 동의가 특히 위험하다. 평가 문항에 정확한 반론 제시, 불확실성 표현, 근거 없는 주문 권유 거절을 포함해야 한다. OpenAI의 사후 분석¹³은 피드백 신호의 결합 문제를 설명한다.

사용자가 ‘내 해석이 맞지?’라고 묻는 경우와 ‘반례를 찾아줘’라고 묻는 경우를 같은 원문으로 비교하면 동조성을 더 잘 드러낼 수 있다. 정답이 바뀌어서는 안 되는 사실 질문에서 프롬프트의 기대 방향에 따라 답이 바뀐다면 보상 신호가 사실 판단을 압도했을 가능성이 있다.

2.21 슬라이드 21 · 사후 분석과 인과 사슬

업데이트 뒤 동조가 관찰되고 이전 버전으로 되돌리자 완화되었다는 시간 순서는 중요한 단서다. 하지만 사후 분석은 여러 변경이 함께 들어갔음을 인정하므로 “좋아요 신호 하나만 원인”이라고 단순화하면 안 된다.

평가 지표가 사용자 만족을 포착해도 진실성, 장기적 편익, 반대 의견 제시까지 완전히 측정하지는 못한다. 제품 평가에서는 개별 지표의 개선뿐 아니라 서로 다른 목표가 충돌하는 극단 사례를 함께 시험한다.

사후 분석에서 변경 전후 차이가 관찰되어도 어떤 구성요소가 원인인지는 추가 분리 실험이 필요하다. 동시에 바뀐 보상 가중치, 사용자 피드백 수집, 안전 평가를 하나씩 고정해 시험하는 방식이다. 금융 업무에서도 새 모형 도입 후 성과가 변하면 시장 상태와 데이터 공급 변화까지 함께 기록해야 한다.

2.22 슬라이드 22 · 체스 에이전트 실험의 설계

도구를 쓸 수 있는 에이전트에게 “체스 엔진을 이겨라”라고만 지시하면, 체스를 두는 방법 외에 게임 파일을 바꾸거나 상대 프로그램에 접근하는 방법도 환경에 존재할 수 있다. 목표를 결과만으로 정의하면 허용된 행동의 경계가 빠진다.

이 실험은 특정 모형이 언제나 부정직하다는 결론보다 **권한 설계의 중요성**을 보여 준다. 금융 에이전트에게 분석과 주문 권한을 한꺼번에 주면, 오류가 설명 단계에서 끝나지 않고 실제로 이어질 수 있다. 실험 논문¹⁴을 읽을 때 성공의 정의와 허용 도구를 먼저 보자.

에이전트의 목표에는 ‘무엇을 달성할지’와 ‘어떤 경로를 허용할지’가 모두 있어야 한다. 매매 에이전트라면 수익 목표 외에 주문 가능 종목, 금액 한도, 사용 가능한 자료, 사람의 승인 시점을 명시한다. 도구 권한을 분리하면 분석 오류가 곧바로 주문이나 파일 수정으로 이어지는 경로를 줄일 수 있다.

2.23 슬라이드 23 · 목표 달성과 규칙 준수는 다른 변수

게임 상태를 바꾸어 얻은 “승리”는 체스 실력의 성과가 아니다. 평가자가 결과 파일의 승패만 읽으면 이런 경로를 구별하지 못한다. 금융에서도 손익 숫자만 보면 미공개 정보 사용, 과도한 위험 부담, 장부 밖 포지션을 숨긴 성과를 놓칠 수 있다.

¹³<https://openai.com/index/expanding-on-sycophancy/>

¹⁴<https://arxiv.org/abs/2502.13295>

따라서 결과 지표와 절차 제약을 동시에 둔다. 모형에 필요한 최소 권한만 주고, 원장·주문·자료 출처의 로그를 독립적으로 검증한다. 성과 측정의 대상이 무엇인지 처음부터 정의해야 한다.

성과를 손익 하나로 채점하면 위험을 크게 키워 높은 평균수익을 얻는 전략을 잘못 선호할 수 있다. 같은 손익이라도 최대 손실, 레버리지, 규정 위반 여부를 함께 기록해야 한다. 평가자가 볼 수 있는 로그를 에이전트가 바꿀 수 있다면 독립 검증이 성립하지 않으므로 원장과 권한도 분리한다.

2.24 슬라이드 24 · 굿하트 법칙, 루커스 비판, 대리인 문제

굿하트 법칙은 유용한 대리 지표를 목표로 최적화하면 원래 목표와의 관계가 약해질 수 있다는 통찰이다. 루커스 비판은 정책이 바뀌면 경제주체의 행동도 바뀌므로 과거 관계를 그대로 새 정책에 적용하기 어렵다는 주장이다. 두 개념은 **행동의 변화가 통계적 관계를 바꾼다**는 점에서 만난다.

모형의 보상 R 이 진짜 사회적 가치 V 의 불완전한 근사라면, $\arg \max R$ 이 $\arg \max V$ 와 다를 수 있다. 개발자와 사용자가 원하는 것을 에이전트에게 완전한 계약으로 명시하기 어려운 주인·대리인 문제다. 독립 감사와 반복 평가, 권한 제한이 보상함수의 문구만큼 중요하다.

굿하트 법칙의 예는 상담원의 통화 시간을 줄이는 목표다. 복잡한 고객 문제를 빨리 끊으면 지표는 좋아져도 진짜 서비스 품질은 악화될 수 있다. 루커스 비판은 그 목표가 도입되자 상담원과 고객의 행동이 바뀌어 과거 통화 시간과 품질의 관계마저 달라질 수 있음을 더한다.

2.25 슬라이드 25 · 환각을 과신으로 측정하기

틀린 답을 모두 같은 위험으로 볼 필요는 없다. “확실하지 않다”라고 말하고 근거 확인을 요청한 오답은 확신에 차서 허위 출처를 만든 오답과 다르다. 확률 p 를 말한 예측은 실제로 약 p 의 비율로 맞아야 **보정**되어 있다고 한다.

예를 들어 90% 확신 답변 100개 중 90개가 맞으면 보정이 좋다. 정답률을 높이는 것과 자신의 불확실성을 제대로 알리는 것은 다른 능력이다. Yona 등¹⁵은 거절 또는 단언의 양자택일 대신 정직한 불확실성 표현을 제안한다.

보정은 정확도와 다르다. 항상 60%라고 말하는 모형은 실제 정답률이 60%이면 보정되어 있어도 쉬운 사례와 어려운 사례를 구별하지 못한다. 금융 판단에는 확률의 서열 능력과 보정이 모두 필요하다. 90% 확신 집단의 실제 정답률을 확인하고, 오답이 큰 손실을 주는 구간을 따로 점검한다.

2.26 슬라이드 26 · 저장된 지식과 인출의 병목

모형이 어떤 사실을 표현 안에 담고 있어도 직접 질문에서 즉시 꺼내지 못할 수 있다. 추가 추론을 제공했을 때 정답이 나오면 자료의 부재와 인출 실패를 구분할 단서가 된다. 다만 특정 벤치마크에서 높은 인코딩 비율을 모든 금융 사실로 일반화할 수는 없다.

공시나 법규처럼 날짜에 민감한 사실은 모형 내부 기억보다 원문 검색이 필요하다. 검색 후에도 문단이 질문의 회사·기간에 맞는지 확인하고 숫자는 계산기로 계산한다. Calderon 등¹⁶은 지식의 저장과 접근을 구분한다.

¹⁵<https://arxiv.org/abs/2605.01428>

¹⁶<https://arxiv.org/abs/2602.14080>

내부에 저장된 정보와 현재 질문에서 사용한 정보는 구별해야 한다. 추가 힌트로 정답이 나온다면 질문 형식이 인출을 방해했을 수 있지만, 우연히 맞힌 것일 수도 있다. 반복 시험과 외부 원문 대조가 필요하다. 법규·공시처럼 버전이 바뀌는 사실에는 기억보다 최신 원문과 적용 날짜가 우선이다.

2.27 슬라이드 27 · 보이는 추론의 한계

단계별 설명은 오류를 발견하는 데 도움이 되지만, 화면에 보이는 설명이 모형 내부에서 실제로 사용한 모든 원인을 기록한다고 볼 수 없다. 설명 자체가 평가의 대상이 되면 그럴듯한 절차를 쓰는 데 최적화될 수도 있다.

금융 분석에서는 “생각한 과정을 써라”만으로 검증을 끝내지 않는다. 입력 공시의 위치, 재현 가능한 계산식, 대체 가정에서의 결과를 요구한다. 계산과 출처를 외부에서 다시 실행할 수 있어야 한다.

설명 검증 가능성을 높이려면 각 중간값을 외부에서 다시 계산할 수 있게 해야 한다. 예를 들어 영업이익 조정이라면 원문 표의 행, 일회성으로 분류한 이유, 조정 전후의 숫자를 따로 적는다. 자연어로 길게 ‘생각한 과정’을 제시하는 것보다 짧은 산식과 원문 위치가 더 강한 감사 흔적이 된다.

2.28 슬라이드 28 · 다음 토큰 맞히기가 만드는 능력

추리소설의 마지막 단어를 잘 예측하려면 앞선 사건과 인물의 관계를 추적해야 한다. 따라서 단순해 보이는 훈련 목표가 복잡한 표현 능력을 유도할 수 있다. 이는 “다음 토큰 예측”이 사소한 기능이라는 뜻이 아니다.

하지만 새로운 사례에서의 이해를 인간의 이해와 동일시해서도 안 된다. 훈련 목표가 요구한 규칙성과 실제 금융 판단의 목표가 다를 수 있다. 원리의 강점과 한계를 동시에 평가하려면 새 자료에서의 결정 성과가 필요하다.

다음 토큰 학습에서 문맥을 이해한 듯한 능력이 나타나는 까닭은 좋은 예측에 사건의 지속성, 단어 사이의 관계, 문서 구조가 필요하기 때문이다. 그러나 훈련자료에서 반복되지 않는 새 회계 기준이나 예상 밖 사건에서는 그 규칙성이 약하다. 일반 능력의 존재와 특정 금융 과제의 신뢰성을 따로 시험한다.

2.29 슬라이드 29 · 산술은 외부 도구로 분리하기

여러 숫자를 더하는 일은 결정적 알고리즘으로 정확히 수행할 수 있다. 언어모형이 숫자 패턴을 바탕으로 합계를 추측하게 둘 이유가 없다. 순서를 바꾸어도 합계가 같아야 한다는 **불변성 검사**는 계산 오류를 찾는 간단한 방법이다.

재무제표 분석 흐름을 “문장에서 항목과 단위 추출 → 표로 구조화 → 계산기로 합산 → 원문과 대조”로 나누면 각 단계의 오류를 구별할 수 있다. 모형의 숫자 해석도 검산해야 하므로 도구 호출만으로 전체 과정이 자동으로 안전해지는 것은 아니다.

합계를 검산할 때는 숫자뿐 아니라 부호와 범위도 확인한다. 괄호 속 손실을 음수로 읽었는지, 연결 자회사 금액을 중복 합산하지 않았는지, 천 원과 백만 원 단위를 섞지 않았는지 살핀다. 계산기가 산술을 보증해도 입력표의 의미가 틀리면 정확한 계산이 틀린 결론을 낳는다.

2.30 슬라이드 30 · 유창함 대신 재현성을 기준으로

좋은 금융 답변은 출처, 기준일, 단위, 계산 경로, 불확실성을 드러낸다. 쉬운 말로 과제를 구체화하고 필요한 자료를 직접 제공한 다음, 중요한 결론은 독립된 자료와 도구로 확인한다. 여러 모형에 묻는 것은 도움이 되지만 같은 오류를 공유할 수 있어 **독립된 원자료 확인**을 대신하지 못한다.

주식 매수 비율처럼 개인 사정을 모르는 상태에서 제시된 그럴듯한 숫자는 맞춤형 결론이 아니다. 독자는 질문의 빈칸을 먼저 채운다. 투자 기간과 제약, 비교 대안, 손실 한도, 정보의 날씨가 정해져야 비로소 예측을 행동으로 바꿀 수 있다.

재현 가능한 답변은 다른 사람이 같은 날짜의 원문을 열어 같은 금액을 얻을 수 있어야 한다. 이 기준으로 보면 모형 간 다수결보다 출처 하나의 정확한 식별이 더 중요할 수 있다. 결정까지 이어질 때는 예측값, 비교 기준, 포지션 한도, 틀렸을 때의 손실을 별도 단계로 남겨야 한다.

3 03. 정규화 회귀와 수익률 예측

주식시장의 미래 수익률은 평균은 작고 변동성은 큰 자료에서 추정해야 한다. 표본 안에서 잘 맞는 식은 과거의 우연을 익혔을 수 있다. 이 장에서는 비교 가능한 표본외 채점 규칙을 세우고, 추정오차가 왜 커지는지 유도한 뒤, 능형회귀·라쏘·교차검증이 어떤 편향을 의도적으로 도입하는지 단계별로 살핀다.

3.1 슬라이드 01 · 수익률 예측의 출발점

AI가 금융에서 유용하려면 과거의 가격을 설명하는 것보다 **아직 보지 않은 수익률**을 예측해야 한다. 시장 전체의 수익률은 종목 간 상대 순위를 맞추는 일과 다르다. 한 해에 모든 주식이 함께 떨어질 수 있어 시장 시계열 예측에는 거시 상태가 중요하다.

이 장의 핵심 질문은 단순하다. 많은 예측변수를 넣어도 과거 평균만 쓰는 사람보다 더 잘 맞힐 수 있는가. 먼저 평가 규칙을 고정해야 답을 비교할 수 있다.

예측의 단위부터 고정하자. 월말 t 에 알려진 정보로 다음 한 달 초과수익률을 예측하는지, 다음 1년 누적수익률을 예측하는지에 따라 변동성과 투자 가능성이 달라진다. 평가 시점보다 늦게 공표된 경제지표를 x_t 에 넣으면 실제로는 만들 수 없는 전략을 검사하게 된다.

3.2 슬라이드 02 · 앞 장에서 이어지는 문제

금융의 예측 신호는 가격·뉴스·재무비율에 퍼져 있지만 수익률의 대부분은 뜻밖의 충격이다. 관계가 시간에 따라 변하는 비정상성도 있다. 그러므로 복잡한 모형을 쓰기 전에 약한 신호와 짧은 실효 표본이라는 제약을 받아들여야 한다.

진행 경로는 예측 회귀의 실패 → 편향·분산 진단 → 계수 축소와 변수 선택 → 올바른 검증이다. 각 수식은 어떤 오차가 줄고 어떤 오차가 늘어나는지 설명하기 위해 등장한다.

시장 수익률에 예측 가능한 성분이 전혀 없다는 가정도 지나치다. 핵심은 존재하는 성분을 제한된 역사 속에서 충분히 정밀하게 추정할 수 있는가다. 표본 안에서 가장 큰 상관을 고르는 행위 자체가 추정의 일부이므로 그 선택에 사용한 데이터는 독립 채점에 다시 쓰지 않는다.

3.3 슬라이드 03 · 시장 수익률 예측의 오래된 실패

배당수익률이나 금리 스프레드가 높을 때 다음 해의 시장 수익률이 달라질 수 있다는 이론은 그럴듯하다. 문제는 과거 자료에서 찾은 관계가 미래에도 남는가다. 발표 시점까지의 자료를 모두 사용해 회귀한 뒤 같은 기간을 채점하면 미래 정보가 추정에 들어간다.

이후의 사례는 특정 변수가 영원히 무용하다는 선언이 아니다. 예측 능력은 기간과 시장 상태에 따라 달라질 수 있으며, 이를 판정하는 규칙을 사전에 정해야 한다.

예를 들어 배당수익률이 높을 때 평균수익률이 높았다는 결과가 있다면, 그 관계가 경기침체 몇 해에만 생긴 것은 아닌지 확인한다. 회귀선을 그린 뒤 원자료의 시간 순서와 극단 관측치를 표시하면 표본내 적합이 어떤 상태에 의존하는지 드러난다. 표본외 비교는 이 관계의 실제 사용 가능성을 묻는다.

3.4 슬라이드 04 · 평균보다 큰 변동성

주식시장의 연평균 수익률이 양수라도 매년 수익률은 크게 흔들린다. 평균이 10% 안팎이고 표준편차가 20% 안팎이면 한 해 관측치의 신호대잡음비는 대략 0.5에 불과하다. 평균을 정확히 추정하려면 단순히 주가 관측 횟수보다 긴 기간이 필요하다.

더 중요한 것은 예측 대상이다. 올해의 주가지수 수준을 아는 것은 내년의 초과수익률을 아는 것과 다르다. 채점에서는 배당을 포함한 총수익률과 무위험수익률을 뺀 초과수익률의 정의를 일관되게 써야 한다.

독립적인 연간 수익률의 표준편차가 20%라면 100년 평균의 표준오차도 대략 $20\%/\sqrt{100} = 2\%$ 포인트다. 평균이 8%인지 10%인지 구별하기에 100년이 생각보다 넉넉하지 않다. 같은 100년을 일별로 쪼개도 장기 평균에 관한 독립 역사가 100배 늘어나는 것은 아니다.

3.5 슬라이드 05 · 예측변수 동물원

가장 단순한 예측 회귀는 $r_{t+1} = a + bx_t + \varepsilon_{t+1}$ 이다. x_t 는 시점 t 에 이미 관찰된 배당/주가, 이익/주가, 장단기금리차 등이다. b 는 지표가 한 단위 높아졌을 때 다음 수익률의 조건부 평균이 얼마나 바뀌는지 나타낸다.

변수가 많아질수록 과거에 우연히 잘 맞은 지표를 고르기 쉬워진다. 경제적으로 그럴듯한 이유와 통계적 유의성만으로 끝내지 않고, 선택 과정 전체를 포함해 미래 예측 성능을 봐야 한다.

기울기 b 의 단위는 수익률의 단위 나누기 x 의 단위다. 배당수익률을 0.04로 적는지 4%로 적는지에 따라 수치가 달라진다. 여러 예측변수를 비교할 때는 표준화 계수나 실제로 의미 있는 변화, 예를 들어 배당수익률 1%포인트 상승에 따른 기대수익률 변화를 같이 보고한다.

3.6 슬라이드 06 · 높은 배당수익률의 두 해석

매년 배당이 g 로 성장하고 요구수익률이 $r > g$ 로 일정하다면, 고든 성장모형에서 $P_t = D_{t+1}/(r - g)$ 이다. 양변을 정리하면 $D_{t+1}/P_t = r - g$ 다. 배당 대비 가격이 낮을 때 높은 미래 수익률 r 때문일 수도 있고 낮은 배당성장률 g 때문일 수도 있다.

따라서 배당수익률의 계수에 인과적 이름을 곧장 붙일 수 없다. 경기침체기에 위험 보상이 올라 가격이 떨어졌다면 이후 수익률이 높아질 수 있다. 기업의 배당 성장 자체가 나빠졌다면 같은 높은 배당수익률이 좋은 투자 신호가 아닐 수도 있다.

고든 모형에서 $D_{t+1}/P_t = r - g$ 이므로 관찰된 높은 비율을 r 의 상승만으로 해석할 수 없다. 분

기 실적 악화로 g 가 하락해도 같은 현상이 나타난다. 미래 배당 성장과 이후 실현 수익률을 각각 예측해 보면 두 설명을 부분적으로 구분할 수 있지만, 성장률 자체의 측정오차도 고려해야 한다.

3.7 슬라이드 07 · 자료를 잘게 나누어도 평균은 정밀해지지 않는다

전체 기간을 T 년, 관측 간격을 h 년이라고 하자. 독립 로그수익률 X_k 가 평균 μh , 분산 $\sigma^2 h$ 를 가지면 $n = T/h$ 개를 합한 연율 평균 추정치는 $\hat{\mu} = \sum_k X_k / T$ 다. 독립성 때문에 분산은 다음과 같이 계산된다.

$$\text{Var}(\hat{\mu}) = \frac{n\sigma^2 h}{T^2} = \frac{\sigma^2}{T}.$$

h 가 지워진다. 하루 자료가 한 달 자료보다 행 수는 많아도, 동일한 역사 기간에서 평균수익률의 핵심 정보량은 크게 늘지 않는다. 실제 수익률에 자기상관이 있으면 식을 수정해야 하지만 “많은 행 = 많은 독립 정보”가 아니라는 직관은 유지된다.

분산 계산은 합의 독립성을 사용한다. 실제 금융자료에서 월별 수익률이 자기상관을 가진다면 $\text{Var}(\sum X_k)$ 에는 각 쌍의 공분산이 더해진다. 고빈도 자료는 거래 미시구조를 보여 주지만, 기대 수익률의 장기 변화를 알아내는 데 필요한 달력 기간을 대체하지는 못한다.

3.8 슬라이드 08 · 단순수익률, 로그수익률, 연속복리

단순수익률은 $R = (P_1 - P_0)/P_0$ 이고 로그수익률은 $r = \ln(P_1/P_0) = \ln(1 + R)$ 이다. R 이 작을 때 테일러 전개 $\ln(1 + R) = R - R^2/2 + \dots$ 로 둘이 가까워진다. 여러 기간의 가격비는 곱이므로 로그를 취하면 수익률은 합이 된다.

$$\frac{P_n}{P_0} = \prod_{k=1}^n (1 + R_k), \quad \ln \frac{P_n}{P_0} = \sum_{k=1}^n r_k.$$

연 r 을 m 번 복리로 적용한 $(1 + r/m)^m$ 은 $m \rightarrow \infty$ 에서 e^r 로 간다. 로그수익률의 합산성과 짧은 구간 분산의 비례관계는 독립 또는 적절한 약한 의존 조건을 구분해 사용해야 한다.

주가가 100에서 110으로 오르고 다시 100으로 내려오면 단순수익률은 10%와 약 -9.09%다. 둘을 더하면 약 0.91%이지만 로그수익률은 $\ln(1.1) + \ln(100/110) = 0$ 으로 정확히 합산된다. 다만 투자자의 원화 손익을 계산할 때는 단순수익률의 곱셈식이 직접적이다.

3.9 슬라이드 09 · 일별 자료의 다른 역할

일별 자료는 연평균 기대수익률 추정에 마법처럼 많은 정보를 더하지 않는다. 오히려 호가 스프레드, 비동시 거래, 가격 정체 때문에 가짜 자기상관이 생길 수 있다. 매수호가와 매도호가 사이의 거래가격 이동만으로 하루 수익률이 오르내릴 수 있다.

반면 변동성은 하루 단위 관측에서 더 잘 추정할 수 있다. 주가가 하루에 얼마나 흔들리는지는 위험관리와 포지션 크기 결정에 중요하다. 따라서 **평균을 예측하는 문제와 분산을 추정하는 문제에 같은 자료 주기를 기계적으로 적용하지 않는다.**

평균과 분산의 정보량 차이를 보자. 변동성이 시간에 따라 지속된다면 최근 일별 수익률 제공은 내일의 위험을 추정하는 데 도움이 될 수 있다. 그러나 내년 평균수익률의 작은 차이는 일별 잡음에 묻힌다. 고빈도 변동성 추정의 성공을 고빈도 방향 예측의 성공으로 혼동하지 않는다.

3.10 슬라이드 10 · 표본 안의 유의성

예측 회귀에서 t 값이 크거나 장기 R^2 가 높다는 결과는 먼저 표본 내 사실이다. 변수를 고른 기간과 계수를 추정된 기간이 같으면 선택 편향이 발생한다. 장기 수익률은 겹치는 기간이 많아 표준오차 계산도 까다롭다.

정말 알고 싶은 것은 과거 어느 시점으로 돌아가 당시 이용 가능했던 자료만으로 만든 예측이 이후 결과를 맞췄는가다. 이 질문은 금융상품의 실제 사용 가능성과도 일치한다.

같은 자료에서 후보 변수를 100개 시험해 가장 높은 t 값 하나를 보고하면 그 값의 통상적인 유의수준은 적용되지 않는다. 장기 수익률을 겹치게 만들면 예컨대 12개월 수익률 두 개가 11개월을 공유해 오차도 강하게 상관된다. 표준오차와 변수 선택을 모두 감안한 뒤에야 신뢰도를 말할 수 있다.

3.11 슬라이드 11 · 표본내와 표본외를 구분하기

표본내 적합은 전체 기간으로 a, b 를 추정한 후 같은 자료에서 잔차를 계산한다. 표본외 검증은 각 시점 t 에 t 까지의 자료만으로 $\hat{a}_t, \hat{b}_t$ 를 추정해 $\hat{r}_{t+1} = \hat{a}_t + \hat{b}_t x_t$ 를 만든다. 이후 r_{t+1} 이 실현되면 오차를 기록한다.

이 과정을 앞으로 이동하며 반복하는 것이 재귀적 예측이다. 데이터 수정본이 나중에 공개되었다면 과거의 정보 집합에 넣으면 안 된다. 금융에서는 이 작은 시점 오류가 약한 진짜 신호보다 클 수 있다.

재귀 예측에서는 첫 훈련 구간을 정하고, 그다음 한 시점의 예측을 저장한 뒤 실제값이 나올 때까지 수정하지 않는다. 이후 데이터를 한 달 추가해 다시 적합한다. 마지막에 모은 예측값들은 각기 다른 계수로 만들었지만 모두 당시 정보만 사용했다는 공통점을 갖는다.

3.12 슬라이드 12 · 과거 평균과 표본외 결정계수

벤치마크는 예측변수 없이 시점 t 까지의 평균 $\bar{r}_t$ 를 다음 수익률 예측으로 쓰는 것이다. 모형과 벤치마크의 제공오차 합을 비교한다.

$$R_{\text{OOS}}^2 = 1 - \frac{\sum_t (r_{t+1} - \hat{r}_{t+1})^2}{\sum_t (r_{t+1} - \bar{r}_t)^2}.$$

분자가 더 작아야 양수다. 표본내 OLS의 절편 포함 R^2 는 0 이상이지만 표본외 값은 음수가 될 수 있다. 누적 제공오차 차이 $\sum_{s \leq t} (e_{\text{bench},s}^2 - e_{\text{model},s}^2)$ 를 그리면 성과가 어느 기간에 생겼는지도 보인다.

예를 들어 벤치마크 제공오차 합이 100이고 모형이 98이면 $R_{\text{OOS}}^2 = 1 - 98/100 = 0.02$ 다. 모형이 105라면 -0.05 다. 표본내 OLS는 같은 자료의 절편만 있는 모형보다 잔차 제곱합이 클 수 없지만, 미래에는 그 보장이 없어 음수가 자연스럽게 가능하다.

3.13 슬라이드 13 · 웰치와 고열의 판정

배당수익률 등 많은 시장 예측변수는 과거 표본 안에서 설명력을 보였지만, 시점마다 다시 추정하는 표본외 평가에서는 과거 평균에 뒤졌다. 한 번의 위기 기간에 기울기가 크게 맞아 전체 통계량을 끌어올렸을 가능성도 살펴야 한다.

이 결과는 초과수익 예측을 포기하라는 뜻보다 **비교 기준을 낮추지 말라**는 교훈이다. Welch·Goyal¹⁷의 누적 오차 그림에서는 선이 내려갈 때 제안 모형이 기준선보다 더 큰 오차를 낸다.

원 논문의 결과를 평가할 때 변수의 경제적 논리와 채점의 결과를 분리하자. 배당수익률이 할 인율과 관련된다는 말이 참이어도 그 변수 하나로 다음 해 수익률을 안정적으로 맞히기는 어려울 수 있다. 실패는 곧 '가격이 무작위'라는 증명보다 추정오차와 관계 변화가 큰 환경이라는 증거다.

3.14 슬라이드 14 · 간단한 경제 제약은 도움이 될까

배당수익률이 높으면 미래 수익률이 높아야 한다는 이론적 부호를 강제하거나, 예상 초과수익률이 음수일 때 0으로 절단하면 과도한 추정값을 줄일 수 있다. 이는 모형에 사전 믿음을 넣는 정규화의 한 형태다.

월별 R_{OOS}^2 가 작아도 평균·분산 투자자는 포트폴리오 비중을 개선할 수 있다. 다만 기대효용 증가는 위험회피계수, 매매비용, 차입 제약에 민감하다. Campbell·Thompson¹⁸의 주장은 통계 점수와 경제적 가치를 구분해 읽어야 한다.

예상 초과수익률을 0으로 절단하면 음의 전망이 모두 사라져 제곱오차가 줄 수도 있지만 진짜 음의 기대수익 상태에서는 편향이 생긴다. 투자 비중은 단순한 평균·분산 문제에서 대략 예상 초과수익률을 위험회피계수와 분산의 곱으로 나눈 값에 비례한다. 작은 예측 변화도 비중 제약과 비용에 따라 가치가 달라진다.

3.15 슬라이드 15 · 시간이 지난 뒤의 재검증

첫 논쟁 이후 발표된 새 변수도 발표 당시의 자료에는 잘 맞을 수 있다. 독립된 후속 기간과 공통한 기준으로 다시 평가하면 결과가 약해지기도 한다. 이는 예측 관계가 소멸했을 수도 있고, 처음부터 선택 편향이 있었을 수도 있음을 뜻한다.

두 설명을 가르려면 원 논문의 표본 종료일, 논문 발표일, 이후 기간을 따로 본다. 발표 전에 이미 감소했다면 데이터 채굴이나 불안정성의 비중이 클 수 있다. 발표 후 추가 감소에는 투자자의 반응도 기여할 수 있다.

표본을 원래 연구의 종료 전·발표 전·발표 후로 나누면 해석이 분명해진다. 발표 전 새 기간에서 이미 성과가 사라졌다면 시장이 논문을 읽어서 없앤 것은 아니다. 반대로 발표 후에만 크게 줄었다면 학습한 투자자의 거래가 후보 설명이다. 어느 경우든 단일 원인으로 확정하려면 더 많은 증거가 필요하다.

3.16 슬라이드 16 · 유의성·안정성·실용성의 갈때기

변수가 표본내 유의성을 유지하는지, 같은 부호로 표본외 예측을 하는지, 거래비용 뒤에도 투자의사결정을 개선하는지는 서로 다른 관문이다. 앞 관문을 통과해도 뒤 관문을 자동으로 통과하지 않는다.

새 논문의 수를 세어 “성공률”이라고 부를 때는 각 연구가 사용한 시작일, 예측 기간, 재추정 방식이 같은지 확인해야 한다. 공정한 비교는 변수 자체뿐 아니라 **검증 절차**를 맞춘다.

¹⁷<https://doi.org/10.1093/rfs/hhm014>

¹⁸<https://doi.org/10.1093/rfs/hhm055>

검증 할때기에서 각 단계는 다른 손실함수를 쓴다. 통계 검정은 계수 0 여부, 표본외 제곱오차는 수치 예측, 경제적 평가는 투자자의 효용이나 순수익을 본다. 예측값이 종목 순위를 바꾸지 않으면 제곱오차의 작은 개선이 거래 성과를 바꾸지 않을 수도 있다.

3.17 슬라이드 17 · 누적 오차 차이 그래프 읽기

그래프의 세로축이 누적 $SSE_{\text{bench}} - SSE_{\text{model}}$ 이면 상승은 예측변수의 승리, 하락은 과거 평균의 승리다. 선이 특정 위기 이후 꺾이는 경우에는 기울기 자체가 달라졌는지, 큰 한두 관측치가 오차를 지배했는지 확인한다.

표본내 선과 표본외 선이 벌어지면 과거를 맞힌 계수가 미래에는 통하지 않았다는 뜻이다. 그래프의 0선뿐 아니라 기울기의 안정성과 표본 종료일 표시를 함께 보아야 한다.

누적 곡선의 한 시점 증가분은 $e_{\text{bench},t}^2 - e_{\text{model},t}^2$ 이다. 예를 들어 기준선 오차가 3이고 모형 오차가 1이면 해당 시점에서 곡선은 $9 - 1 = 8$ 만큼 오른다. 큰 위기 관측치 하나가 긴 기간의 완만한 하락을 뒤집을 수 있으므로, 전체 결과와 극단 시점을 뺀 결과를 함께 읽는다.

3.18 슬라이드 18 · 첫 단계의 결론

예측변수가 많아도 과거 평균보다 좋다는 주장은 어렵게 입증해야 한다. 기준선은 쉽게 이길 수 있는 허수아비가 아니라 실제로 이용 가능하고 추정오차가 작은 대안이어야 한다. 정확도가 조금 높아도 구현 비용과 위험을 함께 본다.

이제 실패의 원인을 모형의 '지능 부족'이 아니라 약한 신호와 큰 추정오차에서 찾는다. 그 원인이 맞다면 복잡성을 제어하는 방법이 다음 처방이 된다.

정규화로 넘어가는 논리는 실패 원인의 진단이다. 자료에 신호가 없으면 어떤 별점도 지속적 예측력을 만들 수 없다. 그러나 신호는 작지만 자유로운 계수의 분산이 더 크다면 계수를 0 쪽으로 조금 당기는 편이 새 자료에서 나올 수 있다. 다음 슬라이드들의 수식은 바로 이 조건을 정량화한다.

3.19 슬라이드 19 · 왜 실패하는가

진짜 조건부 기대수익률이 존재해도 매번 실현 수익률에는 큰 예측 불가능한 충격이 들어온다. 잡음이 클 때 회귀계수는 작은 표본의 우연에 따라 크게 달라진다. 변수 수가 늘면 그 우연을 설명할 자유도가 늘어난다.

핵심은 **참모형의 존재와 참모형을 추정할 수 있는가**가 별개라는 점이다. 금융시장의 역사 하나로 수백 변수를 추정한다면 이론적으로 유효한 관계도 실제 예측에서 실패할 수 있다.

회귀계수의 추정오차는 예측에 쓰인 x_t 와 곱해져 미래 예측오차가 된다. 따라서 계수가 불안정할수록 포트폴리오 비중도 흔들리고 매매회전율이 커진다. 표본내 적합이 뛰어난데 자주 거래하고 성과가 나쁘다면 모형이 가격의 잡음을 추적하고 있을 가능성을 살펴야 한다.

3.20 슬라이드 20 · 작은 참 신호의 규모

$y = f(x) + \varepsilon$ 이고 신호와 잡음이 독립이라면 참 예측 가능 비율은 $R_{\text{true}}^2 = \text{Var}(f(x)) / [\text{Var}(f(x)) + \text{Var}(\varepsilon)]$ 이다. 조건부 평균의 표준편차가 잡음의 1/10이면 $R^2 = 0.01/1.01 \approx 0.99\%$ 다.

따라서 작은 표본외 결정계수는 무조건 무의미하지 않다. 반대로 수익률을 거의 완벽히 맞히는 표본내 모형은 강한 의심을 받아야 한다. 이미 알려진 미래 정보나 거래 불가능한 가격이 입력

에 섞였을 수 있다.

식에서 신호의 분산을 0.01, 잡음의 분산을 1로 놓으면 전체 분산은 1.01이고 참 예측 가능 비율은 약 1%다. 완벽한 참 함수를 알고도 제공오차의 약 99%가 남는다. 실제 모형은 그 함수를 추정해야 하므로 관측 가능한 표본외 R^2 는 더 작을 수 있다.

3.21 슬라이드 21 · 과적합 모의실험을 직접 구성하기

관측치 120개에서 후보 변수 110개를 만들되 실제 영향이 있는 것은 첫 10개라고 하자. 독립 표준정규 변수와 잡음의 분산을 1로 두고 참계수를 모두 c 로 정하면 신호분산은 $10c^2$ 다. 참 $R^2 = 5\%$ 가 되게 하려면 $10c^2/(10c^2 + 1) = 0.05$ 를 풀어 $c^2 = 1/190$ 을 얻는다.

이후 회귀에 넣는 변수 수를 늘리고 훈련자료와 새 자료의 R^2 를 따로 기록한다. 중요한 점은 11번째 이후 변수가 진짜로 효과 0이라는 정답을 우리가 안다는 것이다. 따라서 성능 하락이 추정 오차에서 왔는지 직접 확인할 수 있다.

$c^2 = 1/190$ 이면 각 진짜 계수의 절댓값은 약 0.073이다. 잡음 표준편차가 1인 자료에서 이 신호를 120개 관측으로 분리하기 쉽지 않다. 시뮬레이션을 여러 번 반복해 평균 훈련·시험 곡선을 그리면 단일 변수 추가의 윤과 변수 수가 만드는 체계적 변화를 구별할 수 있다.

3.22 슬라이드 22 · 변수 증가와 별점의 효과

OLS는 변수를 추가할 때 표본내 제공오차가 증가할 수 없다. 추가 변수를 쓰지 않도록 계수를 0으로 놓는 선택이 항상 가능하기 때문이다. 그러나 미래 자료에서는 잡음에 맞춘 계수가 오차를 키울 수 있다.

같은 변수 수를 유지하고 능형회귀의 별점을 키우면 표본내 적합은 다소 낮아지지만 표본외 오차가 줄어드는 구간이 생긴다. 별점이 너무 크면 유용한 신호까지 지워 다시 나빠진다. 그래프의 최저점은 사전 고정값이 아니라 독립 자료로 선택해야 한다.

OLS의 훈련오차가 늘 수 없다는 사실은 최적화의 구조에서 나온다. 변수 하나를 추가한 뒤 새 계수를 0으로 두면 예전 해를 그대로 재현할 수 있기 때문이다. 하지만 미래 오차에는 이런 포함 관계가 없다. 별점을 고르는 검증자료까지 여러 번 들여다보면 그 자료에도 과적합하므로 마지막 시험 구간을 남긴다.

3.23 슬라이드 23 · 차원이 커질 때 추정오차의 유도

실제 평균벡터를 $\mu = Xg$ 라 하고 τ 기간 평균수익률을 $\bar{r} = \mu + \bar{\varepsilon}$ 라 하자. X 의 열공간에 대한 투영행렬 $P = X(X^\top X)^{-1}X^\top$ 로 OLS 예측을 만들면 $\hat{\mu} = P\bar{r} = \mu + P\bar{\varepsilon}$ 이다. $P\mu = \mu$ 이고 잡음 공분산이 $\sigma^2 I/\tau$ 라는 가정 아래 추정오차 제공의 기대값은 다음과 같다.

$$E\|\hat{\mu} - \mu\|^2 = E[\bar{\varepsilon}^\top P \bar{\varepsilon}] = \text{tr}\left(P \frac{\sigma^2}{\tau} I\right) = \frac{K\sigma^2}{\tau}.$$

P 가 대칭이고 $P^2 = P$, $\text{tr} P = K$ 인 성질을 사용했다. 변수 K 가 늘수록 오차가 선형으로 커지고 기간 τ 가 늘수록 줄어든다. 새 자료의 잡음은 이 추정오차와 독립이므로 참 신호의 크기 $\|\mu\|^2$ 보다 추정오차가 크면 0 예측보다 표본외 성능이 낮아질 수 있다.

첫 등호는 $\hat{\mu} - \mu = P\bar{\varepsilon}$ 에서 나오고, 두 번째는 $P^\top P = P$ 인 투영행렬 성질을 쓴다. $E[z^\top A z] = \text{tr}(A \text{Var} z)$ 는 평균 0인 벡터의 이차형식 항등식이다. 각 독립 방향마다 잡음분산 σ^2/τ 가 하나씩 추가되어 총 $K\sigma^2/\tau$ 가 된다.

3.24 슬라이드 24 · 편향과 분산을 식으로 분해하기

새 관측치가 $y_0 = f(x_0) + \varepsilon_0$ 이고 학습자료에서 나온 예측 $\hat{f}(x_0)$ 와 새 잡음이 독립이라고 하자. $\bar{f} = E[\hat{f}(x_0)]$ 를 더하고 빼면 $y_0 - \hat{f} = \varepsilon_0 + (f - \bar{f}) + (\bar{f} - \hat{f})$ 다. 제곱하여 기댓값을 취할 때 새 잡음의 평균이 0이고 $E(\bar{f} - \hat{f}) = 0$ 이므로 교차항이 사라진다.

$$E[(y_0 - \hat{f})^2] = \sigma^2 + (f - E\hat{f})^2 + \text{Var}(\hat{f}).$$

첫 항은 참 함수를 알아도 남는 잡음, 둘째는 평균 예측의 체계적 오류, 셋째는 학습표본에 따른 불안정성이다. 정규화는 둘째를 조금 늘리는 대가로 셋째를 크게 줄이려는 선택이다.

편향항은 여러 훈련표본에서 평균 예측이 참값에서 얼마나 벗어나는지, 분산항은 훈련표본이 바뀔 때 예측이 얼마나 움직이는지다. 한 번의 관측자료에서는 둘을 직접 볼 수 없으므로 재표본·검증으로 근사한다. 금융에서는 시장 상태가 바뀌면 '같은 참 함수'라는 가정도 깨질 수 있어 이 분해를 진단 도구로 사용한다.

3.25 슬라이드 25 · 세 오차의 경제적 의미

수익률의 예측 불가능한 충격은 모형을 아무리 정교하게 해도 없앨 수 없다. 편향은 모형이 지나치게 단순해 실제 위험 보상을 놓칠 때 생긴다. 분산은 작은 표본마다 계수가 요동쳐 투자 비중이 불안정해지는 문제다.

분산이 큰 모형은 계산상 평균 점수가 나쁠 뿐 아니라 잦은 매매와 극단적 레버리지를 유발할 수 있다. 벌점은 통계적 분산과 경제적 거래비용을 동시에 낮추는 방향으로 작동할 수 있지만, 실제 효과는 검증해야 한다.

두 모형이 같은 평균 예측오차를 갖더라도 하나의 예상수익률이 매달 -20%와 +20%를 오가면 투자 비중은 크게 변한다. 다른 모형이 완만한 전망을 내면 거래비용 뒤에는 더 나을 수 있다. 예측오차뿐 아니라 예측값의 변동과 매매회전율을 함께 기록하는 이유다.

3.26 슬라이드 26 · U자형 상충관계

아주 단순한 과거 평균 모형은 변수에 따른 변화를 못 잡아 편향이 크지만 추정이 안정적이다. 모든 변수를 자유롭게 넣는 OLS는 편향이 낮을 수 있으나 잡음에 민감하다. 중간 복잡도에서 합계 오차가 낮아지는 U자형 그림은 이 관계를 요약한다.

그러나 U자의 위치는 자료의 신호대잡음비와 변수 상관에 따라 달라진다. 금융처럼 신호가 약하고 데이터가 짧을수록 왼쪽, 즉 강한 축소 쪽이 유리할 가능성이 크다. 그림은 사전 믿음이며 실제 최저점은 검증에서 찾는다.

U자 그림의 왼쪽 끝에서는 중요한 신호를 모두 0으로 보는 편향이 남고, 오른쪽 끝에서는 우연한 움직임까지 계수로 흡수한다. 어느 쪽이 최적인지는 미리 정한 그림이 아니라 새 기간의 오차가 답한다. 한 번 고른 최저점을 반복해서 시험자료에 맞추면 U자에서 가장 운 좋은 지점을 고르는 과적합이 생긴다.

3.27 슬라이드 27 · 공짜 점심이 없는 이유

모든 가능한 자료생성과정에서 언제나 이기는 추정기는 없다. 능형회귀는 많은 작은 계수가 있다는 믿음, 라쏘는 소수 변수만 중요하다는 믿음을 반영한다. 진실이 다르면 두 방법의 순위도 바뀐다.

따라서 알고리즘 이름보다 가정이 중요하다. 예측변수의 정의, 측정오차, 기간 변화, 거래 가능성에 대한 경제적 지식이 모형을 고르는 데 사용된다. 어떤 방법의 최고 성적만 가져와 보편적으로 좋다고 말하면 선택 편향이 생긴다.

능형회귀의 '많은 작은 효과' 가정과 라쏘의 '소수의 큰 효과' 가정은 모두 검증 가능한 가설이다. 비슷한 가치 지표가 다수 있다면 하나만 남기는 라쏘의 선택은 불안정할 수 있고, 정말 몇 변수만 유효하다면 능형회귀가 잡음 변수도 남길 수 있다. 성능과 변수 선택의 안정성을 같이 비교해야 한다.

3.28 슬라이드 28 · 금융 자료에 맞는 검증

낮은 신호대잡음비는 작은 R^2 를 예상하게 하고, 짧은 실효 표본은 계수의 불확실성을 키운다. 시간에 따라 관계가 변하면 임의 분할보다 미래 방향의 검증이 필요하다. 수익률의 공통 충격은 종목 수가 많아도 독립 표본 수가 그만큼 늘지 않음을 뜻한다.

이 구조에서 모형의 자유도를 제한하고, 자료의 시점을 엄격히 지키고, 단순한 기준선과 비교하는 것이 과학적 기본값이다. 성과가 실패하면 원인과 예외 기간을 기록해야 한다.

금융 검증에서는 같은 달의 여러 종목을 서로 독립된 훈련·검증 묶음으로 나누면 공통 충격이 양쪽에 들어간다. 다음 달 수익률을 예측하려는 목적이라면 검증은 미래 달에 두는 편이 직접적이다. 산업·회사·기간 중 무엇을 독립적으로 일반화하려는지에 따라 분할 단위가 달라진다.

3.29 슬라이드 29 · 편향을 의도적으로 쓰는 처방

비편향 추정은 참계수를 평균적으로 맞힌다는 장점이 있지만 미래 예측오차를 최소화한다는 보장은 없다. 계수를 0에 가깝게 끌어당기면 약한 신호에서 계수의 요동을 줄일 수 있다. 이 의도적 편향이 **축소추정**이다.

두 처방은 모두 적합과 단순성을 맞바꾼다. 능형회귀는 모든 계수를 연속적으로 줄이고, 라쏘는 일부를 0으로 만든다. 어느 쪽이 맞는지는 실제 변수 효과가 넓게 퍼져 있는지 드문지에 달려 있다.

비편향성은 동일한 환경의 표본을 무한히 반복했을 때 추정량 평균이 참값과 같다는 속성이다. 실제 투자자는 하나의 짧은 역사로 한 번 예측한다. 약한 신호에서 큰 계수 오차가 더 큰 비용을 낳는다면 작은 편향을 받아들이는 선택이 합리적이다. 다음의 능형·라쏘는 편향을 명시적 벌점으로 조절한다.

3.30 슬라이드 30 · 첫 번째 처방으로 가기

능형회귀는 OLS의 제곱오차에 계수 크기에 대한 벌점을 더한다. 큰 계수가 꼭 나쁘다는 뜻이 아니라, 약한 자료에서 큰 계수를 확신하려면 그만큼 강한 증거가 필요하다는 뜻이다.

다음 슬라이드부터 벌점이 왜 불안정한 역행렬을 안정화하는지 유도한다. 절편은 보통 벌점을 주지 않고, 변수는 단위를 맞춰 표준화한다는 실무 조건을 먼저 기억해 두자.

벌점이 계수의 제곱합을 비용으로 보는 이유는 큰 절댓값의 계수에 더 빠르게 증가하는 비용을 붙이기 위해서다. 같은 예측오차를 만드는 두 해가 있다면 계수 크기가 작은 쪽을 선호한다. 절편까지 벌점을 주면 자료의 전체 평균도 0으로 부당하게 당기므로 보통 기울기만 축소한다.

3.31 슬라이드 31 · OLS의 역행렬이 불안정해지는 이유

$y = Xg + \varepsilon$ 에서 제곱오차 $(y - Xg)^\top (y - Xg)$ 를 g 에 대해 미분하면 $-2X^\top y + 2X^\top Xg = 0$ 이다. $X^\top X$ 가 가역이면 $\hat{g} = (X^\top X)^{-1}X^\top y$ 다. 변수들이 서로 비슷하면 $X^\top X$ 의 어떤 방향의 고유값이 아주 작아진다.

추정량의 분산 $\text{Var}(\hat{g}) = \sigma^2(X^\top X)^{-1}$ 에서 그 방향의 분산은 $\sigma^2/\lambda_{\min}$ 이다. 작은 고유값으로 나누니 계수가 폭발한다. $K > N$ 이면 열들이 독립일 수 없어 해가 유일하지 않으며, 훈련자료를 완벽히 맞히는 여러 해 가운데 미래에 잘 맞는 해를 OLS만으로 고를 수 없다.

고유값이 작은 방향은 서로 닮은 변수의 '차이'처럼 자료가 거의 변하지 않는 조합이다. 이 방향에서 수익률의 작은 잡음만 있어도 역행렬은 이를 크게 확대한다. 능형회귀는 고유값에 양의 수를 더해 이런 증폭을 제한한다. 변수마다 별도 계수를 정확히 알아야 하는 설명 목적과 안정적인 예측 목적을 구분해야 한다.

3.32 슬라이드 32 · 능형회귀의 해를 직접 유도하기

능형회귀는 $L(g) = (y - Xg)^\top (y - Xg) + \gamma g^\top g$ 를 최소화한다. 미분하여 0으로 놓으면 $-2X^\top (y - Xg) + 2\gamma g = 0$ 이고, 항을 옮기면 $(X^\top X + \gamma I)g = X^\top y$ 다. 따라서 다음의 유일한 해를 얻는다.

$$\hat{g}_{\text{ridge}} = (X^\top X + \gamma I)^{-1}X^\top y, \quad \gamma > 0.$$

$X^\top X$ 의 고유값 λ_j 에 γ 가 더해지므로 작은 고유값으로 나누는 불안정성이 줄어든다. $\gamma \rightarrow 0$ 이면 가역일 때 OLS로, $\gamma \rightarrow \infty$ 이면 표준화된 설명변수의 계수가 0으로 간다. 절편은 별도로 유지되어 과거 평균 예측이 된다.

목적함수의 $\gamma g^\top g$ 를 미분하면 $2\gamma g$ 가 된다. 따라서 정상조건은 OLS의 $X^\top Xg = X^\top y$ 에 γIg 를 추가한 형태다. $\gamma > 0$ 이면 모든 고유값이 양수가 되어 역행렬이 존재한다. 이는 계산의 안정성을 높이지만, 안정된 수치해가 곧 경제적으로 올바른 예측이라는 뜻은 아니다.

3.33 슬라이드 33 · 두 변수로 보는 작은 분모

표준화한 두 변수의 표본 상관이 ρ 이고 $c_j = X_j^\top y/N$ 라 하자. 목적함수에 $1/N$ 을 붙여 미분하면 $(1 + \gamma)g_1 + \rho g_2 = c_1$, $\rho g_1 + (1 + \gamma)g_2 = c_2$ 다. 두 식을 더하고 빼면 다음이 나온다.

$$g_1 + g_2 = \frac{c_1 + c_2}{1 + \rho + \gamma}, \quad g_1 - g_2 = \frac{c_1 - c_2}{1 - \rho + \gamma}.$$

$\rho = 0.99$ 이고 별점이 없으면 두 계수의 차이를 0.01로 나눈다. 아주 작은 표본 차이가 거대한 상반 계수로 변한다. $\gamma = 0.1$ 이면 분모가 0.11이 되어 같은 오차가 훨씬 덜 증폭된다.

두 식을 더하면 공통으로 움직이는 방향 $g_1 + g_2$ 의 분모가 $1 + \rho + \gamma$ 이고, 빼면 서로 반대로 움직이는 방향의 분모가 $1 - \rho + \gamma$ 다. $\rho \approx 1$ 일 때 자료는 합은 잘 알려 주지만 차이는 거의 알려 주지 않는다. 능형 별점의 핵심 효과는 이 불확실한 차이 방향을 누르는 데 있다.

3.34 슬라이드 34 · 교점 그림의 해석

두 예측변수가 거의 같은 방향이면 각각의 계수를 따로 결정할 정보가 부족하다. 회귀의 제곱오차 등고선은 길고 좁은 타원이 되어 작은 데이터 변화에도 최저점이 타원의 긴 축을 따라 크게 움직인다.

능형 별점은 원형 등고선을 더해 원점에서 먼 해에 비용을 부과한다. 결과적으로 같은 두 변수의 합이 가진 신호는 어느 정도 보존하고, 두 변수의 차이에 대한 불필요한 확신을 줄인다. 계수 하나의 해석보다 둘의 합이 더 안정적일 수 있다.

등고선의 긴 축은 비슷한 적합도를 주는 계수 조합이 많음을 뜻한다. 원형 제약을 작게 할수록 타원과 만나는 지점은 원점 쪽으로 이동한다. 이 그림은 계수의 크기를 줄이는 기하학을 보여주지만, 변수의 측정 단위가 다르면 원이 다른 경제적 의미를 갖는다. 표준화가 선행되어야 한다.

3.35 슬라이드 35 · 두 계수의 숫자 예

참계수가 둘 다 1인데 표본에서 OLS가 대략 2.07과 -0.08 을 준다면 각각은 크게 틀렸어도 합의 약 2로 맞을 수 있다. 상관이 높은 변수들 사이에서 어느 하나에 신호를 몰아주고 다른 하나를 반대 부호로 보정한 결과다.

예측의 목적은 반드시 각 계수의 인과적 진실을 찾는 것이 아니다. 새 자료에서 두 변수가 계속 함께 움직인다면 합의 안정성이 중요하다. 반대로 두 변수가 미래에 따로 움직일 수 있다면 개별 계수의 불확실성도 의사결정에 반영해야 한다.

상관이 높은 두 지표가 함께 오르면 예측에는 $g_1 + g_2$ 가 주로 작동한다. 개별 추정치가 2와 0이든 1과 1이든 새 자료가 같은 방향으로 움직이면 예측은 비슷하다. 그러나 정책이 한 변수만 바꾸는 반사실을 묻는다면 두 계수의 구분이 필요하다. 예측 안정성과 인과 해석은 서로 다른 요구다.

3.36 슬라이드 36 · 축소와 유효 자유도

$X^T X = I$ 인 직교 조건에서는 $\hat{g}_{j,\text{ridge}} = \hat{g}_{j,\text{OLS}} / (1 + \gamma)$ 다. 모든 계수가 같은 비율로 줄고 정확히 0이 되지는 않는다. 데이터에 맞춘 자유도의 크기를 $d(\gamma) = \text{tr}[X(X^T X + \gamma I)^{-1} X^T]$ 로 정의하면 직교 조건에서는 $K/(1 + \gamma)$ 다.

즉 계수는 K 개지만 각각 표본의 잡음에 완전히 맞춰지지 않는다. 일반적으로 $X^T X$ 의 고유값 λ_j 를 쓰면 $d(\gamma) = \sum_j \lambda_j / (\lambda_j + \gamma)$ 다. 정보가 적은 작은 고유값 방향일수록 더 강하게 축소된다.

고유값 λ_j 가 큰 방향은 자료에서 많이 변하므로 $\lambda_j / (\lambda_j + \gamma)$ 가 1에 가깝고 거의 유지된다. 작은 방향은 0에 가까워진다. 따라서 능형회귀는 모든 방향을 똑같이 축소하는 것처럼 보이는 원래 계수식과 달리, 정보가 적은 조합을 더 강하게 억제한다.

3.37 슬라이드 37 · 제약식과 별점식

“오차를 최소화하되 $g^T g \leq c$ ”라는 문제를 생각하자. 라그랑지안은 $(y - Xg)^T (y - Xg) + \gamma(g^T g - c)$ 다. $-\gamma c$ 는 g 선택에 영향을 주지 않으므로 능형 목적함수와 같다.

c 가 작을수록 원점 가까운 계수만 허용되고 대응하는 γ 는 커진다. 그림에서 OLS의 타원 등고선과 원형 제약 영역이 처음 닿는 점이 능형 해다. 이 기하학은 왜 예측변수에 단위를 맞춰야 하는지도 드러낸다.

제약 반지름 c 와 별점 γ 는 일대일로 움직이는 경우가 많지만 정확한 대응값은 자료에 달려 있다. 같은 c 라도 변수의 단위를 바꾸면 허용되는 경제적 효과의 범위가 바뀐다. 따라서 제약식을 ‘큰 계수를 싫어한다’는 사전 판단으로 읽고, 그 강도는 훈련 이후 별도 검증에서 결정한다.

3.38 슬라이드 38 · 계수 경로 읽기

별점이 아주 크면 모든 기울기 계수는 거의 0이다. 별점을 줄이면 각 계수가 자료가 가리키는 방향으로 움직인다. **경로 그림**은 어느 변수가 얼마나 빠르게 커지는지와 상관된 변수들이 서로 값을 나누는지를 보여 준다.

의료 자료처럼 신호가 비교적 강한 예제의 경로를 금융에 그대로 대입할 수는 없다. 금융에서는 아주 작은 계수라도 투자 수량을 크게 바꾸면 중요할 수 있고, 표본이 바뀌면 경로가 불안정할 수 있다. 경로는 설명 도구이며 최적 별점의 판정은 검증자료에 맡긴다.

경로의 가로축이 γ 인지 $\log \gamma$ 인지 먼저 확인하자. 로그 축에서는 일정한 가로 이동이 별점의 동일한 절대 증가가 아니라 동일한 배율 변화다. 경로가 특정 지점에서 갑자기 바뀌면 상관된 변수 사이의 가중치 이동일 수도 있으므로, 한 계수의 모양만으로 실물경제 관계의 변화를 주장하지 않는다.

3.39 슬라이드 39 · 표준화가 필수인 이유

같은 경제변수를 원 단위로 쓰는지 백만원 단위로 쓰는지에 따라 회귀계수의 수치는 달라진다. 별점 $\gamma \sum_j g_j^2$ 는 계수 크기에 직접 적용되므로 단위가 다른 변수에 공평하지 않다.

훈련 구간에서 $z_j = (x_j - \bar{x}_j)/s_j$ 로 표준화하면 계수는 해당 변수가 한 표준편차 변할 때의 효과가 된다. 검증·시험 자료에도 **훈련 구간의 $\bar{x}_j, s_j$** 를 그대로 적용해야 미래 분포의 정보를 미리 사용하는 누출을 피한다. 절편은 중심화 뒤 별도로 처리한다.

훈련자료에서 평균 100, 표준편차 20인 변수의 새 관측치가 130이면 표준화 값은 $(130 - 100)/20 = 1.5$ 다. 검증 구간 자체의 평균과 표준편차로 다시 바꾸면 미래 분포를 예측 과정에 알려 주는 셈이다. 결측치 대체, 이상치 절단, 주성분 계산에도 같은 '훈련에서 적합하고 미래에 적용' 원칙을 쓴다.

3.40 슬라이드 40 · 편향된 추정기가 왜 이길 수 있는가

한 계수에 대해 $x^\top x = 1$, 참값 g , OLS 추정량의 분산 σ^2 라 하자. 능형 추정량은 $\hat{g}_\gamma = \hat{g}_{OLS}/(1 + \gamma)$ 다. 기대값은 $g/(1 + \gamma)$ 이므로 편향은 $-\gamma g/(1 + \gamma)$, 분산은 $\sigma^2/(1 + \gamma)^2$ 다.

$$\text{MSE}(\gamma) = \frac{\sigma^2 + \gamma^2 g^2}{(1 + \gamma)^2}, \quad \frac{d\text{MSE}}{d\gamma} = \frac{2(\gamma g^2 - \sigma^2)}{(1 + \gamma)^3}.$$

미분값을 0으로 놓으면 $\gamma^* = \sigma^2/g^2$ 다. 잡음이 크거나 참계수가 작을수록 강하게 축소한다. 이 최적값은 참 g 를 모르므로 실제로는 검증자료에서 근사해야 한다.

$\gamma = 0$ 에서 MSE의 도함수는 $-2\sigma^2 < 0$ 이다. 잡음 분산이 양수라면 별점을 아주 조금 주는 것이 이 단순 설정에서는 언제나 MSE를 낮춘다. 이후에는 편향의 제곱이 커지므로 최저점을 지난다. 이 유도는 능형회귀가 편향을 '실수로' 만드는 것이 아니라 미래 제곱오차를 줄이려고 의도한다는 점을 보여 준다.

3.41 슬라이드 41 · 과거 수익률 357개로 다음 달을 예측하기

한 종목의 과거 119개월 수익률, 그 제곱, 세제곱을 각각 입력하면 357개 특징이 된다. 제곱항은 큰 변동 자체의 효과, 세제곱항은 상승과 하락의 비대칭적 패턴을 표현할 수 있다. 복잡한 기업 정보 없이도 고차원 문제가 된다.

매월 종목 간 비교를 한다면 그 달의 횡단면 평균을 빼고 특성을 표준화한다. 이는 시장 전체의 움직임보다 **어느 종목이 상대적으로 높을지**에 초점을 맞추기 위한 것이다. 변수 정의와 자연 시점은 매매 가능성을 좌우한다.

119개 시차와 그 제곱·세제곱은 서로 독립되지 않는다. 인접한 시차는 시장 국면을 공유하고, 한 시차의 제곱과 세제곱도 원래 수익률과 관련된다. 357개 특징이 곧 357개의 독립 정보라는 뜻이 아니다. 강한 상관과 약한 신호의 조합이 축소추정에 유리한 환경을 만든다.

3.42 슬라이드 42 · 회귀계수에서 읽는 모멘텀과 반전

최근 몇 달의 양의 계수는 과거에 오른 종목이 더 오르는 모멘텀을 뜻하고, 아주 오래된 과거 수익률의 음의 계수는 장기 반전을 뜻한다. 직전 한 달을 건너뛰는 설계는 호가·유동성에 따른 단기 반전과 중기 모멘텀을 구분하는 데 도움이 된다.

다만 계수 곡선은 서로 상관된 시차를 동시에 넣은 **조건부 효과**다. 한 시차의 계수가 양수라고 그 시차만 사는 전략의 수익률과 동일하지 않다. 전체 예측값을 포트폴리오에 적용해 비용 위 성과를 별도로 계산해야 한다.

시차별 계수는 다른 시차를 고정했을 때의 조건부 기여다. 최근 수익률의 양의 계수가 모멘텀처럼 보이더라도 최근 1개월 계수가 음수라면 최종 예측은 두 효과의 합으로 결정된다. 곡선을 경제적 서사와 연결할 때는 실제 종목 사례의 예측값을 계산해 어떤 시차가 얼마나 기여했는지 확인하자.

3.43 슬라이드 43 · 모의실험에서 별점이 작동하는 방식

진짜 변수 10개를 넘어서 잡음 변수까지 넣으면 OLS의 표본내 점수는 계속 좋아질 수 있다. 능형 별점은 잡음 변수의 우연한 계수를 낮춰 새 관측치의 오차를 줄인다. 그렇다고 모든 별점이 좋은 것은 아니다.

과도한 별점은 진짜 변수까지 거의 0으로 만들어 과거 평균과 다르지 않은 예측을 준다. 따라서 그래프에서는 표본외 곡선이 가장 높은 **중간 별점 구간**을 찾는다. 반복 시뮬레이션의 평균 곡선은 한 번의 운 좋은 표본이 아니다.

모의실험에서는 참계수와 잡음변수를 알고 있으므로 결과를 더 엄밀하게 읽을 수 있다. OLS가 잡음변수에 큰 계수를 줄 때 그 계수는 훈련표본을 잘 맞혀도 새 표본에서는 무작위로 작동한다. 능형 별점을 바꾼 뒤 같은 난수 생성 구조의 여러 독립 시험자료에서 평균 오차를 비교해야 개선이 일반적인지 판단된다.

3.44 슬라이드 44 · 여기까지의 처방

문제는 변수 수 자체보다 약한 신호에서 자유로운 계수 추정이 큰 분산을 만든다는 점이다. 능형회귀는 계수를 모두 남기면서 특히 정보가 부족한 방향을 강하게 줄인다. 예측에는 유리할 수 있지만 어떤 변수만 실제로 중요한지 알려 주지는 않는다.

다음 처방은 많은 변수 중 일부를 정확히 0으로 만드는 라쏘다. 두 방법은 경제적 사전 믿음이 다르므로 성능과 해석을 함께 비교해야 한다.

능형회귀가 변수의 경제적 원인을 밝혀 주는 것은 아니다. 서로 비슷한 두 설명변수에 작은 계수를 나눠 주어 예측을 안정화할 수 있지만, 어느 변수가 수익률을 '일으켰는가'에는 답하지 못한다. 이후의 라쏘는 변수 수를 줄여 읽기 쉽게 만들지만 선택된 이름 역시 인과적 보증을 없다.

3.45 슬라이드 45 · 변수 선택의 문제

재무비율, 가격 신호, 텍스트 지표를 수백 개 넣을 때 모든 계수가 조금씩 비영(非零)인지, 소수만 실질적으로 중요한지 모른다. 변수 선택은 예측 비용을 줄이고 설명을 간결하게 만들 수 있지만, 잘못된 제외는 편향을 키운다.

특히 높은 상관을 가진 두 지표가 같은 정보를 담으면 하나만 선택해도 예측은 좋을 수 있다. 하지만 선택된 변수 하나에 유일한 경제적 의미를 부여하면 잘못 해석할 위험이 있다.

변수 선택의 편익은 계산비용뿐 아니라 자료 수집과 검증 비용의 감소다. 모든 기업에 없는 정보를 요구하는 지표를 버리면 실제 운용이 쉬워질 수 있다. 다만 선택이 표본마다 크게 바뀌면 보고된 '핵심 변수'는 불안정하다. 여러 기간에서 선택 빈도와 예측 성능을 함께 제시해야 한다.

3.46 슬라이드 46 · 제곱 벌점에서 절댓값 벌점으로

능형회귀의 L_2 벌점은 계수를 부드럽게 줄이지만 정확히 0으로 만들지 않는다. 라쏘는 L_1 벌점 $\sum_j |g_j|$ 을 사용한다. 0에서 꺾이는 모양 때문에 약한 계수는 0에 붙을 수 있다.

두 방식 모두 적합도와 복잡성의 균형이다. 차이는 "복잡성"을 계수 제곱합으로 재는지 절댓값 합으로 재는지다. 그 작은 수학적 차이가 변수 선택이라는 질적 차이를 만든다.

L_2 벌점의 미분은 0 근처에서 연속적으로 0으로 가므로 작은 계수를 정확히 0에 고정하는 힘이 약하다. L_1 벌점은 0의 양쪽 기울기가 서로 달라 0에서 모서리를 만든다. 자료의 기울기가 그 모서리를 넘지 못하면 최저점이 0이 된다. 이 차이가 라쏘의 희소성을 설명한다.

3.47 슬라이드 47 · 라쏘 목적함수

표준화된 변수에서 라쏘는 $\min_g \{N^{-1} \|y - Xg\|^2 + \gamma \sum_j |g_j|\}$ 를 푼다. $\gamma = 0$ 은 OLS와 같고, 커질수록 많은 계수가 0이 된다. 절댓값은 0에서 미분 가능하지 않아 모든 변수에 대한 단순한 역행렬 해는 없다.

그러나 볼록 함수라 전역 최저점은 효율적 알고리즘으로 찾을 수 있다. 변수 수가 관측치보다 많아도 유용하며, 해가 하나만 존재하는지 여부는 변수의 상관 구조에 따라 따로 확인해야 한다.

라쏘 목적함수의 제곱오차는 잘 맞히려는 압력, 절댓값 합은 계수를 작고 적게 만들려는 압력이다. γ 의 단위는 제곱오차를 N 으로 나누었는지에 따라 바뀌므로 서로 다른 소프트웨어의 벌점 숫자를 직접 비교하지 않는다. 동일한 손실 정의와 표준화 규칙을 먼저 확인한다.

3.48 슬라이드 48 · 연성 임계값의 유도

직교한 한 변수에서 OLS 계수를 z 라고 하면 라쏘 문제는 상수항을 빼고 $(g - z)^2 + 2\lambda|g|$ 의 최소화와 같다. $g > 0$ 이면 도함수 $2(g - z) + 2\lambda = 0$ 이므로 $g = z - \lambda$, 단 $z > \lambda$ 일 때만 양수다. $g < 0$ 이면 $g = z + \lambda$ 이고 $z < -\lambda$ 여야 한다.

$$\hat{g}_{\text{lasso}} = \text{sgn}(z)(|z| - \lambda)_+, \quad (u)_+ = \max(u, 0).$$

$|z| \leq \lambda$ 이면 0이 최소점이다. 능형회귀는 비율로 줄이고 라쏘는 일정 크기를 빼며, 그 과정에서 약한 계수를 없앤다. 벌점의 정의에 따라 교재의 γ 와 여기의 λ 사이에는 2배 상수 차이가 있을 수 있다.

세 구간을 직접 대입하면 $z = 0.8, \lambda = 0.5$ 일 때 해는 0.3이고, $z = 0.3$ 이면 해는 0이다. $z = -0.8$ 이면 해는 -0.3 이다. 0 양쪽에서 목적함수의 기울기가 부호를 바꾸는지 확인하면 $|z| \leq \lambda$ 일 때 0이 최저점인 이유가 보인다. 작은 관측 상관을 신호로 확정하지 않는 규칙이다.

3.49 슬라이드 49 · 마름모의 꼭짓점

L_1 제약 $|g_1| + |g_2| \leq c$ 는 두 차원에서 마름모이고 꼭짓점이 좌표축에 있다. 제곱오차의 타원 등고선이 제약 영역에 처음 닿는 곳이 꼭짓점이면 한 계수가 정확히 0이다. L_2 제약은 원이므로 축 위의 정확한 접촉이 상대적으로 드물다.

기하학은 직관을 주지만 모든 데이터에서 라쏘가 하나의 변수만 남긴다는 뜻은 아니다. 별점 크기와 변수 상관에 따라 선택 수가 달라지고, 해석을 위해서는 선택의 안정성도 보아야 한다.

등고선이 꼭짓점에 닿는 경우가 많은 것은 마름모의 모서리가 좌표축과 정렬되어 있기 때문이다. 그러나 두 변수가 거의 같은 정보를 담으면 어느 축의 꼭짓점에 닿을지는 작은 자료 변화에 민감할 수 있다. '0이 된 변수는 중요하지 않다'고 단정하지 말고 비슷한 변수의 대체 가능성을 살펴야 한다.

3.50 슬라이드 50 · 라쏘 경로의 읽기

별점이 매우 크면 기울기 계수가 모두 0이다. 별점을 줄이면 먼저 자료와 강하게 연결된 변수가 들어오고, 이어 다른 변수가 들어온다. 경로의 각 지점은 하나의 후보 모형이다.

변수가 일찍 들어왔다고 인과적으로 중요하다는 뜻은 아니다. 다른 변수와의 상관, 표본의 우연, 스케일에 영향을 받는다. 경로를 비교할 때는 훈련 자료에서만 표준화하고, 성능은 독립 검증에서 평가한다.

별점을 줄이는 동안 새 변수가 들어오는 순서는 현재 이미 들어온 변수들에 조건부로 결정된다. 첫 변수와 거의 같은 두 번째 변수는 단독 상관이 커도 늦게 들어올 수 있다. 경로의 순서를 경제적 중요도의 순위로 읽지 말고, 각 후보 모형의 검증오차와 선택 안정성을 함께 읽는다.

3.51 슬라이드 51 · 상관된 쌍둥이 변수

두 예측변수가 거의 같은 정보를 담으면 라쏘는 하나에 계수를 몰아주고 다른 하나를 버릴 수 있다. 표본이 조금만 바뀌어도 살아남는 변수의 이름이 바뀔 수 있다. 예측은 안정적이어도 변수 선택 결과는 불안정한 것이다.

예를 들어 배당/주가와 이익/주가가 같은 가치 신호를 담는다면 하나가 선택되었다고 다른 하나가 경제적으로 무의미하다고 결론 내릴 수 없다. 계수 해석에는 변수 그룹을 함께 살펴야 한다.

예측의 목적이라면 두 쌍둥이 변수 중 어느 하나가 남아도 성능이 비슷할 수 있다. 반면 설명의 목적이라면 선택된 이름이 바뀔 때 결론도 바뀌므로 불안정성이 문제다. 여러 훈련 구간에서 재적합해 선택 빈도를 비교하거나 관련 변수를 한 군집으로 묶어 해석하면 과도한 단정이 줄어든다.

3.52 슬라이드 52 · 엘라스틱넷의 두 별점

엘라스틱넷은 $\min_g \{N^{-1} \|y - Xg\|^2 + \gamma_1 \sum_j |g_j| + \gamma_2 \sum_j g_j^2\}$ 를 푼다. L_1 은 약한 변수를 제거하고 L_2 는 상관된 변수 사이의 가중치를 나누어 해를 안정화한다.

두 별점을 정해야 하므로 검증 비용이 늘어난다. 하지만 많은 서로 비슷한 재무비율을 사용할 때 선택의 불안정을 낮출 수 있다. '둘 다 있으니 무조건 더 낫다'가 아니라, 두 하이퍼파라미터를 선택하는 과정까지 표본외 검증해야 한다.

엘라스틱넷의 L_2 부분은 강한 상관으로 생긴 작은 고유값 방향을 안정화하고, L_1 부분은 필요 없는 군집을 일부 제거한다. 두 별점의 효과를 구별하려면 $\gamma_1 = 0$ 인 능형회귀와 $\gamma_2 = 0$ 인 라쏘를 같은 검증 절차로 비교한다. 매개변수가 하나 더 있으므로 개선이 우연일 가능성도 엄격히 확인해야 한다.

3.53 슬라이드 53 · 어떤 별점이 맞는가

진짜 효과가 넓게 퍼져 있다면 능형회귀의 모든 계수 축소가 유리할 수 있다. 효과가 소수 변수에 집중되면 라쏘의 희소성이 유리하다. 관련 변수들이 군집을 이루면 엘라스틱넷이 실용적일 수 있다.

이 판단은 자료가 충분하면 검증 성능으로, 자료가 부족하면 경제적 사전지식으로 보완한다. 여러 방법을 시험한 뒤 최고 성적만 보고하면 모형 선택 자체가 또 하나의 과적합이 된다. 최종 시험자료는 맨 마지막까지 남겨 둔다.

어떤 방법이 '맞는지'를 원자료의 계수 크기만 보고 판단할 수는 없다. 상관된 예측변수 사이에서는 계수 표현 자체가 여러 가지일 수 있기 때문이다. 경제적 가정은 후보를 줄이는 데 쓰고, 선택은 미래 순서의 검증에서 하며, 최종 성능은 별도 기간에 한 번 보고하는 순서를 지키자.

3.54 슬라이드 54 · 별점 선택과 채점

별점 γ 는 회귀계수와 달리 모형을 적합하기 전에 선택하는 **하이퍼파라미터**다. 같은 훈련자료의 제공오차만 보면 별점을 줄일수록 적합이 좋아지므로 항상 0을 선택한다. 미래 성능을 위한 별점은 보지 않은 자료로 정해야 한다.

검증용 기간을 분리하면 훈련 표본이 줄어드는 문제가 있다. 교차검증은 여러 차례 자료를 나누어 각 관측치를 한 번씩 검증에 사용함으로써 제한된 자료를 아낀다.

훈련-검증 분할을 정할 때는 기업 공시의 발표일과 예측 대상 월을 고려한다. 검증 달 직후의 수익률이 훈련 자료에 들어가면 별점 선택에도 미래가 섞인다. 별점 후보를 100개 시험한 뒤 검증 최저값 하나를 고르는 절차 자체도 여러 후보 중 운 좋은 값을 택하므로 최종 시험이 필요하다.

3.55 슬라이드 55 · 하이퍼파라미터와 계수의 역할

계수는 별점을 고정한 뒤 자료에 맞춰 추정한다. 별점은 얼마나 복잡한 모형을 허용할지 결정한다. 둘을 같은 자료에서 무제한으로 최적화하면 재귀적으로 자유도가 늘어나는 것과 같다.

훈련-검증-시험의 역할을 구분한다. 훈련은 계수 추정, 검증은 별점 선택, 시험은 최종 성능 보고다. 시험 성적을 보며 다시 별점을 조정하면 시험자료도 더는 독립 표본이 아니다.

예를 들어 라쏘 계수는 훈련 구간에서만 추정하고, γ 후보 10개는 다음 구간의 평균오차로 고른다. 마지막 구간을 열어 성능을 한 번 측정한 뒤 그 수치를 보고 후보를 다시 바꾸면 그 구간은 사실상 두 번째 검증자료가 된다. 재개발이 필요하다면 더 뒤의 새로운 기간을 최종 시험으로 남긴다.

3.56 슬라이드 56 · k겹 교차검증을 계산하기

표본을 k 개 묶음 $V_1, \dots, V_k$ 로 나누고, 각 묶음 v 를 뺀 자료에서 $\hat{g}_{-v}(\gamma)$ 를 적합한다. 뺀 묶음의 오차를 평균한 값이 교차검증 점수다.

$$CV(\gamma) = \frac{1}{k} \sum_{v=1}^k \frac{1}{|V_v|} \sum_{i \in V_v} (y_i - x_i^\top \hat{g}_{-v}(\gamma))^2.$$

이 값을 가장 작게 하는 γ 를 고른다. 묶음 크기가 다르면 전체 관측치로 가중 평균하는 방식도 가능하며, 기준선의 예측을 각 훈련 부분에서 다시 계산해야 공정하다.

각 묶음에서 기준선도 동일한 훈련 부분으로 다시 계산해야 한다. 전체 표본의 평균을 검증 묶음에 대한 기준 예측으로 쓰면 미래 정답을 기준선에 포함하게 된다. 또한 식의 $1/k$ 평균은 묶음 크기가 같을 때 각 관측치의 비중이 같다. 크기가 다르면 관측치 수로 가중해 전체 제곱오차를 계산할 수 있다.

3.57 슬라이드 57 · 금융 교차검증의 두 경고

시간 의존이 있는 수익률을 무작위로 섞으면 미래 관측치가 과거 예측의 훈련에 들어갈 수 있다. 연 단위 블록을 떼거나, 예측 기간이 겹치는 경계 관측치를 제거해 누출을 줄인다. 같은 기업의 여러 달 관측치를 어떻게 묶을지도 목적에 따라 결정한다.

교차검증 점수는 벌점 선택에 이미 사용했기 때문에 약간 낙관적이다. 정말 손대지 않은 뒤쪽 기간의 성능이 더 높은 수준의 증거다. 표본내 적합, 검증, 최종 표본외 시험의 정보 순서를 유지한다.

12개월 누적수익률을 예측한다면 인접한 두 관측치의 목표가 11개월을 공유한다. 검증 경계의 양쪽 관측치를 그대로 두면 훈련 목표와 검증 목표가 거의 동일한 미래를 포함한다. 예측 기간에 맞는 간격을 두거나 겹치는 관측치를 제거해야 한다. 이는 단순한 무작위 k 겹보다 더 엄격한 시간 검증이다.

3.58 슬라이드 58 · OLS, 능형, 라쏘의 결과 비교

같은 과거 수익률 특징 357개를 쓰면 OLS가 표본내 R^2 는 가장 높아도 검증 점수는 음수가 될 수 있다. 능형과 라쏘는 표본내 적합을 포기하는 대신 검증 점수를 양수로 만들 수 있다. 이것이 편향을 도입한 이유를 경험적으로 보여 준다.

다만 표에 적힌 성과는 특정 자료·기간·검증 방식의 결과다. 모형을 실제로 투자에 사용하려면 종목 선정과 매매 시점, 상장폐지 수익률, 거래비용을 포함해 새 기간에서 다시 평가한다. 숫자 하나를 일반 법칙으로 외우지 않는다.

표본내 R^2 와 검증 R^2 가 반대 방향인 것은 모순이 아니다. OLS는 과거 자료에 가장 잘 맞도록 정의됐고, 능형·라쏘는 그 맞춤을 일부 포기한다. 비교표에서는 변수 수와 벌점뿐 아니라 기준선, 검증 시작일, 종목 필터를 확인해야 어떤 조건에서 역전이 일어났는지 알 수 있다.

3.59 슬라이드 59 · 예측 점수와 투자 성과가 다른 이유

R^2 는 모든 종목의 예측오차 제곱을 벌한다. 포트폴리오는 주로 종목의 상대 순위와 선택 경계 주변의 오류에 민감하다. 예측값의 크기가 다소 틀려도 상위·하위 종목의 순서가 맞으면 통속 수익은 괜찮을 수 있다.

반대로 R^2 가 좋아져도 거래가 잦고 유동성이 낮은 종목에 비중을 몰면 실제 성과는 나빠질 수 있다. 그러므로 통계적 목적함수와 경제적 목적함수를 구분한다. 투자비중의 제약과 비용을 반영한 검증은 별도의 설계 문제다.

예측값이 실제값보다 항상 절반 크기라도 종목의 순서를 정확히 맞히면 상위·하위 포트폴리오 선택은 같을 수 있다. 반대로 평균 제곱오차를 줄이는 데 기여한 대형주 몇 개가 투자 제한으로 매매 불가능하면 실전 편익은 작다. 순위 지표, 포트폴리오 손익, 비용 후 효용을 서로 다른 성과표로 둔다.

3.60 슬라이드 60 · 시장 전체 예측으로 돌아오기

정규화는 시장수익률 예측에서도 변수 선택과 계수의 요동을 줄인다. 그러나 한 나라의 시장 시계열은 독립 역사가 하나뿐이고, 종목 간 횡단면과 달리 같은 달에 수천 개 관측치를 얻지 못한다. 위기와 제도 변화로 관계도 바뀐다.

따라서 개별 종목의 상대 수익률 예측에서 개선이 있었다고 시장 타이밍의 큰 개선을 기대할 수는 없다. 강한 기준선과 다양한 시작일에서 견고한지 확인한다.

횡단면에서는 한 달에 많은 종목의 상대 차이를 관찰하지만 시장 시계열에는 한 달에 시장 수익률 하나뿐이다. 변수 수가 같아도 추정 가능한 정보량과 공통 충격의 비중이 다르다. 시장 타이밍에 정규화를 적용할 때는 긴 기간의 구조 변화와 한 나라에만 맞춘 결과를 특히 경계한다.

3.61 슬라이드 61 · 극단적 복잡성의 논쟁

짧은 자료에 비해 훨씬 많은 무작위 비선형 특징을 만들고 능형회귀를 적용하면, 겉으로는 큰 표본외 성과가 나올 수 있다. 한 해석은 높은 차원의 표현이 놓친 패턴을 잡았다는 것이다. 다른 해석은 특정 설정에서 예측이 최근 수익률의 가중평균으로 수렴해 단순 모멘텀을 재포장한다는 것이다.

두 주장을 가르려면 단순한 최근 수익률 규칙과 같은 기간·비용·위험으로 비교하고, 특징 생성과 튜닝의 모든 선택을 포함해 재현해야 한다. 최신 연구의 성공과 반박을 모두 가설로 두는 태도가 적절하다.

복잡한 특징의 성과를 확인할 때는 가장 단순한 대체 설명을 먼저 구현한다. 최근 수익률의 가중평균만으로 비슷한 예측이 나온다면 많은 무작위 특징의 역할은 새 경제 정보를 찾는 것이 아닐 수 있다. 특징 수, 무작위 시드, 별점 탐색 범위까지 선택 과정에 포함해 독립 기간에서 비교해야 한다.

3.62 슬라이드 62 · 수익률 예측에서 확립된 규칙

첫째, 과거 평균이나 0 같은 명확한 기준선을 정한다. 둘째, 데이터의 발표·수정 시점을 지켜 미래 정보가 들어가지 않게 한다. 셋째, 계수의 자유도를 신호대잡음비에 맞춰 제한한다. 넷째, 검증에 사용한 자료와 최종 보고 자료를 분리한다.

예측 점수와 투자 수익은 다르므로 어느 결정을 개선하려는지 끝까지 명시한다. 다음 장에서는 시장 전체보다 종목 간 상대 수익률로 대상을 바꾼다. 그때는 이상현상의 경제적 이유와 여러 요인을 동시에 시험하는 문제가 추가된다.

실제 분석 체크리스트는 다음 순서로 실행할 수 있다. 먼저 예측 시점과 목표 수익률을 고정하고, 그때 공개된 자료만 묶는다. 과거 평균과 규칙이 단순한 모형을 만들고, 훈련·검증에서 별점을 정한 뒤, 손대지 않은 시험 기간의 오차와 거래비용 후 손익을 보고한다. 이 순서를 지켜야 복잡성의 편익을 믿을 수 있다.

4 04. 종목 간 기대수익률과 요인 논쟁

시장이 내년에 오를지 예측하는 일과, 같은 달에 어떤 종목이 다른 종목보다 나을지 예측하는 일은 다르다. 후자는 공통 시장 충격을 매수·매도 포지션으로 일부 상쇄할 수 있지만, 작은 주식의 거래비용과 공매도 제약이 중요해진다. 이 장은 종목 특성을 전략으로 만드는 절차에서 출발해 위험 보상·가격오류·우연이라는 세 설명을 평가한다.

4.1 슬라이드 01 · 횡단면의 출발점

횡단면은 한 시점의 여러 종목을 가리킨다. 시장 시계열 예측은 다음 달 시장 전체의 평균을 묻지만, 횡단면 예측은 같은 달 종목의 상대 순위를 묻는다. 모든 종목이 하락한 달에도 덜 하락한 종목을 사고 더 하락한 종목을 공매도하면 룬셋 차이는 양수일 수 있다.

하지만 룬셋 수익은 무위험이 아니다. 공매도 비용, 차입 가능성, 포지션을 다시 맞추는 비용, 시장 급변 시 두 다리의 동시 손실을 함께 고려한다.

횡단면 전략은 시장 방향을 완전히 제거하지 않을 수 있다. 매수·매도 다리의 시장 베타가 다르면 시장 급등락의 영향을 받는다. 예를 들어 매수 다리의 베타가 1.2, 매도 다리가 0.8이면 룬셋의 순베타는 약 0.4다. 종목 순위의 예측과 공통시장 노출을 따로 측정해야 한다.

4.2 슬라이드 02 · 앞 장에서 건너오는 다리

시장 전체의 평균수익률은 한 나라의 짧은 역사에서 추정한다. 종목 간 비교에는 매월 여러 기업의 특성이 있어 자료가 풍부해 보인다. 그러나 같은 달 종목은 공통 충격을 공유하므로 표본 행 수가 독립 정보량과 같지는 않다.

이번 장의 목표는 종목 특성이 수익률을 예측한다는 주장과, 왜 그런지에 대한 설명을 구분하는 것이다. 다음 단계의 머신러닝은 많은 특성의 함수를 추정하지만 먼저 고전적 실증 결과의 구조를 알아야 한다.

매달 3,000개 종목이 있어도 경기 충격은 한 번 관찰한 것이다. 종목별 행을 3,000개의 독립 실험처럼 취급하면 자신감이 과장된다. 반대로 횡단면의 장점은 같은 거시 상태에서 여러 기업의 특성을 비교할 수 있다는 점이다. 단면의 폭과 시간의 길이가 각각 어떤 정보를 주는지 분리하자.

4.3 슬라이드 03 · 요인 동물원의 네 질문

수백 개 기업 특성 가운데 어느 것이 다른 특성을 통제된 뒤에도 정보를 갖는가. 그 정보를 보상받는 위험으로 설명할 수 있는가. 발표된 전략은 새 기간과 큰 종목에서도 남는가. 여러 변수가 같은 경제적 주제를 반복 측정하는 것은 아닌가.

한 특성의 평균 수익률만으로 네 질문에 답할 수 없다. 비교 포트폴리오의 구성, 위험모형, 표본 기간, 거래 가능성을 차례로 명시해야 한다.

네 질문은 서로 다른 판정이다. 특성이 다른 특성을 통제된 후에도 예측하면 통계적 독립성의 증거이지만, 그 원인이 위험인지는 아직 모른다. 새 기간에 남아도 거래비용을 넘지 못할 수 있다. 한 논문이 네 질문 중 어느 것에 답했는지 표로 표시하면 과장된 결론을 피할 수 있다.

4.4 슬라이드 04 · 특성에서 전략으로

장부가치/시가총액이나 지난 11개월 수익률 같은 특성은 기업별 숫자다. 투자전략은 이 숫자로 종목을 정렬하고 어느 그룹을 사고 팔지 정해야 비로소 정의된다. 같은 특성도 동일가중·시가총액가중, 소형주 포함 여부에 따라 다른 성과를 낸다.

또한 특성은 미래 시점에 실제로 알 수 있어야 한다. 연말 재무제표를 그해 12월의 거래에 사용하는 것은 발표 전 정보를 사용한 오류가 될 수 있다.

특성 값이 같아도 포트폴리오 규칙이 달라지면 결과가 달라진다. 100개 종목을 동일가중하면 각 1%지만 시가총액가중에서는 대형주가 대부분을 차지한다. 관측된 알파가 몇몇 초소형주에서만 왔다면 큰 기관투자자가 재현하기 어렵다. 정렬 기준, 가중치, 재조정일이 전략의 일부다.

4.5 슬라이드 05 · 십분위 포트폴리오 정렬

매월 종목을 특성 $X_{i,t}$ 순서로 정렬해 10개 그룹으로 나누고, 상위 그룹을 매수하고 하위 그룹을 매도한다. 다음 달 수익률 차이 $r_{10,t+1} - r_{1,t+1}$ 를 계산해 시간 평균을 낸다. 이는 특성의 극단 사이에 수익률 기울기가 있는지 보여 준다.

예를 들어 모멘텀은 최근 한 달을 제외한 과거 6~12개월 수익률이 높은 종목을 사는 방식이다. 최근 한 달 제외는 단기 반전과 거래 미시구조의 영향을 줄인다. 실제 전략 성과에는 종목 교체 비용과 공매도 비용을 빼야 한다.

매수·매도 수익률 차이는 두 다리를 모두 같은 명목 금액으로 잡았을 때의 계산이다. 패자 그룹의 수익률이 -2%, 승자가 1%이면 차이는 3%지만 공매도 주식의 대차 비용과 매매 스프레드는 아직 빠지지 않았다. 그룹 평균을 낼 때 결측·상장폐지 수익률도 포함해야 실제 투자 가능성을 평가할 수 있다.

4.6 슬라이드 06 · 파마·맥베스 회귀의 두 단계

매월 종목들 사이에서 $r_{i,t+1} = a_t + b_t X_{i,t} + e_{i,t+1}$ 를 회귀하여 그 달의 기울기 b_t 를 얻는다. 그런 다음 T 개월 기울기의 평균 $\bar{b} = T^{-1} \sum_t b_t$ 가 0과 다른지 검정한다. 여러 특성을 동시에 넣으면 다른 특성을 고정한 조건부 관련성을 볼 수 있다.

정렬은 극단 그룹의 차이를 직관적으로 보여 주고 회귀는 여러 특성을 동시에 통제하기 쉽다. 둘 다 수익률과 특성의 관계를 측정할 뿐 원인을 자동으로 밝혀 주지 않는다.

두 단계가 필요한 이유는 단면 기울기가 매달 다른 시장 상태에서 추정되기 때문이다. 1단계는 '이번 달 어느 특성이 상대수익과 연결됐는가'를 묻고, 2단계는 '그 기울기가 여러 달에 걸쳐 평균적으로 남는가'를 묻는다. 회귀에 넣는 특성은 수익률보다 먼저 측정해야 하며, 계수는 그 특성의 단위에 의존한다.

4.7 슬라이드 07 · 높은 수익률과 이상현상의 차이

고위험 주식의 높은 평균수익률을 주는 것은 위험을 싫어하는 투자자에게 정상적인 보상일 수 있다. **이상현상**은 특정 기준 자산가격모형이 설명하지 못하는 수익률 차이를 뜻한다. 따라서 기준모형을 바꾸면 이상현상의 유무도 달라질 수 있다.

예를 들어 CAPM만 기준으로 할 때의 알파와 시장·가치·규모 요인을 함께 넣은 뒤의 알파는 다르다. "이상"은 자연법칙 위반이 아니라 선택한 모형의 설명 실패라는 의미다.

CAPM에서 설명한 뒤의 알파는 $\alpha_i = E[r_i - r_f] - \beta_{iM} E[r_M - r_f]$ 이다. 평균 초과수익이 양수여

도 시장 베타에 따른 요구수익률과 같으면 CAPM 알파는 0이다. 다른 기준요인을 더하면 알파가 바뀌므로 '이상현상 100개'는 하나의 절대적 사실 목록이 아니다.

4.8 슬라이드 08 · 왜 월별 기울기의 표준오차를 쓰는가

한 달에 3,000개 종목이 있어도 모두 같은 금리·경기 충격을 겪는다. 모든 종목·월을 독립 관측치로 취급한 단순 합동회귀는 표준오차를 지나치게 작게 만들 수 있다. 월별 횡단면 기울기 b_t 를 구한 뒤 시간에 따라 변하는 b_t 의 분산으로 평균의 불확실성을 재는 이유다.

$$\widehat{se}(\bar{b}) = \sqrt{\frac{1}{T(T-1)} \sum_{t=1}^T (b_t - \bar{b})^2}.$$

이 식은 월별 기울기가 시간상 독립이라는 단순 조건의 표준오차다. 자기상관이 있으면 Newey-West 같은 장기분산 추정이 필요하다. 독립 표본 수를 종목 수가 아니라 시간의 길이와 연결하는 것이 핵심이다.

월별 기울기가 자기상관을 가지면 분산 계산에 시차별 공분산이 더해진다. 즉 $\text{Var}(\bar{b})$ 는 단순한 월별 분산 나누기 T 가 아니라, 인접한 달의 기울기가 함께 움직이는 정도를 반영한다. Newey-West는 일정한 시차까지 이런 공분산을 더해 장기분산을 추정한다.

4.9 슬라이드 09 · 여섯 범주의 지도

수익률 예측변수는 모멘텀, 가치, 투자, 수익성, 무형자산, 거래마찰로 묶을 수 있다. 이는 변수를 정리하는 **분류표**이지 각 범주의 인과이론이 아니다. 같은 범주 안에도 측정 방식과 경제적 채널이 다르다.

각 범주를 읽을 때 신호와 매수·매도 방향, 위험 보상 설명, 기대 오류 설명, 재현성과 거래 가능성의 순서로 살펴보면 서로 비교하기 쉽다.

범주는 복잡한 변수 목록을 읽기 위한 지도다. 예컨대 '가치'에 속하는 장부가치/시가총액과 이익/가격은 모두 낮은 가격을 포착하지만 회계자료의 의미가 다르다. 같은 이름 아래 신호를 합치기 전에 분자와 분모, 발표 시점, 산업 편차를 확인해야 범주 안의 이질성을 놓치지 않는다.

4.10 슬라이드 10 · 여섯 범주의 대표 신호

모멘텀은 최근 승자, 가치는 낮은 가격/기초가치, 투자는 자산 증가가 낮은 기업, 수익성은 이익률이 높은 기업을 매수하는 방향이다. 무형자산은 연구개발과 조직자본처럼 장부에 잘 보이지 않는 투자, 거래마찰은 규모·유동성·변동성과 연결된다.

같은 범주에도 여러 변수와 정렬법이 있다. 한 범주의 일부 전략이 재현된다는 사실을 그 범주의 모든 전략이 유효하다고 해석하면 안 된다. Hou-Xue-Zhang¹⁹은 공통한 구성 규칙으로 대규모 목록을 다시 검정한다.

신호의 방향도 정의에 따라 뒤집힌다. B/M 이 높은 종목을 가치주라 부르면 높은 값 매수지만, 같은 정보를 M/B 로 쓰면 낮은 값 매수다. 표에 '효과가 양수'라고 적혔을 때 변수 정의와 정렬 방향을 함께 읽어야 한다. 실무에서는 원자료의 단위와 극단값 처리까지 맞춰야 재현 가능하다.

¹⁹<https://doi.org/10.1093/rfs/hhy131>

4.11 슬라이드 11 · 낮은 가격은 두 가지를 말한다

한 기간 뒤 현금흐름 CF 의 기대값을 단순화해 쓰면 $P = E[CF]/(1 + E[r])$ 이다. 현재 가격이 낮다는 관찰은 할인율, 즉 요구수익률이 높다는 뜻일 수도 있고 투자자가 미래 현금흐름을 지나치게 비관적으로 봤다는 뜻일 수도 있다.

이 식은 위험과 미래 현금흐름의 공분산을 생략한 교육용 단순식이다. 엄밀한 가격식은 확률적 할인인자 m_{t+1} 을 써서 $P_t = E_t[m_{t+1}CF_{t+1}]$ 로 나타낸다. 이 구별을 지켜야 회계비율의 예측력을 곧바로 위험 프리미엄이라고 단정하지 않는다.

한 기간 가격식에서 $E[CF]$ 가 110, 가격이 100이면 단순 기대수익률은 10%다. 같은 100이라는 가격은 기대현금흐름이 105이고 요구수익률이 5%인 경우에도 나온다. 가격 하나만으로 할인율과 현금흐름 기대를 분리할 수 없는 식별 문제다. 이후 실적과 나쁜 경기 상태의 수익을 함께 보아야 한다.

4.12 슬라이드 12 · 각 범주를 같은 질문으로 읽기

첫째, 특성은 언제 측정하고 어떤 종목을 매수·매도하는가. 둘째, 왜 수익률 차이가 생기는가. 위험에 대한 보상인지, 투자자의 지나친 낙관·비관이 수정되는 것인지 따진다. 셋째, 원래 표본을 벗어나도 남는가.

세 질문은 순서가 있다. 거래를 정의하지 않으면 성과를 측정할 수 없고, 성과가 견고하지 않으면 정교한 설명도 설득력을 잃는다. 설명이 맞더라도 비용 뒤 이익이 없을 수 있다.

공통 질문은 재현 가능한 기록 양식이기도 하다. 매수·매도 방향이 없는 변수 주장은 투자전략이 아니고, 발표 시점을 모르는 성과는 시점 누출을 배제할 수 없다. 위험과 가격오류의 설명이 모두 가능한 경우에는 각각이 예측하는 위기 손실과 실적발표 반응을 적고 자료로 비교한다.

4.13 슬라이드 13 · 모멘텀의 위치

모멘텀은 과거 상승 종목이 단기적으로 더 상승하는 경향이다. 시장 전체가 계속 오르는 것과 다르게 **같은 달 종목 사이의 상대 승자**를 말한다. 투자자의 정보 반응 지연, 추세 추종 거래, 위험 노출 등이 가능한 설명이다.

모멘텀에는 큰 반전 손실이 나타날 수 있어 평균수익률 하나로 위험을 요약하기 어렵다. 다음 세 슬라이드에서 신호·원인·폭락을 분리한다.

모멘텀은 '과거 수익률이 미래 수익률에 양의 관련성을 갖는다'는 말이지만 기간을 정해야 한다. 직전 1개월 반전, 2~12개월 지속, 더 긴 기간의 반전이 동시에 존재할 수 있다. 형성 기간과 보유 기간을 바꿔가며 가장 좋은 조합만 보고하면 선택 편향이 생긴다.

4.14 슬라이드 14 · 과거 승자가 계속 이기는가

매월 형성 시점까지 공개된 가격으로 지난 6~12개월 수익률을 계산하되 직전 한 달을 뺀다. 승자 그룹을 사고 패자 그룹을 판 뒤 다음 달 수익률을 쟀다. 실적 서프라이즈 뒤의 가격 지연 반응도 관련 모멘텀 신호다.

단기 반전 때문에 직전 한 달을 빼는 설계는 임의적인 숫자 놀이가 아니다. 거래비용·유동성 충격과 중기 정보 반응을 구분하려는 장치다. 대형주에서도 남는지와 매매회전율을 함께 확인해야 한다.

예를 들어 12개월 전부터 2개월 전까지의 누적수익률을 신호로 만들고, 현재 월말에 포트폴리

오를 형성해 다음 달 수익률을 낸다. 직전 한 달을 제외한다는 규칙은 예측 시점 뒤의 한 달을 건너뛴다는 뜻이 아니다. 형성·건너뛸·보유 기간을 시간선에 표시하면 이런 혼동을 줄일 수 있다.

4.15 슬라이드 15 · 모멘텀의 위험과 가격오류 설명

위험 설명은 승자·패자 포트폴리오가 나쁜 경제 상태에서 손실을 주기 때문에 평상시 높은 평균 수익률이 보상이라는 주장이다. 가격오류 설명은 투자자가 새 정보에 천천히 반응해 승자의 좋은 소식이 몇 달에 걸쳐 가격에 반영된다는 주장이다.

둘은 폭락 시점과 뉴스 이후 반응에 대해 다른 예측을 한다. 다만 한 사례가 어느 한쪽을 완전히 증명하지는 않는다. 위험 요인이 무엇인지, 투자자가 왜 늦게 반응하는지 각각 검증 가능한 메커니즘을 제시해야 한다.

가격오류가 느린 정보 반응에서 온다면 실적발표 이후 여러 달에 걸친 조정과 분석가 전망의 늦은 수정이 관찰될 수 있다. 위험 보상이라면 평상시 이익이 큰 전략이 투자자의 한계효용이 높은 위기 상태에서 손실을 줄 가능성이 중요하다. 두 설명은 같은 평균수익률을 예측해도 상태별 패턴에서 달라진다.

4.16 슬라이드 16 · 평균 모멘텀과 폭락 위험

모멘텀의 평균 수익이 양수라도 시장 급락 뒤 강한 반등에서는 과거 패자들이 폭등할 수 있다. 패자를 공매도한 포지션은 이때 큰 손실을 낸다. 평상시 평균과 위기 상태의 손실이 비대칭인 것이다.

손실은 단순 표준편차보다 꼬리위험, 마진 요구, 포지션 강제 청산에 중요하다. Daniel Moskowitz²⁰의 분석은 모멘텀 수익과 급격한 반전 위험을 함께 평가하게 한다. 전략의 적정 규모는 평균수익률뿐 아니라 이런 상태에서 버틸 수 있는 자금에 달려 있다.

모멘텀 폭락은 과거 패자를 공매도한 다리에서 크게 나타날 수 있다. 시장이 급락한 뒤 반등하면 재무상태가 취약했던 패자의 주가가 급히 회복해 공매도 손실이 커진다. 이때 표준편차와 샤프비율만 보면 드문 큰 손실을 과소평가할 수 있으므로 조건부 손실과 자금조달 제약을 함께 본다.

4.17 슬라이드 17 · 가치와 성장의 구분

가치주는 주가가 장부가치, 이익, 현금흐름에 비해 낮은 기업이다. “가격이 싸다”는 것은 주당 절대가격이 낮다는 뜻이 아니라 기초가치와의 비율이 낮다는 뜻이다. 성장주는 미래 확장에 대한 기대가 가격에 많이 반영된 기업이다.

가치 프리미엄은 가치주를 사고 성장주를 판 상대수익률이다. 두 그룹의 현재 수익성과 미래 성장성은 다를 수 있으므로 단순 비율의 경제적 해석에는 주의가 필요하다.

주당 1,000원인 주식이 주당 100,000원인 주식보다 자동으로 ‘싸다’는 뜻이 아니다. 주식 수와 기업의 자산·현금흐름이 다르기 때문이다. 가치 분류는 가격을 장부자본, 이익, 현금흐름 등과 비교한다. 분모가 일시적으로 높거나 회계상 낮을 때 신호가 왜곡될 수 있다.

²⁰<https://doi.org/10.1016/j.jfineco.2015.12.002>

4.18 슬라이드 18 · 장부가치/시가총액으로 정렬하기

B/M 이 높은 종목은 장부상 자기자본에 비해 주가가 낮다. 같은 투자금으로 더 많은 장부가치를 사는 셈이지만, 장부가치의 질이 낮거나 미래 손실이 클 수도 있다. 값이 높다는 사실만으로 저평가를 확정하지 않는다.

산업마다 회계처리와 무형자산 비중이 달라 비율이 구조적으로 다르다. 업종 내 비교나 무형자산 보정은 신호를 바꿀 수 있다. 실무에서는 재무제표 발표 지연을 반영하고 상장폐지 종목을 포함해야 성과를 과대평가하지 않는다.

시가총액은 주가에 발행주식 수를 곱한 값이므로 주식분할 자체는 B/M 의 경제적 의미를 바꾸지 않는다. 반면 손실 누적으로 장부자본이 작아지거나 음수가 되면 비율의 해석이 어려워진다. 해당 종목을 어떻게 처리했는지, 산업 내 순위를 썼는지, 회계자료가 언제 공개됐는지 확인해야 한다.

4.19 슬라이드 19 · 가치 프리미엄의 두 해석

위험 해석은 가치기업의 현금흐름이 경기 악화 때 더 크게 줄어들어 투자자가 높은 기대수익률을 요구한다는 것이다. 가격오류 해석은 시장이 과거 부진을 지나치게 연장해 낮은 가격을 매겼다가 예상을 고치는 과정에서 초과수익이 생긴다는 것이다.

둘을 가르려면 나쁜 상태에서의 수익률, 이후 실적발표에 대한 반응, 투자자 기대의 변화가 필요하다. 단순히 B/M 이 높고 미래 수익률도 높다는 상관 하나로는 충분하지 않다.

위험 해석은 투자자에게 가장 어려운 때에 가치주 전략이 손실을 주는지 확인해야 설득력이 있다. 가격오류 해석은 이후 현금흐름이 당시 기대보다 높게 나오는지, 그 발표에 주가가 반응하는지 묻는다. 단순 가치주 평균수익률은 두 설명에서 모두 양수일 수 있으므로 판별력 있는 상태별 자료가 필요하다.

4.20 슬라이드 20 · 가치 효과의 기간과 측정

가치 프리미엄의 크기는 원래 연구 기간, 이후 장기 기간, 대형주만의 결과에 따라 달라질 수 있다. 장부에 계상되지 않은 연구개발·브랜드 자산을 보정하면 현대 기업의 장부가치가 바뀌고 가치 분류도 달라진다.

그러나 사후에 가장 높은 성과를 주는 보정법을 고르면 다시 과적합이 생긴다. 회계 원칙으로 보정법을 먼저 정하고 다른 나라·기간에서 확인해야 한다. 무형자산 조정은 단순한 수익률 높이기 기술이 아니라 **측정오차 개선 가설**이다.

무형자산 보정의 예로 연구개발 지출을 즉시 비용으로 보지 않고 몇 년간 자본화할 수 있다. 그러면 과거 지출의 누적액이 장부자본에 더해지고 당기 이익에서는 상각액을 차감한다. 내용연수와 상각률을 바꾸면 가치주 분류가 달라질 수 있으므로 보정 전후의 순위와 결과를 같이 보고한다.

4.21 슬라이드 21 · 투자와 수익성으로 넘어가기

기업의 실물 투자와 이익 창출 능력은 가격을 결정하는 현금흐름과 할인율 양쪽에 연결된다. 투자율이 높은 기업의 기대수익률이 낮고 수익성이 높은 기업의 기대수익률이 높은 패턴은 처음에는 직관에 어긋나 보인다.

하지만 기업이 언제 투자하기를 선택하는지 생각하면 부호를 유도할 수 있다. 이 장의 후반에서 투자 CAPM의 최적화 식으로 다시 확인한다.

투자과 수익성의 부호가 직관에 어긋나는 까닭은 '좋은 기업'과 '좋은 가격의 주식'이 다른 말이기 때문이다. 수익성이 높은 회사가 이미 매우 비싸다면 미래 수익은 낮을 수 있다. 반대로 같은 가격과 투자 규모에서 높은 미래 이익을 기대한다면 더 높은 요구수익률과 양립한다. 비교할 때 고정하는 조건을 명시해야 한다.

4.22 슬라이드 22 · 빠른 자산 증가와 낮은 미래수익률

총자산이 빠르게 늘어난 기업은 자본비용이 낮아 투자를 많이 할 수 있다. 또는 시장이 확장을 과도하게 낙관한 결과 미래 주식 수익률이 낮아질 수도 있다. 자산 증가율에는 인수합병, 현금 축적, 회계 변화가 섞일 수 있어 지표의 구성을 확인해야 한다.

낮은 투자 기업을 사고 높은 투자 기업을 파는 전략의 수익이 양수라면 두 설명 가운데 어느 것이 맞는지 추가 증거가 필요하다. 자금조달 비용, 이후 현금흐름, 발행 시점의 투자자 기대가 도움이 된다.

자산 증가율은 올해 총자산에서 작년 총자산을 뺀 뒤 작년 자산으로 나누어 계산할 수 있다. 하지만 합병으로 자산이 늘어난 것과 새 설비를 건설한 것은 다른 경제적 행동이다. 현금 보유 증가도 운영 투자가 아닐 수 있다. 변수의 구성요소를 분리해야 낮은 미래수익률이 어떤 투자 결정과 연결되는지 알 수 있다.

4.23 슬라이드 23 · 투자율과 할인율의 연결

새 설비의 기대수익이 할인율보다 높을 때 기업은 투자한다. 다른 조건이 같다면 자본비용이 낮은 기업은 더 많은 프로젝트를 채택할 수 있어 투자율이 높다. 따라서 높은 투자가 낮은 기대주식수익률을 암시할 수 있다.

하지만 모든 고투자 기업의 위험이 낮다는 뜻은 아니다. 투자 결정에는 성장 기회, 조정비용, 내부 자금 제약이 함께 들어간다. 투자율은 할인율의 **간접 신호**이며 다른 조건을 고정해야 해석된다.

기업의 한계 투자 기회가 동일하다면 자본비용이 낮을수록 더 낮은 기대수익을 주는 프로젝트까지 채택하므로 투자량이 늘어난다. 그러나 어떤 기업은 혁신 기회 자체가 많아 자본비용이 높아도 투자할 수 있다. 관찰된 투자율에서 할인율을 역으로 읽을 때 기회와 조정비용을 통제해야 하는 이유다.

4.24 슬라이드 24 · 수익성 높은 회사의 높은 수익률

이익/자산이나 자기자본이익률이 높은 기업이 미래에도 높은 수익률을 주는 패턴은 "좋은 기업은 이미 비쌀 텐데 왜 더 오르는가"라는 질문을 만든다. 가격이 비싸도 미래 현금흐름이 시장의 예측보다 더 좋아지면 추가 수익이 가능하다.

또는 높은 기대 수익성이 같은 투자율 아래에서 높은 할인율과 함께 나타날 수 있다. 수익성은 회계상 일회성 이익과 산업별 자본집약도에 영향을 받으므로 지속 가능한 영업 성과로 측정해야 한다.

수익성 지표가 높은 회사를 '좋은 주식'으로 부르기 전에 그 수익성이 가격에 얼마나 반영됐는지 본다. 현재 이익 10인 회사의 가격이 100인 경우와 300인 경우는 같은 이익률이어도 투자자의 기대수익이 다르다. 미래 이익의 지속성, 일회성 항목, 투자 규모를 함께 봐야 경제적 해석이 가능하다.

4.25 슬라이드 25 · 수익성 효과의 항등식과 설명

기업가치를 미래 현금흐름의 현재가치로 쓰면, 현재 가격과 예상 투자 규모가 주어졌을 때 기대 이익이 클수록 기대수익률도 높아져야 한다. 이는 특정 위험의 존재를 증명하는 이론이 아니라 가격·현금흐름·수익률 사이의 회계적 관계다.

위험 설명은 높은 수익성이 일정 투자와 함께 나타날 때 높은 할인율을 반영한다는 것이다. 가격오류 설명은 투자자가 우량 기업의 지속성을 충분히 가격에 반영하지 못한다는 것이다. 대형 유동주에서도 효과가 남는지, 이후 이익 서프라이즈가 있는지 비교한다.

수익성과 투자율은 기업가치 항등식에서 서로 연결된다. 예상 수익성이 높아도 그 이익을 얻기 위한 추가 투자가 매우 크면 주주에게 돌아올 현금흐름은 작을 수 있다. 위험·오류 논쟁에 앞서 회계 이익에서 투자 지출을 빼고 가격과 비교하는 절차가 필요하다.

4.26 슬라이드 26 · 두 자산가격 요인모형

파마·프렌치 5요인모형은 시장, 규모, 가치에 수익성 RMW와 투자 CMA를 더한다. 다른 q 요인 모형도 수익성과 투자를 중심에 둔다. 요인을 추가하면 원래 이상현상의 알파가 줄어들 수 있지만, 이것만으로 요인이 경제적으로 올바른 위험이라는 뜻은 아니다.

요인모형은 넓은 종목 집합의 평균수익률을 소수 공통 변수로 설명하는 도구다. 모델 간 경쟁은 어떤 포트폴리오를 기준으로 평가하고, 새 자료에서도 가격오차가 작은지로 이루어져야 한다.

RMW는 수익성이 강한 기업을 매수하고 약한 기업을 매도하는 수익률, CMA는 보수적으로 투자하는 기업을 매수하고 공격적으로 투자하는 기업을 매도하는 수익률이다. 요인 수익률은 기업 특성의 숫자 자체가 아니라 그 특성으로 만든 포트폴리오 수익이다. 개별 종목의 요인 베타와 특성 수준을 구별해야 한다.

4.27 슬라이드 27 · 무형자산의 회계 문제

기계는 자산으로 올리고 여러 해에 걸쳐 감가상각하는 반면 연구개발·조직 구축 비용은 즉시 비용 처리되는 경우가 많다. 경제적으로는 둘 다 미래에 수익을 줄 수 있는 투자여도 회계 장부에는 다르게 남는다.

따라서 장부가치, 수익성, 투자율의 비교가 무형자산 비중 높은 기업에 불리하게 왜곡될 수 있다. 단, 모든 연구개발 지출이 성공적 자산으로 남는다는 가정도 과하다.

회계상 비용 처리와 경제적 자산 형성이 다르면 분모인 장부자본뿐 아니라 분자인 이익도 흔들린다. 연구개발 지출이 많은 기업은 당기 보고 이익이 낮고 미래의 수익 창출 능력은 높을 수 있다. 하지만 실패한 연구개발은 자산 가치가 0일 수 있으므로 지출 전액을 기계적으로 자산화해서도 안 된다.

4.28 슬라이드 28 · 장부 밖 투자와 비율의 왜곡

두 기업이 각각 100을 미래 생산능력에 투입한다고 하자. 설비 구매는 자산에 남고 당기 감가상각 10만 비용일 수 있지만, 연구개발 100은 당기 비용으로 처리될 수 있다. 그러면 경제적 투자 규모가 비슷해도 보고 이익과 장부자본이 크게 다르다.

이 차이는 B/M 과 ROE의 분자·분모를 동시에 바꾼다. 무형자산을 자본화하려면 내용연수와 상각률을 가정해야 하므로 새 측정오차도 생긴다. 회계 보정의 경제적 근거와 민감도 분석을 함께 제시해야 한다.

연구개발 100을 5년에 걸쳐 균등 상각한다고 가정하면 첫째 비용은 20이고 남은 자산은 80이 된다. 즉시 비용 처리와 비교해 첫째 이익과 장부자본이 각각 80 높아진다. 이것은 사실의 발견이 아니라 내용연수 5년이라는 가정을 적용한 재작성이다. 다른 상각기간에서도 결론이 남는지 확인해야 한다.

4.29 슬라이드 29 · 무형자산 프리미엄의 두 설명

핵심 인력과 기술 지식은 경기 충격 때 가치가 불안정할 수 있어 위험 보상을 요구할 수 있다. 다른 한편 투자자가 장부에 드러나지 않는 역량을 늦게 인식하면 가격오류가 생길 수 있다. 연구개발의 수익은 성공과 실패가 크게 갈려 평균만으로 판단하기 어렵다.

고용 이동, 특허, 광고, 영업레버리지 같은 대응변수는 서로 다른 무형자본을 측정한다. 여러 지표를 하나의 “무형자산 효과”로 묶을 때는 각각의 측정 대상이 무엇인지 확인한다.

무형자산은 물리적 담보로 회수하기 어렵고 핵심 인력이 떠나면 가치가 급락할 수 있어 위험 설명이 가능하다. 반대로 장부에 드러나지 않는 성공적 연구개발을 시장이 늦게 인식하면 가격오류 설명이 가능하다. 특허 수 같은 대응변수는 연구의 양을 보여도 상업적 가치를 직접 측정하지 못한다.

4.30 슬라이드 30 · 낮은 범주 재현율을 해석하기

무형자산 범주의 많은 신호가 공통 기준에서 재현되지 않는다고 해서 무형자본 자체가 수익률과 무관하다고 결론 낼 수 없다. 범주에 분석가 전망, 이익의 질, 계절성 같은 변수가 함께 포함되기 때문이다.

연구개발을 매출로 나누는지 시가총액으로 나누는지에 따라 신호의 의미도 달라진다. 전자는 활동의 강도, 후자는 시장이 붙인 가격 대비 지출을 뜻한다. 범주의 재현율은 **분류표의 평균**이지 개별 경제 기제의 검정이 아니다.

범주 평균이 낮게 재현된다는 사실은 그 안의 특정 고품질 지표를 반박하지 않는다. 반대로 한 지표가 성공해도 ‘무형자산은 언제나 프리미엄을 준다’고 일반화할 수 없다. 연구개발/매출은 기업의 투자 강도를, 연구개발/시가총액은 가격 대비 투자액을 나타내므로 같은 기업도 두 순위가 다를 수 있다.

4.31 슬라이드 31 · 거래마찰은 가격과 비용을 함께 바꾼다

규모가 작고 거래가 드문 종목의 높은 평균수익률은 위험 프리미엄일 수도 있지만, 실제 투자자가 그 가격에 거래하기 어려운 데 대한 보상일 수도 있다. 호가 스프레드와 가격 충격을 빼면 종이 위의 이익이 줄어든다.

따라서 실증 전략의 수익률을 읽을 때 수익을 만든 종목의 시가총액 비중과 매매 가능한 규모를 함께 본다. 동일가중 포트폴리오는 작은 기업을 경제 전체에서 차지하는 비중보다 크게 반영한다.

거래비용은 고정 수수료만이 아니다. 매수호가와 매도호가의 차이, 주문으로 가격을 움직이는 충격, 공매도 주식의 차입료가 포함된다. 월평균 룬샷 수익이 1%여도 양쪽 다리를 매달 크게 갈아타면 순수익은 음수가 될 수 있다. 명목 수익률과 실제 체결 가능 수익률을 구분하자.

4.32 슬라이드 32 · 소형주와 비유동성

소형주는 분석가의 관심이 적고 정보가 가격에 늦게 반영될 수 있다. 동시에 경기 악화 때 자금 조달이 더 어렵고 거래를 청산하기도 힘들어 투자자가 보상을 요구할 수 있다. 두 설명은 함께 성립할 수 있다.

거래가 드문 주식의 마지막 체결가격은 현재 시장가치보다 오래된 값일 수 있다. 관측 수익률과 실제 가능한 매도가격의 차이를 무시하면 작은 종목 중심 전략의 성과가 과장된다.

마지막 거래가격으로 계산한 수익률은 투자자가 같은 가격에 원하는 수량을 매매할 수 있다는 보장이 없다. 소형주 100개에 동일 금액을 투자하려면 각 기업의 일일 거래대금 대비 주문 비율을 확인해야 한다. 전략 규모가 커질수록 관측 가격과 체결 가격의 차이가 커지는 용량 문제가 생긴다.

4.33 슬라이드 33 · 고유변동성과 단기 반전

시장요인으로 설명되지 않는 개별 종목의 변동성을 고유변동성이라 한다. 전통적 분산투자 이론에서는 잘 분산할 수 있는 위험에 높은 보상이 필요하지 않지만, 실제 자료에서는 고유변동성이 높은 종목의 낮은 평균수익이 관찰되기도 한다.

직전 한 달 급등·급락 뒤 반전은 투자자 과잉반응 또는 유동성 공급의 대가일 수 있다. 호가 반등처럼 미시구조에서 나온 가짜 패턴도 가능하다. 비용과 대형주 표본에서 남는지를 확인해야 한다.

고유변동성이 높다는 것은 시장 베타로 설명되지 않는 잔차가 크게 흔들린다는 뜻이다. 분산투자가 완전하고 거래가 자유롭다면 이런 위험은 가격에 큰 보상을 요구하지 않는다. 실제 투자자에게는 공매도·집중 보유 제약이 있어 분산이 완전하지 않을 수 있다. 관찰된 낮은 평균수익의 원인을 분리하려면 이 제약과 과거 급등 종목의 영향도 살펴야 한다.

4.34 슬라이드 34 · 거래마찰 범주의 재현

소형·비유동주를 큰 비중으로 담는 전략은 원래 표본에서는 강한 차이를 보일 수 있지만 시가총액가중이나 대형주 기준으로 바꾸면 약해진다. 이는 통계적 존재와 실제 운용 가능성이 다른 질문임을 보여 준다.

높은 평균 수익률이 거래비용의 보상이라면 비용을 빼기 전 수익은 '공짜 돈'이 아니다. 매매 규모가 커질수록 자신의 거래가 가격을 움직인다는 시장충격도 반영해야 한다.

동일가중은 종목마다 같은 원화를 놓지만 시가총액가중은 시장 전체에서 큰 기업에 더 많은 원화를 놓는다. 둘의 성과 차이가 크다면 신호가 작은 기업에서 강하다는 단서다. 이것은 효과가 '가짜'라는 증명은 아니지만 규모가 큰 실제 자금을 투입했을 때 얻을 수 있는 수익을 다시 계산하라는 경고다.

4.35 슬라이드 35 · 여섯 범주를 한꺼번에 비교하기

모멘텀은 평균 성과와 폭락 위험, 가치는 할인율과 예상오류의 구분, 투자는 기업의 최적 선택, 수익성은 현금흐름과 가격의 관계, 무형자산은 측정, 거래마찰은 구현 비용이 핵심이다. 서로 다른 범주에 한 가지 설명을 억지로 적용하면 중요한 차이가 사라진다.

재현율은 해당 범주의 여러 지표 중 정해진 통계 기준을 넘은 비중이다. 이것은 경제적 원인이나 모든 종목에서의 거래가능 수익률을 뜻하지 않는다. 다음 절에서 위험·가격오류·우연을 구분하는 검증을 살핀다.

여섯 범주를 하나의 순위로 세우기 전에 공통한 평가표를 만든다. 형성 시점, 보유 기간, 가중치, 공매도 가능성, 기준요인, 거래비용을 같은 방식으로 맞춘다. 모멘텀의 높은 평균과 폭락 위험, 유동성 신호의 비용 문제처럼 서로 다른 약점을 한 숫자의 평균수익률로 덮지 않는다.

4.36 슬라이드 36 · 위험인가 가격오류인가

같은 예측변수가 미래 수익률과 상관되어도 경제적 해석은 갈린다. 위험 프리미엄이라면 나쁜 상태에서 손실을 주는 보상이고, 가격오류라면 투자자의 기대가 체계적으로 잘못되었다가 수정 되는 이익이다.

이 구분은 투자자에게도 중요하다. 위험 보상은 시장이 효율적이어도 남을 수 있지만 위기 손실을 감수해야 한다. 가격오류는 경쟁과 자금 유입으로 줄어들 수 있으며, 그 속도는 차익거래 제약에 달려 있다.

위험 보상은 투자자의 소비가 나쁠 때 돈을 잃는 자산에 더 높은 기대수익을 요구하는 논리다. 가격오류는 같은 위험인데도 정보 해석이나 거래 제약 때문에 가격이 일시적으로 틀렸다는 논리다. 두 설명은 동시에 일부 맞을 수 있으므로 결과를 양자택일로 묻기보다 어느 부분을 각각 설명하는지 측정한다.

4.37 슬라이드 37 · 두 설명의 서로 다른 예측

위험 설명은 전략의 수익이 소비가 낮거나 유동성이 부족한 상태에서 나빠진다고 예측한다. 가격오류 설명은 잘못된 기대가 드러나는 실적발표 같은 시점에 수익이 집중되고, 공개·발표 후에는 효과가 감소할 수 있다고 예측한다.

하지만 발표 후 수익 감소만으로 가격오류를 확정할 수는 없다. 위험의 가격이 바뀌거나 기업의 구성이 변했을 수 있다. 하나의 검정이 아니라 여러 시점·상태·집단에서 예측을 맞춰 보아야 한다.

위험 설명을 시험할 때 '경기침체 달에 수익률이 낮다'는 상관만으로 끝나지 않는다. 투자자의 한계효용이 높은 상태를 어떤 자료로 측정했는지, 그 상태에 대한 노출이 기존 요인과 중복되는지 본다. 가격오류 설명에서는 실적발표 전후의 누적 수익과 기대치 수정이 실제로 같은 방향인지 확인한다.

4.38 슬라이드 38 · 지금까지의 가격 항등식

현재의 낮은 가격은 미래 현금흐름에 대한 낮은 예상 또는 높은 할인율과 양립한다. 종목 특성이 높은 미래 수익률을 예측한다면 먼저 **어느 경로를 통해 가격과 연결되는지** 물어야 한다.

이전 절의 여섯 범주는 같은 항등식을 서로 다른 변수로 시험한다. 모멘텀은 정보 반응의 시간, 무형자산은 현금흐름 측정, 투자는 기업의 자본비용 선택을 특히 강조한다.

가격 항등식은 낮은 가격의 원인을 단독으로 식별하지 못한다. 높은 기대수익률과 낮은 예상 현금흐름이 동시에 가격을 낮출 수 있기 때문이다. 그래서 후속 실적, 분석가 전망, 나쁜 상태의 수익률을 결합한다. 같은 특성이 예측에 유용하다는 사실과 가격을 움직인 경제적 원인은 구별해야 한다.

4.39 슬라이드 39 · 네 가지 구별 질문

발표 뒤 수익이 줄어드는가, 이익이 매수 다리와 공매도 다리 중 어디에 있는가, 큰 유동주에도 남는가, 기업 특성보다 위험요인과의 공분산이 중요한가를 묻는다. 각각은 가격오류와 위험 보상에 대해 다른 힌트를 준다.

어느 질문도 혼자서 결정타가 되지는 않는다. 공매도 다리의 수익은 공매도 제약 때문에 과대평가가 오래 남는다는 해석과 맞지만, 그 종목의 높은 차입 비용이 이익을 지울 수도 있다.

공매도 다리의 성과가 크다면 과대평가가 오래 지속된다는 해석이 가능하지만, 실제 공매도가 비싸거나 불가능할 수도 있다. 큰 유동주에서도 효과가 남으면 초소형주의 가격 오류만으로 설명하기 어려워진다. 각 질문은 대안 설명을 하나씩 줄여 주는 역할이며 단독 결정타는 아니다.

4.40 슬라이드 40 · 판정표의 증거를 읽는 법

발견 이후 평균 룬숫 수익률이 감소했다는 연구, 투자자 심리가 높은 때 공매도 다리의 성과가 크다는 연구, 대형주에서도 모멘텀이 남는다는 연구는 서로 다른 증거를 제공한다. 기간과 전략 구성이 달라 숫자를 한 표에 놓고 직접 대소 비교하면 안 된다.

특성과 위험요인 노출을 분리한 실험도 표본에 민감하다. 표에서 유의한 결과가 있더라도 경제적으로 예상되는 방향, 다른 표본에서의 재현, 매매 가능성을 차례로 본다. McLean-Pontiff²¹는 발표 전후의 변화를 체계적으로 살핀다.

판정표의 결과를 비교할 때 '평균수익 감소'와 '알파 감소'를 구별한다. 시장과 기존 요인의 평균 수익이 바뀌면 원수익은 변해도 상대 알파는 남을 수 있다. 원 연구와 재검증 연구가 같은 포트폴리오와 기간을 썼는지 확인하고, 연구별 정의가 다르면 효과 크기보다 결과의 방향과 메커니즘을 비교한다.

4.41 슬라이드 41 · 예측자와 설명자의 목표

예측모형은 장부가치/시가총액이 다음 수익률을 맞힌다면 위험 때문인지 가격오류 때문인지 몰라도 사용할 수 있다. 그러나 투자자 행동이 바뀐 뒤에도 신호가 남을지 예측하려면 원인을 이해해야 한다.

또한 공공정책이나 규제 효과는 과거 상관만으로 평가하기 어렵다. 예측에 유용한 변수와 시장의 구조적 메커니즘을 구분하는 것이 수익률 연구의 두 과제다.

예측자는 위험인지 오류인지 몰라도 신호가 새 자료에서 남으면 사용할 수 있다. 그러나 시장 전체가 그 신호를 따라 거래하기 시작하면 가격과 예상 수익이 변한다. 구조적 설명은 바로 이런 환경 변화를 예측하려는 데 필요하다. 따라서 단기 예측 성능과 장기적 메커니즘 이해를 별도의 연구 목표로 둔다.

4.42 슬라이드 42 · 투자 CAPM의 최적화 유도

기업이 현재 자산 A 에 추가 투자 I 를 하고, 투자 한 단위의 조정비용이 투자율 I/A 에 따라 올라간다고 하자. 현재 총비용을 $I + (a/2)(I/A)^2 A$ 로 쓰면 I 에 대한 한계비용은 $1 + aI/A$ 다. 한계 투자에서 얻는 미래 이익 Π_1 의 현재가치를 $E[M_1 \Pi_1]$ 라 하면 최적화 조건은 다음과 같다.

$$1 + a \frac{I}{A} = E[M_1 \Pi_1].$$

²¹<https://doi.org/10.1111/jofi.12365>

위험과 할인인자를 단순화하여 한 기간 요구 총수익률 $1 + E[r]$ 로 현재가치를 표현하면 $E[M_1\Pi_1] \approx E[\Pi_1]/(1 + E[r])$ 다. 따라서 $1 + E[r] \approx E[\Pi_1]/(1 + aI/A)$ 다. 예상 수익성이 같다면 높은 투자는 낮은 요구수익률과, 투자율이 같다면 높은 예상 수익성은 높은 요구수익률과 연결된다. 이 최적화는 부호를 설명하지만 왜 할인율이 기업마다 다른지는 별도의 위험·시장 이론이 필요하다.

조정비용 $I + (a/2)I^2/A$ 를 I 로 미분하면 $1 + aI/A$ 가 나온다. 한계 프로젝트를 더 하려면 이 추가 비용과 할인한 한계 이익이 같아야 최적이다. 같은 $E[\Pi_1]$ 에서 I/A 가 높으면 식의 분모가 커져 단순화한 요구수익률은 낮아진다. 반대로 같은 투자율에서 기대 이익이 높으면 요구수익률이 높아질 수 있다.

4.43 슬라이드 43 · 특성과 공분산을 떼어 놓기

가치주가 높은 수익을 얻는 이유가 가치요인 HML에 대한 노출이라면, 장부가치/시가총액을 고정하고 HML 노출만 높은 종목은 더 높은 수익을 주어야 한다. 반대로 특성 자체가 중요하다면 노출 차이를 만들어도 수익 차이가 작을 수 있다.

실험은 규모와 가치 특성이 비슷한 종목 묶음 안에서 위험요인 노출로 다시 정렬한다. 이런 조건부 비교는 단순 상관보다 강하지만, 노출 추정의 잡음과 표본 기간에 민감하다. 서로 다른 장기 표본이 반대 결과를 내면 한 연구로 판정이 끝나지 않는다.

위험요인 베타는 과거 수익률과 요인 수익률의 공분산에서 추정하므로 잡음이 있다. 비슷한 가치 특성을 가진 종목 안에서 베타만 비교해도 베타 측정오차가 크면 진짜 위험 관계를 놓칠 수 있다. 특성과 베타를 분리하는 연구의 상반된 결과는 표본 기간·요인 정의·추정오차를 함께 읽어야 이해된다.

4.44 슬라이드 44 · 우연이라는 세 번째 설명

높은 수익률과 그럴듯한 이야기가 함께 있어도 많은 후보 가운데 운 좋게 발견된 결과일 수 있다. 논문에 실린 전략만 보면 실패한 시도는 보이지 않는다. 이 **선택된 표본의 문제**가 요인 동물원의 핵심이다.

가격오류와 위험 프리미엄을 논하기 전에 신호가 우연인지 검토해야 한다. 연구의 전체 탐색 과정, 관련 변수의 수, 독립 기간의 성적을 가능한 한 기록한다.

가령 연구자가 장부비율의 분모, 극단값 절단, 보유기간, 국가를 여러 번 바꿔 가장 큰 수익만 보고한다면, 표에 보이는 전략은 수많은 실패 후보 중 선택된 것이다. 원래의 t 값은 이 탐색을 보정하지 않는다. 사전 등록된 규칙이나 완전히 새로운 기간의 검증이 우연 설명을 줄이는 핵심이다.

4.45 슬라이드 45 · t 값 2의 의미가 바뀌는 순간

한 개의 사전 지정된 가설을 정규근사로 검정하면 $|t| > 1.96$ 은 양측 5% 수준이다. 하지만 효과가 0인 전략을 300개 시도하면 평균 약 15개가 그 기준을 넘을 수 있다. 가장 높은 값만 발표하면 독자는 300번의 탐색을 보지 못한다.

또한 t 값은 평균/표준오차이므로 경제적 크기와 다르다. 거래비용을 넘는 월수익률인지, 위기 손실을 감수할 만한지, 기간을 늘려도 같은 부호인지 따로 봐야 한다.

독립적인 참귀무가설 300개에서 각 검정의 거짓 양성 확률이 5%이면 거짓 발견 개수의 기대값은 $300 \times 0.05 = 15$ 다. 이는 '반드시 15개'가 아니라 반복 실험의 평균이다. 논문에 그중 가장 큰 통계량만 싣는다면 독자가 보는 표본은 전체 탐색의 무작위 표본이 아니다.

4.46 슬라이드 46 · 잡음 전략 300개의 모의실험

참 기대수익률이 모두 0인 300개 전략을 독립적으로 만들고 각 전략의 평균에 대한 t 값을 계산하면 히스토그램의 일부 막대가 우연히 2를 넘는다. 이때 발견된 '이상현상'은 모의실험 설계상 모두 거짓이다.

독립 가정이 현실에서는 성립하지 않아 15라는 기대 숫자가 그대로 맞지 않을 수 있다. 하지만 여러 번 시도한 뒤 큰 값만 고르면 거짓 발견이 생긴다는 원리는 변하지 않는다. 임계값을 높이거나 탐색되지 않은 자료로 다시 검정한다.

히스토그램에서 $t = 2$ 를 넘는 꼬리는 정규분포의 자연스러운 일부다. 그 안의 한 전략에 경제적인 이야기를 붙여도, 모의실험에서는 참효과가 0임을 이미 알고 있다. 반대로 현실에서는 참효과도 섞여 있으므로 모의실험의 교훈은 '모든 발견이 거짓'이 아니라 '이야기와 통계량만으로 진위를 판정할 수 없다'는 것이다.

4.47 슬라이드 47 · 진짜 전략 10개를 섞었을 때

잡음 290개 사이에 참 신호가 있는 전략 10개를 넣으면 낮은 임계값은 진짜도 많이 잡지만 거짓도 많이 포함한다. 높은 임계값은 거짓을 줄이는 대신 약한 참 신호를 놓친다. 이것이 검정력과 거짓 발견의 상충관계다.

정책 목적에 따라 기준이 달라진다. 수백 후보에서 연구할 만한 주제를 고르는 단계라면 거짓 발견 비율을 통제할 수 있고, 고객 자금을 큰 규모로 투입한다면 더 엄격한 독립 확인이 필요하다.

임계값을 올리면 거짓 양성이 줄지만 참 신호도 일부 빠진다. 참 신호가 약한 금융에서는 특히 큰 문제다. 연구 후보를 발굴하는 단계라면 넓게 찾고 나중에 독립 확인할 수 있지만, 고객 자금을 집행하는 단계에서는 거짓 양성의 비용이 커 더 엄격한 기준이 합리적일 수 있다.

4.48 슬라이드 48 · 왜 새 요인에는 더 높은 기준이 필요한가

발표된 요인이 수백 개라면 각 논문의 5% 유의성 기준을 그대로 유지하기 어렵다. Harvey-Liu-Zhu는 다중검정을 고려해 새 요인의 발견 기준을 대략 $t > 3$ 으로 높일 것을 제안했다.

숫자 3은 모든 연구에 똑같이 적용되는 자연상수가 아니다. 실제로 몇 번 시도했는지, 전략들 사이의 상관, 사전 가설의 강도에 따라 적절한 기준이 달라진다. 연구 원문²²의 수치는 요인 목록이 커질 때 기존 판정 규칙을 재고해야 함을 보여 준다.

$t > 3$ 이라는 제안은 탐색 규모가 커질수록 통상적인 $t \approx 2$ 로는 거짓 발견을 제어하기 어렵다는 신호다. 하지만 효과의 사전 가능성이 높은 소수의 이론 가설과 수백 개를 자동 탐색한 특성에는 같은 문턱을 적용할 필요가 없다. 검정 횟수와 상관 구조를 공개해야 적절한 문턱을 논의할 수 있다.

4.49 슬라이드 49 · 다중검정 규칙의 단계별 계산

M 개 검정에서 하나라도 거짓 양성이 생길 확률을 5% 이하로 두고 싶다면 합집합의 확률은 개별 확률의 합 이하라는 부등식을 쓴다. 각 검정을 α/M 에서 실시하면 전체 거짓 양성 확률은 최대 $M(\alpha/M) = \alpha$ 다. 이것이 본페로니 기준이다.

²²<https://doi.org/10.1093/rfs/hhv059>

$$P\left(\bigcup_{j=1}^M A_j\right) \leq \sum_{j=1}^M P(A_j), \quad p_j \leq \frac{\alpha}{M}.$$

Holm은 p 값을 작은 순서로 정렬해 $p_{(k)} \leq \alpha/(M - k + 1)$ 를 차례로 확인한다. Benjamini-Hochberg는 가족 전체에서 단 한 개의 오류도 허용하지 않는 대신, 발견된 것 가운데 거짓의 기대 비율을 통제한다. 독립 또는 특정 의존 조건 아래 최대 k 에 대해 $p_{(k)} \leq k\alpha/M$ 을 적용한다. 어떤 오류를 통제하려는지 먼저 정해야 방법을 고를 수 있다.

본페로니는 하나라도 틀린 발견을 막는 가족별 오류율을 통제하므로 보수적이다. Holm도 같은 목표지만 작은 p 값부터 순차적으로 비교해 보통 더 많은 발견을 허용한다. BH는 발견된 것 중 거짓의 기대 비중을 통제하므로 탐색 연구에 알맞을 수 있다. 예를 들어 100개 중 10개 발견의 FDR 5%는 매 실험마다 정확히 0.5개가 거짓이라는 뜻이 아니다.

4.50 슬라이드 50 · 재현 논쟁의 질문

한 연구는 대부분의 이상현상이 공통한 엄격한 조건에서 실패한다고 보고하고, 다른 연구는 상당수가 다양한 나라와 기간에서 남는다고 보고한다. 모순처럼 보이지만 “무엇을 같은 전략으로 볼지”와 “재현을 무엇으로 정의할지”가 다르다.

원 논문의 숫자 하나만 비교하는 대신 포트폴리오 가중, 소형주 처리, 알파의 기준모형, 변수 목록의 선택, 통계 기준을 나누어 보아야 한다.

재현율의 분모부터 다를 수 있다. 처음 발표된 모든 이상현상을 세는 연구와 사전에 경제적 주제로 걸러낸 요인만 세는 연구는 같은 비율을 비교하지 않는다. 분자 역시 원수익, CAPM 알파, 새 국가의 같은 부호 등으로 정의된다. 각 연구의 분자·분모를 명시하면 숫자가 왜 갈리는지 보인다.

4.51 슬라이드 51 · 많은 이상현상이 실패한다는 결과

Hou·Xue·Zhang은 여러 전략을 동일한 규칙으로 재구성하고 NYSE 종목의 크기를 기준으로 그룹을 나누며 시가총액 가중 수익률을 쓴다. 이 방식에서는 작은 기업이 종목 수에 비해 시장가치에서 차지하는 비중이 작으므로 그 효과가 전체 전략을 지배하기 어렵다.

상당수 신호가 통계적 기준을 넘지 못한다는 결과는 “어떤 수익 차이도 존재하지 않는다”가 아니다. 원래 동일가중·초소형주 중심의 차이는 있을 수 있으나 큰 자금을 운용하는 투자자가 얻을 수 있는 성과와는 다르다는 뜻이다.

NYSE 크기 기준으로 그룹을 만들면 매우 작은 종목들이 각 그룹의 경계를 임의로 정하지 못한다. 시가총액가중은 작은 종목의 큰 수익률이 전체 포트폴리오를 지배하지 않게 한다. 이는 큰 자금의 운용 가능성에 가까운 질문이지만, 소형주에서의 가격 형성 자체를 연구하려는 목적에는 다른 기준이 필요할 수 있다.

4.52 슬라이드 52 · 많은 요인이 재현된다는 결과

Jensen-Kelly-Pedersen은 요인을 더 적은 주제로 묶고 여러 나라의 자료까지 살펴 높은 재현율을 보고한다. 한 주제의 여러 변형은 완전히 독립된 20개 발견이 아니라 같은 잠재 효과에 대한 여러 측정일 수 있다.

이 관점에서는 관련 요인의 정보를 함께 쓰는 계층모형이 유용하다. 그러나 같은 잘못된 데이터 처리에서 나온 변형들이 서로를 강화할 위험도 있다. 발표 뒤와 다른 나라에서의 성과가 중요한 외부 확인이다. 연구 원문²³을 통해 비교 기준을 확인할 수 있다.

여러 나라에서 같은 방향이 반복되면 특정 미국 표본에만 맞춘 이야기보다 설득력이 생긴다. 그러나 회계 기준, 상장 요건, 자료 제공업체의 편향이 나라 사이에 공유될 수 있어 완전한 독립 실험은 아니다. 한 주제의 신호들이 비슷한 측정이라면 묶어서 추정하되, 묶음의 정의는 결과를 보기 전에 정해야 한다.

4.53 슬라이드 53 · 왜 판정이 갈리는가

원수익률 차이를 볼지 CAPM 알파를 볼지, 십분위와 삼분위 중 무엇을 쓸지, 소형주를 어떻게 제한할지, 전체 목록인지 이미 선별한 목록인지가 다르다. 또한 단일 요인마다 고정 임계값을 적용할지 주제별 증거를 함께 사용할지가 다르다.

따라서 두 재현율을 한 식에 넣어 평균내면 안 된다. 어떤 투자자에게 중요한 질문인지 정한 뒤 그에 맞는 구성 규칙과 손실함수를 택한다. 초소형주를 거래할 수 없는 기관투자자와 소규모 연구 포트폴리오의 답이 다를 수 있다.

기관투자자가 묻는 것은 '대형 유동주에서 비용 뒤에도 남는가'일 수 있고, 자산가격 연구자는 '작은 종목까지 포함해 어떤 평균수익 패턴이 존재하는가'를 물을 수 있다. 두 질문은 같은 데이터에서 다른 판정을 낳는다. 따라서 재현 논쟁을 읽을 때 한 연구의 숫자로 다른 연구를 단순 반박하지 않는다.

4.54 슬라이드 54 · 한 요인의 베이지안 축소를 유도하기

진짜 알파가 $\alpha \sim N(0, \tau^2)$ 이고 관측 추정치가 $\hat{\alpha} | \alpha \sim N(\alpha, \sigma^2/T)$ 라고 하자. 정규분포의 사전 밀도와 우도를 곱해 α 의 제곱항을 완전제곱하면 사후 평균은 정밀도 가중평균이 된다.

$$E[\alpha | \hat{\alpha}] = \frac{T/\sigma^2}{1/\tau^2 + T/\sigma^2} \hat{\alpha} = \frac{\tau^2}{\tau^2 + \sigma^2/T} \hat{\alpha}.$$

자료가 길어 T 가 크면 계수가 1에 가까워 관측치를 믿는다. 사전분포가 0 근처에 강하게 모이거나 추정 잡음이 크면 0에 더 가깝게 축소한다. 이는 능형회귀와 같은 추정오차를 줄이려는 논리가 요인 알파에도 적용된 것이다.

사후 평균의 가중치 $w = \tau^2/(\tau^2 + \sigma^2/T)$ 는 0과 1 사이에 있다. 예컨대 사전분산이 1이고 추정오차 분산이 3이면 $w = 1/4$ 이므로 관측 알파 4%는 사후 평균 1%로 줄어든다. 잡음이 큰 단일 요인의 눈에 띄는 성적을 그대로 미래 기대수익으로 쓰지 않는 수학적 이유다.

4.55 슬라이드 55 · 주제별 정보를 함께 쓰기

요인 i 의 참 알파를 해당 주제의 공통효과 $c_{j(i)}$ 와 요인 고유의 편차 w_i 의 합으로 둔다. $c_j \sim N(0, \tau_c^2)$, $w_i \sim N(0, \tau_w^2)$ 라는 가정은 주제 안의 요인들이 정보를 공유하도록 한다.

자료가 주제 평균을 강하게 지지하면 개별 요인은 같은 방향으로 일부 힘을 얻는다. 반대로 주제 전체가 약하면 우연히 큰 요인도 0 쪽으로 당겨진다. 이런 '정보 빌리기'는 유용하지만 주제 분류 자체가 틀리면 오히려 편향을 퍼뜨릴 수 있다.

²³<https://doi.org/10.1111/jofi.13249>

계층모형에서는 같은 주제의 다른 요인들이 공통효과 c_j 를 추정하는 데 도움을 준다. 가치 관련 요인 여러 개가 비슷한 방향이면 한 요인의 추정치가 흔들려도 주제의 평균 신호는 남을 수 있다. 반대로 연구자가 결과가 좋은 요인만 보고 주제를 만들었다면 '정보 빌리기'가 선택 편향을 퍼뜨릴 수 있다.

4.56 슬라이드 56 · 사후 판정과 82%의 해석

사후 평균을 0으로 축소하면 유의한 요인 수가 줄어들 수 있지만, 관련 요인의 정보를 함께 쓰면 사후 불확실성도 낮아진다. 두 효과가 상쇄되면 단순 알파 검정과 계층모형의 재현율이 비슷할 수 있다.

높은 재현율을 베이시안 방법만의 성과로 해석하지 말아야 한다. 선별된 요인 목록, CAPM 알파라는 목표, 고정된 높은 t 기준의 부재가 함께 작용한다. JKP의 연구²⁴를 읽을 때 이 선택을 따로 비교한다.

82% 같은 수치를 읽을 때는 '무엇의 82%인가'를 먼저 묻는다. 선택된 요인 목록의 CAPM 알파가 사후 기준을 넘은 비율인지, 원 논문의 모든 후보 중 비용 뒤 수익이 남은 비율인지는 완전히 다르다. 사후축소의 통계적 판정과 실제 투자 가능한 수익의 존재를 한 문장으로 합치지 않는다.

4.57 슬라이드 57 · 발표 뒤 수익의 감소

전략의 원 논문 표본, 표본 종료와 발표 사이, 발표 이후를 분리하면 감소가 언제 시작했는지 볼 수 있다. 표본 밖에서 이미 줄었다면 처음 추정값에 선택 편향이 있었을 수 있다. 발표 후 추가 감소는 투자자의 학습과 거래 경쟁에 부합한다.

하지만 평균 변화에 시대별 위험 프리미엄과 거래 가능 종목의 구성이 섞일 수 있다. 발표 후 성과가 양수로 남더라도 비용 뒤 이익이 남는지와 나쁜 상태의 위험은 별도 문제다.

논문 표본 종료와 공개 사이에도 전략 성과가 낮아졌다면 공개 때문에 경쟁이 늘었다는 설명은 그 부분에 적용되지 않는다. 반면 공개 이후 추가 하락은 모방 거래와 일치하지만 시장구조 변화도 가능하다. 세 구간의 평균뿐 아니라 유동성, 포지션 규모, 위험 노출의 변화를 나란히 보고 원인을 추적한다.

4.58 슬라이드 58 · 새 요인의 올바른 검정

새 요인을 파마.프렌치 3요인만 통제한 뒤 유의하다고 선언하면 이전에 발견된 많은 요인과 겹치는 정보를 '새로운' 것으로 착각할 수 있다. 전체 기존 요인을 모두 통제하면 변수 수가 너무 많고 상관이 높아 OLS가 불안정해진다.

정규화가 필요하지만, 관심 대상은 단순 예측점수가 아니라 새 요인의 독립적인 위험가격이다. 통제변수를 선택하는 방법이 그 계수의 편향을 만들지 않도록 설계해야 한다.

기존 요인이 많을수록 새 요인의 '추가 설명력'을 묻는 회귀에는 통제의 선택 문제가 생긴다. 너무 적게 넣으면 누락변수 편향, 모두 넣으면 높은 상관과 작은 표본으로 분산이 커진다. 다음의 이중 선택은 새 요인과 관련된 통제까지 보존하면서 이 둘 사이를 절충하려는 절차다.

²⁴<https://doi.org/10.1111/jofi.13249>

4.59 슬라이드 59 · 선택된 통제만 넣을 때의 편향

기존 요인 Z 가 평균수익률 y 에는 약하게 연결되더라도 새 요인 D 와 강하게 상관될 수 있다. Z 를 빠뜨리고 y 를 D 에만 회귀하면 D 가 Z 의 효과를 대신 가져간다. 이는 미시계량의 **누락변수 편향**과 같은 구조다.

한 번의 라쏘로 y 를 잘 예측하는 통제만 고르면 이런 Z 를 놓칠 수 있다. 새 요인의 독립성을 판단하려면 평균수익률을 설명하는 변수뿐 아니라 새 요인과 연결된 변수도 찾아야 한다.

단순한 식 $y = \theta D + \beta Z + u$ 에서 Z 를 빼면 D 의 계수는 $\theta + \beta \text{Cov}(D, Z) / \text{Var}(D)$ 가 된다. Z 의 y 예측력이 작아도 D 와 강하게 관련되면 새 요인의 계수에 편향이 남는다. 결과 변수만 예측하는 라쏘로 통제를 고르는 것이 충분하지 않은 이유다.

4.60 슬라이드 60 · 새 요인 15개의 비교

좁은 3요인 기준에서 유의하던 새 요인 중 일부는 기존 요인 전체를 적절히 통제하면 약해진다. 반대로 기존 요인과 구별되는 수익성 신호 등은 남을 수 있다. "유의하지 않음"은 효과가 정확히 0이라는 증거가 아니라 그 검정의 불확실성이 크다는 의미다.

표의 서로 다른 t 값은 같은 수익률을 서로 다른 통제집합 아래에서 측정한 것이다. 요인의 이름보다 어떤 위험을 추가로 설명하는지, 이전 요인과 얼마나 중복되는지 살핀다.

새 요인의 t 값이 통제집합을 넓히자 작아졌다면, 효과가 완전히 사라졌다고보다 기존 요인과 공유하던 부분이 제거됐을 수 있다. 반대로 표준오차가 커졌기 때문에 유의성만 잃었을 수도 있다. 계수 자체와 표준오차의 변화를 나눠 보고 어떤 기존 요인이 정보를 흡수했는지 살펴야 한다.

4.61 슬라이드 61 · 이중 선택의 세 단계

평균수익률 벡터를 $\bar{r}$, 기존 요인 노출 행렬을 C_h , 새 요인 노출을 C_g 라 하자. 첫 라쏘는 $\bar{r}$ 를 C_h 로 예측해 가격 결정에 중요한 통제 I_1 을 고른다. 둘째 라쏘는 C_g 를 C_h 로 예측해 새 요인과 상관된 통제 I_2 를 고른다.

$$I_1 = \text{supp arg min}_b \{ \|\bar{r} - C_h b\|^2 + \lambda_1 \|b\|_1 \}, \quad I_2 = \text{supp arg min}_c \{ \|C_g - C_h c\|^2 + \lambda_2 \|c\|_1 \}.$$

마지막에는 C_g 와 $I_1 \cup I_2$ 의 통제를 넣고 별점 없는 회귀로 새 요인의 계수를 추정한다. 둘째 선택이 빠지면 결과에는 약하지만 새 요인과 강하게 연결된 변수가 누락될 수 있다. Feng-Giglio-Xiu²⁵는 이중 선택을 요인 검정에 적용한다.

I_1 은 결과인 평균수익률을 설명하는 통제를 지키고, I_2 는 관심 요인 C_g 와 상관되어 누락편향을 만들 통제를 지킨다. 합집합으로 최종 회귀를 하는 이유는 두 조건 중 하나라도 충족하는 변수를 남기기 위해서다. 선택된 계수에 다시 별점을 주지 않는 마지막 단계가 관심 요인의 추정 편향을 줄인다.

4.62 슬라이드 62 · 다음 문제의 문턱

수백 기업 특성의 어느 조합이 다음 달 수익률을 가장 잘 예측하는가라는 질문이 남는다. 고전적 정렬과 회귀는 개별 신호의 경제적 의미를 보여 주지만 비선형 상호작용이 많으면 하나씩 시

²⁵<https://doi.org/10.1111/jofi.12883>

험하기 어렵다.

그렇다고 더 복잡한 알고리즘이 자동으로 답이 되는 것은 아니다. 앞 장의 시간 순서 검증과 이번 장의 다중검정-거래가능성 기준을 그대로 적용해야 한다.

다음 단계의 머신러닝에서는 후보 함수가 많아지므로 다중검정 문제가 더 커진다. 나무 깊이, 변수 조합, 학습 기간을 반복 조정하면서 가장 좋은 성과만 보고하면 새 요인을 수백 개 시도한 것과 같은 선택 문제가 생긴다. 시간상 뒤의 독립 기간을 남기는 규칙은 알고리즘이 바뀌어도 유지된다.

4.63 슬라이드 63 · 요인 논쟁을 예측 문제로 다시 쓰기

수학적으로 목표는 $E[r_{i,t+1} | X_{i,t}]$ 라는 조건부 평균 함수다. $X_{i,t}$ 에는 기업 규모, 장부비율, 모멘텀, 수익성 등 시점 t 에 알려진 특성이 들어간다. 선형 요인모형은 이 함수에 강한 구조 제약을 두는 한 방식이다.

유연한 머신러닝은 상호작용과 비선형성을 허용하지만 예측 함수의 경제적 설명과 과적합 통제가 더 중요해진다. 조건부 평균을 맞추는 것과 위험 프리미엄의 구조를 밝히는 것은 서로 다른 목표다.

조건부 평균 $E[r_{i,t+1} | X_{i,t}]$ 은 주어진 정보에서 제공오차를 최소화하는 최적 예측값이다. 그러나 투자자는 제공오차만 최소화하지 않고 위험과 거래비용을 고려한다. 또한 이 함수의 예측력만으로 어떤 위험의 가격인지 알 수 없다. 입력 특성의 발표 시점과 경제적 의미를 함께 관리해야 한다.

4.64 슬라이드 64 · 이미 시도한 정규화의 교훈

앞 장에서는 과거 수익률의 여러 시차와 제곱·세제곱을 넣어 능형회귀와 라쏘를 비교했다. OLS의 표본내 우수성이 검증자료에서는 유지되지 않았고, 계수 축소가 개선을 가져왔다. 이 결과는 새로운 특성 집합에도 같은 평가 규칙이 필요함을 보여 준다.

단, 이전의 입력은 과거 가격뿐이었다. 재무제표와 기업 특성이 추가되면 정보의 발표 시점, 산업별 측정 차이, 상장폐지 자료를 더 세심하게 다뤄야 한다.

기존 357개 가격 특징에 재무·텍스트 변수를 추가하면 변수 수만 늘어나는 것이 아니다. 자료의 발표 지연, 회계 개정, 산업별 결측이 새롭게 생긴다. 과거 가격의 지연값은 언제 관찰 가능한지 비교적 명확하지만 회계 특성은 공개 날짜가 중요하다. 같은 표본의 평가 절차라도 데이터 파이프라인을 다시 검증해야 한다.

4.65 슬라이드 65 · 횡단면 연구의 결론

기업 특성에서 룬솟 수익을 만드는 방법과 그 차이를 이상현상이라 부르는 조건을 구분했다. 모멘텀·가치·투자·수익성·무형자산·거래마찰은 평균수익률 패턴을 조직하는 언어이며, 위험 보상·가격오류·우연을 각각 시험해야 한다.

재현 논쟁은 자료와 질문의 정의가 결론을 바꾼다는 사실을 보여 준다. 새 요인은 기존의 많은 요인과 비교하고, 독립 기간과 거래비용 뒤에도 의미가 있는지 확인한다. 예측력의 발견은 엄격한 검증과 경제적 해석이 함께 갈 때 비로소 설득력을 갖는다.

횡단면 연구의 순서는 특성 정의 → 당시 이용 가능성 확인 → 정렬·회귀로 수익 차이 측정 → 기존 위험요인 통제 → 다른 기간·시장 재현 → 거래비용 후 평가다. 한 단계를 통과했다는 결과를

뒤 단계의 결론으로 앞당기지 않으면, 수백 요인의 목록도 서로 비교 가능한 경제적 증거로 정리할 수 있다.